



Pontificia Universidad
JAVERIANA
Cali

[VERGILADA MINEDUCACIÓN No. 1223 de 2010]

PONTIFICIA UNIVERSIDAD JAVERIANA CALI
FACULTAD DE INGENIERÍA Y CIENCIAS.
MAESTRÍA EN CIENCIA DE DATOS

Documento de Análisis Descriptivo y Exploratorio (EDA)

Etapas 3 — Entregable ejecutivo consolidado

Edwin Henao Ochoa
Cindy Lugo Roza
Edwin Silva Salas

DIRECTOR
Sandra Milena Ramírez Buelvas
Pontificia Universidad Javeriana

Contents

Resumen ejecutivo	1
1. Objetivo, alcance y fuentes de datos	1
1.1 Objetivo (OE2)	1
1.2 Universo analítico	1
1.3 Estructura del entregable	2
2. Calidad de datos (§5.3.1–5.3.2)	2
2.1 Datos faltantes	2
2.2 Valores extremos	2
3. Caracterización univariada (§5.3.3–5.3.4)	4
3.1 Estadísticos descriptivos	4
3.2 Análisis de distribución	4
4. Dinámica temporal y dataset de modelado (§5.3.5)	6
4.1 Serie territorial 2021–2025	6
4.2 Delimitación de D_{mod}	6
5. Patrones y visualización sobre D_{mod} (§5.3.6)	7
6. Correlación y asociación (§5.3.7)	10
7. Relaciones multivariadas (§5.3.8)	10
8. Segmentación exploratoria (§5.3.9)	14
9. Conclusiones y lineamientos para la Etapa 4 (§5.3.10)	16
9.1 Síntesis del EDA	16
9.2 Decisiones propuestas para modelado	16
9.3 Limitaciones reconocidas	16
Anexo A — Informes técnicos reproducibles	17

Resumen ejecutivo

Este documento consolida los hallazgos de la **Etapa 3 — Análisis descriptivo y exploratorio de datos (EDA)** del proyecto de predicción de indicadores de continuidad (*SAIDI / SAIFI*) en la red de distribución. El objetivo fue caracterizar la calidad del panel, diagnosticar distribuciones y extremos, identificar patrones temporales y espaciales, y evaluar asociaciones entre clima y operación para orientar la **Etapa 4 (modelado)**.

Hallazgos convergentes:

Área	Conclusión principal
Calidad	Panel diario con NA concentrados en clima (3,91 %); tabla agrupada sin faltantes
Distribución	Bloque operativo cero-inflado y de colas pesadas; precipitación semanal muy asimétrica
Temporal	Salto 2024–2025 explicado en gran parte por homogeneización OMS-SP7, no solo por operación
Dataset de modelado	$D_{\text{mod}} = 2024\text{--}2025$ (36 120 filas; 33 410 eventos; cobertura GIS 79,8 %)
Clima → eventos	Precipitación semanal: señal dominante ($\rho_{\text{Spearman}} \approx 0,41$)
Multivariado	Predictoras propuestas: precip, temp media, humedad y viento medio; respuesta: <code>n_eventos</code> (SAIFI)
Territorial	14,2 % de cuadrantes en nivel <i>Alta</i> ; 4 clusters espaciales; régimen lluvioso con mayor actividad

Recomendación para la Etapa 4: entrenar sobre D_{mod} con partición **2024 (entrenamiento) / 2025 (prueba)**, transformaciones $\log(1+x)$ donde aplique, subconjunto climático reducido y `n_eventos` como variable respuesta de frecuencia.

1. Objetivo, alcance y fuentes de datos

1.1 Objetivo (OE2)

Comprender el comportamiento de los datos e identificar patrones, relaciones y comportamientos relevantes que orienten las decisiones de modelado predictivo de continuidad del servicio.

1.2 Universo analítico

Table 1: Resumen operativo del dataset de modelado (data_agrupada_mod.csv)

Conjunto	Archivo	Horizonte	Grano	Uso en EDA
Panel consolidado	<code>data_consolidada.csv</code>	2021–2025	Activo × día	Calidad (faltantes, extremos)
Tabla agrupada D_{EDA}	<code>data_agrupada.csv</code>	2021–2025	Cuadrante × semana	§5.3.1–5.3.5 (90 128 filas)
Tabla de modelado D_{mod}	<code>data_agrupada_mod.csv</code>	2024–2025	Cuadrante × semana	§5.3.6–5.3.9 y Etapa 4 (36 120 filas)

Metrica	Valor
Filas (D_{mod})	36120.0
Cuadrantes	344.0
Semanas	105.0

Metrica	Valor
Total eventos	33410.0
Eventos 2024	15211.0
Eventos 2025	18199.0
Media eventos/semana	318.2

1.3 Estructura del entregable

Este informe ejecutivo sintetiza las subsecciones **5.3.1 a 5.3.10** del capítulo de Metodología. Cada bloque incluye conclusiones accionables y figuras representativas; el detalle reproducible (código, tablas completas) permanece en los informes técnicos enlazados al final.

2. Calidad de datos (§5.3.1–5.3.2)

2.1 Datos faltantes

Panel consolidado ($N = 87\,007\,074$; activo $\times$ día): la incompletitud se concentra en el bloque climático NASA POWER (3,91 % por variable meteorológica) y en ALTITUD (0,04 %). Variables operativas de interrupción sin NA. El 96,06 % de filas está completo.

Tabla agrupada ($N_{\text{agr}} = 90\,128$): **0 % de faltantes** en las 16 variables, coherente con `na.rm = TRUE` en la agregación semanal.




Figure 1: Porcentaje de NA por variable en el panel consolidado (§5.3.1).

Informe técnico	Enlace
Faltantes panel consolidado	identificacion_datos_faltantes.html

Informe técnico	Enlace
Faltantes tabla agrupada	missing_values_grouped.html

2.2 Valores extremos

Se aplicaron reglas IQR (1,5 y 3,0) y percentiles P1–P99.

- **Clima:** temperaturas y humedad con extremos escasos; **precipitación** con cola derecha (Tukey: 10,38 % diario; 8,98 % semanal) — valores operativamente plausibles.
- **Operativo:** dominancia de ceros (99,94 % días sin evento). En días/semanas con evento, colas pesadas; **duracion_total** con máximos que sugieren revisión puntual (no exclusión en EDA).

Informe técnico	Enlace
Extremos panel consolidado	detection_outliers.html
Extremos tabla agrupada	outliers_gruped.html

Implicación Etapa 4: tratamiento de incompletitud en panel diario; en D_{mod} no hay imputación por faltantes; evaluar winsorización o transformaciones para colas operativas.

3. Caracterización univariada (§5.3.3–5.3.4)

3.1 Estadísticos descriptivos

Sobre `data_agrupada.csv` ($N_{\text{agr}} = 90\,128$):

Clima semanal: distribuciones casi simétricas (CV 0,16–0,81), excepto **precip_total_semana** (mediana 618,8 mm; CV = 3,47; asimetría 30,6).

Operativo: mediana 0 en las cuatro métricas; **74,9 %** de semanas-cuadrante sin eventos. Con evento: **usuarios_afectados** hasta 69 928; **n_eventos** hasta 58 por semana-cuadrante.

Informe técnico	Enlace
Estadísticos descriptivos	calculado_estadistico_descriptivo.html

3.2 Análisis de distribución

Dos regímenes claros:

1. **Bloque climático estable**, con precipitación como excepción asimétrica (9,1 % de semanas con 0 mm).
2. **Bloque operativo cero-inflado** (72,5–74,9 % ceros) con curtosis elevada en semanas con evento.

Diagramas de caja — variables climáticas semanales

Data agrupada cuadrante x semana | N = 90,128 observaciones




Figure 2: Boxplots de variables climáticas — panel consolidado (§5.3.2).

Frecuencia de semanas-cuadrante segun actividad de eventos

Frecuencia absoluta y relativa (%)




Figure 3: Distribución de actividad semanal por cuadrante (§5.3.3).




Figure 4: Precipitación semanal: escala original vs $\log(1+x)$ (§5.3.4).




Figure 5: Proporción de ceros en variables operativas (§5.3.4).

La transformación $\log(1 + \text{precip})$ aproxima la precipitación a simetría; las variables operativas requieren modelos aptos para exceso de ceros (Poisson, ZIP, etc.).

Informe técnico	Enlace
Distribución de variables	distribucion_variables.html

4. Dinámica temporal y dataset de modelado (§5.3.5)

4.1 Serie territorial 2021–2025

- **262 semanas**; mediana 124,5 eventos/semana (media 188,5).
- Régimen bajo 2021–2023; incremento marcado desde 2024 (15 211 eventos) y 2025 (18 199).
- **Estacionalidad**: mayor actividad en meses de lluvias.
- **ACF**: rezago 1 = 0,92; componente anual (rezago 52 = 0,43).




Figure 6: Serie semanal de eventos con tendencia LOESS, 2021–2025 (§5.3.5).

4.2 Delimitación de D_{mod}

El salto temporal **no debe atribuirse solo a mayor actividad operativa**. La brecha código activo vs código de sitio (OMS-SPARD → OMS-SP7) explica cobertura GIS del 30 % (2021–2023) al 80–95 % (2024–2025).

Año	Cobertura inventario GIS	Eventos panel espacial
2021	30,5 %	5 167
2022	30,9 %	4 934
2023	31,7 %	5 845
2024	79,8 %	15 211
2025	95,0 %	18 199




Figure 7: ACF/PACF de la serie semanal territorial (§5.3.5).

D_{mod} : 2024–2025 $\rightarrow$ 36 120 filas, 344 cuadrantes, 105 semanas, 33 410 eventos. Partición natural: entrenamiento 2024 / prueba 2025.

Informe técnico	Enlace
Análisis temporal	analisis_temporal_eventos.html
Emparejamiento y D_{mod}	emparejamiento_eventos.html
Exportación D_{mod}	consolidado_data_mod.html

5. Patrones y visualización sobre D_{mod} (§5.3.6)

Análisis restringido a 2024–2025 con cobertura homogénea.

Temporal: media 318 eventos/semana; 287 (2024) $\rightarrow$ 350 (2025); ACF rezago 1 = 0,80; estacionalidad en meses lluviosos.

Espacial: top 10 cuadrantes concentran 20,5 % de eventos; 49 cuadrantes (14,2 %) en nivel *Alta*.

Clima–evento: asociación positiva precipitación–`n_eventos` visible en dispersión y correlaciones.

Informe técnico	Enlace
Patrones y visualización	identificacion_patrones.html

6. Correlación y asociación (§5.3.7)

Método: **Spearman** (datos asimétricos y cero-inflados). Universo: D_{mod} , 36 120 filas.

Redundancia operativa: ρ hasta 0,99 (`usuarios_afectados`–`elementos_afectados`).

Redundancia climática: 9 pares con $|\rho| \geq 0,70$ (temperaturas y vientos).

Clima $\rightarrow$ operativo:

8			
Par		ρ	p
precip	<code>n_eventos</code>	0,414	< 0,001
precip	<code>usuarios_afectados</code>	0,406	< 0,001




Figure 8: Cobertura anual emparejamiento evento–elemento vs panel espacial (§5.3.5).




Figure 9: Serie semanal de eventos en el dataset de modelado (Sección 5.3.6).




Figure 10: Estacionalidad mensual en el dataset de modelado (Sección 5.3.6).




Figure 11: Dispersion precipitacion semanal vs frecuencia de eventos (Sección 5.3.6).




Figure 12: Mapa de intensidad territorial y segmentación por actividad (§5.3.6).

7. Relaciones multivariadas (§5.3.8)

VIF (bloque climático completo): inflación crítica en temperaturas y vientos; `precip_total_semana` con VIF 1,05.

Subconjunto propuesto para modelado:

Variable	VIF
<code>temp_media_semana</code>	6,94
<code>humedad_media_semana</code>	3,44
<code>viento_medio_semana</code>	3,33
<code>precip_total_semana</code>	1,04

PCA clima: 81,3 % varianza en PC1–PC2; precipitación relativamente independiente.

Correlación parcial `precip` `n_eventos` (controlando `temp` y `viento`): $\rho = 0,43$.

GLM Poisson exploratorio: $\log(1+\text{precip})$ y `viento_medio` significativos ($p < 0,001$).

PCA operativo: PC1 concentra 83,8 % — justifica **una** respuesta principal: `n_eventos` (SAIFI) o `duracion_total` (SAIDI).

Informe técnico	Enlace
Evaluación multivariada	analisis_multivariado.html

8. Segmentación exploratoria (§5.3.9)

Niveles de actividad (cuadrantes con eventos; P50/P85):

Nivel	Cuadrantes	%
Baja	162	47,1
Media	113	32,8
Alta	49	14,2
Sin eventos	20	5,8

Correlacion de Spearman — clima y operativo

Submatriz combinada, D_mod panel completo




Figure 13: Mapa de calor clima-operativo (§5.3.7).




Figure 14: Barras: Spearman clima <U+2192> operativo (§5.3.7).




Figure 15: VIF del bloque climático (§5.3.8).




Figure 16: Dendrograma de variables climáticas (§5.3.8).




Figure 17: Coeficientes GLM Poisson exploratorio (§5.3.8).




Figure 18: Frecuencia de eventos por nivel de actividad del cuadrante (Seccion 5.3.9).




Figure 19: Clusters espaciales de cuadrantes (§5.3.9).

9. Conclusiones y lineamientos para la Etapa 4 (§5.3.10)

9.1 Síntesis del EDA

El análisis exploratorio sobre el panel cuadrante $\times$ semana permitió:

1. **Validar calidad** del insumo agregado y acotar el horizonte de modelado a periodos con trazabilidad GIS homogénea.
2. **Caracterizar distribuciones** que exigen transformaciones y modelos para conteos y exceso de ceros.
3. **Identificar persistencia temporal** y estacionalidad que respaldan rezagos y partición cronológica.
4. **Cuantificar la señal climática** de la precipitación sobre la frecuencia de interrupciones.
5. **Depurar redundancias** multivariadas y proponer un conjunto mínimo de predictoras.
6. **Documentar heterogeneidad territorial** para eventual estratificación o efectos espaciales.

9.2 Decisiones propuestas para modelado

Decisión	Propuesta
Universo de estimación	D_{mod} (2024–2025)
Partición	Entrenamiento 2024 / Prueba 2025
Variable respuesta (SAIFI)	<code>n_eventos</code>
Variable respuesta (SAIDI)	<code>duracion_total</code> (análisis complementario)
Predictoras climáticas	<code>precip_total_semana</code> , <code>temp_media_semana</code> , <code>humedad_media_semana</code> , <code>viento_medio_semana</code>
Excluir por redundancia	<code>temp_max/min</code> , <code>viento_max</code>
Transformaciones	$\log(1+x)$ en precipitación y bloque operativo según distribución
Rezagos / estacionalidad	Incorporar por ACF elevada (rezago 1 0,80–0,92)
Estratificación opcional	Nivel <i>Alta</i> o clusters C1–C2 para modelos por zona

9.3 Limitaciones reconocidas

- Los años 2021–2023 no son comparables en nivel absoluto por la brecha de codificación activo/sitio.
- El 63 % de filas en D_{mod} tiene `n_eventos` = 0; modelos deben contemplar inflación de ceros o enfoques de dos partes.
- Extremos de duración en días con evento requieren validación operativa antes de exclusiones.

Anexo A — Informes técnicos reproducibles

§	Tema	Informe
5.3.1	Datos faltantes (panel)	<code>identificacion_datos_faltantes.html</code>
5.3.1	Datos faltantes (agrupada)	<code>missing_values_grouped.html</code>
5.3.2	Valores extremos (panel)	<code>detection_outliers.html</code>
5.3.2	Valores extremos (agrupada)	<code>outliers_grouped.html</code>
5.3.3	Estadísticos descriptivos	<code>calculo_estadistico_descriptivo.html</code>
5.3.4	Distribución de variables	<code>distribucion_variables.html</code>

§	Tema	Informe
5.3.5	Análisis temporal	analisis_temporal_eventos.html
5.3.5	Emparejamiento / D_{mod}	emparejamiento_eventos.html
5.3.5	Materialización D_{mod}	consolidado_data_mod.html
5.3.6	Patrones y visualización	identificacion_patrones.html
5.3.7	Correlación	analisis_correlacion.html
5.3.8	Multivariado	analisis_multivariado.html
5.3.9	Segmentación	segmentacion_exploratoria.html

Documento generado de forma reproducible desde `Scripts/Edwin/EDA.Rmd`. Versión: 2026-06-29.