



Pontificia Universidad
JAVERIANA
Cali

[PONTIFICIA UNIVERSIDAD JAVERIANA No. 1220 de 2010]

PONTIFICIA UNIVERSIDAD JAVERIANA CALI
FACULTAD DE INGENIERÍA Y CIENCIAS.
MAESTRÍA EN CIENCIA DE DATOS

Documento de Análisis Descriptivo y Exploratorio (EDA)

Etapa 3 — Entregable ejecutivo consolidado

Edwin Silva Salas
Edwin Henao Ochoa
Cindy Lugo Roza

DIRECTOR
Sandra Milena Ramírez Buelvas
Pontificia Universidad Javeriana



Contents

Resumen ejecutivo	2
1. Objetivo, alcance y fuentes de datos	2
1.1 Objetivo (OE2)	2
1.2 Universo analítico	2
2. Calidad de datos (§5.3.1–5.3.2)	3
2.1 Datos faltantes	3
2.2 Valores extremos	3
Cómo se identificaron	3
Qué se encontró	4
Qué hacer en un caso real cuando un valor sale de lo normal	5
3. Caracterización univariada (§5.3.3–5.3.4)	6
3.1 Estadísticos descriptivos	6
3.2 Análisis de distribución	6
4. Dinámica temporal y dataset de modelado (§5.3.5)	8
4.1 Serie territorial 2021–2025	8
4.2 Delimitación de D_{mod}	10
5. Patrones y visualización sobre D_{mod} (§5.3.6)	11
6. Correlación y asociación (§5.3.7)	14
7. Relaciones multivariadas (§5.3.8)	16
8. Segmentación exploratoria (§5.3.9)	19
9. Conclusiones y lineamientos para la Etapa 4 (§5.3.10)	21
9.0 Valor para la empresa	21
9.1 Síntesis del EDA	22
9.2 Decisiones propuestas para modelado	22
9.3 Limitaciones reconocidas	22
10. Conclusiones generales	23

Resumen ejecutivo

Este documento consolida los hallazgos de la **Etapa 3 — Análisis descriptivo y exploratorio de datos (EDA)** del proyecto de predicción de indicadores de continuidad (*SAIDI* / *SAIFI*) en la red de distribución. El objetivo fue caracterizar la calidad del panel, diagnosticar distribuciones y extremos, identificar patrones temporales y espaciales, y evaluar asociaciones entre clima y operación para orientar la **Etapa 4 (modelado)**.

1. Objetivo, alcance y fuentes de datos

1.1 Objetivo (OE2)

Comprender el comportamiento de los datos e identificar patrones, relaciones y comportamientos relevantes que orienten a la toma de decisiones tanto para la empresa como para el modelado predictivo de continuidad del servicio.

1.2 Universo analítico

Table 1: Resumen operativo del dataset de modelado (data_agrupada_mod.csv)

Conjunto	Archivo	Horizonte	Grano	Uso en EDA
Panel consolidado	data consolidada.csv	2021–2025	Activo × día	Calidad (faltantes, extremos)
Tabla agrupada D_{EDA}	data agrupada.csv	2021–2025	Cuadrante × semana	§5.3.1–5.3.5 (90 128 filas)
Tabla de modelado D_{mod}	data agrupada mod.csv	2024–2025	Cuadrante × semana	§5.3.6–5.3.9 y Etapa 4 (36 120 filas)

Metrica	Valor
Filas (D_{mod})	36120.0
Cuadrantes	344.0
Semanas	105.0
Total eventos	33410.0
Eventos 2024	15211.0
Eventos 2025	18199.0
Media eventos/semana	318.2

2. Calidad de datos (§5.3.1–5.3.2)

2.1 Datos faltantes




Figure 1: Porcentaje de NA por variable en el panel consolidado (§5.3.1).

Qué muestra este gráfico. Cada barra representa una variable de la base de datos, y su longitud indica qué porcentaje de registros llega vacío (sin dato). En términos simples, es una “radiografía de la calidad de la información” con la que trabaja la empresa.

Qué revela. La gran mayoría de la información está completa: el **96 %** de los registros no tiene huecos. Los vacíos se concentran casi exclusivamente en las variables de **clima** (3,91 %), que provienen de una fuente externa (satélite NASA POWER), no de los sistemas internos. Las variables críticas del negocio —las que describen las interrupciones del servicio— **no presentan vacíos**.

Por qué le importa a la empresa. Confirma que los sistemas operativos (OMS, GIS) están registrando de forma confiable los eventos de interrupción; el riesgo de calidad de datos no está en la operación, sino en un insumo externo y secundario. Esto da **confianza para construir modelos predictivos** sin necesidad de costosos procesos de limpieza o de descartar grandes volúmenes de información. El hallazgo no evidente es que la calidad del dato **no es un obstáculo** para avanzar al modelado.

2.2 Valores extremos

Un **valor extremo** (o atípico) es una observación numérica que se aparta de la mayoría del conjunto según una regla estadística. **No implica automáticamente un error:** puede reflejar un evento operativo o climático real (p. ej. una semana de lluvia intensa o una interrupción de gran magnitud), o bien una inconsistencia de registro que debe validarse con el área de operación.

Cómo se identificaron

Sobre `data_agrupada.csv` ($N_{agr} = 90\,128$; cuadrante $\times$ semana) y, de forma complementaria, sobre el panel consolidado diario, se aplicaron **tres reglas univariadas** por variable:

Regla	Criterio	Interpretación
Tukey (IQR 1,5)	Fuera de $[Q_1 - 1,5 \text{ IQR}, Q_3 + 1,5 \text{ IQR}]$	Atípico moderado (criterio clásico de diagrama de caja)
Tukey ampliado (IQR 3,0)	Fuera de $[Q_1 - 3 \text{ IQR}, Q_3 + 3 \text{ IQR}]$	Atípico severo
Percentiles P1–P99	Por debajo del percentil 1 o por encima del percentil 99	Cola inferior o superior del 1 % de la distribución

En variables con **exceso de ceros** (semanas sin interrupción), $Q_1 = Q_3 = 0$ y la regla de Tukey sobre el total marca cualquier semana con evento como extrema; por ello el análisis operativo relevante se realiza sobre el subconjunto **semanas con evento** (valor > 0).

Qué se encontró

Bloque climático semanal

- Temperaturas, humedad y viento: extremos **escasos** bajo Tukey (0 %–0,03 %); distribuciones casi simétricas.
- **precip_total_semana**: **excepción** por acumulado semanal muy asimétrico — Tukey 1,5 marca el **8,98 %** de las semanas y el 3,0 el **4,51 %**; percentiles P1–P99 solo el **1,00 %**. Corresponde a **semanas de lluvia intensa plausibles**, no a errores de medición.

Bloque operativo (semanas con evento)

- Mediana de **usuarios_afectados**: 52 usuarios; **máximo: 69 928**.
- Mediana de **duracion_total**: 19,7 h; **máximo: 2 227 h** (~93 días acumulados en una semana), valor que **sugiere revisar** trazabilidad del registro.
- Tukey marca entre **11,6 % y 15,2 %** de las semanas con evento como extremas — proporción **esperable** en colas pesadas, no necesariamente errores.

Diagramas de caja — variables climáticas semanales

Data agrupada cuadrante x semana | N = 90,128 observaciones




Figure 2: Diagramas de caja de variables climaticas semanales en la tabla agrupada (Seccion 5.3.2).

Qué muestra este gráfico. Cada “caja” resume cómo se comporta una variable climática: la caja contiene la mitad central de los valores habituales, y los puntos que quedan por fuera son los **casos fuera de lo normal**. Es la forma visual de detectar qué tan dispersos o atípicos son los datos.

Qué revela. Temperatura, humedad y viento se comportan de forma **estable y predecible** (cajas compactas, pocos puntos fuera). La **precipitación** es la excepción: tiene una larga cola de valores altos, que corresponden a **semanas de lluvia intensa reales**, no a errores. Estos picos de lluvia son precisamente los que coinciden con mayor número de interrupciones.

Por qué le importa a la empresa. El gráfico señala que el principal factor climático de riesgo es la **lluvia extrema**, y que esos episodios son identificables con anticipación. El hallazgo no evidente es que la empresa puede **anticipar semanas de alto riesgo** mirando el pronóstico de precipitación, en lugar de reaccionar solo cuando las fallas ya ocurrieron.

Qué hacer en un caso real cuando un valor sale de lo normal

En operación y en el paso a modelado, se recomienda **no eliminar automáticamente** los extremos detectados en el EDA. El procedimiento sugerido es:

1. Clasificar el origen

- *Plausible operativo/climático:* precipitación alta en temporada de lluvias; pico de usuarios afectados en evento mayor; múltiples eventos en la misma semana-cuadrante.
- *Sospechoso de registro:* duraciones físicamente inverosímiles (p. ej. semanas con continuidad acumulada equivalente a meses), conteos negativos o saltos sin evento asociado en OMS.

2. Validar con fuente y negocio

- Contrastar con OMS, SCADA o GIS el identificador de evento, fechas y magnitud.
- Consultar al área de continuidad si el valor corresponde a un incidente conocido o a una regla de cálculo (p. ej. suma de duraciones de eventos solapados).

3. Decidir tratamiento (Etapa 4)

- **Mantener** si el extremo es real y representa el fenómeno a predecir.
- **Winsorizar o transformar** ($\log(1+x)$) si la cola distorsiona el modelo pero el dato es válido.
- **Corregir o excluir puntualmente** solo tras validación documentada (error confirmado de registro).
- **No aplicar** la regla de Tukey sobre el panel completo en variables cero-infladas; usar subconjunto con evento o modelos aptos para ceros (Poisson, ZIP, etc.).

En esta **Etapa 3** no se excluyeron ni transformaron observaciones: el objetivo fue **diagnosticar y documentar** para fundamentar las decisiones de la Etapa 4.

Informe técnico	Enlace
Extremos panel consolidado	detection_outliers.html
Extremos tabla agrupada	outliers_gruped.html

Implicación Etapa 4: definir reglas de winsorización, transformaciones o exclusión puntual solo para extremos validados; priorizar modelos que toleren colas pesadas y exceso de ceros en el bloque operativo.

3. Caracterización univariada (§5.3.3–5.3.4)

3.1 Estadísticos descriptivos

Sobre `data_agrupada.csv` ($N_{\text{agr}} = 90\,128$):

Clima semanal: distribuciones casi simétricas (CV 0,16–0,81), excepto `precip_total_semana` (mediana 618,8 mm; CV = 3,47; asimetría 30,6).

Operativo: mediana 0 en las cuatro métricas; **74,9 %** de semanas-cuadrante sin eventos. Con evento: usuarios_afectados hasta 69 928; n_eventos hasta 58 por semana-cuadrante.




Figure 3: Distribución de actividad semanal por cuadrante (§5.3.3).

Qué muestra este gráfico. Compara cuántas combinaciones de zona-semana tienen interrupciones frente a cuántas no tienen ninguna. Responde a la pregunta: ¿con qué frecuencia ocurren realmente las fallas en el territorio?

Qué revela. En cerca del **75 %** de las semanas-zona **no ocurre ninguna interrupción**. Las fallas no están repartidas de manera uniforme: se concentran en pocas zonas y pocas semanas. Cuando ocurren, su magnitud varía enormemente (desde unos pocos usuarios afectados hasta casi 70 000).

Por qué le importa a la empresa. Muestra que la afectación del servicio es un fenómeno **concentrado, no generalizado**. El hallazgo no evidente es que **dirigir recursos a todo el territorio por igual es ineficiente**: la mayor parte del esfuerzo de prevención debería enfocarse en el pequeño grupo de zonas y temporadas donde realmente se concentran los eventos.

Informe técnico	Enlace
Estadísticos descriptivos	calculo_estadistico_descriptivo.html

3.2 Análisis de distribución

Dos regímenes claros:

1. **Bloque climático estable**, con precipitación como excepción asimétrica (9,1 % de semanas con 0 mm).
2. **Bloque operativo cero-inflado** (72,5–74,9 % ceros) con curtosis elevada en semanas con evento.

La transformación $\log(1 + \text{precip})$ aproxima la precipitación a simetría; las variables operativas requieren modelos aptos para exceso de ceros (Poisson, ZIP, etc.).




Figure 4: Precipitación semanal: escala original vs $\log(1+x)$ (§5.3.4).

Qué muestra este gráfico. La forma de la distribución de la lluvia semanal: a la izquierda en su escala natural, a la derecha transformada para hacerla más legible. Indica si los valores se agrupan de forma equilibrada o si hay muchos casos pequeños y pocos muy grandes.

Qué revela. La lluvia tiene un patrón **muy desbalanceado**: muchísimas semanas con precipitación baja y unas pocas con valores extremadamente altos. Esos pocos episodios intensos son los que tienen mayor poder explicativo sobre las fallas.

Por qué le importa a la empresa. Confirma que **no todas las lluvias importan por igual**: el riesgo se dispara en los episodios excepcionales. El hallazgo no evidente es que basta con vigilar un número reducido de semanas críticas de lluvia para cubrir buena parte del riesgo operativo del año.




Figure 5: Proporción de ceros en variables operativas (§5.3.4).

Qué muestra este gráfico. Qué proporción de los registros operativos vale cero (sin interrupción) en cada variable del negocio.

Qué revela. Entre el **72 % y el 75 %** de los registros son ceros: la operación “normal” es que no haya fallas. Las interrupciones son eventos relativamente escasos pero de alto impacto cuando ocurren.

Por qué le importa a la empresa. Refuerza que la continuidad del servicio es, en general, buena, y que el reto está en **predecir los eventos poco frecuentes pero costosos**. El hallazgo no evidente es que cualquier herramienta de predicción debe diseñarse específicamente para detectar esos casos raros, no para describir el promedio.

Informe técnico	Enlace
Distribución de variables	distribucion_variables.html

4. Dinámica temporal y dataset de modelado (§5.3.5)

4.1 Serie territorial 2021–2025

- **262 semanas**; mediana 124,5 eventos/semana (media 188,5).
- Régimen bajo 2021–2023; incremento marcado desde 2024 (15 211 eventos) y 2025 (18 199).
- **Estacionalidad**: mayor actividad en meses de lluvias.
- **ACF**: rezago 1 = 0,92; componente anual (rezago 52 = 0,43).




Figure 6: Serie semanal de eventos con tendencia LOESS, 2021–2025 (§5.3.5).

Qué muestra este gráfico. La evolución semana a semana del número de interrupciones entre 2021 y 2025, con una línea de tendencia que suaviza los altibajos.

Qué revela. Se observa un **incremento marcado a partir de 2024**, además de subidas y bajadas que se repiten cada año (estacionalidad ligada a las temporadas de lluvia). Importante: parte de ese “salto” no significa que el servicio haya empeorado, sino que **a partir de 2024 se registran mucho mejor los eventos** (ver gráfico de cobertura más adelante).

Por qué le importa a la empresa. Permite distinguir entre un **deterioro real** y una **mejora en la captura del dato**. El hallazgo no evidente es que las comparaciones históricas de indicadores (SAIDI/SAIFI) antes y después de 2024 pueden ser engañosas si no se considera este cambio de registro, lo que tiene impacto directo en reportes regulatorios y metas internas.




Figure 7: ACF/PACF de la serie semanal territorial (§5.3.5).

Qué muestra este gráfico. Mide qué tanto se “parece” una semana a las semanas anteriores; es decir, si lo que pasó recientemente ayuda a anticipar lo que viene.

Qué revela. Existe una **fuerte memoria** en los datos: una semana con muchas fallas tiende a estar seguida por otra con comportamiento similar (correlación de 0,92 con la semana previa), y aparece también un patrón que se repite cada año.

Por qué le importa a la empresa. Confirma que el comportamiento de las fallas **es predecible** a partir de la historia reciente y del calendario. El hallazgo no evidente es que la empresa tiene una base sólida para **planear con anticipación** cuadrillas, materiales y mantenimiento, porque el futuro cercano se parece al pasado inmediato.

4.2 Delimitación de D_{mod}

El salto temporal **no debe atribuirse solo a mayor actividad operativa**. La brecha código activo vs código de sitio (OMS-SPARD $\rightarrow$ OMS-SP7) explica cobertura GIS del 30 % (2021–2023) al 80–95 % (2024–2025).

Año	Cobertura inventario GIS	Eventos panel espacial
2021	30,5 %	5 167
2022	30,9 %	4 934
2023	31,7 %	5 845
2024	79,8 %	15 211
2025	95,0 %	18 199

D_{mod} : 2024–2025 $\rightarrow$ 36 120 filas, 344 cuadrantes, 105 semanas, 33 410 eventos. Partición natural: entrenamiento 2024 / prueba 2025.




Figure 8: Cobertura anual emparejamiento evento–elemento vs panel espacial (§5.3.5).

Qué muestra este gráfico. Qué porcentaje de las fallas registradas se logró ubicar correctamente en el mapa (asociar a un activo y a una zona) en cada año.

Qué revela. Antes de 2024 solo se ubicaba alrededor del **30 %** de los eventos; a partir de 2024 la cobertura sube a **80–95 %**. Esto se debe a un cambio en la forma de codificar los activos (de OMS-SPARD a OMS-SP7), no a un cambio en la red.

Por qué le importa a la empresa. Este es uno de los hallazgos **más relevantes y menos visibles**: explica por qué los datos previos a 2024 no son comparables con los actuales. Por eso el análisis y el modelo se construyen sobre **2024–2025**, donde la información es confiable. La lección de negocio es clara: **la trazabilidad geográfica de las fallas mejoró drásticamente**, y mantener esa calidad de registro es clave para cualquier analítica futura.

Informe técnico	Enlace
Análisis temporal	analisis_temporal_eventos.html
Emparejamiento y D_{mod}	emparejamiento_eventos.html
Exportación D_{mod}	consolidado_data_mod.html

5. Patrones y visualización sobre D_{mod} (§5.3.6)

Análisis restringido a 2024–2025 con cobertura homogénea.

Temporal: media 318 eventos/semana; 287 (2024) → 350 (2025); ACF rezago 1 = 0,80; estacionalidad en meses lluviosos.

Espacial: top 10 cuadrantes concentran 20,5 % de eventos; 49 cuadrantes (14,2 %) en nivel *Alta*.

Clima–evento: asociación positiva precipitación–**n_eventos** visible en dispersión y correlaciones.




Figure 9: Serie semanal de eventos en el dataset de modelado (Seccion 5.3.6).

Qué muestra este gráfico. La evolución semanal de las interrupciones ya en el periodo confiable (2024–2025).

Qué revela. La actividad pasa de un promedio de **287 eventos semanales en 2024 a 350 en 2025**, con picos que coinciden con las temporadas de lluvia. La tendencia es de aumento sostenido.

Por qué le importa a la empresa. Aun con datos limpios y comparables, **la carga de eventos crece**. El hallazgo no evidente es que la presión sobre la operación va en aumento, lo que justifica invertir en capacidad predictiva y preventiva antes de que el crecimiento impacte los indicadores regulatorios.




Figure 10: Estacionalidad mensual en el dataset de modelado (Seccion 5.3.6).

Qué muestra este gráfico. Cómo se distribuyen las fallas a lo largo de los meses del año.

Qué revela. Hay meses claramente más críticos que otros, concentrados en las **temporadas de lluvia**. La diferencia entre meses tranquilos y meses pico es sustancial.

Por qué le importa a la empresa. Permite **planificar el año por temporadas**: reforzar cuadrillas, inventarios y disponibilidad en los meses de mayor riesgo, y optimizar costos en los meses tranquilos. El hallazgo no evidente es que la estacionalidad es lo bastante marcada como para construir un **calendario operativo basado en datos**.




Figure 11: Dispersion precipitacion semanal vs frecuencia de eventos (Seccion 5.3.6).

Qué muestra este gráfico. Cada punto es una semana-zona; se cruza cuánta lluvia cayó (eje horizontal) contra cuántas fallas hubo (eje vertical). Permite ver si más lluvia se asocia con más interrupciones.

Qué revela. La nube de puntos tiene una **inclinación ascendente**: a mayor precipitación, tiende a haber más eventos. La relación no es perfecta (hay otros factores), pero es consistente y estadísticamente sólida.

Por qué le importa a la empresa. Cuantifica, con datos propios, algo que operativamente se intuía: **la lluvia es el principal disparador climático de fallas**. El hallazgo no evidente es que esta relación es lo bastante fuerte como para usar el pronóstico de lluvia como **alerta temprana** de semanas de alta exigencia.




Figure 12: Mapa de intensidad territorial y segmentación por actividad (§5.3.6).

Qué muestra este gráfico. Un mapa del territorio donde el color/intensidad indica qué zonas acumulan más interrupciones.

Qué revela. Las fallas se **concentran geográficamente**: un grupo reducido de zonas explica una parte desproporcionada de los eventos (el top 10 de zonas concentra el 20,5 %).

Por qué le importa a la empresa. Identifica los “**puntos calientes**” de la red con nombre y ubicación. El hallazgo no evidente es que intervenir o modernizar ese pequeño conjunto de zonas críticas tendría un impacto mucho mayor en los indicadores que acciones distribuidas en toda la red.

Informe técnico	Enlace
Patrones y visualización	identificacion_patrones.html

6. Correlación y asociación (§5.3.7)

Método: **Spearman** (datos asimétricos y cero-inflados). Universo: D_{mod} , 36 120 filas.

Redundancia operativa: ρ hasta 0,99 (`usuarios_afectados`–`elementos_afectados`).

Redundancia climática: 9 pares con $|\rho| \geq 0,70$ (temperaturas y vientos).

Clima $\rightarrow$ operativo:

Par	ρ	p
precip n_eventos	0,414	< 0,001
precip usuarios_afectados	0,406	< 0,001
precip duracion_total	0,383	< 0,001
viento_medio n_eventos	0,135	< 0,001

Condicionado (`n_eventos` > 0; $n = 13\,351$): `precip n_eventos` se atenúa a $\rho = 0,29$ — parte de la señal está en la transición cero/no-cero.




Figure 13: Mapa de calor clima-operativo (§5.3.7).

Qué muestra este gráfico. Un “mapa de calor” donde cada celda indica qué tan relacionadas están dos variables: colores intensos significan relación fuerte; colores tenues, relación débil.

Qué revela. Dos cosas. Primero, varias variables operativas miden prácticamente **lo mismo** (relación cercana a 1), igual que varias climáticas entre sí. Segundo, la **precipitación** es la variable climática mejor relacionada con las fallas.

Por qué le importa a la empresa. El hallazgo no evidente es que **se está midiendo información redundante**: no se necesitan decenas de variables para entender el fenómeno, sino unas pocas bien elegidas. Esto simplifica tableros, reportes y modelos, y reduce el costo de gestionar datos que no aportan información nueva.




Figure 14: Barras: Spearman clima → operativo (§5.3.7).

Qué muestra este gráfico. Un ranking de qué factores climáticos influyen más sobre las interrupciones, ordenados de mayor a menor.

Qué revela. La **precipitación encabeza el ranking** con clara ventaja; el viento aporta de forma secundaria; temperatura y humedad tienen un papel menor.

Por qué le importa a la empresa. Prioriza dónde poner el foco: **vigilar la lluvia** es la palanca de mayor retorno para anticipar fallas. El hallazgo no evidente es que se puede construir un indicador de riesgo climático sencillo, centrado en precipitación, sin depender de modelos meteorológicos complejos.

Informe técnico	Enlace
Análisis de correlación	analisis_correlacion.html

7. Relaciones multivariadas (§5.3.8)

VIF (bloque climático completo): inflación crítica en temperaturas y vientos; `precip_total_semana` con VIF 1,05.

Subconjunto propuesto para modelado:

Variable	VIF
<code>temp_media_semana</code>	6,94
<code>humedad_media_semana</code>	3,44
<code>viento_medio_semana</code>	3,33
<code>precip_total_semana</code>	1,04

PCA clima: 81,3 % varianza en PC1–PC2; precipitación relativamente independiente.

Correlación parcial precip n_eventos (controlando temp y viento): $\rho = 0,43$.

GLM Poisson exploratorio: $\log(1+\text{precip})$ y viento medio significativos ($p < 0,001$).

PCA operativo: PC1 concentra 83,8 % — justifica **una** respuesta principal: n_eventos (SAIFI) o duracion_total (SAIDI).




Figure 15: VIF del bloque climático (§5.3.8).

Qué muestra este gráfico. Mide cuánta información “repetida” aporta cada variable climática respecto a las demás: barras altas indican que la variable dice casi lo mismo que otra ya incluida.

Qué revela. Algunas variables (varias temperaturas y vientos) son **redundantes entre sí**, mientras que la **precipitación aporta información única**.

Por qué le importa a la empresa. Justifica trabajar con un **conjunto reducido y limpio de variables**, sin perder capacidad de explicación. El hallazgo no evidente es que “más datos” no siempre es mejor: incluir variables redundantes puede confundir los modelos y encarecer su mantenimiento.




Figure 16: Dendrograma de variables climáticas (§5.3.8).

Qué muestra este gráfico. Un “árbol” que agrupa las variables climáticas por similitud: las que se unen antes son las más parecidas entre sí.

Qué revela. Las temperaturas forman un grupo, los vientos otro, y la **precipitación queda separada**, confirmando que mide algo distinto.

Por qué le importa a la empresa. Respalda visualmente la decisión de **quedarse con un representante de cada grupo** más la precipitación. El hallazgo no evidente es que la complejidad climática puede resumirse en pocas dimensiones independientes, lo que facilita la comunicación y la toma de decisiones.




Figure 17: Coeficientes GLM Poisson exploratorio (§5.3.8).

Qué muestra este gráfico. Un primer modelo exploratorio que estima el efecto de cada factor climático sobre el número de fallas: barras hacia la derecha aumentan el riesgo, hacia la izquierda lo reducen.

Qué revela. La **precipitación** y el **viento** salen como factores significativos que **incrementan** la cantidad esperada de eventos.

Por qué le importa a la empresa. Es la primera evidencia cuantitativa de que **el clima puede traducirse en una estimación de fallas esperadas**. El hallazgo no evidente es que ya existe una base estadística para pasar de “intuición operativa” a **predicción medible**, antesala del modelo definitivo de la siguiente etapa.

Informe técnico	Enlace
Evaluación multivariada	analisis_multivariado.html

8. Segmentación exploratoria (§5.3.9)

Niveles de actividad (cuadrantes con eventos; P50/P85):

Nivel	Cuadrantes	%
Baja	162	47,1
Media	113	32,8
Alta	49	14,2
Sin eventos	20	5,8

2024 vs 2025: ratio medio eventos 2025/2024 1,24–1,26 en todos los estratos.

Régimen lluvioso (P75): media n_{eventos} 2,01 vs 0,56 en semanas secas (Wilcoxon $p < 0,001$).

Clustering k-means ($k = 4$): hub extremo (C1, 1 cuadrante), cluster de alta severidad (C2, 41 cuadrantes), perfiles intermedios (C3–C4).




Figure 18: Frecuencia de eventos por nivel de actividad del cuadrante (Sección 5.3.9).

Qué muestra este gráfico. Clasifica las zonas en niveles (baja, media, alta actividad) y compara cuántas fallas concentra cada grupo.

Qué revela. Un 14,2 % de las zonas está en nivel “alta” y concentra una porción desproporcionada de los eventos, mientras casi la mitad tiene actividad baja. Además, las semanas lluviosas multiplican la frecuencia de fallas (2,01 vs 0,56 eventos en promedio frente a semanas secas).

Por qué le importa a la empresa. Ofrece un criterio objetivo para **priorizar inversión y mantenimiento** en las zonas que más lo necesitan. El hallazgo no evidente es que un plan focalizado en ese 14 % de zonas críticas podría mejorar los indicadores globales de continuidad de forma más rentable que cualquier acción generalizada.




Figure 19: Clusters espaciales de cuadrantes (§5.3.9).

Qué muestra este gráfico. Agrupa las zonas en perfiles con comportamiento similar (frecuencia y severidad de fallas) y los ubica en el mapa.

Qué revela. Surgen perfiles bien diferenciados: desde un “**punto crítico**” extremo (una zona excepcional), pasando por un grupo de **alta severidad** (41 zonas), hasta perfiles intermedios. No todas las zonas problemáticas lo son por la misma razón.

Por qué le importa a la empresa. Permite diseñar **estrategias diferenciadas por tipo de zona** en lugar de una sola receta. El hallazgo no evidente es que existe un caso atípico que merece atención individual, y un bloque de zonas severas que justifican un programa específico de intervención.

Informe técnico	Enlace
Segmentación exploratoria	segmentacion_exploratoria.html

9. Conclusiones y lineamientos para la Etapa 4 (§5.3.10)

9.0 Valor para la empresa

Más allá del detalle técnico, este análisis pone sobre la mesa cinco mensajes accionables para la organización:

1. **El dato operativo es confiable y la trazabilidad mejoró drásticamente desde 2024.** Esto habilita analítica avanzada sin grandes inversiones previas en limpieza, y obliga a leer con cuidado las comparaciones históricas de indicadores.
2. **Las fallas se concentran en pocas zonas y pocas semanas.** Focalizar recursos en los “puntos calientes” rinde mucho más que actuar sobre toda la red por igual.
3. **La lluvia es el principal disparador climático de interrupciones.** El pronóstico de precipitación puede convertirse en una **alerta temprana** de semanas de alto riesgo.
4. **El comportamiento de las fallas es predecible** (memoria semanal y estacionalidad clara), lo que permite planear cuadrillas, materiales y mantenimiento con anticipación.
5. **La carga de eventos está creciendo**, lo que da urgencia a pasar de un enfoque reactivo a uno **preventivo y predictivo**.

En conjunto, los gráficos no solo describen el pasado: revelan **dónde, cuándo y bajo qué condiciones** es más probable que el servicio se vea afectado, información que puede traducirse directamente en mejores indicadores de continuidad (SAIDI/SAIFI) y en una asignación más eficiente del presupuesto operativo.

9.1 Síntesis del EDA

El análisis exploratorio sobre el panel cuadrante $\times$ semana permitió:

1. **Validar calidad** del insumo agregado y acotar el horizonte de modelado a periodos con trazabilidad GIS homogénea.
2. **Caracterizar distribuciones** que exigen transformaciones y modelos para conteos y exceso de ceros.
3. **Identificar persistencia temporal** y estacionalidad que respaldan rezagos y partición cronológica.
4. **Cuantificar la señal climática** de la precipitación sobre la frecuencia de interrupciones.
5. **Depurar redundancias** multivariadas y proponer un conjunto mínimo de predictoras.
6. **Documentar heterogeneidad territorial** para eventual estratificación o efectos espaciales.

9.2 Decisiones propuestas para modelado

Decisión	Propuesta
Universo de estimación	D_{mod} (2024–2025)
Partición	Entrenamiento 2024 / Prueba 2025
Variable respuesta (SAIFI)	<code>n_eventos</code>
Variable respuesta (SAIDI)	<code>duracion_total</code> (análisis complementario)
Predictoras climáticas	<code>precip_total_semana</code> , <code>temp_media_semana</code> , <code>humedad_media_semana</code> , <code>viento_medio_semana</code>
Excluir por redundancia	<code>temp_max/min</code> , <code>viento_max</code>
Transformaciones	$\log(1+x)$ en precipitación y bloque operativo según distribución
Rezagos / estacionalidad	Incorporar por ACF elevada (rezago 1 0,80–0,92)
Estratificación opcional	Nivel <i>Alta</i> o clusters C1–C2 para modelos por zona

9.3 Limitaciones reconocidas

- Los años 2021–2023 no son comparables en nivel absoluto por la brecha de codificación activo/sitio.
- El 63 % de filas en D_{mod} tiene `n_eventos` = 0; modelos deben contemplar inflación de ceros o enfoques de dos partes.
- Extremos de duración en días con evento requieren validación operativa antes de exclusiones.

10. Conclusiones generales

El análisis descriptivo y exploratorio desarrollado en la Etapa 3 cumplió su propósito: **comprender el comportamiento de los datos de continuidad del servicio y extraer hallazgos accionables** que orientan tanto la gestión operativa como la construcción de modelos predictivos. Las conclusiones de mayor alcance son:

1. **La información del negocio es confiable y está lista para analítica avanzada.** El 96 % de los registros está completo y las variables operativas críticas no presentan vacíos. La trazabilidad geográfica de las fallas mejoró de forma decisiva (de ~30 % a 80–95 % de cobertura desde 2024), lo que define un horizonte sólido de trabajo (2024–2025) y exige prudencia al comparar indicadores históricos.
2. **Las interrupciones son un fenómeno concentrado, no generalizado.** En cerca del 75 % de las semanas-zona no ocurre ninguna falla, y un grupo reducido de zonas (14,2 % en nivel *Alta*; el top 10 concentra el 20,5 % de los eventos) explica una porción desproporcionada de la afectación. Esto abre la puerta a una **gestión focalizada** de mucho mayor retorno que las acciones distribuidas en toda la red.
3. **El clima —y en particular la lluvia— es el principal disparador externo de fallas.** La precipitación encabeza de forma consistente la relación con el número de eventos, su severidad y su duración. El pronóstico de lluvia puede convertirse en una **alerta temprana** de semanas de alta exigencia operativa.
4. **El comportamiento de las fallas es predecible.** La fuerte memoria semanal (correlación de 0,92 con la semana previa) y la estacionalidad marcada por las temporadas de lluvia permiten **planificar con anticipación** cuadrillas, materiales y mantenimiento, pasando de un esquema reactivo a uno preventivo.
5. **Menos variables, mejor información.** Buena parte de las variables disponibles aporta información redundante; un conjunto reducido (precipitación, temperatura media, humedad y viento medio) captura lo esencial, simplificando tableros, reportes y modelos y reduciendo el costo de gestión del dato.
6. **La carga de eventos está creciendo** (de ~287 a ~350 eventos semanales entre 2024 y 2025, ya con datos comparables), lo que aporta **urgencia** a la adopción de capacidades predictivas antes de que el incremento impacte los indicadores regulatorios.

Cierre. En síntesis, los datos no solo describen lo ocurrido: revelan **dónde, cuándo y bajo qué condiciones** es más probable que se afecte el servicio. Esta comprensión constituye la base para la **Etapa 4 (modelado predictivo)**, en la que estos hallazgos se traducirán en herramientas concretas para anticipar interrupciones, mejorar los indicadores de continuidad (SAIDI/SAIFI) y asignar el presupuesto operativo de manera más eficiente.