Pontificia Universidad Javeriana Cali
Facultad de Ingeniería y Ciencias
Maestría en Ciencia de Datos

Metodología Basada en Métodos de Ciencia de Datos para Pronosticar SAIDI y SAIFI en Redes de Distribución de una Empresa de Energía Eléctrica en el Norte de Santander

Proyecto aplicado para optar al título de Magíster en Ciencia de Datos

Edwin Henao Ochoa

Cindy Lugo Rozo

Edwin Silva Salas

Directora

Sandra Milena Ramírez Buelvas

Pontificia Universidad Javeriana

Santiago de Cali, 2026

A nuestras familias y amigos
Edwin Henao Ochoa
Cindy Lugo Rozo
Edwin Silva Salas

Índice general

Resumen xiv

Introducción **xv**

1 Definición del problema **1**
1.1 Planteamiento del problema 1
1.2 Formulación del problema 4

2 Objetivos del proyecto **5**
2.1 Objetivo general 5
2.2 Objetivos específicos 5

3 Marco de referencia **6**
3.1 Marco teórico 6
3.1.1 Contexto del estudio 6
3.1.2 Métodos y modelos 10
3.1.3 Modelos predictivos y espaciales 16
3.2 Antecedentes 20
3.2.1 Revisión de literatura 20
3.2.2 Antecedentes en Colombia y América Latina 24
3.2.3 Variables explicativas recurrentes en la literatura 27

4 Datos **30**
4.1 Construcción del dataset 30
4.1.1 Lógica estructural 30
4.1.2 Definición de variables de evento 31
4.1.3 Estructura del dataset consolidado 31
4.1.4 Variables incorporadas al panel cuadrante–semana 31
4.2 Procedencia de la información 33
4.3 Consideraciones éticas y disponibilidad de datos y código 34

5 Metodología **35**
5.1 Etapa 1 – Extracción de datos 35
5.1.1 Fuentes de información 36
5.1.2 Sistemas y fuentes consultadas 36

5.1.3 Extracción base y depuración de eventos de interrupción (BRAE) . . . 37
5.1.4 Extracción de afectación por evento . . . 38
5.1.5 Extracción del elemento causante histórico . . . 39
5.1.6 Extracción del elemento causante actual . . . 39
5.1.7 Extracción de inventario GIS . . . 40
5.1.8 Extracción de variables meteorológicas . . . 41
5.1.9 Resumen metodológico de extracción e integración de bases de datos . . . 42
5.2 Etapa 2 – Integración y depuración de datos . . . 42
5.2.1 Lógica de integración entre sistemas . . . 42
5.2.2 Diagrama de flujo de la secuencia de integración . . . 47
5.2.3 Descripción de la tabla base consolidada . . . 47
5.2.4 Descripción de las variables . . . 47
5.2.5 Agrupación de data consolidada por semana y cuadrante 49
5.2.6 Descripción de la tabla base semanal cuadrante . . . 52
5.2.7 Justificación y enriquecimiento del panel cuadrante–semana 54
5.2.8 Evidencia de calidad y confiabilidad de las fuentes . . . 61
5.3 Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA) . . . 62
5.4 Etapa 4 – Ingeniería de variables y preparación del modelo . . . 62
5.4.1 Construcción de variables predictoras . . . 64
5.4.2 Construcción de la variable respuesta . . . 66
5.4.3 Análisis de asociación y depuración de variables cuantitativas . . . 69
5.4.4 Análisis de asociación y depuración de variables cualitativas 70
5.4.5 Codificación de variables categóricas . . . 72
5.4.6 Estandarización de variables cuantitativas . . . 73
5.4.7 Generación de ventanas temporales . . . 73
5.4.8 Partición de datos en entrenamiento y prueba . . . 74
5.4.9 Construcción de matrices de diseño . . . 75
5.4.10 Reducción de dimensionalidad . . . 78
5.4.11 Segmentación analítica . . . 78
5.4.12 Transformaciones adicionales para modelado . . . 79
5.4.13 Resultados y entregables de la etapa . . . 80
5.5 Etapa 5 – Modelado predictivo y evaluativo . . . 81
5.5.1 Selección de algoritmos . . . 81
5.5.2 Entrenamiento del modelo . . . 82
5.5.3 Validación del modelo . . . 84
5.5.4 Ajuste de hiperparámetros . . . 85
5.5.5 Evaluación de desempeño . . . 86
5.5.6 Comparación de modelos . . . 88
5.5.7 Descomposición territorial del SAIDI . . . 89
5.5.8 Sensibilidad a la definición de vecindad . . . 90

5.5.9 Pronóstico incondicional de la afectación 90
5.5.10 Validación de la priorización territorial 91
5.5.11 Interpretación de resultados 91
5.5.12 Resultados y entregables de la etapa 92
5.6 Etapa 6 – Cierre metodológico, documentación y reportes 93
5.6.1 Presentación de resultados del modelo 93
5.6.2 Métricas de desempeño 93
5.6.3 Hallazgos principales 94
5.6.4 Interpretación técnica y operativa 94
5.6.5 Generación de reportes 95
5.6.6 Discusión de resultados 95
5.6.7 Limitaciones y trabajos futuros 95
5.6.8 Resultados y entregables de la etapa 96
5.7 Relación entre etapas metodológicas y objetivos específicos 96

6 Resultados **98**
6.1 Etapa 1 – Resultados de la extracción de datos 98
6.2 Etapa 2 – Resultados de la integración y depuración de datos . . . 98
6.3 Etapa 3 – Resultados del análisis descriptivo y exploratorio 100
6.3.1 Identificación de datos faltantes 100
6.3.2 Identificación de valores extremos en variables cuantitativas 102
6.3.3 Cálculo de estadísticos descriptivos 105
6.3.4 Análisis de la distribución de variables 107
6.3.5 Análisis temporal de eventos 109
6.3.6 Identificación de patrones, tendencias y visualización exploratoria 113
6.3.7 Análisis de correlación y asociación 116
6.3.8 Evaluación inicial de relaciones multivariadas 119
6.3.9 Segmentación exploratoria 122
6.3.10 Resultados y entregables de la etapa 123
6.3.11 Síntesis de los hallazgos del análisis exploratorio 125
6.4 Etapa 4 – Resultados de la ingeniería de variables 126
6.5 Etapa 5 – Resultados del modelado predictivo y evaluativo 128
6.5.1 Dependencia espacial 128
6.5.2 Muestra de evaluación 128
6.5.3 Pronóstico semanal frente a pronósticos de referencia . . . 129
6.5.4 Pronóstico de la ocurrencia de falla 133
6.5.5 Sensibilidad al clima extremo 136
6.5.6 Explicación estructural en corte transversal 136
6.5.7 Descomposición territorial del SAIDI 138
6.5.8 Variables más relevantes: triangulación entre modelos . . 140
6.5.9 Validación fuera de muestra de la priorización territorial . 142
6.6 Etapa 6 – Síntesis general y cierre frente a los objetivos 145

7 Discusión y trabajo futuro **148**
7.1 Discusión . . . 148
7.2 Trabajos futuros . . . 153

8 Conclusiones **155**
8.1 Conclusión asociada al objetivo general . . . 155
8.2 Conclusión asociada al objetivo específico 1 . . . 156
8.3 Conclusión asociada al objetivo específico 2 . . . 156
8.4 Conclusión asociada al objetivo específico 3 . . . 157
8.5 Recomendaciones para el operador de red . . . 157

A Anexos **166**
A.1 Diagrama de integración del panel . . . 166
A.2 Código de extracción de datos . . . 166
A.2.1 Consultas SQL . . . 166
A.2.2 Fragmentos Python . . . 168
A.3 Informes reproducibles (HTML) . . . 169
A.3.1 Consolidación del panel activo–día . . . 169
A.3.2 Agrupación cuadrante $\times$ semana . . . 169
A.3.3 Datos faltantes (tabla agrupada) . . . 169
A.3.4 Valores extremos (panel consolidado) . . . 169
A.3.5 Valores extremos (tabla agrupada) . . . 169
A.3.6 Estadísticos descriptivos . . . 169
A.3.7 Distribución de variables . . . 169
A.3.8 Análisis temporal de eventos . . . 169
A.3.9 Emparejamiento evento–elemento . . . 170
A.3.10 Materialización de D_{mod} . . . 170
A.3.11 Identificación de patrones . . . 170
A.3.12 Análisis de correlación . . . 170
A.3.13 Análisis multivariado . . . 170
A.3.14 Segmentación exploratoria . . . 170
A.3.15 EDA consolidado . . . 170
A.3.16 Asociación y depuración de variables cuantitativas . . . 170
A.3.17 Justificación de la agregación espacial . . . 170
A.3.18 Infraestructura eléctrica por cuadrante . . . 171
A.3.19 Estratificación municipal . . . 171
A.3.20 Sismicidad SGC . . . 171
A.3.21 Topología de red eléctrica . . . 171
A.3.22 Integración del panel final . . . 171
A.3.23 Cargue NASA POWER semanal . . . 171
A.3.24 Cargue de eventos semanales . . . 171
A.3.25 Unión del panel semanal . . . 171
A.3.26 Ingeniería de variables para SAIDI y SAIFI . . . 171
A.3.27 Incorporación y selección de rezagos . . . 172

A.3.28 Modelo espacial de SAIDI 172
A.3.29 Modelo espacial de SAIFI 172
A.3.30 Re-estimación final de la Etapa 5 172
A.3.31 Panel construido por evento 172
A.3.32 Indicadores de clima extremo 173
A.3.33 Validación fuera de muestra de la priorización territorial . 173
A.3.34 Pronóstico incondicional de la afectación 173
A.3.35 Descomposición territorial del SAIDI 173
A.3.36 Sensibilidad a la matriz de vecindad 173
A.3.37 Reporte técnico de priorización territorial 173
A.4 Catálogo de datos y métricas de integridad 173
A.5 Robustez de la construcción del indicador operativo 178
A.6 Artefactos reproducibles y reportes técnicos 179
A.7 Muestra completa de tablas base del proyecto 180
A.7.1 Tabla base consolidada (activo–día) 183
A.7.2 Tabla base semanal cuadrante 183
A.8 Figuras complementarias de completitud, extremos y localización territorial 183
A.9 Figuras complementarias del análisis exploratorio 185
A.10 Análisis de componentes principales (PCA) exploratorio 201
A.10.1 PCA exploratorio del bloque climático 201
A.10.2 PCA exploratorio del bloque operativo 202

Lista de figuras

5.1 Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. 5×2.5 km). 50
5.2 Distribución del número de elementos de infraestructura por cuadrante real. 55
5.3 Composición tipológica de infraestructura en los 30 cuadrantes con mayor número de elementos. 55
5.4 Mapa de cuadrantes según estrato socioeconómico predominante del municipio. 56
5.5 Distribución de cuadrantes por estrato predominante municipal. 57
5.6 Serie temporal de sismos considerados en la exposición territorial del panel. 57
5.7 Histograma de magnitudes de sismos integrados al panel cuadrante–semana. 58
5.8 Distribución de la longitud de red eléctrica por cuadrante. 59
5.9 Relación exploratoria entre longitud de red y $SAIDI$ por cuadrante. 59
5.10 Series temporales de $SAIDI$ y $SAIFI$ en el panel enriquecido cuadrante–semana. 60
5.11 Relación exploratoria entre NDVI semanal y $SAIDI$ en el panel enriquecido. 60
5.12 Asociación de Spearman entre candidatas *ex ante* y $SAIFI$ (año 2024 de D_{mod}, corte exploratorio previo a la partición final). . . . 70
5.13 Agrupamiento jerárquico de candidatas ($1-|\rho|$ Spearman); la línea punteada marca el umbral $|\rho| = 0.70$. 71
5.14 VIF del conjunto cuantitativo retenido tras la depuración iterativa (umbral 5). 71
5.15 Mapa de $SAIDI$ promedio por cuadrante usado en el diagnóstico de autocorrelación espacial (Moran). 83
5.16 Partición temporal entrenamiento/prueba para el modelado de $SAIDI$ (holdout $\approx 15\,\%$ final de semanas). 84

6.1 Proporción de ceros en las variables de severidad y continuidad de la tabla agrupada. 108

6.2 Comparación anual entre eventos BRAE y eventos reflejados en el panel espacial. Las etiquetas indican el porcentaje de cobertura respecto a BRAE; la brecha histórica se explica por la incompatibilidad entre el código de activo registrado en OMS-SPARD y el código de sitio del inventario GIS. 111
6.3 Evolución semanal de eventos sobre D_{mod} (2024–2025). 114
6.4 Persistencia y estructura temporal de la serie semanal de eventos en D_{mod}. 114
6.5 Intensidad territorial de eventos por cuadrante (2024–2025). . . . 115
6.6 Asociación de Spearman entre variables climáticas y operativas en D_{mod}. 117
6.7 Inflación de varianza en el bloque climático (modelo auxiliar `n_eventos` $\sim$ `clima`; D_{mod}). 120
6.8 Perfiles territoriales de cuadrantes según actividad y clima ($k = 4$; D_{mod}). 124
6.9 RMSE de validación interna del Random Forest de SAIDI según `mtry` y tamaño mínimo de nodo. 132
6.10 Confiabilidad de la probabilidad semanal de falla por decil en el periodo de prueba: Random Forest y tasa histórica del cuadrante. 134
6.11 Importancia por permutación de las predictoras en el Random Forest ajustado de SAIDI. 141
6.12 Importancia por permutación de las predictoras en el Random Forest ajustado de SAIFI. 141
6.13 SAIDI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1 + y)$). 143
6.14 SAIFI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1 + y)$). 143
6.15 Curva de captura de la afectación de 2025 según el criterio de priorización, para los primeros cien cuadrantes. Las líneas verticales punteadas señalan $k = 10$ y $k = 30$. 144

A.1 Estructura del panel de datos activo–día 166
A.2 Completitud del panel consolidado y extremos en variables diarias. 185
A.3 Extremos en variables agregadas y localización de los cuadrantes más activos. 186
A.4 Segmentación exploratoria de `n_eventos` por nivel de actividad y régimen de lluvia. 186
A.5 Distribución de las variables climáticas: forma y cola (muestra de $200\,000$ observaciones). 187
A.6 Distribución de la severidad y continuidad en días con evento: forma y cola. 187
A.7 Distribución de las variables climáticas semanales: forma y cola ($N_{\mathrm{agr}} = 90\,128$). 188

A.8 Distribución de la severidad y continuidad en semanas con evento: forma y cola. 188
A.9 Distribución de las variables numéricas de la tabla agrupada: forma y cola ($N_{\text{agr}} = 90\,128$). 189
A.10 Forma de la distribución de las variables climáticas semanales ($N_{\text{agr}} = 90\,128$). 189
A.11 Frecuencia de semanas-cuadrante según actividad de eventos ($N_{\text{agr}} = 90\,128$). 190
A.12 Distribución de la severidad y continuidad en escala logarítmica desplazada (semanas con evento). 190
A.13 Distribución de la precipitación acumulada semanal en escala original y logarítmica desplazada ($N_{\text{agr}} = 90\,128$). 191
A.14 Evolución semanal de los eventos de interrupción (suma territorial), 2021–2025. 191
A.15 Total anual de eventos de interrupción sobre la tabla agrupada. . 191
A.16 Distribución del total semanal de eventos según mes calendario (2021–2025). 192
A.17 Persistencia y estructura temporal de la serie semanal de eventos (rezagos en semanas). 192
A.18 Evolución semanal de usuarios afectados y duración acumulada. 193
A.19 Número de cuadrantes con al menos un evento por semana (extensión territorial de la actividad). 193
A.20 Estacionalidad mensual del total semanal de eventos en D_{mod}. . . 194
A.21 Quince cuadrantes con mayor número acumulado de eventos en D_{mod}. 194
A.22 Relación entre precipitación semanal y frecuencia de eventos por cuadrante en D_{mod}. 195
A.23 Segmentación de cuadrantes por nivel de actividad acumulada en D_{mod}. 195
A.24 Correlaciones de Spearman en el bloque climático semanal (D_{mod}). 196
A.25 Correlaciones de Spearman entre variables operativas en D_{mod}. . 196
A.26 Coeficientes de Spearman entre variables climáticas y operativas en D_{mod}. 197
A.27 Correlaciones de Spearman en semanas-cuadrante con `n_eventos` > 0 ($n = 13\,351$). 197
A.28 Agrupamiento de redundancias entre variables climáticas (Sección 3.1.2). 198
A.29 Efecto conjunto del clima reducido sobre la frecuencia de eventos (diagnóstico EDA). 198
A.30 Perfil normalizado por nivel de actividad (eventos, usuarios, duración, semanas activas, clima). 199
A.31 Eventos acumulados por nivel de actividad y año en D_{mod}. 199

A.32 Perfil medio por cluster de cuadrantes (variables operativas y climáticas). 200
A.33 Figuras del PCA exploratorio climático y operativo. 203

Lista de tablas

3.1 Síntesis de los antecedentes más relacionados con este trabajo . . 26

4.1 Estructura del dataset consolidado (grano activo × día). 32

5.1 Muestra de eventos depurados de interrupción (BRAE; primeras cinco filas) 37
5.2 Muestra de afectación por evento (BRAE + QA_TTC1; primeras cinco filas) 38
5.3 Muestra de elemento causante histórico (OMS SPARD; primeras cinco filas) 39
5.4 Muestra de elemento causante actual (OMS SP7; primeras cinco filas) 40
5.5 Muestra de inventario georreferenciado de activos (GIS GTECH; primeras cinco filas) 41
5.6 Muestra de variables meteorológicas (NASA POWER; primeras cinco filas) 42
5.7 Resumen metodológico de extracción e integración de bases de datos 43
5.8 Vista previa de la tabla base consolidada (grano activo–día) 47
5.9 Estructura de la tabla base semanal cuadrante (`data_agrupada.csv`). 53
5.10 Vista previa de la tabla base semanal cuadrante (grano cuadrante–semana) 54
5.11 Partición final de variables antes de la estimación: respuesta $\mathbf{y}$, predictoras $\mathbf{X}$, llaves y exclusiones 77
5.12 Correspondencia entre preguntas de sistematización, objetivos específicos y etapas metodológicas 97

6.1 Resumen de valores faltantes por variable en el panel consolidado 101
6.2 Valores extremos y dispersión relativa en variables climáticas (panel completo) 103
6.3 Valores extremos y dispersión relativa en severidad y continuidad (días con evento, valor > 0) 103

6.4 Valores extremos y dispersión relativa en variables climáticas semanales (tabla agrupada) . . . 104
6.5 Valores extremos y dispersión relativa en severidad y continuidad (semanas con evento, valor > 0) . . . 105
6.6 Estadísticos descriptivos de variables climáticas semanales (tabla agrupada) . . . 106
6.7 Estadísticos descriptivos de severidad y continuidad (tabla agrupada; panel completo) . . . 107
6.8 Distribución de frecuencias por actividad semanal del cuadrante 107
6.9 Cobertura anual de la trazabilidad al inventario GIS y al panel espacial. . . . 110
6.10 Asociación Spearman entre clima y variables operativas: pares de mayor magnitud (D_{mod}; panel completo) . . . 119
6.11 Inflación de varianza con subconjunto climático reducido propuesto para la Etapa 4 . . . 120
6.12 Flujo de inclusión de la muestra de magnitud (semanas con falla) 129
6.13 Desempeño en el conjunto de prueba para SAIDI (escala $\log(1+y)$; muestra común, $N = 2\,212$) . . . 129
6.14 Desempeño en el conjunto de prueba para SAIFI (escala $\log(1+y)$; muestra común, $N = 2\,212$) . . . 129
6.15 Diebold–Mariano semanal y mejora del RMSE con intervalo por remuestreo de bloques de semanas ($T = 16$) . . . 130
6.16 Ajuste de hiperparámetros del Random Forest: mejores configuraciones según la validación temporal interna . . . 131
6.17 Validación de origen móvil: RMSE en las doce semanas siguientes a cada corte (escala $\log(1 + y)$) . . . 132
6.18 Ocurrencia de falla en el periodo de prueba: discriminación, calibración y comparación con referencias ($N = 5\,504$) . . . 133
6.19 Captura semanal entre los k cuadrantes de mayor probabilidad de falla (promedio de las 16 semanas de prueba) . . . 134
6.20 Pronóstico incondicional de la afectación semanal sobre todas las semanas de prueba (escala original; $N = 5\,504$) . . . 135
6.21 Efecto de incorporar indicadores de clima extremo rezagados a la especificación *ex ante* . . . 136
6.22 Modelos de corte transversal ($N = 344$): comparación OLS, SAR y SEM y validación espacial . . . 137
6.23 Sensibilidad de los modelos espaciales de corte transversal a la matriz de vecindad . . . 138
6.24 Corte transversal de SAIDI promedio por cuadrante, OLS completo ($N = 344$; $R^2 = 0.890$) . . . 138
6.25 Corte transversal de SAIFI promedio por cuadrante, OLS completo ($N = 344$; $R^2 = 0.836$) . . . 139

6.26 Correlación de Spearman entre los factores estructurales del cuadrante y los componentes del SAIDI 139
6.27 Triangulación de la relevancia de las variables entre modelos . . . 140
6.28 Proporción de la afectación de 2025 capturada por los k primeros cuadrantes, según el criterio de priorización (%) 144
6.29 Síntesis de resultados por etapa metodológica 146
6.30 Cierre de resultados frente a los objetivos específicos 147

A.1 Catálogo de fuentes: cobertura, integridad y limitaciones 175
A.2 Diccionario de variables del panel de modelado cuadrante $\times$ semana 176
A.3 Trazabilidad de las variables candidatas: fuente, disponibilidad, transformación, decisión y uso 177
A.4 Diagnóstico de la tabla de eventos 2024–2025 y comparación entre el panel vigente y el panel construido por evento 179
A.5 Cuadrantes de prioridad A según su participación en la afectación de 2024–2025 181
A.6 Muestra de la tabla base consolidada (grano activo–día) – Parte 1: activo y fecha 181
A.7 Muestra de la tabla base consolidada (grano activo–día) – Parte 2: severidad y clima inicial (continuación) 181
A.8 Muestra de la tabla base consolidada (grano activo–día) – Parte 3: clima complementario (continuación) 182
A.9 Muestra de la tabla base consolidada (grano activo–día) – Parte 4: variables de continuidad (continuación) 182
A.10 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo 183
A.11 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 2: temperatura (continuación) 183
A.12 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación) 184
A.13 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación) 184
A.14 Cargas (loadings) del PCA climático: peso de cada variable por componente (D_{mod}; PC1–PC3) 202
A.15 Cargas (loadings) del PCA operativo en escala logarítmica desplazada (D_{mod}; PC1–PC2) 202

Resumen

La continuidad del servicio eléctrico en Colombia se mide con los indicadores SAIDI y SAIFI, cuyo incumplimiento genera compensaciones. En la empresa de distribución de Norte de Santander objeto de estudio, la información sobre interrupciones está dispersa en sistemas heterogéneos (BRAE, OMS, GIS) con codificaciones distintas, lo que impide identificar dónde y cuándo se concentra la afectación. Este trabajo desarrolló una metodología basada en CRISP-DM para pronosticar SAIDI y SAIFI por zona e identificar los factores técnicos, operativos y climáticos que más influyen en su comportamiento. Se integraron cinco sistemas corporativos y cuatro fuentes externas en un panel de 87 millones de registros activo $\times$ día, agregado a 344 cuadrantes $\times$ semana. El diagnóstico de integración reveló que solo el 31 % de los eventos de 2021–2023 podía vincularse a la red georreferenciada, frente al 95 % en 2025, por el uso de códigos de activo en lugar de códigos de sitio; por ello el modelado se restringió a 2024–2025. Se compararon modelos de panel (OLS agrupado, efectos fijos y Random Forest ajustado), un clasificador de ocurrencia de falla y modelos espaciales SAR y SEM, con validación temporal, predictoras disponibles antes de la semana pronosticada, dos pronósticos de referencia e inferencia por semanas. Los efectos fijos de cuadrante redujeron entre 21 y 26 % el error de la persistencia en la magnitud condicional a la falla, pero no se demostró una mejora sobre el promedio histórico de cada cuadrante; la ocurrencia de falla se pronosticó con un AUC de 0.84, capacidad que proviene sobre todo de la propensión histórica de cada cuadrante, y, combinada con la magnitud, mejoró en un 16 % el pronóstico de SAIDI frente a ese promedio. Los modelos de corte transversal explicaron entre el 84 y el 89 % de la variación territorial, con el tamaño y la longitud de la red como factores principales y la vegetación asociada a la duración de los eventos; el clima de la semana anterior no resultó significativo, ni siquiera medido como episodios extremos. Un orden de cuadrantes construido con 2024 concentró en diez de ellos el 60 % del SAIDI operativo de 2025. Se concluye que la afectación tiene un componente territorial estable y predecible, útil para priorizar el mantenimiento y anticipar fallas, y un componente de magnitud, una vez ocurre la falla, que no se logró pronosticar con estos datos y modelos. Los indicadores modelados son índices de severidad relativa y no los indicadores regulatorios. Los productos son un panel analítico trazable, un catálogo de datos, informes reproducibles y un prototipo de priorización territorial, cuyo beneficio operativo debe validarse en una prueba piloto.

Palabras clave: SAIDI; SAIFI; calidad del servicio eléctrico; panel espacio-temporal; Random Forest; econometría espacial; CRISP-DM.

Introducción

La energía eléctrica es un insumo esencial para el desarrollo social y económico de cualquier región. En Colombia, su prestación está sujeta a una regulación que exige a los operadores de red garantizar un suministro continuo, seguro y de calidad a hogares, instituciones y empresas [1]. La continuidad del servicio depende, sin embargo, de múltiples factores técnicos, ambientales y operativos que determinan cuántas interrupciones ocurren y cuánto tiempo duran.

Para medir esa continuidad, la Comisión de Regulación de Energía y Gas (CREG) adoptó mediante la Resolución CREG 015 de 2018 los indicadores SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) [1]. Estos indicadores sustentan la evaluación del desempeño de los operadores, el esquema de incentivos y compensaciones y la vigilancia que ejerce la Superintendencia de Servicios Públicos Domiciliarios (SSPD) [2].

La gestión de estos indicadores enfrenta dos dificultades. La primera es la heterogeneidad de los eventos que originan las interrupciones. La segunda es la dispersión de la información: los registros de interrupciones, de la red, de los usuarios, del mantenimiento y del clima se almacenan en sistemas distintos (SCADA, OMS, GIS, CIS y fuentes externas), con codificaciones y resoluciones temporales diferentes. Mientras esa información no se integre de forma trazable, no es posible construir modelos que pronostiquen SAIDI y SAIFI por zona ni identificar los factores que los explican, y las decisiones de inversión, mantenimiento y atención regulatoria se toman con una visión agregada que oculta dónde y cuándo se concentra la afectación.

Este trabajo desarrolló una metodología basada en ciencia de datos para pronosticar SAIDI y SAIFI por zona en una empresa de distribución de energía eléctrica del departamento de Norte de Santander, que atiende a más de 600 000 usuarios, e identificar los factores técnicos, operativos y climáticos que más influyen en su comportamiento. La metodología integró los sistemas corporativos de la empresa con fuentes externas de clima, vegetación, sismicidad y estratificación, construyó indicadores operativos por cuadrante y semana, y comparó modelos estadísticos, de aprendizaje automático y espaciales bajo una validación temporal estricta.

Las contribuciones del trabajo son cuatro. La primera es un panel espacio-temporal trazable, de cuadrante por semana, que integra eventos, red, usuarios, clima y exposición externa para una empresa colombiana de distribución. La segunda es la identificación y cuantificación de una falla de gobernanza de datos, la coexistencia de códigos de sitio y de activo en el sistema de gestión de interrupciones, que dejaba fuera del análisis territorial cerca del 70 % de los eventos de 2021–2023. La tercera es un esquema explícito de disponibilidad de la información, que separa las predictoras conocidas antes de la semana pronosticada de las variables de impacto posterior y evita así la fuga de información. La cuarta es una evaluación de modelos de pronóstico semanal, de ocurrencia de falla y espaciales frente a pronósticos de referencia explícitos, que delimita qué parte de la afectación es pronosticable con la información disponible (el nivel territorial y la ocurrencia de falla) y cuál no lo es (la magnitud de la afectación una vez ocurre la falla), y que se traduce en dos usos operativos validados fuera de muestra: la anticipación de las zonas con mayor probabilidad de falla y la priorización territorial del mantenimiento y la inversión.

El documento se organiza en ocho capítulos. El Capítulo 1 presenta el planteamiento y la formulación del problema, y el Capítulo 2, el objetivo general y los objetivos específicos. El Capítulo 3 desarrolla el marco teórico, con las definiciones regulatorias de SAIDI y SAIFI, sus exclusiones y los métodos empleados, junto con los antecedentes sobre la modelación de interrupciones e indicadores de confiabilidad. El Capítulo 4 describe las fuentes y la estructura de los datos. El Capítulo 5 detalla las seis etapas metodológicas, desde la extracción y la integración de los datos hasta el modelado y la generación de reportes. El Capítulo 6 presenta los resultados de cada etapa; el Capítulo 7 discute su alcance, sus aportes y sus limitaciones frente a cada objetivo, y el Capítulo 8 consolida las conclusiones y las recomendaciones para el operador de red.

1 Definición del problema

1.1. Planteamiento del problema

Los indicadores de continuidad del servicio SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) en la empresa de distribución objeto de estudio presentan dificultades estructurales para su mejora sostenida. Si bien existen técnicas estadísticas y de aprendizaje automático ampliamente documentadas para el análisis de interrupciones en sistemas eléctricos, la principal limitación no radica en la ausencia de metodologías analíticas, sino en la calidad, estructura e interpretación de los datos disponibles, lo que dificulta el entrenamiento de modelos predictivos que sean simultáneamente confiables y explicativos [1], [2], [3], [4]. En particular, resulta complejo detectar, cuantificar y explicar no solo las causas de las interrupciones, sino también su duración y los tiempos de restauración del servicio.

El objetivo predictivo de este trabajo son los indicadores $SAIFI$ y $SAIDI$ a escala de cuadrante $\times$ semana. Se construyen a partir de los registros operativos del panel, con el denominador de usuarios totales del operador (UT) tomado de la serie mensual `data_usuarios_totales_sistema.csv` y asignado a cada semana según el mes calendario de su fecha de inicio:

$$\begin{aligned} \mathrm{SAIFI}_{q,s} &= \frac{\texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \\ \mathrm{SAIDI}_{q,s} &= \frac{\texttt{duracion_total}_{q,s} \times \texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}. \end{aligned} \tag{1.1}$$

`n_eventos` y `duracion_total` permanecen como insumos de construcción y de historial *ex ante*; no constituyen las variables a predecir. `usuarios_afectados` entra en el numerador de Y, pero no como predictora contemporánea.

Los principales obstáculos identificados son los siguientes:

- **Fragmentación de las fuentes de información**: La operación del sistema requiere el uso de múltiples registros provenientes de plataformas hetero-

géneas como SCADA, OMS, GIS, CIS,[1] bases de mantenimiento y fuentes meteorológicas externas. Estos datos se encuentran en distintos formatos, con estructuras disímiles y, en algunos casos, con ausencia de metadatos completos, lo que dificulta su integración sin pérdida de trazabilidad [5], [6].

- **Problemas de sincronización temporal**: Los sistemas operativos no presentan una alineación temporal uniforme. Mientras algunos registran información en intervalos horarios, otros lo hacen en escalas de minutos o presentan series discontinuas. Esta falta de sincronización genera inconsistencias que afectan la estimación precisa de la duración de las interrupciones y de los tiempos de reposición del servicio [6].
- **Eventos extremos y ruido en los datos**: Los registros operativos de interrupciones eléctricas, provenientes de las plataformas mencionadas, contienen alta variabilidad, errores de captura, información incompleta y eventos atípicos, como fenómenos climáticos extremos o fallas excepcionales, que suelen ser excluidos del análisis. Esta situación dificulta la identificación de patrones robustos tanto a nivel agregado como local [1], [7].
- **Pérdida de detalle por agregación**: El uso de indicadores promediados en escalas anuales o geográficas amplias oculta el comportamiento específico de circuitos o zonas particulares, lo que limita la identificación de causas operativamente accionables [2], [6].
- **Ausencia de estándares de datos**: La falta de catálogos de datos, definiciones homogéneas y métricas de integridad impide evaluar de manera sistemática si las fuentes disponibles son adecuadas para la construcción de modelos predictivos confiables [5], [6].
- **Restricciones regulatorias**: Los organismos de control exigen que los resultados sean trazables y explicables. En consecuencia, no es suficiente emplear modelos con alto desempeño predictivo; estos deben ser interpretables y compatibles con los requerimientos de reporte regulatorio, lo que condiciona el tipo de metodologías que pueden adoptarse [2], [3].

Estos obstáculos reducen la capacidad de la organización para explicar la variación de los indicadores SAIDI y SAIFI, priorizar actividades operativas y cumplir con los requerimientos regulatorios mediante herramientas predictivas [3], [7].

[1] SCADA (*Supervisory Control and Data Acquisition*): sistema de supervisión y adquisición de datos de la operación de la red. OMS (*Outage Management System*): sistema de gestión de interrupciones. GIS (*Geographic Information System*): sistema de información geográfica de activos. CIS (*Customer Information System*): sistema de información de clientes.

En términos cuantitativos, el SAIDI promedio de la empresa es de 22.43 horas por año, valor que se ubica un 4.64 % por debajo de la meta establecida por la CREG (23.52 horas por año). Para el indicador SAIFI, el promedio anual es de 6.5 eventos, significativamente inferior al objetivo regulatorio de 9 eventos por año, lo que representa una reducción del 27.78 % [1]. Estos resultados sugieren que la empresa se encuentra dentro de los límites regulatorios; sin embargo, la gestión de dichos indicadores enfrenta importantes desafíos operativos e informativos.

Las compensaciones anuales asociadas a calidad del servicio ascienden aproximadamente a $5 mil millones de pesos, y el análisis de datos históricos de cinco años evidencia que cerca del 2 % de los registros presenta información faltante o inconsistente, como tiempos de evento no registrados, campos incompletos o desajustes temporales entre sistemas. Si bien la Circular 063 de 2019 de la CREG establece criterios técnicos para la exclusión válida de eventos asociados a factores externos, como fuerza mayor o fallas del Sistema Nacional de Transmisión, la presencia de problemas de calidad de datos limita la capacidad de construir modelos predictivos sólidos, diagnosticar con precisión las causas de las interrupciones y priorizar acciones operativas basadas en evidencia [1], [2], [3], [8].

Este problema no es exclusivo de la empresa analizada. En el sector eléctrico colombiano, la calidad del servicio constituye un desafío estructural. De acuerdo con el Informe de Calidad del Servicio de Energía Eléctrica 2023 de la SSPD, el SAIDI promedio nacional fue de 25.46 horas por usuario y el SAIFI de 16.72 interrupciones, con diferencias marcadas entre operadores de red y regiones geográficas [9, pp. 20–21, 37]. Esta dispersión refleja diferencias significativas en infraestructura, gestión operativa y exposición a condiciones climáticas extremas. Durante 2023, el 92.5 % de las interrupciones fue no programado y, entre los eventos excluidos del cálculo de los indicadores, el 36.25 % correspondió a catástrofes naturales, evidenciando la naturaleza multicausal del problema [9, pp. 13–14].

El impacto regulatorio es considerable: en 2023, nueve operadores de red superaron sus límites de SAIDI, y el deterioro del indicador frente a 2022 se explica por un aumento cercano al 14 % de los eventos no programados [9, pp. 18–19]. Para operadores de red ubicados en zonas con alta exposición climática, como Norte de Santander, la problemática se intensifica. En este contexto, la dispersión de información en sistemas heterogéneos dificulta la identificación de patrones causales, la priorización del mantenimiento preventivo y la detección temprana de circuitos críticos, limitando la capacidad de las empresas distribuidoras para anticipar deterioros en la continuidad del servicio y cumplir de manera consistente con los objetivos regulatorios establecidos por la CREG.

1.2. Formulación del problema

¿Cómo desarrollar una metodología basada en métodos de ciencia de datos para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de zonas en redes de distribución de una empresa de energía eléctrica, ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento?

A partir de la formulación anterior, se derivan las siguientes preguntas de sistematización:

- ¿Cómo consolidar un repositorio analítico unificado y trazable que integre SCADA, OMS, GIS, CIS, registros de mantenimiento y datos climáticos, acompañado de un catálogo de datos y métricas de calidad que permitan pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas?
- ¿Qué patrones temporales, espaciales, estacionales o comportamientos atípicos caracterizan la variabilidad de SAIDI y SAIFI a nivel de circuito, y de qué manera estos patrones influyen en la comprensión del fenómeno de continuidad del servicio eléctrico y en la identificación de los factores que explican sus fluctuaciones?
- ¿Qué modelos tienen mejor desempeño para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de circuito o zona?
- ¿Cómo construir artefactos reproducibles (notebooks, contenedores, documentación) y reportes técnicos alineados con los entregables del proyecto que faciliten la interpretación operativa y el uso de resultados en priorización de mantenimiento y reportes regulatorios?

2 Objetivos del proyecto

2.1. Objetivo general

Desarrollar una metodología basada en métodos de ciencia de datos para predecir los indicadores de calidad del servicio (SAIDI y SAIFI) en redes de distribución de una empresa de energía eléctrica ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento.

2.2. Objetivos específicos

1. Consolidar las fuentes de datos relevantes (SCADA/OMS, GIS, registros de fallas y mantenimientos, inventarios/SAC y datos climáticos), documentando su cobertura, calidad y limitaciones mediante un catálogo de datos y métricas de integridad.

2. Determinar qué variables operativas, técnicas y climáticas tienen mayor relevancia para predecir la duración y frecuencia de interrupciones (SAIDI y SAIFI) en la zona de estudio a partir de modelos estadísticos o de Machine Learning.

3. Evaluar el desempeño de diferentes métodos estadísticos o de Machine Learning para predecir SAIDI y SAIFI por circuito o zona, considerando la naturaleza de los datos y la interpretabilidad requerida por los gestores.

3 Marco de referencia

3.1. Marco teórico

3.1.1. Contexto del estudio

La calidad del servicio eléctrico comprende la entrega de energía de forma segura y eficiente, en cumplimiento de estándares regulatorios que garantizan continuidad, confiabilidad y estabilidad a usuarios residenciales, industriales, comerciales e institucionales. En Colombia, la CREG regula la prestación de este servicio esencial y ha establecido métricas y estándares para su seguimiento [1]. Entre ellas, el SAIDI y el SAIFI son las de mayor relevancia para la continuidad del suministro; su definición regulatoria se presenta a continuación.

1. *Definición del SAIDI según la Resolución CREG 015 de 2018:* La Resolución CREG 015 de 2018 define el SAIDI como se indica a continuación. En dicha normativa, el OR es el Operador de Red y el SDL es el Sistema de Distribución Local.

   > *La calidad media anual del OR se mide a través de los indicadores de duración y frecuencia de los eventos sucedidos en los SDL, que se establecen como se describe a continuación. El indicador SAIDI representa la duración total en horas de los eventos que en promedio percibe cada usuario del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:*

   $$SAIDI_{j,t} = \sum_{m=1}^{12} \frac{\sum_{i=1}^{n} (D_{i,u,m} \times NU_{i,u,m})}{UT_{j,m}} \frac{1}{60}, \qquad (3.1)$$

   donde:

   - $SAIDI_{j,t}$*: Indicador de duración promedio por usuario, de los eventos sucedidos en el SDL del OR* j*, durante el año* t*, medido en horas al año.*

- $D_{i,u,m}$: *Duración en minutos del evento i, sucedido durante el mes m, que afectó al activo u perteneciente al SDL del OR j.*
- $NU_{i,u,m}$: *Número de usuarios que fueron afectados por el evento i sucedido durante el mes m, conectados al activo u.*
- $UT_{j,m}$: *Número total de usuarios conectados al SDL del OR j en el mes m.*
- m: *Mes del año t, con enero $= 1, \ldots,$ diciembre $= 12$.*

2. *Definición del SAIFI según la Resolución CREG 015 de 2018:* La misma resolución define el *SAIFI* como:

   "El indicador SAIFI representa la cantidad total de los eventos que en promedio perciben todos los usuarios del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:"

$$SAIFI_{j,t} = \sum_{m=1}^{12} \frac{\sum_{i=1}^{n} NU_{i,u,m}}{UT_{j,m}}, \tag{3.2}$$

   donde:

   - $SAIFI_{j,t}$: *Indicador de frecuencia promedio por usuario, de los eventos sucedidos en el SDL del OR j, durante el año t, medido en cantidad al año.*
   - $NU_{i,u,m}$: *Número de usuarios que fueron afectados por el evento i sucedido durante el mes m, por encontrarse conectados al activo u.*
   - $UT_{j,m}$: *Número total de usuarios conectados al SDL del OR j en el mes m.*
   - m: *Mes del año t, con enero $= 1, \ldots,$ diciembre $= 12$.*

   Cada OR es responsable del cálculo de los indicadores de calidad del servicio. Para ello, debe utilizar la información reportada conforme a lo establecido en el numeral 5.2.11.3.2 de la Resolución CREG 015 de 2018, así como la información de vinculación definida en el literal a) del numeral 5.2.10 [1]. Esta disposición garantiza que el cálculo de los indicadores se realice con base en registros oficiales, trazables y consistentes con los lineamientos regulatorios vigentes.

3. *Interpretación de los indicadores:* Los indicadores SAIDI y SAIFI miden los *eventos* de interrupción del servicio eléctrico, entendidos como situaciones

en las cuales se presenta una pérdida total o parcial del suministro. Dependiendo de su causa y de los criterios regulatorios aplicables, ciertos eventos son incluidos en el cálculo de los indicadores, mientras que otros pueden ser excluidos conforme a la normativa vigente.

El SAIDI expresa el tiempo promedio durante el cual un usuario permanece sin servicio eléctrico en un período determinado. Por su parte, el SAIFI mide la frecuencia promedio con la que un usuario experimenta interrupciones en el mismo período. En conjunto, ambos indicadores permiten evaluar la continuidad y confiabilidad del sistema de distribución.

Desde una perspectiva operativa, valores elevados de SAIDI o SAIFI pueden reflejar deficiencias en el mantenimiento de la red, limitaciones en la infraestructura, obsolescencia tecnológica, fallas en los procedimientos operativos o una alta exposición a factores externos como condiciones climáticas adversas [11], [12]. En consecuencia, estos indicadores no solo describen el desempeño del sistema, sino que también permiten identificar áreas críticas que requieren intervención técnica o inversión en activos.

En el ámbito regulatorio, los OR deben reportar estos indicadores como métricas clave de desempeño y compararlos con las metas establecidas por la CREG. El cumplimiento de dichas metas está asociado a esquemas de remuneración por calidad del servicio, mientras que el incumplimiento puede dar lugar a ajustes tarifarios, obligaciones de reinversión o sanciones económicas [1], [8]. Por tanto, SAIDI y SAIFI no solo constituyen medidas técnicas de continuidad, sino también variables con impacto financiero y regulatorio significativo.

4. *Meta de calidad media del SAIDI:* La Resolución CREG 015 de 2018 establece que la meta de calidad media para el indicador de duración de los eventos en el Sistema de Distribución Local (SDL) de cada OR se determina con base en una expresión específica definida por la regulación. Formalmente, dicha meta se calcula mediante la siguiente formulación:

   > *"La meta para el indicador de duración de los eventos sucedidos en el SDL de cada OR se obtiene con base en la siguiente expresión:"*
   >
   > $$\text{SAIDI_M}_{j,t} = (1 - 0{,}08) \times \text{SAIDI_M}_{j,t-1}, \tag{3.3}$$
   >
   > *donde:*
   >
   > - $\text{SAIDI_M}_{j,t}$: *Meta del indicador de duración de eventos, en horas al año, a ser alcanzada por el OR j al finalizar el año t.*

- $\text{SAIDI_M}_{j,t-1}$: *Meta del indicador de duración de eventos, en horas al año, para el año* $t-1$. *Para el primer año de aplicación del esquema de calidad de cada OR esta variable será igual al indicador de referencia,* SAIDI_R_j.

5. *Dimensión social y económica:* Un servicio con interrupciones frecuentes o prolongadas reduce la productividad de las empresas, afecta la operación de instituciones comerciales e industriales y disminuye los ingresos del operador de red por el esquema de incentivos y compensaciones. Por ello, mejorar la gestión y la capacidad de pronóstico de SAIDI y SAIFI es un objetivo estratégico para los operadores y para la regulación del sector.

6. *Exclusiones de eventos:* La Resolución CREG 015 de 2018 excluye del cálculo de los indicadores un conjunto de eventos [1]. Este trabajo adopta las mismas exclusiones, de modo que los indicadores operativos se construyen sobre el mismo universo de eventos que el cálculo regulatorio (Sección 5.4.2). Las principales exclusiones son las siguientes:

   - Los menores o iguales a 3 minutos.
   - Los debidos a racionamientos programados.
   - Los causados por eventos de activos pertenecientes al Sistema de Transmisión Nacional (STN) y al Sistema de Transmisión Regional (STR).
   - Los eventos requeridos por seguridad ciudadana, solicitados por organismos de socorro o autoridades competentes.
   - Cuando se daña un activo de nivel de tensión 1 de propiedad del usuario.
   - Los debidos a catástrofes naturales.
   - Los debidos a actos de terrorismo.
   - Eventos originados en exigencias de traslados y adecuaciones de la infraestructura eléctrica.
   - Los eventos debidos a trabajos de reposición o modernización en subestaciones.
   - Las demás causales previstas en la resolución, que también se excluyen en este trabajo.

7. *Factores que afectan los indicadores:* La literatura identifica cuatro grupos de factores que deterioran los indicadores de calidad [5], [6], [12]:

- *Clima:* las tormentas eléctricas, los vientos fuertes y otros fenómenos meteorológicos pueden dañar la infraestructura de distribución y causar interrupciones.
- *Infraestructura:* el mantenimiento deficiente, la obsolescencia de los equipos y la falta de redundancia de la red aumentan la frecuencia y la duración de las interrupciones.
- *Gestión operativa:* la falta de planificación del mantenimiento, la ausencia de hojas de vida documentadas de redes y equipos, la respuesta lenta a las fallas y la saturación de la capacidad de atención deterioran los indicadores.
- *Información:* la fragmentación de los datos en distintos aplicativos dificulta el diagnóstico de las causas y el desarrollo de modelos predictivos confiables.

El análisis conjunto de estos factores permite fortalecer la confiabilidad de los procesos internos y orientar la gestión de los indicadores de calidad del operador de red de Norte de Santander.

3.1.2. Métodos y modelos

En este trabajo, la unidad de análisis del modelado es el par *cuadrante* $\times$ *semana* sobre D_{mod} (2024–2025). Para evitar *fuga de información* en el pronóstico, las variables del panel se separan en tres grupos mutuamente excluyentes según su disponibilidad temporal respecto de la semana t a predecir:

1. *Disponibles antes del periodo a pronosticar* (candidatas a predictoras): clima *rezagado* ($t-1, \ldots, t-h$) o *pronosticado* para t cuando exista un pronóstico operativo *ex ante*; histórico de eventos del cuadrante (y vecinos, si aplica); características del cuadrante (altitud, tipología de zona, número de activos, usuarios totales del inventario); estacionalidad y calendario; rezagos de Y o Y'. El clima contemporáneo de la semana t solo entra como predictora si está disponible *antes* de observar los eventos de t; en el EDA se usa como asociación descriptiva, no como garantía de usabilidad predictiva.

2. *Variables respuesta:* $Y = \text{SAIFI}$ y $Y' = \text{SAIDI}$, construidas en el grano cuadrante $\times$ semana como $\text{SAIFI} = \texttt{usuarios_afectados}/UT_m$ y $\text{SAIDI} = (\texttt{duracion_total} \times \texttt{usuarios_afectados})/UT_m$, donde UT_m es el número de usuarios totales del sistema en el mes m de la semana (serie `data_usuarios_totales_sistema.csv`). `n_eventos` y `duracion_total` son insumos de esa construcción y del historial *ex ante*, no las respuestas a predecir.

3. *Impacto posterior* (descriptivo / severidad): `usuarios_afectados` y `elementos_afectados` solo se conocen al ocurrir o cerrar el evento. `usuarios_afectados` entra en el numerador de Y y Y', pero *no* se emplea como predictora contemporánea. `elementos_afectados` queda restringido a la descripción de severidad. Análogamente, $\texttt{duracion_total}_t$ y $\texttt{n_eventos}_t$ contemporáneos no entran como covariables al pronosticar SAIDI_t o SAIFI_t.

El vector climático de referencia, sujeto a la regla de disponibilidad del grupo 1, es

$$\mathbf{x}_{q,s} = (P_{q,s},\ T_{q,s},\ H_{q,s},\ V_{q,s})^\top , \tag{3.4}$$

donde:

- $\mathbf{x}_{q,s}$: Vector climático del cuadrante q en la semana s.
- $P_{q,s}$: Precipitación total semanal, en mm (`precip_total_semana`).
- $T_{q,s}$: Temperatura media semanal, en °C (`temp_media_semana`).
- $H_{q,s}$: Humedad relativa media semanal, en % (`humedad_media_semana`).
- $V_{q,s}$: Velocidad media semanal del viento, en m/s (`viento_medio_semana`).

El vector se enriquece eventualmente con rezagos temporales de Y (o Y') y con términos de estratificación territorial. A continuación se formalizan los métodos empleados en el EDA y en la preparación y el modelado.

1. *Datos faltantes, tipos e imputación:* La proporción de faltantes de cada variable del panel se define como

$$p_j^{\mathrm{NA}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}\{X_{ij} = \mathrm{NA}\}, \tag{3.5}$$

donde:

- p_j^{NA}: Proporción de valores faltantes de la variable j.
- X_{ij}: Valor de la variable j en la observación i.
- N: Número de observaciones del panel.
- $\mathbf{1}\{\cdot\}$: Función indicadora, igual a 1 si se cumple la condición y 0 en otro caso.

En el panel activo × día, los `NA` se concentran en el bloque climático y en `ALTITUD`; en la tabla agregada cuadrante × semana (D_{EDA}, D_{mod}) no se

observan faltantes. Las reglas de imputación o exclusión se aplican en la Etapa 4 solo donde $p_j^{\mathrm{NA}} > 0$ en el grano de origen, conforme a los criterios de tratamiento de datos incompletos de [13].

2. *Dispersión relativa (coeficiente de variación):* Para comparar la variabilidad de variables cuantitativas con distintas unidades o escalas, se emplea el coeficiente de variación

$$\mathrm{CV}(X) = \frac{s_X}{\bar{x}}, \qquad \bar{x} \neq 0, \tag{3.6}$$

donde:

- $\mathrm{CV}(X)$: Coeficiente de variación de la variable X.
- s_X: Desviación estándar muestral de X.
- $\bar{x}$: Media muestral de X.

El CV solo es interpretable en variables medidas en escala de razón, con un cero absoluto (precipitación, viento, humedad relativa o conteos). En la temperatura expresada en grados Celsius el cero es arbitrario y el CV cambia con el origen de la escala, por lo que su dispersión se describe con la desviación estándar y el rango intercuartílico. Valores de CV cercanos a cero indican dispersión baja respecto a la media; valores $\mathrm{CV} \gtrsim 1$ señalan alta heterogeneidad relativa. En variables cero-infladas (p. ej. métricas de interrupción), el CV del panel completo queda inflado por la masa en cero, por lo que se reporta también el CV condicionado a observaciones con valor positivo.

3. *Análisis de atípicos y extremos:* Para una variable cuantitativa X, se emplean reglas basadas en cuartiles, siguiendo el criterio de rango intercuartílico propuesto por [14]. Se marcan como extremos candidatos los valores que cumplen

$$x \notin \left[Q_1 - k\,\mathrm{IQR},\ Q_3 + k\,\mathrm{IQR}\right], \tag{3.7}$$

donde:

- x: Valor observado de la variable X.
- Q_1, Q_3: Primer y tercer cuartil de X.
- IQR: Rango intercuartílico, $\mathrm{IQR} = Q_3 - Q_1$.
- k: Factor de amplitud, $k = 1.5$ (regla de Tukey) y, de forma complementaria, $k = 3.0$ (extremos más severos).

Estas reglas se contrastan con el criterio de percentiles P1–P99 sobre `n_eventos`, `duracion_total`, `usuarios_afectados` y `precip_total_semana`. El tratamiento definitivo (retención, winsorización o exclusión) se decide en la Etapa 4.

4. *Transformaciones de variables:* Ante asimetría y ceros, se usa la transformación logarítmica desplazada, caso límite de la familia de transformaciones de potencia de [15]:

$$T(x) = \log(1 + x), \qquad x \geq 0, \tag{3.8}$$

donde:

- $T(x)$: Valor transformado.
- x: Valor original, no negativo.

Se aplica en particular a `precip_total_semana` y al bloque operativo (`n_eventos`, `duracion_total`, `usuarios_afectados`, `elementos_afectados`) cuando se requieren densidades o PCA más estables. Para homogenizar variables con distintas unidades (p. ej. antes del PCA o del agrupamiento), se emplea la estandarización

$$z = \frac{x - \bar{x}}{s}, \tag{3.9}$$

donde:

- z: Valor estandarizado, con media 0 y desviación estándar 1.
- $\bar{x}$, s: Media y desviación estándar muestrales de la variable.

5. *Series de tiempo y sus características:* La función de autocorrelación (ACF) del total semanal de eventos en el rezago h es

$$\rho(h) = \frac{\mathrm{Cov}(E_t, E_{t-h})}{\mathrm{Var}(E_t)}, \tag{3.10}$$

donde:

- $\rho(h)$: Autocorrelación en el rezago h.
- E_t: Total semanal territorial de eventos en la semana t.
- h: Rezago, en semanas.

En D_{mod} se observa $\rho(1) \approx 0.80$, lo que motiva incorporar rezagos $E_{t-1}, \ldots, E_{t-h}$ (o de `n_eventos` a nivel cuadrante) como predictoras. La PACF complementa la identificación del orden autorregresivo [16]; la estacionalidad mensual se analiza agrupando E_t por mes calendario.

6. *Análisis de correlación:* Por la asimetría y la cero-inflación de las variables operativas, se emplea el coeficiente de correlación por rangos de [17]:

$$\rho_S(X, Y) = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n\,(n^2 - 1)}, \tag{3.11}$$

donde:

- $\rho_S(X, Y)$: Coeficiente de correlación de Spearman entre X y Y.
- d_i: Diferencia entre los rangos de X y Y en la observación i.
- n: Número de observaciones.

La expresión (3.11) es exacta solo en ausencia de empates. Con empates, frecuentes en este trabajo por la masa de ceros de las variables operativas, ρ_S se calcula como el coeficiente de correlación de Pearson entre los rangos promedio de X y de Y, que es el cálculo que realiza la función `cor(..., method = "spearman")` empleada en los informes. En D_{mod}, el par climático de mayor magnitud frente a `n_eventos` es (`viento_max_semana`, `n_eventos`) con $\rho_S \approx 0.14$, mientras el par de mayor interés conceptual, (`precip_total_semana`, `n_eventos`), alcanza $\rho_S \approx 0.07$. Entre variables cualitativas se emplea el estadístico V de Cramér [18]. Para el agrupamiento jerárquico de covariables se usa la distancia $d = 1 - |\rho_S|$.

7. *Datos de entrenamiento y prueba:* La partición es temporal (no aleatoria):

$$\begin{aligned} \mathcal{D}_{\text{train}} &= \{(i, t) : t \leq t^*\}, \\ \mathcal{D}_{\text{test}} &= \{(i, t) : t > t^*\}, \end{aligned} \tag{3.12}$$

donde:

- $\mathcal{D}_{\text{train}}$, $\mathcal{D}_{\text{test}}$: Conjuntos de entrenamiento y de prueba.
- (i, t): Observación del cuadrante i en la semana t.
- t^*: Semana de corte, ubicada en el percentil 85 de las semanas ordenadas de D_{mod} (8 de septiembre de 2025).

De este modo la prueba comprende las últimas 16 semanas de 2025 y ninguna semana de prueba precede a una de entrenamiento, lo que preserva el orden cronológico ante la autocorrelación de la serie [19], [20].

8. *Validación cruzada:* Cuando se ajusten hiperparámetros en $\mathcal{D}_{\text{train}}$, se prioriza validación *forward-chaining* (bloques temporales sucesivos) en lugar de k-fold aleatorio, para no romper la dependencia temporal de `n_eventos` [21].

9. *Análisis de componentes principales (PCA):* El PCA se emplea como herramienta *exploratoria* de redundancia, no como modelo predictivo final [22]. Requiere variables cuantitativas, preferiblemente homogenizadas (estandarización o transformación previa) y con $n \gg p$. Las componentes se obtienen al resolver

$$\mathbf{Z}^\top \mathbf{Z}\, \mathbf{v}_\ell = \lambda_\ell\, \mathbf{v}_\ell, \tag{3.13}$$

donde:

- $\mathbf{Z}$: Matriz del bloque climático estandarizado.
- $\mathbf{v}_\ell$: Vector propio (cargas) de la componente ℓ.
- λ_ℓ: Valor propio de la componente ℓ, proporcional a la varianza que explica.

Las componentes $\mathrm{PC}_\ell = \mathbf{Z}\mathbf{v}_\ell$ resumen ejes de covarianza (temperaturas y vientos frente a precipitación). La importancia de cada variable en la componente ℓ se lee mediante las cargas $v_{\ell j}$; en el EDA se interpretan como relevantes aquellas con $|v_{\ell j}| \geq 0.40$. Sobre el bloque operativo en escala $\log(1+x)$, PC1 concentra la covarianza común de frecuencia, afectación y duración.

10. *Métodos de agrupación:* Los cuadrantes se segmentan por actividad (cuantiles del total de `n_eventos`) y, de forma multivariada, por agrupamiento (p. ej. jerárquico [23] o k-means [24]) sobre perfiles de frecuencia, duración y clima, con el fin de estratificar el modelado en zonas de distinto riesgo operativo.

11. *Factor de inflación de la varianza (VIF):* Para cada predictora del bloque climático en un modelo auxiliar lineal de `n_eventos` sobre `x`,

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{3.14}$$

donde:

- VIF_j: Factor de inflación de la varianza de la predictora X_j.
- R_j^2: Coeficiente de determinación de la regresión de X_j sobre el resto de covariables [25].

Valores altos en `temp_max/temp_min` y `viento_max` motivan el subconjunto reducido $\mathbf{x}$ de la Ecuación (3.4) (VIF aceptables tras la depuración), teniendo en cuenta las advertencias sobre el uso mecánico de umbrales fijos señaladas por [26].

12. *Modelo lineal generalizado de Poisson (GLM Poisson):* Como modelo diagnóstico de conteos [27], [28]:

$$\begin{aligned} Y_i &\sim \text{Poisson}(\mu_i), \\ \log \mu_i &= \beta_0 + \boldsymbol{\beta}^\top \mathbf{x}_i^*, \end{aligned} \tag{3.15}$$

donde:

- Y_i: Número de eventos (`n_eventos`) en la observación cuadrante–semana i.
- μ_i: Tasa esperada de eventos de la observación i.
- β_0, $\boldsymbol{\beta}$: Intercepto y vector de coeficientes.
- $\mathbf{x}_i^*$: Vector de covariables, que incluye, entre otras, $\log(1 + P)$ y el viento medio estandarizado.

Los coeficientes $\hat{\beta}_j$ cuantifican el efecto multiplicativo $e^{\hat{\beta}_j}$ sobre la tasa esperada de interrupciones; este esquema orienta el modelado predictivo de la Etapa 5.

3.1.3. Modelos predictivos y espaciales

Sea $y_{q,s} = \log(1 + Y_{q,s})$, con $Y \in \{\text{SAIDI}, \text{SAIFI}\}$, la respuesta transformada del cuadrante $q = 1, \ldots, Q$ en la semana $s = 1, \ldots, S$, y $\mathbf{x}_{q,s} \in \mathbb{R}^p$ el vector de predictoras disponibles *ex ante*.

1. *Mínimos cuadrados agrupados (Pooled OLS).* Supone un intercepto común a todos los cuadrantes:

$$y_{q,s} = \alpha + \mathbf{x}_{q,s}^\top \boldsymbol{\beta} + \varepsilon_{q,s}, \tag{3.16}$$

donde:

- $y_{q,s}$: Respuesta transformada del cuadrante q en la semana s.
- α: Intercepto común.
- $\boldsymbol{\beta}$: Vector de coeficientes de las predictoras.

- $\varepsilon_{q,s}$: Término de error.

2. *Efectos fijos de cuadrante (FE).* Permite un intercepto propio por cuadrante, que absorbe la heterogeneidad no observada invariante en el tiempo [29]:

$$y_{q,s} = \mu_q + \mathbf{x}_{q,s}^{\top}\boldsymbol{\beta} + \varepsilon_{q,s}, \tag{3.17}$$

donde:

- μ_q: Efecto fijo (intercepto propio) del cuadrante q.
- $y_{q,s}$, $\mathbf{x}_{q,s}$, $\boldsymbol{\beta}$, $\varepsilon_{q,s}$: Como en la Ecuación (3.16).

El modelo se estima mediante la transformación *within*, $\ddot{y}_{q,s} = y_{q,s} - \bar{y}_q$, que elimina μ_q; por ello los atributos constantes del cuadrante no son identificables en esta especificación. La versión con efectos fijos de cuadrante y semana añade un término τ_s común a todos los cuadrantes en la semana s. Dado que los residuos de un mismo cuadrante están autocorrelacionados, la inferencia se basa en errores estándar agrupados por cuadrante.

3. *Random Forest (RF).* Promedia árboles de regresión entrenados sobre muestras *bootstrap*, eligiendo en cada partición entre `mtry` predictoras tomadas al azar [30]:

$$\hat{f}(\mathbf{x}) = \frac{1}{B}\sum_{b=1}^{B} T_b(\mathbf{x}), \tag{3.18}$$

donde:

- $\hat{f}(\mathbf{x})$: Predicción del bosque para el vector de predictoras $\mathbf{x}$.
- B: Número de árboles.
- $T_b(\mathbf{x})$: Predicción del árbol b.

Las observaciones no incluidas en cada muestra (*out-of-bag*, OOB) permiten una estimación interna del error. En un panel con dependencia temporal, el muestreo con reemplazo mezcla semanas próximas entre la muestra y las observaciones OOB, de modo que ese error tiende a ser optimista; en este trabajo se usa solo como diagnóstico complementario, y la selección de hiperparámetros y la evaluación se basan en particiones temporales. La importancia de la variable j (%IncMSE) es el aumento porcentual del error cuadrático medio OOB cuando se permutan aleatoriamente sus valores. Los hiperparámetros `mtry` y tamaño mínimo de nodo terminal se ajustan siguiendo [31].

4. *Índice de Moran.* Mide la autocorrelación espacial de una variable [32]:

$$I = \frac{n}{S_0} \frac{\sum_i \sum_j w_{ij}\, z_i z_j}{\sum_i z_i^2}, \qquad S_0 = \sum_i \sum_j w_{ij}, \tag{3.19}$$

donde:

- I: Índice de Moran.
- n: Número de cuadrantes.
- w_{ij}: Peso espacial entre los cuadrantes i y j, elemento de la matriz $\mathbf{W} = [w_{ij}]$ normalizada por filas.
- z_i: Valor centrado de la variable en el cuadrante i.
- S_0: Suma de todos los pesos espaciales.

Valores positivos y significativos indican que cuadrantes vecinos presentan valores similares.

5. *Modelo de rezago espacial (SAR).* La respuesta de un cuadrante depende directamente de la de sus vecinos [33], [34]:

$$\begin{aligned} \mathbf{y} &= \rho\, \mathbf{W}\mathbf{y} + \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \\ \boldsymbol{\varepsilon} &\sim N\left(\mathbf{0},\, \sigma^2 \mathbf{I}\right), \end{aligned} \tag{3.20}$$

donde:

- $\mathbf{y}$: Vector de respuestas de los cuadrantes.
- ρ: Parámetro de dependencia espacial de la respuesta.
- $\mathbf{W}$: Matriz de pesos espaciales normalizada por filas.
- $\mathbf{X}$: Matriz de predictoras; $\boldsymbol{\beta}$, vector de coeficientes.
- $\boldsymbol{\varepsilon}$: Vector de errores, con varianza σ^2; $\mathbf{I}$ es la matriz identidad.

Como $\mathbf{y} = (\mathbf{I} - \rho\mathbf{W})^{-1}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$, el efecto de una covariable no es β_j, sino que se descompone en un impacto directo y uno indirecto o de derrame hacia los vecinos [34].

6. *Modelo de error espacial (SEM).* La dependencia reside en factores no observados espacialmente correlacionados:

$$\begin{aligned} \mathbf{y} &= \mathbf{X}\boldsymbol{\beta} + \mathbf{u}, \\ \mathbf{u} &= \lambda\, \mathbf{W}\mathbf{u} + \boldsymbol{\varepsilon}, \end{aligned} \tag{3.21}$$

donde:

- $\mathbf{u}$: Vector de errores espacialmente correlacionados.
- λ: Parámetro de dependencia espacial del error.
- $\mathbf{y}$, $\mathbf{X}$, $\boldsymbol{\beta}$, $\mathbf{W}$, $\boldsymbol{\varepsilon}$: Como en la Ecuación (3.20).

La elección entre SAR y SEM se apoya en las pruebas de multiplicadores de Lagrange robustas sobre los residuos de OLS y en el criterio de información de Akaike, $\mathrm{AIC} = 2k - 2\ln\hat{L}$ [33].

7. *Métricas de evaluación.* Sobre el conjunto de prueba:

$$\begin{aligned} \mathrm{RMSE} &= \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}, \\ \mathrm{MAE} &= \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \\ r^2 &= \mathrm{cor}\,(y, \hat{y})^2, \\ R^2_{\mathrm{pred}} &= 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y}_{\mathrm{ent}})^2}, \end{aligned} \tag{3.22}$$

donde:

- y_i, $\hat{y}_i$: Valor observado y valor pronosticado de la observación i.
- n: Número de observaciones del conjunto de prueba.
- r^2: Cuadrado de la correlación de Pearson entre observado y pronosticado; mide el ordenamiento relativo y no penaliza sesgos de nivel ni de escala.
- R^2_{pred}: Coeficiente de determinación predictivo; compara el error del modelo con el de pronosticar la media de entrenamiento $\bar{y}_{\mathrm{ent}}$, y es negativo cuando el modelo es peor que esa media.

Como el error porcentual (MAPE) no está definido cuando $y_i = 0$, la comparación relativa se hace con el error absoluto escalado de [35],

$$\mathrm{MASE} = \frac{\mathrm{MAE}}{\frac{1}{n_{\mathrm{ent}}}\sum_{(q,s)\in\mathcal{D}_{\mathrm{ent}}}|y_{q,s} - y_{q,s-1}|}, \tag{3.23}$$

donde:

- $\mathcal{D}_{\mathrm{ent}}$, n_{ent}: Observaciones de entrenamiento y su número.
- $y_{q,s-1}$: Pronóstico ingenuo de persistencia del cuadrante q para la semana s.

Un MASE < 1 indica que el modelo mejora, en prueba, el error que la persistencia comete dentro del entrenamiento. Se reporta además el *MAE relativo a la persistencia*, cociente entre el MAE del modelo y el de la persistencia sobre las mismas observaciones de prueba, que responde directamente a si el modelo supera a esa referencia. La diferencia de exactitud entre dos modelos se contrasta con la prueba de [36], adaptada a la estructura de panel como se describe en la Sección 5.5.5.

3.2. Antecedentes

3.2.1. Revisión de literatura

Los avances en ciencia de datos, estadística y aprendizaje automático han ampliado los métodos disponibles para predecir fallas, gestionar interrupciones y estimar la calidad del servicio en redes de distribución eléctrica. La revisión se organiza por enfoques: modelos híbridos y de inteligencia artificial, eventos meteorológicos severos, vegetación, causas de falla y discretización espacial.

En primer lugar, varios estudios han explorado la predicción de confiabilidad a partir de modelos híbridos que integran técnicas estadísticas y de inteligencia artificial. Xie et al. [37] desarrollan un modelo integral de pronóstico de confiabilidad que combina redes neuronales artificiales, análisis de relaciones grises y modelos de fallas programadas, demostrando alta aplicabilidad en sistemas en expansión. De manera complementaria, Das et al. [38] proponen un ensamble de redes neuronales profundas que mejora sustancialmente la estimación de interrupciones causadas por viento y descargas eléctricas, superando modelos estadísticos y de comité previos.

En el ámbito de eventos meteorológicos severos, Angalakudati et al. [39] introducen uno de los primeros modelos operativos basados en Machine Learning para la planificación de tormentas, combinando datos climáticos, propiedades físicas de la red e información histórica de daños. En la misma línea, Owerko et al. [40] emplean Graph Neural Networks para procesar mediciones meteorológicas distribuidas en un marco de señales sobre grafos, logrando errores de predicción inferiores al 1.1 % en la región de Nueva York.

El efecto de la vegetación como causa dominante de fallas también ha sido ampliamente estudiado. Cerrai et al. [41] cuantifican el impacto del estándar Enhanced Tree Trimming mediante análisis estadístico y modelos de predicción de interrupciones, mostrando reducciones entre el 16 % y 48 % en fallas durante tormentas. Por su parte, Eskandarpour y Khodaei [42] introducen un modelo

predictivo para componentes de red ante huracanes basado en regresión logística, mientras que Rudin et al. [43] proponen un marco general para extraer conocimiento de datos históricos de la red de Nueva York con el fin de priorizar mantenimiento y estimar la vulnerabilidad de componentes críticos.

Otros aportes relevantes abordan la identificación de causas de fallas. Xu et al. [44] aplican un algoritmo inspirado en sistemas inmunológicos (AIRS) para clasificar causas de interrupción (árboles, animales, rayos), enfrentando el problema de datos desbalanceados.

La estimación de interrupciones bajo condiciones extremas también ha sido examinada mediante enfoques estadísticos. Han et al. [45] modelan la distribución espacial de fallas durante huracanes en la costa del Golfo utilizando variables físicas medibles. Yang et al. [46] estudian la incertidumbre en modelos de predicción de tormentas y demuestran que el rendimiento de los modelos basados en machine learning depende fuertemente del tamaño y representatividad del conjunto de entrenamiento. A su vez, Kankanala et al. [47] presentan AdaBoost+, un método de ensamble que supera regresión, redes neuronales y mixture of experts para estimar fallas asociadas al viento y los rayos.

Otras investigaciones incorporan análisis multivariable para predecir tipos específicos de interrupciones. Kor et al. [48] evalúan arquitecturas de aprendizaje automático para predecir fallas por viento, nieve e hielo, mientras que Doostan y Chowdhury [49] desarrollan un enfoque probabilístico para fallas asociadas a rayos utilizando aprendizaje no supervisado y técnicas de clasificación balanceada.

Asimismo, Chen y Kezunović [50] aplican lógica difusa para análisis predictivo de riesgo, y He et al. [51] comparan árboles de regresión no paramétricos (QRF y BART), demostrando ventajas complementarias según la granularidad espacial y las características del evento.

Dentro de los aportes más recientes, Hou et al. [52] desarrollan un enfoque basado en celdas espaciales de 1 km^2 y Random Forest para predecir interrupciones bajo tifones, alcanzando precisiones superiores al 92 %. De forma similar, Li et al. [53] construyen un modelo de predicción de cantidad de usuarios afectados por tifones, aplicando selección de variables para obtener un modelo simplificado sin sacrificar precisión.

Otras líneas introducen enfoques más estructurales o basados en simulación. Zhai et al. [54] proponen un modelo que genera sistemas de distribución sintéticos y estima fallas a nivel de edificio mediante funciones de fragilidad, reduciendo la dependencia en datos privados de operadores. Zhu et al. [55] desarrollan un modelo de tormentas de dos etapas para predecir interrupciones en tiempo real, mientras que Arif y Wang [56] combinan análisis estadístico y redes

neuronales profundas para predecir tiempos de reparación.

Wanik et al. [57] demuestran que modelos basados en árboles y ensambles, alimentados con datos atmosféricos generados mediante WRF, pueden predecir con alta resolución espacial la distribución de fallas en Connecticut. Por su parte, Jaech et al. [58] incorporan procesamiento de lenguaje natural para actualizar predicciones de duración de interrupciones a partir de reportes de campo.

Más recientemente, Sorokin [59] sistematiza los principios y particularidades de la aplicación de métodos de aprendizaje automático a la evaluación de la confiabilidad de sistemas de potencia, y desarrolla un prototipo capaz de identificar en tiempo real estados potencialmente peligrosos de la red. Por su parte, Liu et al. [60] presentan un método de cálculo rápido de la confiabilidad de redes de distribución activas basado en tasas de falla dinámicas de los equipos, mientras que Avcı [61] integra técnicas híbridas de inteligencia artificial para mejorar la predicción y la gestión de interrupciones, considerando factores meteorológicos, geográficos y operativos. Finalmente, Krstivojević y Terzić [62] aplican simulación de Monte Carlo para seleccionar la opción óptima de inversión orientada a mejorar el desempeño de confiabilidad en redes de distribución, vinculando así el diagnóstico predictivo con la priorización de inversiones.

Un cuerpo de literatura particularmente relevante para este trabajo adopta explícitamente la discretización del espacio en celdas o cuadrículas de tamaño fijo como unidad de análisis, en lugar de trabajar sobre componentes individuales de la red o sobre agregados administrativos. Esta línea es pionera en la disyuntiva entre resolución espacial y error de predicción, disyuntiva central para la especificación de panel cuadrante $\times$ semana empleada en el presente trabajo.

Liu et al. [63] desarrollan uno de los primeros modelos de este tipo, comparando explícitamente un nivel de agregación por código postal (zip code) frente a una malla de celdas de 1 km $\times$ 1 km para predecir interrupciones causadas por huracanes en Carolina del Norte y del Sur; encuentran que, contrario a la intuición de que una mayor resolución mejora la predicción, la agregación a nivel de celda de 1 km introdujo mayores errores que el nivel de código postal, por lo que finalmente seleccionan la especificación menos granular. Este hallazgo temprano anticipa un problema central en la definición de la unidad espacial óptima: celdas demasiado finas pueden diluir la señal disponible en cada unidad y aumentar la dispersión de los datos (muchas más unidades vacías o con pocos eventos), mientras que unidades más gruesas capturan mejor la señal agregada a costa de perder heterogeneidad espacial local.

Como respuesta a esa disyuntiva, un conjunto de estudios posteriores migró hacia celdas de mayor tamaño. Han et al. [11] desarrollan modelos aditivos generalizados (GAM) sobre una malla de celdas de $2{,}5$ km $\times$ $3{,}7$ km en la costa del

Golfo de México, mostrando que las funciones de suavizado no paramétricas de los GAM capturan mejor las relaciones altamente no lineales entre variables meteorológicas (precipitación, humedad del suelo) y el número de interrupciones por celda, en comparación con modelos lineales generalizados (GLM) sobre la misma malla. [64], trabajando sobre la misma resolución de celda, muestran que modelos de Random Forest —más simples en su formulación que los GAM y GLM previos, y que requieren solo seis variables de entrada (velocidad de ráfaga, duración de vientos fuertes, humedad del suelo, número de clientes y prácticas de poda de árboles)— logran una precisión comparable o superior, evidenciando que, a igualdad de resolución espacial, la elección del algoritmo también condiciona el desempeño predictivo. [65], por su parte, adoptan una malla más gruesa de $5\,\text{km} \times 5\,\text{km}$ y proponen un modelo de tres etapas: una primera etapa de clasificación binaria para determinar la presencia de interrupciones en cada celda, una etapa intermedia de agrupamiento (clustering) de celdas según la magnitud del evento para abordar la fuerte asimetría de los datos con valores distintos de cero, y una tercera etapa de regresión para predecir el número de interrupciones dentro de cada grupo; esta arquitectura multietapa aborda directamente el problema de desbalance de clases que surge de manera natural en paneles espaciales de alta resolución temporal, donde la mayoría de las celdas-periodo no registran ningún evento de falla —un reto metodológico compartido con el panel cuadrante $\times$ semana del presente trabajo—.

McRoberts et al. [66] extienden esta línea utilizando el trazado censal (census tract) como unidad espacial, e incorporan factores ambientales locales —cobertura vegetal, profundidad de raíces, tipo de suelo— para mejorar modelos de predicción de interrupciones por huracán previamente calibrados a nivel de celda, evidenciando que la elección de la unidad espacial de agregación no solo afecta la resolución del análisis, sino también qué variables explicativas resultan viables de incorporar dado su nivel de disponibilidad geográfica. En una revisión sistemática reciente, Arora y Ceferino [12] sintetizan esta evolución —desde el nivel de código postal y celdas de 1 km, pasando por mallas de $2{,}5 \times 3{,}7$ km y 5×5 km, hasta el nivel de trazado censal y de ciudad— y muestran, mediante la calibración conjunta de modelos GLM, GAM y Random Forest sobre datos de 1,910 ciudades de Texas, Florida, Nueva Jersey y Nueva York, que los modelos existentes tienden a sobrestimar las interrupciones en unidades espaciales de baja población (en el 19.8 % de las ciudades de su muestra, con una razón de sobrestimación promedio de 5.2), y que los Random Forest, si bien evitan estas sobrestimaciones extremas por estar acotados por el rango de los datos de entrenamiento, no logran extrapolar adecuadamente a eventos de viento fuera del rango observado. Este último hallazgo es particularmente relevante para pane-

les espaciales de alta frecuencia temporal como el aquí propuesto, en la medida en que la capacidad de extrapolación fuera de la muestra —y no solo el ajuste dentro de muestra— condiciona la utilidad del modelo para la priorización de inversión en cuadrantes con historiales de falla poco representados.

En una línea afín mediante representaciones de grafo, Owerko et al. [40] muestran que incorporar explícitamente las relaciones espaciales entre puntos de medición meteorológica mediante redes neuronales de grafos (*Graph Neural Networks*) mejora la predicción de interrupciones, lo que refuerza la idea de que la dependencia espacial entre unidades vecinas contiene información predictiva adicional a la de los atributos puntuales de cada unidad. De manera complementaria, Dunn et al. [7] analizan tres años de registros de interrupciones de alta resolución de una empresa del occidente de Estados Unidos y encuentran que los indicadores de confiabilidad varían en órdenes de magnitud en el espacio y en el tiempo, heterogeneidad que los indicadores agregados reportados públicamente ocultan. Este hallazgo respalda directamente el enfoque del presente trabajo: la desagregación territorial y temporal de SAIDI y SAIFI revela zonas y periodos críticos que el indicador anual del sistema no permite identificar.

En conjunto, esta línea de literatura evidencia una tendencia consistente: el tránsito desde modelos centrados en el componente individual o en agregados puramente administrativos (municipios, circuitos, empresas) hacia esquemas de discretización espacial regular —celdas, cuadrículas o cuadrantes— que permiten capturar de manera más flexible la heterogeneidad espacial de la vulnerabilidad de la red. Esta transición, sin embargo, no está exenta de nuevos retos metodológicos: el tamaño óptimo de la unidad espacial no es neutral frente al desempeño predictivo [63]; la dependencia espacial entre celdas vecinas puede aportar información adicional si se modela explícitamente [40]; y el desbalance de clases derivado de la escasez relativa de eventos de falla en paneles de alta granularidad temporal exige arquitecturas de modelación específicas, como los esquemas multietapa [65]. Estos tres retos —selección del tamaño de la unidad espacial, modelación de la dependencia espacial y tratamiento del desbalance de clases en un panel de alta frecuencia— constituyen precisamente los ejes metodológicos centrales que este trabajo aborda al construir un panel espacial de cuadrante $\times$ semana para la predicción de SAIDI/SAIFI en el contexto colombiano.

3.2.2. Antecedentes en Colombia y América Latina

La literatura revisada hasta aquí proviene mayoritariamente de Estados Unidos y Asia oriental y se concentra en eventos extremos (huracanes y tifones). Los antecedentes nacionales y regionales son menos numerosos, pero fijan tres

referentes directamente pertinentes para este trabajo.

El primero es el contexto regulatorio. En la comparación de las regulaciones de continuidad de Suramérica realizada por **delavechia2023**, Colombia aparece como el país con los peores resultados de duración y frecuencia de interrupciones de la región, y es de los pocos que, con la Resolución CREG 015 de 2018 [1], vincula el desempeño de SAIDI y SAIFI a incentivos y penalidades sobre el ingreso del operador, en lugar de limitarse a compensar al usuario. Esa combinación —indicadores rezagados frente a la región y un esquema que traslada el desempeño al ingreso— es la que convierte la anticipación territorial de la afectación en un problema de gestión con valor económico para el operador.

El segundo referente son los estudios colombianos sobre causas de falla. **aranguren2015** cruzaron datos de descargas atmosféricas con la ubicación de $251\,024$ transformadores del centro del país y encontraron que, en condiciones meteorológicas adversas, una fracción significativa de los transformadores presenta tasas de falla del orden de 45 veces las de condiciones normales, y las redes aéreas extensas más de 75 veces. **alvarez2022** desarrollaron una metodología de mantenimiento predictivo para $15\,869$ transformadores de distribución del Cauca, mediante una máquina de vectores de soporte entrenada con un año y validada con el siguiente; incorporan la densidad de descargas, la ubicación urbana o rural y el tipo de instalación, y reportan que la clase de interés (transformador quemado) se identifica con una precisión cercana al 52–$56\,\%$, muy inferior a la exactitud global, lo que ilustra la dificultad de pronosticar eventos poco frecuentes. Ambos trabajos operan al nivel del activo individual y no estiman indicadores de continuidad.

El tercer referente es la gestión de los indicadores por parte de los operadores. **gomez2017** documentan la estrategia de Enel-Codensa en Bogotá para la transición hacia SAIDI y SAIFI, basada en segmentar la red por grupos de calidad, automatizar y telecontrolar cerca de $3\,700$ equipos y priorizar circuitos mediante análisis de riesgo; reportan reducciones de SAIDI y SAIFI del $31\,\%$ y $26\,\%$ en tres años. En la academia nacional, **velasquez2024** combinan series de tiempo y Random Forest para pronosticar la demanda y la vida útil de equipos de seccionamiento en un circuito de Pereira, con SAIDI y SAIFI solo como contexto. En la región, **dacosta2023** usan Random Forest para seleccionar, entre 146 atributos eléctricos, de infraestructura, climáticos, de vegetación y socioeconómicos, los que mejor explican los indicadores DEC y FEC de los conjuntos de usuarios definidos por el regulador brasileño, y encuentran que pocos atributos —principalmente de tamaño y densidad de la red— concentran la capacidad explicativa.

Frente a estos antecedentes, en la revisión realizada no se identificaron estudios

colombianos que modelen los indicadores SAIDI y SAIFI de un operador con un panel espacio-temporal que integre sus sistemas de interrupciones, red y usuarios con fuentes externas de clima, vegetación y sismicidad, ni que evalúen los modelos frente a pronósticos de referencia con validación temporal estricta. Ese es el vacío que este trabajo aborda. La Tabla 3.1 resume los antecedentes más próximos y su relación con este trabajo.

Tabla 3.1: Síntesis de los antecedentes más relacionados con este trabajo

Estudio	**Ámbito**	**Unidad y respuesta**	**Método**	**Relación con este trabajo**
Liu et al. [63]	Huracanes, EE. UU.	Celda de 1 km y código postal; n.º de interrupciones	Regresión binomial negativa	Origen de la discretización en celdas; disyuntiva entre resolución y dispersión
Han et al. [11]	Huracanes, EE. UU.	Celda de 2.5×3.7 km; interrupciones	GAM	Relaciones no lineales clima–falla; tamaño de celda comparable al de este trabajo
Shashaani et al. [65]	Huracanes, EE. UU.	Celda; interrupciones con exceso de ceros	Modelo multietapa	Motiva el esquema en dos partes (ocurrencia y magnitud)
Arora y Ceferino [12]	Huracanes, EE. UU.	Celda; interrupciones	Random Forest y métodos probabilísticos	Importancia de viento y vegetación; límites de extrapolación de los árboles
Dunn et al. [7]	EE. UU.	Datos de alta resolución; SAIDI/SAIFI	Análisis exploratorio	Heterogeneidad espacial que los agregados ocultan
aranguren2015	Centro de Colombia	Transformador; tasa de falla	Estadística con modelo climático de dos estados	Efecto de las descargas atmosféricas en redes aéreas colombianas
alvarez2022	Cauca, Colombia	Transformador; falla (sí/no)	SVM con validación temporal	Pronóstico de eventos poco frecuentes; mantenimiento predictivo
gomez2017	Bogotá, Colombia	Red del operador; SAIDI y SAIFI	Planeación y priorización por riesgo	Uso operativo de los indicadores en un operador colombiano
dacosta2023	Brasil	Conjunto de usuarios; DEC y FEC	Random Forest y *k*-medias	Atributos de tamaño de red como principales determinantes de los indicadores
delavechia2023	Suramérica	País; indicadores regulatorios	Revisión regulatoria	Desempeño relativo de Colombia y esquema de incentivos de la CREG
Este trabajo	Norte de Santander, Colombia	Cuadrante de $\sim 5 \times 2.5$ km y semana; SAIDI y SAIFI operativos	Panel FE, Random Forest, clasificador de ocurrencia, SAR y SEM	Integración de sistemas del operador y fuentes externas; evaluación frente a pronósticos de referencia

3.2.3. Variables explicativas recurrentes en la literatura

La revisión anterior permite identificar un conjunto relativamente estable de variables explicativas que reaparecen de manera sistemática en los modelos de predicción de fallas e interrupciones, independientemente de si la variable de respuesta es un conteo de interrupciones, la fracción de clientes afectados o, como en el presente trabajo, indicadores agregados de confiabilidad (SAIDI/SAIFI) a nivel de cuadrante-semana. A continuación se sintetizan estas variables, agrupadas por categoría, junto con la dirección y el mecanismo de la relación que la literatura documenta con la variable pronosticada.

Variables meteorológicas. La velocidad del viento —típicamente medida como ráfaga máxima de 3 s— es, de manera consistente, la variable individual con mayor poder explicativo en los modelos revisados: Arora y Ceferino [12] la identifican como el predictor más importante en su modelo de Random Forest, por encima de precipitación y densidad poblacional, y su relación con el número de interrupciones es monótonamente creciente y de naturaleza física directa, ya que vientos por encima de aproximadamente 20 m/s superan el umbral de diseño estructural de postes y líneas aéreas [12]. La duración de vientos fuertes por encima de dicho umbral opera de manera similar y suele estar altamente correlacionada con la velocidad máxima, por lo que buena parte de los modelos retienen solo una de las dos variables tras un análisis de colinealidad [12]. La precipitación acumulada (contemporánea y en ventanas previas de 1, 3, 6 o 12 meses, expresada frecuentemente como índice estandarizado de precipitación, SPI) y la humedad del suelo muestran una relación positiva pero *no lineal* con las interrupciones: suelos saturados facilitan el desarraigo de árboles y la caída de líneas ante vientos moderados, mientras que periodos de sequía prolongada debilitan el sistema radicular de los árboles y los vuelve más susceptibles a fallar incluso ante ráfagas menores [11, 12]; esta no linealidad —efectos marcados tanto en el extremo húmedo como en el extremo seco de la distribución— es precisamente la motivación central para preferir modelos aditivos generalizados (GAM) sobre especificaciones lineales cuando se dispone de variables climáticas de este tipo [11].

Variables de vegetación y cobertura del suelo. La proximidad de árboles a las líneas de distribución y el porcentaje de área arbolada dentro de la unidad espacial de análisis mantienen una relación positiva y robusta con la frecuencia de fallas, dado que la caída de árboles y ramas sobre las líneas aéreas es la causa individual más frecuente de interrupciones en redes con alta exposición a vegetación [12, 41]. En consecuencia, la intensidad y frecuencia de la poda preventiva

(*tree trimming*) actúa como variable de exposición inversa: Cerrai et al. [41] cuantifican que la adopción de estándares de poda mejorada (*Enhanced Tree Trimming*) reduce las tasas de falla asociadas a tormentas entre 16 % y 48 %, por lo que su ausencia o desactualización en los datos de un cuadrante debería interpretarse como un factor que incrementa la probabilidad esperada de interrupción. La profundidad efectiva de raíces también se ha incorporado como proxy de la resistencia estructural de los árboles ante vientos fuertes, con una relación negativa esperada: mayor profundidad radicular implica menor probabilidad de desarraigo [12].

Variables de infraestructura y exposición. El número de clientes servidos y, de manera más general, la densidad poblacional de la unidad espacial funcionan como *proxy* de la densidad de componentes de red expuestos (postes, transformadores, tramos de línea), y presentan una relación positiva con el número absoluto de interrupciones, aunque no necesariamente con la tasa o fracción de clientes afectados, distinción que resulta crítica al momento de definir la variable de respuesta del modelo [12]. La topología de la red —redes radiales frente a redes en malla o interconectadas— también se documenta como determinante de la propagación de fallas: sistemas radiales, más comunes en zonas rurales, tienden a mostrar interrupciones de mayor alcance ante la falla de un único componente aguas arriba [12], un mecanismo que en el caso colombiano resulta pertinente para distinguir cuadrantes urbanos de cuadrantes rurales o de baja densidad.

Variables topográficas y geográficas. La elevación y variables derivadas de modelos digitales de terreno se han incorporado por su efecto indirecto sobre la velocidad del viento y los patrones de precipitación a escala local [12], aunque en varios estudios su contribución marginal al poder predictivo resulta baja una vez controlado por viento y precipitación directamente medidos, por lo que su inclusión debe evaluarse en función de la disponibilidad de las variables meteorológicas primarias [12].

Variables de historial de fallas y autocorrelación. Finalmente, un conjunto de estudios documenta la relevancia de incorporar la propia historia de interrupciones de la unidad espacial —o de sus vecinas— como predictor autorregresivo. Jaech et al. [58] muestran que actualizar predicciones de duración de interrupciones a partir de reportes de campo en tiempo real mejora sustancialmente la precisión respecto a modelos que solo usan información ex ante, mientras que los enfoques de redes neuronales de grafos revisados en la sección anterior [40]

evidencian que el número y la severidad de fallas en celdas vecinas aporta información predictiva adicional a la de los atributos propios de cada celda, lo cual sugiere la pertinencia de incluir rezagos espaciales y temporales de SAIDI/SAIFI —y no solo covariables exógenas— en la especificación del panel cuadrante $\times$ semana propuesto en este trabajo.

Datos

Para el desarrollo del modelo de pronóstico de $SAIFI$ y $SAIDI$ se utilizó una base de datos histórica de eventos de falla reportados en el sistema de distribución, organizada en dos niveles. El *nivel de integración* es el panel *activo* $\times$ *día*, con $N = 87\,007\,074$ observaciones ($A = 47\,649$ activos eléctricos únicos $\times$ $T = 1\,826$ días) entre el 1 de enero de 2021 y el 31 de diciembre de 2025. El *nivel de modelado* es el panel *cuadrante* $\times$ *semana*: 90 128 observaciones (344 cuadrantes con red $\times$ 262 semanas) para el análisis exploratorio y 36 120 observaciones (344 cuadrantes $\times$ 105 semanas de 2024–2025) para el modelado. Las variables de ambos niveles se documentan en el catálogo de datos del Apéndice A.4.

Tiempo o periodo de estudio. El periodo de estudio abarca desde el 1 de enero de 2021 hasta el 31 de diciembre de 2025.

Unidad muestral. La unidad de integración corresponde a un activo eléctrico por día, lo que define un nivel de granularidad tipo *elemento-día* y permite integrar variables de red, climáticas y de eventos a nivel diario. La unidad de análisis y de modelado es el par *cuadrante* $\times$ *semana*, en el que el cuadrante de la malla institucional representa la *zona* a la que se refieren los objetivos del proyecto (Sección 5.2.5).

4.1. Construcción del dataset

4.1.1. Lógica estructural

El conjunto de datos se construyó en tres pasos:

- Se creó un calendario diario entre el 1 de enero de 2021 y el 31 de diciembre de 2025.
- Se construyó el producto cartesiano entre el inventario de activos eléctricos y el calendario, de modo que cada activo está presente en todos los días del periodo.
- Sobre esa estructura se integraron:

- Variables de red.
- Variables climáticas agregadas a nivel de activo por día.
- Variables de eventos asociadas a cada activo por día.

4.1.2. Definición de variables de evento

Las variables de evento se definieron así:

- *Duración* (`DURACION_min`, en minutos): minutos de interrupción del activo en el día de observación, prorrateados según la intersección de `[Fecha_Desconexion, Fecha_Conexion]` con ese día calendario. Si el evento cruza varios días, su duración se reparte entre ellos; si hay varios eventos el mismo día, se suman. No se asigna la duración total del evento solo al día de desconexión. En días sin falla, el valor es 0.
- *Frecuencia* (`FRECUENCIA`): número de interrupciones cuyo inicio (`Fecha_Desconexion`) ocurre en el día (sin prorrateo de la frecuencia).

4.1.3. Estructura del dataset consolidado

El dataset final incluye las variables agrupadas por bloque temático, como se resume en la Tabla 4.1.

4.1.4. Variables incorporadas al panel cuadrante–semana

Para complementar la caracterización técnica, demográfica y socioeconómica del panel de modelado se incorporaron dieciséis variables adicionales. `usuarios_totales` permite construir los indicadores SAIDI y SAIFI con el denominador mensual del sistema, mientras que `cantidad_usuarios_cuadrante` representa la escala local de exposición al servicio. Las variables `ESTRATO_1` a `ESTRATO_6`, junto con `INDUSTRIAL`, `COMERCIAL`, `OFICIAL`, `PROVISIONAL` y `ALUMBRADO_PUBLICO`, describen la composición de los usuarios y permiten analizar si la frecuencia y la duración de las interrupciones presentan diferencias según el tipo de demanda y las características socioeconómicas del territorio.

Por su parte, `FECHA_ACTIVO_MAS_VIEJO`, `FECHA_ACTIVO_MAS_NUEVO` y `PROM_CANT_MODIFICACIONES` aportan información sobre la trayectoria de intervención y renovación de los transformadores. Estas variables permiten evaluar si los

Tabla 4.1: Estructura del dataset consolidado (grano activo × día).

Bloque	**Variables**
Información del activo	`Id_Activo_Electrico`
	`Tipo_Activo_Electrico`
Información geoespacial	`Latitud`
	`Longitud`
	`Altitud`
	`Id_Cuadrante`
	`Latitud_Cuadrante`
	`Longitud_Cuadrante`
Variables de red	`Fecha`
	`Cantidad_Elementos`
	`Cantidad_Usuarios`
	`Antiguedad_Red`
	`Expansion_Red`
Variables climáticas	`Velocidad_Viento_Ms`
	`Temperatura_Media_C`
	`Humedad_Relativa_Pct`
	`Temperatura_Minima_C`
	`Temperatura_Maxima_C`
	`Precipitacion_Total_Mm`
Variables objetivo	`DURACION_min`
	`FRECUENCIA`

cuadrantes con activos menos renovados o con mayor número de modificaciones presentan comportamientos diferentes en SAIDI y SAIFI.

Como salvedad metodológica, las fechas corresponden a `TT2_FMODIFICACION` y no necesariamente a la instalación original del activo, de modo que la edad derivada mide la distancia a la última intervención registrada. Para evitar fuga de información, los modelos predictivos solo emplean modificaciones conocidas antes de la semana pronosticada. SAIDI y SAIFI se incorporan como variables respuesta y no como predictoras contemporáneas.

Adicionalmente, el panel cuadrante–semana incorpora variables de exposición territorial provenientes de las fuentes externas descritas más adelante (sismicidad y vegetación): `sismos_conteo` y `dist_sismo_prom_km` (sismicidad, SGC); y `ndvi_semanal` junto con sus derivadas `log_ndvi` y `cat_ndvi` (vegetación, NDVI/MODIS). Se suman también las métricas de topología de red `longitud_red_km`, densidad de nodos terminales y número de circuitos por cuadrante.

Número de observaciones. La tabla consolidada del nivel de integración se obtiene como

$$N = A \times T = 47\,649 \times 1\,826 = 87\,007\,074, \tag{4.1}$$

donde:

- N: Número de observaciones de la tabla consolidada (activo $\times$ día).
- A: Número de activos eléctricos de la red.
- T: Número de días observados, equivalente a cinco años de información diaria.

4.2. Procedencia de la información

Origen de la información. Los datos operativos y técnicos provienen de Centrales Eléctricas de Norte de Santander S.A. E.S.P. (CENS S.A. E.S.P.).

Lugar donde se registra la información. La información operativa se registra en los sistemas corporativos de la empresa (BRAE, OMS y GIS), y la climatológica proviene de la fuente institucional externa NASA POWER [67].

La información se registra en la red de distribución eléctrica de Norte de Santander, con soporte de localización geográfica por activo y por cuadrante.

Fuentes adicionales incorporadas al panel cuadrante–semana. Para enriquecer la caracterización territorial del panel de modelado se incorporaron dos fuentes externas adicionales: los registros de sismicidad del Servicio Geológico Colombiano (SGC) y el índice de vegetación NDVI derivado del producto satelital MODIS MOD13Q1 de la NASA, procesado semanalmente por cuadrante. Adicionalmente, se construyeron métricas de topología de red eléctrica (longitud de red, densidad de nodos, circuitos) a partir del propio sistema georreferenciado GTECH (Sección 5.1.7).

4.3. Consideraciones éticas y disponibilidad de datos y código

Los datos operativos provienen de los sistemas institucionales de CENS S.A. E.S.P. y se emplearon con autorización de la empresa. El estudio no utiliza datos personales: la unidad mínima de registro es el activo eléctrico y los usuarios intervienen solo como conteos agregados por transformador, por lo que no es posible identificar a ninguna persona. Tampoco se emplean datos sensibles ni se recolecta información mediante encuestas o entrevistas. Las variables socioeconómicas (estrato) se usan como proporciones agregadas por cuadrante y con fines exclusivamente descriptivos de la demanda, no para diferenciar la atención a los usuarios, de modo que los resultados no inducen tratos diferenciados entre grupos de población. Las fuentes externas (NASA POWER, MODIS, SGC y DANE) son públicas.

El código de extracción, integración, análisis y modelado se encuentra en el repositorio `https://github.com/esilvas1/DataCollection_Tesis_MCD`, organizado por etapas, y los informes reproducibles de cada etapa se publican en GitHub Pages (Apéndice A.3); los artefactos de reproducibilidad se describen en el Apéndice A.6. Por tratarse de información institucional, los datos crudos no se publican. El repositorio incluye una muestra sintética con la misma estructura del panel de modelado (`Scripts/muestra_sintetica`, generada con `generar_muestra_sintetica.R`): conserva las columnas, los cuadrantes, las semanas y la definición de SAIDI y SAIFI, pero sus valores se generan al azar, de modo que permite ejecutar de principio a fin la cadena de la Etapa 5 sin reproducir las cifras de la tesis. La verificación de las cifras exactas requiere el panel agregado real, que puede ponerse a disposición del jurado con autorización de CENS.

5 Metodología

La metodología se organiza por etapas alineadas con los objetivos específicos del proyecto (Capítulo 2). El enfoque general consiste en integrar datos, limpiarlos, analizarlos y construir modelos para predecir los indicadores $SAIDI$ y $SAIFI$ de la empresa de distribución eléctrica en Norte de Santander. La correspondencia entre etapas y objetivos se resume al final de este capítulo en la Tabla 5.12.

Se decidió utilizar CRISP-DM (Cross-Industry Standard Process for Data Mining) como marco de referencia por ser un estándar reconocido en la industria para proyectos de ciencia de datos [68], el cual fue adaptado al contexto específico del sector eléctrico regulado. Las fases de CRISP-DM se implementaron de la siguiente manera: el entendimiento del negocio (Business Understanding) corresponde al planteamiento del problema, los objetivos y el marco de referencia (Capítulos 1 a 3). Las fases de entendimiento y preparación de datos (Data Understanding y Data Preparation) corresponden a las Etapas 1 a 4, en Secciones 5.1, 5.2, 5.3 y 5.4, en las que se integran, depuran y exploran los datos y se construyen las variables analíticas. La fase de modelado y evaluación (Modeling y Evaluation) se desarrolla en la Etapa 5, en la Sección 5.5, donde se construyen y validan los modelos predictivos. Finalmente, el despliegue (Deployment) corresponde a la Etapa 6 en la Sección 5.6, en la cual se consolidan los resultados, se documenta el proceso y se entrega código reproducible.

Esta adaptación de CRISP-DM considera los requisitos específicos del regulador (CREG, SSPD), las métricas propias del sector eléctrico ($SAIDI$, $SAIFI$) y la necesidad de que los modelos sean interpretables para su uso en la toma de decisiones.

5.1. Etapa 1 – Extracción de datos

Esta etapa comprende la recolección y estandarización de las fuentes de datos internas y externas enunciadas en el OE1. La correspondencia entre cada tipo de fuente del objetivo (SCADA/OMS, GIS, registros de fallas y mantenimientos, inventarios/SAC y clima) y el sistema efectivamente consultado, junto con su cobertura, sus métricas de integridad y sus limitaciones, se documenta en el

catálogo de datos del Apéndice A.4.

5.1.1. Fuentes de información

A partir del año 2023, la Electrificadora de Norte de Santander realizó una migración de su sistema de gestión de interrupciones. Como resultado, la recopilación de información de interrupciones eléctricas se llevó a cabo a partir de dos bases de datos provenientes de sistemas distintos:

- **OMS SPARD**: sistema utilizado hasta antes de la migración, del cual se extrae la información histórica de interrupciones previas a 2023.
- **OMS SP7 de Siemens**: nuevo sistema implementado desde 2023, del cual se obtiene la información de interrupciones a partir de dicha fecha.

Como se documenta en la Sección 6.3.5, la homologación de códigos asociada al nuevo sistema solo se refleja en la trazabilidad de los eventos a partir de 2024. Esta dualidad de fuentes implica diferencias estructurales en los esquemas de datos (tales como nombres de campos, codificaciones y niveles de granularidad), las cuales fueron consideradas durante el proceso de integración y homologación de la información.

5.1.2. Sistemas y fuentes consultadas

Se integran datos de seis fuentes de información principales, cinco corporativas y una externa:

- **BRAE**: base regulatoria e histórica de eventos.
- **QA_TTC1**: relación entre transformadores y usuarios conectados, insumo de la afectación por evento.
- *OMS SPARD* (sistema histórico): fuente de elemento causante antes de la migración.
- *OMS SP7* (sistema actual): fuente de elemento causante en archivos CSV mensuales.
- **GTECH (GIS)**: inventario y georreferenciación de activos eléctricos.
- **NASA POWER (API)**: serie diaria de variables climatológicas por coordenada/cuadrante.

5.1.3. Extracción base y depuración de eventos de interrupción (BRAE)

La construcción de la base de eventos de interrupción se realizó a partir de la tabla transaccional `BRAE.QA_TFDDREGISTRO`, perteneciente a la Base Regulatoria de Activos Eléctricos (BRAE), la cual contiene el registro histórico de eventos de desconexión del sistema eléctrico. A partir de esta fuente, se ejecutó una consulta SQL orientada a depurar inconsistencias, restringir el periodo de análisis y estandarizar la estructura del identificador de evento.

En primer lugar, se seleccionaron únicamente los campos relevantes para el análisis: el identificador del evento (`FDD_CODIGOEVENTO`), la fecha de inicio de la desconexión (`FDD_FINICIAL`) y la fecha de reconexión (`FDD_FFINAL`). Adicionalmente, se incluyó un campo vacío para `ELEMENTO_FALLADO`, con el fin de mantener compatibilidad estructural con otras fuentes que sí contienen este nivel de desagregación.

Posteriormente, se aplicaron criterios de depuración y filtrado. En primer lugar, se restringió la muestra al periodo comprendido entre los años 2021 y 2025, garantizando consistencia temporal del análisis. En segundo lugar, se excluyeron aquellos registros marcados como no relevantes mediante la variable `FDD_EXCLUSION`, conservando únicamente los eventos clasificados como `NO EXCLUIDA`. En tercer lugar, se eliminaron eventos asociados a causas no válidas según la regulación (`FDD_CAUSA_SSPD NOT IN (1)`), así como aquellos registros sin fecha de finalización (`FDD_FFINAL IS NOT NULL`), los cuales no permiten calcular la duración del evento.

Finalmente, se utilizó la instrucción `DISTINCT` para garantizar la eliminación de duplicados en el identificador de evento, obteniéndose una base depurada y consistente a nivel de evento de interrupción. Como resultado de este proceso de extracción y limpieza, se obtuvo un total de 95 280 registros válidos de eventos de desconexión para el periodo de análisis. La Tabla 5.1 presenta una muestra de la estructura resultante. El código SQL correspondiente se presenta en el Listado A.1 (Apéndice A.2).

Tabla 5.1: Muestra de eventos depurados de interrupción (BRAE; primeras cinco filas)

Id evento	Fecha desconexión	Fecha conexión	Elemento fallado
801851	14/03/21 06:59:00.000	14/03/21 09:30:00.000	(null)
787583	04/01/21 08:50:00.000	04/01/21 17:15:00.000	(null)
787496	03/01/21 14:18:14.296	03/01/21 14:40:42.699	(null)
787232	01/01/21 10:29:33.936	01/01/21 13:30:00.000	(null)
787455	03/01/21 10:34:23.000	03/01/21 13:30:00.000	(null)

5.1.4. Extracción de afectación por evento

Con el fin de complementar la base de eventos de interrupción, se construyó una tabla de afectación asociada a cada evento, incorporando información sobre el número de elementos afectados y la cantidad de usuarios impactados. Este proceso permite pasar de una caracterización puramente temporal del evento a una medición de su severidad en términos de impacto en la red.

La extracción se realizó a partir de la tabla `BRAE.QA_TFDDREGISTRO`, la cual se utilizó como fuente principal de eventos, y se complementó mediante una unión (LEFT JOIN) con la base `QA_TTC1`, que contiene información asociada a la conexión de transformadores y el número de usuarios por conexión.

En particular, la variable `CANTIDAD_USUARIOS` se construyó a partir del conteo de usuarios asociados a cada transformador (`TC1_CODCONEX`) agrupados por periodo, mientras que la variable de afectación por evento se obtuvo mediante la agregación de estos usuarios a nivel de evento de interrupción.

Posteriormente, se aplicaron los mismos criterios de depuración utilizados en la etapa anterior, restringiendo el análisis al periodo 2021–2025, excluyendo eventos marcados como no relevantes (`FDD_EXCLUSION = 'NO EXCLUIDA'`), eliminando causas no válidas según la clasificación regulatoria (`FDD_CAUSA_SSPD NOT IN (1)`) y conservando únicamente registros con fecha de finalización válida (`FDD_FFINAL IS NOT NULL`).

Finalmente, los datos se agregaron a nivel de evento (`FDD_CODIGOEVENTO`) utilizando la función `GROUP BY`, obteniendo como resultado dos indicadores clave: el número de elementos fallados por evento y el total de usuarios afectados. El procedimiento permitió consolidar una base consistente de 95 280 registros, alineada con la estructura del conjunto de eventos previamente depurado. La Tabla 5.2 ilustra una muestra de esta agregación. El código SQL correspondiente se presenta en el Listado A.2 (Apéndice A.2).

Tabla 5.2: Muestra de afectación por evento (BRAE + QA_TTC1; primeras cinco filas)

Id evento	Cantidad elementos fallados	Cantidad usuarios afectados
795044	33	2692
795513	162	11796
788221	10	74
788203	240	3865
789543	8	45

5.1.5. Extracción del elemento causante histórico

Con el objetivo de identificar el elemento de la red asociado a la causa de cada evento de maniobra, se realizó la extracción de información histórica desde la base de datos del sistema OMS (Outage Management System), específicamente desde la tabla `OMS.MANIOBRAS@SPARD`. Esta fuente permite complementar la información de eventos de interrupción mediante la identificación del elemento físico que originó la falla.

El proceso de extracción se centró en dos variables principales: el código de la maniobra (`CODE`), utilizado como identificador del evento en el sistema OMS, y el elemento fallado (`BREAKER`), que corresponde al activo de la red asociado a la causa de la interrupción. Estas variables permiten establecer la relación entre el evento registrado y el componente físico responsable dentro de la infraestructura eléctrica.

Adicionalmente, se aplicaron criterios de filtrado temporal y de calidad de datos. En primer lugar, se restringió la información a registros con fecha igual o posterior al año 2021, garantizando la consistencia histórica del análisis. En segundo lugar, se excluyeron aquellos eventos clasificados como pruebas operativas mediante la condición `CAUSA != 'PRUEBA'`, con el fin de conservar únicamente eventos reales de operación del sistema.

Como resultado de este proceso de extracción y depuración, se obtuvo una base de datos estructurada a nivel de maniobra, la cual permite complementar la trazabilidad entre eventos de interrupción y los elementos físicos de la red asociados a su ocurrencia. La Tabla 5.3 muestra un extracto de esta relación maniobra–elemento. El código SQL correspondiente se presenta en el Listado A.3 (Apéndice A.2).

Tabla 5.3: Muestra de elemento causante histórico (OMS SPARD; primeras cinco filas)

Código maniobra	Elemento fallado
640011	AMVE271
634924	LMVEL79620
634978	LMVEL67393
631108	RMVEL79067-2
631464	CMVE2454

5.1.6. Extracción del elemento causante actual

Con el objetivo de actualizar la información histórica del sistema de maniobras, se realizó la extracción de los datos correspondientes a la versión más reciente del sistema OMS en formato plano (CSV). Este proceso permite complementar la información histórica con registros operativos actuales, garantizando

la continuidad y consistencia de la base de datos utilizada en el análisis.

La extracción se realizó mediante un proceso de lectura y depuración de datos en Python, a partir del archivo fuente correspondiente a la versión actual del sistema. En primer lugar, se cargó el archivo mediante la función `read_csv`, asegurando la correcta lectura de la estructura tabular. Posteriormente, se realizó una limpieza de los nombres de las columnas mediante la eliminación de espacios en blanco al inicio y al final, con el fin de evitar inconsistencias en la identificación de variables.

A continuación, se seleccionaron únicamente las variables relevantes para el análisis: `Maniobra Apertura`, `Tipo Elemento` y `Elemento_Falla`. Esta selección permitió homogenizar la estructura de la base con la información histórica previamente construida. Finalmente, se eliminaron los registros duplicados mediante la función `drop_duplicates`, garantizando la unicidad de las observaciones a nivel de combinación de variables relevantes.

Como resultado, se obtuvo una base depurada y estandarizada del sistema OMS actual, la cual es consistente con la estructura de la base histórica y permite su integración en el proceso de consolidación del conjunto de datos final. La Tabla 5.4 presenta una muestra de los registros resultantes. El fragmento Python correspondiente se presenta en el Listado A.5 (Apéndice A.2).

Tabla 5.4: Muestra de elemento causante actual (OMS SP7; primeras cinco filas)

Maniobra apertura	Tipo elemento	Elemento falla
424000000000114424	Transformador de distribucion	1T07942
124000000000269842	Fusible	F1979
124000000000269842	Transformador de distribucion	F1979
124000000000273378	Fusible	F2004
124000000000269851	Fusible	F2000

5.1.7. Extracción de inventario GIS

Con el propósito de incorporar la dimensión espacial de la red eléctrica, se realizó la extracción del inventario georreferenciado a partir del sistema GIS corporativo. Esta información permite asociar cada activo de la red con sus coordenadas geográficas y características físicas, facilitando posteriormente el análisis espacial de los eventos de interrupción.

La extracción se efectuó desde la base de datos `ccomun@gtech`, la cual contiene el inventario técnico de los activos de la red. A partir de esta fuente, se seleccionaron las variables correspondientes al identificador del elemento (`nodo_transform_v`), la latitud (`coor_gps_lat`), la longitud (`coor_gps_lon`) y la altitud (`coor_z`). Adicionalmente, se incluyó la variable `ubicacion`, que permite

complementar la caracterización espacial del activo.

Asimismo, se definió explícitamente el tipo de activo como `Transformador`, con el fin de estandarizar la clasificación dentro del conjunto de datos integrado. Esta homogenización resulta clave para la posterior vinculación con los eventos de interrupción y la construcción del panel activo–día.

Como resultado, se obtuvo una base georreferenciada de los activos de la red, que constituye el insumo principal para el enriquecimiento espacial del conjunto de datos consolidado. La Tabla 5.5 ilustra la estructura de este inventario. El código SQL correspondiente se presenta en el Listado A.4 (Apéndice A.2); la consulta se replica de forma análoga para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador.

Tabla 5.5: Muestra de inventario georreferenciado de activos (GIS GTECH; primeras cinco filas)

Elemento	Latitud	Longitud	Altitud	Tipo
2T01558	6.960719612	-72.18029066	636	Transformador
2T01557	6.972762106	-72.18726993	743	Transformador
2T01467	6.973200989	-72.15472768	815	Transformador
2T01466	6.978510343	-72.14903608	726	Transformador
F3199	6.978980206	-72.19049387	832	Aisladero

5.1.8. Extracción de variables meteorológicas

Con el objetivo de incorporar condiciones climáticas como variables explicativas en el análisis de interrupciones del sistema eléctrico, se realizó la extracción de información meteorológica a partir de la plataforma NASA POWER [67]. Esta fuente proporciona series temporales diarias de variables climáticas relevantes, las cuales permiten capturar la influencia del entorno atmosférico sobre la ocurrencia y duración de eventos en la red.

El proceso de extracción se centró en un conjunto de variables meteorológicas seleccionadas por su relevancia en el análisis de confiabilidad del sistema eléctrico. En particular, se consideraron las variables de precipitación total (`PRECTOT`), temperatura media (`T2M`), temperatura máxima (`T2M_MAX`), temperatura mínima (`T2M_MIN`), humedad relativa (`RH2M`) y velocidad del viento (`WS2M`). La Tabla 5.6 presenta una muestra de estas series. La definición de estos parámetros en el código de extracción se presenta en el Listado A.6 (Apéndice A.2).

Estas variables fueron extraídas a nivel diario para el periodo comprendido entre el 1 de enero de 2021 y el 31 de diciembre de 2025, lo que dio lugar a una base de aproximadamente 83.5 millones de registros. Este volumen de información refleja la estructura panelizada de la base climática, construida mediante la combinación de múltiples variables atmosféricas observadas diariamente a lo

Tabla 5.6: Muestra de variables meteorológicas (NASA POWER; primeras cinco filas)

Vel. viento	Temp. media	Humedad	Temp. min	Temp. max	Precip.
2.06	13.27	87.24	9.12	18.63	2.6
2.66	13.89	88.27	10.71	18.92	1.41
1.93	13.66	88.59	10.29	18.96	3.04
1.73	13.6	85.07	9.13	20.17	9.07
1.45	11.52	69.12	5.95	18.7	0.79

largo del horizonte temporal de análisis.

La incorporación de estas variables permite enriquecer el conjunto de datos consolidado con condiciones exógenas del entorno, facilitando el análisis de su relación con la frecuencia y severidad de las interrupciones en el sistema eléctrico.

5.1.9. Resumen metodológico de extracción e integración de bases de datos

La Tabla 5.7 sintetiza el proceso de extracción e integración desarrollado en la Etapa 1. En conjunto, se consolidaron seis fuentes complementarias: BRAE como base transaccional de eventos de interrupción; BRAE + QA_TTC1 para cuantificar la severidad operativa (usuarios afectados); OMS SPARD y OMS SP7 para identificar el elemento causante y fallado en los periodos pre y post migración del sistema; GIS (GTECH) para incorporar la georreferenciación de activos de red; y NASA POWER para enriquecer el análisis con variables climáticas diarias. Cada fuente fue sometida a reglas explícitas de filtrado, homologación y depuración, lo que permitió obtener bases consistentes y trazables que constituyen el insumo inicial para la integración del panel descrita en la Etapa 2.

5.2. Etapa 2 – Integración y depuración de datos

5.2.1. Lógica de integración entre sistemas

Una vez extraídas y depuradas las fuentes descritas en la Etapa 5.1, la integración se ejecuta de forma secuencial sobre tablas intermedias, preservando trazabilidad de llaves y evitando pérdida de emparejamiento entre sistemas con esquemas distintos (BRAE, OMS SPARD, OMS SP7, GIS y NASA POWER). La secuencia aplicada fue la siguiente.

5.2.1.1 *Construcción de la tabla base de eventos (BRAE).*

A partir de `BRAE.QA_TFDDREGISTRO` se genera la tabla `tabla_eventos` con `ID_EVENTO`, `FECHA_DESCONEXION` y `FECHA_CONEXION`, aplicando filtros regu-

Tabla 5.7: Resumen metodológico de extracción e integración de bases de datos

Fuente	Variables principales	Proceso aplicado	Resultado
BRAE (TFDDREGISTRO)	Id evento, fecha desconexión, fecha conexión	Filtrado temporal (2021–2025), exclusión de registros no válidos, eliminación de duplicados	95 280 eventos de interrupción
BRAE + QA_TTC1	Cantidad usuarios, elementos de conexión	JOIN por elemento y periodo, agregación por evento	Base de severidad por evento (usuarios)
OMS SPARD (histórico)	Código maniobra, elemento fallado, elemento causante	Filtrado de registros desde 2021, exclusión de pruebas	Base histórica de causa de falla
OMS SP7 (actual)	Maniobra apertura, tipo elemento, cantidad elementos fallados, elemento falla	Lectura CSV, limpieza de columnas, eliminación de duplicados	Base actualizada de elementos causantes
GIS (GTECH)	Elemento, latitud, longitud, altitud, tipo	Extracción desde sistema georreferenciado corporativo	Inventario espacial de la red
NASA POWER	PRECTOT, T2M, T2M_MAX, T2M_MIN, RH2M, WS2M	Extracción diaria (2021–2025) por variables climáticas	83.5 millones de registros meteorológicos

latorios del periodo 2021–2025, exclusión de eventos no válidos y eliminación de duplicados. Esta tabla define el universo analítico de interrupciones (95 280 eventos).

5.2.1.2 *Construcción de la tabla de afectación por evento (Tabla 5.2).*

En la Sección 5.1.4 se construye la Tabla 5.2 de afectación por evento, la cual consolida las columnas `CANTIDAD_ELEMENTOS` y `CANTIDAD_USUARIOS` a nivel de `ID_EVENTO`. Su integración a la tabla base consolidada se realiza en el paso 5.2.1.5.

5.2.1.3 *Completar `ELEMENTO_FALLADO` (OMS SPARD + OMS SP7).*

La tabla base de eventos obtenida en la Sección 5.1.3 se construyó con el campo `ELEMENTO_FALLADO` vacío, reservado para su completamiento en la integración. Dado el cambio de sistema OMS en el año 2023, la información del elemento causante se extrajo de forma separada en dos fuentes: la Sección 5.1.5 (*Extracción del elemento causante histórico*, OMS SPARD) y la Sección 5.1.6 (*Extracción del elemento causante actual*, OMS SP7). En este paso, la tabla de la Sección 5.1.3 se cruza con ambas tablas OMS, aplicando en cada caso la lógica de emparejamiento definida en su extracción:

- *Histórico (Sección 5.1.5 – OMS SPARD):* cruce por `CODIGO_MANIOBRA` ↔ `ID_EVENTO` para completar `ELEMENTO_FALLADO` con el valor de `BREAKER` en eventos del periodo pre-migración.
- *Actual (Sección 5.1.6 – OMS SP7):* cruce por `MANIOBRA_APERTURA` ↔ `ID_EVENTO` para completar `ELEMENTO_FALLADO` con el valor de `ELEMENTO_FALLA`, junto con `TIPO_ELEMENTO`, en eventos del periodo post-migración.

5.2.1.4 *Construcción de la tabla base consolidada (activo–día).*

A partir de este paso se inicia la construcción de la tabla base consolidada del proyecto. Como insumo inicial se toma la Tabla 5.5 (inventario georreferenciado de activos obtenido en la Sección 5.1.7), del cual se conserva un registro por `ELEMENTO` (47 649 activos únicos), y se cruza con un calendario diario comprendido entre el 2021-01-01 y el 2025-12-31 (1 826 días), empleando el campo `FECHA_DIA`. Este cruce genera un producto cartesiano entre el universo de activos eléctricos y el horizonte temporal de análisis, con 87 007 074 observaciones ($47\,649 \times 1\,826$), definiendo la estructura panel *activo* $\times$ *día* sobre la cual, en los pasos 5.2.1.5 a 5.2.1.8, se anexan los valores

restantes de la secuencia de integración. El detalle del procedimiento para los pasos 5.2.1.4 a 5.2.1.8 se documenta en el Apéndice A.3.1.

5.2.1.5 *Integración de `CANTIDAD_ELEMENTOS` y `CANTIDAD_USUARIOS` (afectación por evento).*

Sobre la tabla base consolidada del paso 5.2.1.4, se anexan las métricas de *severidad del evento* (`ELEMENTOS_AFECTADOS` y `USUARIOS_AFECTADOS` de `tabla_eventos_ajustado.csv`, alineadas con la Tabla 5.2). Estas cantidades se miden a nivel de `ID_EVENTO`, tamaño del impacto de la interrupción, y se atribuyen al activo fallado mediante las llaves:

- `COMPONENTE_FALLADO` = `ELEMENTO` (activo de red, no el identificador del evento);
- `as.Date(FECHA_DESCONEXION)` = `FECHA_DIA`.

El cruce es izquierdo por (`ELEMENTO`, `FECHA_DIA`) y conserva $N = 87\,007\,074$ filas. Si un activo registra varios eventos el mismo día, se conserva un único valor de afectación (el primer `ID_EVENTO` ordenado); *no* se suman las severidades de esos eventos en el panel diario. En 2024–2025 esta regla afecta a 2 444 eventos (6.2 %) y deja fuera del panel el 36.6 % de los usuarios afectados de la tabla de eventos; su efecto sobre los indicadores se cuantifica en el Apéndice A.5. La frecuencia de todas las desconexiones del día se construye por separado en el paso 5.2.1.7. En días sin falla, `CANTIDAD_ELEMENTOS = 0` y `CANTIDAD_USUARIOS = 0`.

Nota metodológica: bajo esta regla, `CANTIDAD_*` no representa "usuarios del activo", sino la severidad del evento anclada al breaker en el día de inicio. En la taxonomía de modelado (Sección 3.1.2), estas cantidades pertenecen al *impacto posterior*: describen severidad una vez ocurrido el evento y *no* son predictoras contemporáneas de frecuencia o duración. Definiciones alternativas de agregación, suma o máximo de todos los eventos del mismo activo–día, o conteo de usuarios únicos por cuadrante–semana, pueden reelaborarse en la Etapa 4 sin alterar ese rol.

5.2.1.6 *Integración de variables climáticas (NASA POWER).*

Sobre la tabla resultante del paso 5.2.1.5 ($N = 87\,007\,074$ filas), se anexan las variables de la serie diaria `nasa_power_consolidado` mediante cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`), incorporando precipitación, temperatura (media, máxima, mínima), humedad relativa y velocidad del viento, sin modificar el cardinal del panel.

5.2.1.7 *Agregación de variables objetivo (`DURACION_min` y `FRECUENCIA`).*

En este paso se construyen las columnas `DURACION_min` y `FRECUENCIA` sobre la tabla resultante del paso 5.2.1.6 ($N = 87\,007\,074$ filas). Para ello, se expanden previamente los eventos de la Tabla 5.1 (Sección 5.1.3) a nivel (`COMPONENTE_FALLADO`, `FECHA_DIA`) y el resultado se integra al panel mediante cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`). La Tabla 5.1 contiene los campos `FECHA_DESCONEXION` y `FECHA_CONEXION`. Con base en las fechas de desconexión y reconexión, se asignan los valores diarios de la siguiente forma:

- *Duración* (`DURACION_min`, en minutos): minutos de interrupción del activo *en* `FECHA_DIA`, prorrateados por día. Cuando un evento abarca varios días, su duración se reparte entre cada `FECHA_DIA` según los minutos que el evento ocupa dentro de ese día (intersección del intervalo `[FECHA_DESCONEXION, FECHA_CONEXION]` con cada día calendario). El día de inicio recibe los minutos desde `FECHA_DESCONEXION` hasta la medianoche; los días intermedios, 1 440 min cada uno; y el día de cierre, los minutos desde la medianoche hasta `FECHA_CONEXION`. Si varios eventos ocupan el mismo día, se suman los minutos prorrateados de cada uno. *No* se carga la duración total del evento únicamente en el día de desconexión.
- *Frecuencia* (`FRECUENCIA`): número de desconexiones cuyo inicio (`FECHA_DESCONEXION`) ocurre en `FECHA_DIA` (no se prorratea; se cuenta solo en el día de inicio).

Cuando el activo no presenta interrupciones en un día, se asigna `DURACION_min = 0` y `FRECUENCIA = 0`. El cruce exige que `COMPONENTE_FALLADO` coincida con `ELEMENTO` del inventario `tipo_elemento.csv` (Tabla 5.5), el cual emplea el *código de sitio* georreferenciado. Cuando OMS registra el *código del activo* reemplazado en lugar del código de sitio, el emparejamiento falla y el evento no se propaga al panel espacial (Sección 6.3.5).

5.2.1.8 *Consolidación del panel final (activo–día).*

Sobre la tabla base consolidada definida en el paso 5.2.1.4, y una vez anexados los valores de los pasos 5.2.1.5 a 5.2.1.7, se obtiene el conjunto de datos final con grano *activo eléctrico* $\times$ *día* y $87\,007\,074$ observaciones ($47\,649$ activos $\times$ $1\,826$ días). En días sin falla se registra `DURACION_min = 0`, `FRECUENCIA = 0`, `CANTIDAD_ELEMENTOS = 0` y `CANTIDAD_USUARIOS = 0`.

La base de datos consolidada se estructura como un panel de datos de tipo activo–tiempo, donde la unidad muestral corresponde a un *activo*

eléctrico observado diariamente. Cada observación se identifica mediante el par activo–día dentro del periodo de análisis, lo que permite capturar la evolución temporal de cada activo a lo largo del horizonte de estudio. Con 47 649 activos eléctricos únicos en la Tabla 5.5 (inventario GIS, un registro por `ELEMENTO`) y 1 826 días observados (cinco años de información diaria), el panel balanceado comprende 87 007 074 observaciones.

5.2.2. Diagrama de flujo de la secuencia de integración

La secuencia de integración y la estructura del panel final se resumen visualmente en la Figura A.1 (Apéndice A.1), que especifica las relaciones entre las tablas y las operaciones aplicadas en cada paso.

5.2.3. Descripción de la tabla base consolidada

La Tabla 5.8 presenta una vista previa de la tabla base consolidada resultante del paso 5.2.1.8, con grano *activo eléctrico* × *día*. La muestra completa, con todas las columnas del panel divididas en bloques temáticos (identificación del activo, severidad, clima y continuidad), se documenta en el Apéndice A.7.1.

Tabla 5.8: Vista previa de la tabla base consolidada (grano activo–día)

Id activo	Fecha día	C. elem.	C. usu.	Temp. med.	Precip.	Duración (min)
AASW4819	01/01/2021	0	0	23.91	3.19	0
1T12452	01/01/2021	0	0	24.58	1.31	0
REC21365	01/01/2021	125	2015	23.04	3.19	421.5
CUC12345	01/01/2021	0	0	23.02	7.28	0
INT39845	02/01/2021	0	0	23.83	1.99	0

Nota: los registros sin interrupción en el día presentan `DURACION_min = 0` y `FRECUENCIA = 0`. La duración del panel diario se expresa en *minutos* (columna `DURACION_min` en `data_consolidada.csv`).

5.2.4. Descripción de las variables

Severidad y clima inicial (Tabla 5.8; detalle completo en el Apéndice A.7.1). Las columnas `ID ACTIVO` y `FECHA DIA` se repiten en esta tabla para facilitar la trazabilidad de filas entre bloques consecutivos. Las variables propias de este bloque son:

- *C. elem.* (`CANTIDAD_ELEMENTOS`): número de elementos de red afectados por el *evento* de interrupción atribuido al activo fallado (`COMPONENTE_FALLADO`) en el día de desconexión (paso 5.2.1.5). No es el inventario del activo ni

un conteo de usuarios únicos del cuadrante. Si hay varios eventos el mismo activo–día, el panel conserva la severidad de un solo evento. Cuando el activo no registra falla en el día, el valor es 0. En el modelado es *impacto posterior* (Sección 3.1.2), no predictora contemporánea. *Clasificación:* cuantitativa discreta.

- *C. usu.* (`CANTIDAD_USUARIOS`): número de usuarios afectados por el mismo evento, con la misma atribución espacial y temporal que `CANTIDAD_ELEMENTOS`. Es una medida de severidad operativa del impacto sobre la demanda (impacto posterior; Sección 3.1.2), no una covariable disponible antes del evento ni una predictora válida de su ocurrencia o duración. En días sin interrupción, el valor es 0. *Clasificación:* cuantitativa discreta.
- *Vel. viento* (`WS2M`): velocidad del viento a 2 m de altura, expresada en m/s. Corresponde a la variable `WS2M` de NASA POWER (Sección 5.1.8) e integra al panel por `FECHA_DIA` en el paso 5.2.1.6. *Clasificación:* cuantitativa continua.
- *Temp. med.* (`T2M`): temperatura media del aire en el día, expresada en °C. Proviene del parámetro `T2M` de NASA POWER y captura las condiciones térmicas promedio del entorno asociadas a cada observación activo–día. *Clasificación:* cuantitativa continua.

Clima complementario (detalle completo en el Apéndice A.7.1). Al igual que en la Tabla 5.8, `ID ACTIVO` y `FECHA DIA` permiten alinear filas entre tablas. Las variables climáticas restantes del bloque son:

- *Hum. rel.* (`RH2M`): humedad relativa del aire a 2 m, expresada en porcentaje (%). Proviene del parámetro `RH2M` de NASA POWER e integra al panel por `FECHA_DIA`. *Clasificación:* cuantitativa continua.
- *Temp. min.* (`T2M_MIN`): temperatura mínima diaria del aire, expresada en °C. Corresponde al parámetro `T2M_MIN` de NASA POWER y complementa la temperatura media con el extremo inferior del rango térmico del día. *Clasificación:* cuantitativa continua.
- *Temp. max.* (`T2M_MAX`): temperatura máxima diaria del aire, expresada en °C. Proviene del parámetro `T2M_MAX` de NASA POWER y representa el extremo superior del rango térmico observado en el día. *Clasificación:* cuantitativa continua.
- *Precip.* (`PRECTOT`): precipitación total acumulada en el día, expresada en mm. Corresponde al parámetro `PRECTOT` de NASA POWER y permite

incorporar la exposición del activo a condiciones de lluvia en la fecha de observación. *Clasificación:* cuantitativa continua.

Variables de continuidad (Tabla 5.8). Este bloque concentra las variables objetivo del análisis, construidas en el paso 5.2.1.7 a partir de la Tabla 5.1 (eventos depurados, Sección 5.1.3) y de los campos `FECHA_DESCONEXION` y `FECHA_CONEXION`:

- *Duración* (`DURACION_min`, en minutos): minutos de interrupción del activo *en* `FECHA_DIA`, obtenidos prorrateando cada evento según la intersección de `[FECHA_DESCONEXION, FECHA_CONEXION]` con ese día (paso 5.2.1.7). Si el evento cruza varios días, su duración se reparte entre ellos; si hay varios eventos el mismo día, se suman los minutos prorrateados. No equivale a colocar la duración total del evento solo en el día de desconexión. En días sin falla, el valor es 0. *Clasificación:* cuantitativa continua.
- *Frecuencia* (`FRECUENCIA`): número de interrupciones del activo cuyo inicio (`FECHA_DESCONEXION`) ocurre en `FECHA_DIA`. La frecuencia se contabiliza únicamente en el día de inicio y *no* se prorratea entre días. En días sin falla, el valor es 0. *Clasificación:* cuantitativa discreta.

Una vez construido el panel consolidado (pasos de integración 5.2.1.4–5.2.1.8), se deriva la tabla agregada por cuadrante y semana (Sección 5.2.5). La Etapa 2 cierra con la evidencia institucional de calidad de las fuentes (Sección 5.2.8). El diagnóstico de completitud del panel, la identificación de valores extremos y el resto del análisis exploratorio se desarrollan en la Etapa 3; la imputación, el tratamiento definitivo de atípicos y la preparación del conjunto de datos para modelado, en la Etapa 4.

5.2.5. Agrupación de data consolidada por semana y cuadrante

Definición del grano analítico (cuadrante × semana)

El panel consolidado con grano *activo eléctrico* × *día* ($N = 87\,007\,074$ observaciones) constituye la base de integración y trazabilidad del proyecto: preserva la relación uno a uno entre cada activo de red y cada día del horizonte 2021–2025, y permite reconstruir con rigor la secuencia de pasos descrita en la Sección 5.2.1. No obstante, el objetivo del estudio, pronosticar el comportamiento de $SAIDI$ y $SAIFI$ en distintas áreas del territorio de concesión, exige una unidad de análisis de mayor agregación espacial y temporal, coherente con la lectura regulatoria y operativa de los indicadores de continuidad del servicio.

Desde el punto de vista espacial, los indicadores de calidad se interpretan y gestionan a escala territorial (zonas de concentración, circuitos y áreas de servicio), no a nivel de un activo aislado. Para sintetizar el comportamiento de la red en unidades homogéneas del territorio, se adopta la malla institucional de *800 cuadrantes* que cubre el área de concesión de la red eléctrica. En esta malla, el sufijo `_800` identifica la versión del esquema con 800 divisiones espaciales; cada celda tiene dimensiones aproximadas de 5×2.5 km. Cada activo eléctrico se asigna a un `id_cuadrante` mediante el catálogo `ELEMENTO_FALLA_CUADRANTE_800`, de modo que las observaciones diarias de múltiples activos ubicados en la misma celda puedan consolidarse en una métrica zonal. La Figura 5.1 ilustra la estructura de esta partición espacial sobre el área de estudio. De las 800 celdas, 344 contienen activos de la red eléctrica y constituyen el universo del panel agregado (344 cuadrantes $\times$ 262 semanas $=$ 90 128 filas); en esta tesis la *zona* a la que se refieren los objetivos se operacionaliza como el cuadrante de esta malla. En el periodo de modelado (2024–2025), 324 de esos cuadrantes registran al menos un evento, el corte transversal espacial emplea los 344 y las especificaciones de efectos fijos estiman 323 efectos de cuadrante, los de los cuadrantes con al menos una semana con falla en el entrenamiento.

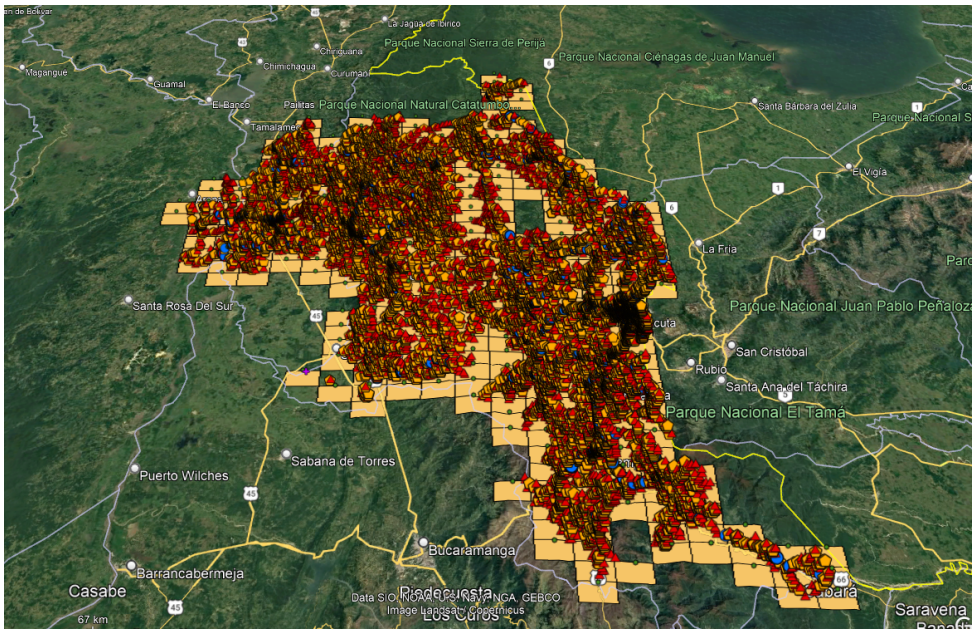


Figura 5.1: Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. 5×2.5 km).

Desde el punto de vista temporal, la granularidad diaria del panel es necesaria para la integración de eventos, clima y severidad, pero resulta excesivamente ruidosa para el análisis exploratorio espacial y para la modelación orientada a

dinámicas semanales de continuidad y clima. Por ello, se define la *semana calendario* (con inicio en lunes) como periodo de agregación temporal, lo que permite suavizar fluctuaciones diarias, estabilizar las series de interrupción y alinear las covariables meteorológicas en un horizonte compatible con la gestión operativa y con visualizaciones espacio-temporales (mapas por cuadrante y series semanales).

Bajo esta definición, la unidad muestral del conjunto de datos agregado es el par *(cuadrante, semana)*. El panel `data_consolidada.csv` se conserva como insumo base y referencia del proyecto; la tabla derivada `data_agrupada_por_cuadrante_semana.csv` constituye la representación analítica para los análisis territoriales posteriores, sin sustituir ni alterar el panel diario original.

Procedimiento de agregación

Con el panel consolidado `data_consolidada.csv`, se construyó la tabla de análisis a grano *cuadrante* × *semana*. El procedimiento se documenta en el Apéndice A.3.2.

El insumo principal es el panel del paso 5.2.1.8. Para asignar cada activo a su zona de análisis espacial, se utiliza el catálogo `ELEMENTO_FALLA_CUADRANTE_800`, del cual se extrae la relación `ELEMENTO` → `id_cuadrante` (campo `CUADRANTE_1`). La asignación se integra al panel mediante cruce izquierdo por `ELEMENTO`, conservando todas las filas del panel y anexando el identificador de cuadrante cuando existe emparejamiento. Complementariamente, el archivo `CUADRANTE_CORD_800` aporta la referencia de centroides por cuadrante.

Sobre el panel enriquecido, cada observación diaria se asigna a una semana calendario mediante `floor_date(FECHA_DIA, unit = "week", week_start = 1)`, de modo que la semana inicia en lunes. La duración del panel activo × día se conserva en *minutos* (`DURACION_min`; paso 5.2.1.7). Para la agregación semanal se convierte a horas como `duracion_horas = DURACION_min / 60`. Esta conversión *no* vuelve a prorratear entre días: el prorrateo temporal ya se resolvió al construir el panel diario; aquí solo se unifican unidades y se suman los minutos diarios (ya prorrateados) de los activos del cuadrante.

La agregación distingue dos naturalezas de variable. Las variables *operativas* (impacto y continuidad) son propias de cada activo: dos activos del mismo cuadrante pueden fallar el mismo día y sus conteos deben sumarse, por lo que se agregan directamente sobre las filas activo × día con `group_by(id_cuadrante, semana)`. Las variables *climáticas*, en cambio, describen un campo espacial común: como consecuencia del cruce del paso 5.2.1.6, todos los activos de un mismo cuadrante comparten el valor meteorológico del día, de modo que la serie diaria aparece replicada tantas veces como activos tenga el cuadrante. Por ello el bloque climático se agrega en *dos etapas*: primero se colapsa el panel a un registro por

(`id_cuadrante`, `FECHA_DIA`), eliminando la replicación por activo, y sobre esa serie diaria del cuadrante se calcula el resumen semanal. Omitir la primera etapa dejaría el acumulado de lluvia multiplicado por el número de activos del cuadrante, un sesgo multiplicativo que además varía entre cuadrantes y contamina cualquier comparación territorial posterior.

Las reglas de resumen son las siguientes:

- *Coordenadas del cuadrante* (`latitud`, `longitud`, `altitud`): primer valor registrado en el grupo (`first`), tomado del inventario georreferenciado del panel.
- *Impacto operativo:* `usuarios_afectados` = `sum(CANTIDAD_USUARIOS)` y `elementos_afectados` = `sum(CANTIDAD_ELEMENTOS)` en la semana, sumando las severidades de evento ya atribuidas a los activos del cuadrante (paso 5.2.1.5). Esta suma agrega *impactos de evento*, no un conteo de usuarios o elementos únicos de la semana; tampoco multiplica la severidad por el número de activos del cuadrante (a diferencia del clima, que sí requería colapsar la replicación diario–activo). En el modelado pertenecen al grupo de *impacto posterior* (Sección 3.1.2): se conservan para el EDA y la descripción de severidad, pero *no* entran como predictoras contemporáneas de `n_eventos` ni de `duracion_total`. Una reelaboración de la regla de agregación, si procede, se documenta en la Etapa 4 sin cambiar esa exclusión.
- *Variables climáticas semanales:* sobre la serie diaria por cuadrante de la primera etapa, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana` como promedio de los días de la semana; `temp_max_semana` y `viento_max_semana` como máximo; `temp_min_semana` como mínimo; y `precip_total_semana` como suma de la precipitación diaria del cuadrante, es decir el acumulado de lluvia de la semana en milímetros.
- *Continuidad del servicio:* `n_eventos` = `sum(FRECUENCIA)` (total de desconexiones *iniciadas* en la semana, sin prorrateo de la frecuencia) y `duracion_total` = `sum(duracion_horas)` (suma semanal, en horas, de los minutos diarios de interrupción ya prorrateados en el panel activo × día; unidad resultante: horas).

El resultado se exporta como `data_agrupada_por_cuadrante_semana.csv` en la ruta definida por la variable de entorno `UBICACION_DATA`.

5.2.6. Descripción de la tabla base semanal cuadrante

La Tabla 5.9 resume la estructura del conjunto de datos agregado `data_agrupada.csv`, con grano *cuadrante* × *semana*. Cada fila corresponde a un par

(`id_cuadrante`, `semana`) y concentra, para esa celda de la malla y ese periodo semanal, las coordenadas de referencia, el impacto operativo acumulado, las variables climáticas resumidas y las métricas de continuidad del servicio. Se incluyen además los bloques incorporados en la materialización de D_{mod} (`data_agrupada_mod.csv`): usuarios y denominadores, composición de estrato/sector, fechas y reposiciones de transformadores, y las respuestas SAIDI/SAIFI. La Tabla 5.10 presenta una vista previa; la muestra completa por bloques temáticos se documenta en el Apéndice A.7.2.

Tabla 5.9: Estructura de la tabla base semanal cuadrante (`data_agrupada.csv`).

Bloque	**Variables**	**Regla de agregación**
Identificación	`id_cuadrante`	Llave del grupo
	`semana`	
Georreferencia	`latitud`	`first`
	`longitud`	
	`altitud`	
Impacto	`usuarios_afectados`	`sum`
	`elementos_afectados`	
Clima	`temp_media_semana`	`mean`†
	`temp_max_semana`	`max`†
	`temp_min_semana`	`min`†
	`humedad_media_semana`	`mean`†
	`viento_medio_semana`	`mean`†
	`viento_max_semana`	`max`†
	`precip_total_semana`	`sum`†
Continuidad	`n_eventos`	`sum`
	`duracion_total`	
Usuarios‡	`usuarios_totales`	Cruce por mes /
	`cantidad_usuarios_cuadrante`	cuadrante
Estrato y sector‡	`ESTRATO_1` … `ESTRATO_6`	Conteo por
	`INDUSTRIAL`, `COMERCIAL`	cuadrante
	`OFICIAL`, `PROVISIONAL`	
	`ALUMBRADO_PUBLICO`	
Activos‡	`FECHA_ACTIVO_MAS_VIEJO`	`min`
	`FECHA_ACTIVO_MAS_NUEVO`	`max`
	`PROM_CANT_MODIFICACIONES`	`mean`
Respuestas‡	`SAIDI`	Cálculo derivado
	`SAIFI`	

Nota: † el bloque climático se resume en dos etapas; la regla indicada opera sobre la serie diaria por cuadrante, obtenida tras colapsar las filas activo × día que replican el mismo valor meteorológico. ‡ bloques incorporados en la materialización de D_{mod} (`data_agrupada_mod.csv`): usuarios y composición de estrato/sector provienen de los maestros comerciales cruzados por mes y cuadrante; las fechas y el promedio de reposiciones se derivan de `TT2_FMODIFICACION` por cuadrante; SAIDI y SAIFI se calculan a partir de la duración y frecuencia de interrupciones sobre `usuarios_totales` y se emplean exclusivamente como variables de respuesta.

Nota: la muestra completa, con coordenadas, temperaturas máxima/mínima, viento y humedad por bloques temáticos, se documenta en el Apéndice A.7.2.

Tabla 5.10: Vista previa de la tabla base semanal cuadrante (grano cuadrante–semana)

Id cuad.	Semana	Usu. afect.	Temp. med.	Precip.	N eventos	Dur. total (h)
1	28/12/2020	0	13.6	18.5	0	0.0
12	11/01/2021	842	22.4	8.4	5	28.4
45	18/01/2021	0	23.8	6.2	0	0.0
117	25/01/2021	1254	24.1	9.8	8	41.7
203	01/02/2021	0	24.5	4.1	0	0.0

Cadena de unidades de continuidad: panel diario en *minutos* (`DURACION_min`) → conversión `/60` → `duracion_total` semanal en *horas*. El prorrateo entre días se aplica solo al construir `DURACION_min` (paso 5.2.1.7); la agregación semanal suma esos minutos ya prorrateados, convertidos a horas. Las semanas sin interrupciones registran `n_eventos = 0` y `duracion_total = 0`. Las unidades de temperatura, humedad, viento y precipitación coinciden con las del panel diario (°C, %, m/s y mm, respectivamente).

5.2.7. Justificación y enriquecimiento del panel cuadrante–semana

Tras materializar la tabla base semanal (Secciones 5.2.5–5.9), se incorporan atributos territoriales, de red y de exposición que no están en el panel operativo original. El procedimiento reproducible corresponde a los informes `Etapa2_03` a `Etapa2_12` (Apéndices A.3.17–A.3.25). Cada bloque se argumenta en el cuerpo del capítulo con hallazgos, figuras representativas y remisión al HTML para el detalle de código.

Justificación de la agregación espacial

La elección del grano cuadrante × semana se fundamenta en la evidencia de concentración espacial de fallas y en la escala de dependencia comparable al tamaño de los cuadrantes de la malla operativa (`Etapa2_03_justificacion_agregacion_espacial.Rmd`). Operar a nivel activo × día preserva trazabilidad, pero genera esparcidad extrema e inviabilidad computacional para vecindades densas; la agregación reduce ceros estructurales y alinea la unidad de análisis con la lectura territorial de $SAIDI$ y $SAIFI$.

Infraestructura eléctrica por cuadrante

A partir del inventario GIS se agregan conteos y tipologías de elementos (transformadores y seccionadores, entre otros) al polígono de cada cuadrante (`Etapa2_04`). El resultado se exporta en `infraestructura_cuadrantes_reales.gpkg` y alimenta variables de exposición estática (`n_elementos`, proporciones por tipo). La Figura 5.2 resume la heterogeneidad de escala entre cuadrantes; la Figura 5.3 ilustra la composición de infraestructura en los cuadrantes con mayor densidad de activos.

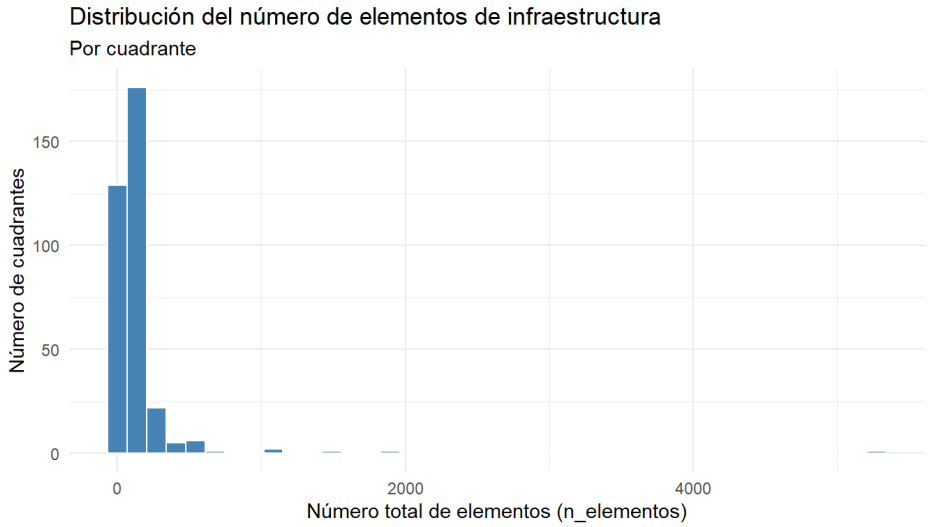


Figura 5.2: Distribución del número de elementos de infraestructura por cuadrante real.

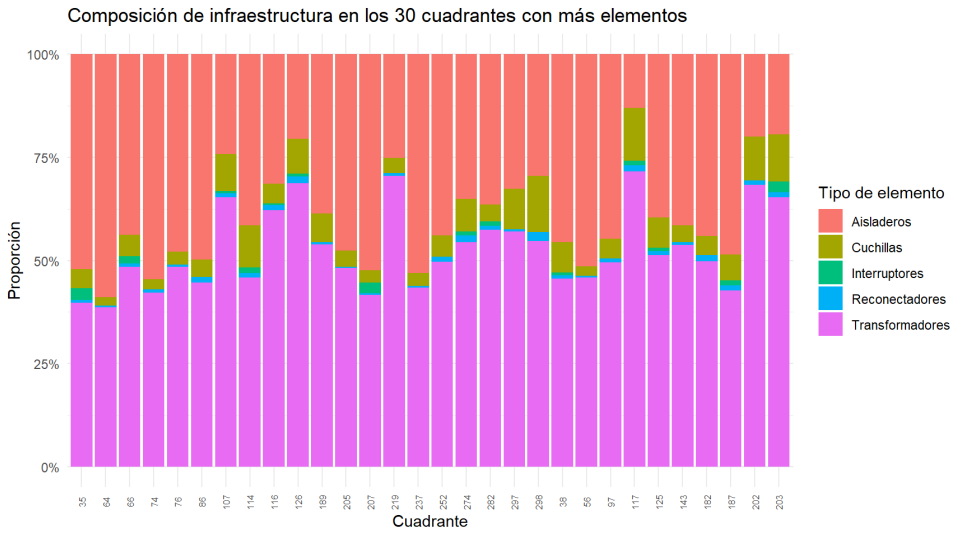


Figura 5.3: Composición tipológica de infraestructura en los 30 cuadrantes con mayor número de elementos.

El procedimiento se documenta en el Apéndice A.3.18.

Estratificación municipal

Mediante intersección espacial entre polígonos de cuadrante y la capa oficial DANE de estratificación municipal (`Mpio_Metodologia_Estr_Estr_Predom`), se asigna a cada cuadrante el municipio y el estrato predominante (`Etapa2_05`). En límites administrativos la regla de desempate es el municipio del centroide. La Figura 5.4 muestra la asignación territorial; la Figura 5.5 la frecuencia de cuadrantes por estrato predominante.

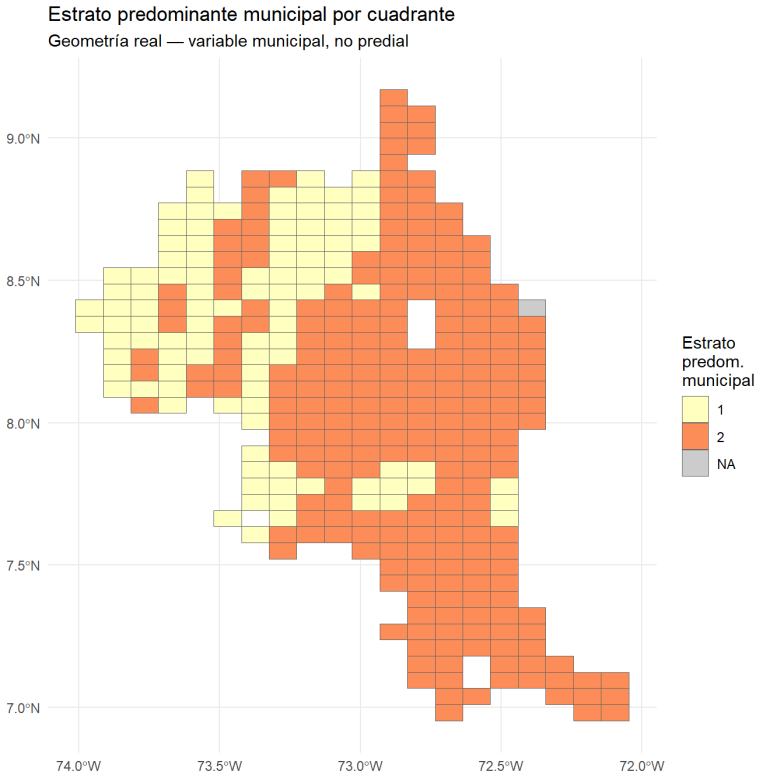


Figura 5.4: Mapa de cuadrantes según estrato socioeconómico predominante del municipio.

El estrato es una variable *municipal* y no predial, por lo que describe el contexto socioeconómico del cuadrante y no la composición exacta de sus usuarios. El procedimiento se documenta en el Apéndice A.3.19.

Sismicidad (SGC)

La sismicidad del Servicio Geológico Colombiano se integra como exposición territorial por buffers de distancia al centroide del cuadrante y agregación semanal (`Etapa2_07`). La Figura 5.6 muestra la evolución temporal; la Figura 5.7 la distribución de magnitudes.

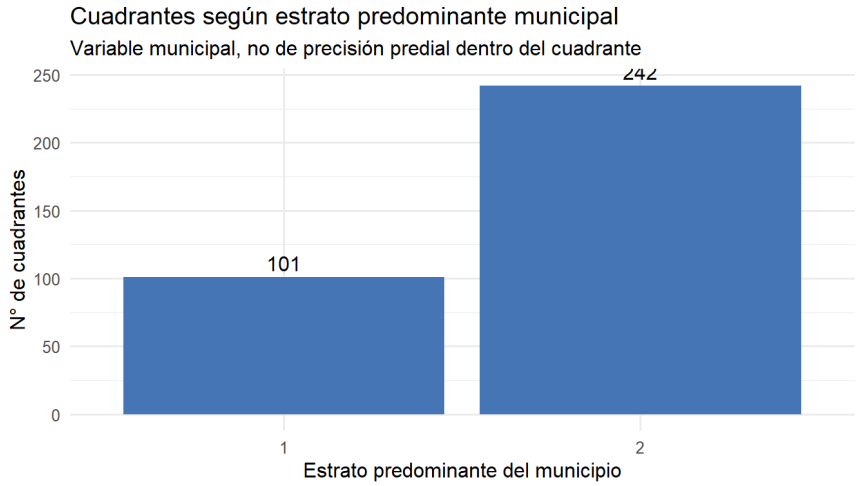


Figura 5.5: Distribución de cuadrantes por estrato predominante municipal.

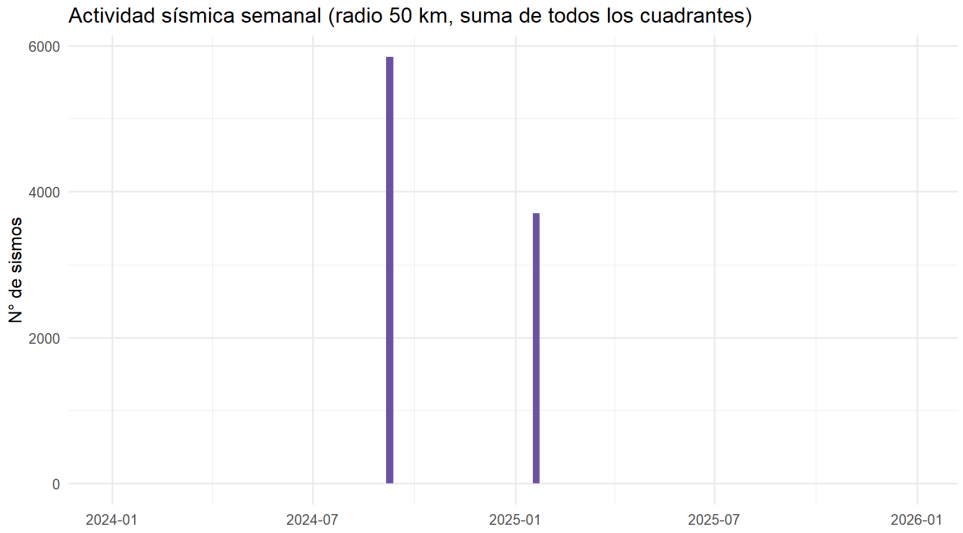


Figura 5.6: Serie temporal de sismos considerados en la exposición territorial del panel.

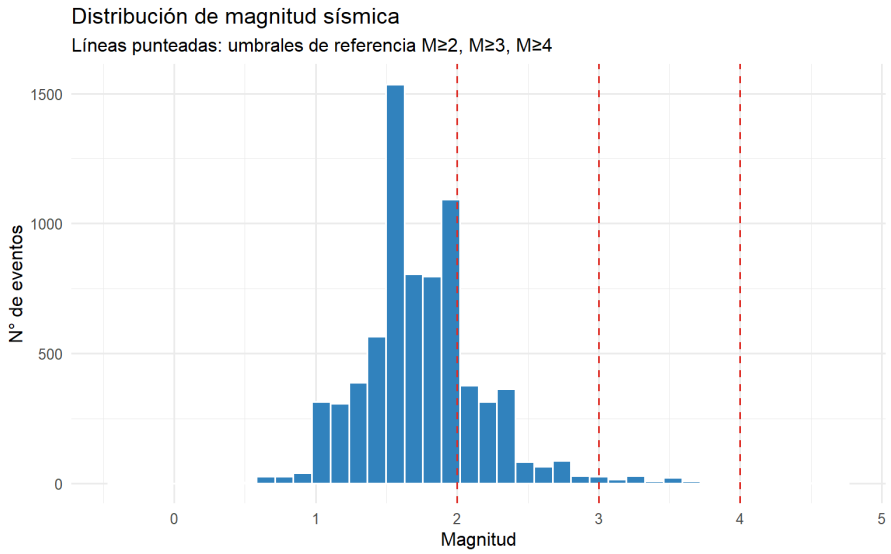


Figura 5.7: Histograma de magnitudes de sismos integrados al panel cuadrante–semana.

Durante la re-estimación final se detectaron y corrigieron dos errores en la construcción de estas variables. El primero era de unidades: la matriz de distancias se dividía entre 1 000 sin perder su unidad de metros, de modo que al compararla con un radio expresado en kilómetros el radio se convertía a metros y la condición resultaba siempre verdadera. En consecuencia, `n_sismos_r25`, `n_sismos_r50` y `n_sismos_r100` contenían el total regional de la semana, idéntico para los 344 cuadrantes (media de 1 366 sismos). El segundo era de asignación temporal: la función que asigna cada sismo a su semana no tenía cota superior, por lo que todos los sismos de 2026 incluidos en la extracción se acumulaban en la última semana del panel (35 042 sismos frente a un máximo de 1 486 en las semanas anteriores). Tras la corrección, el número de sismos a menos de 50 km del centroide tiene una media de 10 por cuadrante–semana, un percentil 99 de 46 y varía entre cuadrantes, como corresponde a una medida de exposición local; `dist_sismo_min_km` se define como la distancia al epicentro más cercano de la semana, con independencia del radio. El panel corregido se materializa en `data_final_modelo_cuadrantes_reales_sismos_corr.rds` y es el que se usa en todos los resultados de la Etapa 5.
El procedimiento se documenta en el Apéndice A.3.20.

Topología de red eléctrica

Sobre tramos y nodos de la red se construyen métricas por cuadrante (longitud de red, densidad de nodos terminales, circuitos) y una matriz de vecindad eléctrica/espacial para rezagos entre vecinos (`Etapa2_08`). La Figura 5.8 describe la heterogeneidad de longitud de red; la Figura 5.9 relaciona preliminarmente

longitud de red y $SAIDI$.

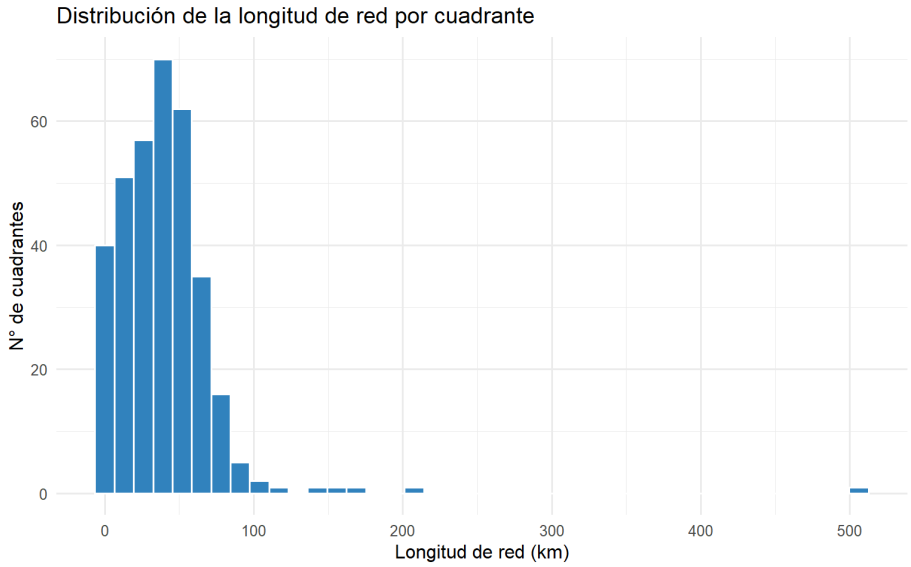


Figura 5.8: Distribución de la longitud de red eléctrica por cuadrante.

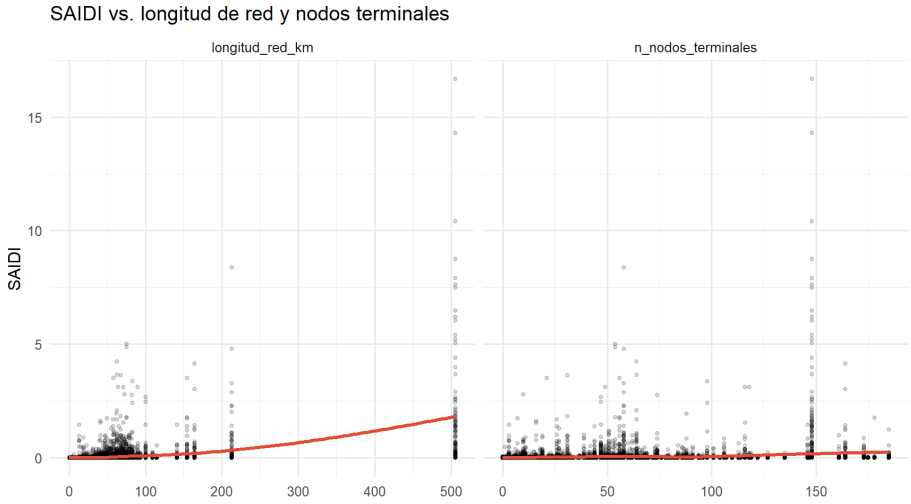


Figura 5.9: Relación exploratoria entre longitud de red y $SAIDI$ por cuadrante.

El procedimiento se documenta en el Apéndice A.3.21.

Integración del panel enriquecido y series SAIDI/SAIFI

Los bloques anteriores se unen al panel base por `id_cuadrante` y `semana` (`Etapa2_09`–`Etapa2_12`): clima NASA semanal, eventos de continuidad, NDVI y atributos estáticos. El artefacto resultante `data_final_modelo_cuadrantes_reales.rds` es el insumo de las Etapas 4 y 5. La Figura 5.10 muestra la coevolución

temporal de $SAIDI$ y $SAIFI$; la Figura 5.11 ilustra la relación exploratoria NDVI–$SAIDI$.

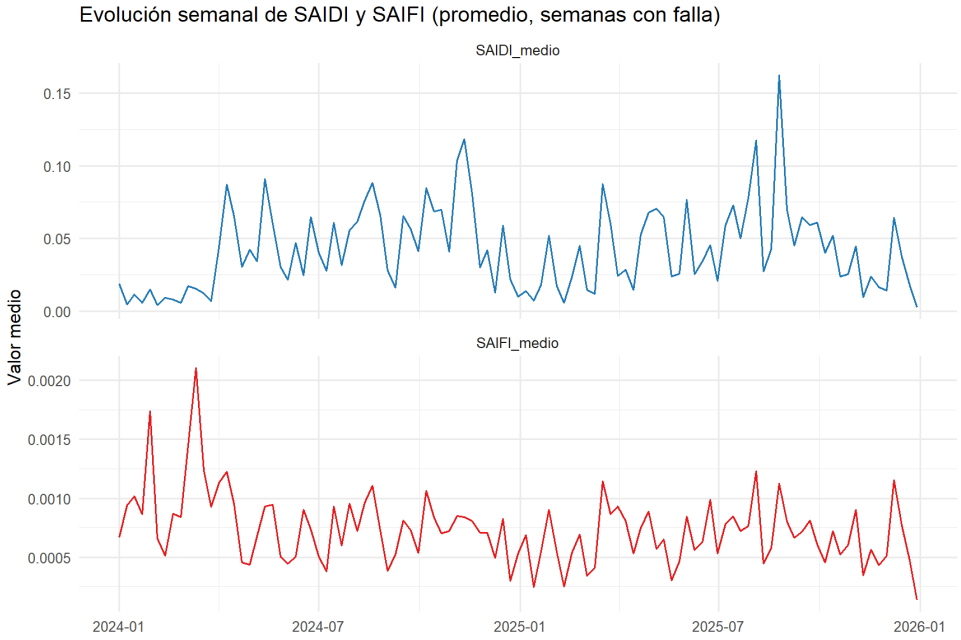


Figura 5.10: Series temporales de $SAIDI$ y $SAIFI$ en el panel enriquecido cuadrante–semana.

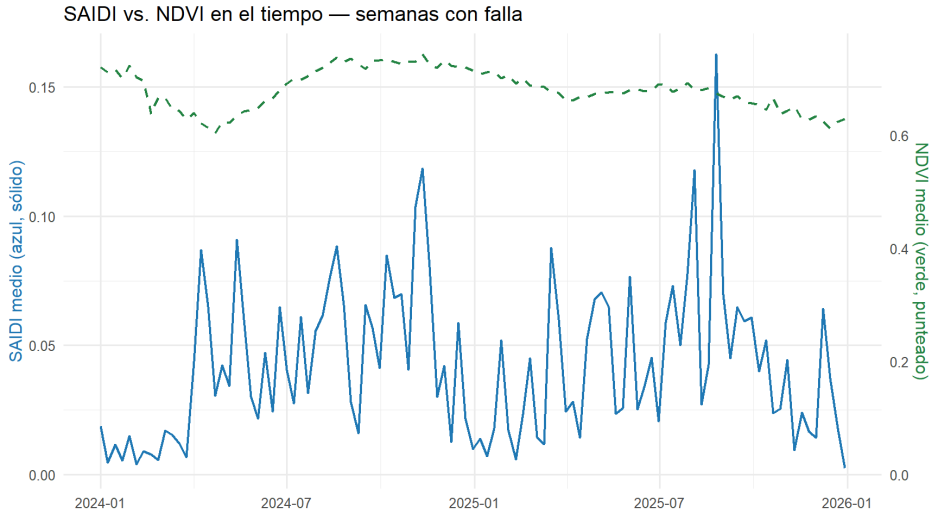


Figura 5.11: Relación exploratoria entre NDVI semanal y $SAIDI$ en el panel enriquecido.

El procedimiento se documenta en los Apéndices A.3.22–A.3.25.

5.2.8. Evidencia de calidad y confiabilidad de las fuentes

La validación de los datos recopilados por Centrales Eléctricas de Norte de Santander S.A. E.S.P. (CENS) se fundamenta en su arquitectura institucional de gestión, enmarcada en la Política de Gestión de Tecnología de la Información (Sesión de la Junta Directiva No. 800 del 20 de febrero de 2018) CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P. [69] y en la Política del Sistema de Gestión Integrado (Sesión de la Junta Directiva No. 831 del 22 de abril de 2020) [70], orientadas a garantizar una gestión sistemática de calidad continua, sostenibilidad ambiental y cumplimiento legal mediante la evaluación permanente de la calidad de los datos, priorizando consistencia, disponibilidad y accesibilidad de la información.

CENS refuerza su gobernanza de datos mediante Instrumentos de Gestión de Información Pública, entre los cuales se destacan el Registro de Activos de Información (IPR), utilizado para detectar, clasificar y almacenar conjuntos de datos institucionales; los Cuadros de Clasificación Documental; el Esquema de Publicación de Información (IPS); el Índice de Información Clasificada y Reservada; los Costos de Reproducción; y el Programa de Gestión Documental (PGD). Estos instrumentos enmarcan el proceso institucional de almacenamiento, organización, acceso, difusión, protección y preservación de la información [71].

En conjunto, estos mecanismos constituyen el marco institucional de control interno y gobernanza de la información del operador. Este marco es una condición necesaria, pero no suficiente, para la calidad analítica de los datos: el propio diagnóstico de cobertura de la Sección 6.3.5 muestra que un campo completo en el 100 % de los registros puede, sin embargo, no ser utilizable para el análisis territorial. Por ello, la calidad efectiva de cada fuente para los fines de este estudio se verificó empíricamente mediante las métricas de integridad del catálogo de datos (Apéndice A.4) y el diagnóstico de emparejamiento evento–elemento.

La fiabilidad técnica de las variables climáticas se sustenta en NASA POWER, plataforma del Langley Research Center de la NASA de la cual provienen las series meteorológicas integradas al panel (Sección 5.1). Esta fuente fue seleccionada por ofrecer cobertura diaria completa y homogénea sobre la totalidad del área de servicio durante el periodo de estudio, sin los vacíos ni las discontinuidades propias de una red de estaciones terrestres.

Los parámetros utilizados se derivan del reanálisis MERRA-2 del programa Earth Science de la NASA y se distribuyen mediante una API pública, documentada y versionada, con definiciones y unidades explícitas para cada variable. Estas características garantizan trazabilidad, reproducibilidad y consistencia metodológica en la captura de las series climáticas, de modo que la extracción documentada en la Etapa 1 puede replicarse de forma íntegra [67].

5.3. Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA)

Una vez completadas las etapas de extracción e integración (Etapas 1 y 2), se desarrolla un análisis exploratorio orientado a caracterizar las distribuciones de las variables, diagnosticar la calidad del panel (valores faltantes y extremos), identificar patrones temporales y espaciales, y evaluar las relaciones entre covariables que podrían explicar la variación de $SAIDI$ y $SAIFI$. Esta etapa se concibe como un análisis diagnóstico previo al modelamiento, orientado a garantizar la estabilidad e interpretabilidad de los resultados y a fundamentar las decisiones de imputación y transformación de la Etapa 4.

Para las variables cuantitativas se calculan medidas de tendencia central y de dispersión, incluida la desviación estándar y el coeficiente de variación (CV; Sección 3.1.2), así como la proporción de valores atípicos; adicionalmente se construyen histogramas y diagramas de caja para examinar la forma de las distribuciones. En el caso de las variables categóricas, se analizan las frecuencias absolutas y relativas de cada categoría. El grado de asociación se evalúa con el coeficiente de Spearman Spearman [17] (cuantitativas) y el estadístico V de Cramér Cramér [18] (cualitativas), según se formalizan en la Sección 3.1.2, con el fin de identificar redundancias y relaciones preliminares que orienten la depuración de variables en la Etapa 4. Las visualizaciones incluyen series de tiempo, gráficos de dispersión, mapas temáticos y mapas de calor de correlaciones.

Los procedimientos de esta etapa son, en su orden: diagnóstico de datos faltantes, identificación de valores extremos, cálculo de estadísticos descriptivos, análisis de la distribución de las variables, análisis temporal de los eventos (que delimitó el conjunto de modelado D_{mod}), identificación de patrones y visualización exploratoria, análisis de correlación y asociación, evaluación multivariada (VIF, PCA, agrupamiento jerárquico y GLM de diagnóstico) y segmentación exploratoria. Sus fundamentos formales se presentan en la Sección 3.1.2; la descripción detallada de cada procedimiento y sus hallazgos, con las tablas y figuras correspondientes, se presenta en la Sección 6.3, conforme a la organización del documento en la que el preprocesamiento y el análisis descriptivo forman parte de los resultados.

5.4. Etapa 4 – Ingeniería de variables y preparación del modelo

A partir de los hallazgos del EDA y de la taxonomía de la Sección 3.1.2, en esta etapa se transforma el conjunto de datos consolidado en una representa-

ción analítica adecuada para el entrenamiento de modelos. El criterio rector es evitar *fuga de información*: solo entran como predictoras variables disponibles *antes* de la semana t a pronosticar. Las actividades incluyen la definición formal de la variable respuesta, la construcción de predictoras informadas por el EDA (clima rezagado o pronosticado, histórico de eventos, rasgos del cuadrante, estacionalidad), la depuración y codificación de covariables, la estandarización de variables continuas y la partición temporal entrenamiento/prueba. `usuarios_afectados` y `elementos_afectados` se tratan como *impacto posterior*: el primero entra en el numerador de $SAIFI$ y $SAIDI$, pero ninguno se habilita como predictora contemporánea. El preprocesamiento, incluida la selección de variables con base en el EDA, se concentra aquí, en coherencia con estabilidad numérica, identificabilidad y validez operativa del pronóstico.

Partición formal del conjunto de columnas. Conviene precisar qué significa, en este trabajo, "preparar los datos para modelar". El panel enriquecido `data_final_modelo_cuadrantes_reales.rds` contiene decenas de columnas que no son intercambiables entre sí: unas identifican la observación, otras son el objeto del pronóstico, otras son legítimamente utilizables como información previa y otras solo se conocen *después* de que el fenómeno ocurrió. Preparar el panel equivale, entonces, a inducir sobre el conjunto de columnas $\mathcal{C}$ una partición en cuatro clases disjuntas:

$$\mathcal{C} = \mathcal{K} \sqcup \mathcal{Y} \sqcup \mathcal{X} \sqcup \mathcal{P}, \tag{5.1}$$

donde:

- $\mathcal{C}$: Conjunto de columnas del panel enriquecido.
- $\mathcal{K}$: Llaves (`id_cuadrante`, `semana`, `latitud` y `longitud`). Identifican la fila y, en las especificaciones de efectos fijos, se consumen como índice de absorción y no como covariables.
- $\mathcal{Y}$: Respuestas (SAIDI y SAIFI), es decir, lo que se quiere pronosticar.
- $\mathcal{X}$: Predictoras *ex ante*, covariables cuyo valor está determinado antes del inicio de la semana s.
- $\mathcal{P}$: Impacto posterior, magnitudes que solo existen una vez ocurrido o cerrado el evento.
- $\sqcup$: Unión disjunta.

La partición no es una formalidad de notación: define el perímetro de validez del ejercicio predictivo. Si una columna de $\mathcal{P}$ migrara a $\mathcal{X}$, el modelo exhibiría un ajuste excelente y carecería de utilidad operativa, porque en el momento de

pronosticar la semana s el operador no dispone todavía de esa información. El caso crítico es `usuarios_afectados`: pertenece simultáneamente al numerador de ambas respuestas (ecuación (5.3)) y al conjunto de severidad observada *ex post*; incluirla como regresor equivaldría a regresar Y contra una transformación de sí misma. El mismo razonamiento excluye `elementos_afectados`, y excluye los valores contemporáneos de `n_eventos` y `duracion_total`, que sí se admiten en su versión rezagada. Esta disciplina es la que explica por qué el desempeño predictivo reportado en el Capítulo 6 es moderado y no artificialmente alto: el modelo opera bajo la misma restricción de información que enfrentaría el operador en producción.

La construcción de rasgos preliminares y la exploración de relaciones clima–indicador que anteceden a esta formalización se documentan en el Apéndice A.3.26 (informe HTML); la evidencia empírica que sustenta la especificación dinámica con rezagos, en el Apéndice A.3.27 (informe HTML). Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.4.1. Construcción de variables predictoras

Se construyen únicamente variables del grupo *disponibles antes del periodo a pronosticar*, es decir, el conjunto $\mathcal{X}$ de la ecuación (5.1). Su composición responde a cinco bloques, cada uno con una justificación distinta:

1. *Clima rezagado o pronosticado.* Se admite clima de las semanas $t-1, \ldots, t-h$ y, cuando exista, clima pronosticado para t con fecha de emisión anterior al inicio de la semana. La distinción importa porque el EDA mostró una asociación bivariada contemporánea débil (Sección 6.3.7): el bloque climático no se conserva por su poder explicativo inmediato, sino porque la literatura y la operación atribuyen a la lluvia y al viento un efecto diferido sobre la vegetación y sobre el esfuerzo mecánico de la red, efecto que solo es capturable mediante rezagos y acumulados (`precip_ma4`, `viento_ma4`).

2. *Histórico de eventos del cuadrante.* Conteos y duraciones rezagadas, además del rezago de la propia respuesta (`SAIDI_lag1`, `SAIDI_lag4`, `SAIFI_lag1`, `SAIFI_lag4`). La inclusión no es opcional: la autocorrelación de la serie semanal alcanza 0.80 en el primer rezago en D_{mod} (Sección 6.3.6); el valor de 0.92 observado en D_{EDA} no se usa como referencia porque está inflado por el cambio de nivel de la serie en 2024, de modo que omitir el rezago propio dejaría en el error una componente sistemática y predecible.

3. *Características estructurales del cuadrante*, enriquecidas en la Sección 5.2.7: infraestructura (`n_elementos`, `n_tipos_infraestructura`, `prop_transformadores`), topología (`longitud_red_km`, `n_circuitos_`

`cuadrante`, `n_nodos_terminales`, `densidad_terminales`), composición socioeconómica (`prop_estrato_1` a `prop_estrato_6`, `prop_no_residencial`, `estrato_modal_real`) y trayectoria de los activos (`edad_activo_mas_viejo_anios`, `edad_activo_mas_nuevo_anios`, `rango_edad_activos_anios`, `PROM_CANT_MODIFICACIONES`). Son variables cuasi-estáticas: su valor no depende de lo ocurrido en la semana s, por lo que su disponibilidad *ex ante* es trivialmente satisfecha. Su procedencia se documenta en los Apéndices A.3.18 (informe HTML), A.3.19 (informe HTML) y A.3.21 (informe HTML).

4. *Exposición externa al sistema eléctrico:* vegetación (`ndvi_semanal`, `log_ndvi`) y sismicidad SGC (`n_sismos_r50`, `n_sismos_m3_r50`, `magnitud_max_r50`, `dist_sismo_min_km_r50`). Estas fuentes son exógenas al operador, lo que las hace especialmente valiosas: no pueden estar contaminadas por decisiones de registro internas ni por el propio proceso de atención de la falla. Su integración se documenta en el Apéndice A.3.20 (informe HTML).

5. *Estacionalidad y calendario:* mes, semana del año, términos armónicos e indicadores de régimen lluvioso/seco, que absorben la heterogeneidad intra-anual detectada en la Sección 6.3.6.

Adicionalmente se construyen dos rasgos de interacción, `ndvi_x_elementos` y `sismo_x_elementos`, bajo la hipótesis de que la exposición ambiental no actúa de forma uniforme sino proporcional a la cantidad de infraestructura expuesta: un cuadrante con vegetación densa pero pocos activos no tiene el mismo riesgo que uno igualmente vegetado con alta densidad de red.

Indicadores de clima extremo. Los promedios y totales semanales pueden diluir los episodios que efectivamente provocan fallas, pues un día de lluvia intensa o de viento fuerte queda promediado con días normales. Para evaluar esta posibilidad se construyeron, a partir de la serie diaria de NASA POWER por cuadrante, seis indicadores semanales de clima extremo: la precipitación diaria máxima, la máxima precipitación acumulada en tres días consecutivos, la anomalía estandarizada de la precipitación semanal frente a la climatología del cuadrante para la misma semana del año y el número de días con lluvia, viento o temperatura máxima extremos. Un día se considera extremo cuando supera el percentil 95 de la serie diaria del propio cuadrante, de modo que el umbral refleja lo inusual para cada lugar y no un valor absoluto común:

$$E^{v}_{q,s} = \sum_{d \in s} \mathbf{1}\left\{x^{v}_{q,d} > P^{v}_{95,q}\right\}, \tag{5.2}$$

donde:

- $E^{v}_{q,s}$: Número de días de la semana s en los que la variable climática v (precipitación, viento o temperatura máxima) fue extrema en el cuadrante q.
- $x^{v}_{q,d}$: Valor diario de la variable v en el cuadrante q el día d.
- $P^{v}_{95,q}$: Percentil 95 de la serie diaria de v en el cuadrante q, calculado con 2021–2023.
- $\mathbf{1}\{\cdot\}$: Función indicadora.

Los umbrales y la climatología de referencia se estimaron con 2021–2023, fuera del periodo de modelado, y todos los indicadores entran rezagados una semana, en coherencia con la regla de disponibilidad *ex ante*. Como referencia descriptiva, y no como predictora, se examinó también su asociación con la ocurrencia de falla en la misma semana.

Quedan *excluidas* como predictoras contemporáneas $\texttt{usuarios_afectados}_t$, $\texttt{elementos_afectados}_t$, $\texttt{n_eventos}_t$ y $\texttt{duracion_total}_t$ al pronosticar SAIFI_t o SAIDI_t. También se excluye la respuesta cruzada contemporánea: al modelar SAIDI_t no se emplea SAIFI_t y viceversa, puesto que ambas comparten el factor $\texttt{usuarios_afectados}_t$ en su numerador y su inclusión recíproca reintroduciría por la puerta trasera la fuga que la partición busca cerrar.

5.4.2. Construcción de la variable respuesta

Las respuestas son $Y_t = \mathrm{SAIFI}_t$ y $Y'_t = \mathrm{SAIDI}_t$, calculadas en cada fila cuadrante × semana como

$$\begin{aligned} \mathrm{SAIFI}_{q,s} &= \frac{\texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \\ \mathrm{SAIDI}_{q,s} &= \frac{\texttt{duracion_total}_{q,s} \times \texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \end{aligned} \tag{5.3}$$

donde:

- $\mathrm{SAIFI}_{q,s}$, $\mathrm{SAIDI}_{q,s}$: Indicadores operativos de frecuencia y de duración del cuadrante q en la semana s.
- $\texttt{usuarios_afectados}_{q,s}$: Usuarios afectados por los eventos del cuadrante q en la semana s.
- $\texttt{duracion_total}_{q,s}$: Duración total de los eventos del cuadrante q en la semana s.

- $UT_{m(s)}$: Usuarios totales del sistema en el mes calendario de la fecha de inicio de la semana s (`CS1_UT_M` en `data_usuarios_totales_sistema.csv`).

Tres decisiones merecen justificación explícita. La primera concierne al alcance de los indicadores y a su denominador. Los indicadores regulatorios definidos en las ecuaciones (3.1) y (3.2) se calculan sobre la totalidad del SDL, con agregación mensual y cierre anual, y su cálculo oficial ya lo realiza el operador a partir de sus sistemas de reporte. Este trabajo no pretende replicar ese cálculo: el problema planteado en el Capítulo 1 es que el indicador agregado no revela *dónde* ni *cuándo* se concentra la afectación, que es la información necesaria para orientar la operación y el mantenimiento hacia la reducción de los índices anuales y de las compensaciones asociadas. Por esa razón, $\mathrm{SAIDI}_{q,s}$ y $\mathrm{SAIFI}_{q,s}$, definidos de forma idéntica en el planteamiento del problema, se interpretan como *indicadores operativos de afectación* del cuadrante q en la semana s y no como el indicador regulatorio desagregado.

La elección del denominador $UT_{m(s)}$, común a todos los cuadrantes, es deliberada y coherente con ese propósito. Con un denominador único, el valor de cada cuadrante–semana queda referido a la base de usuarios de la empresa y ordena las zonas según su peso en la afectación total percibida por los usuarios del operador. En consecuencia, un cuadrante con muchos usuarios y frecuentes interrupciones pesa más que uno pequeño con el mismo número de eventos, que es exactamente el ordenamiento que interesa para priorizar intervenciones cuyo objetivo es reducir el índice global. Un denominador local, basado en los usuarios del cuadrante, respondería a una pregunta distinta —qué tan deficiente es la calidad percibida por el usuario típico de cada zona— y no permitiría ordenar las zonas según su impacto sobre la meta regulatoria.

Dos diferencias respecto del cálculo regulatorio deben quedar explícitas para evitar una lectura equivocada. Primera, el numerador de $\mathrm{SAIDI}_{q,s}$ combina la duración acumulada y los usuarios afectados de la semana, mientras que la regulación pondera cada evento por sus propios usuarios ($\sum_i D_i\, NU_i$); ambas expresiones coinciden en las semanas con un único evento y, en las demás, la forma agregada sobrestima el nivel; además, el panel diario conserva los usuarios de un solo evento cuando un elemento falla varias veces el mismo día, lo que reduce el numerador de ambos indicadores. El Apéndice A.5 reconstruye los indicadores evento a evento y muestra que el orden de los cuadrantes se conserva en buena medida (correlación de Spearman de 0.97 en SAIDI y de 0.999 en SAIFI entre los totales por cuadrante), pero que la concentración de la afectación y parte del grupo de cuadrantes prioritarios cambian. Por ello $\mathrm{SAIDI}_{q,s}$ y $\mathrm{SAIFI}_{q,s}$ se interpretan como índices de severidad relativa y no como fracciones sumables de los indicadores de la empresa. Segunda, la cobertura

del emparejamiento evento–elemento en 2024 y 2025 (77.7 % y 92.4 %; Tabla 6.9) implica que la suma de los indicadores por cuadrante no reproduce el valor oficial del operador; por ello los resultados se emplean para *ordenar y anticipar* la afectación territorial y no para estimar el indicador regulatorio.

En cambio, los indicadores operativos sí comparten con el cálculo regulatorio el universo de eventos. El numerador se construye solo con los eventos que la propia empresa registra como computables para la calidad del servicio: la extracción de BRAE conserva los registros con `FDD_EXCLUSION` = `NO EXCLUIDA`, descarta la causa `FDD_CAUSA_SSPD` $= 1$ y exige fecha de reconexión (Sección 5.1.3). De este modo quedan fuera, con el mismo criterio con que el operador reporta sus indicadores, los eventos que la Resolución CREG 015 de 2018 [1] exime del cálculo, como las interrupciones de hasta tres minutos, las originadas en activos del STN o del STR, los racionamientos programados, las catástrofes naturales y los actos de terrorismo (Sección 3.1). La verificación sobre los 39 272 eventos de 2024–2025 confirma que ninguno dura menos de tres minutos; 161 eventos (0.41 %) duran exactamente tres minutos, valor que no puede discriminarse mejor porque los registros tienen resolución de minuto, y cuyo peso es demasiado pequeño para alterar los resultados. Esta coherencia con las exclusiones regulatorias es la que permite interpretar la afectación modelada como la que efectivamente cuenta para las metas y compensaciones del operador.

La segunda es la asignación mensual del denominador a la semana. La serie de usuarios totales se reporta con periodicidad mensual, mientras que el panel opera en semanas; la regla adoptada asigna a cada semana el UT del mes calendario de su fecha de inicio. El efecto de esta aproximación es pequeño en la práctica, porque UT varía lentamente (crecimiento vegetativo de la base de clientes) frente a la variabilidad semanal del numerador, pero debe quedar documentada como una fuente menor de imprecisión en las semanas que cruzan el cambio de mes.

La tercera es la decisión de *modelar ambos indicadores por separado* en lugar de imponerles una especificación única. SAIDI y SAIFI comparten el factor `usuarios_afectados` pero difieren en que el primero lo pondera por la duración acumulada: SAIFI mide cuántos usuarios se vieron interrumpidos y SAIDI cuánto tiempo lo estuvieron. Operativamente responden a palancas distintas —la frecuencia depende de la exposición y del estado del activo, la duración depende además de la capacidad de respuesta y de la accesibilidad del punto de falla—, y sus distribuciones difieren en varios órdenes de magnitud, lo que haría que un modelo conjunto quedara dominado por la escala de uno de los dos. Los resultados de la Etapa 5 confirman esta decisión: el mejor modelo de pronóstico no coincide entre indicadores (Sección 6.5).

Finalmente, `n_eventos` y `duracion_total` no se modelan como Y: perma-

necen como insumos de construcción y como historial rezagado. `elementos_afectados` no entra en Y ni como predictora contemporánea, y queda restringido a la descripción de severidad del EDA.

5.4.3. Análisis de asociación y depuración de variables cuantitativas

Se define el conjunto candidato *ex ante* sobre D_{mod} (clima rezagado, histórico de eventos, rasgos del cuadrante, exposición y estacionalidad) y se excluyen, por diseño, el clima contemporáneo, la respuesta alterna contemporánea y el impacto posterior (`usuarios_afectados`, `elementos_afectados`). La depuración se estima solo con el entrenamiento (2024) y combina filtros de cobertura, varianza casi nula, asociación de Spearman con corrección FDR, agrupamiento por redundancia ($|\rho| \geq 0.70$) y eliminación iterativa por VIF (umbral 5). No se borran variables del panel: se depuran de la matriz de diseño.

De 27 candidatas se retienen 13 (Figuras 5.12–5.14): precipitación rezagada y acumulada, humedad rezagada, viento máximo rezagado, rezagos de `n_eventos`, estacionalidad armónica, altitud, longitud y $\log(\texttt{n_activos} + 1)$ como *offset*. Las temperaturas y los promedios móviles del histórico se descartan por redundancia o multicolinealidad. El procedimiento se documenta en el Apéndice A.3.16 (informe HTML).

El orden de los filtros no es arbitrario y conviene explicitarlo, porque condiciona el resultado. Primero operan los criterios que no dependen de la respuesta —cobertura y varianza casi nula—, de modo que ninguna variable se descarta por su relación con Y antes de haber superado el umbral mínimo de informatividad propia. Después se evalúa la asociación con la respuesta mediante Spearman, deliberadamente en su versión por rangos y no de Pearson, dada la asimetría y la cero-inflación documentadas en la Sección 6.3.4, y con corrección FDR porque el número de contrastes simultáneos hace esperable una proporción no despreciable de significancias espurias. Por último se aplica el tratamiento de redundancia: el agrupamiento por $|\rho| \geq 0.70$ identifica bloques de variables que miden esencialmente lo mismo y de cada bloque se conserva un representante, y la eliminación iterativa por VIF (umbral 5) remueve la colinealidad que solo aparece en combinaciones de tres o más variables y que el análisis bivariado no detecta.

Dos salvaguardas acompañan el procedimiento. La primera es que *todos* los estadísticos de depuración se calculan exclusivamente sobre el conjunto de entrenamiento. Estimarlos sobre el panel completo constituiría una forma sutil de fuga de información, porque la decisión de qué variables conservar habría sido tomada mirando datos del periodo de prueba. La segunda es que la depuración no borra columnas del panel: solo determina qué entra en la matriz de diseño. El

panel enriquecido conserva las 27 candidatas, de modo que una especificación alternativa puede reconstruirse sin reejecutar la cadena de integración de las Etapas 1 y 2.

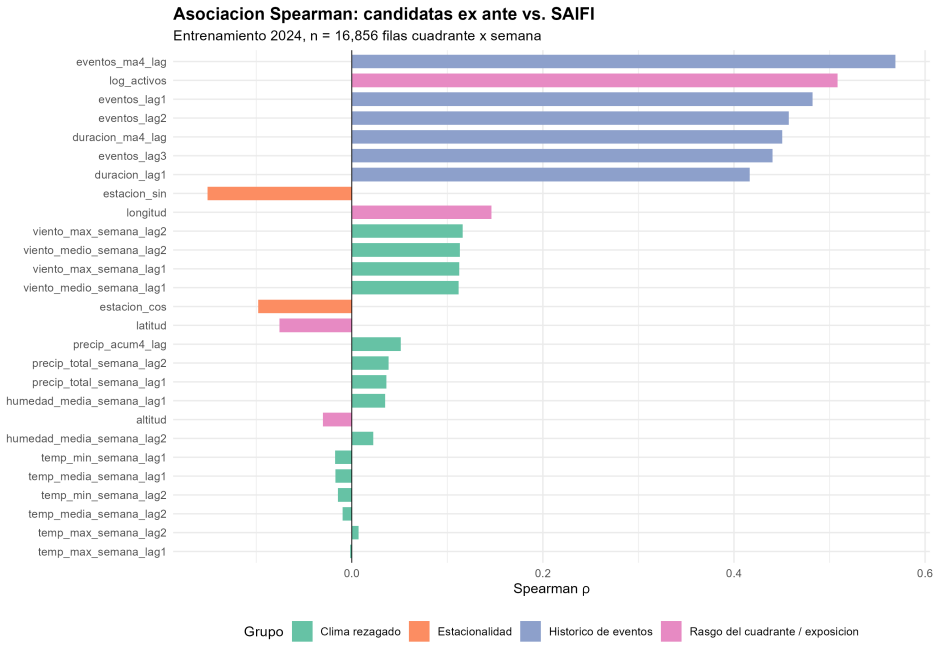


Figura 5.12: Asociación de Spearman entre candidatas *ex ante* y $SAIFI$ (año 2024 de D_{mod}, corte exploratorio previo a la partición final).

5.4.4. Análisis de asociación y depuración de variables cualitativas

Las cualitativas candidatas (`estrato_predominante_municipal`, tipología de zona, indicadores de régimen lluvioso/seco y *flags* de exposición como `cat_ndvi`) se depuran por cobertura de categorías y por asociación con $SAIFI/SAIDI$ en el entrenamiento, siguiendo la misma lógica de la Sección 5.4.3 pero con instrumentos adecuados al nivel de medición.

El criterio de cobertura atiende un problema específico de las variables nominales en paneles territoriales: una categoría presente en un número reducido de cuadrantes produce coeficientes estimados sobre muy pocas observaciones efectivas, con errores estándar grandes y alta sensibilidad a la partición temporal. Cuando además esos cuadrantes se concentran en una franja del horizonte, la categoría puede quedar representada en el entrenamiento y ausente en la prueba, lo que impide generar predicción. Por ello las categorías con frecuencia marginal se colapsan en un nivel agregado antes de cualquier contraste, y no después.

La asociación con la respuesta se evalúa mediante el estadístico V de Cramér

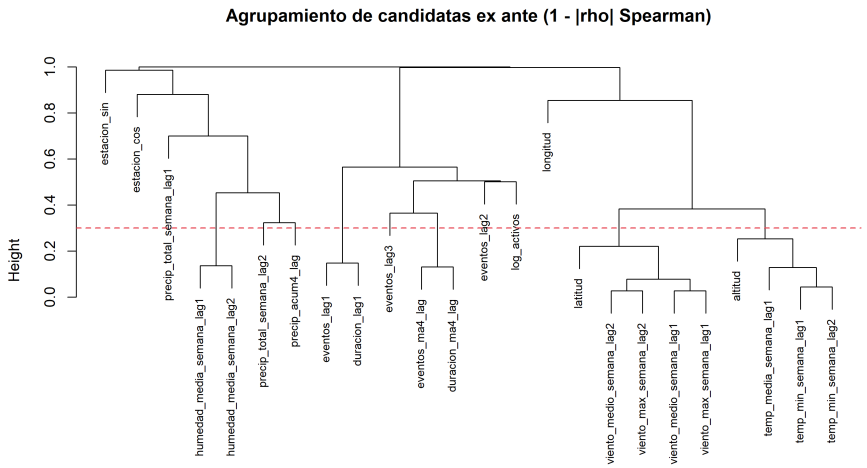


Figura 5.13: Agrupamiento jerárquico de candidatas ($1-|\rho|$ Spearman); la línea punteada marca el umbral $|\rho| = 0.70$.

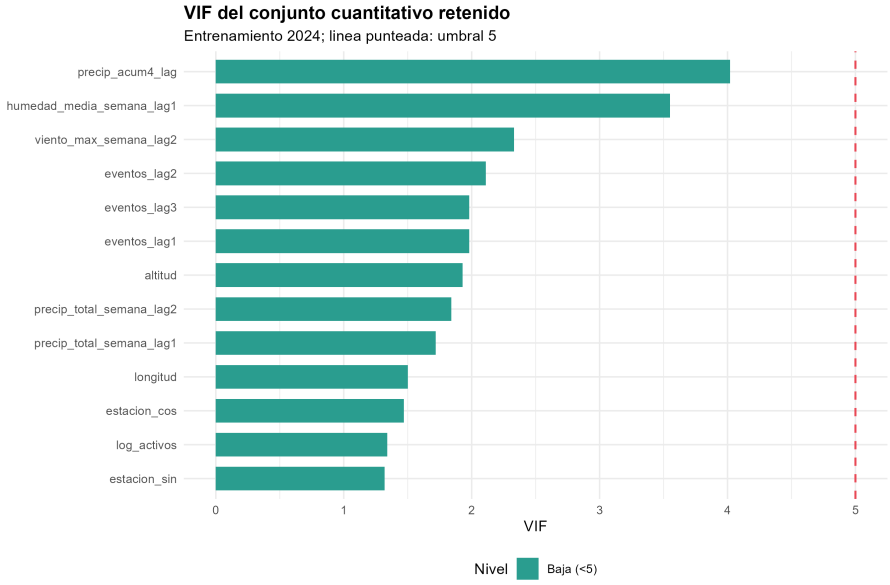


Figura 5.14: VIF del conjunto cuantitativo retenido tras la depuración iterativa (umbral 5).

entre pares de cualitativas y mediante contrastes de diferencia de distribución de $SAIFI/SAIDI$ entre niveles, conforme se formaliza en la Sección 3.1.2. La elección de V de Cramér sobre el χ^2 crudo responde a que el primero normaliza por el tamaño muestral y por el número de categorías, lo que permite comparar la fuerza de asociación entre variables con distinto número de niveles; con $N_{\text{mod}} = 36\,120$ observaciones, prácticamente cualquier asociación resulta estadísticamente significativa y el valor p deja de ser un criterio discriminante útil.

Un resultado relevante de esta depuración es que buena parte del contenido de las cualitativas territoriales ya está representado de forma continua en el panel. El estrato predominante municipal, por ejemplo, resume en una etiqueta única la misma información que las proporciones `prop_estrato_1` a `prop_estrato_6` expresan con mayor resolución; conservar ambas introduce redundancia sin ganancia informativa. Por esa razón la matriz de diseño final privilegia las proporciones y deja la etiqueta modal (`estrato_modal_real`) como variable de apoyo interpretativo. Las variables sin contraste útil se excluyen de la matriz de diseño sin borrarlas del panel. El procedimiento reproducible se documenta en el Apéndice A.3.16 (informe HTML), y la construcción de las variables de estratificación en el Apéndice A.3.19 (informe HTML).

5.4.5. Codificación de variables categóricas

Las categóricas retenidas se codifican como *dummy* de referencia (contrastes tratamiento) o, cuando el orden es informativo, como factor ordinal. La distinción tiene consecuencias interpretativas directas: bajo contrastes tratamiento cada coeficiente mide la diferencia respecto de una categoría base explícita, mientras que un factor ordinal impone una progresión monótona entre niveles. El estrato admite esta segunda lectura porque su escala es efectivamente ordenada en términos socioeconómicos y de densidad de demanda; la tipología de zona no, porque sus niveles no guardan relación de orden.

La codificación se ajusta además a la especificación empleada. En las estimaciones con efectos fijos de cuadrante, cualquier atributo invariante en el tiempo dentro del cuadrante queda absorbido por el efecto fijo y su *dummy* resulta no identificable; incluirla produciría colinealidad perfecta con el conjunto de indicadores de cuadrante. Por ello las cualitativas estáticas se conservan en las especificaciones *Pooled* OLS y en el corte transversal SAR/SEM, donde sí aportan variación explotable, y se omiten de las especificaciones FE. Esta no es una pérdida de información sino un reconocimiento de qué pregunta responde cada modelo: el FE estima el efecto de lo que cambia *dentro* de un cuadrante a lo largo del tiempo, no el de lo que distingue a un cuadrante de otro.

Ninguna codificación se deriva de información posterior al corte de prueba: los niveles, las categorías base y las reglas de colapsamiento se fijan sobre el entrenamiento y se aplican sin modificación al conjunto de prueba, incluso si en este aparece una categoría no observada previamente, caso en el que la observación se asigna al nivel agregado. En el panel de modelado espacial, las proporciones de estrato (`prop_estrato_*`, `prop_no_residencial`) entran ya como proporciones numéricas en $[0, 1]$ y no requieren *dummy* adicional.

5.4.6. Estandarización de variables cuantitativas

Las cuantitativas continuas se estandarizan (z-score) solo cuando el algoritmo lo exige. El criterio es que la estandarización es necesaria cuando el procedimiento de estimación depende de la escala —métodos regularizados, en los que la penalización castiga desproporcionadamente a las variables de magnitud pequeña, y métodos basados en distancias, en los que una variable medida en milímetros de lluvia dominaría mecánicamente a otra medida en proporciones— e innecesaria cuando no lo es. En OLS y en los efectos fijos de `fixest` las estimaciones son equivariantes ante cambios de escala, de modo que estandarizar no altera el ajuste y sí dificulta la lectura: un coeficiente en escala original expresa el cambio en la respuesta por milímetro adicional de precipitación o por año adicional de antigüedad del activo, magnitudes que el operador puede interpretar directamente. Random Forest, por su parte, es invariante ante transformaciones monótonas de los predictores, por lo que la estandarización es irrelevante para su ajuste.

Cuando sí se estandariza, los parámetros de centrado y escala ($\bar{x}$ y s_x) se estiman únicamente sobre el entrenamiento y se aplican al conjunto de prueba sin recalcular, por la misma razón que rige la depuración: recalcularlos sobre el panel completo filtraría información del periodo de prueba hacia el preprocesamiento.

Las respuestas reciben un tratamiento distinto al de los predictores. $SAIDI$ y $SAIFI$ se transforman con $\log(1 + y)$ ante asimetría y presencia de ceros, según `Etapa5_01/Etapa5_02` (Apéndices A.3.28 y A.3.29). La elección de $\log(1 + y)$ y no de $\log(y)$ es forzada por la masa de ceros estructurales del panel: no se registra ningún evento en el $74.9\,\%$ de las semanas-cuadrante de D_{EDA} (2021–2025) ni en el $63.0\,\%$ de las de D_{mod} (2024–2025) (Sección 6.3.4) y el logaritmo simple no está definido en ese punto. El desplazamiento unitario preserva el cero como cero y aproxima el comportamiento logarítmico en la cola derecha, que es precisamente donde la asimetría compromete la estabilidad de la estimación.

5.4.7. Generación de ventanas temporales

Por cuadrante se construyen rezagos $t-1, \ldots, t-h$ de clima y de la respuesta, medias móviles (precipitación y viento a cuatro semanas, `precip_ma4` y `viento_`

`ma4`) e indicadores de calendario (mes, trimestre, términos armónicos). La construcción se realiza *dentro* de cada cuadrante, previo ordenamiento por semana, de modo que ningún rezago arrastre valores de un cuadrante vecino ni cruce la frontera entre series territoriales distintas.

La justificación empírica es directa. El análisis exploratorio (Sección 6.3.5) estableció una autocorrelación de 0.80 en el primer rezago sobre D_{mod} (el 0.92 de D_{EDA} está inflado por el cambio de nivel de 2024), con decaimiento lento (0.60 a doce semanas, 0.38 a veintiséis) y un repunte a 0.43 en el rezago de cincuenta y dos semanas. Estos tres hechos determinan tres decisiones de diseño distintas: la persistencia de corto plazo motiva incluir al menos el primer rezago de la respuesta como predictora *ex ante*; el decaimiento lento, sin corte abrupto, desaconseja fijar un orden de rezago elevado, puesto que rezagos sucesivos aportan información cada vez más redundante y encarecen la estimación con un costo creciente en grados de libertad; y el repunte anual justifica la inclusión de términos estacionales explícitos en lugar de intentar capturar la estacionalidad mediante un rezago de orden 52, que consumiría un año completo de datos en una ventana de modelado de apenas dos años.

El costo de esta construcción es la pérdida de las primeras observaciones de cada serie, para las que el rezago no está definido. Con h fijado en valores bajos y medias móviles de cuatro semanas, la pérdida se concentra en las primeras semanas de D_{mod} y resulta marginal frente a las 105 semanas disponibles. La evidencia que respalda la selección concreta de rezagos se documenta en el Apéndice A.3.27 (informe HTML).

5.4.8. Partición de datos en entrenamiento y prueba

Con fundamento en el diagnóstico de cobertura del emparejamiento evento–elemento (Sección 6.3.5), el universo de estimación se restringe a D_{mod}: observaciones cuadrante $\times$ semana con `year(semana)` $\in \{2024, 2025\}$, periodo en el que la coincidencia entre `COMPONENTE_FALLADO` y el inventario GIS (`tipo_elemento.csv`) alcanza al menos el $79.8\,\%$, frente a $\approx 31\,\%$ en 2021–2023 bajo OMS-SPARD. Los años 2021–2023 no se incluyen ni en entrenamiento ni en prueba, dado el sesgo por incompatibilidad entre código de activo y código de sitio: entrenar con ese tramo introduciría un subregistro sistemático y no aleatorio de eventos, que el modelo aprendería como si fuera una propiedad del territorio.

La partición es *estrictamente temporal* y nunca aleatoria. La razón es que el muestreo aleatorio sobre un panel autocorrelacionado produce una estimación optimista del desempeño: con una ACF de 0.80 en el primer rezago, una observación asignada al conjunto de prueba tiene vecinas temporales inmediatas en el conjunto de entrenamiento, de modo que el modelo dispone de información casi

equivalente a la que debe predecir. El corte cronológico reproduce, en cambio, la situación real de uso, en la que el modelo se entrena con el pasado y se evalúa sobre un futuro que no ha observado.

El corte es proporcional: se ordenan las semanas del panel y se reserva el 15 % final como *holdout*. La semana de corte es la del 8 de septiembre de 2025, de modo que el entrenamiento comprende las semanas del 1 de enero de 2024 al 8 de septiembre de 2025 y la prueba las 16 semanas comprendidas entre el 15 de septiembre y el 29 de diciembre de 2025. Este esquema maximiza el tamaño del conjunto de entrenamiento en un horizonte ya corto y garantiza que ninguna semana de prueba preceda a una semana de entrenamiento. La depuración de variables de la Sección 5.4.3 se estimó sobre 2024, un subconjunto del entrenamiento, por lo que tampoco utiliza información del periodo de prueba.

Una consecuencia conocida de la partición temporal estricta afecta a la especificación con efectos fijos de cuadrante y semana: como las semanas del conjunto de prueba no aparecen en el entrenamiento, sus efectos fijos temporales no están estimados y el modelo no produce predicción fuera de muestra. Esto no invalida la especificación —sigue siendo informativa para la descomposición de varianza dentro de muestra— pero sí implica que no participa de la comparación predictiva, como se documenta en la Sección 6.5.

5.4.9. Construcción de matrices de diseño

Esta subsección cierra la partición formulada en la ecuación (5.1): fija de manera explícita y verificable qué columnas constituyen el vector de respuesta $\mathbf{y}$ y cuáles la matriz de predictoras $\mathbf{X}$ con la que se estiman los modelos de la Etapa 5. La especificación semanal que se somete a estimación adopta la forma

$$\begin{aligned}\log\left(1+Y_{q,s}\right) = \mathbf{x}_{q,s}^{\top}\boldsymbol{\beta} + \gamma\log\left(1+Y_{q,s-1}\right) + \phi\log\left(1+\overline{Y}_{\mathcal{N}(q),\,s-1}\right) \\ + \mu_q + \tau_s + \varepsilon_{q,s},\end{aligned} \tag{5.4}$$

donde:

- $Y_{q,s}$: Respuesta del cuadrante q en la semana s, con $Y \in \{\mathrm{SAIDI}, \mathrm{SAIFI}\}$.
- $\mathbf{x}_{q,s}$: Vector de covariables *ex ante*; $\boldsymbol{\beta}$, su vector de coeficientes.
- γ: Coeficiente del rezago propio de la respuesta.
- $\overline{Y}_{\mathcal{N}(q),\,s-1}$: Promedio de la respuesta en los cuadrantes vecinos de q en la semana anterior; como el rezago propio, entra en la escala $\log(1+y)$ de la respuesta.
- ϕ: Coeficiente del rezago espacial; se usa ϕ y no ρ para no confundirlo con el parámetro autorregresivo espacial del modelo SAR.

- μ_q, τ_s: Efectos fijos de cuadrante y de semana, presentes solo en las especificaciones que los declaran.
- $\varepsilon_{q,s}$: Término de error.

La Tabla 5.11 detalla la asignación final de columnas a cada clase. La estructura de $\mathbf{X}$ es prácticamente idéntica para ambos indicadores; la única diferencia es que los términos autorregresivos y el rezago espacial se construyen sobre la respuesta que se está modelando, de modo que al estimar SAIDI entran $\log(1+\text{SAIDI}_{q,s-1})$ y $\log(1+\overline{\text{SAIDI}}_{\mathcal{N}(q),s-1})$ (`ly_lag1` y `ly_vec_lag1` en el código), y al estimar SAIFI sus equivalentes. Ambos rezagos se transforman con la misma función que la respuesta, de modo que la ecuación (5.4) es exactamente la que se estima. Esta simetría es deliberada: permite atribuir las diferencias de desempeño entre indicadores a la naturaleza del fenómeno y no a una asimetría introducida por el diseño de la matriz.

Tres observaciones precisan la lectura de la tabla. La primera es que `id_cuadrante` y `semana` ocupan una posición intermedia entre llave y predictora: no son covariables sustantivas, pero en las especificaciones FE se consumen como índices de absorción y, en esa función, capturan toda la heterogeneidad no observada invariante en cada dimensión. La segunda es que las coordenadas no entran como regresores sino como insumo de la matriz de contigüidad *queen* que define la vecindad $\mathcal{N}(q)$; su rol es estructural, no explicativo. La tercera es que el bloque $\mathcal{P}$ no se elimina del panel: permanece disponible para el análisis descriptivo de severidad y para la construcción de las respuestas, pero no se expone al estimador como covariable.

El número de predictoras, 16, es deliberadamente moderado frente a las 44 candidatas inicialmente disponibles en el panel enriquecido. Con 344 cuadrantes y 105 semanas, el panel semanal admitiría técnicamente especificaciones más amplias, pero el corte transversal empleado para SAR/SEM opera sobre $N = 344$ observaciones, donde la parsimonia deja de ser una preferencia estética y pasa a ser una condición de identificabilidad. Las dos escalas no comparten exactamente la misma matriz: el corte transversal usa los atributos estructurales del panel más la proporción de transformadores, que en el panel queda absorbida por el efecto fijo, y sustituye las variables semanales por sus promedios del periodo (NDVI, precipitación y distancia al sismo más cercano), sin rezagos de la respuesta. La Tabla A.3 indica qué variables usa cada modelo. Varias variables estructurales retenidas presentan factores de inflación de varianza altos (las proporciones de estrato 1 y 2, de 24 a 25, y el número de elementos y la longitud de la red, de 15 a 17); se conservan porque su papel es controlar la composición y la escala del cuadrante, y no se interpretan sus coeficientes individuales.

Tabla 5.11: Partición final de variables antes de la estimación: respuesta $\mathbf{y}$, predictoras $\mathbf{X}$, llaves y exclusiones

Clase	Bloque	Variables
$\mathbf{y}$ (respuesta)	Continuidad	`SAIDI`, `SAIFI`; estimadas como `log_SAIDI1` $= \log(1 + \text{SAIDI})$ y `log_SAIFI1` $= \log(1 + \text{SAIFI})$, en modelos separados
$\mathbf{X}$ (predictoras)	Clima $(t-1)$	`temp_media_semana`, `viento_max_semana`, `precip_total_semana`, `precip_ma4`
	Vegetación $(t-1)$	`ndvi_semanal`
	Exposición externa $(t-1)$	`n_sismos_r50`, `dist_sismo_min_km_r50`
	Infraestructura y topología	`n_elementos`, `longitud_red_km`, `densidad_terminales`
	Composición socioeconómica	`prop_estrato_1`, `prop_estrato_2`, `prop_no_residencial`
	Dinámica temporal y espacial	$\log(1 + Y_{q,s-1})$; $\log(1 + \overline{Y}_{\mathcal{N}(q),s-1})$; `ndvi_vecinos` $(t-1)$
$\mathcal{K}$ (llaves)	Identificación	`id_cuadrante`, `semana` (índices de efectos fijos y de ordenamiento); `latitud`, `longitud`, `altitud` (geolocalización y matriz de vecindad)
$\mathcal{P}$ (excluidas)	Impacto posterior	`usuarios_afectados`$_t$, `elementos_afectados`$_t$
	Insumos de la respuesta	`n_eventos`$_t$, `duracion_total`$_t$ (admitidas solo rezagadas)
	Respuesta cruzada	SAIFI_t al modelar SAIDI_t, y viceversa
	Información posterior al periodo	`edad_activo_mas_viejo_anios`, `PROM_CANT_MODIFICACIONES` (construidas con fechas de modificación de 2026)

Nota: el conjunto de 16 predictoras de $\mathbf{X}$ corresponde a la especificación final de la Etapa 5 (`Etapa5_09_reestimacion_v3.Rmd`), obtenida tras depurar las 44 candidatas iniciales por los criterios de las Secciones 5.4.3 y 5.4.4. Respecto de los informes preliminares (`Etapa5_01` y `Etapa5_02`), las variables observadas en la semana s —clima, vegetación y sismicidad— entran rezagadas una semana $(t-1)$; se añade `n_elementos`, constante en el tiempo; y se excluyen la edad del activo más antiguo y el número promedio de modificaciones, porque se calculan con fechas de modificación registradas mayoritariamente en 2026 (67 % de las fechas; edad negativa en el 93.2 % de las filas) y no estaban disponibles en las semanas que se pronostican. La trazabilidad de cada variable se presenta en la Tabla A.3 del Apéndice A.4.

Los insumos se materializan en `data_final_modelo_cuadrantes_reales.rds`, cuya construcción y verificación se documentan en los Apéndices A.3.22 (informe HTML) y A.3.25 (informe HTML), y cuyo uso en la estimación se detalla en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.4.10. Reducción de dimensionalidad

La reducción de dimensionalidad en este trabajo se entiende como selección de variables y no como proyección a un espacio latente. Además del filtrado por Spearman y VIF descrito en la Sección 5.4.3, opera un segundo mecanismo dependiente de la especificación: las variables estáticas por cuadrante quedan absorbidas por los efectos fijos cuando la especificación es FE y, en consecuencia, se omiten de esa matriz, mientras se retienen en *Pooled* OLS y en el corte transversal SAR/SEM, donde constituyen precisamente la fuente de variación de interés.

La decisión de no emplear PCA como paso obligatorio merece justificación, porque es una desviación respecto de la práctica habitual en problemas con bloques de covariables correlacionadas. El PCA sí se ejecutó, pero como *diagnóstico* de redundancia y no como generador de predictoras (Apéndice A.10): confirmó que dos componentes concentran el 87.3 % de la varianza climática y que el bloque operativo se resume casi por completo en una sola dirección (83.8 % en PC1). Convertir esas componentes en regresores habría reducido la dimensión, pero a un costo incompatible con el objetivo del proyecto. Una componente principal es una combinación lineal de temperaturas, humedad, viento y precipitación sin referente físico ni operativo; un coeficiente estimado sobre ella no puede traducirse en una recomendación de gestión. Dado que el OE2 exige *identificar qué variables son más relevantes* y el OE3 evaluar modelos con vocación de uso, se privilegió conservar variables originales interpretables y resolver la colinealidad eliminando redundancia explícita.

El criterio operativo resultante es que la reducción se guía por dos señales: la redundancia medida (agrupamiento jerárquico y VIF) y el aporte marginal verificado. Este último se evalúa en la Etapa 5 mediante la significancia de cada variable en el modelo FE, su importancia por permutación en el Random Forest y su contribución en el corte transversal (Tabla 6.27), lo que permite decidir la permanencia de cada bloque con evidencia y no por supuesto.

5.4.11. Segmentación analítica

El modelado principal opera sobre las semanas con falla (`hubo_falla`$= 1$), decisión que condiciona la interpretación de todos los resultados posteriores y debe explicitarse. El panel está dominado por ceros estructurales: en el universo

exploratorio D_{EDA} (2021–2025) el $74.9\,\%$ de los pares cuadrante–semana no registra ningún evento (Sección 6.3.4), y en el panel de modelado D_{mod} (2024–2025) la proporción es del $63.0\,\%$ ($22\,769$ de $36\,120$ filas). Estimar sobre el panel completo convertiría el problema en uno de detección de ausencia de falla, donde un modelo trivial que prediga siempre cero alcanzaría un error aparentemente bajo sin contenido informativo alguno. Al restringir la estimación a las semanas con evento, la pregunta se reformula con precisión: condicional a que el cuadrante experimentó al menos una interrupción, ¿qué magnitud alcanza su contribución a SAIDI o SAIFI? Esta es la pregunta operativamente relevante, porque es la que determina el impacto sobre el indicador agregado del operador.

La contrapartida es que el modelo de magnitud no pronostica la *ocurrencia* de falla. Para cubrir esa parte se estima un segundo componente: un clasificador Random Forest de `hubo_falla` sobre el panel completo, con las mismas predictoras *ex ante* más el indicador de falla de la semana anterior, evaluado por el área bajo la curva ROC. Ambos componentes se combinan en el valor esperado incondicional $\mathbb{E}[Y_{q,s}] = P(\text{falla}_{q,s}) \times \mathbb{E}[Y_{q,s} \mid \text{falla}_{q,s}]$, lo que constituye una estructura en dos partes. Un modelo de conteo con inflación de ceros queda como alternativa para trabajo futuro (Capítulo 7).

En paralelo opera una segunda segmentación, de naturaleza distinta: el corte transversal ponderado agrega el panel a un único vector por cuadrante para estimar SAR y SEM sobre $N = 344$ observaciones. La ponderación sigue un esquema de *suma de dígitos*, que asigna a la semana en posición t de un total de n un peso $w_t = t \,/\, [n(n+1)/2]$, creciente de forma lineal hacia lo reciente y con suma unitaria. La elección responde a que el objetivo de esta agregación es caracterizar el estado *actual* del patrón territorial: una media simple trataría como equivalentes a una semana de inicio de 2024 y a una de cierre de 2025, pese a que la segunda es más representativa de la configuración vigente de la red.

Finalmente, la segmentación territorial derivada del EDA (los cuatro *clusters* de cuadrantes de la Sección 6.3.9) informa la interpretación de resultados y la priorización operativa, pero no sustituye la partición temporal ni se emplea para estimar modelos separados por grupo: con 343 cuadrantes repartidos en cuatro estratos muy desiguales, la estimación por grupo comprometería la precisión sin ganancia clara en capacidad explicativa.

5.4.12. Transformaciones adicionales para modelado

Sobre la matriz de diseño se aplican tres familias de transformaciones, cada una motivada por una propiedad distinta de los datos documentada en el EDA.

Transformación de escala de la respuesta. Se construyen $\log(1 + \text{SAIDI})$ y $\log(1 + \text{SAIFI})$. Más allá de la justificación por asimetría y ceros expuesta en la Sección 5.4.6, la transformación tiene una implicación interpretativa deseable: en escala logarítmica, los coeficientes de la ecuación (5.4) se leen aproximadamente como efectos relativos, lo que resulta más natural para un indicador cuya magnitud absoluta varía en varios órdenes entre cuadrantes. También implica que las métricas de desempeño reportadas en la Etapa 5 están en escala logarítmica y no son directamente comparables con errores expresados en horas-usuario.

Rezagos espaciales. Se construyen `SAIDI_vecinos_lag1`, `SAIFI_vecinos_lag1` y `ndvi_vecinos` mediante una matriz de contigüidad *queen* estimada con `spdep`, en la que dos cuadrantes son vecinos si comparten al menos un punto de frontera. El criterio *queen* —frente al *rook*, que exige frontera compartida de longitud positiva— se adopta porque sobre la malla regular de cuadrantes incorpora también los vecinos diagonales, lo que resulta más coherente con la propagación de fallas a lo largo de circuitos que no siguen la orientación de la malla. Dos precisiones son importantes: el rezago espacial se toma siempre en $t - 1$, nunca contemporáneo, porque el valor simultáneo de los vecinos no está disponible en el momento de pronosticar y su uso reintroduciría fuga de información; y la vecindad se define sobre cuadrantes con presencia efectiva de red, con política de cero vecinos admitida para las celdas aisladas. La construcción de la matriz de vecindad se documenta en el Apéndice A.3.21 (informe HTML).

Interacciones exposición × infraestructura. Se construyen `ndvi_x_elementos` y `sismo_x_elementos`, bajo la hipótesis de que el riesgo ambiental se materializa de forma proporcional a la cantidad de activos expuestos. Incluirlas como términos explícitos permite que las especificaciones lineales capturen una relación que, de otro modo, solo Random Forest podría aproximar; su comparación informa, por tanto, sobre cuánto de la ventaja del modelo no paramétrico proviene de interacciones de este tipo y cuánto de no linealidades de otra naturaleza. El detalle de implementación se documenta en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.4.13. Resultados y entregables de la etapa

La Etapa 4 convierte el panel enriquecido de la Etapa 2, depurado y diagnosticado en la Etapa 3, en un artefacto listo para estimación. Su resultado sustantivo no es un conjunto de datos adicional sino una *decisión documentada*: la partición de la ecuación (5.1), materializada en la Tabla 5.11, que fija qué se predice, con

qué se predice y qué se excluye deliberadamente pese a estar disponible. Esta última categoría es la que distingue un ejercicio predictivo válido de uno que solo parece serlo.

Resultado: panel analítico con respuestas SAIDI y SAIFI formalmente definidas, 16 predictoras *ex ante* depuradas de 44 candidatas, rezagos temporales y espaciales construidos sin fuga de información, y partición temporal documentada (*holdout* del 15 % final de semanas, con corte el 8 de septiembre de 2025).

Entregable: matriz depurada de predictoras (Secciones 5.4.3 y 5.4.9) y panel analítico final `data_final_modelo_cuadrantes_reales.rds`, documentados en los Apéndices A.3.26 (informe HTML), A.3.27 (informe HTML), A.3.16 (informe HTML), A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.5. Etapa 5 – Modelado predictivo y evaluativo

En esta etapa se estiman y comparan modelos para *SAIDI* y *SAIFI* por separado a grano cuadrante $\times$ semana, siguiendo `Etapa5_01_modelo_SAIDI_espacial.Rmd` y `Etapa5_02_modelo_SAIFI_espacial.Rmd` (Apéndices A.3.28–A.3.29). El diseño combina (i) modelos de panel para pronóstico semanal y (ii) modelos espaciales formales SAR/SEM en corte transversal ponderado. La validación es temporal; las métricas de referencia son $RMSE$, MAE y R^2 en escala $\log(1 + y)$.

5.5.1. Selección de algoritmos

Se seleccionan cuatro familias para el panel semanal: (1) *Pooled OLS*; (2) *efectos fijos de cuadrante*; (3) *efectos fijos de cuadrante y semana*; (4) *Random Forest* (`randomForest` con valores por defecto y `ranger` con hiperparámetros ajustados). Los efectos fijos se estiman por mínimos cuadrados con variables indicadoras, estimación idéntica a la de `feols` (`fixest`), con errores estándar agrupados por cuadrante y de Driscoll–Kraay (`sandwich`). En el corte transversal se estiman *SAR* y *SEM* (`spatialreg`). Todos los modelos se comparan además con dos *pronósticos de referencia* que no requieren estimación: la persistencia, que asigna a cada cuadrante el valor de su semana anterior, y la media histórica del cuadrante en el entrenamiento. Un modelo solo aporta valor predictivo si supera a ambos.

La selección no responde a un criterio de exhaustividad sino a una secuencia de relajación de supuestos, en la que cada familia levanta una restricción de la anterior y permite atribuir las ganancias de desempeño a una causa identificable. *Pooled* OLS constituye la referencia mínima: supone que todos los cuadrantes comparten el mismo intercepto y que las covariables observadas agotan la heterogeneidad territorial, supuesto que el EDA ya había cuestionado al docu-

mentar concentración espacial de fallas. Los efectos fijos de cuadrante relajan ese supuesto permitiendo un intercepto por celda, con lo que absorben toda la heterogeneidad no observada invariante en el tiempo —calidad constructiva de la red, accesibilidad del terreno, prácticas de mantenimiento local— sin necesidad de medirla; el precio es que los atributos estáticos del cuadrante dejan de ser identificables. Los efectos fijos de cuadrante y semana añaden un intercepto temporal común que captura choques sistémicos que afectan a toda la concesión en una semana dada, como un temporal regional o un cambio en los protocolos de registro. Random Forest abandona la linealidad y la aditividad, y permite contrastar cuánta estructura queda sin capturar por las especificaciones paramétricas.

Los modelos espaciales responden a una pregunta distinta de las anteriores. Mientras las cuatro familias de panel tratan la dependencia entre vecinos de forma reducida, mediante un regresor de rezago espacial, SAR y SEM la modelan de forma estructural: SAR supone que la respuesta de un cuadrante depende directamente de la respuesta de sus vecinos (ρWy), lo que es coherente con una propagación real de la falla a través de circuitos interconectados; SEM supone en cambio que la dependencia reside en los errores (λWu), lo que corresponde a la existencia de factores no observados espacialmente correlacionados, como condiciones de terreno o de vegetación no capturadas por las covariables. La comparación entre ambos por AIC no es, por tanto, un mero ejercicio de ajuste: discrimina entre dos hipótesis sustantivas sobre el origen de la autocorrelación observada.

La dependencia espacial se diagnostica previamente con el índice de Moran, paso que condiciona la pertinencia de todo el bloque espacial: si el índice no fuera significativo, tanto los rezagos de vecinos como SAR y SEM carecerían de justificación empírica. La Figura 5.15 ilustra el patrón territorial de $SAIDI$ promedio por cuadrante sobre el que se calcula el estadístico.

5.5.2. Entrenamiento del modelo

El entrenamiento usa solo semanas anteriores al corte temporal y la matriz de diseño fijada en la Sección 5.4.9: clima, precipitación móvil, NDVI y sismicidad de la semana anterior, rezago propio (`SAIDI_lag1`/`SAIFI_lag1`), topología de red, proporciones de estrato y rezagos espaciales de vecinos. SAIDI y SAIFI se modelan en escala $\log(1 + y)$ y en modelos independientes, conforme a la justificación de la Sección 5.4.2.

Las cuatro especificaciones de panel comparten exactamente el mismo conjunto de predictoras y difieren únicamente en la estructura de efectos fijos declarada, de modo que cualquier diferencia de desempeño entre ellas es atribuible a esa

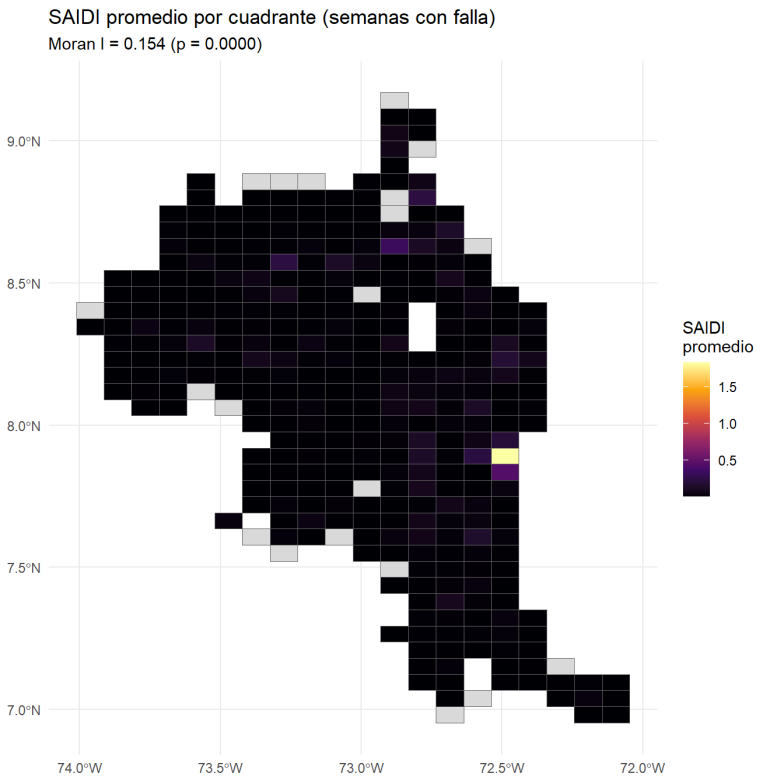


Figura 5.15: Mapa de $SAIDI$ promedio por cuadrante usado en el diagnóstico de autocorrelación espacial (Moran).

estructura y no a una selección distinta de variables. Esta homologación es la que permite leer la comparación de la Sección 5.5.6 como evidencia sobre la naturaleza del fenómeno y no como el resultado de un ajuste diferencial de hiperparámetros.

El entrenamiento se restringe además a las observaciones con `hubo_falla`$= 1$, por la razón expuesta en la Sección 5.4.11, y descarta por `na.omit` las filas con valores ausentes en alguna predictora, lo que afecta principalmente a las primeras semanas de cada serie, donde los rezagos aún no están definidos. La Figura 5.16 muestra la partición temporal train/test resultante en el panel de SAIDI, análoga a la de SAIFI: el volumen de observaciones por semana es comparable entre ambos conjuntos, lo que descarta que el corte haya aislado un tramo atípicamente denso o escaso de actividad.

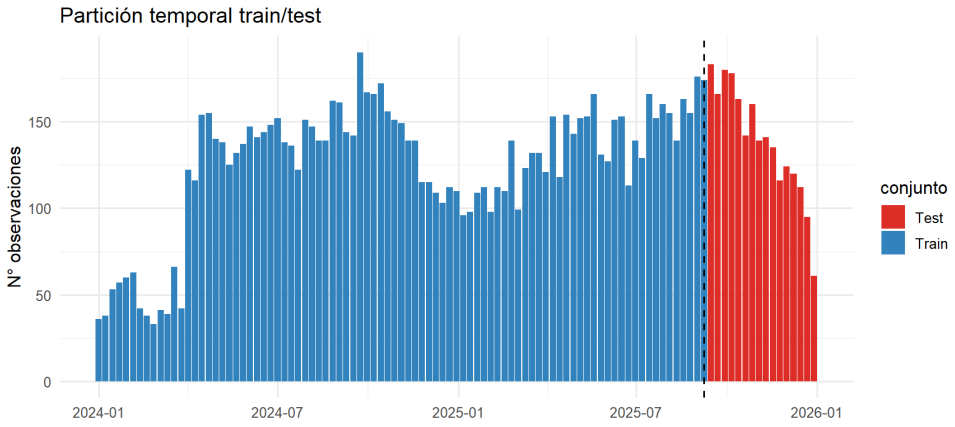


Figura 5.16: Partición temporal entrenamiento/prueba para el modelado de $SAIDI$ (holdout $\approx 15\,\%$ final de semanas).

5.5.3. Validación del modelo

La validación es *holdout temporal*: se reserva aproximadamente el $15\,\%$ final de semanas ordenadas y no se permite muestreo aleatorio, por las razones de autocorrelación expuestas en la Sección 5.4.8. Sobre 105 semanas disponibles, el corte deja alrededor de dieciséis semanas de evaluación, un horizonte suficiente para detectar degradación sistemática del pronóstico pero demasiado corto para evaluar estabilidad interanual, limitación que se discute en el Capítulo 7.

La elección de un esquema de *holdout* simple en lugar de validación cruzada deliberada merece justificación. La validación cruzada con k pliegues aleatorios es inadmisible aquí porque rompería el orden temporal. Como verificación de estabilidad, el desempeño se evalúa además mediante validación de origen móvil: se fijan cuatro cortes sucesivos (semanas 52, 64, 76 y 88 del panel) y en cada uno se reestiman los modelos usando únicamente las semanas anteriores, incluida la

selección de hiperparámetros del Random Forest, que se repite en cada corte con una validación interna sobre ese mismo pasado; la media del cuadrante también se calcula solo con el pasado de cada corte. Cada corte se evalúa sobre las doce semanas siguientes con pronósticos a una semana, en los que los rezagos se actualizan con lo observado hasta la semana anterior. Se reportan las fechas, los tamaños y el RMSE de cada corte (Tabla 6.17), lo que permite distinguir diferencias sistemáticas entre modelos de las que dependen de una ventana de prueba particular.

Un caso particular exige tratamiento explícito. El FE de cuadrante y semana no resulta evaluable fuera de muestra cuando las semanas de prueba no están representadas en el entrenamiento, situación que la partición temporal estricta garantiza por construcción: los efectos fijos τ_s de las semanas de prueba no están estimados y el modelo no puede generar predicción para ellas. La consecuencia no es un defecto del estimador sino una incompatibilidad estructural entre efectos fijos temporales y validación prospectiva; la especificación se conserva por su valor descriptivo dentro de muestra y se excluye de la comparación predictiva, en la que participan *Pooled* OLS, FE de cuadrante, Random Forest y los dos pronósticos de referencia.

Como verificación complementaria, el aporte de la dimensión espacial al pronóstico se juzga por la significancia de los rezagos de vecinos en el modelo FE y por su importancia en el Random Forest, y no solo por el diagnóstico de Moran, que acredita la existencia de autocorrelación pero no que explotarla mejore la predicción.

5.5.4. Ajuste de hiperparámetros

En Random Forest se ajustan los dos hiperparámetros que controlan el grado de regularización: el número de variables candidatas en cada división (`mtry`) y el tamaño mínimo de los nodos terminales. Se evalúa una grilla de 6×4 combinaciones (`mtry` $\in \{2, 4, 6, 9, 12, 16\}$, donde 16 equivale a usar todas las predictoras, y tamaño mínimo de nodo $\in \{5, 10, 20, 50\}$), con 500 árboles y semilla fija. Para no consumir información del conjunto de prueba, la selección se hace con una *validación temporal interna*: cada combinación se estima con el $85\,\%$ inicial de las semanas de entrenamiento (hasta el 2 de junio de 2025) y se evalúa en las semanas de entrenamiento restantes. El error *out-of-bag* no se usa para seleccionar, porque mezcla semanas próximas entre la muestra y las observaciones excluidas. La combinación de menor error de validación interna se reestima con todo el entrenamiento y $1\,000$ árboles, y es la que se evalúa en prueba. El resultado se presenta en la Tabla 6.16 y la Figura 6.9.

En SAR y SEM el ajuste no es de hiperparámetros en sentido estricto sino

de *especificación*: se compara el AIC entre ambas estructuras de dependencia y frente al OLS de referencia sobre el mismo corte transversal, y se selecciona la que minimiza el criterio. Dado que SAR y SEM no son modelos anidados entre sí, el AIC es el instrumento adecuado para discriminarlos, en tanto penaliza la complejidad sin requerir una relación jerárquica entre especificaciones.

La robustez de los modelos de corte transversal se verifica mediante cinco pruebas complementarias, orientadas a descartar que el alto ajuste observado sea un artefacto de colinealidad estructural con el tamaño del cuadrante. La primera examina la correlación entre los predictores retenidos y el número de usuarios del cuadrante, candidato natural a variable de confusión por estar asociado simultáneamente a la cantidad de infraestructura y al numerador del indicador. La segunda reestima el modelo incorporando $\log(1 + \texttt{cantidad_usuarios_cuadrante})$ como control explícito y mide la caída del R^2: una caída pequeña indica que la capacidad explicativa no provenía del tamaño. La tercera cuantifica la pérdida de ajuste al excluir cada predictor por separado, lo que detecta si el resultado depende de una única variable dominante. La cuarta es una prueba de permutación de la respuesta que repite la selección *stepwise* en cada permutación, de modo que la distribución empírica del R^2 bajo la hipótesis nula de ausencia de relación incorpora el sobreajuste propio de la selección y permite asignar un valor p empírico al ajuste observado. La quinta es una validación cruzada espacial: los cuadrantes se dividen en cinco franjas de latitud y cada franja se predice con un modelo cuya selección de variables y estimación se hacen únicamente con las otras cuatro; los modelos SAR y SEM se evalúan del mismo modo, prediciendo la franja retenida con la forma reducida $(\mathbf{I} - \hat{\rho}\mathbf{W})^{-1}\mathbf{X}\hat{\boldsymbol{\beta}}$ y con la tendencia $\mathbf{X}\hat{\boldsymbol{\beta}}$, respectivamente, sin usar las respuestas de esa franja. Esta prueba mide si el patrón explicado es transferible entre zonas o solo describe la muestra. El detalle de sensibilidad y los resultados de las cinco pruebas se documentan en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.5.5. Evaluación de desempeño

Sobre el conjunto de prueba se calculan, en escala $\log(1 + y)$, el $RMSE$, el MAE, el cuadrado de la correlación de Pearson (r^2), el R^2 predictivo, el MAE relativo a la persistencia y el MASE de la ecuación (3.23). Todas las métricas se calculan sobre una *muestra común*: las mismas llaves cuadrante–semana para todos los modelos, que excluye solo las observaciones de cuadrantes sin semanas con falla en el entrenamiento, para los que el efecto fijo y la media del cuadrante no están definidos; el flujo de inclusión se reporta junto con los resultados. En la escala original del indicador, los pronósticos de los modelos estimados en

logaritmos se retransforman con el factor de *smearing* de **duan1983**, estimado con los residuos de entrenamiento (los residuos *out-of-bag* en el caso del Random Forest), porque $\exp(\hat{\mu}) - 1$ no es el valor esperado de Y.

La significancia de las diferencias de error entre dos modelos A y B se contrasta con una adaptación de la prueba de Diebold–Mariano [36] a la estructura del panel. Como los errores de los cuadrantes de una misma semana están correlacionados entre sí, la unidad de inferencia es la semana y no la fila cuadrante–semana:

$$
\begin{aligned}
d_s &= \frac{1}{n_s} \sum_{q=1}^{n_s} \left(e_{A,q,s}^2 - e_{B,q,s}^2 \right), \\
\mathrm{DM} &= \sqrt{\frac{T-1}{T}} \, \frac{\bar{d}}{\sqrt{\hat{\sigma}_{\mathrm{LP}}^2 / T}},
\end{aligned}
\tag{5.5}
$$

donde:

- d_s: Diferencia media de pérdida cuadrática entre los modelos A y B en la semana s; cada semana pesa lo mismo.
- $e_{A,q,s}$, $e_{B,q,s}$: Errores de pronóstico de cada modelo para el cuadrante q en la semana s.
- n_s: Número de cuadrantes evaluados en la semana s.
- T: Número de semanas de prueba; $\bar{d}$, media de d_s.
- $\hat{\sigma}_{\mathrm{LP}}^2$: Varianza de largo plazo de d_s, estimada con el núcleo de Bartlett y $\lfloor T^{1/3} \rfloor$ rezagos.

El factor $\sqrt{(T-1)/T}$ es la corrección de muestra pequeña de **harvey1997** para horizonte de una semana, y el estadístico se compara con una distribución t con $T - 1$ grados de libertad. Con solo $T = 16$ semanas de prueba la potencia del contraste es baja, por lo que se reporta también el tamaño del efecto —la mejora porcentual del RMSE de A frente a B— con un intervalo de confianza del $95\,\%$ obtenido por remuestreo de bloques móviles de tres semanas ($2\,000$ réplicas), que conserva la dependencia temporal y la correlación entre cuadrantes de una misma semana. Un valor p alto se lee como ausencia de evidencia de mejora, no como equivalencia entre los modelos.

El clasificador de ocurrencia se evalúa por su discriminación (área bajo la curva ROC y bajo la curva de precisión–exhaustividad), por su calibración (puntaje de Brier, pérdida logarítmica y tasa observada de falla por decil de probabilidad pronosticada) y por su utilidad operativa: la proporción de aciertos y de afectación capturada entre los k cuadrantes de mayor probabilidad en cada semana

de prueba, con $k = 10$ y $k = 30$ como presupuestos de atención ilustrativos. Se compara con tres referencias: la tasa histórica de falla de cada cuadrante en el entrenamiento, la persistencia (falla si la hubo la semana anterior) y una regresión logística con las mismas predictoras. Las diferencias de AUC y de Brier se acompañan de intervalos por remuestreo de bloques de semanas.

Las métricas de magnitud se reportan conjuntamente porque informan sobre aspectos distintos del error y su lectura aislada puede inducir a conclusiones opuestas. El $RMSE$ penaliza cuadráticamente las desviaciones grandes y es, por tanto, sensible a los fallos de pronóstico en las semanas de mayor afectación, que son precisamente las de mayor relevancia operativa. El MAE pondera todos los errores por igual y resulta más representativo del desempeño típico. El r^2 mide la proporción de variabilidad ordenada correctamente, con independencia de un posible sesgo de nivel, mientras que el R^2 predictivo sí penaliza ese sesgo y es negativo cuando el modelo pronostica peor que la media de entrenamiento. Un modelo puede, en consecuencia, presentar menor $RMSE$ y menor r^2 que otro: el primero sería más preciso en magnitud y el segundo mejor en ordenamiento relativo de cuadrantes, y la elección entre ambos depende del uso previsto.

Debe subrayarse que todas las métricas se expresan en escala logarítmica, lo que las hace comparables entre modelos del mismo indicador pero no entre SAIDI y SAIFI, cuyas escalas difieren en varios órdenes de magnitud, ni con errores expresados en horas-usuario. Los valores observados frente a los predichos del mejor modelo de cada indicador se presentan en las Figuras 6.13 y 6.14 (Sección 6.5). La lectura de estos diagramas es informativa más allá del resumen numérico: la dispersión en torno a la diagonal revela si el error es homogéneo a lo largo del rango o si se concentra en los valores extremos, diagnóstico que ninguna de las tres métricas agregadas permite por sí sola.

5.5.6. Comparación de modelos

La comparación distingue dos usos que responden a preguntas diferentes y que, por tanto, no admiten un criterio único de selección. El primero es el *pronóstico semanal*, evaluado por el menor $RMSE$ en el conjunto de prueba entre *Pooled* OLS, FE de cuadrante y Random Forest, con la condición adicional de superar de forma significativa a los dos pronósticos de referencia. El segundo es la *explicación estructural* del patrón territorial, evaluada por el menor AIC entre OLS, SAR y SEM sobre el corte transversal ponderado.

Esta separación no es una concesión metodológica sino una consecuencia de la naturaleza del problema. Un modelo de pronóstico se juzga por su error sobre observaciones que no ha visto; un modelo estructural se juzga por la verosimilitud con que describe la generación de los datos observados y por la interpretabili-

dad de sus parámetros. Las métricas correspondientes no son conmensurables: un $RMSE$ en escala logarítmica sobre 2 212 observaciones semanales y un AIC sobre 344 promedios por cuadrante miden objetos distintos, y compararlos directamente carecería de sentido. Por esta misma razón el Capítulo 6 advierte explícitamente contra la lectura conjunta del R^2 de ambas escalas.

SAIDI y SAIFI se reportan por separado, lo que permite detectar si el modelo preferido coincide entre indicadores. Que no coincida es, en sí mismo, un resultado sustantivo: indicaría que la duración y la frecuencia de interrupción obedecen a estructuras de dependencia distintas y que una política de gestión única para ambos indicadores estaría mal especificada. Las tablas numéricas completas se concentran en el Capítulo 6 y en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.5.7. Descomposición territorial del SAIDI

El SAIDI operativo de un cuadrante combina tres magnitudes de naturaleza distinta: el número de eventos, su duración y el número de usuarios que alcanza cada uno. Un mismo factor estructural puede actuar sobre una de ellas y no sobre las otras, o en sentidos opuestos, de modo que su efecto sobre el índice compuesto oculte mecanismos diferentes. Para separarlos, el SAIDI acumulado de cada cuadrante se aproxima por el producto de sus tres componentes medios,

$$\log \tilde{S}_q = \log F_q + \log D_q + \log U_q, \tag{5.6}$$

donde:

- $\tilde{S}_q$: Aproximación del SAIDI operativo acumulado del cuadrante q en 2024–2025.
- F_q: Frecuencia, número medio de eventos por semana.
- D_q: Duración media por evento, en horas.
- U_q: Alcance medio por evento, en usuarios afectados.

La participación de cada componente en la variación territorial se mide como la razón entre su covarianza con $\log \tilde{S}_q$ y la varianza de este último, de modo que las tres participaciones suman uno. La asociación de los factores estructurales con cada componente se resume con la correlación de rangos de Spearman, en lugar de coeficientes de regresión múltiple, porque las variables de escala del cuadrante están fuertemente correlacionadas entre sí y sus coeficientes individuales resultan inestables.

5.5.8. Sensibilidad a la definición de vecindad

Los modelos SAR y SEM dependen de la matriz de pesos espaciales $\mathbf{W}$, cuya elección no es única. Para verificar que la selección del modelo y el signo de los parámetros espaciales no son un artefacto de la vecindad adoptada, los modelos de corte transversal se reestimaron con ocho definiciones de $\mathbf{W}$, todas normalizadas por filas: contigüidad tipo reina (referencia) y tipo torre; los cuatro, seis y ocho vecinos más cercanos según la distancia entre centroides; una banda de distancia igual a la mínima que conecta a todos los cuadrantes (10.9 km) y otra de 1.5 veces esa distancia; y una matriz de inverso de la distancia dentro de esta última banda.

5.5.9. Pronóstico incondicional de la afectación

Los modelos de magnitud se estiman sobre las semanas con al menos una falla y el clasificador estima la probabilidad de que esa falla ocurra. Para el operador, sin embargo, la cantidad relevante es el valor esperado de la afectación de cada cuadrante en la semana siguiente, ocurra o no una falla. Ambos componentes se combinan en un pronóstico incondicional,

$$\hat{Y}_{q,s} = \hat{p}_{q,s} \left[\exp\left(\hat{\mu}_{q,s}\right) \hat{\varphi} - 1 \right], \tag{5.7}$$

donde:

- $\hat{Y}_{q,s}$: Pronóstico incondicional del indicador operativo del cuadrante q en la semana s, en su escala original.
- $\hat{p}_{q,s}$: Probabilidad de falla estimada por el clasificador Random Forest.
- $\hat{\mu}_{q,s}$: Pronóstico de $\log(1 + Y_{q,s})$ del modelo de efectos fijos de cuadrante, estimado sobre las semanas con falla.
- $\hat{\varphi}$: Factor de corrección por retransformación de Duan, igual al promedio de $\exp(\hat{e})$ sobre los residuos del modelo de magnitud.

El pronóstico se evalúa sobre todas las semanas del periodo de prueba, con y sin falla, en la escala original del indicador y frente a la persistencia y al promedio histórico del cuadrante, que en esta evaluación también incluye las semanas sin falla. Como alternativa de un solo paso se estima un modelo lineal generalizado con distribución Tweedie y enlace logarítmico, adecuado para variables continuas con masa en cero, cuyo parámetro de potencia se elige por el menor error en las últimas doce semanas del entrenamiento.

5.5.10. Validación de la priorización territorial

El componente territorial se destina a ordenar los cuadrantes según su contribución esperada a la afectación, con el fin de focalizar el mantenimiento preventivo, la poda y la inversión. Un orden de esta naturaleza solo tiene valor operativo si, construido con información pasada, anticipa dónde se concentrará la afectación en el periodo siguiente. Por ello, además de las métricas de error de la Sección 5.5.5, la priorización se valida fuera de muestra: los cuadrantes se ordenan con la afectación acumulada de 2024 y se evalúa la proporción de la afectación de 2025 que concentran los primeros k cuadrantes de ese orden,

$$C(k) = \frac{\sum_{q \in \mathcal{T}_k} Y_q^{2025}}{\sum_{q=1}^{Q} Y_q^{2025}}, \tag{5.8}$$

donde:

- $C(k)$: Proporción de la afectación de 2025 capturada por los k primeros cuadrantes.
- $\mathcal{T}_k$: Conjunto de los k cuadrantes con mayor afectación acumulada en 2024.
- Y_q^{2025}: Suma del indicador operativo (SAIDI o SAIFI) del cuadrante q en las semanas de 2025.
- Q: Número de cuadrantes del panel.

La curva $C(k)$ se contrasta con tres referencias: la selección aleatoria, cuyo valor esperado es k/Q; el orden por número de usuarios del cuadrante, que representa una priorización basada solo en la exposición; y el orden óptimo, construido con los valores observados de 2025, que actúa como cota superior. La estabilidad del orden se evalúa mediante un *bootstrap* sobre las semanas de 2024 (500 réplicas), del que se obtienen la frecuencia con la que cada cuadrante permanece entre los diez primeros y el índice de Jaccard entre el conjunto remuestreado y el original.

5.5.11. Interpretación de resultados

La interpretación combina tres fuentes de evidencia de naturaleza complementaria, cuya convergencia o divergencia es en sí misma informativa: los coeficientes de las especificaciones lineales y de efectos fijos, la importancia de variables del Random Forest, y los parámetros espaciales de SAR y SEM.

Cada fuente tiene un alcance y una limitación propios. Los coeficientes lineales son directamente interpretables como efectos marginales y admiten contraste de significancia, pero presuponen una forma funcional que el propio desempeño de Random Forest sugiere incompleta. La importancia por permutación del

Random Forest (aumento del error cuadrático medio al permutar cada variable) captura relaciones no lineales e interacciones, pero no informa sobre el *signo* del efecto: una variable puede resultar altamente importante tanto por aumentar como por reducir el indicador. Los parámetros ρ de SAR y λ de SEM cuantifican la intensidad de la dependencia espacial, pero se estiman sobre promedios y no sobre la dinámica semanal.

El criterio de interpretación adoptado es, en consecuencia, de *triangulación*: se consideran robustos aquellos hallazgos que aparecen en al menos dos de las tres fuentes, y se tratan con cautela los que dependen de una sola especificación. Este criterio adquiere especial relevancia en presencia de colinealidad residual, donde el reparto de la contribución entre variables correlacionadas es inestable entre métodos: un coeficiente lineal puede resultar no significativo simplemente porque otra variable del mismo bloque absorbió su efecto, mientras que la importancia del Random Forest, al evaluar la pérdida de ajuste ante permutación, puede señalar a ambas. Las Figuras 6.11 y 6.12 resumen la importancia relativa de predictores en los Random Forest de $SAIDI$ y $SAIFI$, y su contraste con los coeficientes de las regresiones de corte transversal se desarrolla en la Sección 6.5.

5.5.12. Resultados y entregables de la etapa

La Etapa 5 produce seis modelos estimados por indicador y escala de análisis: cuatro especificaciones de panel semanal y dos espaciales formales, para SAIDI y SAIFI respectivamente. Su valor no reside únicamente en el modelo de mejor desempeño, sino en la comparación sistemática entre especificaciones bajo una matriz de diseño homologada, que permite atribuir las diferencias observadas a la estructura de dependencia y no a decisiones arbitrarias de preparación de datos.

Resultado: modelos de SAIDI y SAIFI entrenados, validados en *holdout* temporal, contrastados con especificaciones espaciales formales y sometidos a verificación de robustez frente a colinealidad estructural, clima extremo y definición de la vecindad; pronóstico incondicional de la afectación; descomposición territorial del SAIDI, y priorización validada fuera de muestra.

Entregables:

- `Etapa5_01_modelo_SAIDI_espacial.html`, con la estimación, validación, diagnóstico de supuestos y pruebas de robustez del modelo de duración (Apéndice A.3.28; informe HTML).
- `Etapa5_02_modelo_SAIFI_espacial.html`, con el análisis equivalente para el modelo de frecuencia (Apéndice A.3.29; informe HTML).
- Los informes de los análisis de clima extremo, validación de la priorización,

pronóstico incondicional, descomposición del SAIDI y sensibilidad a la matriz de vecindad (Apéndices A.3.32 a A.3.36).

5.6. Etapa 6 – Cierre metodológico, documentación y reportes

En la etapa final se consolidan los resultados del proyecto y se documentan de forma integral las técnicas aplicadas, las transformaciones realizadas y el código reproducible (en R o Python). El capítulo incluye apéndices técnicos, tablas de validación, bibliografía y lineamientos de reproducibilidad, así como una discusión orientada a interpretar los hallazgos en términos técnicos y operativos para la toma de decisiones del operador de red.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.6.1. Presentación de resultados del modelo

Los resultados de los seis modelos estimados (cuatro de panel semanal y dos espaciales formales, para SAIDI y SAIFI) se organizaron en tablas homologadas de desempeño comparado, acompañadas de figuras de valores observados frente a predichos y de importancia de variables, presentadas en el Capítulo de Resultados (Sección 6.5).

El criterio de organización privilegia la comparabilidad sobre la exhaustividad. Cada tabla reporta las mismas tres métricas para todas las especificaciones del mismo indicador, incluidas aquellas que no resultaron evaluables, señaladas de forma explícita en lugar de omitidas: documentar que el FE de cuadrante y semana no produce predicción fuera de muestra es parte del resultado, porque informa sobre una restricción estructural del diseño de validación y no sobre una omisión del análisis. De forma análoga, las tablas de corte transversal reportan tanto los predictores significativos como el conjunto de los no significativos, de modo que el lector pueda verificar qué hipótesis fueron contrastadas y descartadas, y no solo las confirmadas.

5.6.2. Métricas de desempeño

Sobre el conjunto de prueba se calcularon RMSE, MAE, r^2, R^2 predictivo y MASE en escala $\log(1 + y)$ para los modelos de panel evaluables, y AIC para los modelos espaciales SAR/SEM, siguiendo las definiciones formalizadas en la Sección 3.1.2 y los criterios de lectura de la Sección 5.5.5.

A estas métricas se añadió una verificación de significancia empírica sobre el corte transversal, consistente en contrastar el R^2 observado contra la distribución generada por 200 permutaciones aleatorias de la respuesta, repitiendo en cada una la selección *stepwise*. Esta prueba responde a una preocupación específica de los modelos estimados sobre 344 observaciones con un número no trivial de predictores: parte del ajuste podría deberse a capacidad de sobreajuste y no a una relación real. La distribución de permutación proporciona el punto de comparación correcto, puesto que preserva la estructura de la matriz de predictores y destruye únicamente su asociación con la respuesta.

5.6.3. Hallazgos principales

Los hallazgos de las seis etapas se consolidaron en una síntesis única que articula el resultado principal de cada etapa con los tres objetivos específicos del proyecto (Sección 6.6).

La consolidación distingue dos clases de hallazgo que conviene no confundir. Los *hallazgos sustantivos* responden a las preguntas de investigación: qué variables explican la variación territorial de los indicadores, qué modelos pronostican mejor y con qué precisión. Los *hallazgos de proceso* surgieron durante la ejecución y no eran anticipables en el diseño; el principal es el sesgo de cobertura del emparejamiento evento–elemento entre 2021 y 2023 (Sección 6.3.5), que no es un defecto del análisis sino un diagnóstico sobre la calidad de la información histórica del operador, con valor propio para la organización con independencia de los modelos estimados. Ambas clases se reportan, porque un trabajo que solo documentara los hallazgos sustantivos ocultaría la evidencia que explica por qué el horizonte de modelado quedó restringido a dos años.

5.6.4. Interpretación técnica y operativa

Los resultados se tradujeron en implicaciones para la gestión operativa del operador de red, priorizando aquellas variables sobre las cuales existe margen de acción. Esta distinción es central: no todas las variables relevantes son accionables. La exposición sísmica no es modificable; la vegetación lo es mediante poda programada; la densidad de red y el ritmo de reposición de activos dependen de los planes de inversión. Como los modelos estimados son observacionales, la relevancia de una variable indica asociación y no el efecto de intervenirla: las recomendaciones que se derivan se formulan como hipótesis que el operador debe contrastar con criterio de ingeniería, con su historial de intervenciones y, cuando sea posible, con una prueba piloto. Una recomendación útil debe, además, ordenar las variables no solo por importancia estadística sino por el cruce entre importancia y capacidad de intervención.

La traducción también exige explicitar el horizonte de uso de cada modelo. El modelo de panel semanal sirve a la programación de cuadrillas y a la anticipación de semanas críticas; el modelo espacial de corte transversal sirve a la priorización de inversión en cuadrantes estructuralmente vulnerables, una decisión de ciclo anual o plurianual. Confundir ambos horizontes llevaría a usar un modelo de ordenamiento territorial para decisiones operativas de corto plazo, para las que no fue validado. Esta interpretación se desarrolla en el Capítulo 7.

5.6.5. Generación de reportes

Cada etapa del proyecto se documentó en informes reproducibles (R Markdown renderizados a HTML), consolidados en el Apéndice A.3, junto con el código fuente de extracción, integración y modelado (Apéndice A.2).

El esquema de reproducibilidad adoptado tiene tres propiedades que conviene hacer explícitas. Primero, cada informe contiene simultáneamente el código ejecutado, los resultados y la narrativa interpretativa, de modo que no existe posibilidad de divergencia entre lo reportado y lo computado. Segundo, las rutas de datos se resuelven mediante una variable de entorno (`UBICACION_DATA`) y no mediante rutas absolutas, lo que permite reejecutar la cadena completa en una máquina distinta sin editar el código; las credenciales de acceso a las bases institucionales se gestionan por el mismo mecanismo y nunca se incorporan al repositorio. Tercero, los informes se publican como páginas estáticas con URL estable, de modo que cada afirmación del documento puede verificarse en su evidencia computacional de origen mediante los enlaces incorporados en las referencias de apéndice a lo largo de este capítulo.

5.6.6. Discusión de resultados

El análisis crítico de fortalezas, limitaciones y comparaciones entre los modelos estimados se desarrolla en el Capítulo 7, para no duplicar contenido entre los capítulos de Metodología y Discusión. La separación responde a una división funcional: este capítulo documenta *qué se hizo y por qué*, el Capítulo de Resultados reporta *qué se obtuvo*, y el de Discusión interpreta *qué significa* y bajo qué condiciones los hallazgos son generalizables.

5.6.7. Limitaciones y trabajos futuros

Las limitaciones identificadas a lo largo del proyecto y las líneas de trabajo futuro se consolidan en la Sección 7.2. Las de origen metodológico quedan ya señaladas en este capítulo y conviene enumerarlas aquí para trazabilidad: el sesgo de cobertura del emparejamiento 2021–2023, que redujo el horizonte de modelado a dos años (Sección 5.4.8); la señal climática contemporánea débil en el grano semanal, que limita el aporte del bloque meteorológico sin rezagos de

mayor orden (Sección 5.4.1); la restricción del modelado de magnitud a semanas con falla, que obliga a modelar la ocurrencia por separado (Sección 5.4.11); la construcción del indicador operativo a partir del panel diario, cuyos efectos se cuantifican en el Apéndice A.5; la ausencia de histórico del inventario y de fechas de modificación anteriores al periodo, que impidió usar la antigüedad de los activos (Sección 5.4.9); la imposibilidad de validar fuera de muestra la especificación con efectos fijos dobles (Sección 5.5.3); y la brevedad del *holdout*, que impide evaluar estabilidad interanual (Sección 5.5.4).

5.6.8. Resultados y entregables de la etapa

Resultado: documentación final del proyecto y resultados consolidados, con trazabilidad verificable entre cada afirmación del documento y el informe reproducible que la sustenta.

Entregables: compendio de documentación del proyecto (informe final, informe descriptivo, informe de evaluación de modelos y reporte técnico de variables relevantes), código reproducible publicado en el repositorio del proyecto (Apéndices A.3 y A.2) y documentación detallada de procesos y transformaciones a lo largo de las seis etapas.

5.7. Relación entre etapas metodológicas y objetivos específicos

La Tabla 5.12 sintetiza cómo cada etapa de la metodología contribuye a los objetivos específicos formulados en el Capítulo 2. Los objetivos no se reformulan aquí: se indica únicamente su correspondencia con las etapas, de modo que la trazabilidad entre el diseño metodológico y el alcance del proyecto quede explícita. De forma complementaria, los informes reproducibles derivados de los archivos `EtapaX_Y_*.Rmd` se documentan como informes HTML en el Apéndice A.3 (subsecciones de enriquecimiento, ingeniería de variables y modelado espacial).

P1 a P4 denotan las preguntas de sistematización en el orden en que se formulan en la Sección 1.2. En síntesis, las Etapas 1 y 2 materializan el OE1 y responden a la primera pregunta; las Etapas 3 y 4 sustentan el OE2 y la segunda pregunta; la Etapa 5 concentra el OE3 y la tercera pregunta, con aporte interpretativo al OE2; y la Etapa 6, transversal a los tres objetivos, responde a la cuarta pregunta mediante los artefactos reproducibles y los reportes técnicos del proyecto.

Tabla 5.12: Correspondencia entre preguntas de sistematización, objetivos específicos y etapas metodológicas

Etapa	Pregunta	Objetivo	Aporte y evidencia
Etapa 1 – Extracción (Sección 5.1)	P1	OE1	Extracción de las fuentes; linaje de datos (Tabla 5.7); catálogo de datos (Apéndice A.4).
Etapa 2 – Integración (Sección 5.2)	P1	OE1	Panel activo × día y cuadrante × semana; métricas de integridad y cobertura del emparejamiento (Tabla 6.9).
Etapa 3 – EDA (Sección 5.3)	P2	OE2	Patrones temporales, espaciales, estacionales y atípicos; redundancias y señal climática.
Etapa 4 – Ingeniería de variables (Sección 5.4)	P2, P3	OE2, OE3	Respuestas, predictoras *ex ante*, depuración y partición temporal.
Etapa 5 – Modelado (Sección 5.5)	P3	OE2, OE3	Comparación de modelos, variables relevantes e interpretación para los gestores.
Etapa 6 – Cierre y reportes (Sección 5.6)	P4	Transversal (OE1–OE3)	Artefactos reproducibles (informes R Markdown, entorno `renv` y contenedor) y reportes técnicos (Apéndice A.6).

6 Resultados

6.1. Etapa 1 – Resultados de la extracción de datos

La extracción documentada en la Sección 5.1 consolidó seis fuentes complementarias (BRAE, BRAE + QA_TTC1, OMS SPARD, OMS SP7, GIS GTECH y NASA POWER), cuyo linaje de datos se resume en la Tabla 5.7. El resultado directo de esta etapa es la base transaccional de eventos de interrupción del sistema (`tabla_eventos`), con 95 280 eventos depurados tras el filtrado regulatorio del periodo 2021–2025, la exclusión de registros no válidos y la eliminación de duplicados. En paralelo, la extracción climática de NASA POWER produjo una serie diaria de 83.5 millones de registros meteorológicos, con cobertura completa y homogénea sobre toda el área de concesión (Sección 5.2.8).

Cada fuente quedó sujeta a reglas explícitas y verificables de filtrado y homologación (Tabla 5.7), lo que garantiza que el insumo inicial para la integración de la Etapa 2 sea trazable y reproducible: la totalidad del proceso de extracción está documentado mediante consultas SQL y fragmentos de código reproducible (Apéndice A.2).

6.2. Etapa 2 – Resultados de la integración y depuración de datos

La integración secuencial descrita en la Sección 5.2 produjo dos tablas base, cuya construcción se documenta en los Apéndices A.3.1 (informe HTML) y A.3.2 (informe HTML). La primera, con grano activo eléctrico $\times$ día (Tabla 5.8), alcanza $N = 87\,007\,074$ observaciones ($47\,649$ activos únicos $\times$ $1\,826$ días), preservando trazabilidad completa entre el inventario georreferenciado y el calendario de análisis 2021–2025. La segunda, agregada a grano cuadrante $\times$ semana sobre la malla institucional de 800 cuadrantes (Figura 5.1), alcanza $N_{\text{agr}} = 90\,128$ observaciones (Tabla 5.10) para el horizonte completo 2021–2025. En esta segunda tabla se incorporaron, además del clima y los eventos, variables de caracterización territorial por cuadrante: composición socioeconómica (estrato, proporción de clientes no residenciales), topología e infraestructura de red (número de elemen-

tos, longitud de red, densidad de nodos terminales, número de circuitos) y las fuentes de exposición adicionales descritas en el Capítulo de Datos (sismicidad y vegetación/NDVI).

Un hallazgo relevante de esta etapa es un sesgo sistemático detectado al contrastar el conteo anual de eventos de la base BRAE con la suma territorial de eventos de la tabla agregada durante 2021–2023 (Tabla 6.9; Figura 6.2). El diagnóstico descarta la ausencia de datos como causa —el campo `COMPONENTE_FALLADO` está completo en el 100 % de los registros BRAE— y la atribuye a una incompatibilidad entre esquemas de codificación al cruzar eventos con el inventario georreferenciado. Este hallazgo, que no era anticipable antes del análisis, llevó a delimitar el subconjunto de datos con cobertura de emparejamiento confiable como el conjunto de modelado D_{mod}: 36 120 filas cuadrante–semana, 105 semanas y 33 410 eventos georreferenciados en el periodo 2024–2025 (15 211 en 2024 y 18 199 en 2025), que es el que efectivamente alimenta el modelado de la Etapa 5. El horizonte completo 2021–2025 (D_{EDA}) se conserva para el análisis exploratorio de la Etapa 3. El diagnóstico de cobertura se documenta en el Apéndice A.3.9 (informe HTML) y la materialización del subconjunto de modelado en el Apéndice A.3.10 (informe HTML).

Conviene subrayar el alcance de este hallazgo más allá de su consecuencia inmediata sobre el horizonte de modelado. Que el campo `COMPONENTE_FALLADO` esté completo en el 100 % de los registros y que, pese a ello, solo alrededor del 31 % de los eventos de 2021–2023 logre emparejarse con el inventario georreferenciado, demuestra que la completitud formal de un campo no garantiza su utilidad analítica. La discrepancia no se origina en la ausencia de datos sino en la convivencia de dos esquemas de codificación —código de sitio, estable en el tiempo, y código de activo, sujeto a cambio en cada reposición— que el sistema histórico OMS-SPARD empleaba de forma intercambiable. Un diagnóstico basado únicamente en conteos de valores ausentes, como el que se reporta en la Sección 6.3, habría calificado la fuente como de calidad alta y no habría detectado el problema. El hallazgo tiene, por tanto, valor propio para la gobernanza de datos del operador, con independencia de los modelos estimados en este trabajo.

El marco institucional de gobernanza de datos de CENS y la documentación pública y versionada de NASA POWER (Sección 5.2.8) respaldan el origen de las fuentes; su aptitud para este estudio se verificó empíricamente con las métricas de integridad del catálogo de datos (Apéndice A.4).

6.3. Etapa 3 – Resultados del análisis descriptivo y exploratorio

Esta sección presenta, para cada procedimiento del análisis descriptivo y exploratorio descrito en la Sección 5.3, su ejecución y sus hallazgos. Para no recargar el cuerpo del documento, aquí se conservan las figuras que sustentan decisiones metodológicas; las demás figuras del análisis exploratorio se reúnen en el Apéndice A.9. Las Secciones 6.3.1 a 6.3.4 corresponden al preprocesamiento y la caracterización de la base (faltantes, extremos y distribuciones); las siguientes, al análisis temporal, espacial, de asociación y multivariado que fundamentó la ingeniería de variables.

6.3.1. Identificación de datos faltantes

Sobre el panel consolidado final (`data_consolidada.csv`), con $N = 87\,007\,074$ observaciones (grano activo eléctrico $\times$ día), se realizó un diagnóstico sistemático de valores faltantes (`NA`) con dos enfoques complementarios: (i) conteo de `NA` por variable y (ii) conteo de observaciones del panel con al menos un `NA` por fila. El objetivo fue cuantificar la magnitud y localizar el origen de la incompletitud como insumo del EDA y para fundamentar las decisiones de imputación o exclusión en la Etapa 4.

En el análisis por columna, para cada una de las 16 variables del panel se calculó el número absoluto de `NA` y su porcentaje respecto a N. En el análisis por fila, se determinó cuántas observaciones (i, t) presentan cero, uno o más campos incompletos, junto con el máximo de variables faltantes registradas en una misma fila.

Los resultados muestran que la incompletitud se concentra en las variables climáticas integradas desde NASA POWER en el paso 5.2.1.6. Las seis variables meteorológicas (`velocidad_viento_ms`, `temperatura_media_c`, `humedad_relativa_pct`, `temperatura_minima_c`, `temperatura_maxima_c` y `precipitacion_total_mm`) presentan exactamente $3\,401\,838$ valores faltantes cada una, equivalente al $3.91\,\%$ de N. Este patrón es coherente con el cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`): las filas sin emparejamiento en la base climática conservan `NA` en el bloque meteorológico. La variable `ALTITUD` registra $32\,868$ faltantes ($0.04\,\%$ de N), asociados al inventario GIS. El resto de variables del panel, identificación del activo (`ELEMENTO`, `TIPO`, `LATITUD`, `LONGITUD`), calendario (`FECHA_DIA`), severidad (`CANTIDAD_ELEMENTOS`, `CANTIDAD_USUARIOS`) y continuidad (`DURACION_min`, `FRECUENCIA`), no presentan `NA`, dado que los pasos 5.2.1.5 y 5.2.1.7 asignan 0 en días sin evento.

Los faltantes climáticos del panel activo–día no se trasladan al panel de mode-

lado. La serie climática que alimenta el panel cuadrante × semana se integra por cuadrante y día (`clima_cuadrante_dia.csv`): tiene 628 144 filas, exactamente 344 cuadrantes × 1 826 días, sin valores ausentes ni no finitos en ninguna de sus variables. En 2024–2025 cada combinación cuadrante–semana se agrega con sus siete días observados, salvo la última semana del panel (29 de diciembre de 2025), que solo contiene los tres días hasta el cierre del año. La completitud de las variables climáticas semanales no proviene, por tanto, de omitir faltantes al agregar, y no fue necesario fijar reglas de cobertura mínima ni de imputación.

A nivel de fila, 83 576 020 observaciones (96.06 %) están completas; 3 431 054 filas (3.94 %) tienen al menos un `NA`, y el máximo de variables incompletas en una misma observación es 7 (combinación de las seis variables climáticas más `ALTITUD`). La Figura A.2a (Apéndice A.8) y la Tabla 6.1 resumen el porcentaje de faltantes por variable, ordenado de mayor a menor.

Tabla 6.1: Resumen de valores faltantes por variable en el panel consolidado

Variable	n **de** `NA`	**% sobre** N
`velocidad_viento_ms`	3 401 838	3.91
`temperatura_media_c`	3 401 838	3.91
`humedad_relativa_pct`	3 401 838	3.91
`temperatura_minima_c`	3 401 838	3.91
`temperatura_maxima_c`	3 401 838	3.91
`precipitacion_total_mm`	3 401 838	3.91
`ALTITUD`	32 868	0.04
Resto de variables del panel: 0 `NA` (0 %)		

En síntesis, la calidad estructural del panel es alta en variables operativas de interrupción (sin `NA`), y la incompletitud relevante para el modelado se limita al bloque climático y, en menor medida, a `ALTITUD`. Las reglas de imputación o exclusión se definen con base en este diagnóstico y se aplican en la Etapa 4.

Tabla agrupada cuadrante × semana. Sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90\,128$ observaciones y 16 variables, se replicó el mismo esquema de diagnóstico: conteo de `NA` por variable y por fila. El procedimiento se documenta en el Apéndice A.3.3.

En el análisis por columna, las 16 variables del grano agregado, identificación y calendario (`id_cuadrante`, `semana`), georreferenciación (`latitud`, `longitud`, `altitud`), severidad (`usuarios_afectados`, `elementos_afectados`), clima semanal (`temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`, `viento_medio_semana`, `viento_max_semana`, `precip_total_semana`) y continuidad (`n_eventos`, `duracion_total`), registran 0 valores faltantes (0 % sobre N_{agr}). A nivel de fila, las 90 128 observaciones están completas:

ninguna fila presenta al menos un `NA` y el máximo de variables incompletas por fila es 0.

Este resultado es coherente con la agregación descrita en la Sección 5.2.5: las sumas y promedios semanales emplean `na.rm = TRUE`, de modo que los `NA` del panel diario no se propagan como campos vacíos en el grano agregado; las métricas operativas sin evento se consolidan en 0, y cada fila exportada conserva llaves estructurales definidas (`id_cuadrante`, `semana`). La Figura A.2b (Apéndice A.8) ilustra la ausencia de faltantes en una muestra de las primeras 50 filas: todas las celdas se clasifican como completas.
En consecuencia, la tabla agrupada no requiere reglas de imputación por valores faltantes en la Etapa 4; el tratamiento de incompletitud documentado en los párrafos anteriores aplica al panel consolidado activo $\times$ día, grano en el que se originan los `NA` climáticos y de `ALTITUD`.

6.3.2. Identificación de valores extremos en variables cuantitativas

Se evaluó la presencia de valores extremos en las variables cuantitativas mediante reglas univariadas y diagramas de caja e histogramas. El análisis distingue observaciones operativamente plausibles de posibles inconsistencias de registro, sin aplicar aún transformaciones ni exclusiones definitivas; el tratamiento se difiere a la Etapa 4 con base en estos hallazgos. Para cada variable se aplicaron la regla de Tukey [14], el rango intercuartílico ampliado y el criterio de percentiles P1–P99, conforme a lo formalizado en la Sección 3.1.2. Como complemento interpretativo de la dispersión relativa entre variables de distinta escala, se reporta el coeficiente de variación (CV; Sección 3.1.2).

Panel consolidado activo $\times$ día. Sobre `data_consolidada.csv` ($N = 87\,007\,074$) se aplicó el protocolo descrito, excluyendo coordenadas geográficas (`LATITUD`, `LONGITUD`, `ALTITUD`). El detalle reproducible se documenta en el Apéndice A.3.4.

Variables climáticas diarias. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas, baja dispersión (en la humedad, CV del orden de 0.16–0.20; en la temperatura, en grados Celsius, el CV no se interpreta como dispersión relativa) y un porcentaje bajo de extremos según la regla de Tukey (entre 0 % para `humedad_relativa_pct` y 0.20 % para `temperatura_minima_c`); con el factor 3.0 prácticamente no se identifican extremos severos. El viento exhibe mayor heterogeneidad relativa (CV $= 0.69$). La `precipitacion_total_mm` constituye la excepción: por su naturaleza fuertemente asimétrica, con exceso de ceros y CV $= 2.12$, la regla de Tukey marca el 10.38 %

de las observaciones y la ampliada el 5.30 %, aunque la regla de percentiles solo señala el 1.00 %. Estos valores corresponden a días de lluvia intensa operativamente plausibles, no a errores de registro. La Tabla 6.2 resume estos resultados y las Figuras A.2c y A.5 muestran, respectivamente, los diagramas de caja y los histogramas sobre una muestra de 200 000 observaciones.

Tabla 6.2: Valores extremos y dispersión relativa en variables climáticas (panel completo)

Variable	Mediana	CV	% IQR 1.5	% IQR 3.0	% P1–P99
velocidad_viento_ms	1.20	0.69	0.03	0.00	1.60
temperatura_media_c	25.47	0.17	0.02	0.00	1.99
humedad_relativa_pct	69.08	0.18	0.00	0.00	1.98
temperatura_minima_c	20.91	0.20	0.20	0.00	1.99
temperatura_maxima_c	31.32	0.16	0.05	0.00	1.99
precipitacion_total_mm	0.50	2.12	10.38	5.30	1.00

Variables de severidad y continuidad diarias. Estas variables están dominadas por ceros (días sin interrupción): el 99.94 % de las filas registra 0, por lo que sobre el panel completo se cumple $Q_1 = Q_3 = 0$ y la regla de Tukey resulta poco informativa (marca como extremo cualquier día con evento, 0.06 % del panel); el CV del panel completo queda artificialmente inflado por la masa en cero. Por ello, el análisis relevante se realiza sobre los días con evento (valor > 0), donde se concentran 48 375 registros de afectación y 48 364 de continuidad. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha y de alta dispersión relativa: la mediana de CANTIDAD_USUARIOS es 23 usuarios pero su máximo alcanza 34 622 (CV $= 3.97$); la DURACION_min tiene mediana de 417 minutos ($\approx$ 7 horas) y un máximo de 332 395 minutos ($\approx$ 231 días; CV $= 3.56$), sugerente de posibles inconsistencias de registro que se marcan para revisión. La regla de Tukey marca entre el 9 % y el 15 % de los días con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 6.3 resume estos resultados y las Figuras A.2d y A.6 presentan los diagramas de caja e histogramas sobre los días con evento.

Tabla 6.3: Valores extremos y dispersión relativa en severidad y continuidad (días con evento, valor > 0)

Variable	n	Mediana	Máximo	CV	% IQR 1.5	% IQR 3.0
CANTIDAD_ELEMENTOS	48 375	2	2 469	3.15	14.91	11.78
CANTIDAD_USUARIOS	48 375	23	34 622	3.97	14.50	10.83
DURACION_min	48 364	417	332 395	3.56	8.94	5.36
FRECUENCIA	48 364	1	6	0.15	1.96	1.96

Tabla agrupada cuadrante × semana. Sobre `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90\,128$ observaciones, se replicó el mismo esquema excluyendo `id_cuadrante`, `latitud`, `longitud` y `altitud`. El procedimiento se documenta en el Apéndice A.3.5.

Variables climáticas semanales. El diagnóstico se realizó sobre la tabla completa. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas, baja dispersión (en la humedad, CV del orden de 0.16; en la temperatura, en grados Celsius, el CV no se interpreta como dispersión relativa) y un porcentaje bajo de extremos según la regla de Tukey (entre $0\,\%$ y $0.03\,\%$); con el factor 3.0 no se identifican extremos severos. El viento semanal es más heterogéneo (CV ≈ 0.78–0.81). La `precip_total_semana` constituye la excepción: al ser un acumulado semanal asimétrico a la derecha con CV $= 1.17$, la regla de Tukey marca el $6.21\,\%$ de las observaciones y la ampliada el $1.79\,\%$, aunque la regla de percentiles solo señala el $0.99\,\%$. Los valores señalados corresponden a semanas de lluvia intensa operativamente plausibles: el máximo observado es de 198.1 mm acumulados en la semana, magnitud compatible con los registros de temporada de lluvia en la región. La Tabla 6.4 resume estos resultados y las Figuras A.3a y A.7 muestran los diagramas de caja y los histogramas sobre las $90\,128$ observaciones.

Tabla 6.4: Valores extremos y dispersión relativa en variables climáticas semanales (tabla agrupada)

Variable	Mediana	CV	% IQR 1.5	% IQR 3.0	% P1–P99
`temp_media_semana`	24.84	0.19	0.00	0.00	1.95
`temp_max_semana`	32.72	0.17	0.00	0.00	1.99
`temp_min_semana`	18.95	0.25	0.03	0.00	1.96
`humedad_media_semana`	72.28	0.16	0.00	0.00	1.97
`viento_medio_semana`	0.91	0.81	0.00	0.00	1.99
`viento_max_semana`	1.26	0.78	0.00	0.00	1.69
`precip_total_semana`	9.78	1.17	6.21	1.79	0.99

Variables de severidad y continuidad. En la tabla completa persisten semanas sin interrupción registrada ($Q_1 = Q_3 = 0$ en `usuarios_afectados`, `elementos_afectados` y `n_eventos`), por lo que la regla de Tukey sobre el total es poco informativa para esas variables y el CV del panel completo queda inflado por ceros (Tabla 6.7). El análisis relevante se realiza sobre semanas con evento (valor > 0), con $22\,660$–$24\,800$ registros según la variable. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha y de alta dispersión relativa: la mediana de `usuarios_afectados` es 52 usuarios pero su máximo alcanza

69 928 (CV = 3.82); `duracion_total` tiene mediana de 19.7 horas y un máximo de 2 227 horas (≈ 93 días acumulados; CV = 1.73). La regla de Tukey marca entre el 11.6 % y el 15.2 % de las semanas con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 6.5 resume estos resultados y las Figuras A.3b y A.8 presentan los diagramas de caja e histogramas.

Tabla 6.5: Valores extremos y dispersión relativa en severidad y continuidad (semanas con evento, valor > 0)

Variable	n	Mediana	Máximo	CV	% IQR 1.5	% IQR 3.0
`usuarios_afectados`	22 660	52	69 928	3.82	15.16	11.21
`elementos_afectados`	22 660	7	3 626	2.75	15.00	10.70
`duracion_total`	24 800	19.7	2 227	1.73	11.56	4.25
`n_eventos`	22 659	1	58	1.08	14.53	5.73

En síntesis, en el grano cuadrante × semana los extremos climáticos son escasos y operativamente plausibles (con la precipitación acumulada como única variable de asimetría apreciable y CV superior a la unidad), mientras que en severidad y continuidad la cola pesada y el CV condicionado a semanas con evento reflejan semanas de alta afectación o múltiples eventos en un mismo cuadrante. No se aplican transformaciones ni exclusiones en esta etapa; las decisiones de tratamiento se documentan y ejecutan en la Etapa 4 a partir de este diagnóstico sobre la tabla de análisis.

6.3.3. Cálculo de estadísticos descriptivos

Tras el diagnóstico de completitud (Sección 6.3.1) y el análisis de valores extremos (Sección 6.3.2), se calculó un conjunto sistemático de estadísticos descriptivos sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90\,128$ observaciones cuadrante × semana. Se excluyeron las llaves y coordenadas (`id_cuadrante`, `latitud`, `longitud`, `altitud`) y se evaluaron las 11 variables numéricas de severidad, clima semanal y continuidad. El procedimiento reproducible se documenta en el Apéndice A.3.6.

Para cada variable se reportaron: (i) medidas de tendencia central (media, mediana y moda); (ii) medidas de dispersión (rango, varianza, desviación estándar y coeficiente de variación; Sección 3.1.2); (iii) medidas de posición (cuartiles, deciles y percentiles P1, P5, P95 y P99); (iv) medidas de forma (asimetría y curtosis con exceso); y (v) distribución de frecuencias de la categoría derivada *actividad semanal del cuadrante*, construida a partir de `n_eventos` (sin eventos; 1 evento; 2–5 eventos; más de 5 eventos). Las Figuras A.9 y A.3c presentan la vista panorámica de las 11 variables mediante histogramas y diagramas de caja.

Variables climáticas semanales. Las siete variables meteorológicas agregadas presentan distribuciones aproximadamente simétricas. Entre las medidas en escala de razón, el coeficiente de variación (CV) se ubica entre 0.16 (`humedad_media_semana`) y 0.81 (`viento_medio_semana`); para la temperatura se reportan cuartiles, porque el CV no es interpretable en grados Celsius. La temperatura media semanal tiene mediana de 24.8 °C (media 23.8 °C; Q_1–Q_3: 20.4–27.2 °C) y asimetría cercana a cero (-0.37). La humedad relativa media semanal concentra la mediana en $72.3\,\%$ (CV $= 0.16$). La excepción es `precip_total_semana`: acumulado semanal con mediana de 9.8 mm, media de 16.0 mm, CV $= 1.17$ y asimetría positiva (1.98), con un recorrido de 0 a 198.1 mm y un percentil 99 de 85.1 mm que corresponde a semanas de lluvia intensa puntuales. La Tabla 6.6 resume tendencia central y dispersión; la Figura A.10 muestra las curvas de densidad.

Tabla 6.6: Estadísticos descriptivos de variables climáticas semanales (tabla agrupada)

Variable	Media	Mediana	Desv. est.	CV	Asimetría
`temp_media_semana`	23.8	24.8	4.63	0.19	−0.37
`temp_max_semana`	31.9	32.7	5.29	0.17	−0.44
`temp_min_semana`	17.9	19.0	4.49	0.25	−0.49
`humedad_media_semana`	70.9	72.3	11.5	0.16	−0.36
`viento_medio_semana`	0.99	0.91	0.80	0.81	0.44
`viento_max_semana`	1.30	1.26	1.01	0.78	0.37
`precip_total_semana`	16.0	9.8	18.7	1.17	1.98

Variables de severidad y continuidad. Las cuatro variables operativas están dominadas por ceros: la mediana de `usuarios_afectados`, `elementos_afectados`, `n_eventos` y `duracion_total` es 0 en el $74.9\,\%$ de las semanas-cuadrante sin eventos registrados (Tabla 6.8; Figura A.11). Cuando ocurre al menos un evento, las distribuciones son fuertemente leptocúrticas y con cola derecha pesada: `usuarios_afectados` alcanza un máximo de $69\,928$ usuarios (media 156.1; CV del panel completo $= 7.81$, inflado por ceros; CV condicionado a semanas con evento $= 3.82$); `duracion_total` un máximo de $2\,227$ horas acumuladas en la semana (media 13.7 h; CV completo $= 3.67$; CV condicionado $= 1.73$). La Tabla 6.7 resume las medidas principales del panel completo; la Tabla 6.5 reporta el CV condicionado; la Figura A.12 presenta las densidades en escala logarítmica desplazada (Sección 3.1.2) para semanas con evento.

En síntesis, el clima semanal exhibe comportamiento estable y casi simétrico, mientras que las variables operativas reflejan fuerte cero-inflación y colas pesadas propias del fenómeno de interrupciones. Estos perfiles, especialmente la asimetría de `precip_total_semana` y la concentración de semanas sin even-

Tabla 6.7: Estadísticos descriptivos de severidad y continuidad (tabla agrupada; panel completo)

Variable	Media	Mediana	Máx.	CV	Asimetría	Q_3
`usuarios_afectados`	156.1	0	69 928	7.81	20.6	1
`elementos_afectados`	12.0	0	3 626	5.74	14.1	1
`n_eventos`	0.55	0	58	2.76	8.18	1
`duracion_total`	13.7	0	2 227	3.67	10.2	2.5

Nota: el CV del panel completo queda inflado por la cero-inflación; el CV condicionado a semanas con evento se reporta en la Tabla 6.5.

Tabla 6.8: Distribución de frecuencias por actividad semanal del cuadrante

Categoría (n_eventos)	Frec. absoluta	Frec. relativa (%)	Frec. acumulada (%)
Sin eventos	67 469	74.86	74.86
1 evento	12 115	13.44	88.30
2 a 5 eventos	9 246	10.26	98.56
Más de 5 eventos	1 298	1.44	100.00

to, orientan las transformaciones logarítmicas desplazadas (Sección 3.1.2) y la selección de modelos en la Etapa 4.

6.3.4. Análisis de la distribución de variables

Con el propósito de comprender el comportamiento estadístico de las variables incluidas en el estudio, se realizó un análisis de distribución sobre las variables climáticas, de severidad y de continuidad contenidas en la tabla agregada cuadrante $\times$ semana ($N_{\text{agr}} = 90\,128$; Sección 5.2.5). Para las variables cuantitativas se emplearon diagramas de densidad, complementados con indicadores de forma (asimetría, curtosis y proporción de ceros) y con el coeficiente de variación reportado en las Secciones 6.3.2–6.3.3, lo que permitió evaluar simetría, dispersión relativa, unimodalidad y presencia de valores extremos. El procedimiento reproducible se documenta en el Apéndice A.3.7.

Variables climáticas. Los resultados evidencian que las variables meteorológicas presentan distribuciones heterogéneas. Las temperaturas (media, máxima y mínima) y la humedad relativa muestran comportamientos estables, aproximadamente unimodales, con asimetría cercana a cero (entre -0.49 y -0.36) y CV bajo (0.16–0.25), coherentes con las curvas de densidad presentadas en la Figura A.10. En contraste, la precipitación acumulada semanal presenta asimetría positiva (coeficiente de 1.98 y curtosis con exceso de 4.78), CV $= 1.17$, alta frecuencia de semanas con valores bajos de lluvia (el $9.1\,\%$ registra 0 mm) y un número reducido de observaciones con precipitaciones intensas. La Figura A.13

contrasta la distribución en escala original y en escala logarítmica desplazada (Sección 3.1.2): la transformación aproxima la distribución a una forma simétrica, lo que anticipa su utilidad en la Etapa 4.

Variables de severidad y continuidad. Las variables asociadas a interrupciones del servicio (`usuarios_afectados`, `elementos_afectados`, `duracion_total` y `n_eventos`) muestran distribuciones altamente sesgadas hacia cero: la proporción de filas con valor 0 se ubica entre el $72.5\,\%$ (`duracion_total`) y el $74.9\,\%$ (resto de variables), como ilustra la Figura 6.1. Este comportamiento es esperado, dado que la mayor parte de las semanas-cuadrante no registra fallas. Sin embargo, condicionando a la ocurrencia de eventos (valor > 0), las distribuciones presentan colas derechas largas, con asimetrías entre 8.2 y 20.6 y curtosis entre 139 y 643, que reflejan la existencia de incidentes de alta severidad con impacto significativo sobre la continuidad del servicio, según se aprecia en las densidades en escala logarítmica desplazada de la Figura A.12.

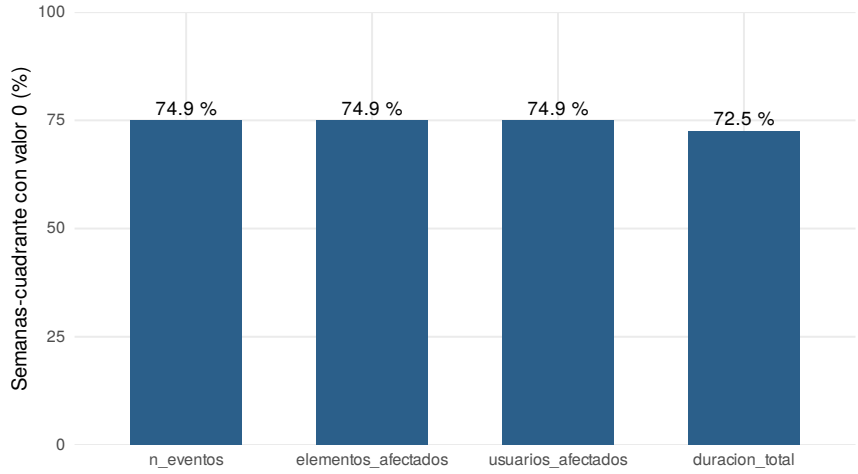


Figura 6.1: Proporción de ceros en las variables de severidad y continuidad de la tabla agrupada.

En síntesis, el análisis de distribución confirma dos regímenes diferenciados: un bloque climático estable y casi simétrico (CV bajo, con la precipitación como excepción asimétrica de CV algo superior a la unidad) y un bloque operativo cero-inflado con colas pesadas y CV condicionado alto. Estos hallazgos fundamentan las transformaciones logarítmicas desplazadas (Sección 3.1.2) y la consideración de modelos aptos para datos cero-inflados en la Etapa 4.

6.3.5. Análisis temporal de eventos

Para caracterizar la dinámica temporal de las interrupciones se construyó, a partir de la tabla agregada `data_agrupada.csv` (Sección 5.2.5), la serie territorial semanal que consolida el total de `n_eventos` de todos los cuadrantes en cada semana calendario. La serie cubre 262 semanas del horizonte 2021–2025, con una mediana de 124.5 eventos por semana (media 188.5; máximo 648). El procedimiento reproducible se documenta en el Apéndice A.3.8.

Evolución de la serie semanal. La Figura A.14 presenta la serie semanal con su tendencia suavizada (LOESS) sobre el horizonte exploratorio 2021–2025 (D_{EDA}). Se distinguen dos regímenes visuales: entre 2021 y 2023 la actividad se mantiene en un nivel bajo y relativamente estable, mientras que a partir de 2024 se observa un incremento sostenido del nivel de la serie. La agregación anual (Figura A.15) cuantifica este cambio: de 5 167 eventos en 2021 y 4 934 en 2022, se pasa a 15 211 en 2024 y 18 199 en 2025; en términos de intensidad, el promedio asciende de ≈ 99 a ≈ 350 eventos por semana entre 2021 y 2025. La reinterpretación de este salto a la luz de la cobertura de integración se desarrolla en el párrafo siguiente (Sección 6.3.5).

Diagnóstico de cobertura del emparejamiento evento–elemento. Al contrastar el conteo anual de eventos en `tabla_eventos_ajustado.csv` (BRAE) con la suma territorial de `n_eventos` en `data_agrupada.csv`, se identificó un *sesgo sistemático* en el grano espacial durante 2021–2023 (Tabla 6.9; Figura 6.2). La causa no es la ausencia del campo `COMPONENTE_FALLADO`, completo en el 100 % de los registros BRAE, sino la *incompatibilidad entre esquemas de codificación* al cruzar eventos con el inventario georreferenciado `tipo_elemento.csv` (Tabla 5.5).

En la operación de la red coexisten dos identificadores para un mismo punto de conexión: (i) el *código de sitio* (ubicación), estable en el tiempo y empleado por el inventario GIS como `ELEMENTO`; y (ii) el *código de activo*, asociado al equipo instalado y *sujeto a cambio* cuando el activo se repone por mantenimiento o renovación, mientras el código de sitio permanece invariante. El panel consolidado y la agregación cuadrante $\times$ semana se construyen sobre el código de sitio. No obstante, en el sistema histórico OMS-SPARD (Sección 5.1.5) el elemento fallado (`BREAKER` $\rightarrow$ `COMPONENTE_FALLADO`) se registraba con frecuencia mediante el *código del activo* y no el del sitio. Ello impide el seguimiento histórico del punto de desconexión, unidad espacial central para el pronóstico territorial de $SAIDI$ y $SAIFI$ en esta tesis, pues el cruce `COMPONENTE_FALLADO` $=$ `ELEMENTO` no encuentra coincidencia en el inventario y el evento no genera `FRECUENCIA` en el panel activo $\times$ día.

El diagnóstico cuantitativo confirma esta hipótesis: la proporción de eventos cuyo `COMPONENTE_FALLADO` coincide con algún `ELEMENTO` de `tipo_elemento.csv` es del 30.5 % (2021), 30.9 % (2022) y 31.7 % (2023), valores cercanos a la cobertura del panel espacial en esos años (28.1 %, 28.1 % y 29.1 %, respectivamente). Con la migración a OMS-SP7 (Sección 5.1.6), la coincidencia asciende al 79.8 % (2024) y al 95.0 % (2025), acompañada por coberturas del panel del 77.7 % y 92.4 %. La Figura A.15 debe interpretarse a la luz de esta brecha: el salto a partir de 2024 refleja en gran medida una *mayor homogeneización de la codificación* bajo OMS-SP7, y no únicamente un incremento operativo de interrupciones.

El procedimiento reproducible se documenta en el Apéndice A.3.9. Con base en este hallazgo, emergido en el presente análisis temporal, se define el *conjunto de modelado* D_{mod} como el subconjunto de `data_agrupada.csv` con `year(semana)` $\in \{2024, 2025\}$, que comprende 36 120 filas cuadrante $\times$ semana, 105 semanas y 33 410 eventos georreferenciados en total (15 211 en 2024 y 18 199 en 2025). El horizonte 2021–2025 se conserva como D_{EDA} para las Secciones 6.3.1–6.3.5, pero *no* se empleará para estimar el modelo predictivo de la Etapa 4.

Tabla 6.9: Cobertura anual de la trazabilidad al inventario GIS y al panel espacial.

Año	Eventos BRAE	En inventario (%)	Panel espacial	Cobertura (%)
2021	18 398	30.5	5 167	28.1
2022	17 542	30.9	4 934	28.1
2023	20 068	31.7	5 845	29.1
2024	19 583	79.8	15 211	77.7
2025	19 689	95.0	18 199	92.4

Nota: "En inventario (%)" es la proporción de eventos cuyo `COMPONENTE_FALLADO` coincide con `ELEMENTO` en `tipo_elemento.csv` (código de sitio). "Panel espacial" es la suma anual de `n_eventos` en `data_agrupada.csv`. La brecha entre ambas columnas en 2021–2023 se atribuye al registro del código de activo, y no del código de sitio, en OMS-SPARD, lo que impide el seguimiento histórico del punto de desconexión. Los años 2024–2025 delimitan D_{mod}.

Estacionalidad intra-anual. La Figura A.16 muestra la distribución de los totales semanales según el mes calendario. Se aprecia heterogeneidad estacional, con mayor actividad y dispersión en algunos meses del año, patrón que motiva incorporar términos estacionales en la Etapa 4. La atribución de esta estacionalidad a la temporada de lluvias debe tomarse con cautela: como se documenta en la Sección 6.3.7, la asociación semanal entre precipitación y frecuencia de eventos es débil en el grano cuadrante $\times$ semana.

Autocorrelación temporal. Las funciones de autocorrelación simple y parcial de la serie semanal (Figura A.17) evidencian fuerte persistencia: la autocorrelación es 0.92 en el rezago de una semana y decae lentamente (0.60 a 12 semanas;

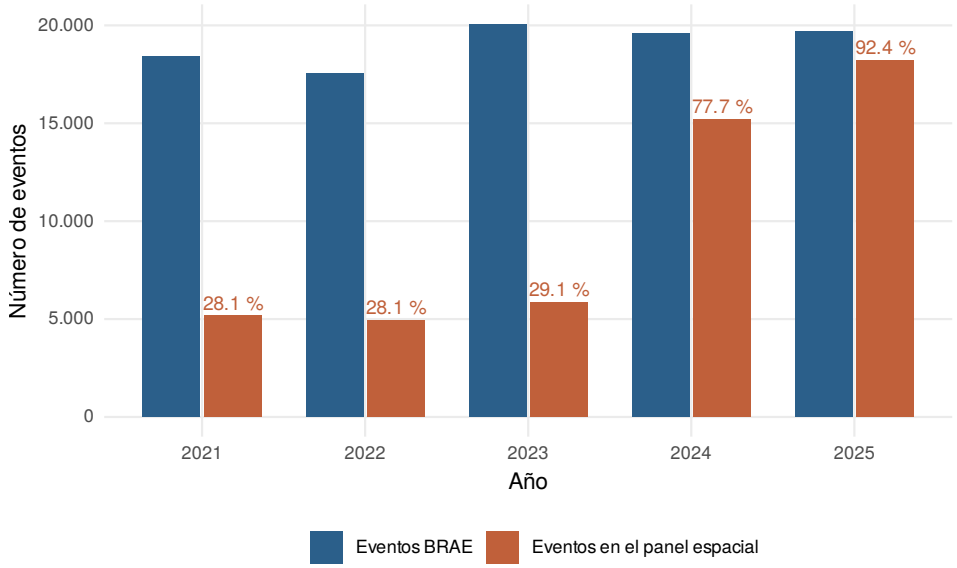


Figura 6.2: Comparación anual entre eventos BRAE y eventos reflejados en el panel espacial. Las etiquetas indican el porcentaje de cobertura respecto a BRAE; la brecha histórica se explica por la incompatibilidad entre el código de activo registrado en OMS-SPARD y el código de sitio del inventario GIS.

0.38 a 26), manteniéndose significativa frente al intervalo de confianza del $95\,\%$ bajo ruido blanco (± 0.12). Adicionalmente, el rezago de 52 semanas conserva una autocorrelación de 0.43, indicativa de un componente estacional anual. Esta estructura justifica la incorporación de rezagos y términos estacionales como variables predictoras en la Etapa 4.

Evolución de la severidad y extensión territorial. La Figura A.18 presenta las series semanales de usuarios afectados y duración acumulada: ambas acompañan el incremento de nivel observado en la frecuencia de eventos a partir de 2024, lo que indica que el cambio de régimen no es solo de conteo sino también de impacto sobre la continuidad del servicio. Complementariamente, la Figura A.19 muestra el número de cuadrantes con al menos un evento por semana, que crece en paralelo: la mayor actividad reciente se distribuye sobre una porción más amplia del territorio y no se explica por unos pocos cuadrantes puntuales.

En síntesis, el análisis temporal sobre D_{EDA} revela: (i) un cambio de nivel de la serie a partir de 2024, reinterpretado como mayor homogeneización de la codificación activo/sitio bajo OMS-SP7, y no como incremento operativo aislado, lo que motiva la restricción del conjunto de modelado a D_{mod} (2024–2025; Sección 6.3.5); (ii) estacionalidad intra-anual en la actividad de interrupciones, cuya atribución al régimen de lluvias no se sostiene con el acumulado semanal de

precipitación (Sección 6.3.7); y (iii) fuerte persistencia semanal con componente anual, que fundamenta el uso de rezagos temporales como predictores en D_{mod}. Estos hallazgos orientan la generación de ventanas temporales y la partición de datos de la Etapa 4.

Materialización de D_{mod}. Para operacionalizar la delimitación temporal sin alterar el insumo exploratorio, se construyó el archivo `data_agrupada_mod.csv` como subconjunto de `data_agrupada.csv` con filtro `year(semana)` $\in \{2024, 2025\}$, conservando el grano cuadrante $\times$ semana y el conjunto completo de variables climáticas y operativas. La tabla original 2021–2025 permanece intacta como D_{EDA}; el resultado filtrado (36 120 filas; 344 cuadrantes; 105 semanas; 33 410 eventos) constituye el insumo analítico para las Secciones 6.3.6 en adelante y la Etapa 4. Los análisis exploratorios de esta etapa contrastan 2024 con 2025; la partición de modelado es distinta y se define en la Sección 5.4.8 (corte el 8 de septiembre de 2025). El procedimiento reproducible, lectura, filtro, resumen por año y exportación, se documenta en el Apéndice A.3.10.

Enriquecimiento de D_{mod}. Sobre la llave cuadrante–semana se incorporaron 16 variables destinadas a ampliar la caracterización de exposición, composición de usuarios y trayectoria de intervención de los activos. La serie mensual `data_usuarios_totales_sistema.csv` aporta `usuarios_totales`, asignada a cada semana de acuerdo con el mes calendario de su fecha de inicio y utilizada como denominador en la construcción de SAIDI y SAIFI. Por otra parte, `cant_usuarios_x_transformador.csv` aporta `cantidad_usuarios_cuadrante`, calculada como la suma mensual de usuarios de los transformadores asociados a cada cuadrante.

La composición socioeconómica y de uso del servicio se integró desde `DATA_ESTRATO_SECTOR.csv`, agregando por cuadrante y mes las variables `ESTRATO_1` a `ESTRATO_6`, `INDUSTRIAL`, `COMERCIAL`, `OFICIAL`, `PROVISIONAL` y `ALUMBRADO_PUBLICO`. Para los meses faltantes de los cuadrantes 258 y 273 se empleó la moda mensual del respectivo cuadrante; los cuadrantes 68, 140, 333 y 344, ausentes en la fuente, se asignaron en cero.

Finalmente, se integró el archivo `Fecha_transformadores.csv` mediante la llave `ID_CUADRANTE`. Para cada elemento se contabilizaron sus registros de modificación y se tomó la última `TT2_FMODIFICACION` en estado `OPERACION`; posteriormente, por cuadrante, se derivaron `FECHA_ACTIVO_MAS_VIEJO`, `FECHA_ACTIVO_MAS_NUEVO` y `PROM_CANT_MODIFICACIONES`. Estas variables permiten evaluar la relación entre la trayectoria de intervención de la infraestructura y los indicadores de continuidad. No obstante, las fechas representan modificaciones registradas

y no necesariamente la instalación original del activo. Para evitar fuga de información, su uso predictivo debe restringirse a registros conocidos antes de la semana pronosticada; SAIDI y SAIFI se emplean exclusivamente como variables objetivo.

6.3.6. Identificación de patrones, tendencias y visualización exploratoria

Con fundamento en la delimitación de D_{mod} (Sección 6.3.5), se identifican patrones temporales, espaciales y de asociación clima–evento sobre la tabla `data_agrupada_mod.csv` (36 120 filas cuadrante $\times$ semana; 344 cuadrantes; 105 semanas; 33 410 eventos en 2024–2025). En esta misma subsección se integra la *visualización exploratoria* sobre D_{mod}: series de tiempo, diagramas de dispersión y mapas temáticos que complementan el análisis cuantitativo de patrones. El procedimiento reproducible se documenta en el Apéndice A.3.11.

Patrones temporales. La Figura 6.3 presenta la serie semanal territorial de eventos en D_{mod}, con media de ≈ 318 eventos por semana. Aunque las etiquetas del eje horizontal se muestran cada 3 meses para facilitar la lectura, cada tramo de la linea corresponde a observaciones semanales consecutivas. La intensidad promedio asciende de 287 eventos/semana en 2024 a 350 en 2025. La estacionalidad mensual (Figura A.20) confirma la heterogeneidad entre meses observada en la Sección 6.3.5 sobre D_{EDA}, sin que el acumulado semanal de lluvia explique ese patrón. La ACF de la serie semanal (Figura 6.4) mantiene persistencia elevada (rezago $1 = 0.80$), lo que respalda el uso de rezagos como predictores en la Etapa 4.

Patrones espaciales. El ranking de cuadrantes por total de `n_eventos` (Figura A.21) y el mapa de intensidad territorial (Figura 6.5) evidencian heterogeneidad espacial: los diez cuadrantes más activos concentran el 20.5 % de los eventos del periodo, mientras el 14.2 % de los cuadrantes (49 de 344) se clasifica en nivel de actividad *alta* (Figura A.23). La actividad no se distribuye de forma uniforme sobre la malla de 800 cuadrantes, sino que se agrupa en zonas de mayor exposición operativa.

La Figura A.3d complementa el ranking anterior con la *ubicación geográfica* de los cuadrantes más activos sobre la malla territorial del área de estudio. Los recuadros resaltados corresponden a los primeros cuadrantes *top* del periodo 2024–2025 y muestran una concentración en cuatro zonas: (i) el área metropolitana de Cúcuta y Villa del Rosario; (ii) un corredor al suroccidente, en torno a Salazar, Arboledas, Durania y Chinácota; (iii) la subregión de Tibú, al norte del

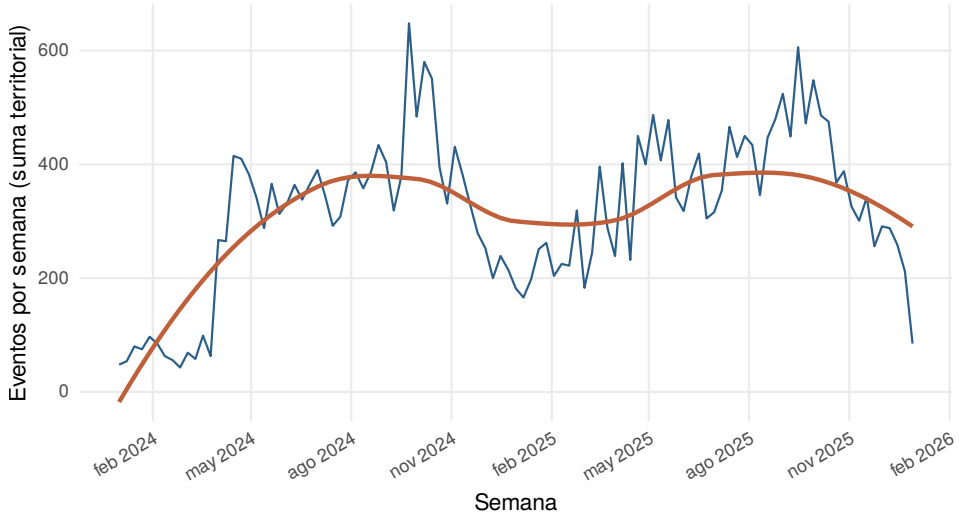


Figura 6.3: Evolución semanal de eventos sobre D_{mod} (2024–2025).

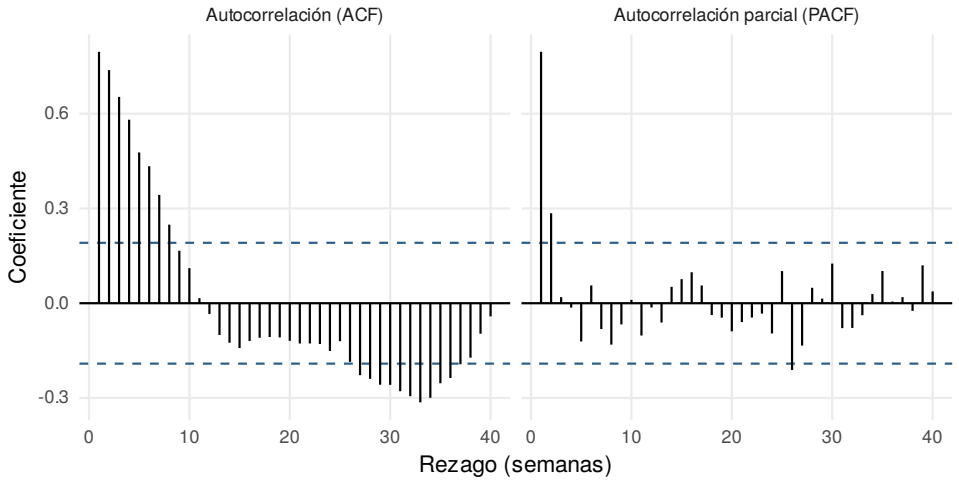


Figura 6.4: Persistencia y estructura temporal de la serie semanal de eventos en D_{mod}.

departamento; y (iv) los municipios de Ocaña y Aguachica, al occidente. Esta distribución espacial confirma que la mayor actividad de interrupciones no es aleatoria, sino que se agrupa en núcleos urbanos y corredores de servicio de la red.

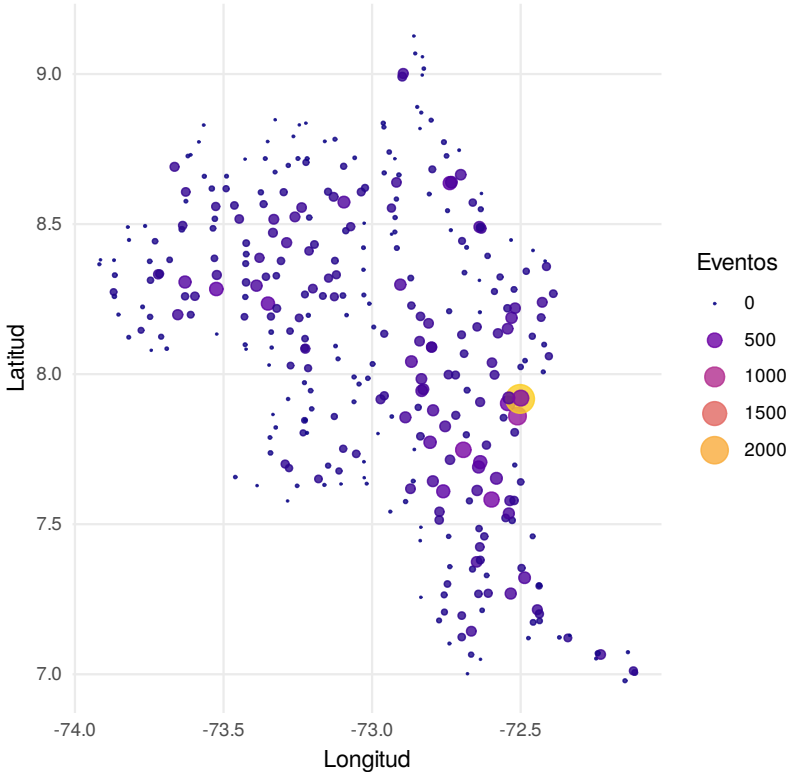


Figura 6.5: Intensidad territorial de eventos por cuadrante (2024–2025).

Patrones clima–evento. Mediante la estimación de la correlación de Spearman a nivel cuadrante $\times$ semana, las variables de viento exhiben la asociación positiva más fuerte con `n_eventos` (`viento_max_semana`: $\hat{\rho} = 0.14$; `viento_medio_semana`: $\hat{\rho} = 0.14$; $p < 0.001$), seguidas de la precipitación acumulada semanal (`precip total semana`: $\hat{\rho} = 0.07$) y la humedad ($\hat{\rho} = 0.05$). La Figura A.22 ilustra la relación entre precipitación y frecuencia de eventos: la nube muestra una tendencia positiva leve, sin un patrón fuerte. Las temperaturas presentan asociaciones débiles y negativas ($|\hat{\rho}| < 0.05$). En el grano semanal, por tanto, la señal climática es de magnitud modesta y está encabezada por el viento, no por la lluvia.

En síntesis, el análisis de patrones y la visualización exploratoria sobre D_{mod} confirman: (i) persistencia y estacionalidad temporal (series semanales, estacionali-

dad mensual y ACF); (ii) concentración espacial en un subconjunto de cuadrantes (ranking, mapa de intensidad y segmentación por actividad); y (iii) asociación positiva pero débil entre las covariables meteorológicas y la frecuencia de interrupciones, encabezada por el viento y seguida por la precipitación (correlación de Spearman y diagrama de dispersión). Estos hallazgos orientan la selección de variables predictoras y la estratificación territorial de la Etapa 4. Los mapas de calor de correlaciones y el análisis multivariado formal se desarrollan en las Secciones 6.3.7 y 6.3.8.

6.3.7. Análisis de correlación y asociación

Con fundamento en los patrones preliminares de la Sección 6.3.6, se realizó un análisis sistemático de asociación pareada sobre `data_agrupada_mod.csv` (D_{mod}; 36 120 filas cuadrante $\times$ semana). Dado el carácter asimétrico, cero-inflado y de colas pesadas de las variables operativas (Sección 6.3.4), se empleó el coeficiente de correlación de *Spearman* en lugar de Pearson. El procedimiento reproducible se documenta en el Apéndice A.3.12.

Matriz de asociación global. Se calcularon las correlaciones de Spearman entre las variables operativas (`n_eventos`, `usuarios_afectados`, `elementos_afectados`, `duracion_total`), las siete variables climáticas semanales y las coordenadas geográficas (`altitud`, `latitud`, `longitud`). La Figura 6.6 resume la submatriz clima–operativo. Los pares con mayor asociación absoluta del panel completo concentran redundancia operativa: `usuarios_afectados`–`elementos_afectados` ($\rho = 0.99$), `n_eventos`–`elementos_afectados` ($\rho = 0.98$) y `n_eventos`–`usuarios_afectados` ($\rho = 0.97$). Parte de esta magnitud es *mecánica*: las tres métricas provienen de la misma tabla de eventos, comparten la masa de ceros en semanas sin interrupción y, al agregarse por suma, crecen juntas cuando aumenta el número de eventos. Por ello no deben interpretarse como evidencia de tres dimensiones independientes ni usarse simultáneamente como respuesta y predictoras; la definición definitiva del rol de la severidad se aplaza a la Etapa 4.

Bloque climático: redundancias. En el bloque meteorológico (Figura A.24) se identificaron *diez* pares con $|\rho| \geq 0.70$, principalmente entre temperaturas (`temp_media`–`temp_max`: $\rho = 0.96$; `temp_media`–`temp_min`: $\rho = 0.91$) y entre componentes de viento ($\rho = 0.97$). Las temperaturas presentan además asociación negativa moderada con la humedad ($\rho \approx -0.76$ a -0.80) y con el viento ($\rho \approx -0.70$ a -0.81). La precipitación no participa en ninguno de estos pares: su mayor asociación dentro del bloque queda por debajo del umbral, lo que la señala como

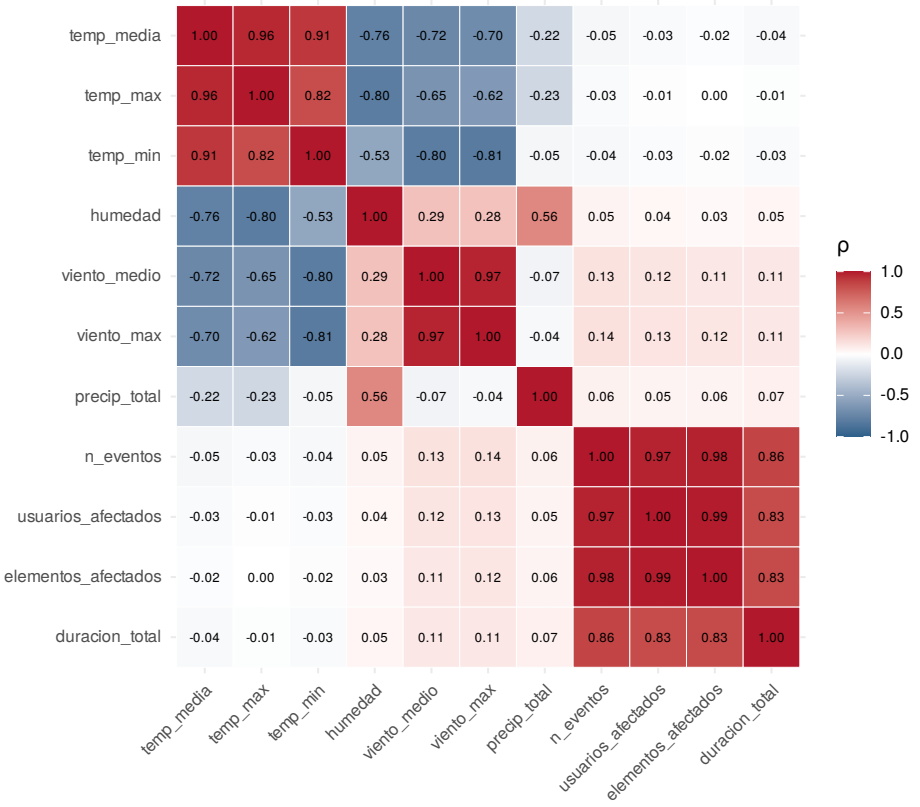


Figura 6.6: Asociación de Spearman entre variables climáticas y operativas en D_{mod}.

la única covariable climática no redundante. Estos resultados anticipan *multicolinealidad* entre temperaturas y vientos, y orientan la depuración de variables en la Etapa 4.

Bloque operativo. La Figura A.25 muestra que las cuatro métricas de continuidad y severidad están fuertemente correlacionadas entre sí (ρ entre 0.83 y 0.99), aunque `duracion_total` exhibe una asociación algo menor con `n_eventos` ($\rho = 0.86$) que con las variables de afectación. Frecuencia y duración capturan dimensiones parcialmente distintas; el alcance (`usuarios_afectados`, `elementos_afectados`) queda, en esta construcción, estrechamente alineado con la frecuencia y se trata aquí como diagnóstico exploratorio de severidad, no como predictor independiente.

Clima → operativo. La Figura A.26 y la Tabla 6.10 cuantifican la asociación entre covariables meteorológicas y métricas de interrupción. Todas las asociaciones son estadísticamente significativas, consecuencia esperable del tamaño del panel, pero de magnitud pequeña. Las variables de *viento* encabezan el bloque: `viento_max_semana` con `n_eventos` ($\rho = 0.139$) y `viento_medio_semana` con `n_eventos` ($\rho = 0.135$), con valores del mismo orden frente a `usuarios_afectados` ($\rho \approx 0.12$), `elementos_afectados` ($\rho \approx 0.11$) y `duracion_total` ($\rho \approx 0.11$). La `precip_total_semana` le sigue con asociaciones positivas débiles ($\rho = 0.069$ con `duracion_total` y $\rho = 0.065$ con `n_eventos`), mientras la humedad ($\rho \approx 0.05$) y las temperaturas ($|\rho| < 0.05$, con signo negativo) resultan prácticamente irrelevantes en el grano semanal.

Conviene precisar el alcance de este resultado. La magnitud reducida de la asociación no implica ausencia de efecto físico de la lluvia sobre la red, sino que el acumulado semanal por cuadrante es un descriptor grueso del fenómeno: promedia días secos y días de tormenta, y no captura la intensidad horaria ni la coincidencia temporal exacta entre el evento meteorológico y la desconexión. Con este descriptor, la asociación bivariada disponible en el grano cuadrante $\times$ semana es débil, y así se reporta.

Análisis condicionado. Dado que el $63\,\%$ de las filas cuadrante $\times$ semana registra `n_eventos` $= 0$, se repitió el análisis sobre el subconjunto con al menos un evento ($13\,351$ filas; $37\,\%$ del panel). En este régimen la asociación precipitación–`n_eventos` se atenúa aún más ($\rho = 0.029$) y el viento conserva la primacía ($\rho = 0.097$ para `viento_max_semana`), lo que indica que la escasa señal climática se concentra en la transición entre semanas sin y con interrupción, y no en la intensidad condicional de los eventos. La Figura A.27 resume las correlaciones

Tabla 6.10: Asociación Spearman entre clima y variables operativas: pares de mayor magnitud (D_{mod}; panel completo)

Par de variables	Spearman ρ	p-valor
`viento_max_semana` ↔ `n_eventos`	0.139	< 0.001
`viento_medio_semana` ↔ `n_eventos`	0.135	< 0.001
`viento_max_semana` ↔ `usuarios_afectados`	0.125	< 0.001
`viento_max_semana` ↔ `duracion_total`	0.112	< 0.001
`precip_total_semana` ↔ `duracion_total`	0.069	< 0.001
`precip_total_semana` ↔ `n_eventos`	0.065	< 0.001
`precip_total_semana` ↔ `elementos_afectados`	0.056	< 0.001
`precip_total_semana` ↔ `usuarios_afectados`	0.053	< 0.001
`humedad_media_semana` ↔ `n_eventos`	0.054	< 0.001
`temp_media_semana` ↔ `n_eventos`	$-0{,}047$	< 0.001

en este subconjunto.

En síntesis, el análisis de correlación sobre D_{mod} confirma: (i) *alta redundancia* entre variables operativas de severidad y entre temperaturas/vientos del bloque climático; (ii) una *señal climática débil en términos bivariados*, encabezada por el viento ($\rho \approx 0.14$) y seguida por la precipitación ($\rho \approx 0.07$); y (iii) *asociaciones prácticamente nulas* de temperatura y humedad en el grano semanal. Estos hallazgos fundamentan conservar `viento_medio_semana` y `precip_total_semana` como candidatas climáticas, sujetas a la regla de disponibilidad *ex ante* (rezago o pronóstico; Sección 3.1.2), la exclusión de variables climáticas redundantes y la fijación de la respuesta en `n_eventos` y/o `duracion_total`, dejando `usuarios_afectados` y `elementos_afectados` fuera del conjunto de predictoras contemporáneas (impacto posterior). Asimismo advierten que la Etapa 4 no debe apoyarse únicamente en covariables meteorológicas de la misma semana: la estructura temporal y territorial de la propia serie de eventos (Secciones 6.3.5 y 6.3.9) concentra la mayor parte de la señal predictiva disponible. El análisis multivariado formal (VIF, redundancia simultánea) se desarrolla en la Sección 6.3.8.

6.3.8. Evaluación inicial de relaciones multivariadas

Con fundamento en las redundancias bivariadas identificadas en la Sección 6.3.7, se evaluaron las relaciones *simultáneas* entre covariables sobre D_{mod} mediante VIF, PCA exploratorio, agrupamiento jerárquico de variables climáticas, correlación parcial y un GLM Poisson de diagnóstico (Sección 3.1.2). El procedimiento reproducible se documenta en el Apéndice A.3.13.

Multicolinealidad climática (VIF). Se estimó un modelo auxiliar lineal `n_eventos` $\sim$ bloque climático completo para calcular el VIF de cada covariable. La Figura 6.7 muestra VIF elevados en `temp_media_semana` (43.92), `viento_`

`medio_semana` (24.22), `viento_max_semana` (22.58), `temp_max_semana` (17.27) y `temp_min_semana` (14.37), mientras `precip_total_semana` (1.50) presenta inflación baja y `humedad_media_semana` (5.68) apenas moderada. Al restringir el bloque a `precip_total_semana`, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana`, los VIF descienden a valores aceptables (máximo 7.21 en temperatura media; Tabla 6.11).

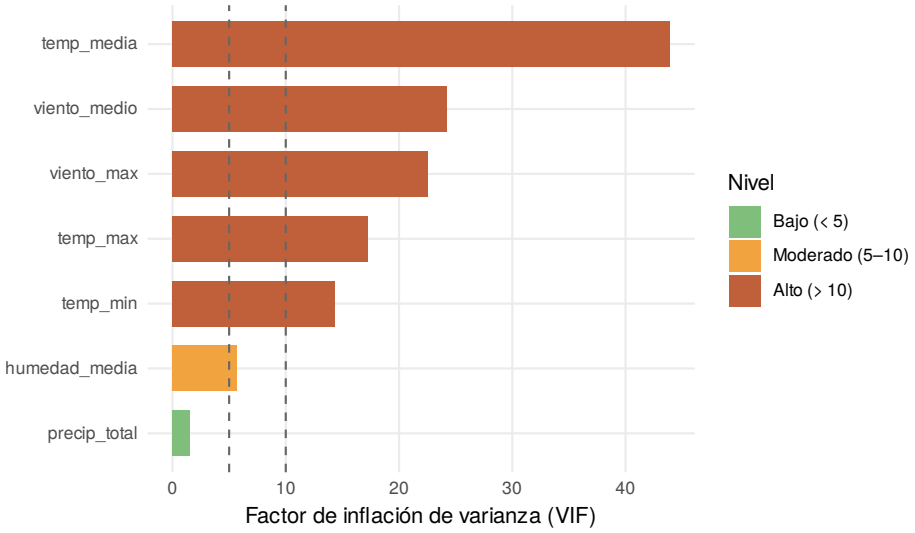


Figura 6.7: Inflación de varianza en el bloque climático (modelo auxiliar `n_eventos` $\sim$ `clima`; D_{mod}).

Tabla 6.11: Inflación de varianza con subconjunto climático reducido propuesto para la Etapa 4

Variable	VIF
`temp_media_semana`	7.21
`humedad_media_semana`	4.47
`viento_medio_semana`	3.27
`precip_total_semana`	1.49

Se realizó adicionalmente un PCA exploratorio del bloque climático como diagnóstico de redundancia (no como fuente de predictoras finales); no se emplea como paso obligatorio del modelado. El detalle completo (variables de entrada, condiciones de aplicación, varianza retenida y cargas) se documenta en el Apéndice A.10.

Agrupamiento jerárquico. El dendrograma de la Figura A.28 confirma dos clusters principales: (i) temperaturas y vientos, altamente intercorrelados; y (ii) `precip_total_semana`, relativamente aislada. Este resultado valida la exclu-

sión de `temp_max_semana`, `temp_min_semana` y `viento_max_semana` del conjunto predictor reducido.

Asociación multivariada clima → `n_eventos`. La correlación parcial de Spearman entre precipitación y `n_eventos`, controlando `temp_media_semana` y `viento_medio_semana`, es $\rho = 0.114$, casi el doble del valor bivariado ($\rho = 0.065$). El aumento al condicionar indica que temperatura y viento, correlacionadas con la precipitación, enmascaraban parcialmente su asociación con los eventos; aun así, la magnitud sigue siendo modesta. Un GLM Poisson exploratorio con el subconjunto reducido (Figura A.29) arroja coeficientes positivos y significativos para las cuatro covariables, con la temperatura media estandarizada ($\hat{\beta} = 0.81$) y el viento medio estandarizado ($\hat{\beta} = 0.73$) como efectos dominantes, seguidos de la humedad ($\hat{\beta} = 0.35$) y de la precipitación en transformación logarítmica desplazada ($\hat{\beta} = 0.13$; todos con $p < 0.001$). Este contraste con el orden bivariado, donde las temperaturas eran irrelevantes, es consistente con la multicolinealidad diagnosticada por el VIF y refuerza que los coeficientes del bloque climático completo no admiten lectura causal individual; se reportan como diagnóstico exploratorio. El supuesto de equidispersión del modelo de Poisson no se cumple: la varianza de `n_eventos` (4.39) casi quintuplica su media (0.92) y el estadístico de dispersión de Pearson es 3.82. Un modelo binomial negativo con las mismas covariables reduce el AIC de 117 787 a 89 960 (razón de verosimilitud = 27 830; $p < 0.001$; $\hat{\theta} = 0.41$) y reproduce la proporción observada de semanas sin eventos (63.2 % frente a 63.0 % observado, contra 43.0 % del Poisson). Los coeficientes apenas cambian (temperatura 0.75, viento 0.70, humedad 0.34 y precipitación 0.14), pero sus errores estándar casi se duplican; todos siguen siendo significativos ($p < 0.001$). La sobredispersión y el exceso de ceros documentados aquí son los que motivan, en la Etapa 5, modelar la magnitud condicional a la ocurrencia de falla y estimar la ocurrencia por separado (Sección 5.4.11).

De forma análoga se aplicó un PCA exploratorio al bloque operativo (frecuencia, afectación y duración) para delimitar dimensiones de impacto, sin emplearlo como fuente de predictoras. El detalle completo se documenta en el Apéndice A.10.

En síntesis, la evaluación multivariada sobre D_{mod} recomienda: (i) predictoras climáticas `precip_total_semana`, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana`, justificadas por loadings, VIF y dendrograma (el PCA no se usa como modelo predictivo, sino como diagnóstico de redundancia); (ii) $SAIFI$ y $SAIDI$ como variables respuesta del modelado, construidas en la Etapa 4; (iii) exclusión de temperaturas extremas y viento máximo por redun-

dancia simultánea; (iv) expectativas moderadas sobre la capacidad explicativa del bloque meteorológico contemporáneo, dado el tamaño reducido de las asociaciones observadas, lo que hace aconsejable complementarlo con rezagos de la propia serie de eventos y con la estratificación territorial; y (v) uso de `usuarios_afectados` solo en el numerador de Y, no como predictora contemporánea. Estos criterios se operacionalizan en la depuración cuantitativa y la construcción de matrices de diseño de la Etapa 4.

6.3.9. Segmentación exploratoria

Con fundamento en la segmentación territorial introducida en la Sección 6.3.6, se profundizó la heterogeneidad de D_{mod} mediante perfiles comparativos por nivel de actividad, evolución 2024–2025, estratificación por régimen de precipitación semanal y clustering multivariado de cuadrantes. El procedimiento reproducible se documenta en el Apéndice A.3.14.

Perfiles por nivel de actividad. Sobre los 344 cuadrantes del periodo, la clasificación Baja/Media/Alta (cuantiles P50 y P85 entre cuadrantes con eventos) arroja: 162 cuadrantes baja (47.1 %), 113 media (32.8 %) y 49 alta (14.2 %); 20 cuadrantes (5.8 %) no registraron eventos. Los perfiles acumulados, resumidos en la Figura A.30, muestran escalamiento marcado en las variables operativas: media de 22 eventos por cuadrante en nivel baja frente a 114.6 en media y 344.7 en alta, con usuarios afectados medios de 1 588 a 88 534. El clima, en cambio, no acompaña ese escalamiento: la precipitación semanal media desciende ligeramente de 19.6 mm (baja) a 18.5 mm (media) y 17.0 mm (alta), de modo que los estratos de mayor actividad no son los más lluviosos. La Figura A.4a confirma que la dispersión semanal de `n_eventos` crece con el estrato territorial.

Evolución 2024 vs 2025 por estrato. El total territorial ascendió de 15 211 eventos en 2024 (287/semana) a 18 199 en 2025 (350/semana). Al desagregar por nivel fijado en el periodo completo, el ratio medio 2025/2024 es homogéneo: 1.24 (baja), 1.26 (media) y 1.24 (alta), lo que indica incremento transversal sin reordenamiento fuerte de la jerarquía territorial (Figura A.31). El crecimiento observado en 2024–2025 debe interpretarse en coherencia con la homogeneización de codificación activo/sitio bajo OMS-SP7 (Sección 6.3.5), no exclusivamente como deterioro operativo.

Régimen climático semanal. Se estratificaron las filas según el percentil 75 de `precip_total_semana` (24.7 mm). Las semanas lluviosas (25 % de las filas; 9 030 observaciones) presentan media de `n_eventos` de 0.918, prácticamente igual a

la de las semanas secas (0.927; 75 %; 27 090 filas), con 37.7 % frente a 36.7 % de semanas con al menos un evento. La prueba de Wilcoxon no detecta diferencia significativa ($p = 0.175$; Figura A.4b), resultado consistente con la débil asociación bivariada precipitación–eventos de la Sección 6.3.7. La dicotomización por umbral resulta así insuficiente para separar regímenes operativos: si la lluvia tiene efecto, opera a través de la intensidad de episodios puntuales y no del acumulado semanal, lo que sugiere explorar en la Etapa 4 indicadores de intensidad diaria o de número de días de lluvia dentro de la semana.

Clustering multivariado de cuadrantes. Se aplicó k-means ($k = 4$) sobre cuadrantes con al menos un evento, con variables estandarizadas de frecuencia, severidad, duración, clima y altitud (Sección 3.1.2; excluyendo covariables de varianza nula). El mapa de la Figura 6.8 y el heatmap de la Figura A.32 distinguen: C3 (1 cuadrante; 2 224 eventos; hub extremo), C1 (139 cuadrantes; media 107.4 eventos; mayor severidad y duración acumulada, altitud media 496 m), C4 (126 cuadrantes; media 97.7 eventos; el estrato de mayor altitud, 1 741 m) y C2 (58 cuadrantes; media 68.0 eventos; el más lluvioso, 26.2 mm semanales, y el de menor duración acumulada). Que el cluster más lluvioso sea también el de menor actividad refuerza que la precipitación no ordena por sí sola el territorio; la altitud y el perfil de severidad discriminan más. La existencia de un hub aislado y de estratos con perfiles distinguibles respalda evaluar modelado global frente a estratificación por cluster en la Etapa 4.
En síntesis, la segmentación exploratoria sobre D_{mod} evidencia: (i) heterogeneidad territorial persistente (14.2 % de cuadrantes en nivel alta concentran actividad desproporcionada); (ii) incremento homogéneo 2024→2025 en todos los estratos; (iii) *ausencia* de diferencia significativa en la frecuencia de interrupciones entre semanas lluviosas y secas cuando la lluvia se mide como acumulado semanal; y (iv) cuatro perfiles espaciales distinguibles por clustering, ordenados principalmente por severidad y altitud más que por régimen de lluvia. Estos criterios orientan la estratificación territorial y la partición entrenamiento/prueba de la Etapa 4.

6.3.10. Resultados y entregables de la etapa

La Etapa 3 sobre D_{mod} (2024–2025; 36 120 filas cuadrante $\times$ semana) produjo un diagnóstico exploratorio integrado: calidad y distribución de variables (Secciones 6.3.1–6.3.4), delimitación temporal y materialización del panel de modelado (Sección 6.3.5), patrones y visualización (Sección 6.3.6), correlación bivariada (Sección 6.3.7), evaluación multivariada con recomendación de predictoras y respuesta (Sección 6.3.8) y segmentación territorial (Sección 6.3.9).

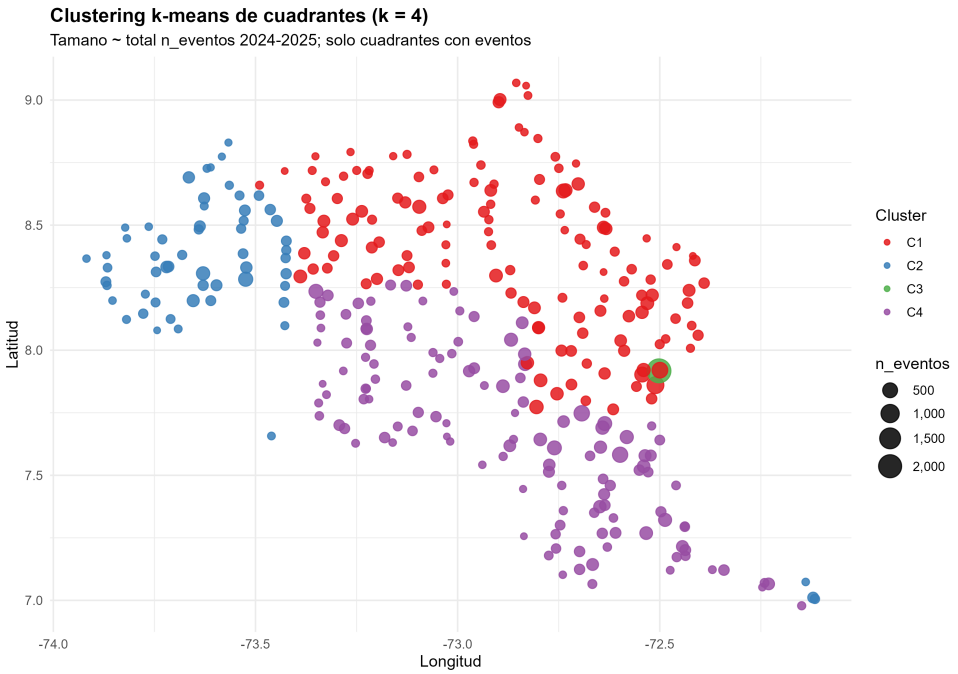


Figura 6.8: Perfiles territoriales de cuadrantes según actividad y clima ($k = 4$; D_{mod}).

Los hallazgos convergentes son: (i) señal climática contemporánea *débil* en el grano semanal (viento por delante de precipitación); (ii) *redundancia* en bloques operativo y climático que justifica subconjuntos reducidos, con la severidad (`usuarios_afectados`, `elementos_afectados`) altamente alineada a `n_eventos` en parte por construcción; (iii) *taxonomía de tres grupos* (Sección 3.1.2): predictoras disponibles *ex ante*, respuestas $SAIFI/SAIDI$, e impacto posterior excluido como predictor contemporáneo; (iv) *heterogeneidad espacial* y clusters territoriales que sugieren estratificación en el modelado; y (v) la necesidad de una *partición temporal estricta*, sin muestreo aleatorio, dentro del periodo de cobertura homogénea del emparejamiento evento–elemento. Los informes HTML reproducibles se consolidan en el Apéndice A.3; el *entregable ejecutivo consolidado* corresponde al Apéndice A.3.15 (síntesis de las Secciones 6.3.1–6.3.10 con hallazgos, figuras representativas y lineamientos para la Etapa 4). La ingeniería de variables de la Etapa 4 operacionaliza esa taxonomía, incluidos rezagos climáticos y operativos y, si procede, la reelaboración de la métrica de severidad solo con fines descriptivos.

Resultado: conocimiento exploratorio del comportamiento de los datos y hallazgos relevantes para el modelado.

Entregable: Documento de análisis descriptivo y exploratorio (EDA), Apéndice A.3.15.

6.3.11. Síntesis de los hallazgos del análisis exploratorio

El diagnóstico de completitud sobre la tabla agregada ($N_{\text{agr}} = 90\,128$) no encontró valores faltantes: las 16 variables registran 0 % de datos ausentes y ninguna fila queda incompleta (Sección 6.3.1; Apéndice A.3.3, informe HTML). Este resultado no debe interpretarse como ausencia de incompletitud en el proyecto, sino como consecuencia del grano de agregación: los valores ausentes del bloque climático y de `ALTITUD` se originan en el panel activo × día y quedan absorbidos por las reglas de resumen semanal, que operan sobre los días efectivamente disponibles de cada cuadrante. La tabla agregada hereda, por tanto, una completitud estructural que no exige imputación en la Etapa 4, pero cuya interpretación requiere conocer el grano en el que se originó la incompletitud.

El análisis de valores extremos (Sección 6.3.2; Apéndice A.3.4, informe HTML) muestra que las variables climáticas diarias tienen baja dispersión relativa (CV entre 0.16 y 0.20) y una proporción marginal de extremos bajo la regla de Tukey, con la precipitación como excepción esperada (CV = 2.12; Tabla 6.2). En los días con evento, la severidad y la continuidad muestran alta dispersión relativa y colas pesadas: la duración de interrupción tiene una mediana de 417 minutos pero un máximo de 332 395 minutos (CV = 3.56), y el número de usuarios afectados una mediana de 23 pero un máximo de 34 622 (CV = 3.97; Tabla 6.3). Estos extremos no se excluyen del modelado, porque corresponden a interrupciones reales y de alto impacto. En la Etapa 5 se documentó su efecto mediante una regla explícita: se marcaron los cuadrantes–semana cuyo indicador supera el percentil 99.5 del entrenamiento (65 casos, el 0.49 % de las semanas con falla) y se reestimó el Random Forest con la respuesta recortada en ese umbral, como análisis de sensibilidad (Sección 6.5.3).

El análisis de correlación identificó redundancia operativa: los pares `usuarios_afectados`–`elementos_afectados` ($\rho = 0.99$), `n_eventos`–`elementos_afectados` ($\rho = 0.98$) y `n_eventos`–`usuarios_afectados` ($\rho = 0.97$) presentan la mayor asociación del panel (Sección 6.3.7; Apéndice A.3.12, informe HTML), en buena parte por construcción compartida desde la misma tabla de eventos. El diagnóstico de multicolinealidad climática (VIF) confirmó inflación severa en el bloque completo de variables meteorológicas (máximo VIF = 43.92 en temperatura media), que se redujo a valores aceptables (máximo 7.21) al restringir el bloque a precipitación, temperatura media, humedad media y viento medio (Sección 6.3.8; Apéndice A.3.13, informe HTML).

Estas dos redundancias tienen orígenes distintos y exigen tratamientos distintos, distinción que resultó determinante para la Etapa 4. La redundancia operativa es *mecánica*: las cuatro métricas provienen de la misma tabla de eventos, comparten la masa de ceros de las semanas sin interrupción y crecen conjun-

tamente con el número de eventos, de modo que su correlación no refleja una relación empírica sino la aritmética de la agregación. La redundancia climática es, en cambio, *física*: temperatura media, máxima y mínima miden el mismo fenómeno térmico con resoluciones distintas, y el viento medio y máximo lo propio con el régimen de viento. La primera se resolvió por decisión de rol —fijar la respuesta en los indicadores construidos y excluir la severidad del conjunto predictor—, mientras que la segunda se resolvió por selección de representantes dentro de cada bloque.

En conjunto, estos hallazgos —señal climática contemporánea débil, redundancia en los bloques operativo y climático, y la taxonomía de tres grupos de variables (predictoras *ex ante*, respuestas y variables de impacto posterior; Sección 3.1.2)— definen los criterios de selección de variables aplicados en la ingeniería de la Etapa 4. En particular, la debilidad de la señal climática contemporánea no condujo a descartar el bloque meteorológico, sino a reformular su forma de entrada: lo que el EDA descarta es la utilidad del clima *simultáneo* como predictor, no la del clima acumulado o rezagado, hipótesis que la Etapa 4 operacionaliza mediante `precip_ma4` y `viento_ma4`. El análisis exploratorio consolidado se documenta en el Apéndice A.3.15 (informe HTML).

6.4. Etapa 4 – Resultados de la ingeniería de variables

El resultado de esta etapa es el panel analítico final de modelado: un conjunto de predictoras restringido a variables disponibles *ex ante* de la semana a pronosticar (clima rezagado, histórico de eventos, características del cuadrante y estacionalidad), con las variables de impacto posterior (`usuarios_afectados`, `elementos_afectados`) excluidas explícitamente como predictoras contemporáneas (Sección 5.2.7). Se incorporaron rezagos espaciales de vecinos (`SAIDI_vecinos_lag1`, `SAIFI_vecinos_lag1`, `ndvi_vecinos`) mediante contigüidad *queen*, y transformaciones logarítmicas $\log(1 + \text{SAIDI})$ y $\log(1 + \text{SAIFI})$ para estabilizar la varianza de las variables respuesta.

El producto concreto de la etapa es la partición del conjunto de columnas del panel en cuatro clases disjuntas (Sección 5.4.9; Tabla 5.11). Las dos **variables respuesta** son SAIDI y SAIFI, estimadas como `log_SAIDI1` y `log_SAIFI1` en modelos independientes. Las **predictoras** quedaron en 18 variables de siete bloques temáticos, todas medidas en la semana anterior o constantes en el tiempo —clima, vegetación, exposición externa, topología de red, composición socioeconómica, activos y mantenimiento, y dinámica temporal y espacial—, seleccionadas desde un conjunto inicial de 44 candidatas disponibles en el panel enriquecido. Las **llaves** (`id_cuadrante`, `semana` y las coordenadas) no actúan co-

mo covariables sustantivas sino como índices de absorción en las especificaciones de efectos fijos y como insumo de la matriz de vecindad. Finalmente, el bloque de **exclusiones deliberadas** comprende las variables de impacto posterior, los insumos contemporáneos de construcción de la respuesta (`n_eventos`$_t$, `duracion_total`$_t$, admitidos solo rezagados) y la respuesta cruzada contemporánea.

Esta última categoría condiciona la lectura de todas las métricas del siguiente apartado: las variables de impacto posterior, en particular `usuarios_afectados`, son las de mayor asociación con ambos indicadores, pero quedan fuera por la razón expuesta en la partición de columnas de la Sección 5.4 (ecuación (5.1)). Las métricas de la Sección 6.5 se obtienen, por tanto, bajo esa restricción de información.

La reducción de 44 a 18 predictoras se obtuvo mediante la secuencia de filtros descrita en la Sección 5.4.3, estimada exclusivamente sobre el conjunto de entrenamiento. En el bloque cuantitativo *ex ante* evaluado de forma independiente sobre D_{mod}, de 27 candidatas se retuvieron 13, con el descarte de las temperaturas por redundancia con el eje térmico ya representado y de los promedios móviles del histórico por multicolinealidad con los rezagos simples. En el bloque cualitativo, la depuración concluyó que la información del estrato predominante municipal ya estaba contenida, con mayor resolución, en las proporciones `prop_estrato_*`, por lo que la matriz final privilegia la representación continua. Ninguna variable fue eliminada del panel: la depuración opera sobre la matriz de diseño, de modo que especificaciones alternativas son reconstruibles sin reejecutar la cadena de integración de las Etapas 1 y 2.

La partición temporal quedó documentada en dos niveles consistentes entre sí: la frontera anual 2024/2025, que coincide con el límite natural de D_{mod}, y el *holdout* del 15 % final de semanas efectivamente aplicado en la estimación, que sobre las 105 semanas disponibles reserva aproximadamente las últimas dieciséis. Ambos esquemas son estrictamente cronológicos; en ningún caso se empleó muestreo aleatorio, dada la autocorrelación de 0.80 en el primer rezago sobre D_{mod}.

Este panel, materializado en `data_final_modelo_cuadrantes_reales.rds`, constituye el insumo directo para el entrenamiento y la validación de los modelos de la Etapa 5. Su construcción y verificación se documentan en los Apéndices A.3.26 (informe HTML), A.3.27 (informe HTML) y A.3.16 (informe HTML).

6.5. Etapa 5 – Resultados del modelado predictivo y evaluativo

Los resultados de esta sección corresponden a la re-estimación final de la Etapa 5 (`Etapa5_09_reestimacion_v3.Rmd`), que sustituye a la re-estimación de cierre de la versión anterior del documento. Respecto de los informes preliminares, la especificación incorpora cinco decisiones: (i) todas las predictoras observadas en la semana s entran rezagadas una semana; (ii) se excluyen las dos variables de activos construidas con fechas posteriores al periodo pronosticado; (iii) los rezagos propio y espacial de la respuesta entran en la escala $\log(1+y)$ de la ecuación (5.4); (iv) todos los modelos se evalúan sobre una muestra común frente a dos pronósticos de referencia; y (v) la inferencia sobre las diferencias de error toma la semana como unidad e incluye intervalos por remuestreo de bloques (Sección 5.5.5). Las variables sísmicas son las reconstruidas tras corregir los dos errores de integración descritos en la Sección 5.2.7.

6.5.1. Dependencia espacial

El diagnóstico de dependencia espacial confirmó autocorrelación positiva y significativa en el promedio por cuadrante tanto de SAIDI (índice de Moran $I = 0.154$; $p < 0.001$) como de SAIFI ($I = 0.179$; $p < 0.001$), y en el corte transversal ponderado ($I = 0.146$ y $I = 0.240$, respectivamente; $p < 0.001$). La magnitud es moderada: la vecindad territorial explica una parte identificable pero no dominante de la variación, lo que justifica incorporar rezagos espaciales y estimar SAR y SEM, sin anticipar que estos dominen a los modelos no espaciales.

6.5.2. Muestra de evaluación

La Tabla 6.12 presenta el flujo de inclusión de la muestra de magnitud. De las $13\,351$ semanas con falla de D_{mod}, $11\,136$ pertenecen al entrenamiento y $2\,215$ al periodo de prueba, comprendido entre el 15 de septiembre y el 29 de diciembre de 2025. El entrenamiento pierde 184 filas por rezagos no definidos en las primeras semanas de cada serie, y la prueba no pierde ninguna. La muestra común de evaluación excluye solo tres observaciones de un cuadrante que no registró fallas en el entrenamiento y para el que, por tanto, ni el efecto fijo ni la media del cuadrante están definidos; todas las métricas de magnitud que siguen se calculan sobre esas mismas $2\,212$ llaves cuadrante–semana. El clasificador de ocurrencia, que solo exige completitud en las variables que utiliza, se evalúa sobre las $5\,504$ semanas del periodo de prueba, con y sin falla.

Tabla 6.12: Flujo de inclusión de la muestra de magnitud (semanas con falla)

	SAIDI		SAIFI	
Paso	**Filas**	**Cuadrantes**	**Filas**	**Cuadrantes**
Filas cuadrante-semana del panel	36 120	344	36 120	344
Semanas con falla	13 351	324	13 351	324
Entrenamiento con falla (hasta el corte)	11 136	323	11 136	323
Entrenamiento con predictoras completas	10 952	323	10 952	323
Prueba con falla (después del corte)	2 215	294	2 215	294
Prueba con predictoras completas	2 215	294	2 215	294
Muestra común (cuadrante visto en entrenamiento)	2 212	293	2 212	293

6.5.3. Pronóstico semanal frente a pronósticos de referencia

Las Tablas 6.13 y 6.14 presentan el desempeño de los modelos de panel y de dos pronósticos de referencia: la *persistencia*, que pronostica para cada cuadrante el valor de su semana anterior, y la *media del cuadrante*, que pronostica su promedio histórico en el entrenamiento. El modelo de efectos fijos de cuadrante y semana no es evaluable fuera de muestra, porque las semanas de prueba no tienen efecto fijo estimado (Sección 5.5.3), y no se incluye en las tablas.

Tabla 6.13: Desempeño en el conjunto de prueba para SAIDI (escala $\log(1+y)$; muestra común, $N = 2\,212$)

Modelo	**RMSE**	**MAE**	r^2	R^2 **predictivo**	**MAE rel. persistencia**	**MASE**
Persistencia ($t-1$)	0.1278	0.0378	0.120	-0.321	1.000	0.995
Media del cuadrante	0.1030	0.0361	0.207	0.142	0.956	0.952
Pooled OLS	0.1012	0.0376	0.209	0.173	0.997	0.992
FE cuadrante	**0.1011**	0.0366	0.225	0.174	0.969	0.964
Random Forest ajustado	0.1108	0.0447	0.200	0.008	1.183	1.177

Tabla 6.14: Desempeño en el conjunto de prueba para SAIFI (escala $\log(1+y)$; muestra común, $N = 2\,212$)

Modelo	**RMSE**	**MAE**	r^2	R^2 **predictivo**	**MAE rel. persistencia**	**MASE**
Persistencia ($t-1$)	0.00324	0.00081	0.085	-0.413	1.000	0.926
Media del cuadrante	**0.00238**	0.00071	0.261	0.240	0.881	0.816
Pooled OLS	0.00243	0.00080	0.221	0.208	0.986	0.913
FE cuadrante	0.00239	0.00073	0.257	0.233	0.907	0.840
Random Forest ajustado	0.00253	0.00092	0.225	0.136	1.143	1.058

Nota: r^2, cuadrado de la correlación de Pearson; R^2 predictivo y MASE según las ecuaciones (3.22) y (3.23); MAE relativo, cociente con el MAE de la persistencia en las mismas observaciones de prueba.

La Tabla 6.15 contrasta las diferencias con la prueba de Diebold–Mariano semanal de la ecuación (5.5) y reporta la mejora porcentual del RMSE con su intervalo por remuestreo de bloques. Tres resultados se desprenden de ella. Primero, los modelos lineales superan con claridad a la persistencia: FE de cuadrante reduce el RMSE en un $20.9\,\%$ en SAIDI y en un $26.3\,\%$ en SAIFI, con intervalos alejados de cero y $p \leq 0.005$. Segundo, no se demostró una mejora sobre la media histórica del cuadrante. En SAIDI, FE de cuadrante reduce el RMSE en un $1.8\,\%$, pero el intervalo incluye el cero (-0.2 a $3.1\,\%$) y la prueba no es significativa al $5\,\%$ ($p = 0.063$); en SAIFI, la media del cuadrante es incluso ligeramente mejor ($0.5\,\%$; $p = 0.30$). Con dieciséis semanas de prueba, esta ausencia de significancia no equivale a que ambos pronósticos sean iguales: indica que, con estos datos y este diseño, la ganancia de FE sobre la media, si existe, es pequeña. Tercero, Random Forest es inferior a FE de cuadrante en ambos indicadores ($9.6\,\%$ y $6.1\,\%$ más RMSE; $p = 0.003$), y su MAE supera incluso al de la persistencia.

Tabla 6.15: Diebold–Mariano semanal y mejora del RMSE con intervalo por remuestreo de bloques de semanas ($T = 16$)

Indicador	Comparación	DM	valor p	Mejora RMSE (%)	IC 95 % (bloques)
SAIDI	RF ajustado vs. FE cuadrante	3.48	0.003	-9.6	$[-22.0;\ -4.4]$
	FE cuadrante vs. persistencia ($t-1$)	-3.33	0.005	20.9	$[15.6;\ 28.5]$
	FE cuadrante vs. media del cuadrante	-2.01	0.063	1.8	$[-0.2;\ 3.1]$
SAIFI	RF ajustado vs. FE cuadrante	3.51	0.003	-6.1	$[-12.4;\ -2.6]$
	FE cuadrante vs. persistencia ($t-1$)	-3.87	0.002	26.3	$[20.5;\ 34.8]$
	FE cuadrante vs. media del cuadrante	1.08	0.296	-0.5	$[-1.0;\ 0.0]$

Nota: un estadístico negativo indica que el primer modelo tiene menor error cuadrático; la mejora es $100\,(1 - \mathrm{RMSE}_A/\mathrm{RMSE}_B)$. Intervalos por remuestreo de bloques móviles de tres semanas (2 000 réplicas).

En la escala original del indicador, con la corrección de *smearing* de Duan, FE de cuadrante obtiene un RMSE de 0.171 en SAIDI frente a 0.203 de la media del cuadrante y un MAE de 0.050 frente a 0.054. En SAIFI, la media del cuadrante conserva una ligera ventaja (0.00242 frente a 0.00243). El factor de corrección es pequeño (1.009 en SAIDI y prácticamente 1 en SAIFI), porque la varianza residual en escala logarítmica es reducida.

La lectura conjunta es consistente: casi toda la capacidad predictiva semanal proviene del *nivel propio de cada cuadrante*. El R^2 predictivo de FE de cuadrante, de 0.17 en SAIDI y 0.23 en SAIFI, es del mismo orden que el de la media del cuadrante (0.14 y 0.24). Una vez conocido el nivel típico de afectación del cuadrante, las variables que cambian de semana a semana —clima rezagado, NDVI y sismicidad— aportan poca información adicional. En SAIDI, los únicos

términos dinámicos con efecto son el rezago propio ($\hat{\gamma} = 0.162$; $p < 0.001$ con errores agrupados por cuadrante y con errores de Driscoll–Kraay) y, con menor solidez, el rezago de los vecinos ($\hat{\phi} = 0.092$; $p = 0.041$ agrupado y $p = 0.053$ Driscoll–Kraay). En SAIFI ningún término dinámico es significativo, y ninguna variable climática, de vegetación o sísmica rezagada lo es en ninguno de los dos indicadores. Todos los contrastes usan errores robustos a heterocedasticidad y a correlación dentro del cuadrante. Los factores de inflación de varianza son altos para el par `prop_estrato_1`–`prop_estrato_2` (25 y 24) y moderados para `n_elementos` y `longitud_red_km` (16 y 15); ninguna variable dinámica tiene un VIF superior a 5, de modo que la colinealidad no explica la ausencia de significancia de las variables semanales.

El bajo desempeño de Random Forest es coherente con lo anterior. La búsqueda de hiperparámetros (Tabla 6.16 y Figura 6.9) seleccionó en ambos indicadores el valor mínimo de `mtry` (2), la configuración más regularizada de la grilla, que es el patrón esperado cuando la señal es débil y el modelo tiende a ajustar ruido.

Tabla 6.16: Ajuste de hiperparámetros del Random Forest: mejores configuraciones según la validación temporal interna

Indicador	`mtry`	Tamaño mínimo de nodo	RMSE validación interna
SAIDI	2	10	0.1250
	2	20	0.1252
	2	5	0.1253
SAIFI	2	20	0.00247
	2	50	0.00249
	4	50	0.00249

Nota: grilla de 6×4 combinaciones (`mtry` $\in \{2, 4, 6, 9, 12, 16\}$; tamaño mínimo de nodo $\in \{5, 10, 20, 50\}$), estimadas con `ranger` (500 árboles) sobre el 85 % inicial de las semanas de entrenamiento y evaluadas en las restantes. El conjunto de prueba no interviene en el ajuste.

La validación de origen móvil (Tabla 6.17) repite la estimación en cuatro cortes, con la selección de hiperparámetros anidada en el pasado de cada uno. La persistencia es el peor pronóstico en los ocho casos. Entre los demás, ningún modelo domina: en SAIDI, Random Forest obtiene el menor error en los dos primeros cortes, la media del cuadrante en el tercero y FE de cuadrante en el cuarto; en SAIFI, Random Forest es mejor en los dos primeros y la media del cuadrante en los dos últimos. Las diferencias entre FE, *Pooled* OLS, Random Forest y la media del cuadrante son pequeñas frente a la variación entre cortes, mientras que la ventaja de todos ellos sobre la persistencia es grande y sistemática. La configuración elegida para el Random Forest también varía entre cortes, lo que confirma que el ajuste de hiperparámetros no encuentra una estructura estable.

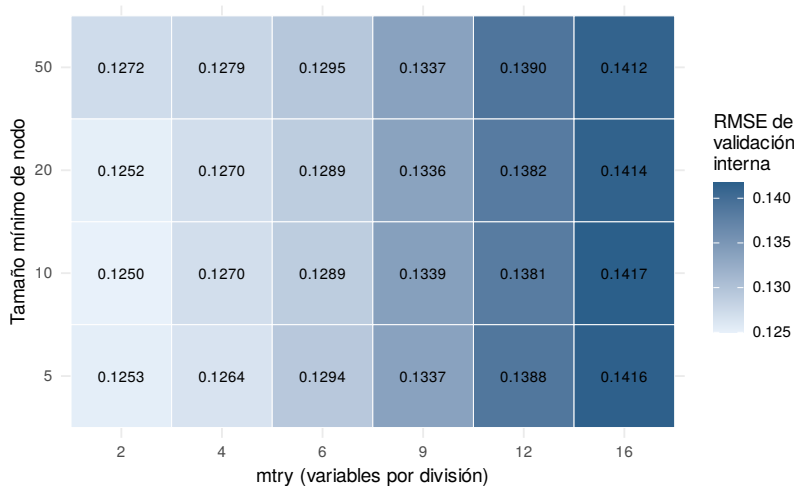


Figura 6.9: RMSE de validación interna del Random Forest de SAIDI según `mtry` y tamaño mínimo de nodo.

Tabla 6.17: Validación de origen móvil: RMSE en las doce semanas siguientes a cada corte (escala $\log(1+y)$)

Ind.	Origen	n entren.	n prueba	`mtry`/ nodo	Persis- tencia	Media del cuadrante	*Pooled* OLS	FE cuadrante	RF ajustado
SAIDI	23/12/2024	5 939	1 337	6/50	0.1026	0.0941	0.0898	0.0906	**0.0875**
	17/03/2025	7 277	1 698	6/50	0.1218	0.1002	0.0958	0.0966	**0.0942**
	09/06/2025	8 978	1 796	16/50	0.1692	**0.1290**	0.1325	0.1293	0.1439
	01/09/2025	10 778	1 874	3/10	0.1331	0.1051	0.1039	**0.1032**	0.1210
SAIFI	23/12/2024	5 939	1 337	3/50	0.00255	0.00214	0.00216	0.00213	**0.00210**
	17/03/2025	7 277	1 698	3/50	0.00341	0.00252	0.00256	0.00251	**0.00249**
	09/06/2025	8 978	1 796	3/50	0.00348	**0.00252**	0.00268	0.00252	0.00253
	01/09/2025	10 778	1 874	3/50	0.00292	**0.00210**	0.00221	0.00211	0.00236

Nota: en cada corte, modelos, media del cuadrante e hiperparámetros del Random Forest se estiman solo con las semanas anteriores; en negrita, el menor RMSE de cada fila.

6.5.4. Pronóstico de la ocurrencia de falla

Los modelos anteriores pronostican la magnitud *condicional* a que ocurra al menos una falla. Para completar el esquema en dos partes señalado en la Sección 5.4.11, se estimó un clasificador Random Forest de la ocurrencia de falla (`hubo_falla`) sobre el panel completo, con las mismas predictoras *ex ante* más el indicador de falla de la semana anterior. La Tabla 6.18 lo compara con tres referencias. En el periodo de prueba, en el que el $40.2\,\%$ de las semanas–cuadrante registró al menos una falla, el clasificador alcanza un AUC de 0.835 y un AUC de precisión–exhaustividad de 0.773, muy por encima de la persistencia (0.721). Sin embargo, la tasa histórica de falla de cada cuadrante en el entrenamiento, que no usa ninguna variable semanal, discrimina ligeramente mejor (AUC de 0.845) y está mejor calibrada (Brier de 0.158 frente a 0.162); la diferencia de AUC es pequeña pero su intervalo excluye el cero (-0.027 a -0.002). El Random Forest supera, en cambio, a la regresión logística con las mismas predictoras.

Tabla 6.18: Ocurrencia de falla en el periodo de prueba: discriminación, calibración y comparación con referencias ($N = 5\,504$)

Modelo	AUC	AUC-PR	Brier	Log-loss
Random Forest	0.835	0.773	0.1621	0.4886
Regresión logística	0.822	0.747	0.1712	0.5122
Tasa histórica del cuadrante	0.845	0.781	0.1576	0.4763
Persistencia ($t-1$)	0.721	0.651	0.2727	2.5118
Diferencias con IC del 95 % por remuestreo de bloques de semanas				
Comparación	**ΔAUC**		**ΔBrier**	
Random Forest vs. tasa histórica del cuadrante	-0.010 $[-0.027;\ -0.002]$		0.0045 $[0.0001;\ 0.0134]$	
Regresión logística vs. tasa histórica del cuadrante	-0.024 $[-0.042;\ -0.017]$		0.0136 $[0.0095;\ 0.0205]$	
Random Forest vs. regresión logística	0.014 $[0.006;\ 0.022]$		-0.0091 $[-0.0131;\ -0.0052]$	

Las probabilidades del clasificador están razonablemente calibradas (Figura 6.10): en el decil de mayor probabilidad la tasa observada de falla es del $90.6\,\%$, para una probabilidad media pronosticada del $86.4\,\%$, y en el decil más bajo es del $2.2\,\%$, con ligera subestimación en los deciles altos. La utilidad operativa se evaluó como lo haría una cuadrilla con capacidad fija (Tabla 6.19): si cada semana se atendieran los diez cuadrantes de mayor probabilidad, el $92.5\,\%$ de ellos habría registrado efectivamente una falla y se habría cubierto el $37.6\,\%$ del SAIDI semanal; con la tasa histórica, el $97.5\,\%$ y el $36.5\,\%$, respectivamente. Con treinta cuadrantes, las cuatro reglas capturan entre el 53 y el $56\,\%$ del SAIDI semanal.

La ocurrencia de falla es, por tanto, pronosticable con una precisión útil, pero esa capacidad proviene casi por completo de la propensión histórica de cada cuadrante: las variables semanales no mejoran el orden que ya ofrece la tasa histórica. La probabilidad semanal sirve para ordenar los cuadrantes según su

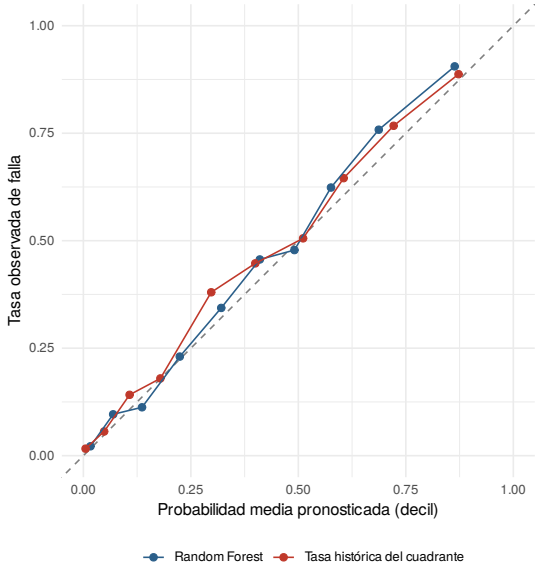


Figura 6.10: Confiabilidad de la probabilidad semanal de falla por decil en el periodo de prueba: Random Forest y tasa histórica del cuadrante.

Tabla 6.19: Captura semanal entre los k cuadrantes de mayor probabilidad de falla (promedio de las 16 semanas de prueba)

k	**Criterio de orden**	**Precisión (%)**	**SAIDI capturado (%)**	**SAIFI capturado (%)**
10	Random Forest	92.5	37.6	37.6
	Regresión logística	93.8	37.1	36.2
	Tasa histórica del cuadrante	97.5	36.5	34.4
	Persistencia ($t-1$)	96.9	36.5	34.2
30	Random Forest	88.8	52.9	53.4
	Regresión logística	86.0	55.4	56.1
	Tasa histórica del cuadrante	89.4	55.9	56.9
	Persistencia ($t-1$)	89.0	54.4	57.1

riesgo de falla la semana siguiente, y el valor añadido del clasificador sobre una regla histórica simple no quedó demostrado.

La Tabla 6.20 evalúa la combinación de ambos componentes (ecuación (5.7)) sobre las $5\,504$ observaciones del periodo de prueba, con y sin falla, en la escala original del indicador. En SAIDI, el pronóstico de dos partes redujo el RMSE en un $15.8\,\%$ frente al promedio histórico del cuadrante (intervalo de 7.2 a $28.8\,\%$; $p < 0.001$) y en un $24.8\,\%$ frente a la persistencia ($p = 0.008$). En SAIFI superó a la persistencia ($p < 0.001$), pero no se demostró una mejora sobre el promedio del cuadrante ($0.2\,\%$; $p = 0.77$). El modelo Tweedie de un solo paso mejora a ambas referencias en SAIDI, pero no al pronóstico de dos partes.

Tabla 6.20: Pronóstico incondicional de la afectación semanal sobre todas las semanas de prueba (escala original; $N = 5\,504$)

Indicador	Modelo	RMSE	MAE	Spearman
SAIDI	Cero	0.1194	0.0153	–
	Persistencia	0.1439	0.0228	0.523
	Media del cuadrante	0.1285	0.0222	0.584
	Dos partes (RF × FE, Duan)	**0.1081**	0.0197	0.527
	Tweedie	0.1155	0.0201	0.451
SAIFI	Cero	0.00180	0.00025	–
	Persistencia	0.00215	0.00036	0.511
	Media del cuadrante	0.00155	0.00031	0.571
	Dos partes (RF × FE, Duan)	**0.00154**	0.00030	0.435
	Tweedie	0.00170	0.00033	0.423

Indicador	Comparación	DM	valor p	Mejora RMSE (%)	IC 95 % (bloques)
SAIDI	Dos partes vs. media del cuadrante	-4.59	< 0.001	15.8	$[7.2;\ 28.8]$
	Dos partes vs. persistencia	-3.06	0.008	24.8	$[15.7;\ 36.7]$
SAIFI	Dos partes vs. media del cuadrante	-0.30	0.768	0.2	$[-0.8;\ 1.4]$
	Dos partes vs. persistencia	-4.61	< 0.001	28.3	$[21.2;\ 38.3]$

Nota: el pronóstico "Cero" asigna afectación nula a todas las semanas. Potencia del modelo Tweedie elegida en las últimas doce semanas del entrenamiento (1.2). Diebold–Mariano semanal e intervalos por remuestreo de bloques como en la Tabla 6.15.

Este resultado matiza la conclusión obtenida para la magnitud condicional, y su lectura requiere una precaución. La ventaja se concentra en el error cuadrático, que pondera las semanas de mayor afectación: en el error absoluto el mejor pronóstico es el trivial de afectación nula, porque el $60\,\%$ de las semanas de prueba no registra fallas y el MAE premia a la mediana. El pronóstico de dos partes también reduce el RMSE del pronóstico nulo en un $9.5\,\%$. La ganancia proviene del componente de ocurrencia —cuándo es esperable que el cuadrante se aparte de su nivel habitual—, mientras que la magnitud de la afectación, una

vez ocurre la falla, sigue sin ser anticipable con la información disponible.

6.5.5. Sensibilidad al clima extremo

La Tabla 6.21 compara la especificación *ex ante* de referencia con la que añade los seis indicadores de clima extremo descritos en la Sección 5.4.1. En la magnitud semanal, los indicadores no modificaron el error de prueba de los efectos fijos de cuadrante y no resultaron conjuntamente significativos en ninguno de los dos indicadores (prueba de Wald con errores agrupados por cuadrante, $p = 0.52$ en SAIDI y $p = 0.97$ en SAIFI). En la ocurrencia de falla, su inclusión elevó el AUC del clasificador de 0.836 a 0.838, una mejora mínima aunque estadísticamente significativa según la prueba de DeLong ($p = 0.025$).

Tabla 6.21: Efecto de incorporar indicadores de clima extremo rezagados a la especificación *ex ante*

Componente	Métrica	Referencia	Con clima extremo	Contraste
Magnitud SAIDI	RMSE de prueba (FE cuadrante)	0.1011	0.1011	Wald $p = 0.52$
Magnitud SAIFI	RMSE de prueba (FE cuadrante)	0.00239	0.00239	Wald $p = 0.97$
Ocurrencia	AUC de prueba (Random Forest)	0.836	0.838	DeLong $p = 0.025$

Nota: la referencia de ocurrencia se reestimó sobre la misma muestra que el modelo ampliado, por lo que su AUC difiere en la tercera cifra decimal del reportado en la Tabla 6.18.

El sentido de los efectos sobre la ocurrencia matiza la lectura. En un modelo logit con errores agrupados, las semanas precedidas por días de calor o de viento extremos mostraron una menor probabilidad de falla (razones de odds de 0.83 y 0.90 por día extremo, $p < 0.001$), lo que sugiere que estos indicadores capturan sobre todo el régimen estacional seco, en el que las fallas son menos frecuentes, y no un efecto mecánico directo. La precipitación solo mostró una asociación positiva en la misma semana: cada milímetro adicional de lluvia en el día más lluvioso de la semana se asoció con un aumento de cerca del $1.2\,\%$ en las odds de falla ($p = 0.001$), equivalente a un $43\,\%$ para un día de 30 mm. Con una semana de anticipación la asociación es débil y de signo contrario (razón de odds de 0.99; $p = 0.02$).

En conjunto, el clima extremo no altera la conclusión sobre la magnitud semanal, pero indica que la lluvia intensa influye en la ocurrencia de fallas a una escala de días que la información de la semana anterior no anticipa. Su aprovechamiento operativo requeriría incorporar pronósticos meteorológicos de corto plazo, una extensión que se retoma en el Capítulo 7.

6.5.6. Explicación estructural en corte transversal

Para la explicación del patrón territorial se agregó cada indicador como promedio ponderado por cuadrante a lo largo de 2024–2025 ($N = 344$ cuadrantes) y se estimaron OLS, SAR y SEM con diez predictoras estructurales y de expo-

sición. La Tabla 6.22 resume la comparación. Para SAIDI, SAR mejora el AIC del OLS en 38 unidades, con un parámetro $\hat{\rho} = -0.32$ ($p < 0.001$). Para SAIFI, ni la especificación de rezago ni la de error mejoran al OLS: el AIC de SEM es prácticamente igual al del OLS y $\hat{\lambda} = -0.14$ no es significativo ($p = 0.16$).

Tabla 6.22: Modelos de corte transversal ($N = 344$): comparación OLS, SAR y SEM y validación espacial

	SAIDI	**SAIFI**
AIC OLS	-1238.1	$\mathbf{-4278.1}$
AIC SAR	$\mathbf{-1275.8}$	-4276.1
AIC SEM	-1236.4	-4278.1
$\hat{\rho}$ (SAR)	-0.322 ($p < 0.001$)	-0.002 ($p = 0.971$)
$\hat{\lambda}$ (SEM)	0.071 ($p = 0.547$)	-0.145 ($p = 0.159$)
R^2 OLS completo (en muestra)	0.890	0.836
R^2 OLS *stepwise* (en muestra)	0.889	0.835
R^2 de validación cruzada espacial (5 franjas de latitud)		
OLS *stepwise* (selección dentro de cada franja)	0.397	0.751
OLS completo	0.396	0.741
SAR (forma reducida)	0.389	0.732
SEM (tendencia)	0.390	0.742
Permutación con selección repetida (valor p)	0.005	0.005

Nota: la permutación repite la selección *stepwise* en cada una de las 200 réplicas; ninguna alcanzó el R^2 observado, de modo que el valor p es la cota $1/201$.

El signo negativo de $\hat{\rho}$ en SAIDI requiere interpretación, porque el índice de Moran de la respuesta es positivo. Las dos afirmaciones son compatibles: los cuadrantes vecinos se parecen entre sí principalmente porque comparten infraestructura y exposición, y una vez que las covariables absorben esa similitud, el remanente espacial es negativo. Una explicación plausible, no verificada con los datos disponibles, es la forma en que se asignan los eventos: cada interrupción se atribuye íntegramente al cuadrante del elemento fallado, aunque sus usuarios afectados se distribuyan sobre cuadrantes vecinos del mismo circuito, lo que concentra la afectación en un cuadrante y la sustrae de los adyacentes.

El resultado de SAIDI no depende de la matriz de vecindad elegida (Tabla 6.23): con las ocho definiciones de $\mathbf{W}$ descritas en la Sección 5.5.8, el AIC prefirió SAR y $\hat{\rho}$ fue negativo y significativo en todas (entre -0.22 y -0.37, $p < 0.001$). En SAIFI, el OLS es preferido con cinco matrices y SEM con tres, y $\hat{\lambda}$ es negativo pero no significativo al $5\,\%$ con ninguna, de modo que no hay evidencia de dependencia espacial residual una vez controlada la estructura del cuadrante.

El ajuste dentro de muestra es alto ($R^2 = 0.89$ para SAIDI y 0.84 para SAIFI) y significativo frente a la prueba de permutación, aun cuando esta repite la selección de variables en cada réplica. Al predecir cada franja de cuadrantes con un modelo cuya selección y estimación usan solo las otras franjas, el R^2

Tabla 6.23: Sensibilidad de los modelos espaciales de corte transversal a la matriz de vecindad

	SAIDI		SAIFI	
Matriz de vecindad	**Preferido (AIC)**	**$\hat{\rho}$ (SAR)**	**Preferido (AIC)**	**$\hat{\lambda}$ (SEM)**
Contigüidad tipo reina (referencia)	SAR	-0.32^{***}	OLS	-0.14
Contigüidad tipo torre	SAR	-0.28^{***}	OLS	-0.10
4 vecinos más cercanos	SAR	-0.32^{***}	SEM	-0.13
6 vecinos más cercanos	SAR	-0.22^{***}	SEM	$-0.20^{\cdot}$
8 vecinos más cercanos	SAR	-0.28^{***}	SEM	-0.19
Banda de distancia mínima	SAR	-0.32^{***}	OLS	-0.14
Banda de $1.5\times$ la distancia mínima	SAR	-0.31^{***}	OLS	-0.11
Inverso de la distancia	SAR	-0.37^{***}	OLS	-0.12

Nota: todas las matrices normalizadas por filas. *** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$; $^{\cdot}$ $p < 0.10$.

desciende a 0.40 para SAIDI y se mantiene en 0.75 para SAIFI. Los modelos espaciales no mejoran esa capacidad de transferencia: SAR y SEM, evaluados sin usar las respuestas de la franja retenida, alcanzan R^2 de 0.39 en SAIDI y de 0.73–0.74 en SAIFI. El patrón territorial de SAIFI es, por tanto, transferible entre zonas; el de SAIDI lo es solo en parte, lo que es coherente con que la duración dependa además de factores locales de accesibilidad y capacidad de respuesta que el modelo no observa. La preferencia de SAR en SAIDI mejora la descripción de los datos observados, pero no la predicción de zonas nuevas. Las Tablas 6.24 y 6.25 presentan los coeficientes del modelo OLS completo, cuyos valores p no están afectados por la selección, e indican qué variables retiene la selección paso a paso.

Tabla 6.24: Corte transversal de SAIDI promedio por cuadrante, OLS completo ($N = 344$; $R^2 = 0.890$)

Predictor	**Coeficiente**	**valor p**	**Retenido (*stepwise*)**
n_elementos	4.42×10^{-4}	< 0.001	Sí
prop_transformadores	1.37×10^{-2}	0.367	No
longitud_red_km	-9.65×10^{-4}	< 0.001	Sí
densidad_terminales	2.37×10^{-3}	0.413	No
prop_estrato_1	1.98×10^{-2}	0.306	No
prop_estrato_2	3.01×10^{-2}	0.125	Sí
prop_no_residencial	-9.04×10^{-2}	0.171	Sí
ndvi_promedio	8.70×10^{-2}	0.003	Sí
dist_sismo_prom_km	2.01×10^{-4}	0.559	No
precip_promedio	2.06×10^{-4}	0.725	No

Tabla 6.25: Corte transversal de SAIFI promedio por cuadrante, OLS completo ($N = 344$; $R^2 = 0.836$)

Predictor	Coeficiente	valor p	Retenido (*stepwise*)
n_elementos	3.59×10^{-6}	< 0.001	Sí
prop_transformadores	8.92×10^{-5}	0.626	No
longitud_red_km	-3.73×10^{-6}	0.059	Sí
densidad_terminales	-9.52×10^{-6}	0.785	No
prop_estrato_1	-9.48×10^{-6}	0.968	No
prop_estrato_2	-2.73×10^{-5}	0.908	No
prop_no_residencial	-8.09×10^{-4}	0.309	No
ndvi_promedio	1.52×10^{-5}	0.965	No
dist_sismo_prom_km	7.09×10^{-6}	0.087	Sí
precip_promedio	1.31×10^{-6}	0.852	No

6.5.7. Descomposición territorial del SAIDI

La aproximación de la ecuación (5.6) reproduce el ordenamiento del SAIDI acumulado en los 324 cuadrantes con al menos un evento (correlación de Spearman de 0.97). Las diferencias territoriales del indicador se explican por la frecuencia de los eventos (55.0 %) y por el número de usuarios que alcanza cada evento (50.0 %), mientras que la duración por evento no contribuye a ellas (-4.9 %): los cuadrantes con mayor SAIDI no son aquellos en los que las interrupciones duran más, sino aquellos en los que ocurren más interrupciones y cada una afecta a más usuarios.

Tabla 6.26: Correlación de Spearman entre los factores estructurales del cuadrante y los componentes del SAIDI

Factor	SAIDI acumulado	Frecuencia	Duración por evento	Usuarios por evento
Número de elementos	$+0.80^{***}$	$+0.83^{***}$	-0.25^{***}	$+0.62^{***}$
Longitud de la red	$+0.77^{***}$	$+0.79^{***}$	-0.17^{**}	$+0.56^{***}$
Usuarios del cuadrante	$+0.83^{***}$	$+0.84^{***}$	-0.34^{***}	$+0.70^{***}$
Densidad de nodos terminales	$+0.04$	$+0.06$	$+0.19^{***}$	-0.09
NDVI medio	$+0.05$	$+0.02$	$+0.24^{***}$	-0.04
Proporción no residencial	$+0.22^{***}$	$+0.29^{***}$	-0.22^{***}	$+0.20^{***}$
Proporción de estrato 1	-0.26^{***}	-0.31^{***}	$+0.23^{***}$	-0.22^{***}

Nota: 324 cuadrantes con al menos un evento en 2024–2025. *** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$.

La Tabla 6.26 muestra que los factores actúan sobre componentes distintos. La escala del cuadrante (número de elementos, longitud de la red y usuarios) se asocia con más eventos y con un mayor alcance de cada uno, pero con una duración por evento menor, lo que es coherente con una atención más rápida en las zonas urbanas y densas. La vegetación, en cambio, no se relaciona con la frecuencia ni con el alcance, sino con la duración: los cuadrantes con mayor NDVI registran eventos más largos ($\rho_S = 0.24$). Este resultado ofrece un mecanismo para el hallazgo de la Sección 6.5.6, en la que el NDVI resultó relevante para

SAIDI pero no para SAIFI: en las zonas más vegetadas la reposición tarda más, probablemente por las condiciones de acceso y por la naturaleza de las fallas asociadas a la vegetación. Un patrón análogo se observa en la proporción de usuarios de estrato 1, asociada con menos eventos pero más largos.

Desde la perspectiva de la gestión, la descomposición sugiere hipótesis sobre el tipo de intervención según el componente que domina en cada zona: la frecuencia se asocia con el mantenimiento preventivo y la poda; el alcance por evento, con el seccionamiento y la topología de la red; y la duración, con la logística de atención y la accesibilidad de los cuadrantes rurales y vegetados. Al tratarse de asociaciones observacionales, estas hipótesis deben contrastarse con el historial de intervenciones antes de atribuirles un efecto.

6.5.8. Variables más relevantes: triangulación entre modelos

La Tabla 6.27 reúne, para cada variable, la evidencia de las tres fuentes previstas en la Sección 5.5.11: la importancia por permutación del Random Forest ajustado (Figuras 6.11 y 6.12), los coeficientes del modelo FE del panel semanal y los del corte transversal. Las tres fuentes responden a preguntas y escalas distintas —contribución predictiva semanal, efecto dentro del cuadrante a lo largo del tiempo y asociación entre cuadrantes—, y las variables constantes en el tiempo no se identifican en el modelo FE. Por ello la tabla no suma evidencia de un mismo efecto, sino que indica en qué escala aparece cada variable. Una variable se considera relevante si aparece en al menos dos de ellas: entre las seis primeras por importancia en el Random Forest, con coeficiente significativo al $5\,\%$ en el modelo FE, o significativa al $5\,\%$ en el corte transversal.

La convergencia se limita a las variables de *tamaño y forma de la red*: el número de elementos y la longitud de red son las dos primeras en importancia en ambos Random Forest y las más significativas en ambos cortes transversales. Para SAIDI se suma la vegetación (NDVI). Las variables que cambian de semana a semana (clima, NDVI y sismicidad rezagados) no resultan significativas en ningún modelo de panel, lo que es coherente con la escasa ganancia de los modelos sobre la media del cuadrante. Las proporciones de estrato ocupan posiciones altas en el Random Forest pero no son significativas en los modelos lineales; como son atributos fijos de cada cuadrante, es probable que el bosque las use como identificadores del cuadrante, es decir, como sustituto del efecto fijo, más que como un efecto socioeconómico propiamente dicho.

El coeficiente negativo de `longitud_red_km` merece comentario, porque podría leerse como contraintuitivo: una red más extensa expone más activos a falla. Condicionada al número de elementos, la longitud deja de medir exposición y pasa a aproximar el carácter rural y disperso del cuadrante: a igual número de

Tabla 6.27: Triangulación de la relevancia de las variables entre modelos

	RF (rango)		FE semanal		Corte transversal		
Variable	SAIDI	SAIFI	SAIDI	SAIFI	SAIDI	SAIFI	**Veredicto**
`n_elementos`	2	2	abs.	abs.	$+^{***}$	$+^{***}$	Relevante
`longitud_red_km`	1	1	abs.	abs.	$-^{***}$	$-^{\cdot}$	Relevante
`prop_estrato_1, _2`	3–4	3–4	n.s.	n.s.	n.s.	n.s.	Solo RF
`prop_no_residencial`	7	8	n.s.	n.s.	n.s.	n.s.	No relevante
`ndvi` (propio y vecinos)	5–6	7–9	n.s.	n.s.	$+^{**}$	n.s.	Relevante (SAIDI)
Exposición sísmica	15–16	13–16	n.s.	n.s.	n.s.	$+^{\cdot}$	No relevante
Clima rezagado	8–14	6–15	n.s.	n.s.	n.s.	n.s.	No relevante
Rezago propio ($t-1$)	11	12	$+^{***}$	n.s.	–	–	Solo SAIDI semanal
Rezago de vecinos ($t-1$)	13	5	$+^{*}$	n.s.	–	–	Débil

Nota: rango de importancia por permutación entre 16 predictoras. FE semanal con errores agrupados por cuadrante; "abs.": variable constante en el tiempo, absorbida por el efecto fijo. Corte transversal: OLS completo (Tablas 6.24 y 6.25); en el corte transversal el NDVI, la precipitación y la sismicidad entran como promedios del periodo. *** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$; $^{\cdot}$ $p < 0.10$; n.s.: no significativa.

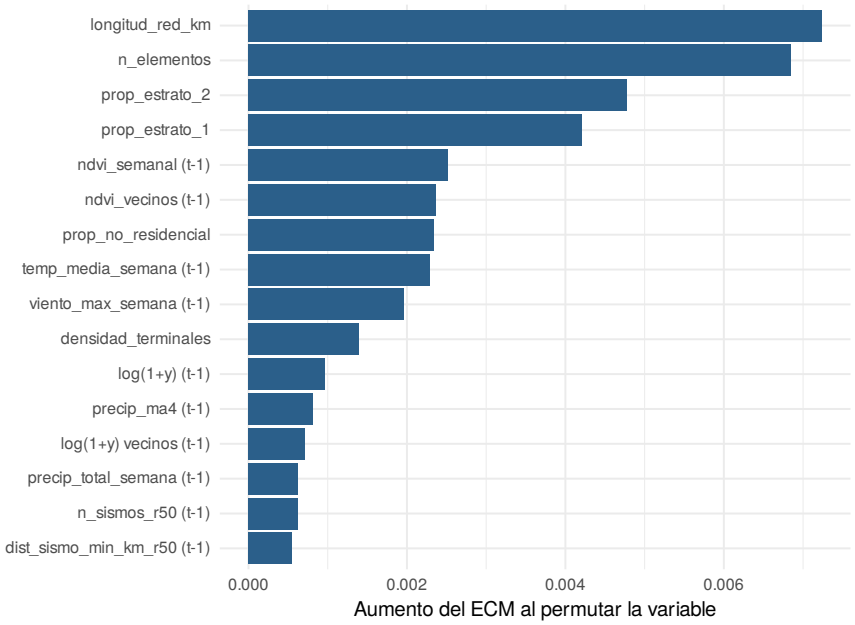


Figura 6.11: Importancia por permutación de las predictoras en el Random Forest ajustado de SAIDI.

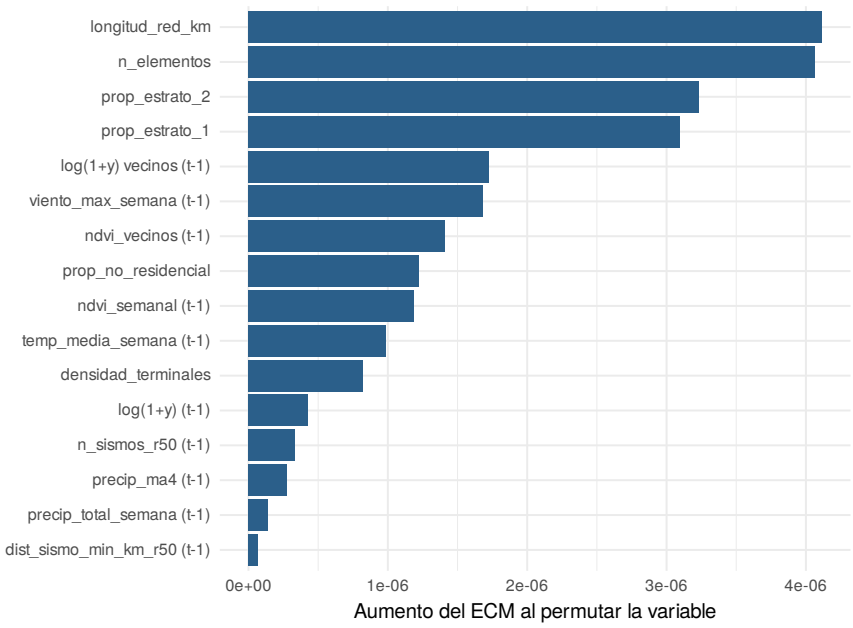


Figura 6.12: Importancia por permutación de las predictoras en el Random Forest ajustado de SAIFI.

activos, mayor longitud implica menor densidad de usuarios y, por tanto, menor contribución a un indicador ponderado por usuarios afectados. Esta lectura es una hipótesis que los datos no permiten verificar, y el signo no justifica reducir la red como intervención. La antigüedad de los activos, que en la versión anterior del análisis aparecía con signo negativo, ya no se incluye: las fechas de modificación con que se calculaba son en su mayoría de 2026, posteriores al periodo de estudio, y no permiten medir el envejecimiento de la red.

Las Figuras 6.13 y 6.14 contrastan los valores observados y pronosticados por FE de cuadrante en el conjunto de prueba. La nube se concentra en una banda estrecha de valores pronosticados para cada cuadrante, mientras los valores observados se dispersan en todo el rango: es la expresión gráfica de que el modelo anticipa el nivel del cuadrante, pero no la magnitud de la semana concreta.

6.5.9. Validación fuera de muestra de la priorización territorial

La Tabla 6.28 y la Figura 6.15 presentan la curva de captura definida en la ecuación (5.8). El orden construido con la afectación de 2024 se aproxima estrechamente al orden óptimo de 2025. Los diez cuadrantes con mayor afectación en 2024 concentraron el $59.6\,\%$ del SAIDI y el $53.2\,\%$ del SAIFI operativos de 2025, frente a un máximo alcanzable de $61.7\,\%$ y $54.6\,\%$, respectivamente, y frente al $2.9\,\%$ esperado bajo una selección aleatoria. Con treinta cuadrantes, que representan el $8.7\,\%$ del territorio, el orden histórico capturó el $78.5\,\%$ del SAIDI y el

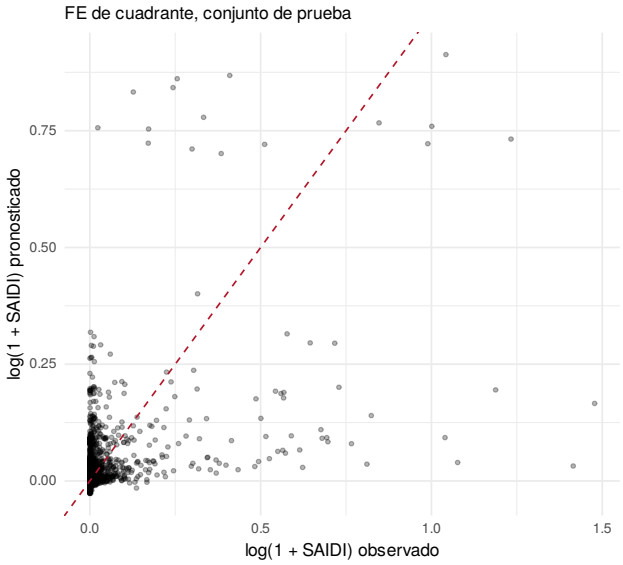


Figura 6.13: SAIDI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1+y)$).

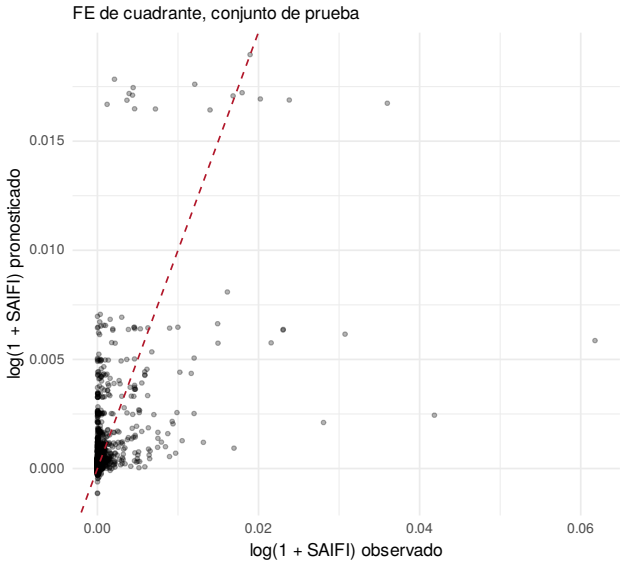


Figura 6.14: SAIFI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1+y)$).

71.7 % del SAIFI.

Tabla 6.28: Proporción de la afectación de 2025 capturada por los k primeros cuadrantes, según el criterio de priorización (%)

Indicador	k	Orden 2024	Usuarios del cuadrante	Orden óptimo 2025	Selección aleatoria
SAIDI	10	59.6	52.2	61.7	2.9
	20	67.3	59.4	74.9	5.8
	30	78.5	66.1	82.7	8.7
	47	85.4	74.4	88.9	13.7
SAIFI	10	53.2	44.2	54.6	2.9
	20	64.9	52.6	69.0	5.8
	30	71.7	57.7	76.8	8.7
	47	79.7	66.2	84.5	13.7

Nota: $k = 47$ corresponde al número de cuadrantes clasificados en prioridad A y B. El orden óptimo se construye con los valores observados de 2025 y constituye una cota superior no alcanzable *ex ante*.

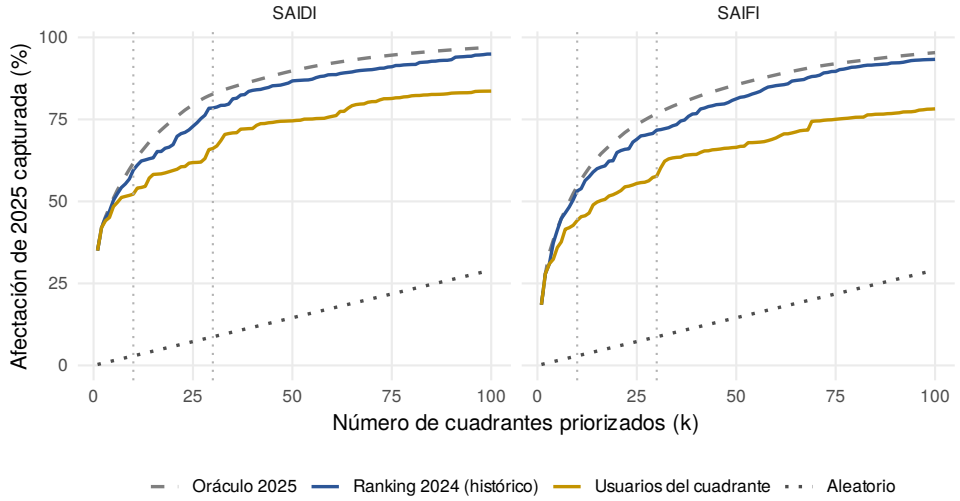


Figura 6.15: Curva de captura de la afectación de 2025 según el criterio de priorización, para los primeros cien cuadrantes. Las líneas verticales punteadas señalan $k = 10$ y $k = 30$.

La historia de interrupciones aportó información que la sola escala del cuadrante no contiene. El orden por número de usuarios capturó entre 7 y 14 puntos porcentuales menos que el orden histórico en todos los cortes considerados, lo que indica que la concentración de la afectación no se explica únicamente por el tamaño de la población atendida. La persistencia del orden se refleja también en la correlación de Spearman entre los totales de 2024 y de 2025, de 0.93 para SAIDI y de 0.95 para SAIFI.

El conjunto de cuadrantes prioritarios resultó, además, estable frente a la variación semanal. En el *bootstrap* sobre las semanas de 2024, los cuadrantes 117,

107 y 296 permanecieron entre los diez primeros de SAIDI en más del 98 % de las réplicas, y el índice de Jaccard medio entre el conjunto remuestreado y el original fue de 0.66 para SAIDI y de 0.78 para SAIFI. Las sustituciones se concentraron en las últimas posiciones de la lista, lo que sugiere revisar anualmente el límite de la prioridad A, pero no su núcleo. Dos precisiones delimitan este resultado. La concentración depende de la construcción del indicador: con el SAIDI reconstruido evento a evento, los diez primeros cuadrantes de 2024 capturan el 32.4 % del SAIDI de 2025, frente a un óptimo del 35.7 % (Apéndice A.5). Y la captura mide la capacidad del orden para anticipar dónde se concentrará la afectación, no el beneficio de intervenir esos cuadrantes, que requiere una evaluación operativa.

En síntesis, **para la magnitud de la afectación condicional a la falla, FE de cuadrante es el modelo de menor error en SAIDI y la media histórica del cuadrante en SAIFI**; ambos superan a la persistencia y a Random Forest, pero no se demostró que FE mejore el promedio histórico de cada cuadrante. **La ocurrencia de falla sí es pronosticable** (AUC de 0.84), aunque esa capacidad proviene de la propensión histórica del cuadrante más que de las variables semanales, y su combinación con la magnitud produce un pronóstico incondicional que mejora al promedio del cuadrante en SAIDI. **Para la explicación del patrón territorial, SAR es el modelo preferido en SAIDI con todas las matrices de vecindad, y OLS en SAIFI**; el ajuste está dominado por la escala de la red, que actúa sobre la frecuencia y el alcance de los eventos, mientras que la vegetación actúa sobre su duración. Finalmente, **la priorización territorial construida con un año anticipa la afectación del año siguiente** con una captura cercana a la óptima, cuya magnitud depende de la construcción del indicador.

6.6. Etapa 6 – Síntesis general y cierre frente a los objetivos

El proyecto recorrió las seis etapas metodológicas descritas en el Capítulo 5 y produjo, de forma trazable y reproducible, un flujo completo desde la extracción de datos crudos hasta modelos predictivos y estructurales validados para SAIDI y SAIFI. La Tabla 6.29 resume el resultado principal de cada etapa.

La Tabla 6.30 articula estos resultados con los tres objetivos específicos del proyecto (Sección 2), evidenciando su cumplimiento.

Tabla 6.29: Síntesis de resultados por etapa metodológica

Etapa	Resultado principal
Etapa 1	Seis fuentes consolidadas (BRAE, OMS SPARD/SP7, GIS, NASA POWER); $95\,280$ eventos depurados y 83.5 millones de registros climáticos.
Etapa 2	Panel activo–día ($N = 87\,007\,074$) y panel cuadrante–semana ($N_{\text{agr}} = 90\,128$); detección de un sesgo sistemático de emparejamiento 2021–2023 que delimitó el conjunto de modelado D_{mod} (2024–2025).
Etapa 3	Sin datos faltantes en la tabla agregada; redundancia identificada entre severidad y frecuencia; señal climática contemporánea débil; multicolinealidad climática corregida (VIF máximo de 43.92 a 7.21).
Etapa 4	Panel analítico final con partición explícita de columnas: 2 respuestas (SAIDI, SAIFI en escala $\log(1+y)$), 16 predictoras *ex ante* seleccionadas de 44 candidatas, llaves de identificación y un bloque de exclusiones deliberadas (impacto posterior y respuesta cruzada contemporánea); rezagos temporales y espaciales de vecinos construidos sin fuga de información.
Etapa 5	Magnitud condicional: FE de cuadrante con el menor error en SAIDI y media del cuadrante en SAIFI, 21–26 % menos RMSE que la persistencia, sin mejora demostrada sobre la media histórica del cuadrante; ocurrencia de falla pronosticable (AUC $= 0.84$), pero no mejor que la tasa histórica del cuadrante; pronóstico incondicional de dos partes $15.8\,\%$ mejor que la media del cuadrante en SAIDI; SAR (SAIDI) con las ocho matrices de vecindad y OLS (SAIFI) en el corte transversal (R^2 de 0.89 y 0.84; 0.40 y 0.75 en validación espacial); diferencias territoriales del SAIDI asociadas a la frecuencia y el alcance de los eventos; priorización validada fuera de muestra (el top 10 de 2024 capturó el $59.6\,\%$ del SAIDI operativo de 2025).
Etapa 6	Documentación reproducible de las seis etapas en informes HTML con URL estable (Apéndice A.3) y código fuente de extracción e integración (Apéndice A.2), con trazabilidad verificable entre cada afirmación del documento y su evidencia computacional.

Tabla 6.30: Cierre de resultados frente a los objetivos específicos

Objetivo específico	**Resultado que lo responde**
1. Consolidar las fuentes de datos relevantes, documentando cobertura, calidad y limitaciones mediante un catálogo de datos y métricas de integridad.	Tabla de linaje de datos (Tabla 5.7) con las seis fuentes, sus reglas de depuración y su resultado; diagnóstico de completitud sin valores faltantes; identificación y documentación explícita del sesgo de cobertura 2021–2023 como limitación conocida (Sección 6.2).
2. Determinar qué variables operativas, técnicas y climáticas son más relevantes para predecir SAIDI y SAIFI mediante modelos estadísticos o de Machine Learning.	Triangulación entre la importancia del Random Forest, los coeficientes del panel FE y los del corte transversal (Tabla 6.27): las variables técnicas de tamaño y forma de la red (número de elementos y longitud de red) son las más relevantes para ambos indicadores; la vegetación (NDVI) lo es además para SAIDI. Las variables climáticas rezagadas no resultan relevantes, y la única variable operativa con efecto semanal robusto es el historial reciente de SAIDI del propio cuadrante. Las variables de antigüedad y mantenimiento de activos se excluyeron por usar fechas posteriores al periodo.
3. Evaluar el desempeño de diferentes métodos estadísticos o de Machine Learning para predecir SAIDI y SAIFI por circuito o zona.	Comparación de cuatro algoritmos de panel (Pooled OLS, FE cuadrante, FE cuadrante+semana, Random Forest ajustado) frente a dos pronósticos de referencia, con RMSE, MAE, r^2, R^2 predictivo, MASE, prueba de Diebold–Mariano semanal con intervalos por bloques y validación de origen móvil anidada (Tablas 6.13–6.17); clasificador de ocurrencia (Sección 6.5.4); y modelos espaciales SAR y SEM con validación cruzada espacial (Tabla 6.22). Se identifica el modelo de menor error y el modelo estructural preferido para cada indicador, así como el límite de lo que se logró pronosticar con los datos disponibles.

Discusión y trabajo futuro

7.1. Discusión

El resultado central de la Etapa 5 es una separación nítida entre lo que es pronosticable y lo que no lo es con la información disponible. El *nivel* de afectación de cada cuadrante es estable y altamente explicable: los modelos de corte transversal alcanzan un R^2 de 0.89 (SAIDI) y 0.84 (SAIFI), significativo frente a una prueba de permutación que repite la selección de variables, y conservan 0.40 y 0.75 cuando se predicen zonas no usadas ni en la selección ni en la estimación. La *ocurrencia* de falla en la semana siguiente también es pronosticable con precisión útil (AUC de 0.84), aunque casi toda esa capacidad proviene de la propensión histórica de cada cuadrante: la tasa histórica de falla discrimina y calibra tan bien o mejor que el clasificador con variables semanales (Tabla 6.18). En cambio, no se obtuvo un pronóstico de la *magnitud* de la afectación, una vez ocurre la falla, mejor que el promedio histórico del cuadrante: el mejor modelo de panel supera a la persistencia en un 21–26 %, pero su ventaja sobre ese promedio es pequeña e incierta (Tabla 6.15). La combinación de ambos componentes matiza esta conclusión sin contradecirla: evaluado sobre todas las semanas de prueba, el pronóstico de dos partes reduce en un 15.8 % el error cuadrático del promedio del cuadrante en SAIDI (Tabla 6.20), y esa ganancia proviene de anticipar *cuándo* es probable que ocurra una falla, no de anticipar su magnitud. En términos prácticos, la red de Norte de Santander tiene un componente territorial predecible —qué cuadrantes son sistemáticamente más vulnerables y cuáles tienen mayor probabilidad de falla la semana próxima— y un componente de magnitud que, con estos datos, modelos y diseño, no se logró anticipar.

La comparación entre familias de modelos es coherente con esa lectura. Los efectos fijos de cuadrante obtienen el menor error de magnitud en SAIDI porque capturan exactamente el componente que es pronosticable, el nivel propio de cada cuadrante; por la misma razón, su desempeño es casi idéntico al de la media del cuadrante, que en SAIFI es incluso ligeramente mejor. Random Forest resulta inferior pese al ajuste de hiperparámetros, y la búsqueda selecciona la configuración más regularizada de la grilla, un patrón típico cuando la señal es débil y el modelo flexible tiende a ajustar ruido. En la validación de origen móvil

ningún modelo domina de forma sistemática a la media del cuadrante, y la configuración óptima del bosque cambia de un corte a otro. Este resultado difiere del de los informes preliminares, en los que Random Forest obtenía el menor error en SAIDI. La diferencia se explica en buena medida por dos errores de construcción de las variables sísmicas, detectados y corregidos en la re-estimación (Sección 5.2.7): con ellos, la última semana del periodo de prueba registraba un número de sismos veinticuatro veces superior al máximo de entrenamiento, y los modelos lineales extrapolaban ese valor de forma severa, mientras que el bosque, que no extrapola, quedaba protegido. El episodio ilustra por qué la verificación de cada variable contra su definición, y de su fecha de disponibilidad, es parte del análisis y no un trámite previo. Por la misma razón se excluyeron de la especificación final la edad de los activos y su número de modificaciones, que se calculaban con fechas de 2026 y habrían introducido información posterior al periodo pronosticado.

Estas cifras deben leerse frente a la restricción de información bajo la cual se obtuvieron. El R^2 predictivo de entre 0.17 y 0.23 en el panel semanal es el alcanzable con predictoras disponibles antes de la semana pronosticada: las variables de severidad que solo se conocen al cerrar el evento quedaron excluidas por diseño (Sección 5.4; Tabla 5.11). Un modelo que las incluyera mostraría métricas mucho mejores y sería inútil en operación. El desempeño reportado es, por tanto, una medida de lo que el modelo puede ofrecer en condiciones reales de uso y la referencia frente a la cual deben compararse futuras iteraciones. La inferencia sobre las diferencias entre modelos se apoya en dieciséis semanas de prueba, lo que limita la potencia de los contrastes; por eso se reportan, junto con los valores p, los tamaños de efecto y sus intervalos.

La autocorrelación espacial significativa detectada mediante el índice de Moran (SAIDI: $I = 0.154$; SAIFI: $I = 0.179$; ambos $p < 0.001$) confirma que el fenómeno de calidad del servicio no es independiente entre cuadrantes vecinos, lo que valida la inclusión de rezagos espaciales y respalda el enfoque territorial adoptado desde el planteamiento del problema. Buena parte de esa similitud, sin embargo, se explica por la estructura compartida: en SAIFI no queda dependencia espacial significativa una vez se controlan las variables del cuadrante, y en SAIDI el remanente es negativo y estable ante ocho definiciones de la matriz de vecindad (Tabla 6.23). Los modelos espaciales describen mejor los datos de SAIDI, pero no mejoran la predicción de zonas nuevas. Las variables que resultan relevantes en al menos dos modelos (Tabla 6.27) —el número de elementos y la longitud de red en ambos indicadores, y la vegetación en SAIDI— coinciden con la literatura revisada en los antecedentes, que señala la infraestructura y la vegetación como factores recurrentes en la predicción de confiabilidad de redes

de distribución. En este estudio, sin embargo, la señal de infraestructura resultó más determinante que la climática, y la exposición sísmica, una vez corregida su construcción, no resulta significativa al $5\,\%$ en ningún modelo. La descomposición del SAIDI precisa la forma en que se asocian estos factores (Tabla 6.26): las diferencias territoriales del indicador obedecen a la frecuencia de los eventos y al número de usuarios que alcanza cada uno, que crecen con la escala de la red, mientras que la vegetación se asocia con la duración de los eventos y no con su número. Este último resultado es coherente con que el NDVI sea relevante para SAIDI y no para SAIFI, y sugiere que la vegetación se relaciona con la reposición del servicio más que con la ocurrencia de fallas; se trata de una asociación observacional que deberá contrastarse con la causa registrada de cada evento.

La comparación con los antecedentes permite situar estos resultados. Primero, la débil señal del clima semanal contrasta con los estudios de huracanes y tifones, en los que la velocidad del viento es el predictor dominante [12], [64]; la diferencia es coherente con la naturaleza de los datos, porque esos trabajos modelan eventos extremos de escala sinóptica, mientras que en Norte de Santander predominan tormentas convectivas locales de pocas horas que un acumulado semanal de reanálisis no captura, y porque la relación clima–interrupción documentada en la literatura es marcadamente no lineal [11]. Segundo, la elección de una celda de aproximadamente 5×2.5 km se ubica en el rango de resoluciones que la literatura identifica como un compromiso entre señal y dispersión [11], [63], [65], y la fracción de cuadrantes–semana sin eventos ($63\,\%$ en D_{mod}) reproduce el problema de inflación de ceros que motivó los esquemas multietapa de Shashaani et al. [65], lo que respalda el esquema de dos componentes adoptado. Tercero, la evidencia de que los modelos de árboles igualan o superan a especificaciones paramétricas con pocas variables [64] proviene de problemas con una señal meteorológica fuerte; cuando, como aquí, la señal dinámica es débil, la flexibilidad del modelo no se traduce en precisión, y la recomendación de Arora y Ceferino [12] de acompañar estos modelos con reentrenamiento periódico y con una referencia simple se vuelve especialmente pertinente. Finalmente, la heterogeneidad espacial encontrada coincide con la de Dunn et al. [7], quienes muestran que los indicadores de confiabilidad varían en órdenes de magnitud entre zonas y periodos y que los valores agregados la ocultan: ese es precisamente el vacío de información que este trabajo aborda para el operador.

Desde el punto de vista de la gestión, la distinción entre asociación y efecto condiciona el uso práctico de estos resultados. Las señales más robustas —número de elementos y longitud de red— describen la escala y la forma de la red; que se asocien con más afectación no implica que modificarlas la reduzca, y el signo negativo de la longitud, condicionada al número de elementos, no

justifica reducir la red. El NDVI sugiere una hipótesis de intervención mediante programas de poda, y la exposición sísmica no es intervenible. Esta jerarquía, unida a los resultados de desempeño, precisa el aporte del trabajo al operador. No reside en pronosticar cuántas horas de interrupción tendrá un cuadrante la semana próxima, sino en dos insumos para un prototipo de apoyo a decisiones: el ordenamiento de los cuadrantes según su nivel estructural de afectación, para focalizar inversión, mantenimiento y poda, y la probabilidad semanal de falla por cuadrante, para programar cuadrillas y recursos de respuesta. Ambos se validaron fuera de muestra: el orden construido con 2024 concentró en sus diez primeros cuadrantes el 59.6 % del SAIDI de 2025, frente a un máximo posible de 61.7 % (Tabla 6.28), y la probabilidad de falla discrimina con un AUC de 0.84 y acierta en el 92.5 % de los diez cuadrantes priorizados cada semana (Tabla 6.19). Esta validación mide la capacidad de anticipar dónde se concentrará la afectación, no el beneficio de actuar sobre ella: demostrar una reducción de interrupciones o de compensaciones exige una prueba piloto con emisión semanal de la lista, un presupuesto de atención definido y comparación con la regla de priorización vigente. La priorización también debe distinguir la concentración absoluta de la afectación, que favorece a los cuadrantes grandes, del riesgo por usuario, para no relegar las zonas pequeñas solo por su tamaño.

Entre las limitaciones del estudio, la más relevante es el sesgo de cobertura de emparejamiento evento–elemento detectado entre 2021 y 2023 (Sección 6.2), que obligó a restringir el conjunto de modelado a 2024–2025. Esta decisión, aunque necesaria para garantizar la validez de los resultados, redujo el horizonte temporal disponible para el entrenamiento y probablemente limita la capacidad de los modelos para capturar variabilidad interanual de más largo plazo; con solo 105 semanas útiles, el *holdout* del 15 % final deja una ventana de evaluación de dieciséis semanas, suficiente para detectar degradación sistemática pero no para contrastar la estabilidad del modelo ante un ciclo anual completo. La validación de origen móvil en cuatro cortes, con ajuste de hiperparámetros anidado (Tabla 6.17), confirma que todos los modelos superan a la persistencia en los ocho casos, pero también que las diferencias entre FE, Random Forest y la media del cuadrante cambian de signo entre cortes.

La segunda limitación se refiere a la construcción del indicador operativo. El panel conserva los usuarios de un solo evento cuando un elemento falla varias veces el mismo día, el SAIDI operativo es el producto de totales semanales y no la suma de duración por usuarios de cada evento, y los eventos que se extienden a semanas posteriores —el 9.9 % de los eventos, con el 59 % de las horas de interrupción— distribuyen su duración entre días mientras sus usuarios se asignan a la semana de inicio. La reconstrucción evento a evento del Apéndice A.5

muestra que el orden de los cuadrantes se conserva en buena medida, pero que los niveles difieren de forma sustancial y que la concentración de la afectación es menor con la forma por evento. Las conclusiones de este trabajo se refieren, por tanto, a índices de severidad relativa y no a los indicadores regulatorios, y la magnitud del beneficio de focalizar depende de esa construcción.

En tercer lugar, la señal climática resultó débil en el grano semanal (Sección 6.3). Para descartar que esta debilidad obedeciera a la agregación, que promedia condiciones heterogéneas y puede diluir episodios intensos de pocas horas, se construyeron indicadores de clima extremo a partir de la serie diaria (Sección 6.5.5). Con ellos, la magnitud semanal siguió sin depender del clima y la ocurrencia de falla mejoró solo marginalmente (AUC de 0.836 a 0.838). La lluvia intensa sí se asocia con la ocurrencia de fallas, pero en la misma semana y no con una semana de anticipación. La evidencia, por tanto, no descarta un efecto climático sobre la continuidad del servicio; indica que ese efecto opera a una escala de días que la información de la semana anterior no anticipa, y que su aprovechamiento operativo requeriría pronósticos meteorológicos de corto plazo.

En cuarto lugar, el modelo de magnitud se estimó sobre las semanas con falla (`hubo_falla`$= 1$), decisión justificada por la cero-inflación del panel: el $63.0\,\%$ de las semanas-cuadrante de D_{mod} no registra eventos (Sección 5.4.11). Los dos componentes se estimaron por separado y se combinaron después en un pronóstico incondicional con retransformación de Duan, que mejoró al promedio del cuadrante en SAIDI pero no en SAIFI; el modelo Tweedie de un solo paso no superó al de dos partes. La combinación empleada es multiplicativa y no modela la posible dependencia entre la probabilidad de falla y su magnitud, una extensión que podría abordarse con especificaciones conjuntas de tipo *hurdle* con efectos aleatorios por cuadrante.

En quinto lugar, varias variables relevantes no tienen historia: el inventario de red corresponde a su corte vigente, sin registro de altas y bajas, y las fechas de modificación de los activos son en su mayoría posteriores al periodo de estudio. La primera se usa bajo el supuesto de una red estable en 2024–2025; la segunda se excluyó. La antigüedad de la red, que la literatura señala como un factor de falla, no pudo evaluarse.

Finalmente, el modelo de efectos fijos de cuadrante y semana no resultó evaluable en el conjunto de prueba por falta de traslape entre semanas de entrenamiento y de prueba, una limitación conocida de los modelos con efectos fijos dobles en validaciones temporales estrictas y no un defecto del modelo en sí. Se documenta de forma explícita porque refleja una incompatibilidad estructural entre efectos fijos temporales y validación prospectiva que cualquier replicación

del trabajo volverá a encontrar.

7.2. Trabajos futuros

A partir de los hallazgos y las limitaciones identificadas, se proponen las siguientes líneas de trabajo futuro:

- Resolver de forma retroactiva la incompatibilidad de esquemas de codificación entre BRAE y el inventario georreferenciado (Sección 6.2), lo que permitiría extender el conjunto de modelado más allá de 2024–2025 y evaluar la estabilidad de los modelos ante un horizonte temporal más largo.
- Explorar especificaciones espacio-temporales formales (por ejemplo, modelos de panel espacial dinámico o *spatial Durbin*) que integren simultáneamente la dependencia espacial confirmada por el índice de Moran y la persistencia temporal identificada en el análisis exploratorio, en lugar de tratarlas como dos modelos separados (panel semanal y corte transversal).
- Incorporar información de mayor resolución temporal que pueda explicar la magnitud semanal alrededor del nivel del cuadrante, que con los datos actuales se comporta como ruido: pronósticos meteorológicos de intensidad máxima intradiaria, alertas de tormenta eléctrica, programación de mantenimientos y maniobras, y disponibilidad de cuadrillas. Solo con información de este tipo tiene sentido volver a evaluar modelos no lineales más flexibles, como *gradient boosting*.
- Estimar el esquema en dos componentes de forma conjunta (*hurdle* con efectos aleatorios por cuadrante), de modo que la dependencia entre la probabilidad de falla y su magnitud se modele explícitamente.
- Incorporar la causa de cada evento registrada en BRAE para estimar los factores por tipo de falla (vegetación, descargas atmosféricas, equipos, terceros), lo que permitiría contrastar directamente la hipótesis de que la vegetación actúa sobre la duración de las interrupciones.
- Estimar el efecto de la priorización sobre las compensaciones con la información de compensaciones por usuario o por circuito del operador, que no estuvo disponible para este trabajo, de modo que el ranking territorial pueda traducirse en un valor económico esperado.
- Incorporar al flujo controles automáticos de cada variable integrada (rango, variación entre unidades y continuidad temporal), como los que permitieron detectar los errores de la variable sísmica.

- Contrastar la robustez de la partición de variables mediante un ejercicio de *ablación* controlada: estimar deliberadamente una especificación que incluya el bloque de impacto posterior y cuantificar la magnitud exacta de la fuga de información. El resultado no sería un modelo utilizable, pero proporcionaría una cota superior del ajuste alcanzable y permitiría dimensionar con precisión el costo predictivo de la restricción *ex ante* adoptada en este trabajo.
- Revisar los signos negativos estimados en el corte transversal para la longitud de red (`longitud_red_km`) y para la antigüedad del activo más viejo (Sección 6.5). La descomposición del SAIDI muestra que, por separado, ambas variables se asocian positivamente con el indicador, por lo que el signo negativo en la regresión múltiple refleja su fuerte correlación con el número de elementos más que un efecto protector. Una medida explícita de densidad de usuarios por kilómetro de red y la fecha de instalación original de los activos permitirían separar estos efectos.
- Diseñar un esquema de actualización periódica del panel y de reentrenamiento de los modelos, de modo que el operador de red pueda adoptar el flujo documentado en este trabajo como una herramienta de monitoreo continuo y no solo como un ejercicio académico puntual, en línea con el objetivo de reproducibilidad planteado desde el inicio del proyecto.

8 Conclusiones

8.1. Conclusión asociada al objetivo general

Este trabajo desarrolló una metodología basada en ciencia de datos, estructurada según CRISP-DM, para pronosticar los indicadores SAIDI y SAIFI por zona en la red de distribución de una empresa de energía eléctrica del Norte de Santander e identificar los factores que más influyen en su comportamiento. La metodología integró cinco sistemas corporativos (BRAE, `QA_TTC1`, OMS SPARD, OMS SP7 y GTECH) y cuatro fuentes externas (NASA POWER, MODIS, SGC y DANE) en un panel cuadrante $\times$ semana, sobre el que se construyeron indicadores operativos de afectación referidos a la base de usuarios de la empresa. En respuesta a la pregunta de investigación, la evidencia muestra que la afectación tiene dos componentes de naturaleza distinta. El primero es territorial y estable: el nivel de afectación de cada cuadrante se asocia en un 84–89 % con la infraestructura y la exposición, un orden construido con un año concentró en diez cuadrantes cerca del 60 % del SAIDI operativo del año siguiente, y la probabilidad de que un cuadrante registre una falla la semana siguiente se pronostica con un AUC de 0.84, capacidad que proviene sobre todo de su propensión histórica. El segundo es la magnitud de la afectación una vez ocurre la falla, que con estos datos, modelos y diseño no se logró pronosticar mejor que el promedio histórico del cuadrante: el mejor modelo reduce el error de la persistencia en un 21–26 %, pero no se demostró una mejora sobre ese promedio. Al combinar ambos componentes, el pronóstico de la afectación semanal de SAIDI sí supera a ese promedio, porque la probabilidad de falla anticipa cuándo el cuadrante se apartará de su nivel habitual. Los indicadores modelados son índices operativos de severidad relativa, construidos con los registros de la empresa, y no los indicadores regulatorios; su orden territorial es robusto a la forma del numerador, pero la magnitud de la concentración no lo es (Apéndice A.5). La metodología completa, desde la extracción de los datos hasta la evaluación de los modelos, quedó documentada en código e informes reproducibles y es replicable por el operador con sus propios sistemas.

8.2. Conclusión asociada al objetivo específico 1

Se consolidaron las fuentes enunciadas en el objetivo en un repositorio analítico trazable, documentado mediante el linaje de datos (Tabla 5.7) y el catálogo de datos (Apéndice A.4), que registra para cada fuente su cobertura, sus métricas de integridad y sus limitaciones. La métrica de integridad más relevante no fue la completitud de los campos, que fue alta, sino la trazabilidad evento–elemento: solo cerca del 31 % de los eventos de 2021–2023 podía vincularse al inventario georreferenciado, frente al 79.8 % en 2024 y el 95.0 % en 2025, por la coexistencia de códigos de sitio y de activo en el sistema histórico de gestión de interrupciones. Este diagnóstico, que un análisis basado únicamente en valores faltantes no habría detectado, delimitó el periodo de modelado a 2024–2025 y constituye en sí mismo un aporte a la gobernanza de datos del operador. La verificación de cada variable contra su definición permitió además detectar y corregir dos errores en la construcción de la exposición sísmica.

8.3. Conclusión asociada al objetivo específico 2

Las variables con mayor relevancia para predecir SAIDI y SAIFI son técnicas y estructurales: el número de elementos y la longitud de la red del cuadrante son las más importantes en todos los modelos que pueden identificarlas, y para SAIDI se suma la vegetación (NDVI) (Tabla 6.27). Entre las variables operativas, el único efecto semanal robusto es el historial reciente de SAIDI del propio cuadrante. La descomposición del SAIDI precisa cómo actúan: la escala de la red se asocia con más eventos y con un mayor número de usuarios afectados por cada uno, que son los componentes que explican las diferencias territoriales del indicador, mientras que la vegetación se asocia con eventos más largos, lo que explica su relevancia para SAIDI y no para SAIFI. Las variables climáticas de la semana anterior no resultaron significativas en ningún modelo, tampoco cuando se midieron como episodios extremos a partir de la serie diaria; la lluvia intensa solo se asoció con la ocurrencia de fallas en la misma semana. Este resultado contradice la expectativa inicial de que el clima sería un predictor principal e indica que su efecto opera en escalas de días que la información disponible con una semana de anticipación no captura. Estas asociaciones son observacionales: identifican dónde se concentra la afectación y qué rasgos de la red la acompañan, pero no demuestran que modificar esos rasgos la reduzca. Desde la perspectiva de la gestión, sugieren hipótesis de intervención —inversión, reposición de activos y poda— que el operador puede contrastar con su historial de intervenciones y con criterio de ingeniería antes de asignarles un beneficio esperado.

8.4. Conclusión asociada al objetivo específico 3

Se evaluaron cuatro especificaciones de panel semanal (*Pooled* OLS, efectos fijos de cuadrante, efectos fijos de cuadrante y semana, y Random Forest con ajuste de hiperparámetros), un clasificador de ocurrencia de falla y dos modelos espaciales formales (SAR y SEM) para cada indicador, bajo validación temporal estricta, con predictoras disponibles antes de la semana pronosticada, sobre una muestra común y frente a dos pronósticos de referencia. Para la magnitud condicional a la falla, los efectos fijos de cuadrante obtuvieron el menor error en SAIDI y la media del cuadrante en SAIFI; FE superó con claridad a la persistencia y a Random Forest (prueba de Diebold–Mariano semanal, $p \leq 0.005$), pero no se demostró una mejora sobre el promedio histórico del cuadrante ($1.8\,\%$ en SAIDI, con un intervalo que incluye el cero), y en la validación de origen móvil, con ajuste anidado, ningún modelo dominó de forma sistemática a ese promedio. El clasificador de ocurrencia discriminó bien (AUC de 0.84) y está calibrado, pero no superó a la tasa histórica de falla de cada cuadrante. El pronóstico incondicional que combina la probabilidad de falla con la magnitud redujo en un $15.8\,\%$ el error del promedio del cuadrante en SAIDI ($p < 0.001$) y lo igualó en SAIFI. Para la explicación territorial, SAR fue preferido por AIC en SAIDI con las ocho definiciones de vecindad evaluadas y OLS en SAIFI; el ajuste es alto y se conserva en un $40\,\%$ y un $75\,\%$ al predecir zonas no usadas en la selección ni en la estimación, sin que los modelos espaciales mejoren esa transferencia. La priorización derivada de la afectación histórica se validó fuera de muestra: el orden de 2024 capturó el $78.5\,\%$ del SAIDI operativo de 2025 con treinta cuadrantes, frente a un $82.7\,\%$ del orden óptimo. En consecuencia, como referencia semanal se propone el pronóstico de dos partes para SAIDI y el promedio histórico del cuadrante para SAIFI; para anticipar semanas y zonas críticas, la probabilidad de falla o la tasa histórica del cuadrante; y para priorizar territorialmente la inversión y el mantenimiento preventivo, el orden de la afectación histórica explicado por los modelos de corte transversal. Estos productos constituyen un prototipo de apoyo a decisiones cuyo beneficio sobre los índices anuales y las compensaciones debe medirse en una prueba piloto. Los modelos más simples e interpretables resultaron también los de mejor desempeño, lo que favorece su adopción por los gestores.

8.5. Recomendaciones para el operador de red

- Homologar retroactivamente los códigos de activo y de sitio en el histórico del sistema de gestión de interrupciones, lo que permitiría recuperar cerca

del 70 % de los eventos de 2021–2023 para el análisis territorial.

- Usar el ranking de cuadrantes por contribución a SAIDI y SAIFI (Apéndice A.6) y la probabilidad semanal de falla como prototipo de apoyo a la planeación de mantenimiento preventivo, poda, inversión y programación de cuadrillas, y validarlo mediante una prueba piloto antes de su adopción: emisión semanal de la lista con fecha de corte, presupuesto de atención fijo (por ejemplo, los k cuadrantes que una cuadrilla puede atender), comparación con la regla de priorización vigente y métricas acordadas con el operador (afectación capturada, eventos evitados y compensaciones). El beneficio esperado que se deriva de este trabajo no sustituye el beneficio observado en ese piloto.
- Distinguir, al priorizar, la concentración absoluta de la afectación (que favorece a los cuadrantes grandes) del riesgo por usuario, de modo que las zonas pequeñas con alta afectación relativa no queden relegadas solo por su tamaño.
- Contrastar, como hipótesis de intervención, la diferenciación según el componente que domina el SAIDI de cada zona: mantenimiento preventivo y poda donde predomina la frecuencia de los eventos, seccionamiento y reconfiguración donde predomina el número de usuarios afectados por evento, y logística de atención y acceso en los cuadrantes rurales y con mayor vegetación, donde los eventos son más largos.
- Integrar pronósticos meteorológicos de corto plazo a la programación operativa, dado que la lluvia intensa se asocia con la ocurrencia de fallas en la misma semana y no es anticipable con la información de la semana anterior.
- Registrar la fecha de instalación original y el tipo de intervención de los activos, hoy no disponibles, para mejorar la medición de su antigüedad y del efecto del mantenimiento.
- Actualizar periódicamente el panel y reentrenar los modelos con la cadena reproducible documentada en este trabajo, incluyendo controles automáticos de rango y continuidad de cada variable integrada.

Bibliografía

[1] Comisión de Regulación de Energía y Gas (CREG), «Resolución CREG 015 de 2018 – Por la cual se establecen los indicadores de calidad del servicio de energía eléctrica y las fórmulas de compensación,» CREG, Bogotá, Colombia, inf. téc., 2018. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0015_2018.htm

[2] S.-S. de Servicios Públicos Domiciliarios, «Resolución SSPD 20192200020155,» Superintendencia de Servicios Públicos Domiciliarios, inf. téc., 2019, [Online; accessed 2025-11-23]. dirección: https://www.superservicios.gov.co/node/5072

[3] IEEE Power and Energy Society, «IEEE Std 1366-2012: IEEE Guide for Electric Power Distribution Reliability Indices,» IEEE, New York, USA, inf. téc., 2012.

[4] A. Escalera, B. Hayes y M. Prodanović, «A survey of reliability assessment techniques for modern distribution networks,» *Renewable and Sustainable Energy Reviews*, vol. 91, págs. 344-357, 2018. DOI: 10.1016/j.rser.2018.02.031

[5] K. Zhou, C. Fu y S. Yang, «Big data driven smart energy management: From big data to big insights,» *Renewable and Sustainable Energy Reviews*, vol. 56, págs. 215-225, 2016. DOI: 10.1016/j.rser.2015.11.050

[6] M. Kezunovic, L. Xie y S. Grijalva, «The role of big data in improving power system operation and protection,» en *2013 IREP Symposium – Bulk Power System Dynamics and Control – IX Optimization, Security and Control of the Emerging Power Grid*, Rethymnon, Greece, 2013.

[7] L. N. Dunn, M. D. Sohn, K. H. LaCommare y J. H. Eto, «Exploratory analysis of high-resolution power interruption data reveals spatial and temporal heterogeneity in electric grid reliability,» *Energy Policy*, vol. 129, págs. 206-214, 2019. DOI: 10.1016/j.enpol.2019.01.042

[8] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Circular 063 de 2019 – Criterios técnicos para el cálculo de indicadores de calidad del servicio de energía eléctrica,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, Circular 063, 2019, [En línea]. dirección: https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/$FILE/Circular063-2019.pdf

[9] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Informe de Calidad del Servicio de Energía Eléctrica 2023,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, inf. téc., 2024, [En línea]. Disponible en: https://www.superservicios.gov.co. dirección: https://www.superservicios.gov.co

[10] U. de Planeación Minero Energética (UPME), «Plan de Expansión de Referencia Generación - Transmisión 2023 - 2037,» Unidad de Planeación Minero Energética (UPME), inf. téc., 2023.

[11] S.-R. Han, S. D. Guikema y S. M. Quiring, «Improving the Predictive Accuracy of Hurricane Power Outage Forecasts Using Generalized Additive Models,» *Risk Analysis*, vol. 29, n.º 10, págs. 1443-1453, 2009. DOI: 10.1111/j.1539-6924.2009.01280.x

[12] P. Arora y L. Ceferino, «Probabilistic and machine learning methods for uncertainty quantification in power outage prediction due to extreme events,» *Natural Hazards and Earth System Sciences*, vol. 23, n.º 5, págs. 1665-1683, 2023. DOI: 10.5194/nhess-23-1665-2023

[13] R. J. A. Little y D. B. Rubin, *Statistical Analysis with Missing Data*, 3.ª ed. Hoboken, NJ, USA: John Wiley & Sons, 2019.

[14] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[15] G. E. P. Box y D. R. Cox, «An Analysis of Transformations,» *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 26, n.º 2, págs. 211-252, 1964.

[16] G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5.ª ed. Hoboken, NJ, USA: John Wiley & Sons, 2015.

[17] C. Spearman, «The Proof and Measurement of Association between Two Things,» *The American Journal of Psychology*, vol. 15, n.º 1, págs. 72-101, 1904.

[18] H. Cramér, *Mathematical Methods of Statistics*. Princeton, NJ, USA: Princeton University Press, 1946.

[19] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.ª ed. Melbourne, Australia: OTexts, 2021. dirección: https://otexts.com/fpp3/

[20] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2.ª ed. New York, NY, USA: Springer, 2009.

[21] C. Bergmeir y J. M. Benítez, «On the Use of Cross-Validation for Time Series Predictor Evaluation,» *Information Sciences*, vol. 191, págs. 192-213, 2012. DOI: 10.1016/j.ins.2011.12.028

[22] I. T. Jolliffe, *Principal Component Analysis*, 2.ª ed. New York, NY, USA: Springer, 2002.

[23] L. Kaufman y P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. New York, NY, USA: John Wiley & Sons, 1990.

[24] J. MacQueen, «Some Methods for Classification and Analysis of Multivariate Observations,» en *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, Berkeley, CA, USA: University of California Press, 1967, págs. 281-297.

[25] M. H. Kutner, C. J. Nachtsheim, J. Neter y W. Li, *Applied Linear Statistical Models*, 5.ª ed. New York, NY, USA: McGraw-Hill/Irwin, 2005.

[26] R. M. O'Brien, «A Caution Regarding Rules of Thumb for Variance Inflation Factors,» *Quality & Quantity*, vol. 41, n.º 5, págs. 673-690, 2007. DOI: 10.1007/s11135-006-9018-6

[27] P. McCullagh y J. A. Nelder, *Generalized Linear Models*, 2.ª ed. London, UK: Chapman & Hall, 1989.

[28] A. C. Cameron y P. K. Trivedi, *Regression Analysis of Count Data*, 2.ª ed. Cambridge, UK: Cambridge University Press, 2013.

[29] J. M. Wooldridge, *Econometric Analysis of Cross Section and Panel Data*, 2.ª ed. Cambridge, MA, USA: MIT Press, 2010.

[30] L. Breiman, «Random Forests,» *Machine Learning*, 2003. DOI: 10.1023/A:1010933404324

[31] P. Probst, M. N. Wright y A.-L. Boulesteix, «Hyperparameters and tuning strategies for random forest,» *WIREs Data Mining and Knowledge Discovery*, vol. 9, n.º 3, e1301, 2019. DOI: 10.1002/widm.1301

[32] P. A. P. Moran, «Notes on Continuous Stochastic Phenomena,» *Biometrika*, vol. 37, n.º 1/2, págs. 17-23, 1950. DOI: 10.2307/2332142

[33] L. Anselin, *Spatial Econometrics: Methods and Models*. Dordrecht, Netherlands: Kluwer Academic Publishers, 1988. DOI: 10.1007/978-94-015-7799-1

[34] J. LeSage y R. K. Pace, *Introduction to Spatial Econometrics*. Boca Raton, FL, USA: Chapman y Hall/CRC, 2009. DOI: 10.1201/9781420064254

[35] R. J. Hyndman y A. B. Koehler, «Another look at measures of forecast accuracy,» *International Journal of Forecasting*, vol. 22, n.º 4, págs. 679-688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001

[36] F. X. Diebold y R. S. Mariano, «Comparing Predictive Accuracy,» *Journal of Business & Economic Statistics*, vol. 13, n.º 3, págs. 253-263, 1995. DOI: 10.1080/07350015.1995.10524599

[37] K. Xie, H. Zhang y C. Singh, «Reliability forecasting models for electrical distribution systems considering component failures and planned outages,» *International Journal of Electrical Power & Energy Systems*, vol. 78, págs. 337-346, 2016. DOI: 10.1016/j.ijepes.2016.01.020

[38] S. Das, P. Kankanala y A. Pahwa, «Outage Estimation in Electric Power Distribution Systems Using a Neural Network Ensemble,» *Energies*, 2021. DOI: 10.3390/en14164797

[39] M. Angalakudati et al., «Improving emergency storm planning using machine learning,» en *2014 IEEE PES T&D Conference and Exposition*, 2014. DOI: 10.1109/TDC.2014.6863406

[40] D. Owerko, F. Gama y A. Ribeiro, «Predicting Power Outages Using Graph Neural Networks,» en *IEEE Global Conference on Signal and Information Processing*, 2018. DOI: 10.1109/GLOBALSIP.2018.8646486

[41] D. Cerrai, P. L. Watson y E. N. Anagnostou, «Assessing the effects of a vegetation management standard on distribution grid outage rates,» *Electric Power Systems Research*, 2019. DOI: 10.1016/j.epsr.2019.105909

[42] R. Eskandarpour y A. Khodaei, «Machine Learning Based Power Grid Outage Prediction in Response to Extreme Events,» *IEEE Transactions on Power Systems*, 2017. DOI: 10.1109/TPWRS.2016.2631895

[43] C. Rudin et al., «Machine Learning for the New York City Power Grid,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012. DOI: 10.1109/TPAMI.2011.108

[44] L. Xu, M.-Y. Chow, J. Timmis y L. Taylor, «Power Distribution Outage Cause Identification With Imbalanced Data Using Artificial Immune Recognition System (AIRS) Algorithm,» *IEEE Transactions on Power Systems*, 2007. DOI: 10.1109/TPWRS.2006.889040

[45] S.-R. Han, S. D. Guikema, S. M. Quiring, K. H. Lee, D. V. Rosowsky y R. A. Davidson, «Estimating the spatial distribution of power outages during hurricanes in the Gulf coast region,» *Reliability Engineering & System Safety*, 2009. DOI: 10.1016/j.ress.2008.02.018

[46] F. Yang, D. W. Wanik, D. Cerrai, M. A. E. Bhuiyan y E. N. Anagnostou, «Quantifying Uncertainty in Machine Learning-Based Power Outage Prediction Model Training: A Tool for Sustainable Storm Restoration,» *Sustainability*, 2020. DOI: 10.3390/su12041525

[47] P. Kankanala, S. Das y A. Pahwa, «AdaBoost+: An Ensemble Learning Approach for Estimating Weather-Related Outages in Distribution Systems,» *IEEE Transactions on Power Systems*, 2013. DOI: 10.1109/TPWRS.2013.2281137

[48] Y. Kor, M. Reformat y P. Musilek, «Predicting Weather-related Power Outages in Distribution Grid,» en *IEEE Power & Energy Society General Meeting*, 2020. DOI: 10.1109/PESGM41954.2020.9281829

[49] M. Doostan y B. Chowdhury, «Predicting Lightning-Related Outages in Power Distribution Systems: A Statistical Approach,» *IEEE Access*, 2020. DOI: 10.1109/ACCESS.2020.2991923

[50] P.-C. Chen y M. Kezunović, «Fuzzy logic approach to predictive risk analysis in distribution outage management,» en *IEEE Power & Energy Society General Meeting*, 2017. DOI: 10.1109/PESGM.2017.8274298

[51] J. He, D. W. Wanik, B. Hartman, E. N. Anagnostou, M. Astitha y M. Frediani, «Nonparametric Tree-Based Predictive Modeling of Storm Outages on an Electric Distribution Network,» *Risk Analysis*, 2017. DOI: 10.1111/risa.12652

[52] H. Hou et al., «Spatial distribution assessment of power outage under typhoon disasters,» *International Journal of Electrical Power & Energy Systems*, 2021. DOI: 10.1016/j.ijepes.2021.107169

[53] M. Li et al., «Prediction of Power Outage Quantity of Distribution Network Users under Typhoon Disaster Based on Random Forest and Important Variables,» 2021. DOI: 10.1155/2021/6682242

[54] C. Zhai, T. Y.-J. Chen, A. White y S. D. Guikema, «Power outage prediction for natural hazards using synthetic power distribution systems,» *Reliability Engineering & System Safety*, 2021. DOI: 10.1016/j.ress.2020.107348

[55] D. Zhu, D. Cheng, R. Broadwater y C. Scirbona, «Storm modeling for prediction of power distribution system outages,» *Electric Power Systems Research*, 2007. DOI: 10.1016/j.epsr.2006.08.020

[56] A. Arif y Z. Wang, «Distribution Network Outage Data Analysis and Repair Time Prediction Using Deep Learning,» en *IEEE International Conference on Probabilistic Methods Applied to Power Systems*, 2018. DOI: 10.1109/PMAPS.2018.8440354

[57] D. W. Wanik, E. N. Anagnostou, B. Hartman, M. Frediani y M. Astitha, «Storm outage modeling for an electric distribution network in Northeastern USA,» *Natural Hazards*, 2015. DOI: 10.1007/s11069-015-1908-2

[58] A. Jaech, B. Zhang, M. Ostendorf y D. S. Kirschen, «Real-Time Prediction of the Duration of Distribution System Outages,» *IEEE Transactions on Power Systems*, 2018. DOI: 10.1109/TPWRS.2018.2860904

[59] D. Sorokin, «Machine learning application for power systems reliability assessment,» en *E3S Web of Conferences*, vol. 461, 2023. DOI: 10.1051/e3sconf/202346101032

[60] Z. Liu, J. Li, T. Zhang y J. Shao, «Rapid Calculation of Active Distribution Network Reliability Based on Dynamic Equipment Failure Rate,» *Energies*, vol. 16, n.º 14, 2023. DOI: 10.3390/en16145245

[61] E. Avcı, «Hybrid Artificial Intelligence Techniques for Enhanced Electricity Outage Prediction and Management in Distribution Networks,» *Turkish Journal of Electrical Power and Energy Systems*, 2024. DOI: 10.5152/TEPES.2024.24008

[62] J. Krstivojević y J. S. Terzić, «Enhancing Reliability Performance in Distribution Networks Using Monte Carlo Simulation for Optimal Investment Option Selection,» *Applied Sciences*, págs. 1-26, 2025.

[63] H. Liu, R. A. Davidson, D. V. Rosowsky y J. R. Stedinger, «Negative Binomial Regression of Electric Power Outages in Hurricanes,» *Journal of Infrastructure Systems*, vol. 11, n.º 4, págs. 258-267, 2005. DOI: 10.1061/(ASCE)1076-0342(2005)11:4(258)

[64] R. Nateghi, S. D. Guikema y S. M. Quiring, «Power Outage Estimation for Tropical Cyclones: Improved Accuracy with Simpler Models,» *Risk Analysis*, 2014. DOI: 10.1111/risa.12131

[65] S. Shashaani, S. D. Guikema, C. Zhai, J. V. Pino y S. M. Quiring, «Multi-Stage Prediction for Zero-Inflated Hurricane Induced Power Outages,» *IEEE Access*, vol. 6, págs. 62 432-62 449, 2018. DOI: 10.1109/ACCESS.2018.2877078

[66] D. B. McRoberts, S. M. Quiring y S. D. Guikema, «Improving Hurricane Power Outage Prediction Models Through the Inclusion of Local Environmental Factors,» *Risk Analysis*, vol. 38, n.º 12, págs. 2722-2737, 2018, Verificar DOI antes de citar.

[67] NASA Langley Research Center (LaRC) POWER Project, *NASA Prediction of Worldwide Energy Resources (POWER): Data Access Viewer and API documentation*, https://power.larc.nasa.gov/, Financiado por el programa NASA Earth Science/Applied Science; en línea, 2024.

[68] P. Chapman et al., «CRISP-DM 1.0: Step-by-step data mining guide,» SPSS Inc., inf. téc., 2000, Cross-Industry Standard Process for Data Mining.

[69] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política de Gestión de Tecnologías de la Información*, Sesión Junta Directiva No. 800, feb. de 2018.

[70] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política Sistema de Gestión Integrado*, Sesión Junta Directiva No. 831, abr. de 2020.

[71] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Instrumentos de gestión de información pública*, https://www.cens.com.co/transparencia-y-acceso-a-la-informacion-publica/instrumentos-de-gestion-de-informacion-publica, En línea; consultado, 2024.

Anexos

A.1. Diagrama de integración del panel

La Figura A.1 presenta el diagrama de flujo de la secuencia de integración descrita en la Sección 5.2.1, desde las fuentes de origen hasta el panel consolidado activo × día.

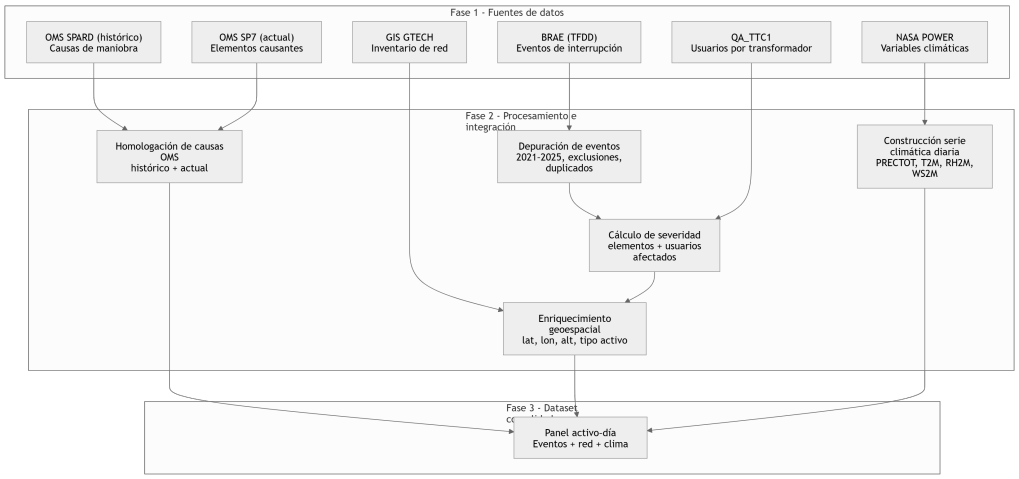


Figura A.1: Estructura del panel de datos activo–día

A.2. Código de extracción de datos

Esta sección consolida el código de extracción utilizado en la Etapa 1 de la metodología (consultas SQL y fragmentos Python). En el cuerpo del documento se describe el procedimiento y se referencia el listado correspondiente.

A.2.1. Consultas SQL

Eventos de interrupción (BRAE)

```
SELECT DISTINCT FDD_CODIGOEVENTO AS ID_EVENTO
      ,FDD_FINICIAL AS FECHA_DESCONEXION
      ,FDD_FFINAL AS FECHA_CONEXION
```

```
      ,'' AS ELEMENTO_FALLADO
FROM BRAE.QA_TFDDREGISTRO
WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
  AND FDD_EXCLUSION = 'NO EXCLUIDA'
  AND FDD_CAUSA_SSPD NOT IN (1)
  AND FDD_FFINAL IS NOT NULL;
```

Listado A.1: Consulta SQL de extracción y depuración de eventos de interrupción (BRAE)

Afectación por evento (BRAE + QA_TTC1)

```
SELECT FDD_CODIGOEVENTO AS ID_EVENTO
      ,COUNT(FDD_CODIGOELEMENTO) AS CANTIDAD_ELEMENTOS_FALLADOS
      ,SUM(CANTIDAD_USUARIOS) AS CANTIDAD_USUARIOS
FROM BRAE.QA_TFDDREGISTRO
LEFT JOIN (
    SELECT TC1_CODCONEX AS TRANSFORMADOR
          ,COUNT(TC1_CODCONEX) AS CANTIDAD_USUARIOS
          ,TC1_PERIODO AS PERIODO
    FROM QA_TTC1
    WHERE SUBSTR(TC1_PERIODO, 1, 4) IN ('2021', '2022', '2023', '2024', '2025')
    GROUP BY TC1_PERIODO, TC1_CODCONEX
) ON FDD_CODIGOELEMENTO = TRANSFORMADOR
 AND FDD_PERIODO_TC1 = PERIODO
WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
  AND FDD_EXCLUSION = 'NO EXCLUIDA'
  AND FDD_CAUSA_SSPD NOT IN (1)
  AND FDD_FFINAL IS NOT NULL
GROUP BY FDD_CODIGOEVENTO;
```

Listado A.2: Consulta SQL de afectación por evento (elementos y usuarios)

Elemento causante histórico (OMS SPARD)

```
SELECT CODE AS CODIGO_MANIOBRA
      ,BREAKER AS ELEMENTO_FALLADO
FROM OMS.MANIOBRAS@SPARD
WHERE TO_NUMBER(TO_CHAR(FECHA, 'YYYY')) >= 2021
  AND CAUSA != 'PRUEBA';
```

Listado A.3: Consulta SQL del elemento causante histórico (OMS SPARD)

Inventario georreferenciado (GIS GTECH)

```
SELECT
    nodo_transform_v AS ELEMENTO,
    coor_gps_lat     AS LATITUD,
```

```
    coor_gps_lon     AS LONGITUD,
    coor_z           AS ALTITUD,
    'Transformador'  AS TIPO,
    ubicacion
FROM ccomun@gtech c
JOIN cconectividad_e@gtech USING (g3e_fid)
WHERE c.estado = 'OPERACION'
  AND c.g3e_fno = 20400
UNION
SELECT
    r.codigo         AS ELEMENTO,
    coor_gps_lat     AS LATITUD,
    coor_gps_lon     AS LONGITUD,
    coor_z           AS ALTITUD,
    'Reconectador'   AS TIPO,
    ubicacion
FROM ereconec_at@gtech r
JOIN ccomun@gtech c USING (g3e_fid)
JOIN cconectividad_e@gtech USING (g3e_fid)
WHERE c.estado = 'OPERACION';
```

Listado A.4: Consulta SQL del inventario georreferenciado de activos (GIS GTECH)

La consulta del Listado A.4 se replica de forma análoga para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador, homologando el tipo de activo en cada bloque `UNION`.

A.2.2. Fragmentos Python

Elemento causante actual (OMS SP7)

```
columnas_necesarias = ['Maniobra Apertura', 'Tipo Elemento', 'Elemento_Falla']
df = pd.read_csv(ruta_actual)
df.columns = df.columns.str.strip()
df = df[columnas_necesarias].drop_duplicates()
```

Listado A.5: Fragmento Python de lectura y depuración del elemento causante actual (OMS SP7)

Parámetros meteorológicos (NASA POWER)

```
parametros_nasa = ("PRECTOT", "T2M", "T2M_MAX", "T2M_MIN", "RH2M", "WS2M")
```

Listado A.6: Definición de parámetros meteorológicos extraídos de NASA POWER

A.3. Informes reproducibles (HTML)

Los procedimientos de extracción, integración, análisis exploratorio y modelado descritos en la metodología se documentan de forma reproducible en informes HTML publicados en el repositorio del proyecto (GitHub Pages). En el cuerpo del documento se cita el apartado correspondiente de este apéndice; los hipervínculos a cada informe se concentran aquí.

A.3.1. Consolidación del panel activo–día

Informe `Consolidada.html`: detalle de los pasos 5.2.1.4 a 5.2.1.8 de integración hacia el panel consolidado. Abrir informe.

A.3.2. Agrupación cuadrante × semana

Informe `data_agrupacion.html`: construcción de la tabla de análisis a grano cuadrante × semana. Abrir informe.

A.3.3. Datos faltantes (tabla agrupada)

Informe `missing_values_grouped.html`: diagnóstico de valores faltantes en `data_agrupada.csv`. Abrir informe.

A.3.4. Valores extremos (panel consolidado)

Informe `detection_outliers.html`: identificación de valores extremos en el panel activo × día. Abrir informe.

A.3.5. Valores extremos (tabla agrupada)

Informe `outliers_gruped.html`: identificación de valores extremos en la tabla cuadrante × semana. Abrir informe.

A.3.6. Estadísticos descriptivos

Informe `calculo_estadistico_descriptivo.html`: cálculo de estadísticos descriptivos sobre la tabla agrupada. Abrir informe.

A.3.7. Distribución de variables

Informe `distribucion_variables.html`: análisis de la forma de las distribuciones (densidades, asimetría, curtosis y ceros). Abrir informe.

A.3.8. Análisis temporal de eventos

Informe `analisis_temporal_eventos.html`: series semanales, estacionalidad y autocorrelación de eventos. Abrir informe.

A.3.9. Emparejamiento evento–elemento

Informe `emparejamiento_eventos.html`: cobertura anual de la trazabilidad entre eventos BRAE e inventario GIS. Abrir informe.

A.3.10. Materialización de D_{mod}

Informe `consolidado_data_mod.html`: filtro y exportación del dataset de modelado 2024–2025. Abrir informe.

A.3.11. Identificación de patrones

Informe `identificacion_patrones.html`: patrones temporales, espaciales y clima–evento sobre D_{mod}. Abrir informe.

A.3.12. Análisis de correlación

Informe `analisis_correlacion.html`: asociaciones de Spearman entre variables climáticas y operativas. Abrir informe.

A.3.13. Análisis multivariado

Informe `analisis_multivariado.html`: VIF, PCA, agrupamiento jerárquico y GLM Poisson exploratorio. Abrir informe.

A.3.14. Segmentación exploratoria

Informe `segmentacion_exploratoria.html`: perfiles por nivel de actividad, régimen de lluvia y clustering de cuadrantes. Abrir informe.

A.3.15. EDA consolidado

Informe `EDA.html`: síntesis ejecutiva del análisis exploratorio (Etapa 3) con hallazgos y lineamientos para la Etapa 4. Abrir informe.

A.3.16. Asociación y depuración de variables cuantitativas

Informe `asociacion_depuracion_cuantitativas.html`: depuración *ex ante* de covariables cuantitativas y exportación de la matriz de diseño. Abrir informe.

A.3.17. Justificación de la agregación espacial

Informe `Etapa2_03_justificacion_agregacion_espacial.html`: justificación del grano cuadrante $\times$ semana y evidencia de concentración espacial de fallas. Abrir informe.

A.3.18. Infraestructura eléctrica por cuadrante

Informe `Etapa2_04_infraestructura_gis_cuadrante.html`: agregación de tipologías y conteos de infraestructura GIS al polígono de cada cuadrante. Abrir informe.

A.3.19. Estratificación municipal

Informe `Etapa2_05_estratificacion_municipal.html`: asignación espacial de municipio y estrato predominante a cuadrantes reales. Abrir informe.

A.3.20. Sismicidad SGC

Informe `Etapa2_07_sismicidad_sgc.html`: incorporación de sismicidad del SGC como exposición territorial del panel. Abrir informe.

A.3.21. Topología de red eléctrica

Informe `Etapa2_08_topologia_red.html`: métricas topológicas de red por cuadrante y vecindad espacial/eléctrica. Abrir informe.

A.3.22. Integración del panel final

Informe `Etapa2_09_integracion_panel_final.html`: unión de fuentes enriquecidas hacia el panel base de modelado. Abrir informe.

A.3.23. Cargue NASA POWER semanal

Informe `Etapa2_10_cargue_nasa_semana.html`: cargue de variables climáticas NASA POWER agregadas por semana. Abrir informe.

A.3.24. Cargue de eventos semanales

Informe `Etapa2_11_cargue_eventos_semana.html`: agregación de eventos y métricas de continuidad a cuadrante–semana. Abrir informe.

A.3.25. Unión del panel semanal

Informe `Etapa2_12_union_panel_semana.html`: unión semanal de clima, eventos y atributos territoriales. Abrir informe.

A.3.26. Ingeniería de variables para SAIDI y SAIFI

Informe `Etapa4_01_feature_engineering_general.html`: exploración de relaciones clima–indicador, matrices de correlación y gráficos de pares sobre el panel cuadrante–semana, como paso previo a la formalización de $SAIFI$ y $SAIDI$ con el denominador de usuarios totales. Abrir informe. *Nota:* es un informe exploratorio previo a la definición final de las respuestas; las fórmulas de trabajo

de $SAIFI$ y $SAIDI$ que emplea difieren de las adoptadas, que son las de la ecuación (5.3) (Sección 5.4.2).

A.3.27. Incorporación y selección de rezagos

Informe `Etapa4_02_rezagos_SAIDI.html`: justificación econométrica de la especificación dinámica $Y_t = X_t\beta + \gamma Y_{t-1} + \delta X_{t-1} + \varepsilon_t$ y evidencia empírica de dependencia temporal para la selección de rezagos. Abrir informe. *Nota:* informe exploratorio; la especificación de rezagos finalmente estimada es la de la Tabla 5.11.

A.3.28. Modelo espacial de SAIDI

Informe `Etapa5_01_modelo_SAIDI_espacial.html`: estimación, validación e interpretación del modelo espacial de SAIDI. Abrir informe. *Nota:* informe preliminar con la especificación contemporánea y el panel previo a la corrección de la sismicidad; las cifras definitivas son las de la re-estimación final (Apéndice A.3.30).

A.3.29. Modelo espacial de SAIFI

Informe `Etapa5_02_modelo_SAIFI_espacial.html`: estimación, validación e interpretación del modelo espacial de SAIFI. Abrir informe. *Nota:* informe preliminar; las cifras definitivas son las de la re-estimación final (Apéndice A.3.30).

A.3.30. Re-estimación final de la Etapa 5

Script `Etapa2_13_correccion_sismos.R` (reconstrucción de las variables sísmicas) e informe `Etapa5_09_reestimacion_v3.Rmd` (especificación *ex ante* sin variables con fechas posteriores, muestra común, pronósticos de referencia, ajuste de hiperparámetros, origen móvil anidado, Diebold–Mariano semanal y remuestreo por bloques, calibración y utilidad del clasificador de ocurrencia, pronóstico incondicional con retransformación de Duan, modelos espaciales con validación por franjas y trazabilidad de variables). Generan las cifras de la Sección 6.5; reemplazan a `Etapa5_03_reestimacion_cierre.R` de la versión anterior.

A.3.31. Panel construido por evento

Informe `Etapa2_14_panel_por_evento.html`: diagnóstico de la tabla de eventos (eventos múltiples por elemento y día, eventos que cruzan semanas, duraciones extremas), reconstrucción de las respuestas evento a evento y conciliación con el panel vigente (Apéndice A.5). Abrir carpeta de código.

A.3.32. Indicadores de clima extremo

Informe `Etapa4_03_clima_extremos.html`: construcción de los indicadores de clima extremo a partir de la serie diaria de NASA POWER y su evaluación en la magnitud y en la ocurrencia de falla (Sección 6.5.5).

A.3.33. Validación fuera de muestra de la priorización territorial

Informe `Etapa5_04_validacion_priorizacion.html`: curva de captura del orden de 2024 sobre la afectación de 2025, referencias de comparación y estabilidad por *bootstrap* (Sección 6.5.9).

A.3.34. Pronóstico incondicional de la afectación

Sección del informe `Etapa5_09_reestimacion_v3.html`: combinación de la probabilidad de falla y la magnitud condicional con retransformación de Duan, modelo Tweedie y pruebas de Diebold–Mariano semanales sobre todas las semanas de prueba (Sección 6.5.4).

A.3.35. Descomposición territorial del SAIDI

Informe `Etapa5_06_descomposicion_saidi.html`: descomposición del SAIDI en frecuencia, duración y alcance de los eventos, y asociación de los factores estructurales con cada componente (Sección 6.5.7).

A.3.36. Sensibilidad a la matriz de vecindad

Informe `Etapa5_08_sensibilidad_W.html`: reestimación de los modelos SAR y SEM con ocho definiciones de la matriz de vecindad (Tabla 6.23).

A.3.37. Reporte técnico de priorización territorial

Informe `Etapa6_01_reporte_priorizacion.html`: concentración de la afectación por cuadrante, probabilidad semanal de falla, clases de prioridad, mapas y orientaciones de gestión; exporta `priorizacion_cuadrantes.csv`. Abrir informe.

A.4. Catálogo de datos y métricas de integridad

Este apéndice materializa el catálogo de datos previsto en el OE1. La Tabla A.1 documenta, para cada tipo de fuente enunciado en el objetivo, el sistema efectivamente consultado, su cobertura, sus métricas de integridad y sus limitaciones; la Tabla A.2 presenta el diccionario de variables del panel de modelado. El objetivo exige documentar la cobertura, la calidad y las limitaciones de cada fuente:

por ello, cuando una fuente se aprovechó solo de manera parcial, la tabla registra explícitamente la limitación que lo explica.

Tabla A.1: Catálogo de fuentes: cobertura, integridad y limitaciones

Fuente del OE1	Sistema o tabla consultada	Cobertura	Métricas de integridad	Limitación documentada	Uso en el modelo
SCADA/OMS y registros de fallas	BRAE `QA_TFDDREGISTRO`; OMS SPARD (`OMS.MANIOBRAS`); OMS SP7 (CSV mensuales)	2021–2025; 95 280 eventos no excluidos	`COMPONENTE_FALLADO` completo en el 100 %; emparejamiento con el inventario GIS de 30.5–31.7 % (2021–2023), 79.8 % (2024) y 95.0 % (2025)	Doble codificación sitio/activo en OMS SPARD (Sección 6.3.5); la información de los equipos de maniobra supervisados por SCADA llega al estudio a través del registro de eventos del OMS y no como serie de telemedida; solo eventos no excluidos (CREG 015 de 2018); 161 eventos de exactamente 3 min (0.41 %) por la resolución de minuto	Respuestas SAIDI/SAIFI y rezagos
GIS (inventario georreferenciado)	GTECH (`ccomun`, `cconectividad_e`)	47 649 activos; 344 cuadrantes con red	`ALTITUD` con 0.04 % de faltantes; coordenadas completas	Inventario vigente, sin histórico de altas y bajas de activos	Infraestructura, topología y vecindad
Mantenimientos	`Fecha_transformadores.csv` (`TT2_FMODIFICACION`, estado `OPERACION`)	28 878 registros (25 399 en operación); fechas de modificación entre marzo de 2023 y septiembre de 2026	0 % de faltantes; la fecha del activo más viejo es posterior a la semana del panel en el 93.2 % de las filas (edad negativa)	Registra la última modificación (67 % de las fechas en 2026) y el número de modificaciones, no la fecha de instalación original ni el tipo de intervención; la "edad" mide en realidad la distancia a la última intervención	`edad_activo_*`, `PROM_CANT_MODIFICACIONES`
Inventarios/SAC (usuarios)	`QA_TTC1`; `cant_usuarios_x_transformador.csv`; `DATA_ESTRATO_SECTOR.csv`; `data_usuarios_totales_sistema.csv`	2021–2025, mensual	Meses faltantes de los cuadrantes 258 y 273 imputados con la moda; cuadrantes 68, 140, 333 y 344 ausentes en la fuente (asignados en cero)	Usuarios asociados al transformador y no al punto exacto de conexión	Denominador UT, `usuarios_afectados`, composición de estrato y sector
Clima	NASA POWER (reanálisis MERRA-2)	Diario 2021–2025; 100 % del área de estudio	3.91 % de faltantes en el panel activo × día; 0 % en el panel cuadrante × semana	Resolución espacial gruesa; no captura tormentas convectivas de pocas horas	Clima rezagado y acumulado
Exposición externa (complementaria)	MODIS MOD13Q1 (NDVI); SGC (catálogo de sismos); DANE	2024–2025	0 % de faltantes en NDVI, sismicidad y estrato	DANE en escala municipal; dos errores de la sismicidad corregidos (Sección 5.2.7)	NDVI y sismicidad rezagados

Tabla A.2: Diccionario de variables del panel de modelado cuadrante × semana

Variable	Descripción	Unidad	Rol
`id_cuadrante`, `semana`	Identificación de la fila (cuadrante de la malla; lunes de inicio de la semana)	–	Llave
`SAIDI`, `SAIFI`	Indicadores operativos de afectación (Sección 5.4.2)	h; eventos	Respuesta
`usuarios_afectados`, `elementos_afectados`	Severidad del evento, conocida solo al cerrarlo	usuarios; elementos	Excluida (*ex post*)
`n_eventos`, `duracion_total`	Insumos de la respuesta	eventos; h	Solo rezagadas
`temp_media_semana`, `viento_max_semana`, `precip_total_semana`, `precip_ma4`	Clima semanal NASA POWER	°C; m/s; mm	Predictora ($t-1$)
`ndvi_semanal`, `ndvi_vecinos`	Índice de vegetación MODIS del cuadrante y de sus vecinos	adimensional	Predictora ($t-1$)
`n_sismos_r50`, `dist_sismo_min_km_r50`	Sismos a menos de 50 km del centroide; distancia al epicentro más cercano de la semana (SGC)	conteo; km	Predictora ($t-1$)
`longitud_red_km`, `densidad_terminales`, `n_elementos`	Topología e infraestructura de red	km; nodos/km; elementos	Predictora
`prop_estrato_1`, `prop_estrato_2`, `prop_no_residencial`	Composición de usuarios del cuadrante	proporción	Predictora
`edad_activo_mas_viejo_anios`, `PROM_CANT_MODIFICACIONES`	Años desde la última modificación registrada del transformador más antiguo (negativa en el 93.2 % de las filas) y número medio de modificaciones; calculadas con fechas de 2026	años; modificaciones	Excluida (información posterior)
`ly_lag1`, `ly_vec_lag1`	Rezago propio y espacial de la respuesta en escala $\log(1+y)$	–	Predictora

La Tabla A.3 complementa el diccionario con la trazabilidad de cada variable candidata: la fuente, la fecha a la que corresponde la observación, la transformación aplicada, la decisión adoptada y los modelos que la usan. Las variables del inventario de red provienen del corte vigente del inventario, que no conserva el histórico de altas y bajas; su uso en 2024–2025 supone que la red del cuadrante fue estable en ese periodo, supuesto que se declara como limitación.

Tabla A.3: Trazabilidad de las variables candidatas: fuente, disponibilidad, transformación, decisión y uso

Variable	Fuente	Fecha de observación	Transformación	Decisión	Modelos
`temp_media_semana`, `viento_max_semana`, `precip_total_semana`	NASA POWER (diario por cuadrante)	Semana s, disponible al cierre de s	Agregación semanal; rezago de una semana	Retenida ($t-1$)	Panel (FE, OLS, RF) y ocurrencia
`precip_ma4`	NASA POWER	Semanas $s-3$ a s	Media móvil de cuatro semanas; rezago de una semana	Retenida ($t-1$)	Panel y ocurrencia
`ndvi_semanal`, `ndvi_vecinos`	MODIS MOD13Q1	Composición de la semana s	Interpolación semanal; promedio de vecinos con $\mathbf{W}$; rezago de una semana	Retenida ($t-1$)	Panel y ocurrencia
`n_sismos_r50`, `dist_sismo_min_km_r50`	SGC	Semana s	Conteo en 50 km y distancia mínima; rezago de una semana	Retenida ($t-1$)	Panel y ocurrencia
$\log(1+Y_{s-1})$ y $\log(1+\overline{Y}_{\mathcal{N},s-1})$	Respuesta construida	Semana $s-1$	`log1p` del nivel rezagado	Retenida	Panel
`hubo_falla` rezagada	Respuesta construida	Semana $s-1$	Indicador $0/1$	Retenida	Ocurrencia
`longitud_red_km`, `densidad_terminales`, `n_elementos`	Inventario GIS (GTECH)	Corte vigente del inventario	Agregación por cuadrante; constante en el tiempo	Retenida (red estable en 2024–2025)	Panel, ocurrencia y corte transversal
`prop_transformadores`	Inventario GIS (GTECH)	Corte vigente del inventario	Proporción por cuadrante	Retenida solo en el corte transversal (absorbida por el efecto fijo)	Corte transversal
`prop_estrato_1`, `prop_estrato_2`, `prop_no_residencial`	Inventarios de usuarios (SAC)	Mensual 2021–2025	Proporción por cuadrante	Retenida	Panel, ocurrencia y corte transversal
Promedios de NDVI, precipitación y distancia al sismo	NASA POWER, MODIS, SGC	2024–2025	Promedio del periodo por cuadrante	Retenida	Corte transversal
`edad_activo_mas_viejo_anios`	Fechas de modificación del inventario	67 % de las fechas en 2026	Diferencia entre la semana y la fecha	Excluida (información posterior)	Ninguno
`PROM_CANT_MODIFICACIONES`	Historial de modificaciones	Registros hasta 2026	Promedio por cuadrante	Excluida (información posterior)	Ninguno
`n_eventos_catastroficos` y su rezago espacial	UNGRD	2019–2022	Conteo semanal	Excluidas (sin solape con 2024–2025)	Ninguno
Temperatura máxima y mínima, humedad, viento medio	NASA POWER	Semana s	Agregación semanal	Excluidas por redundancia con las retenidas (Spearman y VIF)	Ninguno
`n_eventos`, `duracion_total`, `usuarios_afectados`, `elementos_afectados`	Tabla de eventos	Semana s	Insumos de la respuesta	Excluidas (*ex post*)	Ninguno

A.5. Robustez de la construcción del indicador operativo

El panel de modelado construye las respuestas a partir del panel activo–día, y esa construcción tiene tres rasgos que pueden afectar al indicador. Primero, cuando un mismo elemento registra varios eventos en un día, el panel diario suma su frecuencia y su duración pero conserva los usuarios afectados de uno solo de ellos. Segundo, el SAIDI operativo semanal es el producto de totales semanales, $\texttt{duracion_total}_{q,s} \times \texttt{usuarios_afectados}_{q,s}/UT_{m(s)}$, y no la suma de duración por usuarios de cada evento. Tercero, la frecuencia y los usuarios se asignan a la semana en que inicia el evento, mientras que la duración se distribuye entre los días que abarca. Para cuantificar el efecto de estas decisiones se reconstruyeron las respuestas directamente desde `tabla_eventos_ajustado.csv` con una sola regla temporal —cada evento completo se asigna a la semana en que inicia— y con la forma por evento del indicador,

$$\begin{aligned} \mathrm{SAIDI}^{\mathrm{ev}}_{q,s} &= \frac{\sum_{i\in(q,s)} D_i\, NU_i}{UT_{m(s)}}, \\ \mathrm{SAIFI}^{\mathrm{ev}}_{q,s} &= \frac{\sum_{i\in(q,s)} NU_i}{UT_{m(s)}}, \end{aligned} \tag{A.1}$$

donde:

- $i \in (q, s)$: Eventos cuyo elemento fallado pertenece al cuadrante q y que inician en la semana s.
- D_i: Duración del evento i, en horas.
- NU_i: Usuarios afectados por el evento i.
- $UT_{m(s)}$: Usuarios totales del operador en el mes de inicio de la semana s.

El procedimiento y sus verificaciones se documentan en el informe `Etapa2_14_panel_por_evento`. La Tabla A.4 resume el diagnóstico de la tabla de eventos y la comparación entre ambas construcciones.

La comparación tiene tres lecturas. La primera es de *nivel*: el SAIDI vigente multiplica en conjunto por 11 el SAIDI por evento, porque el producto de totales suma términos cruzados entre eventos distintos, y el SAIFI vigente subestima en un tercio la suma de usuarios afectados, por los usuarios que el panel diario no conserva. Los valores de $\mathrm{SAIDI}_{q,s}$ y $\mathrm{SAIFI}_{q,s}$ del panel vigente se interpretan, por tanto, como índices de severidad relativa para ordenar y anticipar la afectación, y no como horas o interrupciones sumables a los indicadores de la empresa. La segunda es de *orden semanal*: en SAIFI ambas construcciones son prácticamente

Tabla A.4: Diagnóstico de la tabla de eventos 2024–2025 y comparación entre el panel vigente y el panel construido por evento

Medida	Valor
Tabla de eventos (39 272 eventos que inician en 2024–2025)	
Eventos en un elemento–día con más de un evento	2 444 (6.2 %)
Usuarios afectados de los eventos no conservados en el panel diario	4 095 442 (36.6 %)
Eventos que terminan en una semana posterior a la de inicio	3 892 (9.9 %)
Horas de interrupción de esos eventos (% del total)	59.1
Eventos de más de 24 horas	8 987 (22.9 %)
Comparación entre construcciones (semanas con falla, D_{mod})	
Semanas con el mismo número de eventos en ambas construcciones (%)	95.5
Correlación de Spearman semanal: SAIDI / SAIFI	0.874 / 0.999
Razón mediana SAIDI vigente / por evento (rango intercuartílico)	1.80 (1.00–4.67)
Razón entre los totales 2024–2025: SAIDI / SAIFI (vigente / por evento)	11.3 / 0.67
Ordenamiento territorial por cuadrante (totales 2024–2025)	
Correlación de Spearman: SAIDI / SAIFI	0.974 / 0.999
Coincidencia de los 10, 20 y 30 primeros cuadrantes, SAIDI	8, 15 y 25
Coincidencia de los 10, 20 y 30 primeros cuadrantes, SAIFI	9, 18 y 28
Captura del SAIDI de 2025 por los 10 primeros cuadrantes de 2024 (%): vigente / por evento	59.6 / 32.4

idénticas fila a fila (Spearman de 0.999), mientras que en SAIDI la concordancia es menor (0.874), porque el producto de totales crece con el número de eventos de la semana. La tercera es de *orden territorial*: los totales por cuadrante conservan el orden en ambas construcciones (Spearman de 0.97 y 0.999), pero el grupo de cuadrantes prioritarios de SAIDI cambia en dos de los diez primeros y en cinco de los veinte primeros, y la concentración de la afectación es muy distinta: los diez cuadrantes con mayor SAIDI de 2024 capturan el 59.6 % del SAIDI vigente de 2025, pero solo el 32.4 % del SAIDI por evento. La priorización territorial no es, por tanto, independiente de la forma del numerador: el núcleo de cuadrantes críticos se mantiene, pero la magnitud de la concentración, y con ella el beneficio esperable de focalizar la intervención, depende de la construcción del indicador. Estas cifras delimitan el alcance de las conclusiones de la Etapa 5, que se obtienen con el panel vigente.

A.6. Artefactos reproducibles y reportes técnicos

Este apéndice reúne la evidencia de la cuarta pregunta de sistematización. Los *artefactos reproducibles* del proyecto son: (i) los informes R Markdown de cada etapa, publicados en HTML (Apéndice A.3); (ii) el repositorio de código https://github.com/esilvas1/DataCollection_Tesis_MCD, cuyo archivo `Scripts/README_reproducibilidad.md` indica el orden de ejecución de cada etapa, los productos que genera y la verificación numérica de la re-estimación; y (iii) el entorno de ejecución, documentado con las versiones de R y de los paquetes empleados (`sessionInfo`), con `requirements.txt` para los scripts de Python y con un `Dockerfile` basado en la imagen `rocker/geospatial`; el

script `instalar_entorno.R` permite además fijar esas versiones en un archivo `renv.lock` para reconstruir el mismo entorno en otra máquina. Todos los modelos aleatorios usan semilla fija.

Los *reportes técnicos* alineados con los entregables del proyecto son tres:

1. *Informe descriptivo y exploratorio*: síntesis del EDA con hallazgos y lineamientos para el modelado (informe HTML; Apéndice A.3.15).

2. *Informe de evaluación de modelos*: estimación, validación, diagnóstico de supuestos y pruebas de robustez de los modelos de SAIDI y SAIFI (informe SAIDI y informe SAIFI; Apéndices A.3.28 y A.3.29).

3. *Reporte técnico de variables relevantes y priorización territorial*: ranking de los cuadrantes con mayor contribución esperada a SAIDI y SAIFI, variables que la explican y acciones de gestión asociadas (mantenimiento, poda e inversión), orientado al uso operativo y al seguimiento de la meta regulatoria (informe HTML; Apéndice A.3.37).

El reporte de priorización muestra que la afectación operativa está muy concentrada: 6 de los 344 cuadrantes (1.7 %) acumulan la mitad del SAIDI operativo de 2024–2025 y 30 cuadrantes acumulan el 80 %; para SAIFI, la mitad se concentra en 9 cuadrantes y el 80 % en 41. Con ese criterio, 10 cuadrantes quedan en prioridad A (los que acumulan el primer 50 % de SAIDI o de SAIFI), 37 en prioridad B (hasta el 80 %) y 297 en seguimiento. La concentración del SAIDI es menor cuando el indicador se reconstruye evento a evento (Apéndice A.5). La Tabla A.5 lista los cuadrantes de prioridad A. La probabilidad semanal de falla del clasificador está razonablemente calibrada: en el decil de mayor probabilidad la tasa observada de falla en el periodo de prueba es del 90.6 %, frente al 2.2 % en el decil más bajo. Este orden es un insumo para un prototipo de priorización; su utilidad operativa debe evaluarse con listas emitidas semana a semana bajo un presupuesto de atención definido.

A.7. Muestra completa de tablas base del proyecto

Esta sección presenta, con todas las columnas y divididas en los bloques temáticos originales, las muestras ilustrativas de las dos tablas base descritas en la Etapa 2 de la metodología (Secciones 5.2.1 y 5.2.5). Las vistas previas de estas mismas filas, con un subconjunto representativo de columnas, se presentan en el cuerpo del documento (Tablas 5.8 y 5.10).

Tabla A.5: Cuadrantes de prioridad A según su participación en la afectación de 2024–2025

Cuadrante	Municipio	Rango SAIDI	% SAIDI	Rango SAIFI	% SAIFI	P(falla) semanal
117	Cúcuta	1	30.5	1	17.7	98 %
107	Los Patios	2	7.0	2	7.9	94 %
296	Tibú	3	4.0	8	2.5	61 %
116	Cúcuta	4	3.4	6	3.3	92 %
126	Cúcuta	5	3.0	4	4.2	97 %
198	Cúcuta	6	2.4	10	2.3	71 %
310	Tibú	9	1.8	3	5.6	75 %
203	Aguachica	11	1.7	5	3.9	87 %
38	Pamplona	18	1.1	9	2.4	84 %
190	Ocaña	42	0.4	7	2.6	54 %

Nota: participación en la suma de los indicadores operativos por cuadrante–semana; se interpreta como orden relativo y no como fracción del indicador regulatorio (Apéndice A.5). P(falla): probabilidad media pronosticada por el clasificador en las 16 semanas de prueba; es un resumen del periodo y no una secuencia de listas emitidas y evaluadas semana a semana, que corresponde a la evaluación de la Tabla 6.19.

Tabla A.6: Muestra de la tabla base consolidada (grano activo–día) – Parte 1: activo y fecha

Id activo	Tipo	Lat.	Lon.	Alt.	Fecha día
AASW4819	Aisladero	8.5786778	-72.92349	219	01/01/2021
1T12452	Transformador	8.5839989	-72.92248	241	01/01/2021
REC21365	Reconectador	8.5840628	-72.92246	241	01/01/2021
CUC12345	Cuchilla	7.7523729	-73.23971	1236	01/01/2021
INT39845	Interruptor	7.7476080	-73.25551	1359	02/01/2021
AASW4820	Aisladero	7.7561057	-73.26037	1169	02/01/2021
1T12453	Aisladero	7.7409332	-73.20825	1636	02/01/2021
REC21366	Transformador	7.7428641	-73.18990	1542	02/01/2021
CUC12346	Reconectador	7.7538839	-73.17721	1707	03/01/2021

Tabla A.7: Muestra de la tabla base consolidada (grano activo–día) – Parte 2: severidad y clima inicial (continuación)

Id activo	Fecha día	C. elem.	C. usu.	Vel. viento	Temp. med.
AASW4819	01/01/2021	0	0	1.11	23.91
1T12452	01/01/2021	0	0	1.23	24.58
REC21365	01/01/2021	125	2015	0.96	23.04
CUC12345	01/01/2021	0	0	0.81	23.02
INT39845	02/01/2021	0	0	1.05	23.83
AASW4820	02/01/2021	0	0	1.12	24.08
1T12453	02/01/2021	0	0	1.08	24.52
REC21366	02/01/2021	0	0	1.26	24.37
CUC12346	03/01/2021	0	0	1.41	24.34

Tabla A.8: Muestra de la tabla base consolidada (grano activo–día) – Parte 3: clima complementario (continuación)

Id activo	Fecha día	Hum. rel.	Temp. min.	Temp. max.	Precip.
AASW4819	01/01/2021	78.91	20.06	29.98	3.19
1T12452	01/01/2021	75.79	20.27	30.90	1.31
REC21365	01/01/2021	83.94	20.26	27.82	3.19
CUC12345	01/01/2021	79.55	17.92	30.09	7.28
INT39845	02/01/2021	69.70	19.35	30.79	1.99
AASW4820	02/01/2021	61.99	17.20	30.81	0.98
1T12453	02/01/2021	72.16	20.38	30.59	2.70
REC21366	02/01/2021	75.50	20.18	30.63	3.29
CUC12346	03/01/2021	74.34	20.40	30.43	1.86

Tabla A.9: Muestra de la tabla base consolidada (grano activo–día) – Parte 4: variables de continuidad (continuación)

Duración (min)	Frecuencia
0	0
0	0
421.5	3
0	0
0	0
0	0
0	0
0	0
0	0

A.7.1. Tabla base consolidada (activo–día)

Nota: las filas de las Tablas A.6 a A.9 corresponden al mismo conjunto de observaciones en el mismo orden.

A.7.2. Tabla base semanal cuadrante

Tabla A.10: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo

Id cuad.	Semana	Lat.	Lon.	Alt.	Usu. afect.	Elem. afect.
1	28/12/2020	7.0012	-72.6855	3418	0	0
1	04/01/2021	7.0012	-72.6855	3418	0	0
3	04/01/2021	7.1548	-72.7196	2850	0	0
12	11/01/2021	7.4521	-72.8903	1240	842	18
45	18/01/2021	7.7539	-73.1204	890	0	0
117	25/01/2021	7.9215	-72.5021	286	1254	24
203	01/02/2021	8.0812	-72.4108	312	0	0
45	08/02/2021	7.7539	-73.1204	890	315	6
117	15/02/2021	7.9215	-72.5021	286	680	11

Tabla A.11: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 2: temperatura (continuación)

Id cuad.	Semana	Temp. med.	Temp. max.	Temp. min.
1	28/12/2020	13.6	19.8	6.2
1	04/01/2021	12.8	18.5	5.8
3	04/01/2021	13.1	19.2	6.0
12	11/01/2021	22.4	28.6	16.8
45	18/01/2021	23.8	30.1	18.2
117	25/01/2021	24.1	30.4	18.9
203	01/02/2021	24.5	30.8	19.1
45	08/02/2021	23.5	29.7	17.8
117	15/02/2021	24.3	30.2	18.6

Nota: las filas de las Tablas A.10 a A.13 corresponden al mismo conjunto de observaciones en el mismo orden. Cadena de unidades de continuidad: panel diario en minutos (`DURACION_min`) → conversión `/60` → `duracion_total` semanal en horas.

A.8. Figuras complementarias de completitud, extremos y localización territorial

Esta sección reúne, en cuadrículas de cuatro figuras por página, las visualizaciones de apoyo del análisis exploratorio (Sección 6.3.1, 6.3.2, 6.3.3, 6.3.6 y 6.3.9)

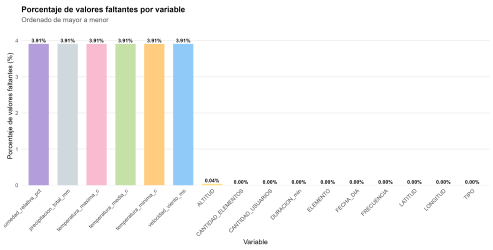
Tabla A.12: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación)

Id cuad.	Semana	Hum. med.	Vel. med.	Vel. max.	Precip.
1	28/12/2020	82.4	1.15	2.31	18.5
1	04/01/2021	80.1	1.08	2.18	12.3
3	04/01/2021	81.6	1.12	2.25	15.7
12	11/01/2021	76.3	0.98	1.95	8.4
45	18/01/2021	74.8	1.05	2.10	6.2
117	25/01/2021	73.5	1.18	2.42	9.8
203	01/02/2021	72.9	1.22	2.55	4.1
45	08/02/2021	75.2	1.09	2.08	11.6
117	15/02/2021	74.1	1.14	2.35	7.3

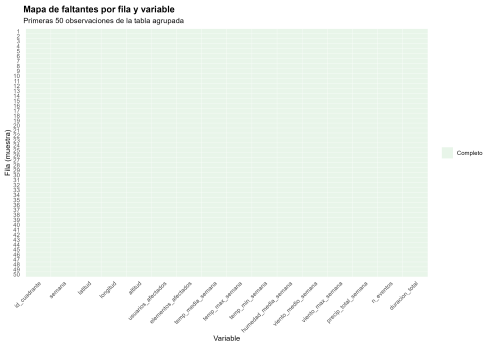
Tabla A.13: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación)

N eventos	Duración total (h)
0	0.0
0	0.0
0	0.0
5	28.4
0	0.0
8	41.7
0	0.0
2	12.6
4	22.3

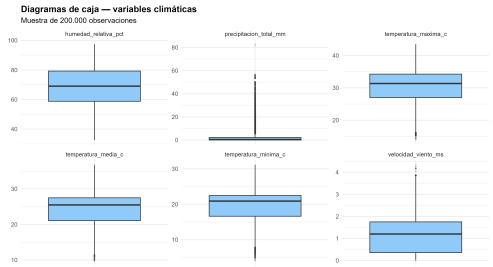
cuya lectura no es indispensable en el cuerpo principal del documento. El comentario e interpretación de cada una se mantiene en el capítulo de Metodología, junto a la referencia cruzada correspondiente.



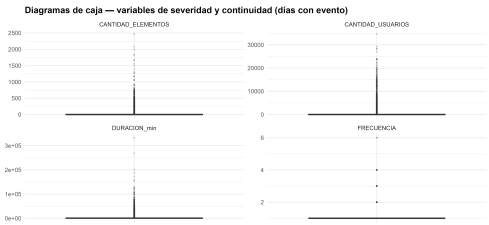
(a) Porcentaje de valores faltantes por variable en el panel consolidado ($N = 87\,007\,074$).



(b) Completitud de la tabla agrupada por fila y variable ($N_{\text{agr}} = 90\,128$; muestra de 50 filas).



(c) Distribución de las variables climáticas: mediana y extremos (muestra de 200 000 observaciones).

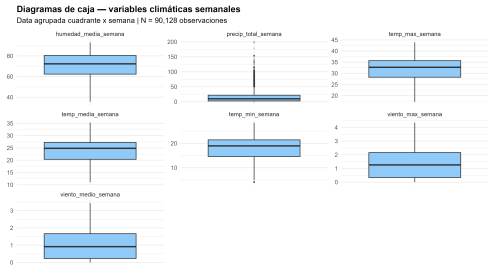


(d) Distribución de la severidad y continuidad en días con evento: mediana y extremos.

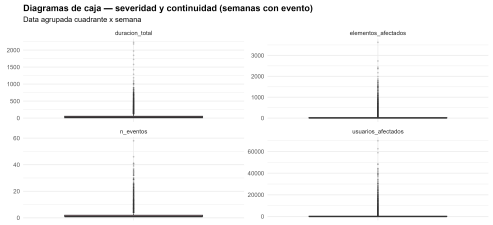
Figura A.2: Completitud del panel consolidado y extremos en variables diarias.

A.9. Figuras complementarias del análisis exploratorio

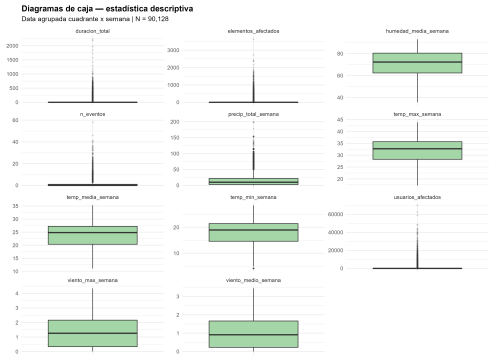
Este apéndice reúne las figuras del análisis exploratorio (Capítulo 6, Etapa 3) que documentan los hallazgos descritos en el texto pero no sustentan por sí mismas una decisión metodológica. Las figuras que sí lo hacen se conservan en el cuerpo del documento.



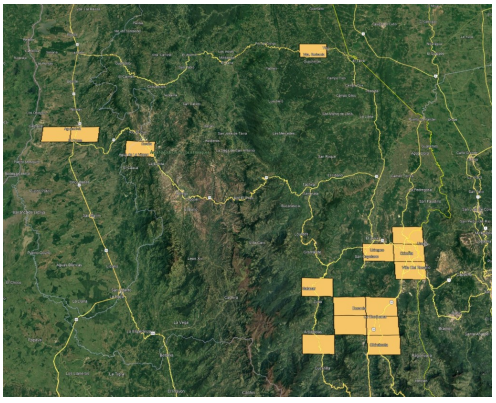
(a) Distribución de las variables climáticas semanales: mediana y extremos ($N_{\text{agr}} = 90\,128$).



(b) Distribución de la severidad y continuidad en semanas con evento: mediana y extremos.

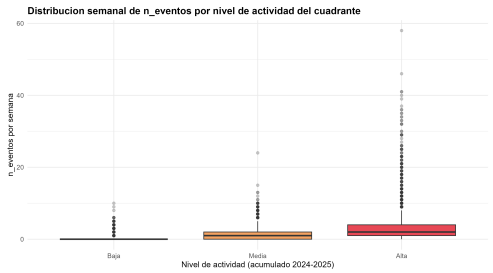


(c) Distribución de las variables numéricas de la tabla agrupada: mediana y extremos ($N_{\text{agr}} = 90\,128$).

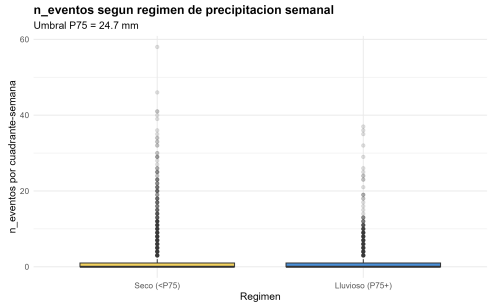


(d) Ubicación geográfica de los cuadrantes *top* con mayor acumulado de eventos en D_{mod} (2024–2025). Los recuadros resaltados identifican la posición espacial de los primeros cuadrantes del ranking.

Figura A.3: Extremos en variables agregadas y localización de los cuadrantes más activos.



(a) Distribución semanal de `n_eventos` por nivel de actividad del cuadrante (D_{mod}).



(b) `n_eventos` según régimen de precipitación semanal (umbral P75).

Figura A.4: Segmentación exploratoria de `n_eventos` por nivel de actividad y régimen de lluvia.

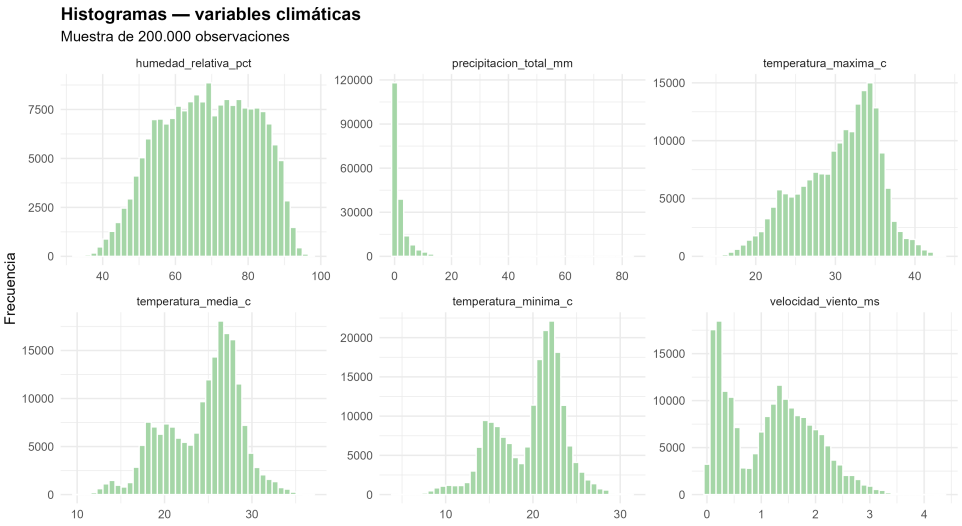


Figura A.5: Distribución de las variables climáticas: forma y cola (muestra de 200 000 observaciones).

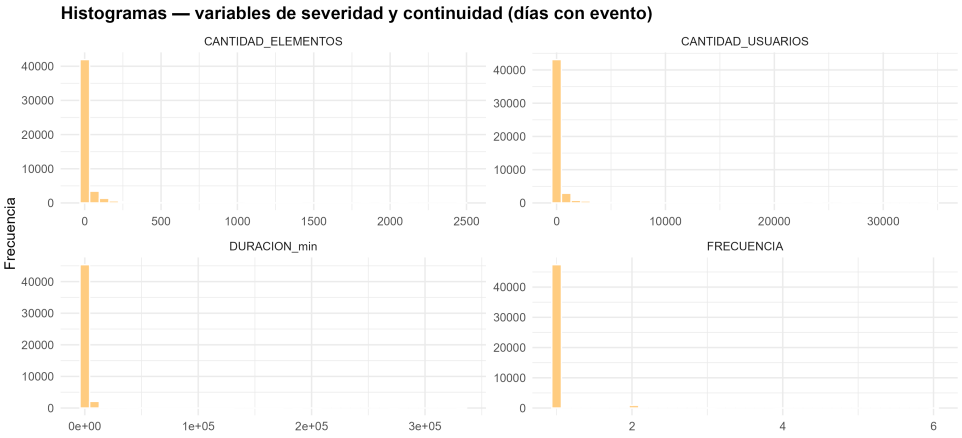


Figura A.6: Distribución de la severidad y continuidad en días con evento: forma y cola.

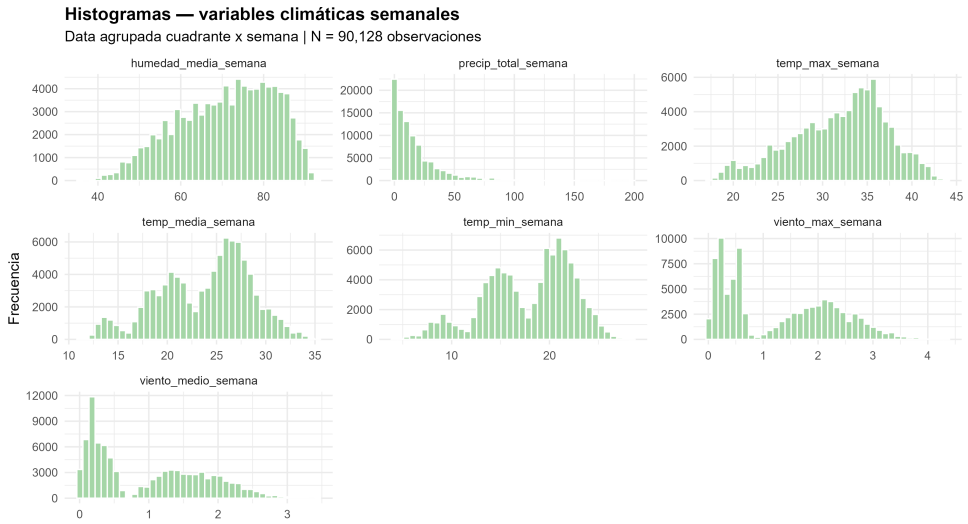


Figura A.7: Distribución de las variables climáticas semanales: forma y cola ($N_{\text{agr}} = 90\,128$).

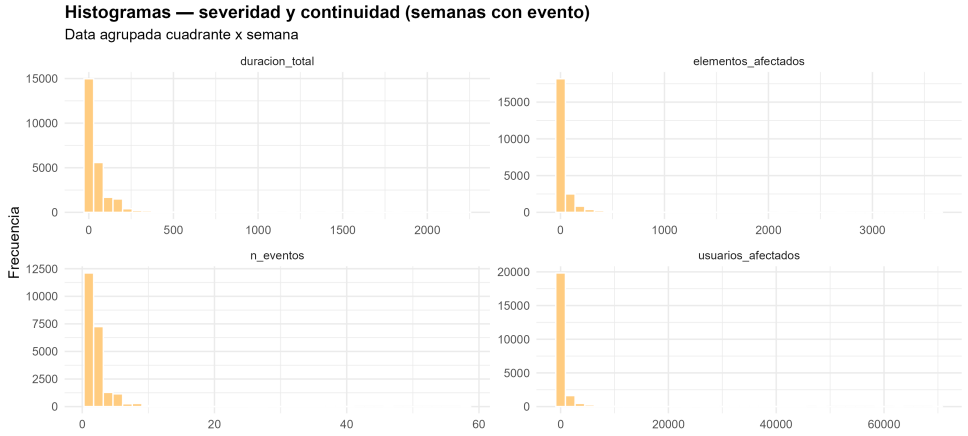


Figura A.8: Distribución de la severidad y continuidad en semanas con evento: forma y cola.

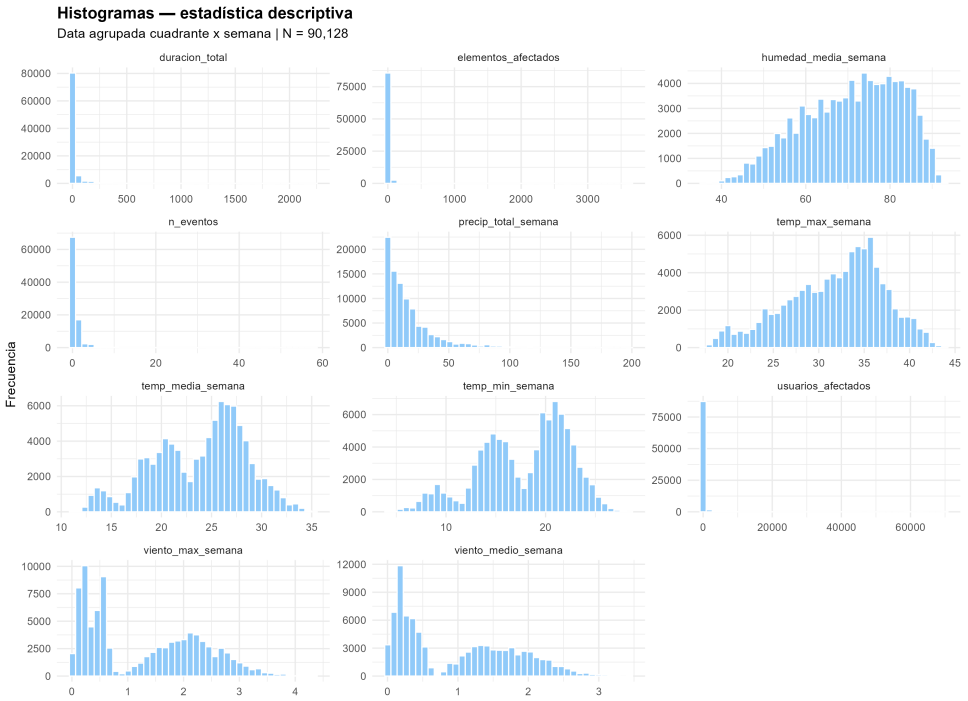


Figura A.9: Distribución de las variables numéricas de la tabla agrupada: forma y cola ($N_{\text{agr}} = 90\,128$).

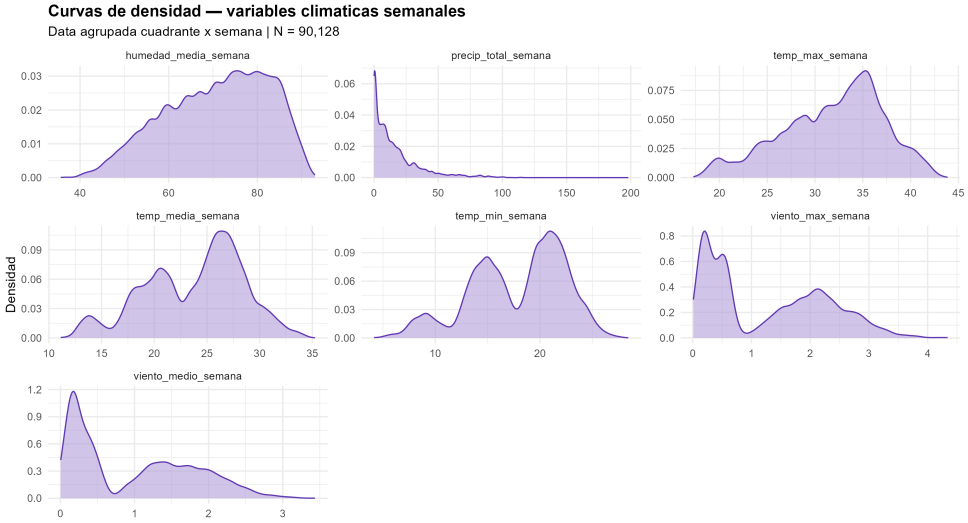


Figura A.10: Forma de la distribución de las variables climáticas semanales ($N_{\text{agr}} = 90\,128$).

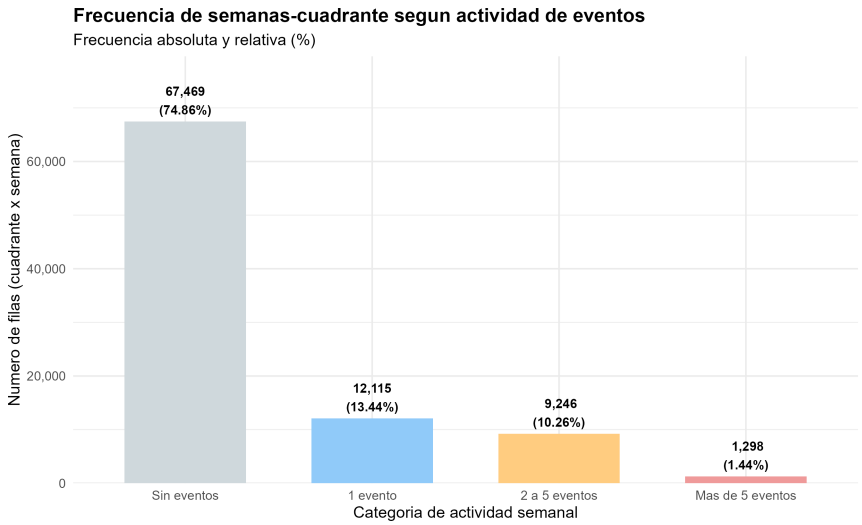


Figura A.11: Frecuencia de semanas-cuadrante según actividad de eventos ($N_{\text{agr}} = 90\,128$).

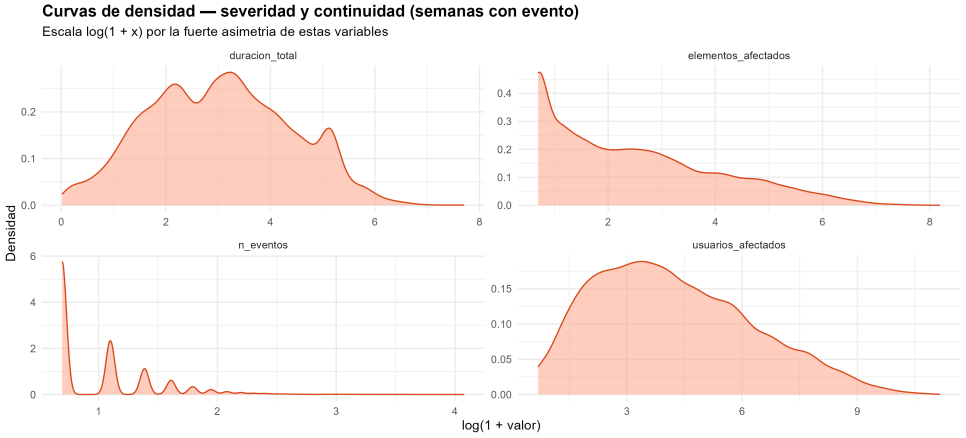


Figura A.12: Distribución de la severidad y continuidad en escala logarítmica desplazada (semanas con evento).

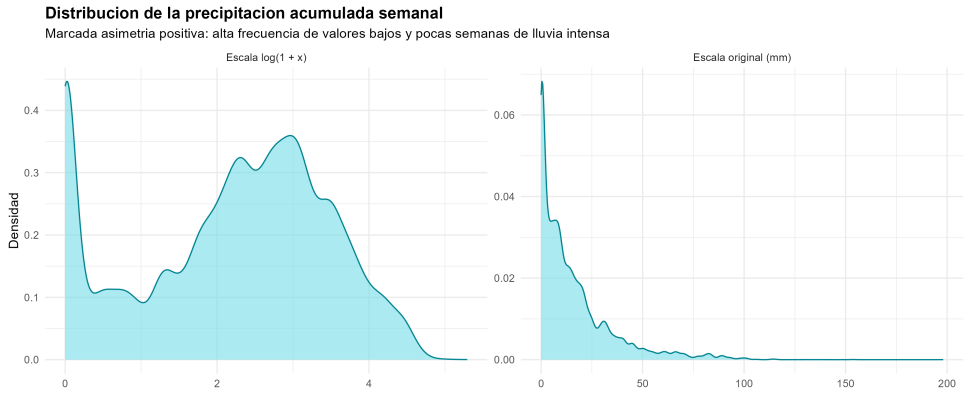


Figura A.13: Distribución de la precipitación acumulada semanal en escala original y logarítmica desplazada ($N_{\text{agr}} = 90\,128$).

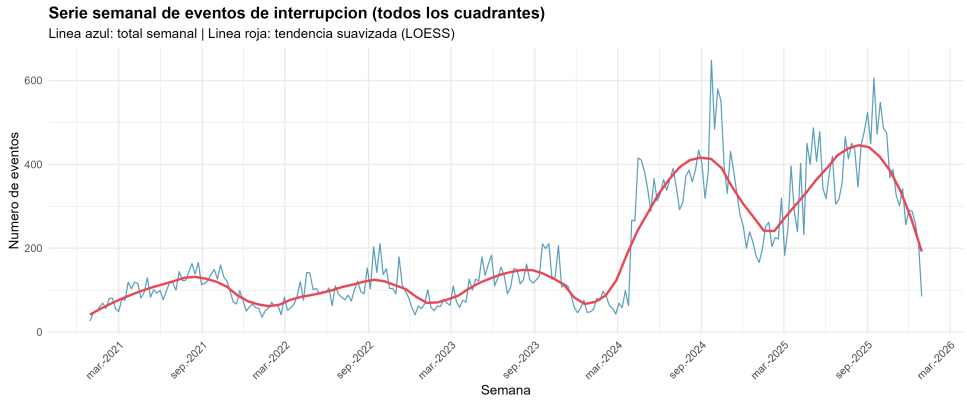


Figura A.14: Evolución semanal de los eventos de interrupción (suma territorial), 2021–2025.

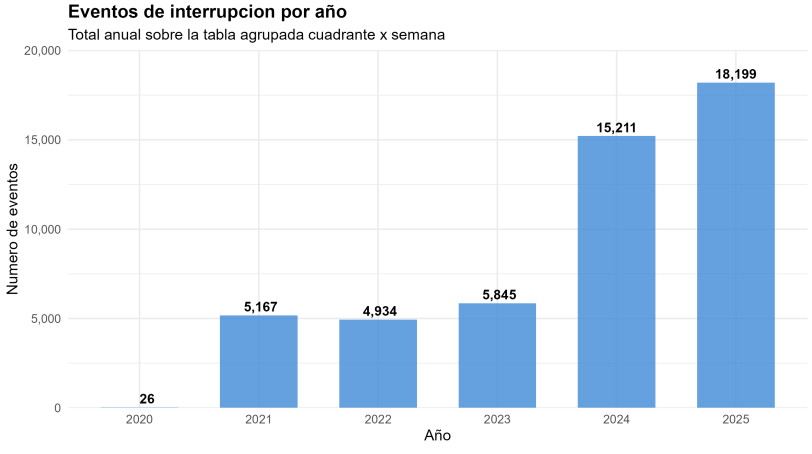


Figura A.15: Total anual de eventos de interrupción sobre la tabla agrupada.

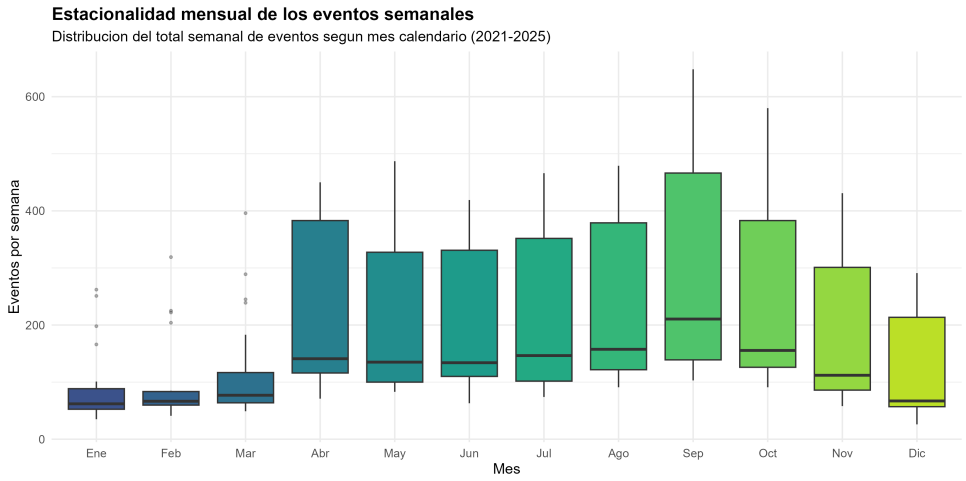


Figura A.16: Distribución del total semanal de eventos según mes calendario (2021–2025).

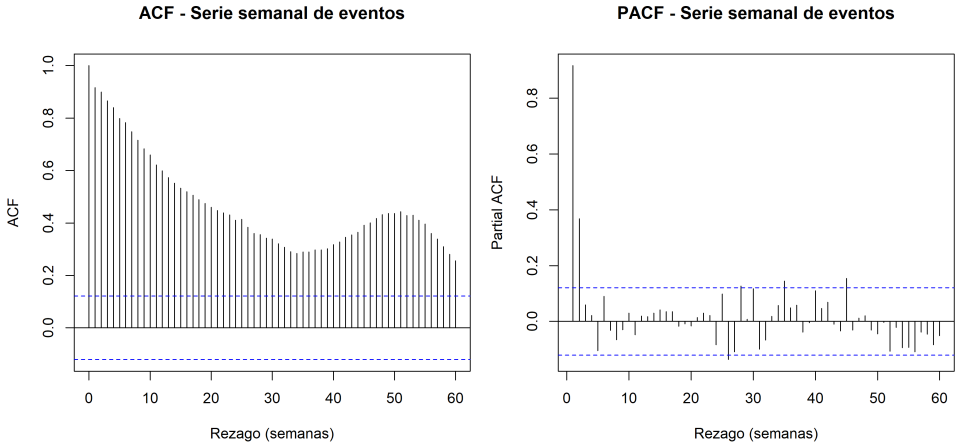


Figura A.17: Persistencia y estructura temporal de la serie semanal de eventos (rezagos en semanas).

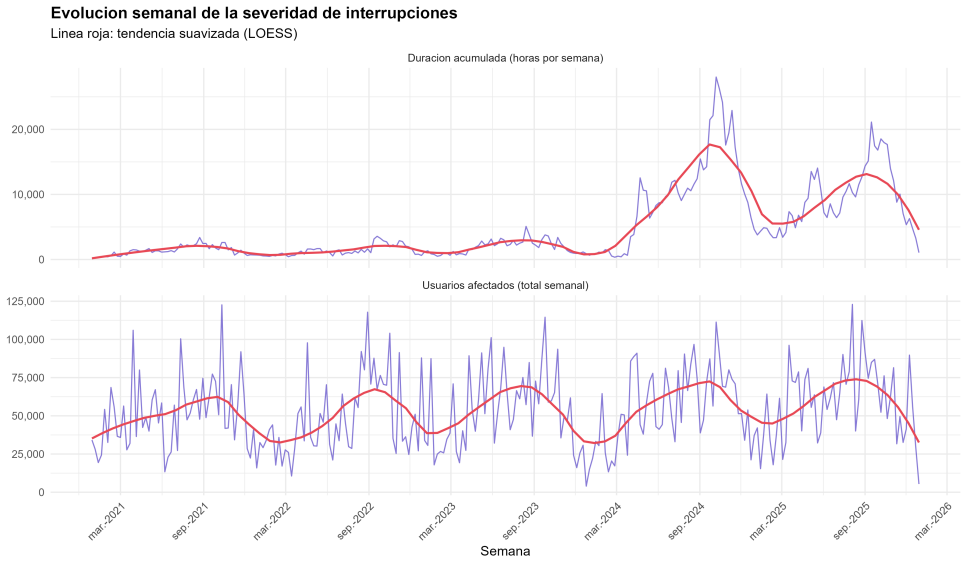


Figura A.18: Evolución semanal de usuarios afectados y duración acumulada.

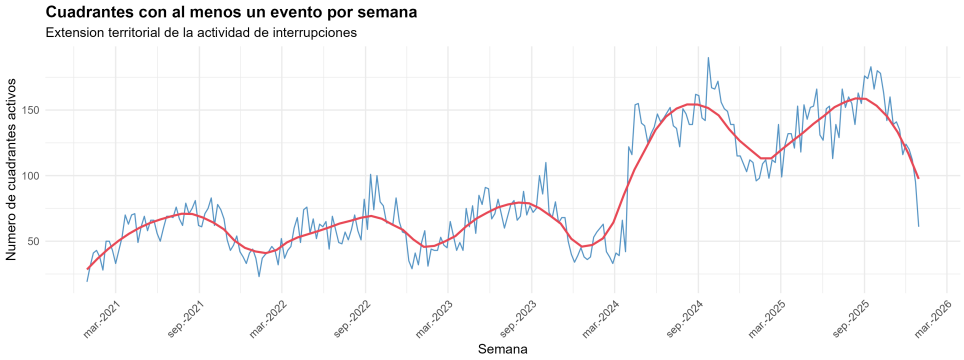


Figura A.19: Número de cuadrantes con al menos un evento por semana (extensión territorial de la actividad).

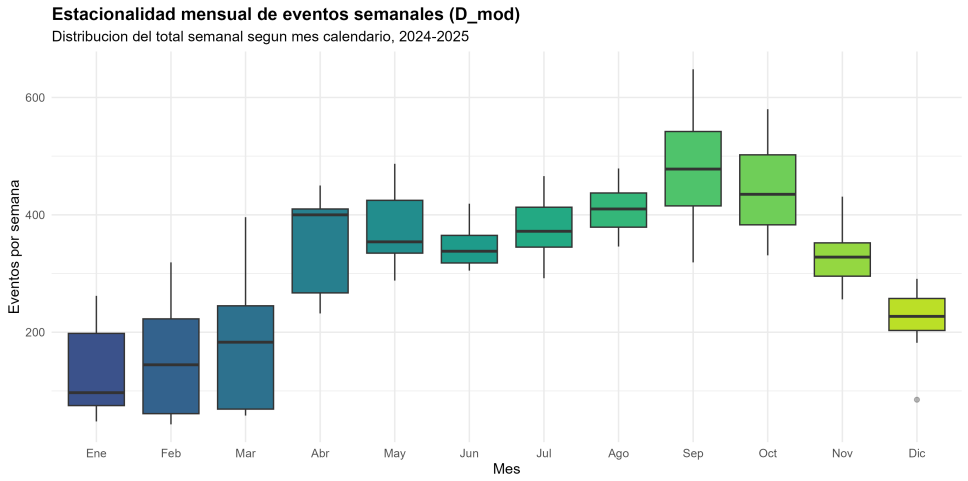


Figura A.20: Estacionalidad mensual del total semanal de eventos en D_{mod}.

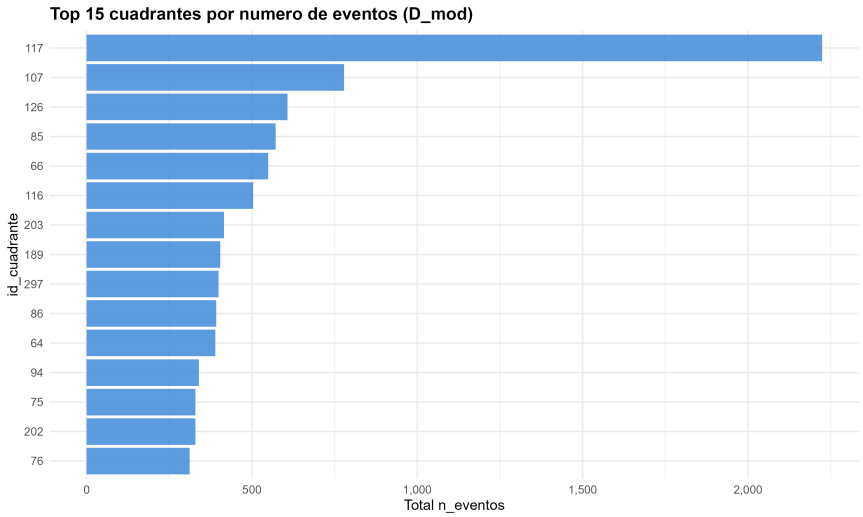


Figura A.21: Quince cuadrantes con mayor número acumulado de eventos en D_{mod}.

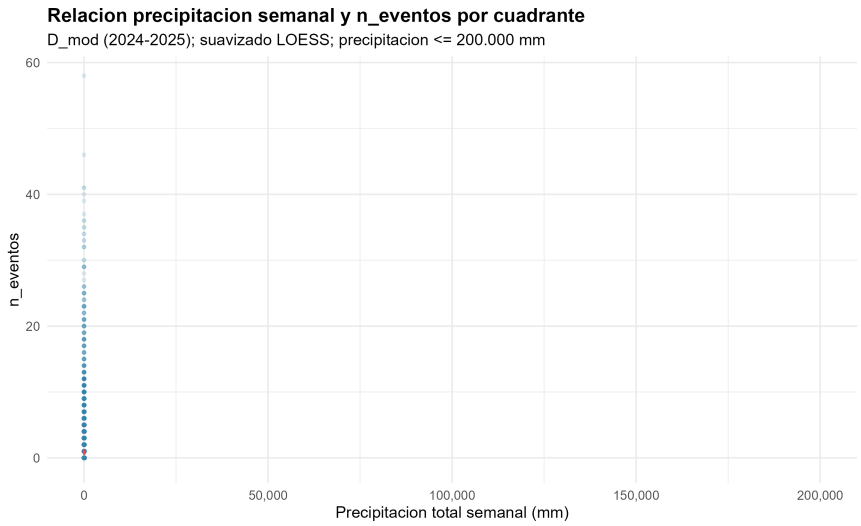


Figura A.22: Relación entre precipitación semanal y frecuencia de eventos por cuadrante en D_{mod}.

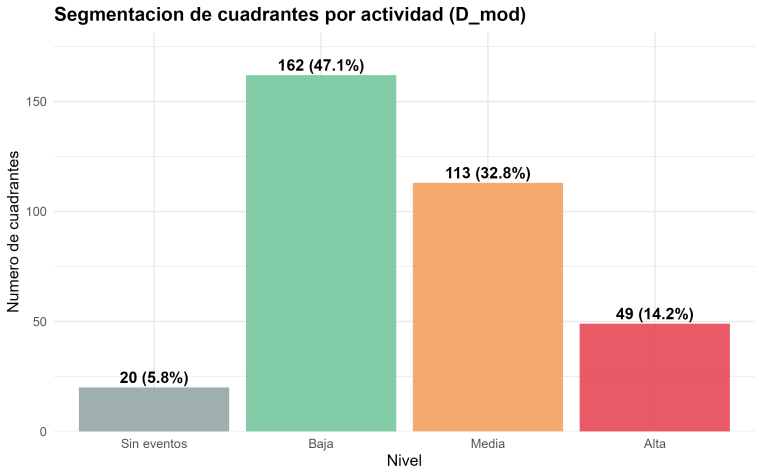


Figura A.23: Segmentación de cuadrantes por nivel de actividad acumulada en D_{mod}.

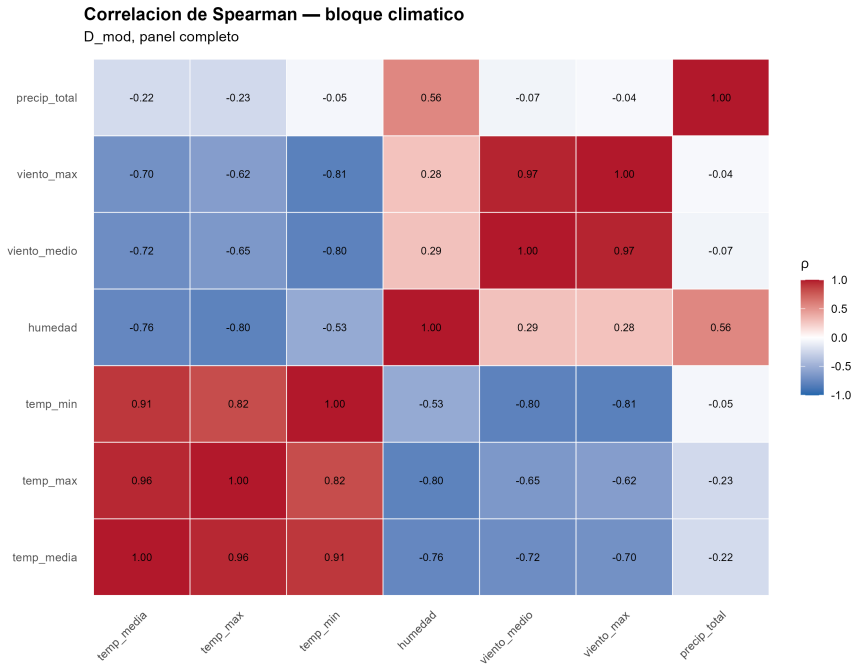


Figura A.24: Correlaciones de Spearman en el bloque climático semanal (D_{mod}).

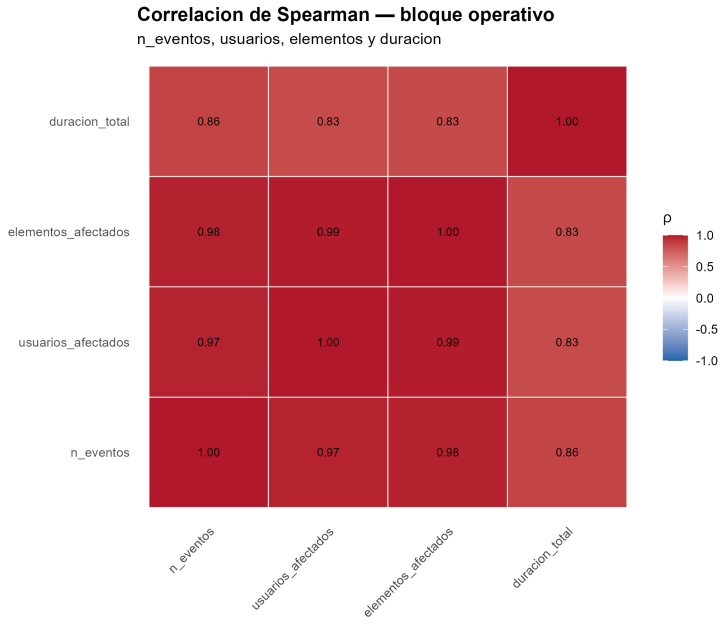


Figura A.25: Correlaciones de Spearman entre variables operativas en D_{mod}.

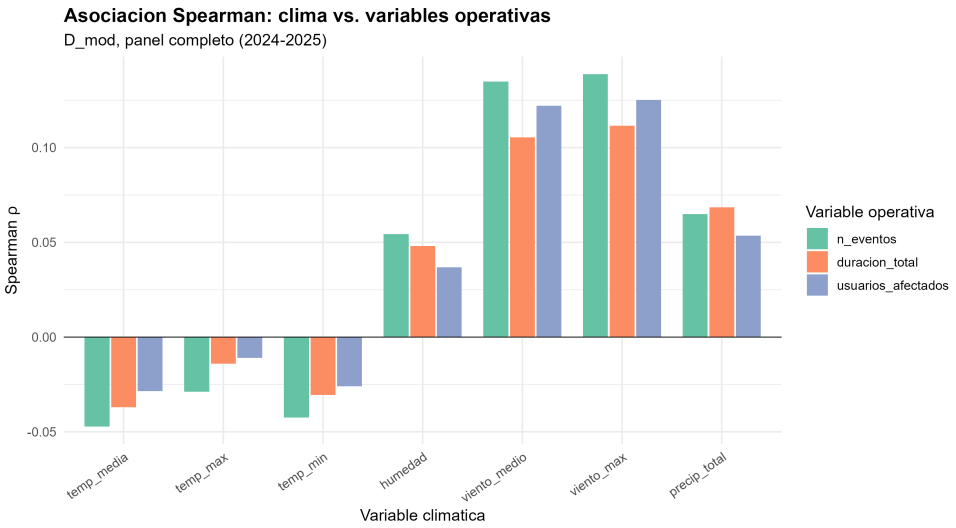


Figura A.26: Coeficientes de Spearman entre variables climáticas y operativas en D_{mod}.

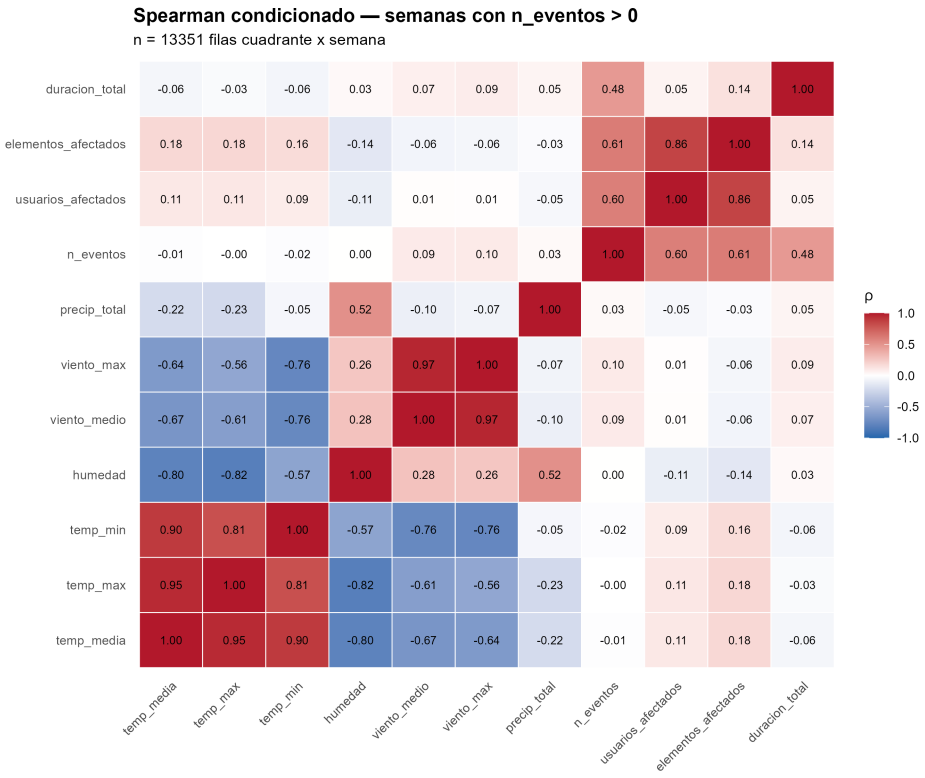


Figura A.27: Correlaciones de Spearman en semanas-cuadrante con `n_eventos` > 0 ($n = 13\,351$).

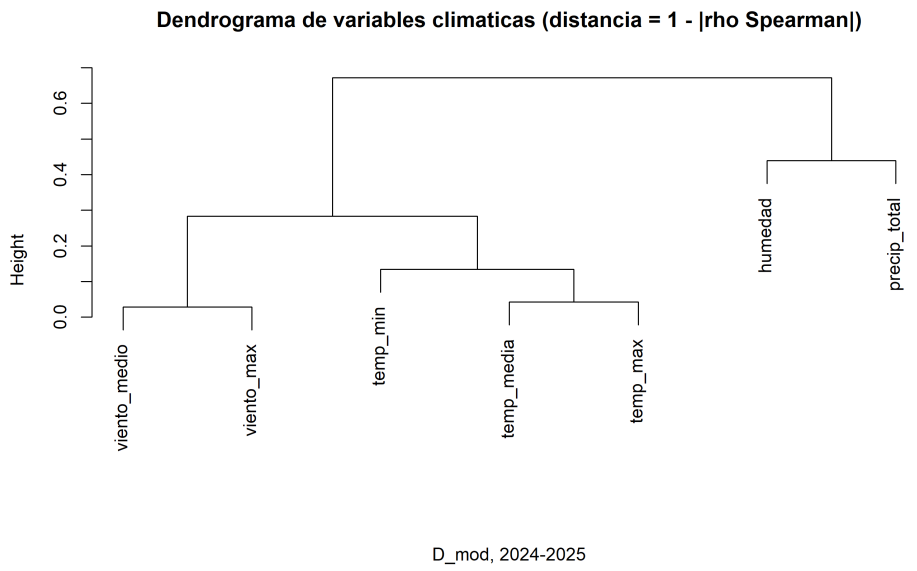


Figura A.28: Agrupamiento de redundancias entre variables climáticas (Sección 3.1.2).

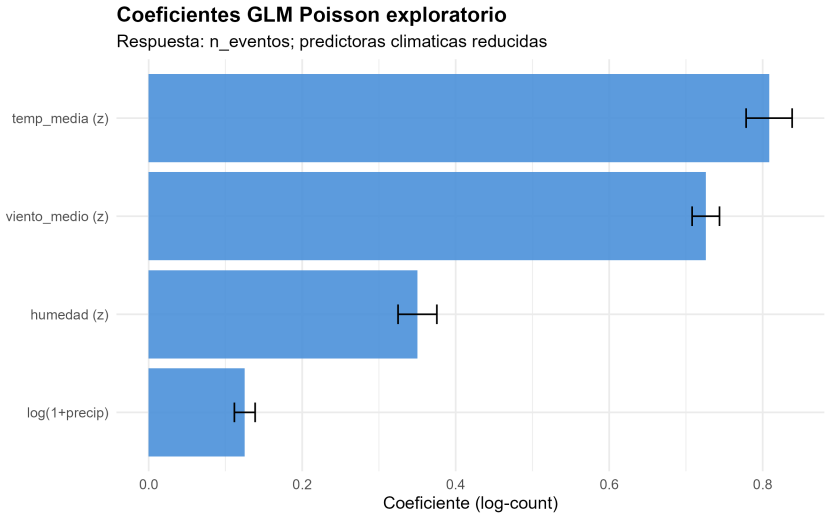


Figura A.29: Efecto conjunto del clima reducido sobre la frecuencia de eventos (diagnóstico EDA).

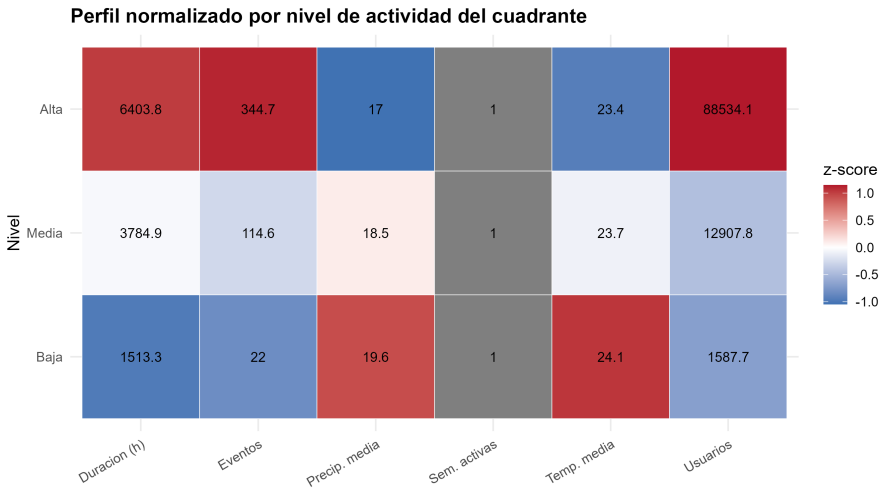


Figura A.30: Perfil normalizado por nivel de actividad (eventos, usuarios, duración, semanas activas, clima).

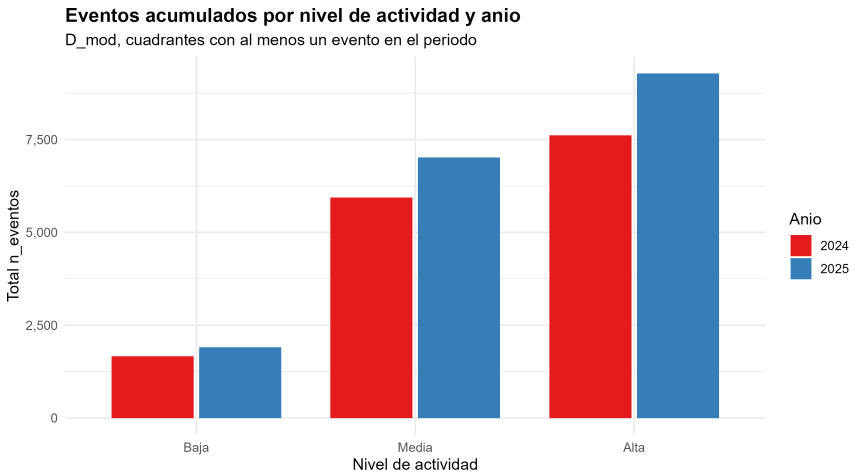


Figura A.31: Eventos acumulados por nivel de actividad y año en D_{mod}.

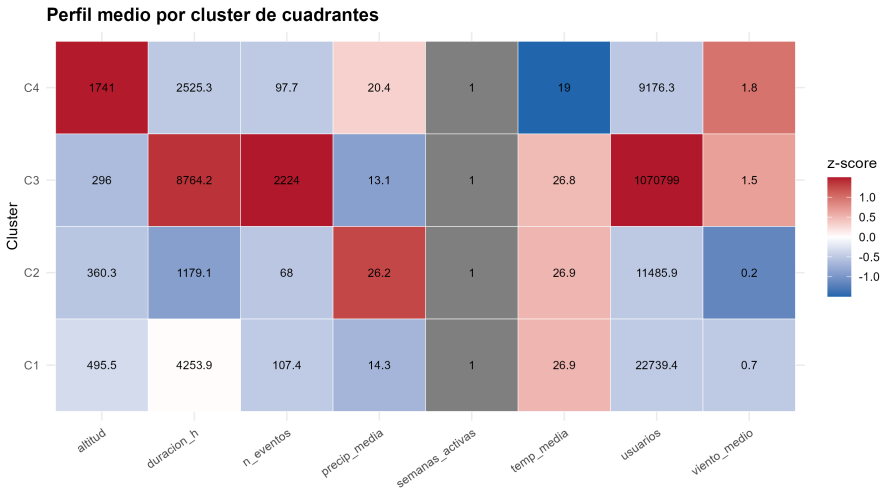


Figura A.32: Perfil medio por cluster de cuadrantes (variables operativas y climáticas).

A.10. Análisis de componentes principales (PCA) exploratorio

El equipo realizó un ejercicio de PCA exploratorio sobre los bloques climático y operativo de D_{mod}, documentado en detalle a continuación. Se trató de un diagnóstico de redundancia entre covariables, no de una técnica de reducción de dimensionalidad empleada para construir predictoras: ninguna componente principal se utilizó como insumo de los modelos de la Etapa 5. Las decisiones de selección de variables se basaron, en cambio, en el VIF y en el agrupamiento jerárquico presentados en la Sección 6.3.8.

A.10.1. PCA exploratorio del bloque climático

Variables de entrada. Ingresan las siete variables climáticas semanales de D_{mod} ($n = 36\,120$ filas cuadrante $\times$ semana; $p = 7$): `temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`, `viento_medio_semana`, `viento_max_semana` y `precip_total_semana`.

Condiciones de aplicación. Las siete son cuantitativas continuas; $n \gg p$; no hay faltantes en D_{mod}; y se homogenizan mediante estandarización (z-scores) porque tienen distintas unidades (°C, %, m/s, mm). El PCA se ejecuta sobre la matriz de correlaciones implícita en la estandarización (`prcomp` sobre la matriz centrada y escalada).

Varianza retenida y pesos (loadings). Las dos primeras componentes condensan el 87.3 % de la varianza (PC1: 66.9 %; PC2: 20.4 %) y PC3 aporta un 8.3 % adicional (acumulado 95.6 %; Figura A.33a). La Tabla A.14 y la Figura A.33b reportan las cargas:

- *PC1 (eje térmico–viento):* dominan las temperaturas (`temp_media_semana` 0.45, `temp_max_semana` 0.43, `temp_min_semana` 0.43), con cargas negativas de viento (`viento_medio_semana` -0.40, `viento_max_semana` -0.39). La precipitación es irrelevante en este eje (-0.08).
- *PC2 (eje de humedad–lluvia):* la variable más importante es `precip_total_semana` (0.70), seguida de `humedad_media_semana` (0.51).
- *PC3:* contrastan precipitación (-0.66) y viento máximo (-0.43) frente a humedad (0.32), con contribución adicional del viento medio (-0.37).

En síntesis, las temperaturas (y, en sentido opuesto, el viento) concentran el peso en PC1, mientras la precipitación concentra su importancia en PC2–PC3,

resultado coherente con el VIF y el dendrograma presentados en el cuerpo del documento.

Tabla A.14: Cargas (loadings) del PCA climático: peso de cada variable por componente (D_{mod}; PC1–PC3)

Variable	PC1	PC2	PC3
`temp_media_semana`	0.45	−0,07	−0,22
`temp_max_semana`	0.43	−0,12	−0,28
`temp_min_semana`	0.43	0.11	−0,10
`humedad_media_semana`	−0,33	0.51	0.32
`viento_medio_semana`	−0,40	−0,33	−0,37
`viento_max_semana`	−0,39	−0,33	−0,43
`precip_total_semana`	−0,08	0.70	−0,66

Nota: se destacan como relevantes en la interpretación las cargas con valor absoluto ≥ 0.40.

A.10.2. PCA exploratorio del bloque operativo

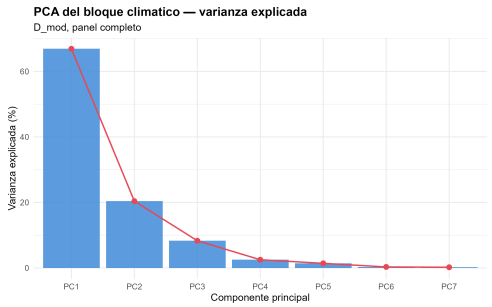
De forma análoga, se aplicó un PCA exploratorio al bloque operativo de D_{mod} para delimitar dimensiones de impacto, no para construir predictoras. Ingresan las cuatro métricas `n_eventos`, `usuarios_afectados`, `elementos_afectados` y `duracion_total` ($n = 36\,120$; $p = 4$), tras transformación logarítmica desplazada y estandarización, dadas la cero-inflación, la asimetría y las distintas escalas.

PC1 concentra el $83.8\,\%$ de la varianza, con cargas elevadas y del mismo signo en las cuatro variables (Tabla A.15; Figura A.33c): las más importantes son `usuarios_afectados` (0.53) y `n_eventos` (0.52), seguidas de `elementos_afectados` (0.50) y `duracion_total` (0.45). PC2 ($11.9\,\%$; acumulado $95.7\,\%$) contrasta duración (0.81) frente a afectación (`elementos_afectados` -0.48; `usuarios_afectados` -0.33). Este resultado, junto con la evaluación multivariada del cuerpo del documento, respalda no emplear simultáneamente las cuatro variables operativas como respuestas ni como predictoras, y construir $SAIFI$ y $SAIDI$ en la Etapa 4 a partir de `usuarios_afectados` y `duracion_total`.

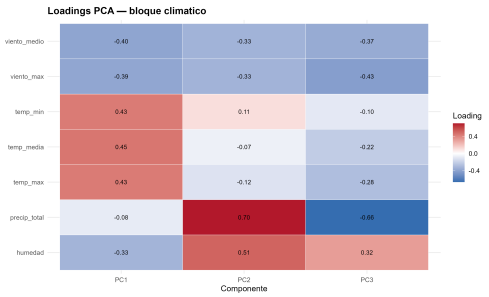
Tabla A.15: Cargas (loadings) del PCA operativo en escala logarítmica desplazada (D_{mod}; PC1–PC2)

Variable	PC1	PC2
`n_eventos`	0.52	0.09
`usuarios_afectados`	0.53	−0,33
`elementos_afectados`	0.50	−0,48
`duracion_total`	0.45	0.81

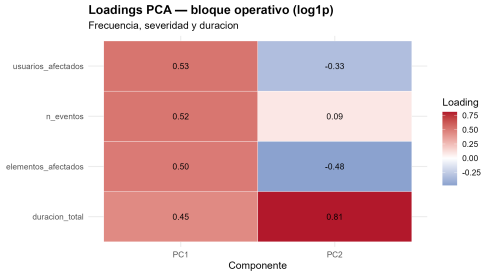
Nota: se interpretan como relevantes las cargas con valor absoluto ≥ 0.40.



(a) Varianza acumulada del bloque climático por componente principal.



(b) Peso (loadings) de las variables climáticas en las tres primeras componentes principales.



(c) Peso (loadings) de frecuencia, afectación y duración en las dos primeras componentes del bloque operativo.

Figura A.33: Figuras del PCA exploratorio climático y operativo.