



Pontificia Universidad
JAVERIANA
Cali

[REGISTRADA MINEDUCACIÓN No. 12226 de 2016]

PONTIFICIA UNIVERSIDAD JAVERIANA CALI
FACULTAD DE INGENIERÍA Y CIENCIAS.
MAESTRÍA EN CIENCIA DE DATOS

Metodología Basada en Métodos de Ciencia de Datos para Predecir los Indicadores de Calidad del Servicio (SAIDI y SAIFI) en Redes de Distribución de una Empresa de Energía Eléctrica en el Norte de Santander

Edwin Henao Ochoa

Cindy Lugo Rozo

Edwin Silva Salas

DIRECTOR

Sandra Milena Ramírez Buelvas

Pontificia Universidad Javeriana



A nuestras familias y amigos

Edwin Henao Ochoa

Cindy Lugo Rozo

Edwin Silva Salas

Índice general

Resumen	ix
1 Definición del problema	1
1.1 Planteamiento del problema	1
1.1.1 Planteamiento del problema	1
1.2 Formulación del problema	4
1.2.1 Pregunta general	4
1.2.2 Preguntas específicas	4
2 Objetivos del proyecto	5
2.1 Objetivo general	5
2.2 Objetivos específicos	5
3 Marco de referencia	7
3.1 Contexto empresarial	7
3.2 Marco teórico	7
3.2.1 Definición del SAIDI según la Resolución CREG 015 de 2018	7
3.2.2 Definición del SAIFI según la Resolución CREG 015 de 2018	8
3.2.3 Interpretación de los indicadores	9
3.2.4 Meta de calidad media del SAIDI	9
3.2.5 Dimensión social y económica	10
3.2.6 Exclusiones de eventos	10
3.2.7 Factores que afectan los indicadores	11
3.3 Antecedentes	11
3.3.1 Revisión de literatura	11
4 Datos	15
4.1 Tiempo o periodo de estudio	15
4.2 Unidad muestral	15
4.3 Construcción del dataset	15
4.3.1 Lógica estructural	15
4.3.2 Definición de variables de evento	16
4.3.3 Estructura del dataset consolidado	16
4.4 Numero de observaciones:	17
4.5 Origen de la información:	17

4.6	Lugar donde se registra la información:	18
5	Metodología	19
5.1	Etapla 1 – Extracción de datos	19
	Fuentes de informacion	20
5.1.1	Sistemas y fuentes consultadas	20
5.1.2	Extracción base y depuración de eventos de interrupción (BRAE)	20
5.1.3	Extracción de afectación por evento	22
5.1.4	Extracción del elemento causante histórico	23
5.1.5	Extracción del elemento causante actual	24
5.1.6	Extracción de inventario GIS	25
5.1.7	Extracción de variables meteorológicas	27
5.1.8	Resumen metodológico de extracción e integración de bases de datos	28
5.2	Etapla 2 - Integración y depuración de datos	29
5.2.1	Lógica de integración entre sistemas	29
5.2.2	Diagrama de flujo de la secuencia de integración	33
5.2.3	Descripción de la tabla base consolidada	33
5.2.4	Descripción de las variables	35
	Tabla 5.9 (severidad y clima inicial).	36
	Tabla 5.10 (clima complementario).	37
	Tabla 5.11 (variables de continuidad).	37
5.2.5	Agrupación de data consolidada por semana y cuadrante	38
	Definición del grano analítico (cuadrante $\times$ semana) . . .	38
	Procedimiento de agregación	39
5.2.6	Descripción de la tabla base semanal cuadrante	40
5.2.7	Evidencia de calidad y confiabilidad de las fuentes	43
5.3	Etapla 3 – Análisis descriptivo y exploratorio de datos (EDA) . . .	44
5.3.1	Identificación de datos faltantes	45
	Tabla agrupada cuadrante $\times$ semana.	46
5.3.2	Identificación de valores extremos en variables cuantitativas	47
	Panel consolidado activo $\times$ día.	48
	Tabla agrupada cuadrante $\times$ semana.	48
5.3.3	Cálculo de estadísticos descriptivos	51
	Variables climáticas.	52
	Altitud.	53
	Variables de severidad y continuidad en el panel completo.	53
	Variables de severidad y continuidad en días con evento.	54
	Variable categórica TIPO.	55
	Patrón temporal de días con interrupción.	56
5.3.4	Análisis de la distribución de variables	58

5.3.5	Análisis temporal de eventos	58
5.3.6	Identificación de patrones y tendencias	58
5.3.7	Visualización exploratoria	58
5.3.8	Análisis de correlación y asociación	58
5.3.9	Evaluación inicial de relaciones multivariadas	58
5.3.10	Segmentación exploratoria	58
5.3.11	Resultados y entregables de la etapa	58
5.4	Etapa 4 – Ingeniería de variables y preparación del modelo	58
5.4.1	Construcción de variables predictoras	59
5.4.2	Construcción de la variable respuesta	59
5.4.3	Análisis de asociación y depuración de variables cuantitativas	59
5.4.4	Análisis de asociación y depuración de variables cualitativas	59
5.4.5	Codificación de variables categóricas	59
5.4.6	Estandarización de variables cuantitativas	59
5.4.7	Generación de ventanas temporales	59
5.4.8	Partición de datos en entrenamiento y prueba	59
5.4.9	Construcción de matrices de diseño	59
5.4.10	Reducción de dimensionalidad	59
5.4.11	Segmentación analítica	59
5.4.12	Transformaciones adicionales para modelado	59
5.4.13	Resultados y entregables de la etapa	59
5.5	Etapa 5 – Modelado predictivo y evaluativo	59
5.5.1	Selección de algoritmos	60
5.5.2	Entrenamiento del modelo	60
5.5.3	Validación del modelo	60
5.5.4	Ajuste de hiperparámetros	60
5.5.5	Evaluación de desempeño	60
5.5.6	Comparación de modelos	60
5.5.7	Interpretación de resultados	60
5.5.8	Resultados y entregables de la etapa	60
5.6	Etapa 6 – Cierre metodológico, documentación y reportes	60
5.6.1	Presentación de resultados del modelo	61
5.6.2	Métricas de desempeño	61
5.6.3	Hallazgos principales	61
5.6.4	Interpretación técnica y operativa	61
5.6.5	Generación de reportes	61
5.6.6	Discusión de resultados	61
5.6.7	Limitaciones y trabajos futuros	61
5.6.8	Resultados y entregables de la etapa	61
6	Resultados	63
6.1	Resultados de la estimación del modelo	63

7	Discusión y trabajo futuro	65
7.1	Discusión	65
7.2	Trabajos futuros	65
8	Conclusiones	67
8.1	Conclusión asociada al objetivo general	67
8.2	Conclusión asociada al objetivo específico 1	67
8.3	Conclusión asociada al objetivo específico 2	67
8.4	Conclusión asociada al objetivo específico 3	67
A	Appendix	75
A.1	Parte 1	75
A.2	Parte 2	75

Resumen

En este estudio se desarrolla una metodología basada en el estándar CRISP-DM para la predicción de dos indicadores fundamentales de la calidad del servicio eléctrico: SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema), aplicados a las redes de distribución de una empresa ubicada en el departamento de Norte de Santander. Actualmente, la operación del sistema se apoya en múltiples plataformas heterogéneas, tales como SCADA, OMS, GIS, CIS e información climática proveniente del IDEAM, cuyos registros operativos no siempre son fácilmente interpretables ni consistentes entre sí, lo que puede generar conflictos relevantes frente al cumplimiento de la regulación vigente. En este contexto, el objetivo del estudio consiste en integrar y armonizar estas fuentes de información en un sistema analítico unificado que permita identificar cuáles variables técnicas, operativas y climáticas influyen de manera significativa en el comportamiento de los indicadores, con el fin de evaluar distintos modelos predictivos a nivel de circuito. La metodología propuesta se estructura en cuatro etapas principales: (i) integración y estandarización de las fuentes de datos, (ii) desarrollo de un análisis exploratorio detallado, (iii) selección de variables relevantes y (iv) comparación de métodos estadísticos y de aprendizaje automático, incluyendo enfoques supervisados, no supervisados e híbridos, definidos a partir del conocimiento obtenido en el análisis exploratorio. El desempeño de los modelos se evalúa mediante métricas de error ampliamente utilizadas en tareas de pronóstico, tales como MAE, RMSE y MAPE. Como resultado del proceso metodológico, se generarán códigos reproducibles implementados en cuadernos computacionales y contenedores, un documento con el análisis exploratorio integral, un informe comparativo de modelos y un reporte final que identifique las variables con mayor capacidad explicativa sobre SAIDI y SAIFI. En términos aplicados, esta estrategia busca reducir las interrupciones no programadas mediante la identificación temprana de circuitos críticos, optimizar la asignación de recursos hacia mantenimiento preventivo basado en evidencia empírica y fortalecer el cumplimiento de los lineamientos regulatorios establecidos por la CREG y la SSPD, contribuyendo así a mejorar la confiabilidad del servicio eléctrico para más de 600 000 usuarios en la región.

Sin duda, la energía eléctrica es vital para el progreso de cada región, tanto social, económica como industrialmente. En Colombia, el acceso a este servicio está estrictamente regulado en términos de provisión, con el objetivo de asegurar que todos los usuarios cuenten con un suministro de energía constante, seguro y de alta calidad para vivir y trabajar. Los operadores de red, en realidad, tienen de manera continua la responsabilidad de garantizar que la entrega de energía sea

confiable para hogares, instituciones y negocios, evitando fallas en la prestación del servicio en cualquier tipo de edificación.

No obstante, esta tarea no es sencilla. La operación de los sistemas de distribución de energía se ve afectada por múltiples factores técnicos, ambientales y operativos, así como por la duración y frecuencia de las interrupciones del servicio. En este contexto, la Comisión de Regulación de Energía y Gas (CREG) adoptó los indicadores SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) como los criterios oficiales para evaluar la calidad del servicio en las redes de distribución, mediante la Resolución CREG 015 de 2018 [1]. Estos indicadores permiten evaluar el desempeño operativo y facilitan la implementación de esquemas de compensación y control por parte de la Superintendencia de Servicios Públicos Domiciliarios (SSPD) [2].

Sin embargo, la gestión efectiva de estos indicadores ha resultado compleja, dada la heterogeneidad de los eventos que originan las interrupciones y la limitada conectividad de la información almacenada en sistemas dispares como SCADA, OMS, GIS, CIS y bases de datos externas. Debido a que los registros operativos, climáticos y de mantenimiento se encuentran dispersos y fragmentados en múltiples plataformas, construir modelos analíticos capaces de predecir interrupciones y describir el comportamiento de SAIDI y SAIFI en distintas áreas o circuitos representa un desafío significativo.

Esta brecha limita la capacidad de las empresas para tomar decisiones oportunas, priorizar inversiones, mejorar la planificación del mantenimiento y responder adecuadamente a los requerimientos regulatorios. En consecuencia, resulta fundamental desarrollar herramientas apoyadas en ciencia de datos que permitan consolidar información histórica, identificar patrones relevantes y predecir la dinámica de la calidad del servicio.

Este trabajo presenta técnicas para la recopilación de datos provenientes de plataformas operativas internas y fuentes externas, así como el análisis de modelos estadísticos y de aprendizaje automático orientados al pronóstico de los indicadores SAIDI y SAIFI en una empresa de distribución de energía que opera en el departamento de Norte de Santander. Al adoptar esta estrategia, se busca no solo anticipar el comportamiento futuro de los indicadores, sino también identificar las influencias técnicas, operativas y climáticas más relevantes en la continuidad del servicio. Este desarrollo constituye una contribución significativa para fortalecer la toma de decisiones basada en evidencia, optimizar los planes de mantenimiento, apoyar el cumplimiento regulatorio y ofrecer un caso académico aplicado sobre el uso de técnicas analíticas en el sector eléctrico regulado, beneficiando a más de 600 000 usuarios.

Definición del problema

1.1. Planteamiento del problema

1.1.1. Planteamiento del problema

Los indicadores de continuidad del servicio SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) en la empresa de distribución objeto de estudio presentan dificultades estructurales para su mejora sostenida. Si bien existen técnicas estadísticas y de aprendizaje automático ampliamente documentadas para el análisis de interrupciones en sistemas eléctricos, la principal limitación no radica en la ausencia de metodologías analíticas, sino en la calidad, estructura e interpretación de los datos disponibles, lo que dificulta el entrenamiento de modelos predictivos que sean simultáneamente confiables y explicativos [1], [2], [3]. En particular, resulta complejo detectar, cuantificar y explicar no solo las causas de las interrupciones, sino también su duración y los tiempos de restauración del servicio.

Los principales obstáculos identificados son los siguientes:

- **Fragmentación de las fuentes de información:** La operación del sistema requiere el uso de múltiples registros provenientes de plataformas heterogéneas como SCADA, OMS, GIS, CIS, bases de mantenimiento y fuentes meteorológicas externas. Estos datos se encuentran en distintos formatos, con estructuras disímiles y, en algunos casos, con ausencia de metadatos completos, lo que dificulta su integración sin pérdida de trazabilidad [4], [5].
- **Problemas de sincronización temporal:** Los sistemas operativos no presentan una alineación temporal uniforme. Mientras algunos registran información en intervalos horarios, otros lo hacen en escalas de minutos o presentan series discontinuas. Esta falta de sincronización genera inconsistencias que afectan la estimación precisa de la duración de las interrupciones y de los tiempos de reposición del servicio [4], [6].
- **Eventos extremos y ruido en los datos:** Los registros contienen alta va-

riabilidad, errores de captura, información incompleta y eventos atípicos, como fenómenos climáticos extremos o fallas excepcionales, que suelen ser excluidos del análisis. Esta situación dificulta la identificación de patrones robustos tanto a nivel agregado como local [1], [7].

- **Pérdida de detalle por agregación:** El uso de indicadores promediados en escalas anuales o geográficas amplias oculta el comportamiento específico de circuitos o zonas particulares, lo que limita la identificación de causas operativamente accionables [2], [6].
- **Ausencia de estándares de datos:** La falta de catálogos de datos, definiciones homogéneas y métricas de integridad impide evaluar de manera sistemática si las fuentes disponibles son adecuadas para la construcción de modelos predictivos confiables [4], [5].
- **Restricciones regulatorias:** Los organismos de control exigen que los resultados sean trazables y explicables. En consecuencia, no es suficiente emplear modelos con alto desempeño predictivo; estos deben ser interpretables y compatibles con los requerimientos de reporte regulatorio, lo que condiciona el tipo de metodologías que pueden adoptarse [2], [3].

Estos obstáculos reducen la capacidad de la organización para explicar la variación de los indicadores SAIDI y SAIFI, priorizar actividades operativas y cumplir con los requerimientos regulatorios mediante herramientas predictivas [3], [4], [7]. En términos cuantitativos, el SAIDI promedio de la empresa es de 22.43 horas por año, valor que se ubica un 4.64 % por debajo de la meta establecida por la CREG (23.522 horas por año). Para el indicador SAIFI, el promedio anual es de 6.5 eventos, significativamente inferior al objetivo regulatorio de 9 eventos por año, lo que representa una reducción del 27.78 % [8]. Estos resultados sugieren que la empresa se encuentra dentro de los límites regulatorios; sin embargo, la gestión de dichos indicadores enfrenta importantes desafíos operativos e informativos.

Las compensaciones anuales asociadas a calidad del servicio ascienden aproximadamente a \$5 mil millones de pesos, y el análisis de datos históricos de cinco años evidencia que cerca del 2 % de los registros presenta información faltante o inconsistente, como tiempos de evento no registrados, campos incompletos o desajustes temporales entre sistemas. Si bien la Circular 063 de 2019 de la SSPD establece criterios técnicos para la exclusión válida de eventos asociados a factores externos, como fuerza mayor o fallas del Sistema Nacional de Transmisión, la presencia de problemas de calidad de datos limita la capacidad de construir modelos predictivos sólidos, diagnosticar con precisión las causas de

las interrupciones y priorizar acciones operativas basadas en evidencia [1], [2], [3], [9].

Este problema no es exclusivo de la empresa analizada. En el sector eléctrico colombiano, la calidad del servicio constituye un desafío estructural. De acuerdo con el Informe de Calidad del Servicio de Energía Eléctrica de la SSPD 2023, el SAIDI promedio nacional fue de 16.83 horas por usuario, con valores que oscilaron entre 4.5 horas y más de 50 horas dependiendo del operador y de la región geográfica [10]. Esta dispersión refleja diferencias significativas en infraestructura, gestión operativa y exposición a condiciones climáticas extremas. Durante 2023, el 68 % de las interrupciones estuvo asociado a eventos externos, como contacto con vegetación, animales o terceros, mientras que el 24 % se atribuyó a fallas técnicas en equipos de red, evidenciando la naturaleza multicausal del problema [2].

El impacto regulatorio es considerable: en 2023, las compensaciones totales por incumplimiento de metas de calidad alcanzaron aproximadamente \$487 000 millones a nivel nacional, siendo los indicadores de continuidad responsables del 73 % de este valor [2]. Para operadores de red ubicados en zonas con alta exposición climática, como Norte de Santander, la problemática se intensifica. Según datos de la SSPD consolidados por la UPME, los eventos meteorológicos extremos incrementaron en un 35 % las interrupciones no programadas respecto al periodo 2019–2021 [2]. En este contexto, la dispersión de información en sistemas heterogéneos dificulta la identificación de patrones causales, la priorización del mantenimiento preventivo y la detección temprana de circuitos críticos, limitando la capacidad de las empresas distribuidoras para anticipar deterioros en la continuidad del servicio y cumplir de manera consistente con los objetivos regulatorios establecidos por la CREG.

1.2. Formulación del problema

1.2.1. Pregunta general

¿Qué variables técnicas, operativas y climáticas permiten predecir con mayor precisión los indicadores SAIDI y SAIFI a nivel de circuito o zona en la red de distribución de la empresa en Norte de Santander, y qué modelos estadísticos o de Machine Learning ofrecen mejor desempeño predictivo, capacidad de generalización e interpretabilidad operativa?

1.2.2. Preguntas específicas

- ¿Qué limitaciones estructurales, inconsistencias y problemas de calidad presentan las distintas fuentes de información (operativas, geográficas, administrativas y climáticas) utilizadas en la estimación de SAIDI y SAIFI, y cómo dichas limitaciones afectan la capacidad de representar adecuadamente el fenómeno de interrupciones en la red de distribución?
- ¿Qué patrones temporales, espaciales, estacionales y comportamientos atípicos caracterizan la variabilidad de SAIDI y SAIFI a nivel de circuito, y de qué manera estos patrones influyen en la comprensión del fenómeno de continuidad del servicio y en la identificación de los factores que explican sus fluctuaciones?
- ¿Qué tipos de ruido, sesgos, discrepancias u omisiones emergen al integrar información proveniente de SCADA, OMS, GIS, CIS y fuentes climáticas, y cómo estas discrepancias condicionan la validez, coherencia y trazabilidad de la información utilizada para caracterizar el comportamiento de los indicadores SAIDI y SAIFI?
- ¿Qué restricciones regulatorias, operativas y técnicas deben considerarse para garantizar que la caracterización del fenómeno de continuidad del servicio eléctrico sea trazable, interpretable y útil para la priorización de intervenciones, la gestión del riesgo operativo y el cumplimiento de los estándares de la CREG y la SSPD?

Objetivos del proyecto

2.1. Objetivo general

Lo que buscamos es mejorar nuestra capacidad para predecir cuándo van a ocurrir interrupciones eléctricas, cuánto van a durar y con qué frecuencia (todo esto medido con SAIDI y SAIFI) en la red de distribución de la empresa en Norte de Santander. Para lograrlo, vamos a integrar datos de diferentes fuentes de manera trazable y crear modelos predictivos que no solo funcionen bien, sino que también sean interpretables. La idea es que estos modelos nos den información útil tanto para priorizar el mantenimiento como para tomar mejores decisiones operativas y cumplir con lo solicitado por la autoridad competente.

2.2. Objetivos específicos

- Consolidar un repositorio analítico unificado y trazable que integre SCADA, OMS, GIS, CIS, registros de mantenimiento y datos climáticos, acompañado de un catálogo de datos y métricas de calidad que permitan evaluar la idoneidad de las fuentes para modelado predictivo.
- Caracterizar y cuantificar el comportamiento temporal y espacial de SAIDI y SAIFI en la zona de estudio (variabilidad, estacionalidad, efectos de agregación) y priorizar las variables técnicas, operativas y climáticas que expliquen su variación.
- Generar y validar modelos predictivos a nivel de circuito o zona que estimen probabilidad, duración y frecuencia de interrupciones, entregando medidas de desempeño (MAE, RMSE, MAPE u otras relevantes) y criterios de interpretabilidad aplicables por gestores.
- Producir artefactos reproducibles (notebooks, contenedores, documentación) y reportes técnicos alineados con los entregables del proyecto que faciliten la interpretación operativa y el uso de resultados en priorización de mantenimiento y reportes regulatorios.

Marco de referencia

3.1. Contexto empresarial

3.2. Marco teórico

Cuando hablamos de calidad del servicio eléctrico, nos referimos básicamente a entregar energía de forma segura y eficiente, cumpliendo con estándares regulatorios que garanticen continuidad, confiabilidad y estabilidad para todos los tipos de usuarios: residenciales, industriales, comerciales e institucionales. En Colombia, este servicio es esencial y por eso está regulado por la Comisión de Regulación de Energía y Gas (CREG) [3], que ha establecido métricas y estándares específicos para hacer seguimiento a cómo se presta el servicio. Entre estas métricas, dos son particularmente importantes: el SAIDI (*System Average Interruption Duration Index*) y el SAIFI (*System Average Interruption Frequency Index*).

3.2.1. Definición del SAIDI según la Resolución CREG 015 de 2018

La Resolución CREG 015 de 2018 define el SAIDI como:

La calidad media anual del OR se mide a través de los indicadores de duración y frecuencia de los eventos sucedidos en los SDL, que se establecen como se describe a continuación. El indicador SAIDI representa la duración total en horas de los eventos que en promedio percibe cada usuario del SDL de un OR, hayan sido o no afectados por un evento, en un período anual.

Se establece mediante la siguiente expresión:

$$SAIDI_{j,t} = \frac{\sum_{m=1}^{12} \sum_{i=1}^n D_{i,u,m} \times NU_{i,u,m}}{UT_{j,m} \times 60} \quad (3.1)$$

Donde:

- $SAIDI_{j,t}$: Indicador de duración promedio por usuario, de los eventos sucedidos en el SDL del OR j , durante el año t , medido en horas al año.

- $D_{i,u,m}$: Duración en minutos del evento i , sucedido durante el mes m , que afectó al activo u perteneciente al SDL del OR j .
- $NU_{i,u,m}$: Número de usuarios que fueron afectados por el evento i sucedido durante el mes m , conectados al activo u .
- $UT_{j,m}$: Número total de usuarios conectados al SDL del OR j en el mes m .
- m : Mes del año t , con enero = 1, ..., diciembre = 12.

3.2.2. Definición del SAIFI según la Resolución CREG 015 de 2018

La misma resolución define el SAIFI como:

“El indicador SAIFI representa la cantidad total de los eventos que en promedio perciben todos los usuarios del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:”

$$SAIFI_{j,t} = \frac{\sum_{m=1}^{12} \sum_{i=1}^n NU_{i,u,m}}{UT_{j,m}} \quad (3.2)$$

Donde:

- $SAIFI_{j,t}$: Indicador de frecuencia promedio por usuario, de los eventos sucedidos en el SDL del OR j , durante el año t , medido en cantidad al año.
- $NU_{i,u,m}$: Número de usuarios que fueron afectados por el evento i sucedido durante el mes m , por encontrarse conectados al activo u .
- $UT_{j,m}$: Número total de usuarios conectados al SDL del OR j en el mes m .
- m : Mes del año t , con enero = 1, ..., diciembre = 12.

Cada Operador de Red (OR) es responsable del cálculo de los indicadores de calidad del servicio. Para ello, debe utilizar la información reportada conforme a lo establecido en el numeral 5.2.11.3.2 de la Resolución CREG 015 de 2018, así como la información de vinculación definida en el literal a) del numeral 5.2.10 [1]. Esta disposición garantiza que el cálculo de los indicadores se realice con base en registros oficiales, trazables y consistentes con los lineamientos regulatorios vigentes.

3.2.3. Interpretación de los indicadores

Los indicadores SAIDI y SAIFI miden los *eventos* de interrupción del servicio eléctrico, entendidos como situaciones en las cuales se presenta una pérdida total o parcial del suministro. Dependiendo de su causa y de los criterios regulatorios aplicables, ciertos eventos son incluidos en el cálculo de los indicadores, mientras que otros pueden ser excluidos conforme a la normativa vigente.

El SAIDI expresa el tiempo promedio durante el cual un usuario permanece sin servicio eléctrico en un período determinado, generalmente anual. Por su parte, el SAIFI mide la frecuencia promedio con la que un usuario experimenta interrupciones en el mismo período. En conjunto, ambos indicadores permiten evaluar la continuidad y confiabilidad del sistema de distribución.

Desde una perspectiva operativa, valores elevados de SAIDI o SAIFI pueden reflejar deficiencias en el mantenimiento de la red, limitaciones en la infraestructura, obsolescencia tecnológica, fallas en los procedimientos operativos o una alta exposición a factores externos como condiciones climáticas adversas [1], [4]. En consecuencia, estos indicadores no solo describen el desempeño del sistema, sino que también permiten identificar áreas críticas que requieren intervención técnica o inversión en activos.

En el ámbito regulatorio, los OR deben reportar estos indicadores como métricas clave de desempeño y compararlos con las metas establecidas por la CREG. El cumplimiento de dichas metas está asociado a esquemas de remuneración por calidad del servicio, mientras que el incumplimiento puede dar lugar a ajustes tarifarios, obligaciones de reinversión o sanciones económicas [3], [7]. Por tanto, SAIDI y SAIFI no solo constituyen medidas técnicas de continuidad, sino también variables con impacto financiero y regulatorio significativo.

3.2.4. Meta de calidad media del SAIDI

La Resolución CREG 015 de 2018 establece que la meta de calidad media para el indicador de duración de los eventos en el Sistema de Distribución Local (SDL) de cada OR se determina con base en una expresión específica definida por la regulación. Formalmente, dicha meta se calcula mediante la siguiente formulación:

“La meta para el indicador de frecuencia de los eventos sucedidos en el SDL de cada OR se obtiene con base en la siguiente expresión:”

$$\text{SAIDI_M}_{j,t} = (1 - 0,08) \times \text{SAIDI_M}_{j,t-1} \quad (3.3)$$

Donde:

- $SAIDI_M_{j,t}$: Meta del indicador de duración de eventos, en horas al año, a ser alcanzada por el OR j al finalizar el año t .
- $SAIDI_M_{j,t-1}$: Meta del indicador de duración de eventos, en horas al año, para el año $t - 1$. Para el primer año de aplicación del esquema de calidad de cada OR esta variable será igual al indicador de referencia, $SAIDI_R_j$.

3.2.5. Dimensión social y económica

Desde una dimensión social y económica, un servicio deficiente ocasiona pérdidas significativas en la productividad empresarial y en los ingresos por remuneración al operador de red, y afecta la operación de instituciones comerciales e industriales. Por ello, mejorar la gestión y la capacidad de predicción de *SAIDI* y *SAIFI* es un objetivo estratégico para los operadores y para la regulación del sector, con impactos directos en usuarios, empresas y entes de control.

3.2.6. Exclusiones de eventos

Para la realización del cálculo de la calidad del servicio y el seguimiento de estos indicadores se tienen algunas exclusiones que permiten exonerar o excluir eventos de este cálculo. Entre los aspectos de la calidad del servicio de energía eléctrica que no serán observados dentro de este estudio se encuentran las siguientes exclusiones de eventos, tal como lo dicta la regulación CREG 015 del 2018 [3]:

- Los menores o iguales a 3 minutos.
- Los debidos a racionamientos programados.
- Los causados por eventos de activos pertenecientes al Sistema de Transmisión Nacional (STN) y al Sistema de Transmisión Regional (STR).
- Los eventos requeridos por seguridad ciudadana, solicitados por organismos de socorro o autoridades competentes.
- Cuando se daña un activo de nivel de tensión 1 de propiedad del usuario.
- Los debidos a catástrofes naturales.
- Los debidos a actos de terrorismo.
- Eventos originados en exigencias de traslados y adecuaciones de la infraestructura eléctrica.
- Los eventos debidos a trabajos de reposición o modernización en subestaciones.

- Y otros menos relevantes para este estudio, pero que serán igualmente excluidos.

3.2.7. Factores que afectan los indicadores

Hay varios factores que deben considerarse, ya que terminan afectando negativamente los indicadores de calidad:

- **El clima:** Las tormentas eléctricas, vientos fuertes y otros fenómenos meteorológicos pueden dañar la infraestructura de distribución y causar interrupciones.
- **Aspectos técnicos e infraestructura:** Si el mantenimiento es deficiente, si los equipos están viejos u obsoletos, o si no hay redundancia en la red, se generan problemas que impactan los indicadores.
- **La gestión operativa:** Cuando falta planificación en el mantenimiento, cuando existen redes y equipos sin hojas de vida documentadas, cuando la respuesta a fallas es lenta o cuando el servicio está saturado, los indicadores se ven afectados. El problema se agrava al tener la información dispersa en múltiples sistemas.
- **Los datos:** Cuando la información está fragmentada en diferentes aplicativos, se dificulta el desarrollo de modelos predictivos que funcionen adecuadamente.

Por lo tanto, analizar en conjunto todas estas situaciones que afectan el indicador de forma negativa o positiva constituye un ejercicio relevante, ya que permitiría fortalecer la confiabilidad de los procesos internos y mejorar la gestión de los indicadores de calidad del servicio público de redes eléctricas de la empresa operadora de red de Norte de Santander.

3.3. Antecedentes

3.3.1. Revisión de literatura

Los avances recientes en ciencia de datos, estadística avanzada y aprendizaje automático han impulsado una evolución significativa en los métodos para predecir fallas, gestionar interrupciones y estimar la calidad del servicio en redes de distribución eléctrica.

En primer lugar, varios estudios han explorado la predicción de confiabilidad a partir de modelos híbridos que integran técnicas estadísticas y de inteligencia

artificial. Xie et al. [11] desarrollan un modelo integral de pronóstico de confiabilidad que combina redes neuronales artificiales, análisis de relaciones grises y modelos de fallas programadas, demostrando alta aplicabilidad en sistemas en expansión. De manera complementaria, Das et al. [12] proponen un ensamble de redes neuronales profundas que mejora sustancialmente la estimación de interrupciones causadas por viento y descargas eléctricas, superando modelos estadísticos y de comité previos.

En el ámbito de eventos meteorológicos severos, Angalakudati et al. [13] introducen uno de los primeros modelos operativos basados en Machine Learning para la planificación de tormentas, combinando datos climáticos, propiedades físicas de la red e información histórica de daños. En la misma línea, Owerko et al. [14] emplean Graph Neural Networks para procesar mediciones meteorológicas distribuidas en un marco de señales sobre grafos, logrando errores de predicción inferiores al 1.1 % en la región de Nueva York.

El efecto de la vegetación como causa dominante de fallas también ha sido ampliamente estudiado. Cerrai et al. [15] cuantifican el impacto del estándar Enhanced Tree Trimming mediante análisis estadístico y modelos de predicción de interrupciones, mostrando reducciones entre el 16 % y 48 % en fallas durante tormentas. Por su parte, Eskandarpour y Khodaei [16] introducen un modelo predictivo para componentes de red ante huracanes basado en regresión logística, mientras que Rudin et al. [17] proponen un marco general para extraer conocimiento de datos históricos de la red de Nueva York con el fin de priorizar mantenimiento y estimar la vulnerabilidad de componentes críticos.

Otros aportes relevantes abordan la identificación de causas de fallas. Xu et al. [18] aplican un algoritmo inspirado en sistemas inmunológicos (AIRS) para clasificar causas de interrupción (árboles, animales, rayos), enfrentando el problema de datos desbalanceados. Mientras tanto, Breiman [19] establece los fundamentos teóricos de los Random Forest, técnica ampliamente usada en predicción de fallas debido a su robustez y capacidad de manejar alta dimensionalidad.

La estimación de interrupciones bajo condiciones extremas también ha sido examinada mediante enfoques estadísticos. Han et al. [20] modelan la distribución espacial de fallas durante huracanes en la costa del Golfo utilizando variables físicas medibles. Yang et al. [21] estudian la incertidumbre en modelos de predicción de tormentas y demuestran que el rendimiento de los modelos basados en machine learning depende fuertemente del tamaño y representatividad del conjunto de entrenamiento. A su vez, Kankanala et al. [22] presentan AdaBoost+, un método de ensamble que supera regresión, redes neuronales y mixture of experts para estimar fallas asociadas al viento y los rayos.

Otras investigaciones incorporan análisis multivariable para predecir tipos es-

pecíficos de interrupciones. Kor et al. [23] evalúan arquitecturas de aprendizaje automático para predecir fallas por viento, nieve e hielo, mientras que Doostan y Chowdhury [24] desarrollan un enfoque probabilístico para fallas asociadas a rayos utilizando aprendizaje no supervisado y técnicas de clasificación balanceada.

Asimismo, Chen y Kezunovic [25] aplican lógica difusa para análisis predictivo de riesgo, y He et al. [26] comparan árboles de regresión no paramétricos (QRF y BART), demostrando ventajas complementarias según la granularidad espacial y las características del evento.

Dentro de los aportes más recientes, Hou et al. [27] desarrollan un enfoque basado en celdas espaciales de 1 km^2 y Random Forest para predecir interrupciones bajo tifones, alcanzando precisiones superiores al 92 %. De forma similar, Li et al. [28] construyen un modelo de predicción de cantidad de usuarios afectados por tifones, aplicando selección de variables para obtener un modelo simplificado sin sacrificar precisión.

Otras líneas introducen enfoques más estructurales o basados en simulación. Zhai et al. [29] proponen un modelo que genera sistemas de distribución sintéticos y estima fallas a nivel de edificio mediante funciones de fragilidad, reduciendo la dependencia en datos privados de operadores. Zhu et al. [30] desarrollan un modelo de tormentas de dos etapas para predecir interrupciones en tiempo real, mientras que Arif y Wang [31] combinan análisis estadístico y redes neuronales profundas para predecir tiempos de reparación.

Wanik et al. [32] demuestran que modelos basados en árboles y ensambles, alimentados con datos atmosféricos generados mediante WRF, pueden predecir con alta resolución espacial la distribución de fallas en Connecticut. Por su parte, Jaech et al. [33] incorporan procesamiento de lenguaje natural para actualizar predicciones de duración de interrupciones a partir de reportes de campo.

Más recientemente, Krstivojević et al. [34] proponen modelos de regresión basados en Machine Learning para predecir indicadores de confiabilidad en redes suecas, mientras que Sorokin [35] emplea técnicas similares para optimizar la planificación del mantenimiento. Además, Lui et al. [36] presentan un método de cálculo rápido para evaluar la confiabilidad bajo condiciones operativas variables, y Avci [36] integra técnicas híbridas de inteligencia artificial para mejorar la predicción de interrupciones, considerando factores meteorológicos, geográficos y operativos.

Datos

Para el desarrollo del modelo de predicción de indicadores de calidad del servicio eléctrico, se utilizará una base de datos histórica de eventos de falla reportados en el sistema de distribución. La tabla principal consolidada tiene $N = 87,007,074$ observaciones ($A = 47,649$ activos eléctricos únicos $\times T = 1,826$ días), correspondientes al panel **activo $\times$ día** entre el 1 de enero de 2021 y el 31 de diciembre de 2025.

4.1. Tiempo o periodo de estudio

El periodo de estudio abarca desde el 1 de enero de 2021 hasta el 31 de diciembre de 2025.

4.2. Unidad muestral

La unidad muestral adoptada corresponde a un activo eléctrico por día, lo que define un nivel de granularidad tipo *elemento-día*. Esta elección permite capturar la variabilidad temporal de los eventos e integrar variables de red y climáticas a nivel diario.

4.3. Construcción del dataset

4.3.1. Lógica estructural

La construcción del conjunto de datos sigue la siguiente lógica:

- Se crea un calendario diario para el periodo comprendido entre el 01-01-2021 y el 31-12-2025.
- Se construye el producto cartesiano entre el inventario de activos eléctricos y el calendario diario, garantizando la presencia de todos los activos en cada día del periodo de análisis.
- Sobre esta estructura base se integran:

- Variables de red.
- Variables climáticas agregadas a nivel de activo por día.
- Variables de eventos asociadas a cada activo por día.

4.3.2. Definición de variables de evento

Las variables de eventos se definen así:

- **DURACION (minutos):** duración total del evento de interrupción, expresada en minutos, asignada al día de `FECHA_DESCONEXION` (sin prorrateo entre días). En días sin falla, el valor es 0.
- **FRECUENCIA:** número de interrupciones cuyo inicio (`FECHA_DESCONEXION`) ocurre en el día.

4.3.3. Estructura del dataset consolidado

El dataset final incluye las siguientes variables:

- **Información del activo:**
 - `ID_ACTIVO_ELECTRICO`
 - `TIPO_ACTIVO_ELECTRICO`
- **Información geoespacial:**
 - `LATITUD`, `LONGITUD`, `ALTITUD`
 - `ID_CUADRANTE`
 - `LATITUD_CUADRANTE`, `LONGITUD_CUADRANTE`
- **Variables de red:**
 - `FECHA`
 - `CANTIDAD_ELEMENTOS`
 - `CANTIDAD_USUARIOS`
 - `ANTIGUEDAD_RED`

- EXPANSION_RED

■ **Variables climáticas:**

- VELOCIDAD_VIENTO_MS
- TEMPERATURA_MEDIA_C
- HUMEDAD_RELATIVA_PCT
- TEMPERATURA_MINIMA_C
- TEMPERATURA_MAXIMA_C
- PRECIPITACION_TOTAL_MM

■ **Variables objetivo:**

- DURACION
- FRECUENCIA

4.4. Numero de observaciones:

- La tabla consolidada final se estima como:

$$\text{Total de observaciones} = 47,649 \times 1,826 = 87,007,074$$

correspondiente a 5 años de información a nivel elemento-día.

4.5. Origen de la información:

La empresa origen de los datos operativos y técnicos es **CENTRALES ELÉCTRICAS DE NORTE DE SANTANDER S.A E.S.P (CENS S.A E.S.P)**.

4.6. Lugar donde se registra la información:

Sistemas corporativos (BRAE, OMS y GIS). Para variables climatológicas se utiliza la fuente institucional externa NASA POWER.

La información se registra en la red de distribución eléctrica de Norte de Santander, con soporte de localización geográfica por activo y por cuadrante.

Metodología

Nuestra metodología está organizada por etapas que se alinean con los objetivos específicos del proyecto. El enfoque general consiste en integrar datos, limpiarlos, analizarlos y construir modelos para predecir los indicadores *SAIDI* y *SAIFI* de la empresa de distribución eléctrica en Norte de Santander.

Se decidió utilizar CRISP-DM (Cross-Industry Standard Process for Data Mining) como marco de referencia por ser un estándar reconocido en la industria para proyectos de ciencia de datos, el cual fue adaptado al contexto específico del sector eléctrico regulado. Las fases de CRISP-DM se implementaron de la siguiente manera: el entendimiento del negocio (Business Understanding) se desarrolla en las Secciones 1–4, donde se describen el problema, los objetivos y la justificación. Las fases de entendimiento y preparación de datos (Data Understanding y Data Preparation) corresponden a las Etapas 1, 2, 3 y 4, en las que se integran, depuran, exploran los datos y se construyen las variables analíticas. La fase de modelado y evaluación (Modeling y Evaluation) se desarrolla en la Etapa 5, donde se construyen y validan los modelos predictivos. Finalmente, el despliegue (Deployment) corresponde a la Etapa 6, en la cual se consolidan los resultados, se documenta el proceso y se entrega código reproducible.

Esta adaptación de CRISP-DM considera los requisitos específicos del regulador (CREG, SSPD), las métricas propias del sector eléctrico (*SAIDI*, *SAIFI*) y la necesidad de que los modelos sean interpretables para su uso en la toma de decisiones.

5.1. Etapa 1 – Extracción de datos

Objetivo específico asociado: OE1

Esta etapa comprende la recolección, integración y estandarización de las fuentes de datos internas (SCADA, OMS, GIS, CIS, registros de fallas y mantenimiento) y externas (NASA, CREG, SSPD). Incluye la creación de un repositorio analítico unificado y la elaboración de un catálogo de datos que documenta metadatos, alcances, limitaciones y métricas de integridad.

Entregable: Informe de consolidación de datos y catálogo de calidad e integridad.

Fuentes de información

A partir del año 2023, la Electrificadora de Norte de Santander realizó una migración de su sistema de gestión de interrupciones. Como resultado, la recopilación de información de interrupciones eléctricas se llevó a cabo a partir de dos bases de datos provenientes de sistemas distintos:

- **OMS Energy:** sistema utilizado hasta antes de la migración, del cual se extrae la información histórica de interrupciones previas a 2023.
- **OMS SP7 de Siemens:** nuevo sistema implementado desde 2023, del cual se obtiene la información de interrupciones a partir de dicha fecha.

Esta dualidad de fuentes implica diferencias estructurales en los esquemas de datos (tales como nombres de campos, codificaciones y niveles de granularidad), las cuales fueron consideradas durante el proceso de integración y homologación de la información.

5.1.1. Sistemas y fuentes consultadas

Se integran datos de cinco fuentes de información principales:

- **BRAE:** base regulatoria e histórica de eventos.
- **OMS SPARD (sistema histórico):** fuente de elemento causante antes de la migración.
- **OMS SP7 (sistema actual):** fuente de elemento causante en archivos CSV mensuales.
- **GTECH (GIS):** inventario y georreferenciación de activos eléctricos.
- **NASA POWER (API):** serie diaria de variables climatológicas por coordenada/cuadrante.

5.1.2. Extracción base y depuración de eventos de interrupción (BRAE)

La construcción de la base de eventos de interrupción se realizó a partir de la tabla transaccional `BRAE.QA_TFDDREGISTRO`, la cual contiene el registro histórico de eventos de desconexión del sistema eléctrico. A partir de esta fuente, se ejecutó una consulta SQL orientada a depurar inconsistencias, restringir el periodo de análisis y estandarizar la estructura del identificador de evento.

En primer lugar, se seleccionaron únicamente los campos relevantes para el análisis: el identificador del evento (`FDD_CODIGOEVENTO`), la fecha de inicio de

la desconexión (FDD_FINICIAL) y la fecha de reconexión (FDD_FFFINAL). Adicionalmente, se incluyó un campo vacío para ELEMENTO_FALLADO, con el fin de mantener compatibilidad estructural con otras fuentes que sí contienen este nivel de desagregación.

Posteriormente, se aplicaron criterios de depuración y filtrado. En primer lugar, se restringió la muestra al periodo comprendido entre los años 2021 y 2025, garantizando consistencia temporal del análisis. En segundo lugar, se excluyeron aquellos registros marcados como no relevantes mediante la variable FDD_EXCLUSION, conservando únicamente los eventos clasificados como NO EXCLUIDA. En tercer lugar, se eliminaron eventos asociados a causas no válidas según la regulación (FDD_CAUSA_SSPD NOT IN (1)), así como aquellos registros sin fecha de finalización (FDD_FFFINAL IS NOT NULL), los cuales no permiten calcular la duración del evento.

Finalmente, se utilizó la instrucción DISTINCT para garantizar la eliminación de duplicados en el identificador de evento, obteniéndose una base depurada y consistente a nivel de evento de interrupción. Como resultado de este proceso de extracción y limpieza, se obtuvo un total de 95,280 registros válidos de eventos de desconexión para el periodo de análisis.

```
1 SELECT DISTINCT FDD_CODIGOEVENTO AS ID_EVENTO
2     ,FDD_FINICIAL AS FECHA_DESCONEXION
3     ,FDD_FFFINAL AS FECHA_CONEXION
4     ,'' AS ELEMENTO_FALLADO
5 FROM BRAE.QA_TFDDREGISTRO
6 WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
7     AND FDD_EXCLUSION = 'NO EXCLUIDA'
8     AND FDD_CAUSA_SSPD NOT IN (1)
9     AND FDD_FFFINAL IS NOT NULL;
```

Tabla 5.1: Muestra de eventos depurados de interrupción (BRAE)

ID EVENTO	FECHA DESCONEXION	FECHA CONEXION	ELEMENTO FALLADO
801851	14/03/21 06:59:00.000	14/03/21 09:30:00.000	(null)
787583	04/01/21 08:50:00.000	04/01/21 17:15:00.000	(null)
787496	03/01/21 14:18:14.296	03/01/21 14:40:42.699	(null)
787232	01/01/21 10:29:33.936	01/01/21 13:30:00.000	(null)
787455	03/01/21 10:34:23.000	03/01/21 13:30:00.000	(null)
787376	02/01/21 12:09:22.000	02/01/21 18:20:00.000	(null)
789756	16/01/21 08:50:00.000	16/01/21 15:50:00.000	(null)
788677	10/01/21 08:37:45.000	10/01/21 10:10:00.000	(null)
788932	12/01/21 06:47:47.000	12/01/21 08:30:00.000	(null)
787922	06/01/21 08:42:00.000	06/01/21 15:28:00.000	(null)

5.1.3. Extracción de afectación por evento

Con el fin de complementar la base de eventos de interrupción, se construyó una tabla de afectación asociada a cada evento, incorporando información sobre el número de elementos afectados y la cantidad de usuarios impactados. Este proceso permite pasar de una caracterización puramente temporal del evento a una medición de su severidad en términos de impacto en la red.

La extracción se realizó a partir de la tabla `BRAE.QA_TFDDREGISTRO`, la cual se utilizó como fuente principal de eventos, y se complementó mediante una unión (`LEFT JOIN`) con la base `QA_TTC1`, que contiene información asociada a la conexión de transformadores y el número de usuarios por conexión.

En particular, la variable `CANTIDAD_USUARIOS` se construyó a partir del conteo de usuarios asociados a cada transformador (`TC1_CODCONEX`) agrupados por periodo, mientras que la variable de afectación por evento se obtuvo mediante la agregación de estos usuarios a nivel de evento de interrupción.

Posteriormente, se aplicaron los mismos criterios de depuración utilizados en la etapa anterior, restringiendo el análisis al periodo 2021–2025, excluyendo eventos marcados como no relevantes (`FDD_EXCLUSION = 'NO EXCLUIDA'`), eliminando causas no válidas según la clasificación regulatoria (`FDD_CAUSA_SSPD NOT IN (1)`) y conservando únicamente registros con fecha de finalización válida (`FDD_FFIAL IS NOT NULL`).

Finalmente, los datos se agregaron a nivel de evento (`FDD_CODIGOEVENTO`) utilizando la función `GROUP BY`, obteniendo como resultado dos indicadores clave: el número de elementos fallados por evento y el total de usuarios afectados. El procedimiento permitió consolidar una base consistente de 95,280 registros, alineada con la estructura del conjunto de eventos previamente depurado.


```

1 SELECT FDD_CODIGOEVENTO AS ID_EVENTO
2       ,COUNT(FDD_CODIGOELEMENTO) AS CANTIDAD_ELEMENTOS_FALLADOS
3       ,SUM(CANTIDAD_USUARIOS) AS CANTIDAD_USUARIOS
4 FROM BRAE.QA_TFDDREGISTRO
5 LEFT JOIN (
6     SELECT TC1_CODCONEX AS TRANSFORMADOR
7           ,COUNT(TC1_CODCONEX) AS CANTIDAD_USUARIOS
8           ,TC1_PERIODO AS PERIODO
9     FROM QA_TTC1
10    WHERE SUBSTR(TC1_PERIODO, 1, 4) IN ('2021', '2022', '2023', '2024', '2025')
11    GROUP BY TC1_PERIODO, TC1_CODCONEX
12 ) ON FDD_CODIGOELEMENTO = TRANSFORMADOR
13 AND FDD_PERIODO_TC1 = PERIODO
14 WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
15 AND FDD_EXCLUSION = 'NO EXCLUIDA'
16 AND FDD_CAUSA_SSPD NOT IN (1)
17 AND FDD_FFINAL IS NOT NULL
18 GROUP BY FDD_CODIGOEVENTO;

```

Tabla 5.2: Muestra de afectación por evento (BRAE + QA_TTC1)

ID EVENTO	CANTIDAD ELEMENTOS FALLADOS	CANTIDAD USUARIOS AFECTADOS
795044	33	2692
795513	162	11796
788221	10	74
788203	240	3865
789543	8	45
789719	109	503
789929	109	503
788758	1	6
798712	159	1869

5.1.4. Extracción del elemento causante histórico

Con el objetivo de identificar el elemento de la red asociado a la causa de cada evento de maniobra, se realizó la extracción de información histórica desde la base de datos del sistema OMS (Outage Management System), específicamente desde la tabla OMS.MANIOBRAS@SPARD. Esta fuente permite complementar la información de eventos de interrupción mediante la identificación del elemento físico que originó la falla.

El proceso de extracción se centró en dos variables principales: el código de la maniobra (CODE), utilizado como identificador del evento en el sistema OMS, y

el elemento fallado (BREAKER), que corresponde al activo de la red asociado a la causa de la interrupción. Estas variables permiten establecer la relación entre el evento registrado y el componente físico responsable dentro de la infraestructura eléctrica.

Adicionalmente, se aplicaron criterios de filtrado temporal y de calidad de datos. En primer lugar, se restringió la información a registros con fecha igual o posterior al año 2021, garantizando la consistencia histórica del análisis. En segundo lugar, se excluyeron aquellos eventos clasificados como pruebas operativas mediante la condición CAUSA != 'PRUEBA', con el fin de conservar únicamente eventos reales de operación del sistema.

Como resultado de este proceso de extracción y depuración, se obtuvo una base de datos estructurada a nivel de maniobra, la cual permite complementar la trazabilidad entre eventos de interrupción y los elementos físicos de la red asociados a su ocurrencia.

```

1 SELECT CODE AS CODIGO_MANIOBRA
2     ,BREAKER AS ELEMENTO_FALLADO
3 FROM OMS.MANIOBRAS@SPARD
4 WHERE TO_NUMBER(TO_CHAR(FECHA, 'YYYY')) >= 2021
5 AND CAUSA != 'PRUEBA';

```

Tabla 5.3: Muestra de elemento causante histórico (OMS SPARD)

CODIGO MANIOBRA	ELEMENTO FALLADO
640011	AMVE271
634924	LMVEL79620
634978	LMVEL67393
631108	RMVEL79067-2
631464	CMVE2454
631761	SW6844
637873	BMVE749
640442	LMVEL99259
631793	SANC52

5.1.5. Extracción del elemento causante actual

Con el objetivo de actualizar la información histórica del sistema de maniobras, se realizó la extracción de los datos correspondientes a la versión más reciente del sistema OMS en formato plano (CSV). Este proceso permite complementar la información histórica con registros operativos actuales, garantizando la continuidad y consistencia de la base de datos utilizada en el análisis.

La extracción se realizó mediante un proceso de lectura y depuración de datos en Python, a partir del archivo fuente correspondiente a la versión actual del sistema. En primer lugar, se cargó el archivo mediante la función `read_csv`, asegurando la correcta lectura de la estructura tabular. Posteriormente, se realizó una limpieza de los nombres de las columnas mediante la eliminación de espacios en blanco al inicio y al final, con el fin de evitar inconsistencias en la identificación de variables.

A continuación, se seleccionaron únicamente las variables relevantes para el análisis: `Maniobra Apertura`, `Tipo Elemento` y `Elemento_Falla`. Esta selección permitió homogenizar la estructura de la base con la información histórica previamente construida. Finalmente, se eliminaron los registros duplicados mediante la función `drop_duplicates`, garantizando la unicidad de las observaciones a nivel de combinación de variables relevantes.

Como resultado, se obtuvo una base depurada y estandarizada del sistema OMS actual, la cual es consistente con la estructura de la base histórica y permite su integración en el proceso de consolidación del dataset final.

```
1 columnas_necesarias = ['Maniobra Apertura', 'Tipo Elemento', 'Elemento_Falla']
2 df = pd.read_csv(ruta_actual)
3 df.columns = df.columns.str.strip()
4 df = df[columnas_necesarias].drop_duplicates()
```

Tabla 5.4: Muestra de elemento causante actual (OMS SP7)

MANIOBRA APERTURA	TIPO ELEMENTO	ELEMENTO FALLA
424000000000114424	Transformador de distribucion	1T07942
124000000000269842	Fusible	F1979
124000000000269842	Transformador de distribucion	F1979
124000000000273378	Fusible	F2004
124000000000269851	Fusible	F2000
124000000000273383	Fusible	F2001
124000000000273374	Fusible	F2006
124000000000273377	Fusible	F2004
124000000000273372	Fusible	F2006
124000000000273356	Fusible	F2005
124000000000273381	Fusible	F1993

5.1.6. Extracción de inventario GIS

Con el propósito de incorporar la dimensión espacial de la red eléctrica, se realizó la extracción del inventario georreferenciado a partir del sistema GIS

corporativo. Esta información permite asociar cada activo de la red con sus coordenadas geográficas y características físicas, facilitando posteriormente el análisis espacial de los eventos de interrupción.

La extracción se efectuó desde la base de datos ccomun@gtech, la cual contiene el inventario técnico de los activos de la red. A partir de esta fuente, se seleccionaron las variables correspondientes al identificador del elemento (nodo_transform_v), la latitud (coor_gps_lat), la longitud (coor_gps_lon) y la altitud (coor_z). Adicionalmente, se incluyó la variable ubicacion, que permite complementar la caracterización espacial del activo.

Asimismo, se definió explícitamente el tipo de activo como Transformador, con el fin de estandarizar la clasificación dentro del conjunto de datos integrado. Esta homogenización resulta clave para la posterior vinculación con los eventos de interrupción y la construcción del panel activo-día.

Como resultado, se obtuvo una base georreferenciada de los activos de la red, la cual constituye un insumo fundamental para el enriquecimiento espacial del dataset consolidado.

```
1 SELECT
2     nodo_transform_v AS ELEMENTO,
3     coor_gps_lat     AS LATITUD,
4     coor_gps_lon     AS LONGITUD,
5     coor_z           AS ALTITUD,
6     'Transformador' AS TIPO,
7     ubicacion
8 FROM ccomun@gtech c
9 JOIN cconectividad_e@gtech USING (g3e_fid)
10 WHERE c.estado = 'OPERACION'
11     AND c.g3e_fno = 20400
12 UNION
13 SELECT
14     r.codigo         AS ELEMENTO,
15     coor_gps_lat     AS LATITUD,
16     coor_gps_lon     AS LONGITUD,
17     coor_z           AS ALTITUD,
18     'Reconectador'  AS TIPO,
19     ubicacion
20 FROM ereconec_at@gtech r
21 JOIN ccomun@gtech c USING (g3e_fid)
22 JOIN cconectividad_e@gtech USING (g3e_fid)
23 WHERE c.estado = 'OPERACION';
```

Tabla 5.5: Muestra de inventario georreferenciado de activos (GIS GTECH)

ELEMENTO	LATITUD	LONGITUD	ALTITUD	TIPO
2T01558	6.960719612	-72.18029066	636	Transformador
2T01557	6.972762106	-72.18726993	743	Transformador
2T01467	6.973200989	-72.15472768	815	Transformador
2T01466	6.978510343	-72.14903608	726	Transformador
F3199	6.978980206	-72.19049387	832	Aisladero
PSW8910	6.978980206	-72.19049387	832	Aisladero
2T01555	6.982222682	-72.19495813	825	Transformador
2T01554	6.982742594	-72.20226264	867	Transformador
2T01556	6.984663810	-72.18619273	727	Transformador
2T01465	6.985402944	-72.13537905	530	Transformador
F3192	6.987527091	-72.20044897	767	Aisladero
PSW8909	6.987527091	-72.20044897	767	Aisladero
F5217	6.991040416	-72.20123180	726	Aisladero
PSW8908	6.991040416	-72.20123180	726	Aisladero
2T01553	6.991242376	-72.19636467	679	Transformador
2T01470	6.991396285	-72.15644527	790	Transformador
ESW6924	6.992103744	-72.13486380	453	Aisladero
F5211	6.992103744	-72.13486380	453	Aisladero
2T01471	6.992290614	-72.13485446	453	Transformador
2T01469	6.993224220	-72.14776723	656	Transformador
F8201	6.997255476	-72.12409341	361	Aisladero

Y así sucesivamente para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador.

5.1.7. Extracción de variables meteorológicas

Con el objetivo de incorporar condiciones climáticas como variables explicativas en el análisis de interrupciones del sistema eléctrico, se realizó la extracción de información meteorológica a partir de la plataforma NASA POWER. Esta fuente proporciona series temporales diarias de variables climáticas relevantes, las cuales permiten capturar la influencia del entorno atmosférico sobre la ocurrencia y duración de eventos en la red.

El proceso de extracción se centró en un conjunto de variables meteorológicas seleccionadas por su relevancia en el análisis de confiabilidad del sistema eléctrico. En particular, se consideraron las variables de precipitación total (PRECTOT), temperatura media (T2M), temperatura máxima (T2M_MAX), temperatura mínima (T2M_MIN), humedad relativa (RH2M) y velocidad del viento (WS2M).

```
1 parametros_nasa = ("PRECTOT", "T2M", "T2M_MAX", "T2M_MIN", "
    RH2M", "WS2M")
```

Tabla 5.6: Muestra de variables meteorológicas (NASA POWER) - Parte 1

VEL. VIENTO	TEMP. MEDIA	HUMEDAD	TEMP. MIN	TEMP. MAX	PRECIP.
2.06	13.27	87.24	9.12	18.63	2.6
2.66	13.89	88.27	10.71	18.92	1.41
1.93	13.66	88.59	10.29	18.96	3.04
1.73	13.6	85.07	9.13	20.17	9.07
1.45	11.52	69.12	5.95	18.7	0.79
1.1	12.29	80.8	7.55	17.76	0.77
1.76	13.23	88.9	10.65	17.93	3.03
2.34	12.95	88.44	10.14	17.84	2.51
2.41	12.69	87.38	9.48	16.55	1.84
2.98	12.99	90.13	9.65	17.44	3.35
3.18	13.12	87.67	10.58	17.69	0.9

Estas variables fueron extraídas a nivel diario para el periodo comprendido entre el 1 de enero de 2021 y el 31 de diciembre de 2025, lo que dio lugar a una base de aproximadamente 83.5 millones de registros. Este volumen de información refleja la estructura panelizada de la base climática, construida mediante la combinación de múltiples variables atmosféricas observadas diariamente a lo largo del horizonte temporal de análisis.

La incorporación de estas variables permite enriquecer el dataset consolidado con condiciones exógenas del entorno, facilitando el análisis de su relación con la frecuencia y severidad de las interrupciones en el sistema eléctrico.

5.1.8. Resumen metodológico de extracción e integración de bases de datos

Lógica de in La Tabla 5.7 sintetiza el proceso de extracción e integración desarrollado en la Etapa 1. En conjunto, se consolidaron seis fuentes complementarias: BRAE como base transaccional de eventos de interrupción; BRAE + QA_TTC1 para cuantificar la severidad operativa (usuarios afectados); OMS SPARD y OMS SP7 para identificar el elemento causante y fallado en los periodos pre y post migración del sistema; GIS (GTECH) para incorporar la georreferenciación de activos de red; y NASA POWER para enriquecer el análisis con variables climáticas diarias. Cada fuente fue sometida a reglas explícitas de filtrado, homologación y depuración, lo que permitió obtener bases consistentes y trazables que constituyen el insumo inicial para la integración del panel descrita en la Etapa 2.

Tabla 5.7: Resumen metodológico de extracción e integración de bases de datos

Fuente	Variables principales	Proceso aplicado	Resultado
BRAE (QA_TFDDREGISTRO)	ID EVENTO, FECHA DESCONEXION, FECHA CONEXION	Filtrado temporal (2021–2025), exclusión de registros no válidos, eliminación de duplicados	95.280 eventos de interrupción
BRAE + QA_TTC1	CANTIDAD USUARIOS, ELEMENTOS DE CONEXION	JOIN por elemento y periodo, agregación por evento	Base de severidad por evento (usuarios)
OMS SPARD (histórico)	CODIGO MANIOBRA, ELEMENTO FALLADO, ELEMENTO CAUSANTE	Filtrado de registros desde 2021, exclusión de pruebas	Base histórica de causa de falla
OMS SP7 (actual)	MANIOBRA APERTURA, TIPO ELEMENTO, CANTIDAD ELEMENTOS FALLADOS, ELEMENTO FALLA	Lectura CSV, limpieza de columnas, eliminación de duplicados	Base actualizada de elementos causantes
GIS (GTECH)	ELEMENTO, LATITUD, LONGITUD, ALTITUD, TIPO	Extracción desde sistema georreferenciado corporativo	Inventario espacial de la red
NASA POWER	PRECTOT, T2M, T2M_MAX, T2M_MIN, RH2M, WS2M	Extracción diaria (2021–2025) por variables climáticas	83.5 millones de registros meteorológicos

5.2. Etapa 2 - Integración y depuración de datos

5.2.1. Lógica de integración entre sistemas

Una vez extraídas y depuradas las fuentes descritas en la Etapa 1, la integración se ejecuta de forma secuencial sobre tablas intermedias, preservando trazabilidad de llaves y evitando pérdida de emparejamiento entre sistemas con esquemas distintos (BRAE, OMS SPARD, OMS SP7, GIS y NASA POWER). La secuencia aplicada fue la siguiente.

5.2.1.1 Construcción de la tabla base de eventos (BRAE).

A partir de BRAE.QA_TFDDREGISTRO se genera la tabla `tabla_eventos` con ID_EVENTO, FECHA_DESCONEXION y FECHA_CONEXION, aplicando filtros regu-

latorios del periodo 2021–2025, exclusión de eventos no válidos y eliminación de duplicados. Esta tabla define el universo analítico de interrupciones (95,280 eventos).

5.2.1.2 Construcción de la tabla de afectación por evento (Tabla 5.2).

En la Sección 5.1.3 se construye la Tabla 5.2 de afectación por evento, la cual consolida las columnas CANTIDAD_ELEMENTOS y CANTIDAD_USUARIOS a nivel de ID_EVENTO. Su integración a la tabla base consolidada se realiza en el paso 5.2.1.5.

5.2.1.3 Completar ELEMENTO_FALLADO (OMS SPARD + OMS SP7).

La tabla base de eventos obtenida en la Sección 5.1.2 se construyó con el campo ELEMENTO_FALLADO vacío, reservado para su completamiento en la integración. Dado el cambio de sistema OMS en el año 2023, la información del elemento causante se extrajo de forma separada en dos fuentes: la Sección 5.1.4 (*Extracción del elemento causante histórico*, OMS SPARD) y la Sección 5.1.5 (*Extracción del elemento causante actual*, OMS SP7). En este paso, la tabla de la Sección 5.1.2 se cruza con ambas tablas OMS, aplicando en cada caso la lógica de emparejamiento definida en su extracción:

- *Histórico (Sección 5.1.4 – OMS SPARD)*: cruce por CODIGO_MANIOBRA ↔ ID_EVENTO para completar ELEMENTO_FALLADO con el valor de BREAKER en eventos del periodo pre-migración.
- *Actual (Sección 5.1.5 – OMS SP7)*: cruce por MANIOBRA_APERTURA ↔ ID_EVENTO para completar ELEMENTO_FALLADO con el valor de ELEMENTO_FALLA, junto con TIPO_ELEMENTO, en eventos del periodo post-migración.

5.2.1.4 Construcción de la tabla base consolidada (activo–día).

A partir de este paso se inicia la construcción de la tabla base consolidada del proyecto. Como insumo inicial se toma la Tabla 5.5 (inventario georreferenciado de activos obtenido en la Sección 5.1.6), del cual se conserva un registro por ELEMENTO ($A = 47,649$ activos únicos), y se cruza con un calendario diario comprendido entre el 2021-01-01 y el 2025-12-31 ($T = 1,826$ días), empleando el campo FECHA_DIA. Este cruce genera un producto cartesiano entre el universo de activos eléctricos y el horizonte temporal de análisis, con cardinal $N = A \times T = 47,649 \times 1,826 = 87,007,074$ observaciones, definiendo la estructura panel **activo** × **día** sobre la cual, en los

pasos 5.2.1.5 a 5.2.1.8, se anexan los valores restantes de la secuencia de integración. El detalle del procedimiento para los pasos 5.2.1.4 a 5.2.1.8 se documenta en [Consolidada.html](#).

5.2.1.5 Integración de **CANTIDAD_ELEMENTOS** y **CANTIDAD_USUARIOS** (Tabla 5.2).

Sobre la tabla base consolidada obtenida en el paso 5.2.1.4, se integran las columnas **CANTIDAD_ELEMENTOS** y **CANTIDAD_USUARIOS** provenientes de la Tabla 5.2 (afectación por evento, Sección 5.1.3), mediante el siguiente cruce de llaves:

- **ID_EVENTO = ELEMENTO**

entre la Tabla 5.2 y la tabla del paso 5.2.1.4, incorporando al panel las métricas de severidad e impacto operativo asociadas a cada evento de interrupción. La integración se realiza mediante cruce izquierdo por (**ELEMENTO**, **FECHA_DIA**), de modo que el panel conserva $N = 87,007,074$ filas.

5.2.1.6 Integración de variables climáticas (NASA POWER).

Sobre la tabla resultante del paso 5.2.1.5 ($N = 87,007,074$ filas), se anexan las variables de la serie diaria **nasa_power_consolidado** mediante cruce izquierdo por (**ELEMENTO**, **FECHA_DIA**), incorporando precipitación, temperatura (media, máxima, mínima), humedad relativa y velocidad del viento, sin modificar el cardinal del panel.

5.2.1.7 Agregación de variables objetivo (**DURACION** y **FRECUENCIA**).

En este paso se construyen las columnas **DURACION** y **FRECUENCIA** sobre la tabla resultante del paso 5.2.1.6 ($N = 87,007,074$ filas). Para ello, se agregan previamente los eventos de la Tabla 5.1 (Sección 5.1.2) a nivel (**COMPONENTE_FALLADO**, **FECHA_DIA**) y el resultado se integra al panel mediante cruce izquierdo por (**ELEMENTO**, **FECHA_DIA**). La Tabla 5.1 contiene los campos **FECHA_DESCONEXION** y **FECHA_CONEXION**. Con base en las fechas de desconexión y reconexión, se asignan los valores diarios de la siguiente forma:

- **DURACION** (minutos): duración del evento prorrateada por día. Cuando un evento abarca varios días, su duración se reparte entre cada **FECHA_DIA** según los minutos que el evento ocupa dentro de ese día (intersección del intervalo [**FECHA_DESCONEXION**, **FECHA_CONEXION**] con cada día calendario). Así, el día de inicio recibe los minutos desde

FECHA_DESCONEXION hasta la medianoche, los días intermedios reciben 1,440 min cada uno, y el día de cierre recibe los minutos desde la medianoche hasta FECHA_CONEXION.

- FRECUENCIA: número de desconexiones cuyo inicio (FECHA_DESCONEXION) ocurre en FECHA_DIA (no se prorratea; se cuenta en el día de inicio).

Cuando el activo no presenta interrupciones en un día, se asigna DURACION = 0 y FRECUENCIA = 0.

5.2.1.8 Consolidación del panel final (activo–día).

Sobre la tabla base consolidada definida en el paso 5.2.1.4, y una vez anexados los valores de los pasos 5.2.1.5 a 5.2.1.7, se obtiene el dataset final con grano **activo eléctrico × día** y $N = 87,007,074$ observaciones ($A = 47,649$ activos $\times T = 1,826$ días). En días sin falla se registra DURACION = 0, FRECUENCIA = 0, CANTIDAD_ELEMENTOS = 0 y CANTIDAD_USUARIOS = 0.

La base de datos consolidada se estructura como un panel de datos de tipo activo–tiempo, donde la unidad muestral corresponde a un **activo eléctrico observado diariamente**. En términos formales, cada observación se identifica mediante el par (i, t) , donde i denota el activo eléctrico y t el día dentro del periodo de análisis. Bajo esta estructura, el conjunto de datos permite capturar la evolución temporal de cada activo a lo largo del horizonte de estudio.

Sea A el número total de activos eléctricos en la red y T el número total de periodos diarios observados, el tamaño teórico del panel balanceado está dado por:

$$N = A \times T$$

donde:

- $A = 47,649$ corresponde al número de activos eléctricos únicos en la Tabla 5.5 (inventario GIS, un registro por ELEMENTO),
- $T = 1,826$ corresponde al número de días observados (cinco años de información diaria).

En consecuencia, el número total de observaciones en la base consolidada se calcula como:

$$N = 47,649 \times 1,826 = 87,007,074$$

5.2.2. Diagrama de flujo de la secuencia de integración

Este diagrama de flujo resume visualmente la secuencia de integración y la estructura del panel final, como guía para el lector, especificando las relaciones entre las tablas y las operaciones aplicadas en cada paso.




Figura 5.1: Estructura del panel de datos activo-día

5.2.3. Descripción de la tabla base consolidada

Las Tablas 5.8 a 5.11 presentan una muestra de la tabla base consolidada resultante del paso 5.2.1.8, con grano **activo eléctrico** × **día**. Por limitaciones de ancho en la página, la muestra se divide en cuatro bloques consecutivos que conservan el mismo orden de filas: identificación del activo (Tabla 5.8), severidad y clima inicial (Tabla 5.9), clima complementario (Tabla 5.10) y variables de continuidad (Tabla 5.11).

Tabla 5.8: Muestra de la tabla base consolidada (grano activo–día) – Parte 1: activo y fecha

ID ACTIVO	TIPO	LAT.	LON.	ALT.	FECHA DIA
AASW4819	Aisladero	8.5786778	-72.92349	219	01/01/2021
1T12452	Transformador	8.5839989	-72.92248	241	01/01/2021
REC21365	Reconectador	8.5840628	-72.92246	241	01/01/2021
CUC12345	Cuchilla	7.7523729	-73.23971	1236	01/01/2021
INT39845	Interruptor	7.7476080	-73.25551	1359	02/01/2021
AASW4820	Aisladero	7.7561057	-73.26037	1169	02/01/2021
1T12453	Aisladero	7.7409332	-73.20825	1636	02/01/2021
REC21366	Transformador	7.7428641	-73.18990	1542	02/01/2021
CUC12346	Reconectador	7.7538839	-73.17721	1707	03/01/2021

Tabla 5.9: Muestra de la tabla base consolidada (grano activo–día) – Parte 2: severidad y clima inicial (continuación)

ID ACTIVO	FECHA DIA	C. ELEM.	C. USU.	VEL. VIENTO	TEMP. MED.
AASW4819	01/01/2021	0	0	1.11	23.91
1T12452	01/01/2021	0	0	1.23	24.58
REC21365	01/01/2021	125	2015	0.96	23.04
CUC12345	01/01/2021	0	0	0.81	23.02
INT39845	02/01/2021	0	0	1.05	23.83
AASW4820	02/01/2021	0	0	1.12	24.08
1T12453	02/01/2021	0	0	1.08	24.52
REC21366	02/01/2021	0	0	1.26	24.37
CUC12346	03/01/2021	0	0	1.41	24.34

Tabla 5.10: Muestra de la tabla base consolidada (grano activo–día) – Parte 3: clima complementario (continuación)

ID ACTIVO	FECHA DIA	HUM. REL.	TEMP. MIN.	TEMP. MAX.	PRECIP.
AASW4819	01/01/2021	78.91	20.06	29.98	3.19
1T12452	01/01/2021	75.79	20.27	30.90	1.31
REC21365	01/01/2021	83.94	20.26	27.82	3.19
CUC12345	01/01/2021	79.55	17.92	30.09	7.28
INT39845	02/01/2021	69.70	19.35	30.79	1.99
AASW4820	02/01/2021	61.99	17.20	30.81	0.98
1T12453	02/01/2021	72.16	20.38	30.59	2.70
REC21366	02/01/2021	75.50	20.18	30.63	3.29
CUC12346	03/01/2021	74.34	20.40	30.43	1.86

Tabla 5.11: Muestra de la tabla base consolidada (grano activo-día) – Parte 4: variables de continuidad (continuación)

DURACION	FRECUENCIA
0	0
0	0
4.215	3
0	0
0	0
0	0
0	0
0	0
0	0
0	0

Nota: las filas de las Tablas 5.8 a 5.11 corresponden al mismo conjunto de observaciones en el mismo orden. Los registros sin interrupción en el día presentan DURACION = 0 y FRECUENCIA = 0.

5.2.4. Descripción de las variables

La Tabla 5.8 reúne las variables de identificación del activo y del periodo de observación. A continuación se describe el significado, origen, unidad y clasificación estadística de cada columna. Cada variable se clasifica como **cuantitativa** o **cualitativa**; en las cualitativas se distingue si la escala es **ordinal** o **categorica** (nominal). En las cuantitativas se indica además si la medición es **discreta** o **continua**. La Tabla 5.12 sintetiza esta clasificación para todas las variables del panel consolidado.

Tabla 5.12: Clasificación estadística de las variables del panel consolidado

Variable	Clasificación
ID ACTIVO	Cualitativa categorica
TIPO	Cualitativa categorica
LAT., LON., ALT.	Cuantitativa continua
FECHA DIA	Cualitativa ordinal
C. ELEM., C. USU., FRECUENCIA	Cuantitativa discreta
VEL. VIENTO, TEMP.	Cuantitativa continua
MED./MIN./MAX., HUM. REL., PRECIP., DURACION	

- **ID ACTIVO (ELEMENTO):** identificador único del activo eléctrico en la red de distribución. Proviene del inventario georreferenciado GIS (Sección 5.1.6, Tabla 5.5) y constituye la llave primaria del panel a nivel de activo. Permite

vincular cada observación diaria con el elemento físico asociado a eventos de interrupción y con sus atributos espaciales. **Clasificación:** cualitativa categórica.

- **TIPO:** clasificación funcional del activo según su rol en la red. Los valores observados incluyen *Transformador, Reconectador, Aisladero, Cuchilla e Interruptor*, homologados en la extracción GIS para estandarizar la tipología dentro del dataset consolidado. **Clasificación:** cualitativa categórica.
- **LAT. (LATITUD):** coordenada de latitud del activo, expresada en grados decimales (WGS84). Se obtiene del campo `coor_gps_lat` del sistema GTECH y habilita el análisis espacial de la red y la asignación de contexto geográfico a cada registro. **Clasificación:** cuantitativa continua.
- **LON. (LONGITUD):** coordenada de longitud del activo, expresada en grados decimales (WGS84). Corresponde al campo `coor_gps_lon` del inventario GIS y se emplea conjuntamente con la latitud para localizar el activo en el territorio de operación. **Clasificación:** cuantitativa continua.
- **ALT. (ALTITUD):** cota del activo sobre el nivel del mar, en metros. Proviene del campo `coor_z` del sistema GIS y complementa la caracterización geográfica del punto de conexión en la red. **Clasificación:** cuantitativa continua.
- **FECHA DIA (FECHA_DIA):** fecha calendario de la observación, con granularidad diaria en el intervalo 2021-01-01 a 2025-12-31. Se genera mediante el cruce del inventario de activos con el calendario diario (paso 5.2.1.4) y define, junto con ID ACTIVO, la unidad muestral del panel **activo × día**. **Clasificación:** cualitativa ordinal.

Tabla 5.9 (severidad y clima inicial). Las columnas ID ACTIVO y FECHA DIA se repiten en esta tabla para facilitar la trazabilidad de filas entre bloques consecutivos. Las variables propias de este bloque son:

- **C. ELEM. (CANTIDAD_ELEMENTOS):** número de elementos de red afectados por el evento de interrupción asociado al activo en el día. Proviene de la Tabla 5.2 (afectación por evento, Sección 5.1.3) e integra al panel en el paso 5.2.1.5. Cuando el activo no registra falla en el día, el valor es 0. **Clasificación:** cuantitativa discreta.
- **C. USU. (CANTIDAD_USUARIOS):** número de usuarios afectados por el evento de interrupción vinculado al activo en el día. Se obtiene de la misma fuente

y mediante el mismo cruce que CANTIDAD_ELEMENTOS, y constituye una medida de severidad operativa del impacto sobre la demanda. En días sin interrupción, el valor es 0. **Clasificación:** cuantitativa discreta.

- **VEL. VIENTO (WS2M):** velocidad del viento a 2 m de altura, expresada en m/s. Corresponde a la variable WS2M de NASA POWER (Sección 5.1.7) e integra al panel por FECHA_DIA en el paso 5.2.1.6. **Clasificación:** cuantitativa continua.
- **TEMP. MED. (T2M):** temperatura media del aire en el día, expresada en °C. Proviene del parámetro T2M de NASA POWER y captura las condiciones térmicas promedio del entorno asociadas a cada observación activo-día. **Clasificación:** cuantitativa continua.

Tabla 5.10 (clima complementario). Al igual que en la Tabla 5.9, ID ACTIVO y FECHA DIA permiten alinear filas entre tablas. Las variables climáticas restantes del bloque son:

- **HUM. REL. (RH2M):** humedad relativa del aire a 2 m, expresada en porcentaje (%). Proviene del parámetro RH2M de NASA POWER e integra al panel por FECHA_DIA. **Clasificación:** cuantitativa continua.
- **TEMP. MIN. (T2M_MIN):** temperatura mínima diaria del aire, expresada en °C. Corresponde al parámetro T2M_MIN de NASA POWER y complementa la temperatura media con el extremo inferior del rango térmico del día. **Clasificación:** cuantitativa continua.
- **TEMP. MAX. (T2M_MAX):** temperatura máxima diaria del aire, expresada en °C. Proviene del parámetro T2M_MAX de NASA POWER y representa el extremo superior del rango térmico observado en el día. **Clasificación:** cuantitativa continua.
- **PRECIP. (PRECTOT):** precipitación total acumulada en el día, expresada en mm. Corresponde al parámetro PRECTOT de NASA POWER y permite incorporar la exposición del activo a condiciones de lluvia en la fecha de observación. **Clasificación:** cuantitativa continua.

Tabla 5.11 (variables de continuidad). Este bloque concentra las variables objetivo del análisis, construidas en el paso 5.2.1.7 a partir de la Tabla 5.1 (eventos depurados, Sección 5.1.2) y de los campos FECHA_DESCONEXION y FECHA_CONEXION:

- **DURACION** (*DURACION*, en **minutos**): duración total del evento de interrupción, calculada como la diferencia entre *FECHA_CONEXION* y *FECHA_DESCONEXION* y asignada al día de *FECHA_DESCONEXION* (sin prorrateo entre días calendario). En días sin falla, el valor es 0. **Clasificación:** cuantitativa continua.
- **FRECUENCIA** (*FRECUENCIA*): número de interrupciones del activo cuyo inicio (*FECHA_DESCONEXION*) ocurre en *FECHA_DIA*. La frecuencia se contabiliza únicamente en el día de ocurrencia del evento. En días sin falla, el valor es 0. **Clasificación:** cuantitativa discreta.

Objetivo específico asociado: OE1

Una vez construido el panel consolidado (pasos de integración 5.2.1.4–5.2.1.8), se deriva la tabla agregada por cuadrante y semana (Sección 5.2.5). La Etapa 2 cierra con la evidencia institucional de calidad de las fuentes (Sección 5.2.7). El diagnóstico de completitud del panel, la identificación de valores extremos y el resto del análisis exploratorio se desarrollan en la Etapa 3; la imputación, el tratamiento definitivo de atípicos y la preparación del dataset para modelado, en la Etapa 4.

5.2.5. Agrupación de data consolidada por semana y cuadrante

Definición del grano analítico (cuadrante $\times$ semana)

El panel consolidado con grano **activo eléctrico $\times$ día** ($N = 87,007,074$ observaciones) constituye la base de integración y trazabilidad del proyecto: preserva la relación uno a uno entre cada activo de red y cada día del horizonte 2021–2025, y permite reconstruir con rigor la secuencia de pasos descrita en la Sección 5.2.1. No obstante, el objetivo del estudio —pronosticar el comportamiento de *SAIDI* y *SAIFI* en distintas áreas del territorio de concesión— exige una unidad de análisis de mayor agregación espacial y temporal, coherente con la lectura regulatoria y operativa de los indicadores de continuidad del servicio.

Desde el punto de vista espacial, los indicadores de calidad se interpretan y gestionan a escala territorial (zonas de concentración, circuitos y áreas de servicio), no a nivel de un activo aislado. Para sintetizar el comportamiento de la red en unidades homogéneas del territorio, se adopta la malla institucional de **800 cuadrantes** que cubre el área de concesión de la red eléctrica. En esta malla, el sufijo **_800** identifica la versión del esquema con 800 divisiones espaciales; cada celda tiene dimensiones aproximadas de $5 \times 2,5$ km. Cada activo eléctrico se asigna a un *id_cuadrante* mediante el catálogo *ELEMENTO_FALLA_CUADRANTE_800*, de modo que las observaciones diarias de múltiples activos ubicados en la misma celda puedan consolidarse en una métrica zonal. La Figura 5.2 ilustra la estructura de esta partición espacial sobre el área de estudio.




Figura 5.2: Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. $5 \times 2,5$ km).

Desde el punto de vista temporal, la granularidad diaria del panel es necesaria para la integración de eventos, clima y severidad, pero resulta excesivamente ruidosa para el análisis exploratorio espacial y para la modelación orientada a dinámicas semanales de continuidad y clima. Por ello, se define la **semana calendario** (con inicio en lunes) como periodo de agregación temporal, lo que permite suavizar fluctuaciones diarias, estabilizar las series de interrupción y alinear las covariables meteorológicas en un horizonte compatible con la gestión operativa y con visualizaciones espacio-temporales (mapas por cuadrante y series semanales).

Bajo esta definición, la unidad muestral del dataset agregado es el par (**cuadrante, semana**). El panel `data_consolidada.csv` se conserva como insumo base y referencia del proyecto; la tabla derivada `data_agrupada_por_cuadrante_semana.csv` constituye la representación analítica para los análisis territoriales posteriores, sin sustituir ni alterar el panel diario original.

Procedimiento de agregación

Con el panel consolidado `data_consolidada.csv`, se construyó la tabla de análisis a grano **cuadrante** $\times$ **semana**. El procedimiento se documenta en [data_agrupacion.html](#).

El insumo principal es el panel del paso 5.2.1.8. Para asignar cada activo a su zona de análisis espacial, se utiliza el catálogo `ELEMENTO_FALLA_CUADRANTE_800`,

del cual se extrae la relación `ELEMENTO → id_cuadrante` (campo `CUADRANTE_1`). La asignación se integra al panel mediante cruce izquierdo por `ELEMENTO`, conservando todas las filas del panel y anexando el identificador de cuadrante cuando existe emparejamiento. Complementariamente, el archivo `CUADRANTE_CORD_800` aporta la referencia de centroides por cuadrante.

Sobre el panel enriquecido, cada observación diaria se asigna a una semana calendario mediante `floor_date(FECHA_DIA, unit = "week", week_start = 1)`, de modo que la semana inicia en lunes. La duración diaria en horas se obtiene como `DURACION_min / 60`, coherente con la unidad en minutos definida en el paso 5.2.1.7.

La agregación se ejecuta con `group_by(id_cuadrante, semana)` y las siguientes reglas de resumen:

- **Coordenadas del cuadrante** (latitud, longitud, altitud): primer valor registrado en el grupo (`first`), tomado del inventario georreferenciado del panel.
- **Impacto operativo**: `usuarios_afectados = sum(CANTIDAD_USUARIOS)` y `elementos_afectados = sum(CANTIDAD_ELEMENTOS)` en la semana, acumulando los conteos diarios de los activos del cuadrante.
- **Variables climáticas semanales**: `temp_media_semana` y `humedad_media_semana` como promedio; `temp_max_semana` y `viento_max_semana` como máximo; `temp_min_semana` como mínimo; `viento_medio_semana` como promedio; `precip_total_semana` como suma de la precipitación diaria.
- **Continuidad del servicio**: `n_eventos = sum(FRECUENCIA)` (total de desconexiones iniciadas en la semana) y `duracion_total = sum(duracion_horas)` (suma de horas de interrupción prorrateadas por día en el cuadrante).

El resultado se exporta como `data_agrupada_por_cuadrante_semana.csv` en la ruta definida por la variable de entorno `UBICACION_DATA`.

5.2.6. Descripción de la tabla base semanal cuadrante

La Tabla 5.13 resume la estructura del dataset agregado `data_agrupada.csv`, con grano **cuadrante × semana**. Cada fila corresponde a un par (`id_cuadrante`, `semana`) y concentra, para esa celda de la malla y ese periodo semanal, las coordenadas de referencia, el impacto operativo acumulado, las variables climáticas resumidas y las métricas de continuidad del servicio. Las Tablas 5.14 a 5.17 presentan una muestra ilustrativa; por limitaciones de ancho en la página, la muestra se divide en cuatro bloques consecutivos que conservan el mismo orden de filas: identificación espacio-temporal e impacto operativo (Tabla 5.14),

temperatura (Tabla 5.15), clima complementario (Tabla 5.16) y continuidad del servicio (Tabla 5.17).

Tabla 5.13: Estructura de la tabla base semanal cuadrante (`data_agrupada.csv`).

Bloque	Variables	Regla de agregación
Identificación	id_cuadrante	Llave del grupo
Georreferencia	semana	first
	latitud	
	longitud	
Impacto	altitud	sum
	usuarios_afectados	
Clima	elementos_afectados	mean
	temp_media_semana	
	temp_max_semana	max
	temp_min_semana	min
	humedad_media_semana	mean
	viento_medio_semana	mean
	viento_max_semana	max
	precip_total_semana	sum
Continuidad	n_eventos	sum
	duracion_total	

Tabla 5.14: Muestra de la tabla base semanal cuadrante (grano cuadrante-semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo

ID CUAD.	SEMANA	LAT.	LON.	ALT.	USU. AFECT.	ELEM. AFECT.
1	28/12/2020	7.0012	-72.6855	3418	0	0
1	04/01/2021	7.0012	-72.6855	3418	0	0
3	04/01/2021	7.1548	-72.7196	2850	0	0
12	11/01/2021	7.4521	-72.8903	1240	842	18
45	18/01/2021	7.7539	-73.1204	890	0	0
117	25/01/2021	7.9215	-72.5021	286	1254	24
203	01/02/2021	8.0812	-72.4108	312	0	0
45	08/02/2021	7.7539	-73.1204	890	315	6
117	15/02/2021	7.9215	-72.5021	286	680	11

Tabla 5.15: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 2: temperatura (continuación)

ID CUAD.	SEMANA	TEMP. MED.	TEMP. MAX.	TEMP. MIN.
1	28/12/2020	13.6	19.8	6.2
1	04/01/2021	12.8	18.5	5.8
3	04/01/2021	13.1	19.2	6.0
12	11/01/2021	22.4	28.6	16.8
45	18/01/2021	23.8	30.1	18.2
117	25/01/2021	24.1	30.4	18.9
203	01/02/2021	24.5	30.8	19.1
45	08/02/2021	23.5	29.7	17.8
117	15/02/2021	24.3	30.2	18.6

Tabla 5.16: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación)

ID CUAD.	SEMANA	HUM. MED.	VEL. MED.	VEL. MAX.	PRECIP.
1	28/12/2020	82.4	1.15	2.31	18.5
1	04/01/2021	80.1	1.08	2.18	12.3
3	04/01/2021	81.6	1.12	2.25	15.7
12	11/01/2021	76.3	0.98	1.95	8.4
45	18/01/2021	74.8	1.05	2.10	6.2
117	25/01/2021	73.5	1.18	2.42	9.8
203	01/02/2021	72.9	1.22	2.55	4.1
45	08/02/2021	75.2	1.09	2.08	11.6
117	15/02/2021	74.1	1.14	2.35	7.3

Tabla 5.17: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación)

N EVENTOS	DURACION TOTAL (h)
0	0.0
0	0.0
0	0.0
5	28.4
0	0.0
8	41.7
0	0.0
2	12.6
4	22.3

Nota: las filas de las Tablas 5.14 a 5.17 corresponden al mismo conjunto de obser-

vaciones en el mismo orden. `duracion_total` se expresa en horas (suma semanal de `DURACION_min/60` prorrateada por día). Las semanas sin interrupciones registran `n_eventos = 0` y `duracion_total = 0`. Las unidades de temperatura, humedad, viento y precipitación coinciden con las del panel diario (°C, %, m/s y mm, respectivamente).

5.2.7. Evidencia de calidad y confiabilidad de las fuentes

La validación de los datos recopilados por Centrales Eléctricas de Norte de Santander S.A. E.S.P. (CENS) se fundamenta en su arquitectura institucional de gestión, enmarcada en la Política de Gestión de Tecnología de la Información (Sesión de la Junta Directiva No. 800 del 20 de febrero de 2018) [37] y en la Política del Sistema de Gestión Integrado (Sesión de la Junta Directiva No. 831 del 22 de abril de 2020) [38], orientadas a garantizar una gestión sistemática de calidad continua, sostenibilidad ambiental y cumplimiento legal mediante la evaluación permanente de la calidad de los datos, priorizando consistencia, disponibilidad y accesibilidad de la información [39].

CENS refuerza su gobernanza de datos mediante Instrumentos de Gestión de Información Pública, entre los cuales se destacan el Registro de Activos de Información (IPR), utilizado para detectar, clasificar y almacenar conjuntos de datos institucionales; los Cuadros de Clasificación Documental; el Esquema de Publicación de Información (IPS); el Índice de Información Clasificada y Reservada; los Costos de Reproducción; y el Programa de Gestión Documental (PGD). Estos instrumentos enmarcan el proceso institucional de almacenamiento, organización, acceso, difusión, protección y preservación de la información [40].

En conjunto, estos mecanismos reflejan sistemas de control interno, gobernanza, confianza en la información documentada y transparencia institucional. Asimismo, evidencian el funcionamiento estructurado de los registros y su disponibilidad operativa, garantizando la calidad, veracidad y consistencia de los datos utilizados en este estudio para la toma de decisiones analíticas y gerenciales.

La fiabilidad técnica de las fuentes climáticas y ambientales está respaldada por el IDEAM, entidad pública responsable de la recopilación oficial de datos hidrológicos, meteorológicos y ambientales en Colombia. El IDEAM opera bajo la Política Institucional para la Gestión de Información Estadística (E-SGI-PI003) [41] y las disposiciones del Sistema Estadístico Nacional, que establecen normas obligatorias de trazabilidad, control de calidad, validación estadística, metadatos estructurados y consistencia metodológica en los procesos de captura, procesamiento y difusión de datos [42].

Adicionalmente, en cumplimiento del Decreto 1081 de 2015, el Decreto 103 de

2015, la Ley 1712 de 2014 (Ley de Transparencia) y la Resolución 1519 de 2020 del MINTIC, el IDEAM garantiza que la información publicada sea auditable, actualizada y accesible, respaldada por canales institucionales de difusión, monitoreo interno e integridad documental. Estas disposiciones fortalecen la calidad estadística y aseguran que las series climáticas oficiales cumplan criterios formales de confiabilidad, oportunidad y validez técnica a escala nacional [8], [41], [42].

5.3. Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA)

Objetivo específico asociado: OE2

Objetivo: comprender el comportamiento de los datos e identificar patrones, relaciones y comportamientos relevantes que orienten las decisiones de modelado.

Una vez completadas las etapas de extracción e integración (Etapas 1 y 2), se desarrolla un análisis exploratorio orientado a caracterizar las distribuciones de las variables, diagnosticar la calidad del panel (valores faltantes y extremos), identificar patrones temporales y espaciales, y evaluar las relaciones entre covariables que podrían explicar la variación de *SAIDI* y *SAIFI*. Esta etapa se concibe como un análisis diagnóstico previo al modelamiento, orientado a garantizar la estabilidad e interpretabilidad de los resultados y a fundamentar las decisiones de imputación y transformación de la Etapa 4.

Para las variables cuantitativas se calculan medidas de tendencia central y dispersión, así como la proporción de valores atípicos; adicionalmente se construyen histogramas y diagramas de caja para examinar la forma de las distribuciones. En el caso de las variables categóricas, se analizan las frecuencias absolutas y relativas de cada categoría. El grado de asociación entre variables cuantitativas se evalúa mediante el coeficiente de correlación de Spearman y entre variables cualitativas mediante el estadístico de Cramér, con el fin de identificar redundancias y relaciones preliminares que orienten la depuración de variables en la Etapa 4. Las visualizaciones incluyen series de tiempo, gráficos de dispersión, mapas temáticos y mapas de calor de correlaciones.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes. Tras la caracterización del panel, se documentan el diagnóstico de datos faltantes (Sección 5.3.1) y la identificación de valores extremos (Sección 5.3.2); a continuación se profundiza en estadísticos descriptivos, distribuciones, patrones temporales y asociaciones entre variables.

5.3.1. Identificación de datos faltantes

Sobre el panel consolidado final (`data_consolidada.csv`), con $N = 87,007,074$ observaciones (grano activo eléctrico $\times$ día), se realizó un diagnóstico sistemático de valores faltantes (NA) con dos enfoques complementarios: (i) conteo de NA por variable y (ii) conteo de observaciones del panel con al menos un NA por fila. El objetivo fue cuantificar la magnitud y localizar el origen de la incompletitud como insumo del EDA y para fundamentar las decisiones de imputación o exclusión en la Etapa 4.

En el análisis por columna, para cada una de las 16 variables del panel se calculó el número absoluto de NA y su porcentaje respecto a N . En el análisis por fila, se determinó cuántas observaciones (i, t) presentan cero, uno o más campos incompletos, junto con el máximo de variables faltantes registradas en una misma fila.

Los resultados muestran que la incompletitud se concentra en las variables climáticas integradas desde NASA POWER en el paso 5.2.1.6. Las seis variables meteorológicas (`velocidad_viento_ms`, `temperatura_media_c`, `humedad_relativa_pct`, `temperatura_minima_c`, `temperatura_maxima_c` y `precipitacion_total_mm`) presentan exactamente 3,401,838 valores faltantes cada una, equivalente al 3,91 % de N . Este patrón es coherente con el cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`): las filas sin emparejamiento en la base climática conservan NA en el bloque meteorológico. La variable `ALTITUD` registra 32,868 faltantes (0,04 % de N), asociados al inventario GIS. El resto de variables del panel—identificación del activo (`ELEMENTO`, `TIPO`, `LATITUD`, `LONGITUD`), calendario (`FECHA_DIA`), severidad (`CANTIDAD_ELEMENTOS`, `CANTIDAD_USUARIOS`) y continuidad (`DURACION`, `FRECUENCIA`)—no presentan NA, dado que los pasos 5.2.1.5 y 5.2.1.7 asignan 0 en días sin evento.

A nivel de fila, 83,576,020 observaciones (96,06 %) están completas; 3,431,054 filas (3,94 %) tienen al menos un NA, y el máximo de variables incompletas en una misma observación es 7 (combinación de las seis variables climáticas más `ALTITUD`). La Figura 5.3 resume el porcentaje de faltantes por variable, ordenado de mayor a menor.




Figura 5.3: Porcentaje de valores faltantes por variable en el panel consolidado ($N = 87,007,074$).

Tabla 5.18: Resumen de valores faltantes por variable en el panel consolidado

Variable	<i>n</i> de NA	% sobre <i>N</i>
velocidad_viento_ms	3,401,838	3,91
temperatura_media_c	3,401,838	3,91
humedad_relativa_pct	3,401,838	3,91
temperatura_minima_c	3,401,838	3,91
temperatura_maxima_c	3,401,838	3,91
precipitacion_total_mm	3,401,838	3,91
ALTITUD	32,868	0,04
<i>Resto de variables del panel: 0 NA (0 %)</i>		

En síntesis, la calidad estructural del panel es alta en variables operativas de interrupción (sin NA), y la incompletitud relevante para el modelado se limita al bloque climático y, en menor medida, a ALTITUD. Las reglas de imputación o exclusión se definen con base en este diagnóstico y se aplican en la Etapa 4.

Tabla agrupada cuadrante $\times$ semana. Sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90,128$ observaciones y 16 variables, se replicó el mismo esquema de diagnóstico: conteo de NA por variable y por fila. El procedimiento se documenta en [missing_values_grouped.html](#).

En el análisis por columna, las 16 variables del grano agregado—identificación y calendario (`id_cuadrante`, `semana`), georreferenciación (`latitud`, `longitud`, `altitud`), severidad (`usuarios_afectados`, `elementos_afectados`), clima semanal (`temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`,

viento_medio_semana, viento_max_semana, precip_total_semana) y continuidad (n_eventos, duracion_total)—registran 0 valores faltantes (0 % sobre N_{agr}). A nivel de fila, las 90,128 observaciones están completas: ninguna fila presenta al menos un NA y el máximo de variables incompletas por fila es 0.

Este resultado es coherente con la agregación descrita en la Sección 5.2.5: las sumas y promedios semanales emplean `na.rm = TRUE`, de modo que los NA del panel diario no se propagan como campos vacíos en el grano agregado; las métricas operativas sin evento se consolidan en 0, y cada fila exportada conserva llaves estructurales definidas (`id_cuadrante`, `semana`). La Figura 5.4 ilustra la ausencia de faltantes en una muestra de las primeras 50 filas: todas las celdas se clasifican como completas.




Figura 5.4: Mapa de faltantes por fila y variable en la tabla agrupada cuadrante $\times$ semana ($N_{agr} = 90,128$; muestra de 50 filas).

En consecuencia, la tabla agrupada no requiere reglas de imputación por valores faltantes en la Etapa 4; el tratamiento de incompletitud documentado en los párrafos anteriores aplica al panel consolidado activo $\times$ día, grano en el que se originan los NA climáticos y de ALTITUD.

5.3.2. Identificación de valores extremos en variables cuantitativas

Se evaluó la presencia de valores extremos en las variables cuantitativas mediante reglas univariadas y diagramas de caja e histogramas. El análisis distingue

observaciones operativamente plausibles de posibles inconsistencias de registro, sin aplicar aún transformaciones ni exclusiones definitivas; el tratamiento se difiere a la Etapa 4 con base en estos hallazgos. Para cada variable se aplicaron tres reglas: (i) rango intercuartílico de Tukey, $[Q_1 - 1,5 \text{ IQR}, Q_3 + 1,5 \text{ IQR}]$; (ii) rango ampliado con factor 3,0; y (iii) percentiles P1–P99.

Panel consolidado activo $\times$ día. Sobre `data_consolidada.csv` ($N = 87,007,074$) se replicó el protocolo descrito, excluyendo coordenadas geográficas (LATITUD, LONGITUD, ALTITUD). El detalle reproducible se documenta en [detection_outliers.html](#). En ese grano, el 99,94 % de las filas registra cero en severidad y continuidad, por lo que el diagnóstico relevante se concentra en días con evento ($\approx 48,400$ registros), donde las distribuciones presentan cola pesada (máximo de DURACION de ≈ 231 días, sugerente de posibles inconsistencias de registro). En clima, la `precipitacion_total_mm` diaria marca el 10,38 % de extremos bajo Tukey por su asimetría y exceso de ceros. Este análisis funda la calidad del insumo de integración; las conclusiones para el modelado territorial se formulan sobre la tabla agregada.

Tabla agrupada cuadrante $\times$ semana. Sobre `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90,128$ observaciones, se replicó el mismo esquema excluyendo `id_cuadrante`, `latitud`, `longitud` y `altitud`. El procedimiento se documenta en [outliers_gruped.html](#).


Variables climáticas semanales. El diagnóstico se realizó sobre la tabla completa. Las variables de temperatura, humedad y viento presentan distribuciones aproximadamente simétricas y un porcentaje muy bajo de extremos bajo Tukey (entre 0 % y 0,03 %); con el factor 3,0 no se identifican extremos severos. La `precip_total_semana` constituye la excepción: al ser un acumulado semanal fuertemente asimétrico, la regla de Tukey marca el 8,98 % de las observaciones y la ampliada el 4,51 %, aunque la regla de percentiles solo señala el 1,00 %; estos valores corresponden a semanas de lluvia intensa operativamente plausibles. La Tabla 5.19 resume estos resultados y las Figuras 5.5 y 5.6 muestran los diagramas de caja y los histogramas sobre las 90,128 observaciones.

Tabla 5.19: Valores extremos en variables climáticas semanales (tabla agrupada)

Variable	Mediana	% IQR 1.5	% IQR 3.0	% P1-P99
temp_media_semana	24,84	0,00	0,00	1,95
temp_max_semana	32,76	0,00	0,00	1,99
temp_min_semana	18,95	0,03	0,00	1,96
humedad_media_semana	72,28	0,00	0,00	1,97
viento_medio_semana	0,91	0,00	0,00	1,99
viento_max_semana	1,29	0,00	0,00	1,69
precip_total_semana	618,8	8,98	4,51	1,00

Diagramas de caja — variables climáticas semanales

Data agrupada cuadrante x semana | N = 90,128 observaciones

**Figura 5.5:** Diagramas de caja de las variables climáticas semanales en la tabla agrupada ($N_{\text{agr}} = 90,128$).




Figura 5.6: Histogramas de las variables climáticas semanales en la tabla agrupada ($N_{\text{agr}} = 90,128$).

Variables de severidad y continuidad. En la tabla completa persisten semanas sin interrupción registrada ($Q_1 = Q_3 = 0$ en `usuarios_afectados`, `elementos_afectados` y `n_eventos`), por lo que la regla de Tukey sobre el total es poco informativa para esas variables. El análisis relevante se realiza sobre semanas con evento (valor > 0), con 22,660–24,800 registros según la variable. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha: la mediana de `usuarios_afectados` es 52 usuarios pero su máximo alcanza 69,928; `duracion_total` tiene mediana de 19,7 horas y un máximo de 2,227 horas (≈ 93 días acumulados en la semana). La regla de Tukey marca entre el 11,6 % y el 15,2 % de las semanas con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 5.20 resume estos resultados y las Figuras 5.7 y 5.8 presentan los diagramas de caja e histogramas.

Tabla 5.20: Valores extremos en severidad y continuidad (semanas con evento, valor > 0)

Variable	n	Mediana	Máximo	% IQR 1.5	% IQR 3.0
<code>usuarios_afectados</code>	22,660	52	69,928	15,16	11,21
<code>elementos_afectados</code>	22,660	7	3,626	15,00	10,70
<code>duracion_total</code>	24,800	19,7	2,227	11,56	4,25
<code>n_eventos</code>	22,659	1	58	14,53	5,73




Figura 5.7: Diagramas de caja de severidad y continuidad en semanas con evento (tabla agrupada).




Figura 5.8: Histogramas de severidad y continuidad en semanas con evento (tabla agrupada).

En síntesis, en el grano cuadrante $\times$ semana los extremos climáticos son escasos y operativamente plausibles (con la precipitación acumulada marcada por asimetría natural), mientras que en severidad y continuidad la cola pesada refleja semanas de alta afectación o múltiples eventos en un mismo cuadrante. No se aplican transformaciones ni exclusiones en esta etapa; las decisiones de tratamiento se documentan y ejecutan en la Etapa 4 a partir de este diagnóstico sobre la tabla de análisis.

5.3.3. Cálculo de estadísticos descriptivos

Tras el diagnóstico de completitud (Sección 5.3.1) y el análisis de valores extremos (Sección 5.3.2), se calculó un conjunto sistemático de estadísticos descrip-

tivos sobre el panel consolidado ($N = 87,007,074$ observaciones activo $\times$ día).

Para cada variable cuantitativa se estimaron: (i) conteo de observaciones válidas (n) y porcentaje de NA respecto a N ; (ii) para variables de interrupción, el porcentaje de ceros sobre el panel completo; (iii) medidas de tendencia central (media y mediana); (iv) medidas de dispersión (desviación estándar y coeficiente de variación en porcentaje); y (v) cuantiles de orden 25, 50 y 75 %, junto con los valores mínimo y máximo. En variables categóricas se reportaron frecuencias absolutas y relativas. Dado que las variables de severidad y continuidad están dominadas por ceros (días sin falla), el análisis cuantitativo se presenta en dos ámbitos complementarios: *panel completo* e *días con evento* (valor > 0), coherente con la estrategia de la Sección 5.3.2.

Variables climáticas. El cálculo se realizó sobre observaciones sin NA ($n = 83,605,236$; 3,91 % de incompletitud, coherente con la Sección 5.3.1). La Tabla 5.21 resume los resultados y la Figura 5.9 contrasta las medias con barras de error de ± 1 desviación estándar.

Las variables térmicas y de humedad presentan dispersión moderada: la *temperatura_media_c* tiene media de 24,42 °C, mediana de 25,47 °C y desviación estándar de 4,27 °C (coeficiente de variación CV = 17,5 %); la *temperatura_minima_c* y la *temperatura_maxima_c* delimitan un rango diario típico entre P25–P75 de aproximadamente 16,6–22,5 °C y 27,0–34,2 °C, respectivamente. La *humedad_relativa_pct* se concentra en valores altos (mediana 69,1 %, media 68,8 %). La *velocidad_viento_ms* es baja en términos absolutos (mediana 1,20 m/s, máximo 4,34 m/s), con CV elevado (68,9 %) por la proximidad frecuente al cero.

La *precipitacion_total_mm* exhibe el comportamiento más heterogéneo: media 2,09 mm, mediana 0,50 mm, P75 2,22 mm y máximo 82,82 mm, con CV = 211,8 %. La mediana inferior a la media y el percentil 25 en cero reflejan abundantes días sin lluvia registrada, en línea con el diagnóstico de extremos de la Sección 5.3.2. Estos patrones son compatibles con el clima de la zona de estudio y no sugieren, por sí solos, errores sistemáticos de captura.

Tabla 5.21: Estadísticos descriptivos de variables climáticas (observaciones sin NA, $n = 83,605,236$)

Variable	Media	DE	Mín.	P25	Med.	P75	Máx.	CV (%)
velocidad_viento_ms	1,16	0,80	0	0,36	1,20	1,75	4,34	68,9
temperatura_media_c	24,42	4,27	9,84	21,07	25,47	27,49	36,80	17,5
humedad_relativa_pct	68,82	12,71	31,57	58,84	69,08	79,36	97,40	18,5
temperatura_minima_c	19,78	3,86	4,15	16,64	20,91	22,48	31,48	19,5
temperatura_maxima_c	30,47	4,94	13,87	27,00	31,32	34,24	43,87	16,2
precipitacion_total_mm	2,09	4,43	0	0	0,50	2,22	82,82	211,8




Figura 5.9: Medias y desviación estándar (± 1 DE) de las variables climáticas en el panel consolidado ($n = 83,605,236$ observaciones sin NA).

Altitud. Sobre $n = 86,974,206$ observaciones con ALTITUD no faltante (0,04 % de NA), la cota presenta media de 840 m, mediana de 513 m, P25 de 259 m, P75 de 1,356 m y máximo de 3,767 m, con desviación estándar de 738 m (CV = 87,9 %). La diferencia entre media y mediana indica asimetría positiva: la mayor parte de los activos se ubica en cotas moderadas, con una cola hacia zonas de mayor elevación en el territorio de operación.

Variables de severidad y continuidad en el panel completo. La Tabla 5.22 y la Figura 5.10 documentan la estructura cero-inflada del panel. El 99,94 % de las filas registra cero en CANTIDAD_ELEMENTOS, CANTIDAD_USUARIOS, DURACION y FRECUENCIA, de modo que las medias globales son cercanas a cero (por ejemplo, media de CANTIDAD_USUARIOS = 0,16 usuarios y media de DURACION = 0,85 minutos) y no representan el comportamiento típico *cuando ocurre* una interrup-

ción. Los máximos globales ($CANTIDAD_ELEMENTOS = 2,469$; $CANTIDAD_USUARIOS = 34,622$; $DURACION = 332,395$; $FRECUENCIA = 6$) coinciden con los hallazgos de la Sección 5.3.2 y confirman la necesidad de analizar el subconjunto de días con evento por separado.

Tabla 5.22: Estadísticos descriptivos de severidad y continuidad — panel completo ($N = 87,007,074$)

Variable	% cero	Media	DE	Med.	Máx.	CV (%)
CANTIDAD_ELEMENTOS	99,94	0,01	1,74	0	2,469	—
CANTIDAD_USUARIOS	99,94	0,16	28,06	0	34,622	—
DURACION	99,94	0,85	133,34	0	332,395	—
FRECUENCIA	99,94	0,00	0,02	0	6	—




Figura 5.10: Proporción de observaciones en cero en variables de severidad y continuidad (panel completo).

Variables de severidad y continuidad en días con evento. El subconjunto con valor > 0 comprende 48,375 registros para $CANTIDAD_ELEMENTOS$ y $CANTIDAD_USUARIOS$, y 48,364 para $DURACION$ y $FRECUENCIA$ (diferencia mínima asociada a casos con afectación sin duración registrada o viceversa). La Tabla 5.23 y la Figura 5.11 resumen la distribución condicional.

En severidad, la mediana de $CANTIDAD_ELEMENTOS$ es 2 elementos (media 22,3; $P75 = 11$; máximo 2,469), y la de $CANTIDAD_USUARIOS$ es 23 usuarios (media 290,8; $P75 = 117$; máximo 34,622), evidenciando colas pesadas hacia eventos de gran impacto. En continuidad, $DURACION$ presenta mediana de 417 min (≈ 7 h), media de 1,527,6 min ($\approx 25,5$ h), $P25$ de 170 min y $P75$ de 1,293 min, con

máximo de 332,395 min; FRECUENCIA es casi constante en 1 interrupción por día en este subconjunto (mediana y moda = 1; media 1,02; máximo 6), coherente con la regla de conteo del paso 5.2.1.7 (un evento se contabiliza en el día de FECHA_DESCONEXION).

Tabla 5.23: Estadísticos descriptivos de severidad y continuidad en días con evento (valor > 0)

Variable	<i>n</i>	Media	DE	P25	Med.	P75	Máx.	CV (%)
CANTIDAD_ELEMENTOS	48,375	22,29	70,18	1	2	11	2,469	314,8
CANTIDAD_USUARIOS	48,375	290,82	1,154,2	7	23	117	34,622	396,9
DURACION	48,364	1,527,6	5,445,6	170	417	1,293	332,395	356,5
FRECUENCIA	48,364	1,02	0,16	1	1	1	6	15,3





Figura 5.11: Mediana de variables de severidad y continuidad en días con evento (valor > 0).

Variable categórica TIPO. Se calcularon frecuencias sobre el total de filas del panel y sobre activos distintos (ELEMENTO), obteniendo la misma composición porcentual en ambos conteos dado que cada activo conserva un único TIPO en el inventario. La Tabla 5.24 y la Figura 5.12 muestran que los *Transformadores* concentran el 53,32 % de las observaciones (46,389,530 filas; 25,405 activos), seguidos por *Aisladores* con 40,04 % (34,834,602 filas; 19,077 activos). Las categorías *Cuchilla* (5,30 %), *Reconectador* (0,77 %) e *Interruptor* (0,57 %) participan con menor peso en el panel, lo que debe considerarse al estratificar análisis o modelos por tipo de activo.

Tabla 5.24: Distribución de la variable TIPO en el panel consolidado


TIPO	Filas (<i>n</i>)	% filas	Activos	% activos
Transformador	46,389,530	53,32	25,405	53,32
Aisladero	34,834,602	40,04	19,077	40,04
Cuchilla	4,614,302	5,30	2,527	5,30
Reconectador	670,142	0,77	367	0,77
Interruptor	498,498	0,57	273	0,57
Total	87,007,074	100,00	47,649	100,00

**Figura 5.12:** Distribución de filas del panel por TIPO de activo ($N = 87,007,074$).

Patrón temporal de días con interrupción. A partir de FECHA_DIA y de la condición $FRECUENCIA > 0$, se contabilizaron por año calendario las filas activo × día con al menos una interrupción iniciada en ese día. La Tabla 5.25 y la Figura 5.13 muestran un volumen relativamente estable entre 2021 y 2023 (entre 4,759 y 5,621 días con evento; 0,027–0,032 % del panel anual), un incremento en 2024 (14,862 días; 0,085 %) y un máximo en 2025 (18,143 días; 0,104 %). Este comportamiento es consistente con una mayor captura o depuración de eventos en los años recientes del periodo de estudio, y se examina con mayor detalle en la subsección de análisis temporal (Sección 5.3.5).

Tabla 5.25: Días activo $\times$ día con FRECUENCIA > 0 por año calendario

Año	Filas del año	Días con evento	% sobre filas del año
2021	17,391,885	4,979	0,0286
2022	17,391,885	4,759	0,0274
2023	17,391,885	5,621	0,0323
2024	17,439,534	14,862	0,0852
2025	17,391,885	18,143	0,1043

**Figura 5.13:** Número de filas activo $\times$ día con al menos una interrupción (FRECUENCIA > 0) por año.

En síntesis, los estadísticos descriptivos confirman un panel operativamente completo en variables de interrupción (sin NA), con incompletitud acotada al bloque climático y a ALTITUD; variables meteorológicas acordes con la zona de estudio; severidad y continuidad fuertemente cero-infladas en el grano diario, con distribuciones de cola pesada en días con evento; composición del inventario dominada por transformadores y aisladores; y un aumento reciente en el conteo de días con interrupción registrada. Estos resultados fundamentan las subsecciones siguientes (forma de las distribuciones, patrones temporales y correlaciones) y las decisiones de transformación e imputación de la Etapa 4.

5.3.4. Análisis de la distribución de variables**5.3.5. Análisis temporal de eventos****5.3.6. Identificación de patrones y tendencias****5.3.7. Visualización exploratoria****5.3.8. Análisis de correlación y asociación****5.3.9. Evaluación inicial de relaciones multivariadas****5.3.10. Segmentación exploratoria****5.3.11. Resultados y entregables de la etapa**

Resultado: conocimiento exploratorio del comportamiento de los datos y hallazgos relevantes para el modelado.

Entregable: Documento de análisis descriptivo y exploratorio (EDA).

5.4. Etapa 4 – Ingeniería de variables y preparación del modelo**Objetivo específico asociado: OE2**

Objetivo: construir las variables analíticas necesarias para el entrenamiento de modelos predictivos, asegurando un dataset consistente, balanceado y estadísticamente apto para la modelación.

A partir de los hallazgos del EDA, en esta etapa se transforma el dataset consolidado en una representación analítica adecuada para el entrenamiento de modelos. Esto incluye la definición formal de la variable respuesta, la construcción de variables predictoras informadas por el comportamiento observado, la depuración y codificación de covariables, la estandarización de variables continuas y la definición de las particiones temporales de entrenamiento y prueba. El preprocesamiento orientado al modelado —incluida la selección de variables con base en los análisis de asociación del EDA— se concentra en esta etapa, en coherencia con criterios de estabilidad numérica, identificabilidad del modelo y validez de supuestos.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

-
- 5.4.1. Construcción de variables predictoras
 - 5.4.2. Construcción de la variable respuesta
 - 5.4.3. Análisis de asociación y depuración de variables cuantitativas
 - 5.4.4. Análisis de asociación y depuración de variables cualitativas
 - 5.4.5. Codificación de variables categóricas
 - 5.4.6. Estandarización de variables cuantitativas
 - 5.4.7. Generación de ventanas temporales
 - 5.4.8. Partición de datos en entrenamiento y prueba
 - 5.4.9. Construcción de matrices de diseño
 - 5.4.10. Reducción de dimensionalidad
 - 5.4.11. Segmentación analítica
 - 5.4.12. Transformaciones adicionales para modelado
 - 5.4.13. Resultados y entregables de la etapa

Resultado: dataset analítico listo para entrenamiento y validación del modelo.

Entregable: Reporte técnico de ingeniería de variables y dataset analítico documentado.

5.5. Etapa 5 – Modelado predictivo y evaluativo

Objetivo específico asociado: OE2 y OE3

Objetivo: entrenar, validar y evaluar modelos predictivos utilizando métricas de desempeño que permitan estimar *SAIDI* y *SAIFI* por circuito o área.

En esta etapa se desarrollan y evalúan diversos modelos estadísticos y de aprendizaje automático. La selección del enfoque (supervisado, no supervisado o híbrido) se determina según los hallazgos del análisis exploratorio, la naturaleza de los datos disponibles y los requerimientos de interpretabilidad. La evaluación comparativa considera métricas de error como *RMSE*, *MAE* y *MAPE*, así como la estabilidad del modelo y la validez de supuestos. Adicionalmente, se realiza un análisis de importancia de variables mediante técnicas interpretables, con el objetivo de identificar los factores operativos, técnicos o climáticos que influyen de manera significativa en la calidad del servicio.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.5.1. Selección de algoritmos**5.5.2. Entrenamiento del modelo****5.5.3. Validación del modelo****5.5.4. Ajuste de hiperparámetros****5.5.5. Evaluación de desempeño****5.5.6. Comparación de modelos****5.5.7. Interpretación de resultados****5.5.8. Resultados y entregables de la etapa**

Resultado: modelo predictivo validado y evaluado técnicamente.

Entregables: Informe de evaluación comparativa de modelos predictivos (OE3) y reporte técnico de importancia de variables (OE2).

5.6. Etapa 6 – Cierre metodológico, documentación y reportes

Objetivo específico asociado: OE1–OE2–OE3

Objetivo: presentar los resultados obtenidos y documentar el proceso metodológico desarrollado, asegurando la reproducibilidad y la trazabilidad de los hallazgos.

En la etapa final se consolidan los resultados del proyecto y se documentan de forma integral las técnicas aplicadas, las transformaciones realizadas y el código reproducible (en R o Python). El capítulo incluye apéndices técnicos, tablas de validación, bibliografía y lineamientos de reproducibilidad, así como una discusión orientada a interpretar los hallazgos en términos técnicos y operativos para la toma de decisiones del operador de red.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.6.1. Presentación de resultados del modelo**5.6.2. Métricas de desempeño****5.6.3. Hallazgos principales****5.6.4. Interpretación técnica y operativa****5.6.5. Generación de reportes****5.6.6. Discusión de resultados****5.6.7. Limitaciones y trabajos futuros****5.6.8. Resultados y entregables de la etapa**

Resultado: documentación final del proyecto y resultados consolidados.

Entregables: Compendio de documentación del proyecto (informe final, informe descriptivo, informe de evaluación de modelos y reporte técnico de variables relevantes), código reproducible y documentación detallada de procesos y transformaciones.

Resultados

6.1. Resultados de la estimación del modelo

Discusión y trabajo futuro

7.1. Discusión

7.2. Trabajos futuros

Conclusiones

- 8.1. Conclusión asociada al objetivo general
- 8.2. Conclusión asociada al objetivo específico 1
- 8.3. Conclusión asociada al objetivo específico 2
- 8.4. Conclusión asociada al objetivo específico 3

Bibliografía

- [1] Comisión de Regulación de Energía y Gas (CREG), «Resolución CREG 015 de 2018 – Por la cual se establecen los indicadores de calidad del servicio de energía eléctrica y las fórmulas de compensación,» CREG, Bogotá, Colombia, inf. téc., 2018. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0015_2018.htm
- [2] S.-S. de Servicios Públicos Domiciliarios, «Resolución SSPD 20192200020155,» Superintendencia de Servicios Públicos Domiciliarios, inf. téc., 2019, [Online; accessed 2025-11-23]. dirección: <https://www.superservicios.gov.co/node/5072>
- [3] IEEE Power and Energy Society, «IEEE Std 1366-2012: IEEE Guide for Electric Power Distribution Reliability Indices,» IEEE, New York, USA, inf. téc., 2012.
- [4] IDEAM, «Boletín climático nacional,» Instituto de Hidrología, Meteorología y Estudios Ambientales, Bogotá, Colombia, inf. téc., 2023.
- [5] J. M. A. Ospina y T. L. López, «Efecto de variables meteorológicas en la confiabilidad del servicio eléctrico en Colombia,» *Revista Energética Colombiana*, vol. 18, n.º 2, págs. 67-75, 2020.
- [6] D. M. Pérez y L. J. Echeverría, «Aplicación de herramientas de analítica de datos para la mejora de indicadores de calidad eléctrica en redes de distribución,» *Ingeniería y Desarrollo*, vol. 39, n.º 1, págs. 25-40, 2021.
- [7] Y. L. Huang y Z. M. Zhang, «Application of deep learning to predict SAIDI and SAIFI indicators in smart grids,» *IEEE Transactions on Smart Grid*, vol. 11, n.º 6, págs. 5153-5163, 2020.
- [8] República de Colombia, *Decreto Único Reglamentario del Sector Presidencia de la República 1081 de 2015; Decreto 103 de 2015; Ley 1712 de 2014 – Transparencia y Acceso a Información Pública; Resolución 1519 de 2020 – Gobierno Digital*, Marco normativo sobre transparencia y acceso a la información pública en Colombia, 2015.

- [9] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Circular 063 de 2019 – Criterios técnicos para el cálculo de indicadores de calidad del servicio de energía eléctrica,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, Circular 063, 2019, [En línea]. dirección: [https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/\\$FILE/Circular063-2019.pdf](https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/$FILE/Circular063-2019.pdf)
- [10] Y. Wang y S. Chen, «Modern reliability assessment of power distribution systems: A data-driven approach,» *Energies*, vol. 12, n.º 15, pág. 2857, 2019.
- [11] K. Xie, H. Zhang y C. Singh, «Reliability forecasting models for electrical distribution systems considering component failures and planned outages,» *International Journal of Electrical Power & Energy Systems*, vol. 78, págs. 337-346, 2016. doi: [10.1016/j.ijepes.2016.01.020](https://doi.org/10.1016/j.ijepes.2016.01.020)
- [12] S. Das, P. Kankanala y A. Pahwa, «Outage Estimation in Electric Power Distribution Systems Using a Neural Network Ensemble,» *Energies*, 2021. doi: [10.3390/en14164797](https://doi.org/10.3390/en14164797)
- [13] M. Angalakudati et al., «Improving emergency storm planning using machine learning,» en *2014 IEEE PES T&D Conference and Exposition*, 2014. doi: [10.1109/TDC.2014.6863406](https://doi.org/10.1109/TDC.2014.6863406)
- [14] D. Owerko, F. Gama y A. Ribeiro, «Predicting Power Outages Using Graph Neural Networks,» en *IEEE Global Conference on Signal and Information Processing*, 2018. doi: [10.1109/GLOBALSIP.2018.8646486](https://doi.org/10.1109/GLOBALSIP.2018.8646486)
- [15] D. Cerrai, P. L. Watson y E. N. Anagnostou, «Assessing the effects of a vegetation management standard on distribution grid outage rates,» *Electric Power Systems Research*, 2019. doi: [10.1016/j.epsr.2019.105909](https://doi.org/10.1016/j.epsr.2019.105909)
- [16] R. Eskandarpour y A. Khodaei, «Machine Learning Based Power Grid Outage Prediction in Response to Extreme Events,» *IEEE Transactions on Power Systems*, 2017. doi: [10.1109/TPWRS.2016.2631895](https://doi.org/10.1109/TPWRS.2016.2631895)
- [17] C. Rudin et al., «Machine Learning for the New York City Power Grid,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012. doi: [10.1109/TPAMI.2011.108](https://doi.org/10.1109/TPAMI.2011.108)
- [18] L. Xu, M.-Y. Chow, J. Timmis y L. Taylor, «Power Distribution Outage Cause Identification With Imbalanced Data Using Artificial Immune Recognition System (AIRS) Algorithm,» *IEEE Transactions on Power Systems*, 2007. doi: [10.1109/TPWRS.2006.889040](https://doi.org/10.1109/TPWRS.2006.889040)
- [19] L. Breiman, «Random Forests,» *Machine Learning*, 2003. doi: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324)

-
- [20] S.-R. Han, S. D. Guikema, S. M. Quiring, K. H. Lee, D. V. Rosowsky y R. A. Davidson, «Estimating the spatial distribution of power outages during hurricanes in the Gulf coast region,» *Reliability Engineering & System Safety*, 2009. DOI: [10.1016/j.ress.2008.02.018](https://doi.org/10.1016/j.ress.2008.02.018)
 - [21] F. Yang, D. W. Wanik, D. Cerrai, M. A. E. Bhuiyan y E. N. Anagnostou, «Quantifying Uncertainty in Machine Learning-Based Power Outage Prediction Model Training: A Tool for Sustainable Storm Restoration,» *Sustainability*, 2020. DOI: [10.3390/su12041525](https://doi.org/10.3390/su12041525)
 - [22] P. Kankanala, S. Das y A. Pahwa, «AdaBoost+: An Ensemble Learning Approach for Estimating Weather-Related Outages in Distribution Systems,» *IEEE Transactions on Power Systems*, 2013. DOI: [10.1109/TPWRS.2013.2281137](https://doi.org/10.1109/TPWRS.2013.2281137)
 - [23] Y. Kor, M. Reformat y P. Musilek, «Predicting Weather-related Power Outages in Distribution Grid,» en *IEEE Power & Energy Society General Meeting*, 2020. DOI: [10.1109/PESGM41954.2020.9281829](https://doi.org/10.1109/PESGM41954.2020.9281829)
 - [24] M. Doostan y B. Chowdhury, «Predicting Lightning-Related Outages in Power Distribution Systems: A Statistical Approach,» *IEEE Access*, 2020. DOI: [10.1109/ACCESS.2020.2991923](https://doi.org/10.1109/ACCESS.2020.2991923)
 - [25] P.-C. Chen y M. Kezunović, «Fuzzy logic approach to predictive risk analysis in distribution outage management,» en *IEEE Power & Energy Society General Meeting*, 2017. DOI: [10.1109/PESGM.2017.8274298](https://doi.org/10.1109/PESGM.2017.8274298)
 - [26] J. He, D. W. Wanik, B. Hartman, E. N. Anagnostou, M. Astitha y M. Frediani, «Nonparametric Tree-Based Predictive Modeling of Storm Outages on an Electric Distribution Network,» *Risk Analysis*, 2017. DOI: [10.1111/risa.12652](https://doi.org/10.1111/risa.12652)
 - [27] H. Hou et al., «Spatial distribution assessment of power outage under typhoon disasters,» *International Journal of Electrical Power & Energy Systems*, 2021. DOI: [10.1016/j.ijepes.2021.107169](https://doi.org/10.1016/j.ijepes.2021.107169)
 - [28] M. Li et al., «Prediction of Power Outage Quantity of Distribution Network Users under Typhoon Disaster Based on Random Forest and Important Variables,» 2021. DOI: [10.1155/2021/6682242](https://doi.org/10.1155/2021/6682242)
 - [29] C. Zhai, T. Y.-J. Chen, A. White y S. D. Guikema, «Power outage prediction for natural hazards using synthetic power distribution systems,» *Reliability Engineering & System Safety*, 2021. DOI: [10.1016/j.ress.2020.107348](https://doi.org/10.1016/j.ress.2020.107348)
 - [30] D. Zhu, D. Cheng, R. Broadwater y C. Scirbona, «Storm modeling for prediction of power distribution system outages,» *Electric Power Systems Research*, 2007. DOI: [10.1016/j.epsr.2006.08.020](https://doi.org/10.1016/j.epsr.2006.08.020)

- [31] A. Arif y Z. Wang, «Distribution Network Outage Data Analysis and Repair Time Prediction Using Deep Learning,» en *IEEE International Conference on Probabilistic Methods Applied to Power Systems*, 2018. DOI: [10.1109/PMAPS.2018.8440354](https://doi.org/10.1109/PMAPS.2018.8440354)
- [32] D. W. Wanik, E. N. Anagnostou, B. Hartman, M. Frediani y M. Astitha, «Storm outage modeling for an electric distribution network in Northeastern USA,» *Natural Hazards*, 2015. DOI: [10.1007/s11069-015-1908-2](https://doi.org/10.1007/s11069-015-1908-2)
- [33] A. Jaech, B. Zhang, M. Ostendorf y D. S. Kirschen, «Real-Time Prediction of the Duration of Distribution System Outages,» *IEEE Transactions on Power Systems*, 2018. DOI: [10.1109/TPWRS.2018.2860904](https://doi.org/10.1109/TPWRS.2018.2860904)
- [34] D. Sorokin, «Machine learning application for power systems reliability assessment,» en *E3S Web of Conferences*, vol. 461, 2023. DOI: [10.1051/e3sconf/202346101032](https://doi.org/10.1051/e3sconf/202346101032)
- [35] Z. Liu, J. Li, T. Zhang y J. Shao, «Rapid Calculation of Active Distribution Network Reliability Based on Dynamic Equipment Failure Rate,» *Energies*, vol. 16, n.º 14, 2023. DOI: [10.3390/en16145245](https://doi.org/10.3390/en16145245)
- [36] E. Avci, «Hybrid Artificial Intelligence Techniques for Enhanced Electricity Outage Prediction and Management in Distribution Networks,» *Turkish Journal of Electrical Power and Energy Systems*, 2024. DOI: [10.5152/TEPES.2024.24008](https://doi.org/10.5152/TEPES.2024.24008)
- [37] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política de Gestión de Tecnologías de la Información*, Sesión Junta Directiva No. 800, feb. de 2018.
- [38] Unidad de Planeación Minero Energética (UPME), «Plan de expansión de referencia generación - transmisión 2017 - 2031,» Ministerio de Minas y Energía, Bogotá, Colombia, inf. téc., 2017.
- [39] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política Sistema de Gestión Integrado*, Sesión Junta Directiva No. 831, abr. de 2020.
- [40] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Instrumentos de gestión de información pública*, <https://www.cens.com.co/transparencia-y-acceso-a-la-informacion-publica/instrumentos-de-gestion-de-informacion-publica>, En línea; consultado, 2024.
- [41] IDEAM, *E-SGI-PI003 Política Institucional de Gestión de Información Estadística*, <http://www.meteoaeronautica.gov.co/documents/24189/126529520/E-SGI-PI003+-Pol%C3%ADtica+Gesti%C3%B3n+de+Informaci%C3%B3n+Estadistica.pdf>, En línea, 2023.

- [42] IDEAM, *Transparencia y acceso a la información pública*, <https://www.ideam.gov.co/transparencia>, En línea, 2024.

A

Appendix

A.1. Parte 1

A.2. Parte 2