Pontificia Universidad Javeriana Cali
Facultad de Ingeniería y Ciencias
Maestría en Ciencia de Datos

Metodología Basada en Métodos de Ciencia de Datos para Pronosticar SAIDI y SAIFI en Redes de Distribución de una Empresa de Energía Eléctrica en el Norte de Santander

Proyecto aplicado para optar al título de Magíster en Ciencia de Datos

Edwin Henao Ochoa

Cindy Lugo Rozo

Edwin Silva Salas

Directora

Sandra Milena Ramírez Buelvas

Pontificia Universidad Javeriana

Santiago de Cali, 2026

A nuestras familias y amigos
Edwin Henao Ochoa
Cindy Lugo Rozo
Edwin Silva Salas

Índice general

Resumen xiv

Introducción **xv**

1 Definición del problema **1**
1.1 Planteamiento del problema 1
1.2 Formulación del problema 4

2 Objetivos del proyecto **5**
2.1 Objetivo general 5
2.2 Objetivos específicos 5

3 Marco de referencia **6**
3.1 Marco teórico 6
3.1.1 Contexto del estudio 6
3.1.2 Métodos y modelos 10
3.1.3 Modelos predictivos y espaciales 16
3.2 Antecedentes 19
3.2.1 Revisión de literatura 19
3.2.2 Antecedentes en Colombia y América Latina 24
3.2.3 Variables explicativas recurrentes en la literatura 25

4 Datos **29**
4.1 Construcción del dataset 29
4.1.1 Lógica estructural 29
4.1.2 Definición de variables de evento 30
4.1.3 Estructura del dataset consolidado 30
4.1.4 Variables incorporadas al panel cuadrante–semana 30
4.2 Procedencia de la información 32
4.3 Consideraciones éticas y disponibilidad de datos y código 33

5 Metodología **34**
5.1 Etapa 1 – Extracción de datos 34
5.1.1 Fuentes de información 35
5.1.2 Sistemas y fuentes consultadas 35

5.1.3 Extracción base y depuración de eventos de interrupción (BRAE) . . . 36
5.1.4 Extracción de afectación por evento . . . 37
5.1.5 Extracción del elemento causante histórico . . . 38
5.1.6 Extracción del elemento causante actual . . . 38
5.1.7 Extracción de inventario GIS . . . 39
5.1.8 Extracción de variables meteorológicas . . . 40
5.1.9 Resumen metodológico de extracción e integración de bases de datos . . . 41
5.2 Etapa 2 - Integración y depuración de datos . . . 41
5.2.1 Lógica de integración entre sistemas . . . 41
5.2.2 Diagrama de flujo de la secuencia de integración . . . 46
5.2.3 Descripción de la tabla base consolidada . . . 46
5.2.4 Descripción de las variables . . . 46
5.2.5 Agrupación de data consolidada por semana y cuadrante 48
5.2.6 Descripción de la tabla base semanal cuadrante . . . 51
5.2.7 Justificación y enriquecimiento del panel cuadrante–semana 53
5.2.8 Evidencia de calidad y confiabilidad de las fuentes . . . 59
5.3 Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA) . . . 61
5.4 Etapa 4 – Ingeniería de variables y preparación del modelo . . . 62
5.4.1 Construcción de variables predictoras . . . 63
5.4.2 Construcción de la variable respuesta . . . 65
5.4.3 Análisis de asociación y depuración de variables cuantitativas . . . 67
5.4.4 Análisis de asociación y depuración de variables cualitativas 70
5.4.5 Codificación de variables categóricas . . . 70
5.4.6 Estandarización de variables cuantitativas . . . 71
5.4.7 Generación de ventanas temporales . . . 72
5.4.8 Partición de datos en entrenamiento y prueba . . . 73
5.4.9 Construcción de matrices de diseño . . . 73
5.4.10 Reducción de dimensionalidad . . . 76
5.4.11 Segmentación analítica . . . 77
5.4.12 Transformaciones adicionales para modelado . . . 78
5.4.13 Resultados y entregables de la etapa . . . 79
5.5 Etapa 5 – Modelado predictivo y evaluativo . . . 79
5.5.1 Selección de algoritmos . . . 79
5.5.2 Entrenamiento del modelo . . . 80
5.5.3 Validación del modelo . . . 82
5.5.4 Ajuste de hiperparámetros . . . 83
5.5.5 Evaluación de desempeño . . . 84
5.5.6 Comparación de modelos . . . 85
5.5.7 Interpretación de resultados . . . 86
5.5.8 Resultados y entregables de la etapa . . . 86

5.6 Etapa 6 – Cierre metodológico, documentación y reportes 87
5.6.1 Presentación de resultados del modelo 87
5.6.2 Métricas de desempeño 88
5.6.3 Hallazgos principales 88
5.6.4 Interpretación técnica y operativa 88
5.6.5 Generación de reportes 89
5.6.6 Discusión de resultados 89
5.6.7 Limitaciones y trabajos futuros 89
5.6.8 Resultados y entregables de la etapa 90
5.7 Relación entre etapas metodológicas y objetivos específicos 90

6 Resultados **92**
6.1 Etapa 1 – Resultados de la extracción de datos 92
6.2 Etapa 2 – Resultados de la integración y depuración de datos . . . 92
6.3 Etapa 3 – Resultados del análisis descriptivo y exploratorio 94
6.3.1 Identificación de datos faltantes 94
6.3.2 Identificación de valores extremos en variables cuantitativas 96
6.3.3 Cálculo de estadísticos descriptivos 99
6.3.4 Análisis de la distribución de variables 101
6.3.5 Análisis temporal de eventos 102
6.3.6 Identificación de patrones, tendencias y visualización exploratoria 106
6.3.7 Análisis de correlación y asociación 109
6.3.8 Evaluación inicial de relaciones multivariadas 112
6.3.9 Segmentación exploratoria 115
6.3.10 Resultados y entregables de la etapa 117
6.3.11 Síntesis de los hallazgos del análisis exploratorio 117
6.4 Etapa 4 – Resultados de la ingeniería de variables 119
6.5 Etapa 5 – Resultados del modelado predictivo y evaluativo 120
6.5.1 Dependencia espacial 121
6.5.2 Pronóstico semanal frente a pronósticos de referencia . . . 121
6.5.3 Pronóstico de la ocurrencia de falla 124
6.5.4 Explicación estructural en corte transversal 125
6.5.5 Variables más relevantes: triangulación entre modelos . . 126
6.6 Etapa 6 – Síntesis general y cierre frente a los objetivos 130

7 Discusión y trabajo futuro **133**
7.1 Discusión 133
7.2 Trabajos futuros 136

8 Conclusiones **139**
8.1 Conclusión asociada al objetivo general 139
8.2 Conclusión asociada al objetivo específico 1 139
8.3 Conclusión asociada al objetivo específico 2 140
8.4 Conclusión asociada al objetivo específico 3 140

8.5 Recomendaciones para el operador de red 141

A Anexos **149**
A.1 Diagrama de integración del panel 149
A.2 Código de extracción de datos 149
A.2.1 Consultas SQL 149
A.2.2 Fragmentos Python 151
A.3 Informes reproducibles (HTML) 152
A.3.1 Consolidación del panel activo–día 152
A.3.2 Agrupación cuadrante × semana 152
A.3.3 Datos faltantes (tabla agrupada) 152
A.3.4 Valores extremos (panel consolidado) 152
A.3.5 Valores extremos (tabla agrupada) 152
A.3.6 Estadísticos descriptivos 152
A.3.7 Distribución de variables 152
A.3.8 Análisis temporal de eventos 152
A.3.9 Emparejamiento evento–elemento 153
A.3.10 Materialización de D_{mod} 153
A.3.11 Identificación de patrones 153
A.3.12 Análisis de correlación 153
A.3.13 Análisis multivariado 153
A.3.14 Segmentación exploratoria 153
A.3.15 EDA consolidado 153
A.3.16 Asociación y depuración de variables cuantitativas 153
A.3.17 Justificación de la agregación espacial 153
A.3.18 Infraestructura eléctrica por cuadrante 154
A.3.19 Estratificación municipal 154
A.3.20 Sismicidad SGC 154
A.3.21 Topología de red eléctrica 154
A.3.22 Integración del panel final 154
A.3.23 Cargue NASA POWER semanal 154
A.3.24 Cargue de eventos semanales 154
A.3.25 Unión del panel semanal 154
A.3.26 Ingeniería de variables para SAIDI y SAIFI 154
A.3.27 Incorporación y selección de rezagos 155
A.3.28 Modelo espacial de SAIDI 155
A.3.29 Modelo espacial de SAIFI 155
A.3.30 Re-estimación final de la Etapa 5 155
A.3.31 Reporte técnico de priorización territorial 155
A.4 Catálogo de datos y métricas de integridad 155
A.5 Robustez de la construcción del indicador operativo 158
A.6 Artefactos reproducibles y reportes técnicos 159
A.7 Muestra completa de tablas base del proyecto 160
A.7.1 Tabla base consolidada (activo–día) 161

A.7.2 Tabla base semanal cuadrante 162
A.8 Figuras complementarias de completitud, extremos y localización territorial 164
A.9 Figuras complementarias del análisis exploratorio 164
A.10 Análisis de componentes principales (PCA) exploratorio 180
A.10.1 PCA exploratorio del bloque climático 180
A.10.2 PCA exploratorio del bloque operativo 181

Lista de figuras

5.1 Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. 5×2.5 km). 49
5.2 Distribución del número de elementos de infraestructura por cuadrante real. 54
5.3 Composición tipológica de infraestructura en los 30 cuadrantes con mayor número de elementos. 54
5.4 Mapa de cuadrantes según estrato socioeconómico predominante del municipio. 55
5.5 Distribución de cuadrantes por estrato predominante municipal. 56
5.6 Serie temporal de sismos considerados en la exposición territorial del panel. 56
5.7 Histograma de magnitudes de sismos integrados al panel cuadrante–semana. 57
5.8 Distribución de la longitud de red eléctrica por cuadrante. 58
5.9 Relación exploratoria entre longitud de red y $SAIDI$ por cuadrante. 58
5.10 Series temporales de $SAIDI$ y $SAIFI$ en el panel enriquecido cuadrante–semana. 59
5.11 Relación exploratoria entre NDVI semanal y $SAIDI$ en el panel enriquecido. 60
5.12 Asociación de Spearman entre candidatas *ex ante* y $SAIFI$ (entrenamiento 2024). 68
5.13 Agrupamiento jerárquico de candidatas ($1-|\rho|$ Spearman); la línea punteada marca el umbral $|\rho| = 0.70$. 69
5.14 VIF del conjunto cuantitativo retenido tras la depuración iterativa (umbral 5). 69
5.15 Mapa de $SAIDI$ promedio por cuadrante usado en el diagnóstico de autocorrelación espacial (Moran). 81
5.16 Partición temporal entrenamiento/prueba para el modelado de $SAIDI$ (holdout $\approx 15\,\%$ final de semanas). 82

6.1 Proporción de ceros en las variables de severidad y continuidad de la tabla agrupada. 102

6.2 Comparación anual entre eventos BRAE y eventos reflejados en el panel espacial. Las etiquetas indican el porcentaje de cobertura respecto a BRAE; la brecha histórica se explica por la incompatibilidad entre el código de activo registrado en OMS-SPARD y el código de sitio del inventario GIS. 104
6.3 Evolución semanal de eventos sobre D_{mod} (2024–2025). 107
6.4 Persistencia y estructura temporal de la serie semanal de eventos en D_{mod}. 107
6.5 Intensidad territorial de eventos por cuadrante (2024–2025). . . . 108
6.6 Asociación de Spearman entre variables climáticas y operativas en D_{mod}. 110
6.7 Inflación de varianza en el bloque climático (modelo auxiliar `n_eventos` $\sim$ `clima`; D_{mod}). 113
6.8 Perfiles territoriales de cuadrantes según actividad y clima ($k = 4$; D_{mod}). 116
6.9 RMSE de validación interna del Random Forest de SAIDI según `mtry` y tamaño mínimo de nodo. La figura de SAIFI, con el mismo patrón, se incluye en el informe de la Etapa 5. 124
6.10 Importancia por permutación de las predictoras en el Random Forest ajustado de SAIDI. 127
6.11 Importancia por permutación de las predictoras en el Random Forest ajustado de SAIFI. 128
6.12 SAIDI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1 + y)$). 129
6.13 SAIFI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1 + y)$). 130

A.1 Estructura del panel de datos activo–día 149
A.2 Completitud del panel consolidado y extremos en variables diarias. 164
A.3 Extremos en variables agregadas y localización de los cuadrantes más activos. 165
A.4 Segmentación exploratoria de `n_eventos` por nivel de actividad y régimen de lluvia. 165
A.5 Distribución de las variables climáticas: forma y cola (muestra de $200\,000$ observaciones). 166
A.6 Distribución de la severidad y continuidad en días con evento: forma y cola. 166
A.7 Distribución de las variables climáticas semanales: forma y cola ($N_{\mathrm{agr}} = 90\,128$). 167
A.8 Distribución de la severidad y continuidad en semanas con evento: forma y cola. 167
A.9 Distribución de las variables numéricas de la tabla agrupada: forma y cola ($N_{\mathrm{agr}} = 90\,128$). 168

A.10 Forma de la distribución de las variables climáticas semanales ($N_{\text{agr}} = 90\,128$). 168
A.11 Frecuencia de semanas-cuadrante según actividad de eventos ($N_{\text{agr}} = 90\,128$). 169
A.12 Distribución de la severidad y continuidad en escala logarítmica desplazada (semanas con evento). 169
A.13 Distribución de la precipitación acumulada semanal en escala original y logarítmica desplazada ($N_{\text{agr}} = 90\,128$). 170
A.14 Evolución semanal de los eventos de interrupción (suma territorial), 2021–2025. 170
A.15 Total anual de eventos de interrupción sobre la tabla agrupada. . 170
A.16 Distribución del total semanal de eventos según mes calendario (2021–2025). 171
A.17 Persistencia y estructura temporal de la serie semanal de eventos (rezagos en semanas). 171
A.18 Evolución semanal de usuarios afectados y duración acumulada. 172
A.19 Número de cuadrantes con al menos un evento por semana (extensión territorial de la actividad). 172
A.20 Estacionalidad mensual del total semanal de eventos en D_{mod}. . . 173
A.21 Quince cuadrantes con mayor número acumulado de eventos en D_{mod}. 173
A.22 Relación entre precipitación semanal y frecuencia de eventos por cuadrante en D_{mod}. 174
A.23 Segmentación de cuadrantes por nivel de actividad acumulada en D_{mod}. 174
A.24 Correlaciones de Spearman en el bloque climático semanal (D_{mod}). 175
A.25 Correlaciones de Spearman entre variables operativas en D_{mod}. . 175
A.26 Coeficientes de Spearman entre variables climáticas y operativas en D_{mod}. 176
A.27 Correlaciones de Spearman en semanas-cuadrante con `n_eventos` > 0 ($n = 13\,351$). 176
A.28 Agrupamiento de redundancias entre variables climáticas (Sección 3.1.2). 177
A.29 Efecto conjunto del clima reducido sobre la frecuencia de eventos (diagnóstico EDA). 177
A.30 Perfil normalizado por nivel de actividad (eventos, usuarios, duración, semanas activas, clima). 178
A.31 Eventos acumulados por nivel de actividad y año en D_{mod}. 178
A.32 Perfil medio por cluster de cuadrantes (variables operativas y climáticas). 179
A.33 Figuras del PCA exploratorio climático y operativo. 182

Lista de tablas

3.1 Síntesis de los antecedentes más relacionados con este trabajo . . 26

4.1 Estructura del dataset consolidado (grano activo × día). 31

5.1 Muestra de eventos depurados de interrupción (BRAE; primeras cinco filas) 36
5.2 Muestra de afectación por evento (BRAE + QA_TTC1; primeras cinco filas) 37
5.3 Muestra de elemento causante histórico (OMS SPARD; primeras cinco filas) 38
5.4 Muestra de elemento causante actual (OMS SP7; primeras cinco filas) 39
5.5 Muestra de inventario georreferenciado de activos (GIS GTECH; primeras cinco filas) 40
5.6 Muestra de variables meteorológicas (NASA POWER; primeras cinco filas) 41
5.7 Resumen metodológico de extracción e integración de bases de datos 42
5.8 Vista previa de la tabla base consolidada (grano activo–día) 46
5.9 Estructura de la tabla base semanal cuadrante (`data_agrupada.csv`). 52
5.10 Vista previa de la tabla base semanal cuadrante (grano cuadrante–semana) 53
5.11 Partición final de variables antes de la estimación: respuesta $\mathbf{y}$, predictoras $\mathbf{X}$, llaves y exclusiones 75
5.12 Correspondencia entre preguntas de sistematización, objetivos específicos y etapas metodológicas 91

6.1 Resumen de valores faltantes por variable en el panel consolidado 95
6.2 Valores extremos y dispersión relativa en variables climáticas (panel completo) 97
6.3 Valores extremos y dispersión relativa en severidad y continuidad (días con evento, valor > 0) 97

6.4 Valores extremos y dispersión relativa en variables climáticas semanales (tabla agrupada) . . . 98
6.5 Valores extremos y dispersión relativa en severidad y continuidad (semanas con evento, valor > 0) . . . 99
6.6 Estadísticos descriptivos de variables climáticas semanales (tabla agrupada) . . . 100
6.7 Estadísticos descriptivos de severidad y continuidad (tabla agrupada; panel completo) . . . 100
6.8 Distribución de frecuencias por actividad semanal del cuadrante 100
6.9 Cobertura anual de la trazabilidad al inventario GIS y al panel espacial. . . . 104
6.10 Asociación Spearman entre clima y variables operativas: pares de mayor magnitud (D_{mod}; panel completo) . . . 111
6.11 Inflación de varianza con subconjunto climático reducido propuesto para la Etapa 4 . . . 113
6.12 Desempeño en el conjunto de prueba para SAIDI (escala $\log(1+y)$; $N = 2\,215$) . . . 121
6.13 Desempeño en el conjunto de prueba para SAIFI (escala $\log(1+y)$; $N = 2\,215$) . . . 122
6.14 Prueba de Diebold–Mariano sobre los errores cuadráticos de prueba (horizonte de una semana) . . . 122
6.15 Ajuste de hiperparámetros del Random Forest: mejores configuraciones según la validación temporal interna . . . 123
6.16 Validación de origen móvil: RMSE medio (desviación estándar) en cuatro cortes, escala $\log(1 + y)$ . . . 124
6.17 Modelos de corte transversal ($N = 343$): comparación OLS, SAR y SEM . . . 125
6.18 Corte transversal de SAIDI promedio por cuadrante, modelo *stepwise* ($N = 343$; $R^2 = 0.900$) . . . 126
6.19 Corte transversal de SAIFI promedio por cuadrante, modelo *stepwise* ($N = 343$; $R^2 = 0.837$) . . . 126
6.20 Triangulación de la relevancia de las variables entre modelos . . . 127
6.21 Síntesis de resultados por etapa metodológica . . . 131
6.22 Cierre de resultados frente a los objetivos específicos . . . 132

A.1 Catálogo de fuentes: cobertura, integridad y limitaciones . . . 157
A.2 Diccionario de variables del panel de modelado cuadrante $\times$ semana 158
A.3 Concordancia entre la versión agregada y la versión evento a evento de $\text{SAIDI}_{q,s}$ (D_{mod}, semanas con falla) . . . 159
A.4 Cuadrantes de prioridad A según su participación en la afectación de 2024–2025 . . . 160
A.5 Muestra de la tabla base consolidada (grano activo–día) – Parte 1: activo y fecha . . . 161

A.6 Muestra de la tabla base consolidada (grano activo–día) – Parte 2: severidad y clima inicial (continuación) 161
A.7 Muestra de la tabla base consolidada (grano activo–día) – Parte 3: clima complementario (continuación) 161
A.8 Muestra de la tabla base consolidada (grano activo–día) – Parte 4: variables de continuidad (continuación) 162
A.9 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo 162
A.10 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 2: temperatura (continuación) 162
A.11 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación) 163
A.12 Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación) 163
A.13 Cargas (loadings) del PCA climático: peso de cada variable por componente (D_{mod}; PC1–PC3) 181
A.14 Cargas (loadings) del PCA operativo en escala logarítmica desplazada (D_{mod}; PC1–PC2) 181

Resumen

La continuidad del servicio de energía eléctrica en Colombia se mide con los indicadores SAIDI y SAIFI, cuyo incumplimiento genera compensaciones para los operadores de red. En la empresa de distribución de Norte de Santander objeto de estudio, la información sobre interrupciones está dispersa en sistemas heterogéneos (BRAE, OMS, GIS) con codificaciones distintas, lo que impide identificar dónde y cuándo se concentra la afectación. Este trabajo desarrolló una metodología basada en CRISP-DM para pronosticar SAIDI y SAIFI por zona e identificar los factores técnicos, operativos y climáticos que más influyen en su comportamiento. Se integraron cinco sistemas corporativos y cinco fuentes externas en un panel de 87 millones de registros activo $\times$ día, agregado a 344 cuadrantes $\times$ semana. El diagnóstico de integración reveló que solo el 31 % de los eventos de 2021–2023 podía vincularse a la red georreferenciada, frente al 95 % en 2025, por el uso de códigos de activo en lugar de códigos de sitio; por ello el modelado se restringió a 2024–2025. Se compararon modelos de panel (OLS agrupado, efectos fijos y Random Forest ajustado), un clasificador de ocurrencia de falla y modelos espaciales SAR y SEM, con validación temporal, predictoras disponibles antes de la semana pronosticada y dos pronósticos de referencia. Los efectos fijos de cuadrante obtuvieron el menor error semanal en ambos indicadores, entre 20 y 26 % por debajo de la persistencia, pero sin mejorar de forma significativa el promedio histórico de cada cuadrante; la ocurrencia de falla se pronosticó con un AUC de 0.84. Los modelos espaciales explicaron entre el 84 y el 90 % de la variación territorial, con el tamaño y la longitud de la red como factores principales y la vegetación como factor adicional en SAIDI; el clima de la semana anterior no resultó significativo. Se concluye que la afectación tiene un componente territorial estable y predecible, útil para priorizar inversión, mantenimiento y poda y para anticipar dónde ocurrirán fallas, y un componente de magnitud semanal que no es pronosticable con la información disponible. Los productos son un panel analítico trazable, un catálogo de datos, informes reproducibles y un procedimiento para anticipar la degradación de la continuidad, priorizar el mantenimiento en zonas críticas y apoyar el cumplimiento de las metas regulatorias.

Palabras clave: SAIDI; SAIFI; calidad del servicio eléctrico; panel espacio-temporal; Random Forest; econometría espacial; CRISP-DM.

Introducción

Sin duda, la energía eléctrica es vital para el progreso de cada región, tanto social, económica como industrialmente. En Colombia, el acceso a este servicio está estrictamente regulado en términos de provisión, con el objetivo de asegurar que todos los usuarios cuenten con un suministro de energía constante, seguro y de alta calidad para vivir y trabajar [1]. Los operadores de red tienen de manera continua la responsabilidad de garantizar que la entrega de energía sea confiable para hogares, instituciones y negocios, evitando fallas en la prestación del servicio en cualquier tipo de edificación.

No obstante, esta tarea no es sencilla. La operación de los sistemas de distribución de energía se ve afectada por múltiples factores técnicos, ambientales y operativos, así como por la duración y frecuencia de las interrupciones del servicio. En este contexto, la Comisión de Regulación de Energía y Gas (CREG) adoptó los indicadores SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) como los criterios oficiales para evaluar la calidad del servicio en las redes de distribución, mediante la Resolución CREG 015 de 2018 [1]. Estos indicadores permiten evaluar el desempeño operativo y facilitan la implementación de esquemas de compensación y control por parte de la Superintendencia de Servicios Públicos Domiciliarios (SSPD) [2].

Sin embargo, la gestión efectiva de estos indicadores ha resultado compleja, dada la heterogeneidad de los eventos que originan las interrupciones y la limitada conectividad de la información almacenada en sistemas dispares como SCADA, OMS, GIS, CIS y bases de datos externas. Debido a que los registros operativos, climáticos y de mantenimiento se encuentran dispersos y fragmentados en múltiples plataformas, construir modelos analíticos capaces de pronosticar $SAIFI$ y $SAIDI$ en distintas áreas o circuitos representa un desafío significativo.

Esta brecha limita la capacidad de las empresas para tomar decisiones oportunas, priorizar inversiones, mejorar la planificación del mantenimiento y responder adecuadamente a los requerimientos regulatorios. En consecuencia, resulta fundamental desarrollar herramientas apoyadas en ciencia de datos que permitan consolidar información histórica, identificar patrones relevantes y pronosticar $SAIFI$ y $SAIDI$.

Este trabajo presenta técnicas para la recopilación de datos provenientes de plataformas operativas internas y fuentes externas, así como el análisis de modelos estadísticos y de aprendizaje automático orientados al pronóstico de $SAIFI$ y $SAIDI$ en una empresa de distribución de energía que opera en el departamento de Norte de Santander. Al adoptar esta estrategia, se busca anticipar cuándo y con qué intensidad operativa pueden ocurrir las interrupciones, e identificar las influencias técnicas, operativas y climáticas más relevantes en la continuidad del servicio. Este desarrollo constituye una contribución significativa para fortalecer la toma de decisiones basada en evidencia, optimizar los planes de mantenimiento, apoyar el cumplimiento regulatorio y ofrecer un caso académico aplicado sobre el uso de técnicas analíticas en el sector eléctrico regulado, beneficiando a más de 600 000 usuarios.

Las principales contribuciones del trabajo son cuatro. Primera, un panel espacio-temporal trazable cuadrante $\times$ semana que integra eventos, red, usuarios, clima y exposición externa para una empresa colombiana de distribución. Segunda, la identificación y cuantificación de una falla de gobernanza de datos —la coexistencia de códigos de sitio y de activo en el sistema de gestión de interrupciones—, que dejaba fuera del análisis territorial cerca del 70 % de los eventos de 2021–2023. Tercera, un esquema explícito de disponibilidad de la información (predictoras *ex ante* frente a variables de impacto posterior) que evita la fuga de información y produce métricas representativas del uso real del modelo. Cuarta, una evaluación de modelos de pronóstico semanal, de ocurrencia y espaciales frente a pronósticos de referencia explícitos, que delimita qué parte de la afectación es pronosticable con la información disponible —el nivel territorial y la ocurrencia de falla— y cuál no —la magnitud semanal—, y la traduce en dos usos operativos: la anticipación de las zonas con mayor probabilidad de falla y la priorización territorial de la inversión.

El documento se organiza de la siguiente manera. En el Capítulo 1 se presenta el planteamiento y la formulación del problema de continuidad del servicio. En el Capítulo 2 se exponen el objetivo general y los objetivos específicos, alineados con las preguntas de investigación. En el Capítulo 3 se desarrolla el marco teórico (definiciones regulatorias de SAIDI y SAIFI, exclusiones y factores asociados) y los antecedentes sobre modelación de interrupciones e indicadores de confiabilidad. En el Capítulo 4 se describe la fuente y la estructura de los datos empleados. En el Capítulo 5 se detallan las etapas metodológicas, desde la extracción e integración hasta el EDA, la ingeniería de variables y el modelamiento, orientadas al pronóstico de $SAIFI$ y $SAIDI$. Posteriormente, en el Capítulo 6 se presentan los resultados por etapa; en el Capítulo 7 se discute el alcance, los aportes y las limitaciones frente a cada objetivo; y en el Capítulo 8 se consolidan las conclusiones del trabajo.

1 Definición del problema

1.1. Planteamiento del problema

Los indicadores de continuidad del servicio SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) en la empresa de distribución objeto de estudio presentan dificultades estructurales para su mejora sostenida. Si bien existen técnicas estadísticas y de aprendizaje automático ampliamente documentadas para el análisis de interrupciones en sistemas eléctricos, la principal limitación no radica en la ausencia de metodologías analíticas, sino en la calidad, estructura e interpretación de los datos disponibles, lo que dificulta el entrenamiento de modelos predictivos que sean simultáneamente confiables y explicativos [1], [2], [3], [4]. En particular, resulta complejo detectar, cuantificar y explicar no solo las causas de las interrupciones, sino también su duración y los tiempos de restauración del servicio.

El objetivo predictivo de este trabajo son los indicadores $SAIFI$ y $SAIDI$ a escala de cuadrante $\times$ semana. Se construyen a partir de los registros operativos del panel, con el denominador de usuarios totales del operador (UT) tomado de la serie mensual `data_usuarios_totales_sistema.csv` y asignado a cada semana según el mes calendario de su fecha de inicio:

$$\begin{aligned} \mathrm{SAIFI}_{q,s} &= \frac{\texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \\ \mathrm{SAIDI}_{q,s} &= \frac{\texttt{duracion_total}_{q,s} \times \texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}. \end{aligned} \tag{1.1}$$

`n_eventos` y `duracion_total` permanecen como insumos de construcción y de historial *ex ante*; no constituyen las variables a predecir. `usuarios_afectados` entra en el numerador de Y, pero no como predictora contemporánea.

Los principales obstáculos identificados son los siguientes:

- **Fragmentación de las fuentes de información**: La operación del sistema requiere el uso de múltiples registros provenientes de plataformas hetero-

géneas como SCADA, OMS, GIS, CIS,[1] bases de mantenimiento y fuentes meteorológicas externas. Estos datos se encuentran en distintos formatos, con estructuras disímiles y, en algunos casos, con ausencia de metadatos completos, lo que dificulta su integración sin pérdida de trazabilidad [5], [6].

- **Problemas de sincronización temporal**: Los sistemas operativos no presentan una alineación temporal uniforme. Mientras algunos registran información en intervalos horarios, otros lo hacen en escalas de minutos o presentan series discontinuas. Esta falta de sincronización genera inconsistencias que afectan la estimación precisa de la duración de las interrupciones y de los tiempos de reposición del servicio [6].
- **Eventos extremos y ruido en los datos**: Los registros operativos de interrupciones eléctricas, provenientes de las plataformas mencionadas, contienen alta variabilidad, errores de captura, información incompleta y eventos atípicos, como fenómenos climáticos extremos o fallas excepcionales, que suelen ser excluidos del análisis. Esta situación dificulta la identificación de patrones robustos tanto a nivel agregado como local [1], [7].
- **Pérdida de detalle por agregación**: El uso de indicadores promediados en escalas anuales o geográficas amplias oculta el comportamiento específico de circuitos o zonas particulares, lo que limita la identificación de causas operativamente accionables [2], [6].
- **Ausencia de estándares de datos**: La falta de catálogos de datos, definiciones homogéneas y métricas de integridad impide evaluar de manera sistemática si las fuentes disponibles son adecuadas para la construcción de modelos predictivos confiables [5], [6].
- **Restricciones regulatorias**: Los organismos de control exigen que los resultados sean trazables y explicables. En consecuencia, no es suficiente emplear modelos con alto desempeño predictivo; estos deben ser interpretables y compatibles con los requerimientos de reporte regulatorio, lo que condiciona el tipo de metodologías que pueden adoptarse [2], [3].

Estos obstáculos reducen la capacidad de la organización para explicar la variación de los indicadores SAIDI y SAIFI, priorizar actividades operativas y cumplir con los requerimientos regulatorios mediante herramientas predictivas [3], [7].

[1] SCADA (*Supervisory Control and Data Acquisition*): sistema de supervisión y adquisición de datos de la operación de la red. OMS (*Outage Management System*): sistema de gestión de interrupciones. GIS (*Geographic Information System*): sistema de información geográfica de activos. CIS (*Customer Information System*): sistema de información de clientes.

En términos cuantitativos, el SAIDI promedio de la empresa es de 22.43 horas por año, valor que se ubica un 4.64 % por debajo de la meta establecida por la CREG (23.52 horas por año). Para el indicador SAIFI, el promedio anual es de 6.5 eventos, significativamente inferior al objetivo regulatorio de 9 eventos por año, lo que representa una reducción del 27.78 % [1]. Estos resultados sugieren que la empresa se encuentra dentro de los límites regulatorios; sin embargo, la gestión de dichos indicadores enfrenta importantes desafíos operativos e informativos.

Las compensaciones anuales asociadas a calidad del servicio ascienden aproximadamente a $5 mil millones de pesos, y el análisis de datos históricos de cinco años evidencia que cerca del 2 % de los registros presenta información faltante o inconsistente, como tiempos de evento no registrados, campos incompletos o desajustes temporales entre sistemas. Si bien la Circular 063 de 2019 de la SSPD establece criterios técnicos para la exclusión válida de eventos asociados a factores externos, como fuerza mayor o fallas del Sistema Nacional de Transmisión, la presencia de problemas de calidad de datos limita la capacidad de construir modelos predictivos sólidos, diagnosticar con precisión las causas de las interrupciones y priorizar acciones operativas basadas en evidencia [1], [2], [3], [8].

Este problema no es exclusivo de la empresa analizada. En el sector eléctrico colombiano, la calidad del servicio constituye un desafío estructural. De acuerdo con el Informe de Calidad del Servicio de Energía Eléctrica de la SSPD 2023, el SAIDI promedio nacional fue de 16.83 horas por usuario, con valores que oscilaron entre 4.5 horas y más de 50 horas dependiendo del operador y de la región geográfica [9]. Esta dispersión refleja diferencias significativas en infraestructura, gestión operativa y exposición a condiciones climáticas extremas. Durante 2023, el 68 % de las interrupciones estuvo asociado a eventos externos, como contacto con vegetación, animales o terceros, mientras que el 24 % se atribuyó a fallas técnicas en equipos de red, evidenciando la naturaleza multicausal del problema [9].

El impacto regulatorio es considerable: en 2023, las compensaciones totales por incumplimiento de metas de calidad alcanzaron aproximadamente 487 000 millones a nivel nacional, siendo los indicadores de continuidad responsables del 73 % de este valor [9]. Para operadores de red ubicados en zonas con alta exposición climática, como Norte de Santander, la problemática se intensifica. Según datos de la SSPD consolidados por la UPME, los eventos meteorológicos extremos incrementaron en un 35 % las interrupciones no programadas respecto al periodo 2019–2021 [9], [10]. En este contexto, la dispersión de información en sistemas heterogéneos dificulta la identificación de patrones causales, la priorización del mantenimiento preventivo y la detección temprana de circuitos críticos,

limitando la capacidad de las empresas distribuidoras para anticipar deterioros en la continuidad del servicio y cumplir de manera consistente con los objetivos regulatorios establecidos por la CREG.

1.2. Formulación del problema

¿Cómo desarrollar una metodología basada en métodos de ciencia de datos para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de zonas en redes de distribución de una empresa de energía eléctrica, ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento?

A partir de la formulación anterior, se derivan las siguientes preguntas de sistematización:

- ¿Cómo consolidar un repositorio analítico unificado y trazable que integre SCADA, OMS, GIS, CIS, registros de mantenimiento y datos climáticos, acompañado de un catálogo de datos y métricas de calidad que permitan pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas?
- ¿Qué patrones temporales, espaciales, estacionales o comportamientos atípicos caracterizan la variabilidad de SAIDI y SAIFI a nivel de circuito, y de qué manera estos patrones influyen en la comprensión del fenómeno de continuidad del servicio eléctrico y en la identificación de los factores que explican sus fluctuaciones?
- ¿Qué modelos tienen mejor desempeño para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de circuito o zona?
- ¿Cómo construir artefactos reproducibles (notebooks, contenedores, documentación) y reportes técnicos alineados con los entregables del proyecto que faciliten la interpretación operativa y el uso de resultados en priorización de mantenimiento y reportes regulatorios?

2 Objetivos del proyecto

2.1. Objetivo general

Desarrollar una metodología basada en métodos de ciencia de datos para predecir los indicadores de calidad del servicio (SAIDI y SAIFI) en redes de distribución de una empresa de energía eléctrica ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento.

2.2. Objetivos específicos

1. Consolidar las fuentes de datos relevantes (SCADA/OMS, GIS, registros de fallas y mantenimientos, inventarios/SAC y datos climáticos), documentando su cobertura, calidad y limitaciones mediante un catálogo de datos y métricas de integridad.

2. Determinar qué variables operativas, técnicas y climáticas tienen mayor relevancia para predecir la duración y frecuencia de interrupciones (SAIDI y SAIFI) en la zona de estudio a partir de modelos estadísticos o de Machine Learning.

3. Evaluar el desempeño de diferentes métodos estadísticos o de Machine Learning para predecir SAIDI y SAIFI por circuito o zona, considerando la naturaleza de los datos y la interpretabilidad requerida por los gestores.

3 Marco de referencia

3.1. Marco teórico

3.1.1. Contexto del estudio

La calidad del servicio eléctrico se refiere a la entrega de energía de forma segura y eficiente, en cumplimiento de estándares regulatorios que garanticen continuidad, confiabilidad y estabilidad para todos los tipos de usuarios: residenciales, industriales, comerciales e institucionales. En Colombia, este servicio es esencial y por eso está regulado por la CREG [1], que ha establecido métricas y estándares específicos para hacer seguimiento a cómo se presta el servicio. Entre estas métricas, dos son particularmente importantes: el SAIDI y el SAIFI, ya definidos en la introducción de este trabajo.

1. *Definición del SAIDI según la Resolución CREG 015 de 2018:* La Resolución CREG 015 de 2018 define el SAIDI como se indica a continuación. En dicha normativa, el OR es el Operador de Red y el SDL es el Sistema de Distribución Local.

   > *La calidad media anual del OR se mide a través de los indicadores de duración y frecuencia de los eventos sucedidos en los SDL, que se establecen como se describe a continuación. El indicador SAIDI representa la duración total en horas de los eventos que en promedio percibe cada usuario del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:*

   $$SAIDI_{j,t} = \sum_{m=1}^{12} \frac{\sum_{i=1}^{n} (D_{i,u,m} \times NU_{i,u,m})}{UT_{j,m}} \frac{1}{60}, \tag{3.1}$$

   donde:

   - $SAIDI_{j,t}$*: Indicador de duración promedio por usuario, de los eventos sucedidos en el SDL del OR* j*, durante el año* t*, medido en horas al año.*

- $D_{i,u,m}$: *Duración en minutos del evento i, sucedido durante el mes m, que afectó al activo u perteneciente al SDL del OR j.*
- $NU_{i,u,m}$: *Número de usuarios que fueron afectados por el evento i sucedido durante el mes m, conectados al activo u.*
- $UT_{j,m}$: *Número total de usuarios conectados al SDL del OR j en el mes m.*
- m: *Mes del año t, con enero $= 1, \ldots,$ diciembre $= 12$.*

2. *Definición del SAIFI según la Resolución CREG 015 de 2018:* La misma resolución define el *SAIFI* como:

   "El indicador SAIFI representa la cantidad total de los eventos que en promedio perciben todos los usuarios del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:"

$$SAIFI_{j,t} = \sum_{m=1}^{12} \frac{\sum_{i=1}^{n} NU_{i,u,m}}{UT_{j,m}}, \tag{3.2}$$

   donde:

   - $SAIFI_{j,t}$: *Indicador de frecuencia promedio por usuario, de los eventos sucedidos en el SDL del OR j, durante el año t, medido en cantidad al año.*
   - $NU_{i,u,m}$: *Número de usuarios que fueron afectados por el evento i sucedido durante el mes m, por encontrarse conectados al activo u.*
   - $UT_{j,m}$: *Número total de usuarios conectados al SDL del OR j en el mes m.*
   - m: *Mes del año t, con enero $= 1, \ldots,$ diciembre $= 12$.*

   Cada OR es responsable del cálculo de los indicadores de calidad del servicio. Para ello, debe utilizar la información reportada conforme a lo establecido en el numeral 5.2.11.3.2 de la Resolución CREG 015 de 2018, así como la información de vinculación definida en el literal a) del numeral 5.2.10 [1]. Esta disposición garantiza que el cálculo de los indicadores se realice con base en registros oficiales, trazables y consistentes con los lineamientos regulatorios vigentes.

3. *Interpretación de los indicadores:* Los indicadores SAIDI y SAIFI miden los *eventos* de interrupción del servicio eléctrico, entendidos como situaciones

en las cuales se presenta una pérdida total o parcial del suministro. Dependiendo de su causa y de los criterios regulatorios aplicables, ciertos eventos son incluidos en el cálculo de los indicadores, mientras que otros pueden ser excluidos conforme a la normativa vigente.

El SAIDI expresa el tiempo promedio durante el cual un usuario permanece sin servicio eléctrico en un período determinado. Por su parte, el SAIFI mide la frecuencia promedio con la que un usuario experimenta interrupciones en el mismo período. En conjunto, ambos indicadores permiten evaluar la continuidad y confiabilidad del sistema de distribución.

Desde una perspectiva operativa, valores elevados de SAIDI o SAIFI pueden reflejar deficiencias en el mantenimiento de la red, limitaciones en la infraestructura, obsolescencia tecnológica, fallas en los procedimientos operativos o una alta exposición a factores externos como condiciones climáticas adversas [11], [12]. En consecuencia, estos indicadores no solo describen el desempeño del sistema, sino que también permiten identificar áreas críticas que requieren intervención técnica o inversión en activos.

En el ámbito regulatorio, los OR deben reportar estos indicadores como métricas clave de desempeño y compararlos con las metas establecidas por la CREG. El cumplimiento de dichas metas está asociado a esquemas de remuneración por calidad del servicio, mientras que el incumplimiento puede dar lugar a ajustes tarifarios, obligaciones de reinversión o sanciones económicas [1], [8]. Por tanto, SAIDI y SAIFI no solo constituyen medidas técnicas de continuidad, sino también variables con impacto financiero y regulatorio significativo.

4. *Meta de calidad media del SAIDI:* La Resolución CREG 015 de 2018 establece que la meta de calidad media para el indicador de duración de los eventos en el Sistema de Distribución Local (SDL) de cada OR se determina con base en una expresión específica definida por la regulación. Formalmente, dicha meta se calcula mediante la siguiente formulación:

   > *"La meta para el indicador de duración de los eventos sucedidos en el SDL de cada OR se obtiene con base en la siguiente expresión:"*
   >
   > $$\text{SAIDI_M}_{j,t} = (1 - 0{,}08) \times \text{SAIDI_M}_{j,t-1}, \tag{3.3}$$
   >
   > *donde:*
   >
   > - $\text{SAIDI_M}_{j,t}$: *Meta del indicador de duración de eventos, en horas al año, a ser alcanzada por el OR j al finalizar el año t.*

- $\text{SAIDI_M}_{j,t-1}$: *Meta del indicador de duración de eventos, en horas al año, para el año* $t-1$. *Para el primer año de aplicación del esquema de calidad de cada OR esta variable será igual al indicador de referencia,* SAIDI_R_j.

5. *Dimensión social y económica:* Desde una dimensión social y económica, un servicio deficiente ocasiona pérdidas significativas en la productividad empresarial y en los ingresos por remuneración al operador de red, y afecta la operación de instituciones comerciales e industriales. Por ello, mejorar la gestión y la capacidad de predicción de $SAIDI$ y $SAIFI$ es un objetivo estratégico para los operadores y para la regulación del sector, con impactos directos en usuarios, empresas y entes de control.

6. *Exclusiones de eventos:* Para la realización del cálculo de la calidad del servicio y el seguimiento de estos indicadores se tienen algunas exclusiones que permiten exonerar o excluir eventos de este cálculo. Entre los aspectos de la calidad del servicio de energía eléctrica que no serán observados dentro de este estudio se encuentran las siguientes exclusiones de eventos, tal como lo dicta la Resolución CREG 015 de 2018 [1]:

   - Los menores o iguales a 3 minutos.
   - Los debidos a racionamientos programados.
   - Los causados por eventos de activos pertenecientes al Sistema de Transmisión Nacional (STN) y al Sistema de Transmisión Regional (STR).
   - Los eventos requeridos por seguridad ciudadana, solicitados por organismos de socorro o autoridades competentes.
   - Cuando se daña un activo de nivel de tensión 1 de propiedad del usuario.
   - Los debidos a catástrofes naturales.
   - Los debidos a actos de terrorismo.
   - Eventos originados en exigencias de traslados y adecuaciones de la infraestructura eléctrica.
   - Los eventos debidos a trabajos de reposición o modernización en subestaciones.
   - Y otros menos relevantes para este estudio, pero que serán igualmente excluidos.

7. *Factores que afectan los indicadores:* Hay varios factores que deben considerarse, ya que terminan afectando negativamente los indicadores de calidad [5], [6], [12]:

   - *El clima:* Las tormentas eléctricas, vientos fuertes y otros fenómenos meteorológicos pueden dañar la infraestructura de distribución y causar interrupciones.
   - *Aspectos técnicos e infraestructura:* Si el mantenimiento es deficiente, si los equipos están viejos u obsoletos, o si no hay redundancia en la red, se generan problemas que impactan los indicadores.
   - *La gestión operativa:* Cuando falta planificación en el mantenimiento, cuando existen redes y equipos sin hojas de vida documentadas, cuando la respuesta a fallas es lenta o cuando el servicio está saturado, los indicadores se ven afectados. El problema se agrava al tener la información dispersa en múltiples sistemas.
   - *Los datos:* Cuando la información está fragmentada en diferentes aplicativos, se dificulta el desarrollo de modelos predictivos que funcionen adecuadamente.

   Por lo tanto, analizar en conjunto todas estas situaciones que afectan el indicador de forma negativa o positiva constituye un ejercicio relevante, ya que permitiría fortalecer la confiabilidad de los procesos internos y mejorar la gestión de los indicadores de calidad del servicio público de redes eléctricas de la empresa operadora de red de Norte de Santander.

3.1.2. Métodos y modelos

En este trabajo, la unidad de análisis del modelado es el par *cuadrante* $\times$ *semana* sobre D_{mod} (2024–2025). Para evitar *fuga de información* en el pronóstico, las variables del panel se separan en tres grupos mutuamente excluyentes según su disponibilidad temporal respecto de la semana t a predecir:

1. *Disponibles antes del periodo a pronosticar* (candidatas a predictoras): clima *rezagado* ($t-1, \ldots, t-h$) o *pronosticado* para t cuando exista un forecast operativo *ex ante*; histórico de eventos del cuadrante (y vecinos, si aplica); características del cuadrante (altitud, tipología de zona, número de activos, usuarios totales del inventario); estacionalidad y calendario; rezagos de Y o Y'. El clima contemporáneo de la semana t solo entra como predictora si está disponible *antes* de observar los eventos de t; en el EDA se usa como asociación descriptiva, no como garantía de usabilidad predictiva.

2. *Variables respuesta:* $Y = \text{SAIFI}$ y $Y' = \text{SAIDI}$, construidas en el grano cuadrante $\times$ semana como $\text{SAIFI} = \texttt{usuarios_afectados}/UT_m$ y $\text{SAIDI} = (\texttt{duracion_total} \times \texttt{usuarios_afectados})/UT_m$, donde UT_m es el número de usuarios totales del sistema en el mes m de la semana (serie `data_usuarios_totales_sistema.csv`). `n_eventos` y `duracion_total` son insumos de esa construcción y del historial *ex ante*, no las respuestas a predecir.

3. *Impacto posterior* (descriptivo / severidad): `usuarios_afectados` y `elementos_afectados` solo se conocen al ocurrir o cerrar el evento. `usuarios_afectados` entra en el numerador de Y y Y', pero *no* se emplea como predictora contemporánea. `elementos_afectados` queda restringido a la descripción de severidad. Análogamente, $\texttt{duracion_total}_t$ y $\texttt{n_eventos}_t$ contemporáneos no entran como covariables al pronosticar SAIDI_t o SAIFI_t.

El vector climático de referencia, sujeto a la regla de disponibilidad del grupo 1, es

$$\mathbf{x}_{q,s} = (P_{q,s},\ T_{q,s},\ H_{q,s},\ V_{q,s})^\top , \tag{3.4}$$

donde:

- $\mathbf{x}_{q,s}$: Vector climático del cuadrante q en la semana s.
- $P_{q,s}$: Precipitación total semanal, en mm (`precip_total_semana`).
- $T_{q,s}$: Temperatura media semanal, en °C (`temp_media_semana`).
- $H_{q,s}$: Humedad relativa media semanal, en % (`humedad_media_semana`).
- $V_{q,s}$: Velocidad media semanal del viento, en m/s (`viento_medio_semana`).

El vector se enriquece eventualmente con rezagos temporales de Y (o Y') y con términos de estratificación territorial. A continuación se formalizan los métodos empleados en el EDA y en la preparación y el modelado.

1. *Datos faltantes, tipos e imputación:* La proporción de faltantes de cada variable del panel se define como

$$p_j^{\text{NA}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1}\{X_{ij} = \text{NA}\}, \tag{3.5}$$

donde:

- p_j^{NA}: Proporción de valores faltantes de la variable j.

- X_{ij}: Valor de la variable j en la observación i.
- N: Número de observaciones del panel.
- $\mathbf{1}\{\cdot\}$: Función indicadora, igual a 1 si se cumple la condición y 0 en otro caso.

En el panel activo $\times$ día, los `NA` se concentran en el bloque climático y en `ALTITUD`; en la tabla agregada cuadrante $\times$ semana (D_{EDA}, D_{mod}) no se observan faltantes. Las reglas de imputación o exclusión se aplican en la Etapa 4 solo donde $p_j^{\text{NA}} > 0$ en el grano de origen, conforme a los criterios de tratamiento de datos incompletos de [13].

2. *Dispersión relativa (coeficiente de variación):* Para comparar la variabilidad de variables cuantitativas con distintas unidades o escalas, se emplea el coeficiente de variación

$$\text{CV}(X) = \frac{s_X}{\bar{x}}, \qquad \bar{x} \neq 0, \tag{3.6}$$

donde:

- $\text{CV}(X)$: Coeficiente de variación de la variable X.
- s_X: Desviación estándar muestral de X.
- $\bar{x}$: Media muestral de X.

Valores de CV cercanos a cero indican dispersión baja respecto a la media; valores CV $\gtrsim 1$ señalan alta heterogeneidad relativa. En variables cero-infladas (p. ej. métricas de interrupción), el CV del panel completo queda inflado por la masa en cero, por lo que se reporta también el CV condicionado a observaciones con valor positivo.

3. *Análisis de atípicos y extremos:* Para una variable cuantitativa X, se emplean reglas basadas en cuartiles, siguiendo el criterio de rango intercuartílico propuesto por [14]. Se marcan como extremos candidatos los valores que cumplen

$$x \notin \left[Q_1 - k\,\text{IQR},\ Q_3 + k\,\text{IQR}\right], \tag{3.7}$$

donde:

- x: Valor observado de la variable X.
- Q_1, Q_3: Primer y tercer cuartil de X.
- IQR: Rango intercuartílico, $\text{IQR} = Q_3 - Q_1$.
- k: Factor de amplitud, $k = 1.5$ (regla de Tukey) y, de forma complementaria, $k = 3.0$ (extremos más severos).

Estas reglas se contrastan con el criterio de percentiles P1–P99 sobre `n_eventos`, `duracion_total`, `usuarios_afectados` y `precip_total_semana`. El tratamiento definitivo (retención, winsorización o exclusión) se decide en la Etapa 4.

4. *Transformaciones de variables:* Ante asimetría y ceros, se usa la transformación logarítmica desplazada, caso límite de la familia de transformaciones de potencia de [15]:

$$T(x) = \log(1 + x), \qquad x \geq 0, \tag{3.8}$$

donde:

- $T(x)$: Valor transformado.
- x: Valor original, no negativo.

Se aplica en particular a `precip_total_semana` y al bloque operativo (`n_eventos`, `duracion_total`, `usuarios_afectados`, `elementos_afectados`) cuando se requieren densidades o PCA más estables. Para homogenizar variables con distintas unidades (p. ej. antes del PCA o del agrupamiento), se emplea la estandarización

$$z = \frac{x - \bar{x}}{s}, \tag{3.9}$$

donde:

- z: Valor estandarizado, con media 0 y desviación estándar 1.
- $\bar{x}$, s: Media y desviación estándar muestrales de la variable.

5. *Series de tiempo y sus características:* La función de autocorrelación (ACF) del total semanal de eventos en el rezago h es

$$\rho(h) = \frac{\mathrm{Cov}(E_t, E_{t-h})}{\mathrm{Var}(E_t)}, \tag{3.10}$$

donde:

- $\rho(h)$: Autocorrelación en el rezago h.
- E_t: Total semanal territorial de eventos en la semana t.
- h: Rezago, en semanas.

En D_{mod} se observa $\rho(1) \approx 0.80$, lo que motiva incorporar rezagos $E_{t-1}, \ldots, E_{t-h}$ (o de `n_eventos` a nivel cuadrante) como predictoras. La PACF complementa la identificación del orden autorregresivo [16]; la estacionalidad mensual se analiza agrupando E_t por mes calendario.

6. *Análisis de correlación:* Por la asimetría y la cero-inflación de las variables operativas, se emplea el coeficiente de correlación por rangos de [17]:

$$\rho_S(X, Y) = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n\,(n^2 - 1)}, \tag{3.11}$$

donde:

- $\rho_S(X, Y)$: Coeficiente de correlación de Spearman entre X y Y.
- d_i: Diferencia entre los rangos de X y Y en la observación i.
- n: Número de observaciones.

En D_{mod}, el par climático de mayor magnitud frente a `n_eventos` es (`viento_max_semana`, `n_eventos`) con $\rho_S \approx 0.14$, mientras el par de mayor interés conceptual, (`precip_total_semana`, `n_eventos`), alcanza $\rho_S \approx 0.07$. Entre variables cualitativas se emplea el estadístico V de Cramér [18]. Para el agrupamiento jerárquico de covariables se usa la distancia $d = 1 - |\rho_S|$.

7. *Datos de entrenamiento y prueba:* La partición es temporal (no aleatoria):

$$\begin{aligned} \mathcal{D}_{\text{train}} &= \{(i, t) : t \leq t^*\}, \\ \mathcal{D}_{\text{test}} &= \{(i, t) : t > t^*\}, \end{aligned} \tag{3.12}$$

donde:

- $\mathcal{D}_{\text{train}}$, $\mathcal{D}_{\text{test}}$: Conjuntos de entrenamiento y de prueba.
- (i, t): Observación del cuadrante i en la semana t.
- t^*: Semana de corte, ubicada en el percentil 85 de las semanas ordenadas de D_{mod} (8 de septiembre de 2025).

De este modo la prueba comprende las últimas 16 semanas de 2025 y ninguna semana de prueba precede a una de entrenamiento, lo que preserva el orden cronológico ante la autocorrelación de la serie [19], [20].

8. *Validación cruzada:* Cuando se ajusten hiperparámetros en $\mathcal{D}_{\text{train}}$, se prioriza validación *forward-chaining* (bloques temporales sucesivos) en lugar de k-fold aleatorio, para no romper la dependencia temporal de `n_eventos` [21].

9. *Análisis de componentes principales (PCA):* El PCA se emplea como herramienta *exploratoria* de redundancia, no como modelo predictivo final [22]. Requiere variables cuantitativas, preferiblemente homogenizadas (estandarización o transformación previa) y con $n \gg p$. Las componentes se obtienen al resolver

$$\mathbf{Z}^\top \mathbf{Z}\, \mathbf{v}_\ell = \lambda_\ell\, \mathbf{v}_\ell, \tag{3.13}$$

donde:

- $\mathbf{Z}$: Matriz del bloque climático estandarizado.
- $\mathbf{v}_\ell$: Vector propio (cargas) de la componente ℓ.
- λ_ℓ: Valor propio de la componente ℓ, proporcional a la varianza que explica.

Las componentes $\mathrm{PC}_\ell = \mathbf{Z}\mathbf{v}_\ell$ resumen ejes de covarianza (temperaturas y vientos frente a precipitación). La importancia de cada variable en la componente ℓ se lee mediante las cargas $v_{\ell j}$; en el EDA se interpretan como relevantes aquellas con $|v_{\ell j}| \geq 0.40$. Sobre el bloque operativo en escala $\log(1+x)$, PC1 concentra la covarianza común de frecuencia, afectación y duración.

10. *Métodos de agrupación:* Los cuadrantes se segmentan por actividad (cuantiles del total de `n_eventos`) y, de forma multivariada, por agrupamiento (p. ej. jerárquico [23] o k-means [24]) sobre perfiles de frecuencia, duración y clima, con el fin de estratificar el modelado en zonas de distinto riesgo operativo.

11. *Factor de inflación de la varianza (VIF):* Para cada predictora del bloque climático en un modelo auxiliar lineal de `n_eventos` sobre `x`,

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{3.14}$$

donde:

- VIF_j: Factor de inflación de la varianza de la predictora X_j.
- R_j^2: Coeficiente de determinación de la regresión de X_j sobre el resto de covariables [25].

Valores altos en `temp_max/temp_min` y `viento_max` motivan el subconjunto reducido `x` de la Ecuación (3.4) (VIF aceptables tras la depuración), teniendo en cuenta las advertencias sobre el uso mecánico de umbrales fijos señaladas por [26].

12. *Modelo lineal generalizado de Poisson (GLM Poisson):* Como modelo diagnóstico de conteos [27], [28]:

$$\begin{aligned} Y_i &\sim \text{Poisson}(\mu_i), \\ \log \mu_i &= \beta_0 + \boldsymbol{\beta}^\top \mathbf{x}_i^*, \end{aligned} \tag{3.15}$$

donde:

- Y_i: Número de eventos (`n_eventos`) en la observación cuadrante–semana i.
- μ_i: Tasa esperada de eventos de la observación i.
- β_0, $\boldsymbol{\beta}$: Intercepto y vector de coeficientes.
- $\mathbf{x}_i^*$: Vector de covariables, que incluye, entre otras, $\log(1+P)$ y el viento medio estandarizado.

Los coeficientes $\hat{\beta}_j$ cuantifican el efecto multiplicativo $e^{\hat{\beta}_j}$ sobre la tasa esperada de interrupciones; este esquema orienta el modelado predictivo de la Etapa 5.

3.1.3. Modelos predictivos y espaciales

Sea $y_{q,s} = \log(1 + Y_{q,s})$, con $Y \in \{\text{SAIDI}, \text{SAIFI}\}$, la respuesta transformada del cuadrante $q = 1, \ldots, Q$ en la semana $s = 1, \ldots, S$, y $\mathbf{x}_{q,s} \in \mathbb{R}^p$ el vector de predictoras disponibles *ex ante*.

1. *Mínimos cuadrados agrupados (Pooled OLS).* Supone un intercepto común a todos los cuadrantes:

$$y_{q,s} = \alpha + \mathbf{x}_{q,s}^\top \boldsymbol{\beta} + \varepsilon_{q,s}, \tag{3.16}$$

donde:

- $y_{q,s}$: Respuesta transformada del cuadrante q en la semana s.
- α: Intercepto común.
- $\boldsymbol{\beta}$: Vector de coeficientes de las predictoras.
- $\varepsilon_{q,s}$: Término de error.

2. *Efectos fijos de cuadrante (FE).* Permite un intercepto propio por cuadrante, que absorbe la heterogeneidad no observada invariante en el tiempo [29]:

$$y_{q,s} = \mu_q + \mathbf{x}_{q,s}^{\top}\boldsymbol{\beta} + \varepsilon_{q,s}, \tag{3.17}$$

donde:

- μ_q: Efecto fijo (intercepto propio) del cuadrante q.
- $y_{q,s}$, $\mathbf{x}_{q,s}$, $\boldsymbol{\beta}$, $\varepsilon_{q,s}$: Como en la Ecuación (3.16).

El modelo se estima mediante la transformación *within*, $\ddot{y}_{q,s} = y_{q,s} - \bar{y}_q$, que elimina μ_q; por ello los atributos constantes del cuadrante no son identificables en esta especificación. La versión con efectos fijos de cuadrante y semana añade un término τ_s común a todos los cuadrantes en la semana s. Dado que los residuos de un mismo cuadrante están autocorrelacionados, la inferencia se basa en errores estándar agrupados por cuadrante.

3. *Random Forest (RF).* Promedia árboles de regresión entrenados sobre muestras *bootstrap*, eligiendo en cada partición entre `mtry` predictoras tomadas al azar [30]:

$$\hat{f}(\mathbf{x}) = \frac{1}{B}\sum_{b=1}^{B} T_b(\mathbf{x}), \tag{3.18}$$

donde:

- $\hat{f}(\mathbf{x})$: Predicción del bosque para el vector de predictoras $\mathbf{x}$.
- B: Número de árboles.
- $T_b(\mathbf{x})$: Predicción del árbol b.

Las observaciones no incluidas en cada muestra (*out-of-bag*, OOB) permiten estimar el error sin un conjunto de validación adicional. La importancia de la variable j (%IncMSE) es el aumento porcentual del error cuadrático medio OOB cuando se permutan aleatoriamente sus valores. Los hiperparámetros `mtry` y tamaño mínimo de nodo terminal se ajustan siguiendo [31].

4. *Índice de Moran.* Mide la autocorrelación espacial de una variable [32]:

$$I = \frac{n}{S_0}\,\frac{\sum_i \sum_j w_{ij}\, z_i z_j}{\sum_i z_i^2}, \qquad S_0 = \sum_i \sum_j w_{ij}, \tag{3.19}$$

donde:

- I: Índice de Moran.

- n: Número de cuadrantes.
- w_{ij}: Peso espacial entre los cuadrantes i y j, elemento de la matriz $\mathbf{W} = [w_{ij}]$ normalizada por filas.
- z_i: Valor centrado de la variable en el cuadrante i.
- S_0: Suma de todos los pesos espaciales.

Valores positivos y significativos indican que cuadrantes vecinos presentan valores similares.

5. *Modelo de rezago espacial (SAR).* La respuesta de un cuadrante depende directamente de la de sus vecinos [33], [34]:

$$\begin{aligned} \mathbf{y} &= \rho\,\mathbf{W}\mathbf{y} + \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \\ \boldsymbol{\varepsilon} &\sim N\left(\mathbf{0},\, \sigma^2\mathbf{I}\right), \end{aligned} \tag{3.20}$$

donde:

- $\mathbf{y}$: Vector de respuestas de los cuadrantes.
- ρ: Parámetro de dependencia espacial de la respuesta.
- $\mathbf{W}$: Matriz de pesos espaciales normalizada por filas.
- $\mathbf{X}$: Matriz de predictoras; $\boldsymbol{\beta}$, vector de coeficientes.
- $\boldsymbol{\varepsilon}$: Vector de errores, con varianza σ^2; $\mathbf{I}$ es la matriz identidad.

Como $\mathbf{y} = (\mathbf{I} - \rho\mathbf{W})^{-1}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})$, el efecto de una covariable no es β_j, sino que se descompone en un impacto directo y uno indirecto o de derrame hacia los vecinos [34].

6. *Modelo de error espacial (SEM).* La dependencia reside en factores no observados espacialmente correlacionados:

$$\begin{aligned} \mathbf{y} &= \mathbf{X}\boldsymbol{\beta} + \mathbf{u}, \\ \mathbf{u} &= \lambda\,\mathbf{W}\mathbf{u} + \boldsymbol{\varepsilon}, \end{aligned} \tag{3.21}$$

donde:

- $\mathbf{u}$: Vector de errores espacialmente correlacionados.
- λ: Parámetro de dependencia espacial del error.
- $\mathbf{y}$, $\mathbf{X}$, $\boldsymbol{\beta}$, $\mathbf{W}$, $\boldsymbol{\varepsilon}$: Como en la Ecuación (3.20).

La elección entre SAR y SEM se apoya en las pruebas de multiplicadores de Lagrange robustas sobre los residuos de OLS y en el criterio de información de Akaike, $\mathrm{AIC} = 2k - 2\ln\hat{L}$ [33].

7. *Métricas de evaluación.* Sobre el conjunto de prueba:

$$\begin{aligned} \mathrm{RMSE} &= \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}, \\ \mathrm{MAE} &= \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \\ R^2 &= \mathrm{cor}\,(y, \hat{y})^2, \end{aligned} \tag{3.22}$$

donde:

- y_i, $\hat{y}_i$: Valor observado y valor pronosticado de la observación i.
- n: Número de observaciones del conjunto de prueba.

Como el error porcentual (MAPE) no está definido cuando $y_i = 0$, la comparación relativa se hace con el error absoluto escalado [35], $\mathrm{MASE} = \mathrm{MAE}/\mathrm{MAE}_{\text{ingenuo}}$, donde el pronóstico ingenuo es la persistencia $\hat{y}_{q,s} = y_{q,s-1}$; un $\mathrm{MASE} < 1$ indica que el modelo supera a la persistencia. La diferencia de exactitud entre dos modelos se contrasta con la prueba de [36].

3.2. Antecedentes

3.2.1. Revisión de literatura

Los avances recientes en ciencia de datos, estadística avanzada y aprendizaje automático han impulsado una evolución significativa en los métodos para predecir fallas, gestionar interrupciones y estimar la calidad del servicio en redes de distribución eléctrica.

En primer lugar, varios estudios han explorado la predicción de confiabilidad a partir de modelos híbridos que integran técnicas estadísticas y de inteligencia artificial. Xie et al. [37] desarrollan un modelo integral de pronóstico de confiabilidad que combina redes neuronales artificiales, análisis de relaciones grises y modelos de fallas programadas, demostrando alta aplicabilidad en sistemas en expansión. De manera complementaria, Das et al. [38] proponen un ensamble de redes neuronales profundas que mejora sustancialmente la estimación de interrupciones causadas por viento y descargas eléctricas, superando modelos estadísticos y de comité previos.

En el ámbito de eventos meteorológicos severos, Angalakudati et al. [39] introducen uno de los primeros modelos operativos basados en Machine Learning

para la planificación de tormentas, combinando datos climáticos, propiedades físicas de la red e información histórica de daños. En la misma línea, Owerko et al. [40] emplean Graph Neural Networks para procesar mediciones meteorológicas distribuidas en un marco de señales sobre grafos, logrando errores de predicción inferiores al 1.1 % en la región de Nueva York.

El efecto de la vegetación como causa dominante de fallas también ha sido ampliamente estudiado. Cerrai et al. [41] cuantifican el impacto del estándar Enhanced Tree Trimming mediante análisis estadístico y modelos de predicción de interrupciones, mostrando reducciones entre el 16 % y 48 % en fallas durante tormentas. Por su parte, Eskandarpour y Khodaei [42] introducen un modelo predictivo para componentes de red ante huracanes basado en regresión logística, mientras que Rudin et al. [43] proponen un marco general para extraer conocimiento de datos históricos de la red de Nueva York con el fin de priorizar mantenimiento y estimar la vulnerabilidad de componentes críticos.

Otros aportes relevantes abordan la identificación de causas de fallas. Xu et al. [44] aplican un algoritmo inspirado en sistemas inmunológicos (AIRS) para clasificar causas de interrupción (árboles, animales, rayos), enfrentando el problema de datos desbalanceados.

La estimación de interrupciones bajo condiciones extremas también ha sido examinada mediante enfoques estadísticos. Han et al. [45] modelan la distribución espacial de fallas durante huracanes en la costa del Golfo utilizando variables físicas medibles. Yang et al. [46] estudian la incertidumbre en modelos de predicción de tormentas y demuestran que el rendimiento de los modelos basados en machine learning depende fuertemente del tamaño y representatividad del conjunto de entrenamiento. A su vez, Kankanala et al. [47] presentan AdaBoost+, un método de ensamble que supera regresión, redes neuronales y mixture of experts para estimar fallas asociadas al viento y los rayos.

Otras investigaciones incorporan análisis multivariable para predecir tipos específicos de interrupciones. Kor et al. [48] evalúan arquitecturas de aprendizaje automático para predecir fallas por viento, nieve e hielo, mientras que Doostan y Chowdhury [49] desarrollan un enfoque probabilístico para fallas asociadas a rayos utilizando aprendizaje no supervisado y técnicas de clasificación balanceada.

Asimismo, Chen y Kezunović [50] aplican lógica difusa para análisis predictivo de riesgo, y He et al. [51] comparan árboles de regresión no paramétricos (QRF y BART), demostrando ventajas complementarias según la granularidad espacial y las características del evento.

Dentro de los aportes más recientes, Hou et al. [52] desarrollan un enfoque basado en celdas espaciales de 1 km^2 y Random Forest para predecir interrupciones

bajo tifones, alcanzando precisiones superiores al 92 %. De forma similar, Li et al. [53] construyen un modelo de predicción de cantidad de usuarios afectados por tifones, aplicando selección de variables para obtener un modelo simplificado sin sacrificar precisión.

Otras líneas introducen enfoques más estructurales o basados en simulación. Zhai et al. [54] proponen un modelo que genera sistemas de distribución sintéticos y estima fallas a nivel de edificio mediante funciones de fragilidad, reduciendo la dependencia en datos privados de operadores. Zhu et al. [55] desarrollan un modelo de tormentas de dos etapas para predecir interrupciones en tiempo real, mientras que Arif y Wang [56] combinan análisis estadístico y redes neuronales profundas para predecir tiempos de reparación.

Wanik et al. [57] demuestran que modelos basados en árboles y ensambles, alimentados con datos atmosféricos generados mediante WRF, pueden predecir con alta resolución espacial la distribución de fallas en Connecticut. Por su parte, Jaech et al. [58] incorporan procesamiento de lenguaje natural para actualizar predicciones de duración de interrupciones a partir de reportes de campo.

Más recientemente, Sorokin [59] sistematiza los principios y particularidades de la aplicación de métodos de aprendizaje automático a la evaluación de la confiabilidad de sistemas de potencia, y desarrolla un prototipo capaz de identificar en tiempo real estados potencialmente peligrosos de la red. Por su parte, Liu et al. [60] presentan un método de cálculo rápido de la confiabilidad de redes de distribución activas basado en tasas de falla dinámicas de los equipos, mientras que Avcı [61] integra técnicas híbridas de inteligencia artificial para mejorar la predicción y la gestión de interrupciones, considerando factores meteorológicos, geográficos y operativos. Finalmente, Krstivojević y Terzić [62] aplican simulación de Monte Carlo para seleccionar la opción óptima de inversión orientada a mejorar el desempeño de confiabilidad en redes de distribución, vinculando así el diagnóstico predictivo con la priorización de inversiones.

Un cuerpo de literatura particularmente relevante para este trabajo adopta explícitamente la discretización del espacio en celdas o cuadrículas de tamaño fijo como unidad de análisis, en lugar de trabajar sobre componentes individuales de la red o sobre agregados administrativos. Esta línea es pionera en la disyuntiva entre resolución espacial y error de predicción, disyuntiva central para la especificación de panel cuadrante $\times$ semana empleada en el presente trabajo.

Liu et al. [63] desarrollan uno de los primeros modelos de este tipo, comparando explícitamente un nivel de agregación por código postal (zip code) frente a una malla de celdas de $1\,\text{km} \times 1\,\text{km}$ para predecir interrupciones causadas por huracanes en Carolina del Norte y del Sur; encuentran que, contrario a la intuición de que una mayor resolución mejora la predicción, la agregación a nivel

de celda de 1 km introdujo mayores errores que el nivel de código postal, por lo que finalmente seleccionan la especificación menos granular. Este hallazgo temprano anticipa un problema central en la definición de la unidad espacial óptima: celdas demasiado finas pueden diluir la señal disponible en cada unidad y aumentar la dispersión de los datos (muchas más unidades vacías o con pocos eventos), mientras que unidades más gruesas capturan mejor la señal agregada a costa de perder heterogeneidad espacial local.

Como respuesta a esa disyuntiva, un conjunto de estudios posteriores migró hacia celdas de mayor tamaño. Han et al. [11] desarrollan modelos aditivos generalizados (GAM) sobre una malla de celdas de $2{,}5\,\text{km} \times 3{,}7\,\text{km}$ en la costa del Golfo de México, mostrando que las funciones de suavizado no paramétricas de los GAM capturan mejor las relaciones altamente no lineales entre variables meteorológicas (precipitación, humedad del suelo) y el número de interrupciones por celda, en comparación con modelos lineales generalizados (GLM) sobre la misma malla. [64], trabajando sobre la misma resolución de celda, muestran que modelos de Random Forest —más simples en su formulación que los GAM y GLM previos, y que requieren solo seis variables de entrada (velocidad de ráfaga, duración de vientos fuertes, humedad del suelo, número de clientes y prácticas de poda de árboles)— logran una precisión comparable o superior, evidenciando que, a igualdad de resolución espacial, la elección del algoritmo también condiciona el desempeño predictivo. [65], por su parte, adoptan una malla más gruesa de $5\,\text{km} \times 5\,\text{km}$ y proponen un modelo de tres etapas: una primera etapa de clasificación binaria para determinar la presencia de interrupciones en cada celda, una etapa intermedia de agrupamiento (clustering) de celdas según la magnitud del evento para abordar la fuerte asimetría de los datos con valores distintos de cero, y una tercera etapa de regresión para predecir el número de interrupciones dentro de cada grupo; esta arquitectura multietapa aborda directamente el problema de desbalance de clases que surge de manera natural en paneles espaciales de alta resolución temporal, donde la mayoría de las celdas-periodo no registran ningún evento de falla —un reto metodológico compartido con el panel cuadrante $\times$ semana del presente trabajo—.

McRoberts et al. [66] extienden esta línea utilizando el trazado censal (census tract) como unidad espacial, e incorporan factores ambientales locales —cobertura vegetal, profundidad de raíces, tipo de suelo— para mejorar modelos de predicción de interrupciones por huracán previamente calibrados a nivel de celda, evidenciando que la elección de la unidad espacial de agregación no solo afecta la resolución del análisis, sino también qué variables explicativas resultan viables de incorporar dado su nivel de disponibilidad geográfica. En una revisión sistemática reciente, Arora y Ceferino [12] sintetizan esta evolución —desde

el nivel de código postal y celdas de 1 km, pasando por mallas de $2{,}5 \times 3{,}7$ km y 5×5 km, hasta el nivel de trazado censal y de ciudad— y muestran, mediante la calibración conjunta de modelos GLM, GAM y Random Forest sobre datos de 1,910 ciudades de Texas, Florida, Nueva Jersey y Nueva York, que los modelos existentes tienden a sobrestimar las interrupciones en unidades espaciales de baja población (en el 19.8 % de las ciudades de su muestra, con una razón de sobrestimación promedio de 5.2), y que los Random Forest, si bien evitan estas sobrestimaciones extremas por estar acotados por el rango de los datos de entrenamiento, no logran extrapolar adecuadamente a eventos de viento fuera del rango observado. Este último hallazgo es particularmente relevante para paneles espaciales de alta frecuencia temporal como el aquí propuesto, en la medida en que la capacidad de extrapolación fuera de la muestra —y no solo el ajuste dentro de muestra— condiciona la utilidad del modelo para la priorización de inversión en cuadrantes con historiales de falla poco representados.

En una línea afín mediante representaciones de grafo, Owerko et al. [40] muestran que incorporar explícitamente las relaciones espaciales entre puntos de medición meteorológica mediante redes neuronales de grafos (*Graph Neural Networks*) mejora la predicción de interrupciones, lo que refuerza la idea de que la dependencia espacial entre unidades vecinas contiene información predictiva adicional a la de los atributos puntuales de cada unidad. De manera complementaria, Dunn et al. [7] analizan tres años de registros de interrupciones de alta resolución de una empresa del occidente de Estados Unidos y encuentran que los indicadores de confiabilidad varían en órdenes de magnitud en el espacio y en el tiempo, heterogeneidad que los indicadores agregados reportados públicamente ocultan. Este hallazgo respalda directamente el enfoque del presente trabajo: la desagregación territorial y temporal de SAIDI y SAIFI revela zonas y periodos críticos que el indicador anual del sistema no permite identificar.

En conjunto, esta línea de literatura evidencia una tendencia consistente: el tránsito desde modelos centrados en el componente individual o en agregados puramente administrativos (municipios, circuitos, empresas) hacia esquemas de discretización espacial regular —celdas, cuadrículas o cuadrantes— que permiten capturar de manera más flexible la heterogeneidad espacial de la vulnerabilidad de la red. Esta transición, sin embargo, no está exenta de nuevos retos metodológicos: el tamaño óptimo de la unidad espacial no es neutral frente al desempeño predictivo [63]; la dependencia espacial entre celdas vecinas puede aportar información adicional si se modela explícitamente [40]; y el desbalance de clases derivado de la escasez relativa de eventos de falla en paneles de alta granularidad temporal exige arquitecturas de modelación específicas, como los esquemas multietapa [65]. Estos tres retos —selección del tamaño de la unidad

espacial, modelación de la dependencia espacial y tratamiento del desbalance de clases en un panel de alta frecuencia— constituyen precisamente los ejes metodológicos centrales que este trabajo aborda al construir un panel espacial de cuadrante $\times$ semana para la predicción de SAIDI/SAIFI en el contexto colombiano.

3.2.2. Antecedentes en Colombia y América Latina

La literatura revisada hasta aquí proviene mayoritariamente de Estados Unidos y Asia oriental y se concentra en eventos extremos (huracanes y tifones). Los antecedentes nacionales y regionales son menos numerosos, pero fijan tres referentes directamente pertinentes para este trabajo.

El primero es el contexto regulatorio. En la comparación de las regulaciones de continuidad de Suramérica realizada por **delavechia2023**, Colombia aparece como el país con los peores resultados de duración y frecuencia de interrupciones de la región, y es de los pocos que, con la Resolución CREG 015 de 2018 [1], vincula el desempeño de SAIDI y SAIFI a incentivos y penalidades sobre el ingreso del operador, en lugar de limitarse a compensar al usuario. Esa combinación —indicadores rezagados frente a la región y un esquema que traslada el desempeño al ingreso— es la que convierte la anticipación territorial de la afectación en un problema de gestión con valor económico para el operador.

El segundo referente son los estudios colombianos sobre causas de falla. **aranguren2015** cruzaron datos de descargas atmosféricas con la ubicación de $251\,024$ transformadores del centro del país y encontraron que, en condiciones meteorológicas adversas, una fracción significativa de los transformadores presenta tasas de falla del orden de 45 veces las de condiciones normales, y las redes aéreas extensas más de 75 veces. **alvarez2022** desarrollaron una metodología de mantenimiento predictivo para $15\,869$ transformadores de distribución del Cauca, mediante una máquina de vectores de soporte entrenada con un año y validada con el siguiente; incorporan la densidad de descargas, la ubicación urbana o rural y el tipo de instalación, y reportan que la clase de interés (transformador quemado) se identifica con una precisión cercana al 52–$56\,\%$, muy inferior a la exactitud global, lo que ilustra la dificultad de pronosticar eventos poco frecuentes. Ambos trabajos operan al nivel del activo individual y no estiman indicadores de continuidad.

El tercer referente es la gestión de los indicadores por parte de los operadores. **gomez2017** documentan la estrategia de Enel-Codensa en Bogotá para la transición hacia SAIDI y SAIFI, basada en segmentar la red por grupos de calidad, automatizar y telecontrolar cerca de $3\,700$ equipos y priorizar circuitos mediante análisis de riesgo; reportan reducciones de SAIDI y SAIFI del $31\,\%$ y

26 % en tres años. En la academia nacional, **velasquez2024** combinan series de tiempo y Random Forest para pronosticar la demanda y la vida útil de equipos de seccionamiento en un circuito de Pereira, con SAIDI y SAIFI solo como contexto. En la región, **dacosta2023** usan Random Forest para seleccionar, entre 146 atributos eléctricos, de infraestructura, climáticos, de vegetación y socioeconómicos, los que mejor explican los indicadores DEC y FEC de los conjuntos de usuarios definidos por el regulador brasileño, y encuentran que pocos atributos —principalmente de tamaño y densidad de la red— concentran la capacidad explicativa.

Frente a estos antecedentes, en la revisión realizada no se identificaron estudios colombianos que modelen los indicadores SAIDI y SAIFI de un operador con un panel espacio-temporal que integre sus sistemas de interrupciones, red y usuarios con fuentes externas de clima, vegetación y sismicidad, ni que evalúen los modelos frente a pronósticos de referencia con validación temporal estricta. Ese es el vacío que este trabajo aborda. La Tabla 3.1 resume los antecedentes más próximos y su relación con este trabajo.

3.2.3. Variables explicativas recurrentes en la literatura

La revisión anterior permite identificar un conjunto relativamente estable de variables explicativas que reaparecen de manera sistemática en los modelos de predicción de fallas e interrupciones, independientemente de si la variable de respuesta es un conteo de interrupciones, la fracción de clientes afectados o, como en el presente trabajo, indicadores agregados de confiabilidad (SAIDI/SAIFI) a nivel de cuadrante-semana. A continuación se sintetizan estas variables, agrupadas por categoría, junto con la dirección y el mecanismo de la relación que la literatura documenta con la variable pronosticada.

Variables meteorológicas. La velocidad del viento —típicamente medida como ráfaga máxima de 3 s— es, de manera consistente, la variable individual con mayor poder explicativo en los modelos revisados: Arora y Ceferino [12] la identifican como el predictor más importante en su modelo de Random Forest, por encima de precipitación y densidad poblacional, y su relación con el número de interrupciones es monótonamente creciente y de naturaleza física directa, ya que vientos por encima de aproximadamente 20 m/s superan el umbral de diseño estructural de postes y líneas aéreas [12]. La duración de vientos fuertes por encima de dicho umbral opera de manera similar y suele estar altamente correlacionada con la velocidad máxima, por lo que buena parte de los modelos retienen solo una de las dos variables tras un análisis de colinealidad [12]. La precipitación acumulada (contemporánea y en ventanas previas de 1, 3, 6 o 12

Tabla 3.1: Síntesis de los antecedentes más relacionados con este trabajo

Estudio	Ámbito	Unidad y respuesta	Método	Relación con este trabajo
Liu et al. [63]	Huracanes, EE. UU.	Celda de 1 km y código postal; n.º de interrupciones	Regresión binomial negativa	Origen de la discretización en celdas; disyuntiva entre resolución y dispersión
Han et al. [11]	Huracanes, EE. UU.	Celda de 2.5×3.7 km; interrupciones	GAM	Relaciones no lineales clima–falla; tamaño de celda comparable al de este trabajo
Shashaani et al. [65]	Huracanes, EE. UU.	Celda; interrupciones con exceso de ceros	Modelo multietapa	Motiva el esquema en dos partes (ocurrencia y magnitud)
Arora y Ceferino [12]	Huracanes, EE. UU.	Celda; interrupciones	Random Forest y métodos probabilísticos	Importancia de viento y vegetación; límites de extrapolación de los árboles
Dunn et al. [7]	EE. UU.	Datos de alta resolución; SAIDI/SAIFI	Análisis exploratorio	Heterogeneidad espacial que los agregados ocultan
aranguren2015	Centro de Colombia	Transformador; tasa de falla	Estadística con modelo climático de dos estados	Efecto de las descargas atmosféricas en redes aéreas colombianas
alvarez2022	Cauca, Colombia	Transformador; falla (sí/no)	SVM con validación temporal	Pronóstico de eventos poco frecuentes; mantenimiento predictivo
gomez2017	Bogotá, Colombia	Red del operador; SAIDI y SAIFI	Planeación y priorización por riesgo	Uso operativo de los indicadores en un operador colombiano
dacosta2023	Brasil	Conjunto de usuarios; DEC y FEC	Random Forest y *k*-medias	Atributos de tamaño de red como principales determinantes de los indicadores
delavechia2023	Suramérica	País; indicadores regulatorios	Revisión regulatoria	Desempeño relativo de Colombia y esquema de incentivos de la CREG
Este trabajo	Norte de Santander, Colombia	Cuadrante de $\sim 5 \times 2.5$ km y semana; SAIDI y SAIFI operativos	Panel FE, Random Forest, clasificador de ocurrencia, SAR y SEM	Integración de sistemas del operador y fuentes externas; evaluación frente a pronósticos de referencia

meses, expresada frecuentemente como índice estandarizado de precipitación, SPI) y la humedad del suelo muestran una relación positiva pero *no lineal* con las interrupciones: suelos saturados facilitan el desarraigo de árboles y la caída de líneas ante vientos moderados, mientras que periodos de sequía prolongada debilitan el sistema radicular de los árboles y los vuelve más susceptibles a fallar incluso ante ráfagas menores [11, 12]; esta no linealidad —efectos marcados tanto en el extremo húmedo como en el extremo seco de la distribución— es precisamente la motivación central para preferir modelos aditivos generalizados (GAM) sobre especificaciones lineales cuando se dispone de variables climáticas de este tipo [11].

Variables de vegetación y cobertura del suelo. La proximidad de árboles a las líneas de distribución y el porcentaje de área arbolada dentro de la unidad espacial de análisis mantienen una relación positiva y robusta con la frecuencia de fallas, dado que la caída de árboles y ramas sobre las líneas aéreas es la causa individual más frecuente de interrupciones en redes con alta exposición a vegetación [12, 41]. En consecuencia, la intensidad y frecuencia de la poda preventiva (*tree trimming*) actúa como variable de exposición inversa: Cerrai et al. [41] cuantifican que la adopción de estándares de poda mejorada (*Enhanced Tree Trimming*) reduce las tasas de falla asociadas a tormentas entre 16 % y 48 %, por lo que su ausencia o desactualización en los datos de un cuadrante debería interpretarse como un factor que incrementa la probabilidad esperada de interrupción. La profundidad efectiva de raíces también se ha incorporado como proxy de la resistencia estructural de los árboles ante vientos fuertes, con una relación negativa esperada: mayor profundidad radicular implica menor probabilidad de desarraigo [12].

Variables de infraestructura y exposición. El número de clientes servidos y, de manera más general, la densidad poblacional de la unidad espacial funcionan como *proxy* de la densidad de componentes de red expuestos (postes, transformadores, tramos de línea), y presentan una relación positiva con el número absoluto de interrupciones, aunque no necesariamente con la tasa o fracción de clientes afectados, distinción que resulta crítica al momento de definir la variable de respuesta del modelo [12]. La topología de la red —redes radiales frente a redes en malla o interconectadas— también se documenta como determinante de la propagación de fallas: sistemas radiales, más comunes en zonas rurales, tienden a mostrar interrupciones de mayor alcance ante la falla de un único componente aguas arriba [12], un mecanismo que en el caso colombiano resulta pertinente para distinguir cuadrantes urbanos de cuadrantes rurales o de baja

densidad.

Variables topográficas y geográficas. La elevación y variables derivadas de modelos digitales de terreno se han incorporado por su efecto indirecto sobre la velocidad del viento y los patrones de precipitación a escala local [12], aunque en varios estudios su contribución marginal al poder predictivo resulta baja una vez controlado por viento y precipitación directamente medidos, por lo que su inclusión debe evaluarse en función de la disponibilidad de las variables meteorológicas primarias [12].

Variables de historial de fallas y autocorrelación. Finalmente, un conjunto de estudios documenta la relevancia de incorporar la propia historia de interrupciones de la unidad espacial —o de sus vecinas— como predictor autorregresivo. Jaech et al. [58] muestran que actualizar predicciones de duración de interrupciones a partir de reportes de campo en tiempo real mejora sustancialmente la precisión respecto a modelos que solo usan información ex ante, mientras que los enfoques de redes neuronales de grafos revisados en la sección anterior [40] evidencian que el número y la severidad de fallas en celdas vecinas aporta información predictiva adicional a la de los atributos propios de cada celda, lo cual sugiere la pertinencia de incluir rezagos espaciales y temporales de SAIDI/SAIFI —y no solo covariables exógenas— en la especificación del panel cuadrante $\times$ semana propuesto en este trabajo.

4 Datos

Para el desarrollo del modelo de pronóstico de $SAIFI$ y $SAIDI$ se utilizó una base de datos histórica de eventos de falla reportados en el sistema de distribución, organizada en dos niveles. El *nivel de integración* es el panel *activo* $\times$ *día*, con $N = 87\,007\,074$ observaciones ($A = 47\,649$ activos eléctricos únicos $\times$ $T = 1\,826$ días) entre el 1 de enero de 2021 y el 31 de diciembre de 2025. El *nivel de modelado* es el panel *cuadrante* $\times$ *semana*: $90\,128$ observaciones (344 cuadrantes con red $\times$ 262 semanas) para el análisis exploratorio y $36\,120$ observaciones (344 cuadrantes $\times$ 105 semanas de 2024–2025) para el modelado. Las variables de ambos niveles se documentan en el catálogo de datos del Apéndice A.4.

Tiempo o periodo de estudio. El periodo de estudio abarca desde el 1 de enero de 2021 hasta el 31 de diciembre de 2025.

Unidad muestral. La unidad de integración corresponde a un activo eléctrico por día, lo que define un nivel de granularidad tipo *elemento-día* y permite integrar variables de red, climáticas y de eventos a nivel diario. La unidad de análisis y de modelado es el par *cuadrante* $\times$ *semana*, en el que el cuadrante de la malla institucional representa la *zona* a la que se refieren los objetivos del proyecto (Sección 5.2.5).

4.1. Construcción del dataset

4.1.1. Lógica estructural

La construcción del conjunto de datos sigue la siguiente lógica:

- Se crea un calendario diario para el periodo comprendido entre el 01-01-2021 y el 31-12-2025.
- Se construye el producto cartesiano entre el inventario de activos eléctricos y el calendario diario, garantizando la presencia de todos los activos en cada día del periodo de análisis.
- Sobre esta estructura base se integran:

- Variables de red.
- Variables climáticas agregadas a nivel de activo por día.
- Variables de eventos asociadas a cada activo por día.

4.1.2. Definición de variables de evento

Las variables de eventos se definen así:

- *Duración* (`DURACION_min`, en minutos): minutos de interrupción del activo en el día de observación, prorrateados según la intersección de `[Fecha_Desconexion, Fecha_Conexion]` con ese día calendario. Si el evento cruza varios días, su duración se reparte entre ellos; si hay varios eventos el mismo día, se suman. No se asigna la duración total del evento solo al día de desconexión. En días sin falla, el valor es 0.
- *Frecuencia* (`FRECUENCIA`): número de interrupciones cuyo inicio (`Fecha_Desconexion`) ocurre en el día (sin prorrateo de la frecuencia).

4.1.3. Estructura del dataset consolidado

El dataset final incluye las variables agrupadas por bloque temático, como se resume en la Tabla 4.1.

4.1.4. Variables incorporadas al panel cuadrante–semana

Para complementar la caracterización técnica, demográfica y socioeconómica del panel de modelado se incorporaron 16 variables adicionales. `usuarios_totales` permite construir los indicadores SAIDI y SAIFI con el denominador mensual del sistema, mientras que `cantidad_usuarios_cuadrante` representa la escala local de exposición al servicio. Las variables `ESTRATO_1` a `ESTRATO_6`, junto con `INDUSTRIAL`, `COMERCIAL`, `OFICIAL`, `PROVISIONAL` y `ALUMBRADO_PUBLICO`, describen la composición de los usuarios y permiten analizar si la frecuencia y la duración de las interrupciones presentan diferencias según el tipo de demanda y las características socioeconómicas del territorio.

Por su parte, `FECHA_ACTIVO_MAS_VIEJO`, `FECHA_ACTIVO_MAS_NUEVO` y `PROM_CANT_MODIFICACIONES` aportan información sobre la trayectoria de intervención y renovación de los transformadores. Estas variables permiten evaluar si los

Tabla 4.1: Estructura del dataset consolidado (grano activo × día).

Bloque	**Variables**
Información del activo	`Id_Activo_Electrico`
	`Tipo_Activo_Electrico`
Información geoespacial	`Latitud`
	`Longitud`
	`Altitud`
	`Id_Cuadrante`
	`Latitud_Cuadrante`
	`Longitud_Cuadrante`
Variables de red	`Fecha`
	`Cantidad_Elementos`
	`Cantidad_Usuarios`
	`Antiguedad_Red`
	`Expansion_Red`
Variables climáticas	`Velocidad_Viento_Ms`
	`Temperatura_Media_C`
	`Humedad_Relativa_Pct`
	`Temperatura_Minima_C`
	`Temperatura_Maxima_C`
	`Precipitacion_Total_Mm`
Variables objetivo	`DURACION_min`
	`FRECUENCIA`

cuadrantes con activos menos renovados o con mayor número de modificaciones presentan comportamientos diferentes en SAIDI y SAIFI.

Como salvedad metodológica, las fechas corresponden a `TT2_FMODIFICACION` y no necesariamente a la instalación original del activo. Para evitar fuga de información, en los modelos predictivos solo deben emplearse modificaciones conocidas antes de la semana que se pretende pronosticar. Finalmente, SAIDI y SAIFI se incorporan como variables objetivo y no como predictoras contemporáneas.

Adicionalmente, el panel cuadrante–semana incorpora variables de exposición territorial provenientes de las fuentes externas descritas más adelante (sismicidad y vegetación): `sismos_conteo` y `dist_sismo_prom_km` (sismicidad, SGC); y `ndvi_semanal` junto con sus derivadas `log_ndvi` y `cat_ndvi` (vegetación, NDVI/MODIS). Se suman también las métricas de topología de red `longitud_red_km`, densidad de nodos terminales y número de circuitos por cuadrante.

Número de observaciones. La tabla consolidada del nivel de integración se obtiene como

$$N = A \times T = 47\,649 \times 1\,826 = 87\,007\,074, \tag{4.1}$$

donde:

- N: Número de observaciones de la tabla consolidada (activo $\times$ día).
- A: Número de activos eléctricos de la red.
- T: Número de días observados, equivalente a cinco años de información diaria.

4.2. Procedencia de la información

Origen de la información. La empresa origen de los datos operativos y técnicos es Centrales Eléctricas de Norte de Santander S.A E.S.P (Cens S.A E.S.P).

Lugar donde se registra la información. Sistemas corporativos (BRAE, OMS y GIS). Para variables climatológicas se utiliza la fuente institucional externa NASA POWER [67].

La información se registra en la red de distribución eléctrica de Norte de Santander, con soporte de localización geográfica por activo y por cuadrante.

Fuentes adicionales incorporadas al panel cuadrante–semana. Para enriquecer la caracterización territorial del panel de modelado se incorporaron dos fuentes externas adicionales: los registros de sismicidad del Servicio Geológico Colombiano (SGC) y el índice de vegetación NDVI derivado del producto satelital MODIS MOD13Q1 de la NASA, procesado semanalmente por cuadrante. Adicionalmente, se construyeron métricas de topología de red eléctrica (longitud de red, densidad de nodos, circuitos) a partir del propio sistema georreferenciado GTECH (Sección 5.1.7).

4.3. Consideraciones éticas y disponibilidad de datos y código

Los datos operativos provienen de los sistemas institucionales de CENS S.A. E.S.P. y se emplearon con autorización de la empresa. El estudio no utiliza datos personales: la unidad mínima de registro es el activo eléctrico y los usuarios intervienen solo como conteos agregados por transformador, por lo que no es posible identificar a ninguna persona. Tampoco se emplean datos sensibles ni se recolecta información mediante encuestas o entrevistas. Las variables socioeconómicas (estrato) se usan como proporciones agregadas por cuadrante y con fines exclusivamente descriptivos de la demanda, no para diferenciar la atención a los usuarios, de modo que los resultados no inducen tratos diferenciados entre grupos de población. Las fuentes externas (NASA POWER, MODIS, SGC y DANE) son públicas.

El código de extracción, integración, análisis y modelado se encuentra en el repositorio `https://github.com/esilvas1/DataCollection_Tesis_MCD`, organizado por etapas, y los informes reproducibles de cada etapa se publican en GitHub Pages (Apéndice A.3); los artefactos de reproducibilidad se describen en el Apéndice A.6. Por tratarse de información institucional, los datos crudos no se publican. El repositorio incluye una muestra sintética con la misma estructura del panel de modelado (`Scripts/muestra_sintetica`, generada con `generar_muestra_sintetica.R`): conserva las columnas, los cuadrantes, las semanas y la definición de SAIDI y SAIFI, pero sus valores se generan al azar, de modo que permite ejecutar de principio a fin la cadena de la Etapa 5 sin reproducir las cifras de la tesis. La verificación de las cifras exactas requiere el panel agregado real, que puede ponerse a disposición del jurado con autorización de CENS.

Metodología

La metodología se organiza por etapas alineadas con los objetivos específicos del proyecto (Capítulo 2). El enfoque general consiste en integrar datos, limpiarlos, analizarlos y construir modelos para predecir los indicadores $SAIDI$ y $SAIFI$ de la empresa de distribución eléctrica en Norte de Santander. La correspondencia entre etapas y objetivos se resume al final de este capítulo en la Tabla 5.12.

Se decidió utilizar CRISP-DM (Cross-Industry Standard Process for Data Mining) como marco de referencia por ser un estándar reconocido en la industria para proyectos de ciencia de datos [68], el cual fue adaptado al contexto específico del sector eléctrico regulado. Las fases de CRISP-DM se implementaron de la siguiente manera: el entendimiento del negocio (Business Understanding) corresponde al planteamiento del problema, los objetivos y el marco de referencia (Capítulos 1 a 3). Las fases de entendimiento y preparación de datos (Data Understanding y Data Preparation) corresponden a las Etapas 1 a 4, en Secciones 5.1, 5.2, 5.3 y 5.4, en las que se integran, depuran y exploran los datos y se construyen las variables analíticas. La fase de modelado y evaluación (Modeling y Evaluation) se desarrolla en la Etapa 5, en la Sección 5.5, donde se construyen y validan los modelos predictivos. Finalmente, el despliegue (Deployment) corresponde a la Etapa 6 en la Sección 5.6, en la cual se consolidan los resultados, se documenta el proceso y se entrega código reproducible.

Esta adaptación de CRISP-DM considera los requisitos específicos del regulador (CREG, SSPD), las métricas propias del sector eléctrico ($SAIDI$, $SAIFI$) y la necesidad de que los modelos sean interpretables para su uso en la toma de decisiones.

5.1. Etapa 1 – Extracción de datos

Esta etapa comprende la recolección y estandarización de las fuentes de datos internas y externas enunciadas en el OE1. La correspondencia entre cada tipo de fuente del objetivo (SCADA/OMS, GIS, registros de fallas y mantenimientos, inventarios/SAC y clima) y el sistema efectivamente consultado, junto con su cobertura, sus métricas de integridad y sus limitaciones, se documenta en el

catálogo de datos del Apéndice A.4.

5.1.1. Fuentes de información

A partir del año 2023, la Electrificadora de Norte de Santander realizó una migración de su sistema de gestión de interrupciones. Como resultado, la recopilación de información de interrupciones eléctricas se llevó a cabo a partir de dos bases de datos provenientes de sistemas distintos:

- **OMS SPARD**: sistema utilizado hasta antes de la migración, del cual se extrae la información histórica de interrupciones previas a 2023.
- **OMS SP7 de Siemens**: nuevo sistema implementado desde 2023, del cual se obtiene la información de interrupciones a partir de dicha fecha.

Como se documenta en la Sección 6.3.5, la homologación de códigos asociada al nuevo sistema solo se refleja en la trazabilidad de los eventos a partir de 2024. Esta dualidad de fuentes implica diferencias estructurales en los esquemas de datos (tales como nombres de campos, codificaciones y niveles de granularidad), las cuales fueron consideradas durante el proceso de integración y homologación de la información.

5.1.2. Sistemas y fuentes consultadas

Se integran datos de seis fuentes de información principales, cinco corporativas y una externa:

- **BRAE**: base regulatoria e histórica de eventos.
- **QA_TTC1**: relación entre transformadores y usuarios conectados, insumo de la afectación por evento.
- *OMS SPARD* (sistema histórico): fuente de elemento causante antes de la migración.
- *OMS SP7* (sistema actual): fuente de elemento causante en archivos CSV mensuales.
- **GTECH (GIS)**: inventario y georreferenciación de activos eléctricos.
- **NASA POWER (API)**: serie diaria de variables climatológicas por coordenada/cuadrante.

5.1.3. Extracción base y depuración de eventos de interrupción (BRAE)

La construcción de la base de eventos de interrupción se realizó a partir de la tabla transaccional `BRAE.QA_TFDDREGISTRO`, perteneciente a la Base Regulatoria de Activos Eléctricos (BRAE), la cual contiene el registro histórico de eventos de desconexión del sistema eléctrico. A partir de esta fuente, se ejecutó una consulta SQL orientada a depurar inconsistencias, restringir el periodo de análisis y estandarizar la estructura del identificador de evento.

En primer lugar, se seleccionaron únicamente los campos relevantes para el análisis: el identificador del evento (`FDD_CODIGOEVENTO`), la fecha de inicio de la desconexión (`FDD_FINICIAL`) y la fecha de reconexión (`FDD_FFINAL`). Adicionalmente, se incluyó un campo vacío para `ELEMENTO_FALLADO`, con el fin de mantener compatibilidad estructural con otras fuentes que sí contienen este nivel de desagregación.

Posteriormente, se aplicaron criterios de depuración y filtrado. En primer lugar, se restringió la muestra al periodo comprendido entre los años 2021 y 2025, garantizando consistencia temporal del análisis. En segundo lugar, se excluyeron aquellos registros marcados como no relevantes mediante la variable `FDD_EXCLUSION`, conservando únicamente los eventos clasificados como `NO EXCLUIDA`. En tercer lugar, se eliminaron eventos asociados a causas no válidas según la regulación (`FDD_CAUSA_SSPD NOT IN (1)`), así como aquellos registros sin fecha de finalización (`FDD_FFINAL IS NOT NULL`), los cuales no permiten calcular la duración del evento.

Finalmente, se utilizó la instrucción `DISTINCT` para garantizar la eliminación de duplicados en el identificador de evento, obteniéndose una base depurada y consistente a nivel de evento de interrupción. Como resultado de este proceso de extracción y limpieza, se obtuvo un total de 95 280 registros válidos de eventos de desconexión para el periodo de análisis. La Tabla 5.1 presenta una muestra de la estructura resultante. El código SQL correspondiente se presenta en el Listado A.1 (Apéndice A.2).

Tabla 5.1: Muestra de eventos depurados de interrupción (BRAE; primeras cinco filas)

Id evento	Fecha desconexión	Fecha conexión	Elemento fallado
801851	14/03/21 06:59:00.000	14/03/21 09:30:00.000	(null)
787583	04/01/21 08:50:00.000	04/01/21 17:15:00.000	(null)
787496	03/01/21 14:18:14.296	03/01/21 14:40:42.699	(null)
787232	01/01/21 10:29:33.936	01/01/21 13:30:00.000	(null)
787455	03/01/21 10:34:23.000	03/01/21 13:30:00.000	(null)

5.1.4. Extracción de afectación por evento

Con el fin de complementar la base de eventos de interrupción, se construyó una tabla de afectación asociada a cada evento, incorporando información sobre el número de elementos afectados y la cantidad de usuarios impactados. Este proceso permite pasar de una caracterización puramente temporal del evento a una medición de su severidad en términos de impacto en la red.

La extracción se realizó a partir de la tabla `BRAE.QA_TFDDREGISTRO`, la cual se utilizó como fuente principal de eventos, y se complementó mediante una unión (LEFT JOIN) con la base `QA_TTC1`, que contiene información asociada a la conexión de transformadores y el número de usuarios por conexión.

En particular, la variable `CANTIDAD_USUARIOS` se construyó a partir del conteo de usuarios asociados a cada transformador (`TC1_CODCONEX`) agrupados por periodo, mientras que la variable de afectación por evento se obtuvo mediante la agregación de estos usuarios a nivel de evento de interrupción.

Posteriormente, se aplicaron los mismos criterios de depuración utilizados en la etapa anterior, restringiendo el análisis al periodo 2021–2025, excluyendo eventos marcados como no relevantes (`FDD_EXCLUSION = 'NO EXCLUIDA'`), eliminando causas no válidas según la clasificación regulatoria (`FDD_CAUSA_SSPD NOT IN (1)`) y conservando únicamente registros con fecha de finalización válida (`FDD_FFINAL IS NOT NULL`).

Finalmente, los datos se agregaron a nivel de evento (`FDD_CODIGOEVENTO`) utilizando la función `GROUP BY`, obteniendo como resultado dos indicadores clave: el número de elementos fallados por evento y el total de usuarios afectados. El procedimiento permitió consolidar una base consistente de 95 280 registros, alineada con la estructura del conjunto de eventos previamente depurado. La Tabla 5.2 ilustra una muestra de esta agregación. El código SQL correspondiente se presenta en el Listado A.2 (Apéndice A.2).

Tabla 5.2: Muestra de afectación por evento (BRAE + QA_TTC1; primeras cinco filas)

Id evento	Cantidad elementos fallados	Cantidad usuarios afectados
795044	33	2692
795513	162	11796
788221	10	74
788203	240	3865
789543	8	45

5.1.5. Extracción del elemento causante histórico

Con el objetivo de identificar el elemento de la red asociado a la causa de cada evento de maniobra, se realizó la extracción de información histórica desde la base de datos del sistema OMS (Outage Management System), específicamente desde la tabla `OMS.MANIOBRAS@SPARD`. Esta fuente permite complementar la información de eventos de interrupción mediante la identificación del elemento físico que originó la falla.

El proceso de extracción se centró en dos variables principales: el código de la maniobra (`CODE`), utilizado como identificador del evento en el sistema OMS, y el elemento fallado (`BREAKER`), que corresponde al activo de la red asociado a la causa de la interrupción. Estas variables permiten establecer la relación entre el evento registrado y el componente físico responsable dentro de la infraestructura eléctrica.

Adicionalmente, se aplicaron criterios de filtrado temporal y de calidad de datos. En primer lugar, se restringió la información a registros con fecha igual o posterior al año 2021, garantizando la consistencia histórica del análisis. En segundo lugar, se excluyeron aquellos eventos clasificados como pruebas operativas mediante la condición `CAUSA != 'PRUEBA'`, con el fin de conservar únicamente eventos reales de operación del sistema.

Como resultado de este proceso de extracción y depuración, se obtuvo una base de datos estructurada a nivel de maniobra, la cual permite complementar la trazabilidad entre eventos de interrupción y los elementos físicos de la red asociados a su ocurrencia. La Tabla 5.3 muestra un extracto de esta relación maniobra–elemento. El código SQL correspondiente se presenta en el Listado A.3 (Apéndice A.2).

Tabla 5.3: Muestra de elemento causante histórico (OMS SPARD; primeras cinco filas)

Código maniobra	Elemento fallado
640011	AMVE271
634924	LMVEL79620
634978	LMVEL67393
631108	RMVEL79067-2
631464	CMVE2454

5.1.6. Extracción del elemento causante actual

Con el objetivo de actualizar la información histórica del sistema de maniobras, se realizó la extracción de los datos correspondientes a la versión más reciente del sistema OMS en formato plano (CSV). Este proceso permite complementar la información histórica con registros operativos actuales, garantizando

la continuidad y consistencia de la base de datos utilizada en el análisis.

La extracción se realizó mediante un proceso de lectura y depuración de datos en Python, a partir del archivo fuente correspondiente a la versión actual del sistema. En primer lugar, se cargó el archivo mediante la función `read_csv`, asegurando la correcta lectura de la estructura tabular. Posteriormente, se realizó una limpieza de los nombres de las columnas mediante la eliminación de espacios en blanco al inicio y al final, con el fin de evitar inconsistencias en la identificación de variables.

A continuación, se seleccionaron únicamente las variables relevantes para el análisis: `Maniobra Apertura`, `Tipo Elemento` y `Elemento_Falla`. Esta selección permitió homogenizar la estructura de la base con la información histórica previamente construida. Finalmente, se eliminaron los registros duplicados mediante la función `drop_duplicates`, garantizando la unicidad de las observaciones a nivel de combinación de variables relevantes.

Como resultado, se obtuvo una base depurada y estandarizada del sistema OMS actual, la cual es consistente con la estructura de la base histórica y permite su integración en el proceso de consolidación del dataset final. La Tabla 5.4 presenta una muestra de los registros resultantes. El fragmento Python correspondiente se presenta en el Listado A.5 (Apéndice A.2).

Tabla 5.4: Muestra de elemento causante actual (OMS SP7; primeras cinco filas)

Maniobra apertura	Tipo elemento	Elemento falla
424000000000114424	Transformador de distribucion	1T07942
124000000000269842	Fusible	F1979
124000000000269842	Transformador de distribucion	F1979
124000000000273378	Fusible	F2004
124000000000269851	Fusible	F2000

5.1.7. Extracción de inventario GIS

Con el propósito de incorporar la dimensión espacial de la red eléctrica, se realizó la extracción del inventario georreferenciado a partir del sistema GIS corporativo. Esta información permite asociar cada activo de la red con sus coordenadas geográficas y características físicas, facilitando posteriormente el análisis espacial de los eventos de interrupción.

La extracción se efectuó desde la base de datos `ccomun@gtech`, la cual contiene el inventario técnico de los activos de la red. A partir de esta fuente, se seleccionaron las variables correspondientes al identificador del elemento (`nodo_transform_v`), la latitud (`coor_gps_lat`), la longitud (`coor_gps_lon`) y la altitud (`coor_z`). Adicionalmente, se incluyó la variable `ubicacion`, que permite

complementar la caracterización espacial del activo.

Asimismo, se definió explícitamente el tipo de activo como `Transformador`, con el fin de estandarizar la clasificación dentro del conjunto de datos integrado. Esta homogenización resulta clave para la posterior vinculación con los eventos de interrupción y la construcción del panel activo–día.

Como resultado, se obtuvo una base georreferenciada de los activos de la red, la cual constituye un insumo fundamental para el enriquecimiento espacial del dataset consolidado. La Tabla 5.5 ilustra la estructura de este inventario. El código SQL correspondiente se presenta en el Listado A.4 (Apéndice A.2); la consulta se replica de forma análoga para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador.

Tabla 5.5: Muestra de inventario georreferenciado de activos (GIS GTECH; primeras cinco filas)

Elemento	Latitud	Longitud	Altitud	Tipo
2T01558	6.960719612	-72.18029066	636	Transformador
2T01557	6.972762106	-72.18726993	743	Transformador
2T01467	6.973200989	-72.15472768	815	Transformador
2T01466	6.978510343	-72.14903608	726	Transformador
F3199	6.978980206	-72.19049387	832	Aisladero

5.1.8. Extracción de variables meteorológicas

Con el objetivo de incorporar condiciones climáticas como variables explicativas en el análisis de interrupciones del sistema eléctrico, se realizó la extracción de información meteorológica a partir de la plataforma NASA POWER [67]. Esta fuente proporciona series temporales diarias de variables climáticas relevantes, las cuales permiten capturar la influencia del entorno atmosférico sobre la ocurrencia y duración de eventos en la red.

El proceso de extracción se centró en un conjunto de variables meteorológicas seleccionadas por su relevancia en el análisis de confiabilidad del sistema eléctrico. En particular, se consideraron las variables de precipitación total (`PRECTOT`), temperatura media (`T2M`), temperatura máxima (`T2M_MAX`), temperatura mínima (`T2M_MIN`), humedad relativa (`RH2M`) y velocidad del viento (`WS2M`). La Tabla 5.6 presenta una muestra de estas series. La definición de estos parámetros en el código de extracción se presenta en el Listado A.6 (Apéndice A.2).

Estas variables fueron extraídas a nivel diario para el periodo comprendido entre el 1 de enero de 2021 y el 31 de diciembre de 2025, lo que dio lugar a una base de aproximadamente 83.5 millones de registros. Este volumen de información refleja la estructura panelizada de la base climática, construida mediante la combinación de múltiples variables atmosféricas observadas diariamente a lo

Tabla 5.6: Muestra de variables meteorológicas (NASA POWER; primeras cinco filas)

Vel. viento	Temp. media	Humedad	Temp. min	Temp. max	Precip.
2.06	13.27	87.24	9.12	18.63	2.6
2.66	13.89	88.27	10.71	18.92	1.41
1.93	13.66	88.59	10.29	18.96	3.04
1.73	13.6	85.07	9.13	20.17	9.07
1.45	11.52	69.12	5.95	18.7	0.79

largo del horizonte temporal de análisis.

La incorporación de estas variables permite enriquecer el dataset consolidado con condiciones exógenas del entorno, facilitando el análisis de su relación con la frecuencia y severidad de las interrupciones en el sistema eléctrico.

5.1.9. Resumen metodológico de extracción e integración de bases de datos

La Tabla 5.7 sintetiza el proceso de extracción e integración desarrollado en la Etapa 1. En conjunto, se consolidaron seis fuentes complementarias: BRAE como base transaccional de eventos de interrupción; BRAE + QA_TTC1 para cuantificar la severidad operativa (usuarios afectados); OMS SPARD y OMS SP7 para identificar el elemento causante y fallado en los periodos pre y post migración del sistema; GIS (GTECH) para incorporar la georreferenciación de activos de red; y NASA POWER para enriquecer el análisis con variables climáticas diarias. Cada fuente fue sometida a reglas explícitas de filtrado, homologación y depuración, lo que permitió obtener bases consistentes y trazables que constituyen el insumo inicial para la integración del panel descrita en la Etapa 2.

5.2. Etapa 2 - Integración y depuración de datos

5.2.1. Lógica de integración entre sistemas

Una vez extraídas y depuradas las fuentes descritas en la Etapa 5.1, la integración se ejecuta de forma secuencial sobre tablas intermedias, preservando trazabilidad de llaves y evitando pérdida de emparejamiento entre sistemas con esquemas distintos (BRAE, OMS SPARD, OMS SP7, GIS y NASA POWER). La secuencia aplicada fue la siguiente.

5.2.1.1 *Construcción de la tabla base de eventos (BRAE).*

A partir de `BRAE.QA_TFDDREGISTRO` se genera la tabla `tabla_eventos` con `ID_EVENTO`, `FECHA_DESCONEXION` y `FECHA_CONEXION`, aplicando filtros regu-

Tabla 5.7: Resumen metodológico de extracción e integración de bases de datos

Fuente	**Variables principales**	**Proceso aplicado**	**Resultado**
BRAE (TFDDREGISTRO)	Id evento, fecha desconexión, fecha conexión	Filtrado temporal (2021–2025), exclusión de registros no válidos, eliminación de duplicados	95 280 eventos de interrupción
BRAE + QA_TTC1	Cantidad usuarios, elementos de conexión	JOIN por elemento y periodo, agregación por evento	Base de severidad por evento (usuarios)
OMS SPARD (histórico)	Código maniobra, elemento fallado, elemento causante	Filtrado de registros desde 2021, exclusión de pruebas	Base histórica de causa de falla
OMS SP7 (actual)	Maniobra apertura, tipo elemento, cantidad elementos fallados, elemento falla	Lectura CSV, limpieza de columnas, eliminación de duplicados	Base actualizada de elementos causantes
GIS (GTECH)	Elemento, latitud, longitud, altitud, tipo	Extracción desde sistema georreferenciado corporativo	Inventario espacial de la red
NASA POWER	PRECTOT, T2M, T2M_MAX, T2M_ MIN, RH2M, WS2M	Extracción diaria (2021–2025) por variables climáticas	83.5 millones de registros meteorológicos

latorios del periodo 2021–2025, exclusión de eventos no válidos y eliminación de duplicados. Esta tabla define el universo analítico de interrupciones (95 280 eventos).

5.2.1.2 *Construcción de la tabla de afectación por evento (Tabla 5.2).*

En la Sección 5.1.4 se construye la Tabla 5.2 de afectación por evento, la cual consolida las columnas `CANTIDAD_ELEMENTOS` y `CANTIDAD_USUARIOS` a nivel de `ID_EVENTO`. Su integración a la tabla base consolidada se realiza en el paso 5.2.1.5.

5.2.1.3 *Completar `ELEMENTO_FALLADO` (OMS SPARD + OMS SP7).*

La tabla base de eventos obtenida en la Sección 5.1.3 se construyó con el campo `ELEMENTO_FALLADO` vacío, reservado para su completamiento en la integración. Dado el cambio de sistema OMS en el año 2023, la información del elemento causante se extrajo de forma separada en dos fuentes: la Sección 5.1.5 (*Extracción del elemento causante histórico*, OMS SPARD) y la Sección 5.1.6 (*Extracción del elemento causante actual*, OMS SP7). En este paso, la tabla de la Sección 5.1.3 se cruza con ambas tablas OMS, aplicando en cada caso la lógica de emparejamiento definida en su extracción:

- *Histórico (Sección 5.1.5 – OMS SPARD):* cruce por `CODIGO_MANIOBRA` ↔ `ID_EVENTO` para completar `ELEMENTO_FALLADO` con el valor de `BREAKER` en eventos del periodo pre-migración.
- *Actual (Sección 5.1.6 – OMS SP7):* cruce por `MANIOBRA_APERTURA` ↔ `ID_EVENTO` para completar `ELEMENTO_FALLADO` con el valor de `ELEMENTO_FALLA`, junto con `TIPO_ELEMENTO`, en eventos del periodo post-migración.

5.2.1.4 *Construcción de la tabla base consolidada (activo–día).*

A partir de este paso se inicia la construcción de la tabla base consolidada del proyecto. Como insumo inicial se toma la Tabla 5.5 (inventario georreferenciado de activos obtenido en la Sección 5.1.7), del cual se conserva un registro por `ELEMENTO` (47 649 activos únicos), y se cruza con un calendario diario comprendido entre el 2021-01-01 y el 2025-12-31 (1 826 días), empleando el campo `FECHA_DIA`. Este cruce genera un producto cartesiano entre el universo de activos eléctricos y el horizonte temporal de análisis, con 87 007 074 observaciones ($47\,649 \times 1\,826$), definiendo la estructura panel *activo* $\times$ *día* sobre la cual, en los pasos 5.2.1.5 a 5.2.1.8, se anexan los valores

restantes de la secuencia de integración. El detalle del procedimiento para los pasos 5.2.1.4 a 5.2.1.8 se documenta en el Apéndice A.3.1.

5.2.1.5 *Integración de `CANTIDAD_ELEMENTOS` y `CANTIDAD_USUARIOS` (afectación por evento).*

Sobre la tabla base consolidada del paso 5.2.1.4, se anexan las métricas de *severidad del evento* (`ELEMENTOS_AFECTADOS` y `USUARIOS_AFECTADOS` de `tabla_eventos_ajustado.csv`, alineadas con la Tabla 5.2). Estas cantidades se miden a nivel de `ID_EVENTO`, tamaño del impacto de la interrupción, y se atribuyen al activo fallado mediante las llaves:

- `COMPONENTE_FALLADO` = `ELEMENTO` (activo de red, no el identificador del evento);
- `as.Date(FECHA_DESCONEXION)` = `FECHA_DIA`.

El cruce es izquierdo por (`ELEMENTO`, `FECHA_DIA`) y conserva $N = 87\,007\,074$ filas. Si un activo registra varios eventos el mismo día, se conserva un único valor de afectación (el primer `ID_EVENTO` ordenado); *no* se suman las severidades de esos eventos en el panel diario. La frecuencia de todas las desconexiones del día se construye por separado en el paso 5.2.1.7. En días sin falla, `CANTIDAD_ELEMENTOS = 0` y `CANTIDAD_USUARIOS = 0`.

Nota metodológica: bajo esta regla, `CANTIDAD_*` no representa "usuarios del activo", sino la severidad del evento anclada al breaker en el día de inicio. En la taxonomía de modelado (Sección 3.1.2), estas cantidades pertenecen al *impacto posterior*: describen severidad una vez ocurrido el evento y *no* son predictoras contemporáneas de frecuencia o duración. Definiciones alternativas de agregación, suma o máximo de todos los eventos del mismo activo–día, o conteo de usuarios únicos por cuadrante–semana, pueden reelaborarse en la Etapa 4 sin alterar ese rol.

5.2.1.6 *Integración de variables climáticas (NASA POWER).*

Sobre la tabla resultante del paso 5.2.1.5 ($N = 87\,007\,074$ filas), se anexan las variables de la serie diaria `nasa_power_consolidado` mediante cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`), incorporando precipitación, temperatura (media, máxima, mínima), humedad relativa y velocidad del viento, sin modificar el cardinal del panel.

5.2.1.7 *Agregación de variables objetivo (`DURACION_min` y `FRECUENCIA`).*

En este paso se construyen las columnas `DURACION_min` y `FRECUENCIA` sobre la tabla resultante del paso 5.2.1.6 ($N = 87\,007\,074$ filas). Para ello, se

expanden previamente los eventos de la Tabla 5.1 (Sección 5.1.3) a nivel (`COMPONENTE_FALLADO`, `FECHA_DIA`) y el resultado se integra al panel mediante cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`). La Tabla 5.1 contiene los campos `FECHA_DESCONEXION` y `FECHA_CONEXION`. Con base en las fechas de desconexión y reconexión, se asignan los valores diarios de la siguiente forma:

- *Duración* (`DURACION_min`, en minutos): minutos de interrupción del activo *en* `FECHA_DIA`, prorrateados por día. Cuando un evento abarca varios días, su duración se reparte entre cada `FECHA_DIA` según los minutos que el evento ocupa dentro de ese día (intersección del intervalo `[FECHA_DESCONEXION, FECHA_CONEXION]` con cada día calendario). El día de inicio recibe los minutos desde `FECHA_DESCONEXION` hasta la medianoche; los días intermedios, 1 440 min cada uno; y el día de cierre, los minutos desde la medianoche hasta `FECHA_CONEXION`. Si varios eventos ocupan el mismo día, se suman los minutos prorrateados de cada uno. *No* se carga la duración total del evento únicamente en el día de desconexión.
- *Frecuencia* (`FRECUENCIA`): número de desconexiones cuyo inicio (`FECHA_DESCONEXION`) ocurre en `FECHA_DIA` (no se prorratea; se cuenta solo en el día de inicio).

Cuando el activo no presenta interrupciones en un día, se asigna `DURACION_min = 0` y `FRECUENCIA = 0`. El cruce exige que `COMPONENTE_FALLADO` coincida con `ELEMENTO` del inventario `tipo_elemento.csv` (Tabla 5.5), el cual emplea el *código de sitio* georreferenciado. Cuando OMS registra el *código del activo* reemplazado en lugar del código de sitio, el emparejamiento falla y el evento no se propaga al panel espacial (Sección 6.3.5).

5.2.1.8 *Consolidación del panel final (activo–día).*

Sobre la tabla base consolidada definida en el paso 5.2.1.4, y una vez anexados los valores de los pasos 5.2.1.5 a 5.2.1.7, se obtiene el dataset final con grano *activo eléctrico* $\times$ *día* y 87 007 074 observaciones (47 649 activos $\times$ 1 826 días). En días sin falla se registra `DURACION_min = 0`, `FRECUENCIA = 0`, `CANTIDAD_ELEMENTOS = 0` y `CANTIDAD_USUARIOS = 0`.

La base de datos consolidada se estructura como un panel de datos de tipo activo–tiempo, donde la unidad muestral corresponde a un *activo eléctrico observado diariamente*. Cada observación se identifica mediante el par activo–día dentro del periodo de análisis, lo que permite capturar la evolución temporal de cada activo a lo largo del horizonte de estudio. Con

47 649 activos eléctricos únicos en la Tabla 5.5 (inventario GIS, un registro por `ELEMENTO`) y 1 826 días observados (cinco años de información diaria), el panel balanceado comprende 87 007 074 observaciones.

5.2.2. Diagrama de flujo de la secuencia de integración

La secuencia de integración y la estructura del panel final se resumen visualmente en la Figura A.1 (Apéndice A.1), que especifica las relaciones entre las tablas y las operaciones aplicadas en cada paso.

5.2.3. Descripción de la tabla base consolidada

La Tabla 5.8 presenta una vista previa de la tabla base consolidada resultante del paso 5.2.1.8, con grano *activo eléctrico* × *día*. La muestra completa, con todas las columnas del panel divididas en bloques temáticos (identificación del activo, severidad, clima y continuidad), se documenta en el Apéndice A.7.1.

Tabla 5.8: Vista previa de la tabla base consolidada (grano activo–día)

Id activo	Fecha día	C. elem.	C. usu.	Temp. med.	Precip.	Duración (min)
AASW4819	01/01/2021	0	0	23.91	3.19	0
1T12452	01/01/2021	0	0	24.58	1.31	0
REC21365	01/01/2021	125	2015	23.04	3.19	421.5
CUC12345	01/01/2021	0	0	23.02	7.28	0
INT39845	02/01/2021	0	0	23.83	1.99	0

Nota: los registros sin interrupción en el día presentan `DURACION_min = 0` y `FRECUENCIA = 0`. La duración del panel diario se expresa en *minutos* (columna `DURACION_min` en `data_consolidada.csv`).

5.2.4. Descripción de las variables

Severidad y clima inicial (Tabla 5.8; detalle completo en el Apéndice A.7.1). Las columnas `ID ACTIVO` y `FECHA DIA` se repiten en esta tabla para facilitar la trazabilidad de filas entre bloques consecutivos. Las variables propias de este bloque son:

- *C. elem.* (`CANTIDAD_ELEMENTOS`): número de elementos de red afectados por el *evento* de interrupción atribuido al activo fallado (`COMPONENTE_FALLADO`) en el día de desconexión (paso 5.2.1.5). No es el inventario del activo ni un conteo de usuarios únicos del cuadrante. Si hay varios eventos el mismo activo–día, el panel conserva la severidad de un solo evento. Cuando

el activo no registra falla en el día, el valor es 0. En el modelado es *impacto posterior* (Sección 3.1.2), no predictora contemporánea. *Clasificación:* cuantitativa discreta.

- *C. usu.* (`CANTIDAD_USUARIOS`): número de usuarios afectados por el mismo evento, con la misma atribución espacial y temporal que `CANTIDAD_ELEMENTOS`. Es una medida de severidad operativa del impacto sobre la demanda (impacto posterior; Sección 3.1.2), no una covariable disponible antes del evento ni una predictora válida de su ocurrencia o duración. En días sin interrupción, el valor es 0. *Clasificación:* cuantitativa discreta.
- *Vel. viento* (`WS2M`): velocidad del viento a 2 m de altura, expresada en m/s. Corresponde a la variable `WS2M` de NASA POWER (Sección 5.1.8) e integra al panel por `FECHA_DIA` en el paso 5.2.1.6. *Clasificación:* cuantitativa continua.
- *Temp. med.* (`T2M`): temperatura media del aire en el día, expresada en °C. Proviene del parámetro `T2M` de NASA POWER y captura las condiciones térmicas promedio del entorno asociadas a cada observación activo–día. *Clasificación:* cuantitativa continua.

Clima complementario (detalle completo en el Apéndice A.7.1). Al igual que en la Tabla 5.8, `ID ACTIVO` y `FECHA DIA` permiten alinear filas entre tablas. Las variables climáticas restantes del bloque son:

- *Hum. rel.* (`RH2M`): humedad relativa del aire a 2 m, expresada en porcentaje (%). Proviene del parámetro `RH2M` de NASA POWER e integra al panel por `FECHA_DIA`. *Clasificación:* cuantitativa continua.
- *Temp. min.* (`T2M_MIN`): temperatura mínima diaria del aire, expresada en °C. Corresponde al parámetro `T2M_MIN` de NASA POWER y complementa la temperatura media con el extremo inferior del rango térmico del día. *Clasificación:* cuantitativa continua.
- *Temp. max.* (`T2M_MAX`): temperatura máxima diaria del aire, expresada en °C. Proviene del parámetro `T2M_MAX` de NASA POWER y representa el extremo superior del rango térmico observado en el día. *Clasificación:* cuantitativa continua.
- *Precip.* (`PRECTOT`): precipitación total acumulada en el día, expresada en mm. Corresponde al parámetro `PRECTOT` de NASA POWER y permite incorporar la exposición del activo a condiciones de lluvia en la fecha de observación. *Clasificación:* cuantitativa continua.

Variables de continuidad (Tabla 5.8). Este bloque concentra las variables objetivo del análisis, construidas en el paso 5.2.1.7 a partir de la Tabla 5.1 (eventos depurados, Sección 5.1.3) y de los campos `FECHA_DESCONEXION` y `FECHA_CONEXION`:

- *Duración* (`DURACION_min`, en minutos): minutos de interrupción del activo *en* `FECHA_DIA`, obtenidos prorrateando cada evento según la intersección de `[FECHA_DESCONEXION, FECHA_CONEXION]` con ese día (paso 5.2.1.7). Si el evento cruza varios días, su duración se reparte entre ellos; si hay varios eventos el mismo día, se suman los minutos prorrateados. No equivale a colocar la duración total del evento solo en el día de desconexión. En días sin falla, el valor es 0. *Clasificación:* cuantitativa continua.
- *Frecuencia* (`FRECUENCIA`): número de interrupciones del activo cuyo inicio (`FECHA_DESCONEXION`) ocurre en `FECHA_DIA`. La frecuencia se contabiliza únicamente en el día de inicio y *no* se prorratea entre días. En días sin falla, el valor es 0. *Clasificación:* cuantitativa discreta.

Una vez construido el panel consolidado (pasos de integración 5.2.1.4–5.2.1.8), se deriva la tabla agregada por cuadrante y semana (Sección 5.2.5). La Etapa 2 cierra con la evidencia institucional de calidad de las fuentes (Sección 5.2.8). El diagnóstico de completitud del panel, la identificación de valores extremos y el resto del análisis exploratorio se desarrollan en la Etapa 3; la imputación, el tratamiento definitivo de atípicos y la preparación del dataset para modelado, en la Etapa 4.

5.2.5. Agrupación de data consolidada por semana y cuadrante

Definición del grano analítico (cuadrante $\times$ semana)

El panel consolidado con grano *activo eléctrico* $\times$ *día* ($N = 87\,007\,074$ observaciones) constituye la base de integración y trazabilidad del proyecto: preserva la relación uno a uno entre cada activo de red y cada día del horizonte 2021–2025, y permite reconstruir con rigor la secuencia de pasos descrita en la Sección 5.2.1. No obstante, el objetivo del estudio, pronosticar el comportamiento de $SAIDI$ y $SAIFI$ en distintas áreas del territorio de concesión, exige una unidad de análisis de mayor agregación espacial y temporal, coherente con la lectura regulatoria y operativa de los indicadores de continuidad del servicio.

Desde el punto de vista espacial, los indicadores de calidad se interpretan y gestionan a escala territorial (zonas de concentración, circuitos y áreas de servicio), no a nivel de un activo aislado. Para sintetizar el comportamiento de la red en unidades homogéneas del territorio, se adopta la malla institucional de

800 cuadrantes que cubre el área de concesión de la red eléctrica. En esta malla, el sufijo `_800` identifica la versión del esquema con 800 divisiones espaciales; cada celda tiene dimensiones aproximadas de 5×2.5 km. Cada activo eléctrico se asigna a un `id_cuadrante` mediante el catálogo `ELEMENTO_FALLA_CUADRANTE_800`, de modo que las observaciones diarias de múltiples activos ubicados en la misma celda puedan consolidarse en una métrica zonal. La Figura 5.1 ilustra la estructura de esta partición espacial sobre el área de estudio. De las 800 celdas, 344 contienen activos de la red eléctrica y constituyen el universo del panel agregado (344 cuadrantes $\times$ 262 semanas $=$ 90 128 filas); en esta tesis la *zona* a la que se refieren los objetivos se operacionaliza como el cuadrante de esta malla. En el periodo de modelado (2024–2025), 324 de esos cuadrantes registran al menos un evento, el corte transversal espacial emplea 343 y las especificaciones de efectos fijos estiman 310 efectos de cuadrante, diferencias que obedecen a la exclusión de filas con predictoras incompletas.

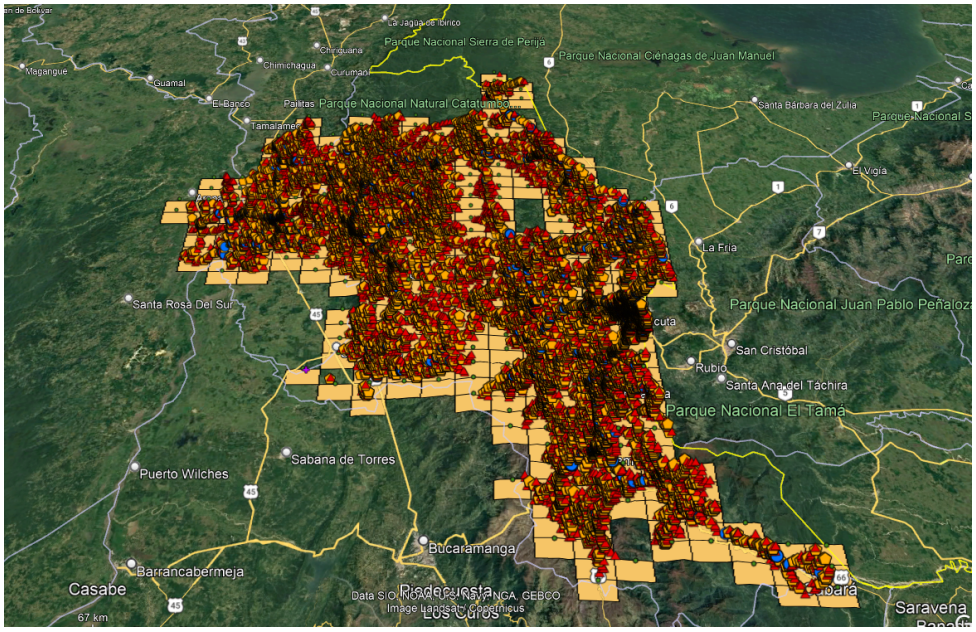


Figura 5.1: Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. 5×2.5 km).

Desde el punto de vista temporal, la granularidad diaria del panel es necesaria para la integración de eventos, clima y severidad, pero resulta excesivamente ruidosa para el análisis exploratorio espacial y para la modelación orientada a dinámicas semanales de continuidad y clima. Por ello, se define la *semana calendario* (con inicio en lunes) como periodo de agregación temporal, lo que permite suavizar fluctuaciones diarias, estabilizar las series de interrupción y alinear las covariables meteorológicas en un horizonte compatible con la gestión ope-

rativa y con visualizaciones espacio-temporales (mapas por cuadrante y series semanales).

Bajo esta definición, la unidad muestral del dataset agregado es el par *(cuadrante, semana)*. El panel `data_consolidada.csv` se conserva como insumo base y referencia del proyecto; la tabla derivada `data_agrupada_por_cuadrante_semana.csv` constituye la representación analítica para los análisis territoriales posteriores, sin sustituir ni alterar el panel diario original.

Procedimiento de agregación

Con el panel consolidado `data_consolidada.csv`, se construyó la tabla de análisis a grano *cuadrante* × *semana*. El procedimiento se documenta en el Apéndice A.3.2.

El insumo principal es el panel del paso 5.2.1.8. Para asignar cada activo a su zona de análisis espacial, se utiliza el catálogo `ELEMENTO_FALLA_CUADRANTE_800`, del cual se extrae la relación `ELEMENTO` → `id_cuadrante` (campo `CUADRANTE_1`). La asignación se integra al panel mediante cruce izquierdo por `ELEMENTO`, conservando todas las filas del panel y anexando el identificador de cuadrante cuando existe emparejamiento. Complementariamente, el archivo `CUADRANTE_CORD_800` aporta la referencia de centroides por cuadrante.

Sobre el panel enriquecido, cada observación diaria se asigna a una semana calendario mediante `floor_date(FECHA_DIA, unit = "week", week_start = 1)`, de modo que la semana inicia en lunes. La duración del panel activo × día se conserva en *minutos* (`DURACION_min`; paso 5.2.1.7). Para la agregación semanal se convierte a horas como `duracion_horas = DURACION_min / 60`. Esta conversión *no* vuelve a prorratear entre días: el prorrateo temporal ya se resolvió al construir el panel diario; aquí solo se unifican unidades y se suman los minutos diarios (ya prorrateados) de los activos del cuadrante.

La agregación distingue dos naturalezas de variable. Las variables *operativas* (impacto y continuidad) son propias de cada activo: dos activos del mismo cuadrante pueden fallar el mismo día y sus conteos deben sumarse, por lo que se agregan directamente sobre las filas activo × día con `group_by(id_cuadrante, semana)`. Las variables *climáticas*, en cambio, describen un campo espacial común: como consecuencia del cruce del paso 5.2.1.6, todos los activos de un mismo cuadrante comparten el valor meteorológico del día, de modo que la serie diaria aparece replicada tantas veces como activos tenga el cuadrante. Por ello el bloque climático se agrega en *dos etapas*: primero se colapsa el panel a un registro por (`id_cuadrante`, `FECHA_DIA`), eliminando la replicación por activo, y sobre esa serie diaria del cuadrante se calcula el resumen semanal. Omitir la primera etapa dejaría el acumulado de lluvia multiplicado por el número de activos del cuadrante, un sesgo multiplicativo que además varía entre cuadrantes y

contamina cualquier comparación territorial posterior.

Las reglas de resumen son las siguientes:

- *Coordenadas del cuadrante* (`latitud`, `longitud`, `altitud`): primer valor registrado en el grupo (`first`), tomado del inventario georreferenciado del panel.
- *Impacto operativo:* `usuarios_afectados` = `sum(CANTIDAD_USUARIOS)` y `elementos_afectados` = `sum(CANTIDAD_ELEMENTOS)` en la semana, sumando las severidades de evento ya atribuidas a los activos del cuadrante (paso 5.2.1.5). Esta suma agrega *impactos de evento*, no un conteo de usuarios o elementos únicos de la semana; tampoco multiplica la severidad por el número de activos del cuadrante (a diferencia del clima, que sí requería colapsar la replicación diario–activo). En el modelado pertenecen al grupo de *impacto posterior* (Sección 3.1.2): se conservan para el EDA y la descripción de severidad, pero *no* entran como predictoras contemporáneas de `n_eventos` ni de `duracion_total`. Una reelaboración de la regla de agregación, si procede, se documenta en la Etapa 4 sin cambiar esa exclusión.
- *Variables climáticas semanales:* sobre la serie diaria por cuadrante de la primera etapa, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana` como promedio de los días de la semana; `temp_max_semana` y `viento_max_semana` como máximo; `temp_min_semana` como mínimo; y `precip_total_semana` como suma de la precipitación diaria del cuadrante, es decir el acumulado de lluvia de la semana en milímetros.
- *Continuidad del servicio:* `n_eventos` = `sum(FRECUENCIA)` (total de desconexiones *iniciadas* en la semana, sin prorrateo de la frecuencia) y `duracion_total` = `sum(duracion_horas)` (suma semanal, en horas, de los minutos diarios de interrupción ya prorrateados en el panel activo × día; unidad resultante: horas).

El resultado se exporta como `data_agrupada_por_cuadrante_semana.csv` en la ruta definida por la variable de entorno `UBICACION_DATA`.

5.2.6. Descripción de la tabla base semanal cuadrante

La Tabla 5.9 resume la estructura del dataset agregado `data_agrupada.csv`, con grano *cuadrante* × *semana*. Cada fila corresponde a un par (`id_cuadrante`, `semana`) y concentra, para esa celda de la malla y ese periodo semanal, las coordenadas de referencia, el impacto operativo acumulado, las variables climáticas resumidas y las métricas de continuidad del servicio. Se incluyen además los

bloques incorporados en la materialización de D_{mod} (`data_agrupada_mod.csv`): usuarios y denominadores, composición de estrato/sector, fechas y reposiciones de transformadores, y las respuestas SAIDI/SAIFI. La Tabla 5.10 presenta una vista previa; la muestra completa por bloques temáticos se documenta en el Apéndice A.7.2.

Tabla 5.9: Estructura de la tabla base semanal cuadrante (`data_agrupada.csv`).

Bloque	Variables	Regla de agregación
Identificación	`id_cuadrante`	Llave del grupo
	`semana`	
Georreferencia	`latitud`	`first`
	`longitud`	
	`altitud`	
Impacto	`usuarios_afectados`	`sum`
	`elementos_afectados`	
Clima	`temp_media_semana`	`mean`†
	`temp_max_semana`	`max`†
	`temp_min_semana`	`min`†
	`humedad_media_semana`	`mean`†
	`viento_medio_semana`	`mean`†
	`viento_max_semana`	`max`†
	`precip_total_semana`	`sum`†
Continuidad	`n_eventos`	`sum`
	`duracion_total`	
Usuarios‡	`usuarios_totales`	Cruce por mes /
	`cantidad_usuarios_cuadrante`	cuadrante
Estrato y sector‡	`ESTRATO_1` ... `ESTRATO_6`	Conteo por
	`INDUSTRIAL`, `COMERCIAL`	cuadrante
	`OFICIAL`, `PROVISIONAL`	
	`ALUMBRADO_PUBLICO`	
Activos‡	`FECHA_ACTIVO_MAS_VIEJO`	`min`
	`FECHA_ACTIVO_MAS_NUEVO`	`max`
	`PROM_CANT_MODIFICACIONES`	`mean`
Respuestas‡	`SAIDI`	Cálculo derivado
	`SAIFI`	

Nota: † el bloque climático se resume en dos etapas; la regla indicada opera sobre la serie diaria por cuadrante, obtenida tras colapsar las filas activo × día que replican el mismo valor meteorológico. ‡ bloques incorporados en la materialización de D_{mod} (`data_agrupada_mod.csv`): usuarios y composición de estrato/sector provienen de los maestros comerciales cruzados por mes y cuadrante; las fechas y el promedio de reposiciones se derivan de `TT2_FMODIFICACION` por cuadrante; SAIDI y SAIFI se calculan a partir de la duración y frecuencia de interrupciones sobre `usuarios_totales` y se emplean exclusivamente como variables de respuesta.

Nota: la muestra completa, con coordenadas, temperaturas máxima/mínima, viento y humedad por bloques temáticos, se documenta en el Apéndice A.7.2. Cadena de unidades de continuidad: panel diario en *minutos* (`DURACION_min`) → conversión `/60` → `duracion_total` semanal en *horas*. El prorrateo entre días se aplica solo al construir `DURACION_min` (paso 5.2.1.7); la agregación semanal

Tabla 5.10: Vista previa de la tabla base semanal cuadrante (grano cuadrante–semana)

Id cuad.	Semana	Usu. afect.	Temp. med.	Precip.	N eventos	Dur. total (h)
1	28/12/2020	0	13.6	18.5	0	0.0
12	11/01/2021	842	22.4	8.4	5	28.4
45	18/01/2021	0	23.8	6.2	0	0.0
117	25/01/2021	1254	24.1	9.8	8	41.7
203	01/02/2021	0	24.5	4.1	0	0.0

suma esos minutos ya prorrateados, convertidos a horas. Las semanas sin interrupciones registran `n_eventos = 0` y `duracion_total = 0`. Las unidades de temperatura, humedad, viento y precipitación coinciden con las del panel diario (°C, %, m/s y mm, respectivamente).

5.2.7. Justificación y enriquecimiento del panel cuadrante–semana

Tras materializar la tabla base semanal (Secciones 5.2.5–5.9), se incorporan atributos territoriales, de red y de exposición que no están en el panel operativo original. El procedimiento reproducible corresponde a los informes `Etapa2_03` a `Etapa2_12` (Apéndices A.3.17–A.3.25). Cada bloque se argumenta en el cuerpo del capítulo con hallazgos, figuras representativas y remisión al HTML para el detalle de código.

Justificación de la agregación espacial

La elección del grano cuadrante × semana se fundamenta en la evidencia de concentración espacial de fallas y en la escala de dependencia comparable al tamaño de los cuadrantes de la malla operativa (`Etapa2_03_justificacion_agregacion_espacial.Rmd`). Operar a nivel activo × día preserva trazabilidad, pero genera esparcidad extrema e inviabilidad computacional para vecindades densas; la agregación reduce ceros estructurales y alinea la unidad de análisis con la lectura territorial de $SAIDI$ y $SAIFI$.

Infraestructura eléctrica por cuadrante

A partir del inventario GIS se agregan conteos y tipologías de elementos (transformadores, seccionadores, etc.) al polígono de cada cuadrante (`Etapa2_04`). El resultado se exporta en `infraestructura_cuadrantes_reales.gpkg` y alimenta variables de exposición estática (`n_elementos`, proporciones por tipo). La Figura 5.2 resume la heterogeneidad de escala entre cuadrantes; la Figura 5.3 ilustra la composición de infraestructura en los cuadrantes con mayor densidad de activos.

Detalle reproducible: Apéndice A.3.18.

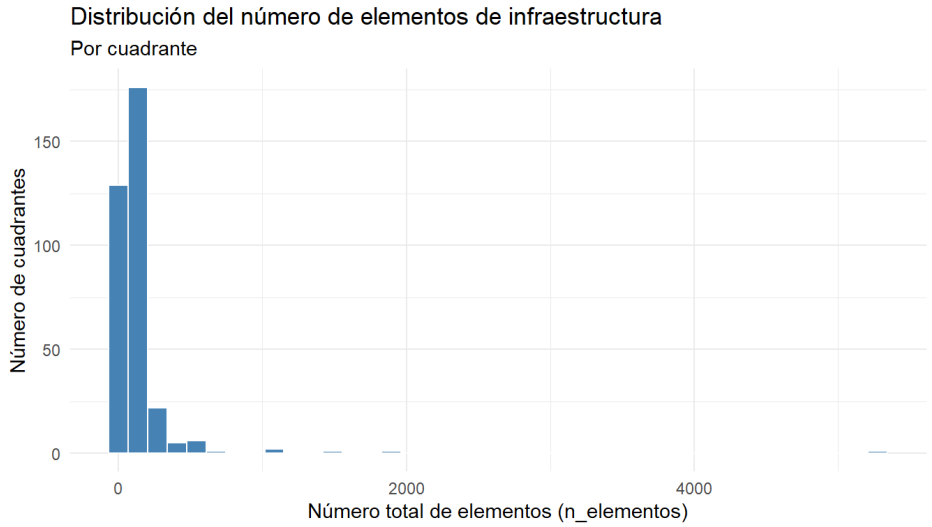


Figura 5.2: Distribución del número de elementos de infraestructura por cuadrante real.

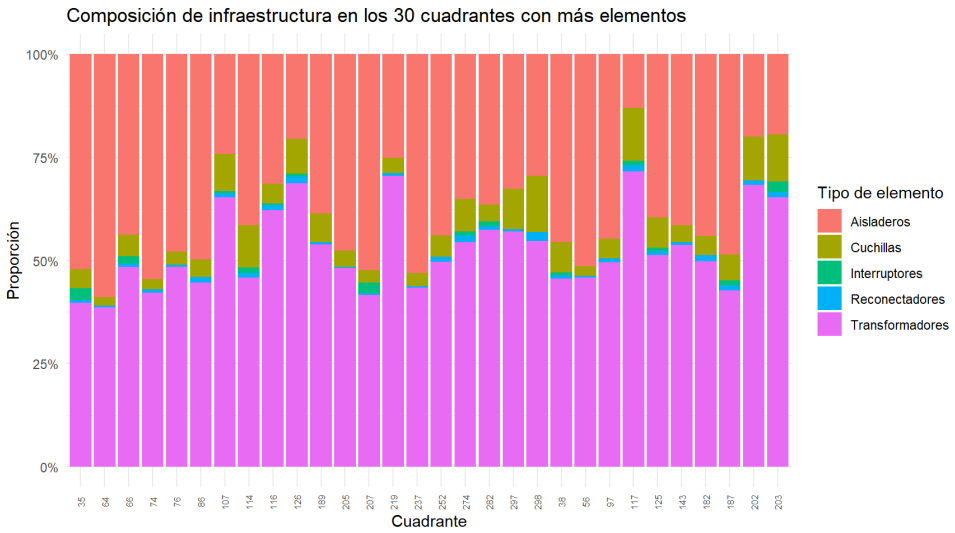


Figura 5.3: Composición tipológica de infraestructura en los 30 cuadrantes con mayor número de elementos.

Estratificación municipal

Mediante intersección espacial entre polígonos de cuadrante y la capa oficial DANE de estratificación municipal (`Mpio_Metodologia_Estr_Estr_Predom`), se asigna a cada cuadrante el municipio y el estrato predominante (`Etapa2_05`). En límites administrativos la regla de desempate es el municipio del centroide. La Figura 5.4 muestra la asignación territorial; la Figura 5.5 la frecuencia de cuadrantes por estrato predominante.

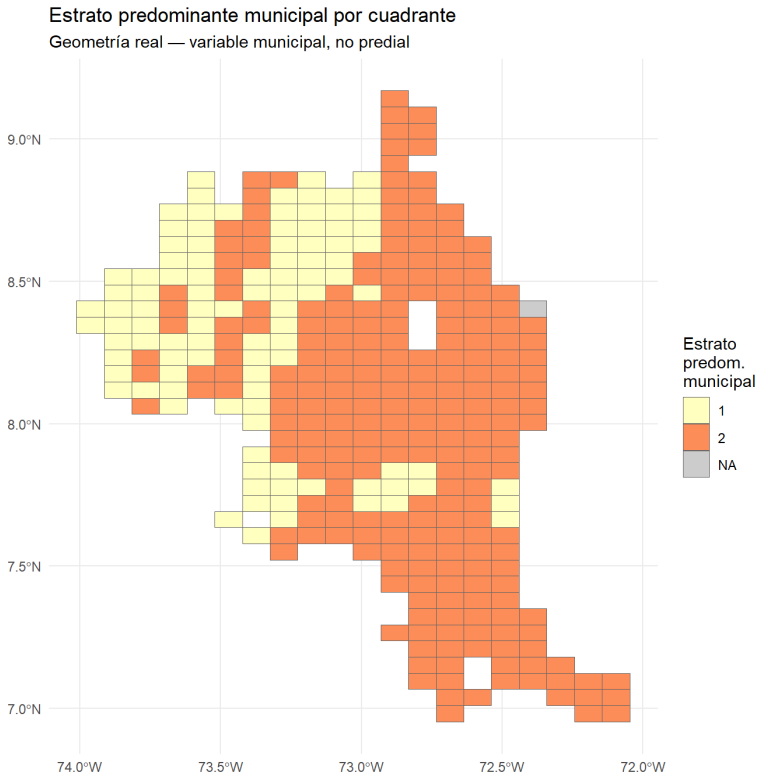


Figura 5.4: Mapa de cuadrantes según estrato socioeconómico predominante del municipio.

Se reconoce que el estrato es una variable *municipal*, no predial dentro del cuadrante. Detalle: Apéndice A.3.19.

Sismicidad (SGC)

La sismicidad del Servicio Geológico Colombiano se integra como exposición territorial por buffers de distancia al centroide del cuadrante y agregación semanal (`Etapa2_07`). La Figura 5.6 muestra la evolución temporal; la Figura 5.7 la distribución de magnitudes.

Durante la re-estimación final se detectaron y corrigieron dos errores en la construcción de estas variables. El primero era de unidades: la matriz de dis-

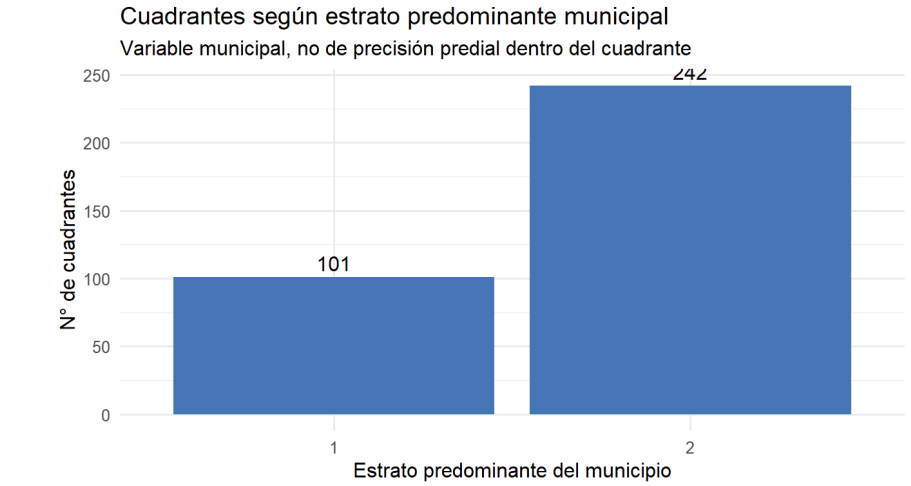


Figura 5.5: Distribución de cuadrantes por estrato predominante municipal.

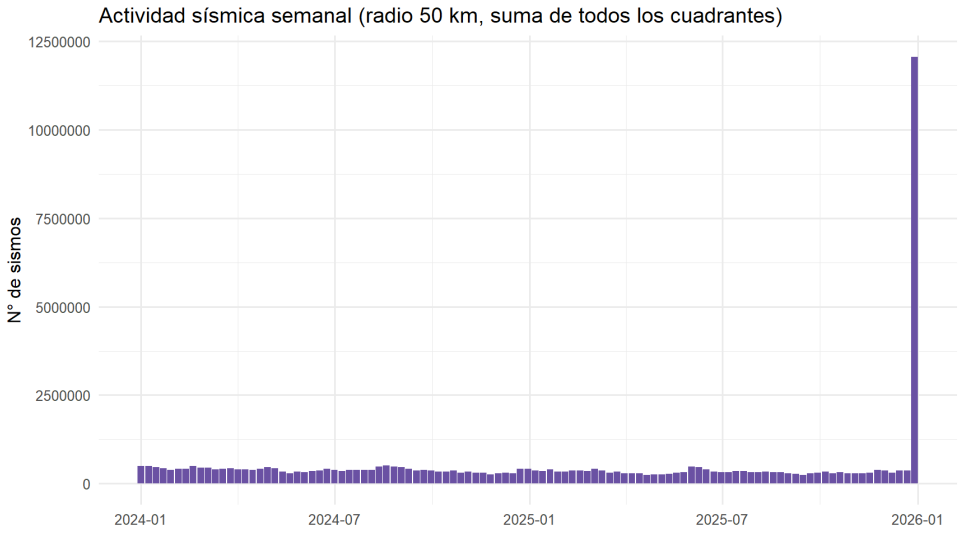


Figura 5.6: Serie temporal de sismos considerados en la exposición territorial del panel.

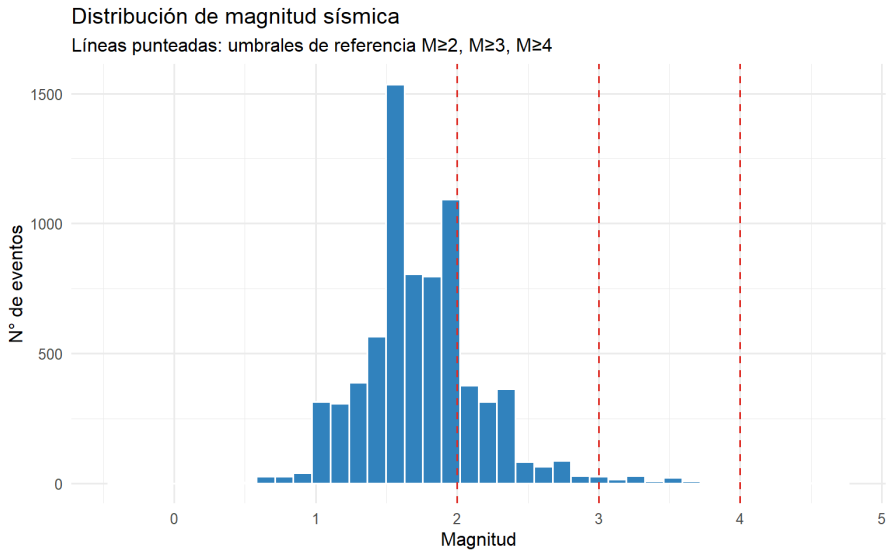


Figura 5.7: Histograma de magnitudes de sismos integrados al panel cuadrante–semana.

tancias se dividía entre 1 000 sin perder su unidad de metros, de modo que al compararla con un radio expresado en kilómetros el radio se convertía a metros y la condición resultaba siempre verdadera. En consecuencia, `n_sismos_r25`, `n_sismos_r50` y `n_sismos_r100` contenían el total regional de la semana, idéntico para los 344 cuadrantes (media de 1 366 sismos). El segundo era de asignación temporal: la función que asigna cada sismo a su semana no tenía cota superior, por lo que todos los sismos de 2026 incluidos en la extracción se acumulaban en la última semana del panel (35 042 sismos frente a un máximo de 1 486 en las semanas anteriores). Tras la corrección, el número de sismos a menos de 50 km del centroide tiene una media de 10 por cuadrante–semana, un percentil 99 de 46 y varía entre cuadrantes, como corresponde a una medida de exposición local; `dist_sismo_min_km` se define como la distancia al epicentro más cercano de la semana, con independencia del radio. El panel corregido se materializa en `data_final_modelo_cuadrantes_reales_sismos_corr.rds` y es el que se usa en todos los resultados de la Etapa 5.
Detalle: Apéndice A.3.20.

Topología de red eléctrica

Sobre tramos y nodos de la red se construyen métricas por cuadrante (longitud de red, densidad de nodos terminales, circuitos) y una matriz de vecindad eléctrica/espacial para rezagos entre vecinos (`Etapa2_08`). La Figura 5.8 describe la heterogeneidad de longitud de red; la Figura 5.9 relaciona preliminarmente longitud de red y $SAIDI$.
Detalle: Apéndice A.3.21.

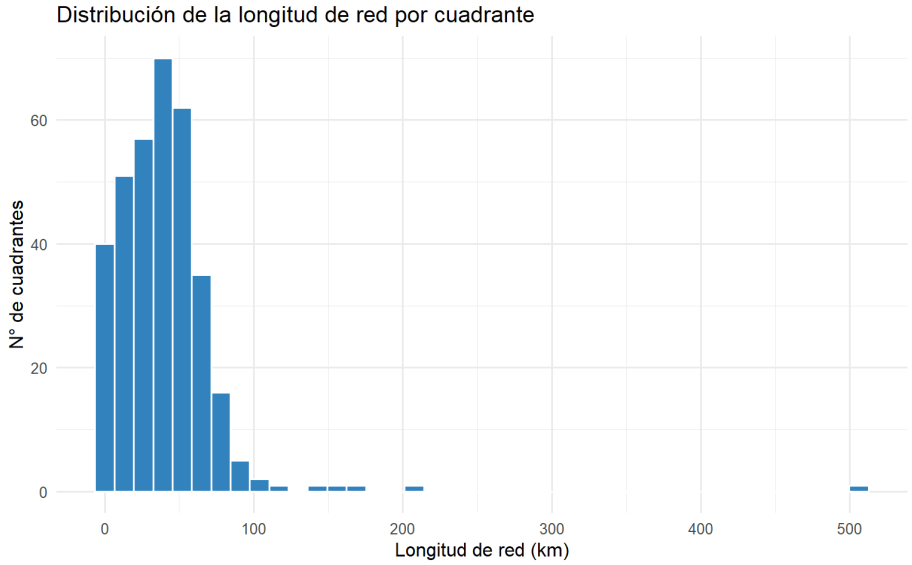


Figura 5.8: Distribución de la longitud de red eléctrica por cuadrante.

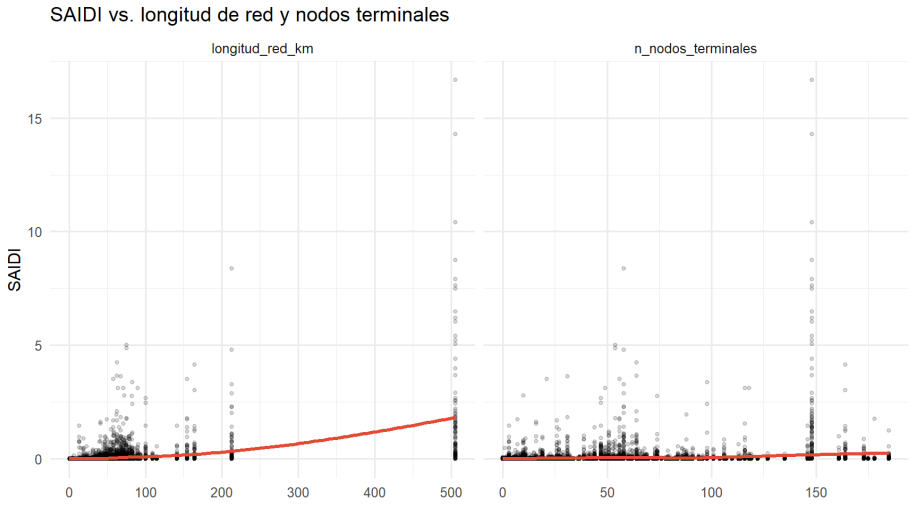


Figura 5.9: Relación exploratoria entre longitud de red y $SAIDI$ por cuadrante.

Integración del panel enriquecido y series SAIDI/SAIFI

Los bloques anteriores se unen al panel base por `id_cuadrante` y `semana` (`Etapa2_09`–`Etapa2_12`): clima NASA semanal, eventos de continuidad, NDVI y atributos estáticos. El artefacto resultante `data_final_modelo_cuadrantes_reales.rds` es el insumo de las Etapas 4 y 5. La Figura 5.10 muestra la coevolución temporal de $SAIDI$ y $SAIFI$; la Figura 5.11 ilustra la relación exploratoria NDVI–$SAIDI$.

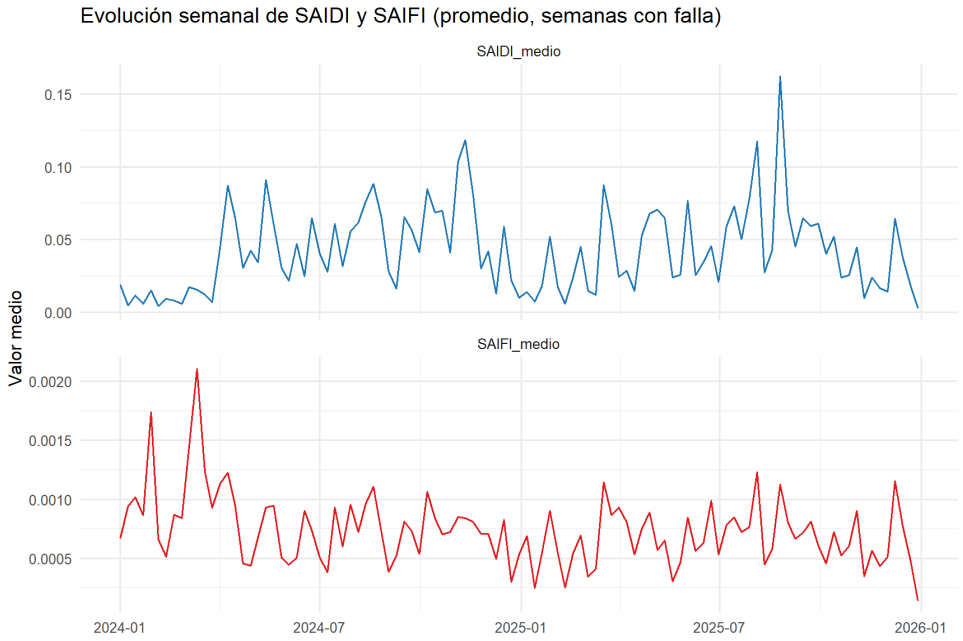


Figura 5.10: Series temporales de $SAIDI$ y $SAIFI$ en el panel enriquecido cuadrante–semana.

Detalle reproducible: Apéndices A.3.22–A.3.25.

5.2.8. Evidencia de calidad y confiabilidad de las fuentes

La validación de los datos recopilados por Centrales Eléctricas de Norte de Santander S.A. E.S.P. (CENS) se fundamenta en su arquitectura institucional de gestión, enmarcada en la Política de Gestión de Tecnología de la Información (Sesión de la Junta Directiva No. 800 del 20 de febrero de 2018) CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P. [69] y en la Política del Sistema de Gestión Integrado (Sesión de la Junta Directiva No. 831 del 22 de abril de 2020) [70], orientadas a garantizar una gestión sistemática de calidad continua, sostenibilidad ambiental y cumplimiento legal mediante la evaluación permanente de la calidad de los datos, priorizando consistencia, disponibilidad y accesibilidad de la información.

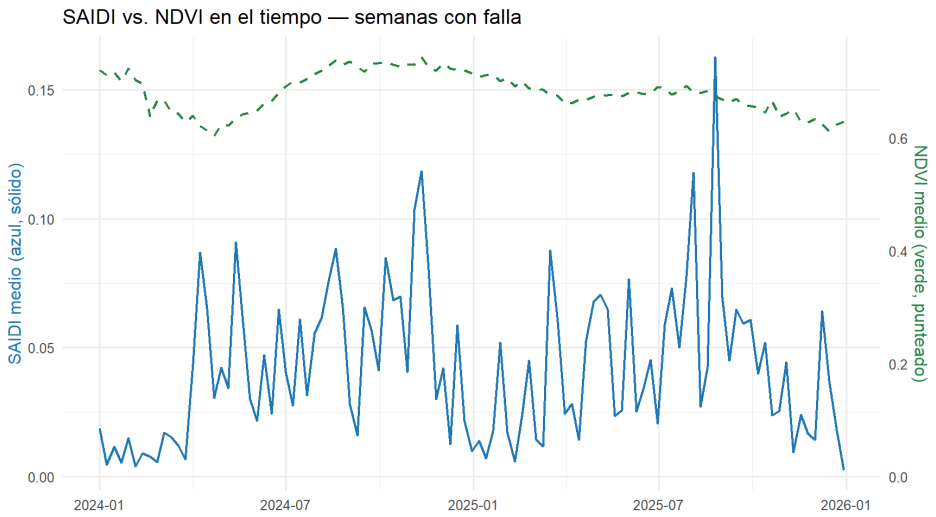


Figura 5.11: Relación exploratoria entre NDVI semanal y $SAIDI$ en el panel enriquecido.

CENS refuerza su gobernanza de datos mediante Instrumentos de Gestión de Información Pública, entre los cuales se destacan el Registro de Activos de Información (IPR), utilizado para detectar, clasificar y almacenar conjuntos de datos institucionales; los Cuadros de Clasificación Documental; el Esquema de Publicación de Información (IPS); el Índice de Información Clasificada y Reservada; los Costos de Reproducción; y el Programa de Gestión Documental (PGD). Estos instrumentos enmarcan el proceso institucional de almacenamiento, organización, acceso, difusión, protección y preservación de la información [71].

En conjunto, estos mecanismos constituyen el marco institucional de control interno y gobernanza de la información del operador. Este marco es una condición necesaria, pero no suficiente, para la calidad analítica de los datos: el propio diagnóstico de cobertura de la Sección 6.3.5 muestra que un campo completo en el 100 % de los registros puede, sin embargo, no ser utilizable para el análisis territorial. Por ello, la calidad efectiva de cada fuente para los fines de este estudio se verificó empíricamente mediante las métricas de integridad del catálogo de datos (Apéndice A.4) y el diagnóstico de emparejamiento evento–elemento.

La fiabilidad técnica de las variables climáticas se sustenta en NASA POWER, plataforma del Langley Research Center de la NASA de la cual provienen las series meteorológicas integradas al panel (Sección 5.1). Esta fuente fue seleccionada por ofrecer cobertura diaria completa y homogénea sobre la totalidad del área de servicio durante el periodo de estudio, sin los vacíos ni las discontinuidades propias de una red de estaciones terrestres.

Los parámetros utilizados se derivan del reanálisis MERRA-2 del programa Earth Science de la NASA y se distribuyen mediante una API pública, docu-

mentada y versionada, con definiciones y unidades explícitas para cada variable. Estas características garantizan trazabilidad, reproducibilidad y consistencia metodológica en la captura de las series climáticas, de modo que la extracción documentada en la Etapa 1 puede replicarse de forma íntegra [67].

5.3. Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA)

Una vez completadas las etapas de extracción e integración (Etapas 1 y 2), se desarrolla un análisis exploratorio orientado a caracterizar las distribuciones de las variables, diagnosticar la calidad del panel (valores faltantes y extremos), identificar patrones temporales y espaciales, y evaluar las relaciones entre covariables que podrían explicar la variación de $SAIDI$ y $SAIFI$. Esta etapa se concibe como un análisis diagnóstico previo al modelamiento, orientado a garantizar la estabilidad e interpretabilidad de los resultados y a fundamentar las decisiones de imputación y transformación de la Etapa 4.

Para las variables cuantitativas se calculan medidas de tendencia central y de dispersión, incluida la desviación estándar y el coeficiente de variación (CV; Sección 3.1.2), así como la proporción de valores atípicos; adicionalmente se construyen histogramas y diagramas de caja para examinar la forma de las distribuciones. En el caso de las variables categóricas, se analizan las frecuencias absolutas y relativas de cada categoría. El grado de asociación se evalúa con el coeficiente de Spearman Spearman [17] (cuantitativas) y el estadístico V de Cramér Cramér [18] (cualitativas), según se formalizan en la Sección 3.1.2, con el fin de identificar redundancias y relaciones preliminares que orienten la depuración de variables en la Etapa 4. Las visualizaciones incluyen series de tiempo, gráficos de dispersión, mapas temáticos y mapas de calor de correlaciones.

Los procedimientos de esta etapa son, en su orden: diagnóstico de datos faltantes, identificación de valores extremos, cálculo de estadísticos descriptivos, análisis de la distribución de las variables, análisis temporal de los eventos (que delimitó el conjunto de modelado D_{mod}), identificación de patrones y visualización exploratoria, análisis de correlación y asociación, evaluación multivariada (VIF, PCA, agrupamiento jerárquico y GLM de diagnóstico) y segmentación exploratoria. Sus fundamentos formales se presentan en la Sección 3.1.2; la descripción detallada de cada procedimiento y sus hallazgos, con las tablas y figuras correspondientes, se presenta en la Sección 6.3, conforme a la organización del documento en la que el preprocesamiento y el análisis descriptivo forman parte de los resultados.

5.4. Etapa 4 – Ingeniería de variables y preparación del modelo

A partir de los hallazgos del EDA y de la taxonomía de la Sección 3.1.2, en esta etapa se transforma el dataset consolidado en una representación analítica adecuada para el entrenamiento de modelos. El criterio rector es evitar *fuga de información*: solo entran como predictoras variables disponibles *antes* de la semana t a pronosticar. Las actividades incluyen la definición formal de la variable respuesta, la construcción de predictoras informadas por el EDA (clima rezagado o pronosticado, histórico de eventos, rasgos del cuadrante, estacionalidad), la depuración y codificación de covariables, la estandarización de variables continuas y la partición temporal entrenamiento/prueba. `usuarios_afectados` y `elementos_afectados` se tratan como *impacto posterior*: el primero entra en el numerador de $SAIFI$ y $SAIDI$, pero ninguno se habilita como predictora contemporánea. El preprocesamiento, incluida la selección de variables con base en el EDA, se concentra aquí, en coherencia con estabilidad numérica, identificabilidad y validez operativa del pronóstico.

Partición formal del conjunto de columnas. Conviene precisar qué significa, en este trabajo, "preparar los datos para modelar". El panel enriquecido `data_final_modelo_cuadrantes_reales.rds` contiene decenas de columnas que no son intercambiables entre sí: unas identifican la observación, otras son el objeto del pronóstico, otras son legítimamente utilizables como información previa y otras solo se conocen *después* de que el fenómeno ocurrió. Preparar el panel equivale, entonces, a inducir sobre el conjunto de columnas $\mathcal{C}$ una partición en cuatro clases disjuntas:

$$\mathcal{C} = \mathcal{K} \sqcup \mathcal{Y} \sqcup \mathcal{X} \sqcup \mathcal{P}, \tag{5.1}$$

donde:

- $\mathcal{C}$: Conjunto de columnas del panel enriquecido.
- $\mathcal{K}$: Llaves (`id_cuadrante`, `semana`, `latitud` y `longitud`). Identifican la fila y, en las especificaciones de efectos fijos, se consumen como índice de absorción y no como covariables.
- $\mathcal{Y}$: Respuestas (SAIDI y SAIFI), es decir, lo que se quiere pronosticar.
- $\mathcal{X}$: Predictoras *ex ante*, covariables cuyo valor está determinado antes del inicio de la semana s.
- $\mathcal{P}$: Impacto posterior, magnitudes que solo existen una vez ocurrido o cerrado el evento.

- $\sqcup$: Unión disjunta.

La partición no es una formalidad de notación: define el perímetro de validez del ejercicio predictivo. Si una columna de $\mathcal{P}$ migrara a $\mathcal{X}$, el modelo exhibiría un ajuste excelente y carecería de utilidad operativa, porque en el momento de pronosticar la semana s el operador no dispone todavía de esa información. El caso crítico es `usuarios_afectados`: pertenece simultáneamente al numerador de ambas respuestas (ecuación (5.2)) y al conjunto de severidad observada *ex post*; incluirla como regresor equivaldría a regresar Y contra una transformación de sí misma. El mismo razonamiento excluye `elementos_afectados`, y excluye los valores contemporáneos de `n_eventos` y `duracion_total`, que sí se admiten en su versión rezagada. Esta disciplina es la que explica por qué el desempeño predictivo reportado en el Capítulo 6 es moderado y no artificialmente alto: el modelo opera bajo la misma restricción de información que enfrentaría el operador en producción.

La construcción de rasgos preliminares y la exploración de relaciones clima–indicador que anteceden a esta formalización se documentan en el Apéndice A.3.26 (informe HTML); la evidencia empírica que sustenta la especificación dinámica con rezagos, en el Apéndice A.3.27 (informe HTML). Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.4.1. Construcción de variables predictoras

Se construyen únicamente variables del grupo *disponibles antes del periodo a pronosticar*, es decir, el conjunto $\mathcal{X}$ de la ecuación (5.1). Su composición responde a cinco bloques, cada uno con una justificación distinta:

1. *Clima rezagado o pronosticado.* Se admite clima de las semanas $t-1, \ldots, t-h$ y, cuando exista, clima pronosticado para t con fecha de emisión anterior al inicio de la semana. La distinción importa porque el EDA mostró una asociación bivariada contemporánea débil (Sección 6.3.7): el bloque climático no se conserva por su poder explicativo inmediato, sino porque la literatura y la operación atribuyen a la lluvia y al viento un efecto diferido sobre la vegetación y sobre el esfuerzo mecánico de la red, efecto que solo es capturable mediante rezagos y acumulados (`precip_ma4`, `viento_ma4`).

2. *Histórico de eventos del cuadrante.* Conteos y duraciones rezagadas, además del rezago de la propia respuesta (`SAIDI_lag1`, `SAIDI_lag4`, `SAIFI_lag1`, `SAIFI_lag4`). La inclusión no es opcional: la autocorrelación de la serie semanal alcanza 0.80 en el primer rezago en D_{mod} (Sección 6.3.6); el valor de 0.92 observado en D_{EDA} no se usa como referencia porque está inflado

por el cambio de nivel de la serie en 2024, de modo que omitir el rezago propio dejaría en el error una componente sistemática y predecible.

3. *Características estructurales del cuadrante*, enriquecidas en la Sección 5.2.7: infraestructura (`n_elementos`, `n_tipos_infraestructura`, `prop_transformadores`), topología (`longitud_red_km`, `n_circuitos_cuadrante`, `n_nodos_terminales`, `densidad_terminales`), composición socioeconómica (`prop_estrato_1` a `prop_estrato_6`, `prop_no_residencial`, `estrato_modal_real`) y trayectoria de los activos (`edad_activo_mas_viejo_anios`, `edad_activo_mas_nuevo_anios`, `rango_edad_activos_anios`, `PROM_CANT_MODIFICACIONES`). Son variables cuasi-estáticas: su valor no depende de lo ocurrido en la semana s, por lo que su disponibilidad *ex ante* es trivialmente satisfecha. Su procedencia se documenta en los Apéndices A.3.18 (informe HTML), A.3.19 (informe HTML) y A.3.21 (informe HTML).

4. *Exposición externa al sistema eléctrico:* vegetación (`ndvi_semanal`, `log_ndvi`) y sismicidad SGC (`n_sismos_r50`, `n_sismos_m3_r50`, `magnitud_max_r50`, `dist_sismo_min_km_r50`). Estas fuentes son exógenas al operador, lo que las hace especialmente valiosas: no pueden estar contaminadas por decisiones de registro internas ni por el propio proceso de atención de la falla. Su integración se documenta en el Apéndice A.3.20 (informe HTML).

5. *Estacionalidad y calendario:* mes, semana del año, términos armónicos e indicadores de régimen lluvioso/seco, que absorben la heterogeneidad intra-anual detectada en la Sección 6.3.6.

Adicionalmente se construyen dos rasgos de interacción, `ndvi_x_elementos` y `sismo_x_elementos`, bajo la hipótesis de que la exposición ambiental no actúa de forma uniforme sino proporcional a la cantidad de infraestructura expuesta: un cuadrante con vegetación densa pero pocos activos no tiene el mismo riesgo que uno igualmente vegetado con alta densidad de red.

Quedan *excluidas* como predictoras contemporáneas $\texttt{usuarios_afectados}_t$, $\texttt{elementos_afectados}_t$, $\texttt{n_eventos}_t$ y $\texttt{duracion_total}_t$ al pronosticar SAIFI_t o SAIDI_t. También se excluye la respuesta cruzada contemporánea: al modelar SAIDI_t no se emplea SAIFI_t y viceversa, puesto que ambas comparten el factor $\texttt{usuarios_afectados}_t$ en su numerador y su inclusión recíproca reintroduciría por la puerta trasera la fuga que la partición busca cerrar.

5.4.2. Construcción de la variable respuesta

Las respuestas son $Y_t = \text{SAIFI}_t$ y $Y'_t = \text{SAIDI}_t$, calculadas en cada fila cuadrante $\times$ semana como

$$\begin{aligned} \text{SAIFI}_{q,s} &= \frac{\texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \\ \text{SAIDI}_{q,s} &= \frac{\texttt{duracion_total}_{q,s} \times \texttt{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \end{aligned} \tag{5.2}$$

donde:

- $\text{SAIFI}_{q,s}$, $\text{SAIDI}_{q,s}$: Indicadores operativos de frecuencia y de duración del cuadrante q en la semana s.
- $\texttt{usuarios_afectados}_{q,s}$: Usuarios afectados por los eventos del cuadrante q en la semana s.
- $\texttt{duracion_total}_{q,s}$: Duración total de los eventos del cuadrante q en la semana s.
- $UT_{m(s)}$: Usuarios totales del sistema en el mes calendario de la fecha de inicio de la semana s (`CS1_UT_M` en `data_usuarios_totales_sistema.csv`).

Tres decisiones merecen justificación explícita. La primera concierne al alcance de los indicadores y a su denominador. Los indicadores regulatorios definidos en las ecuaciones (3.1) y (3.2) se calculan sobre la totalidad del SDL, con agregación mensual y cierre anual, y su cálculo oficial ya lo realiza el operador a partir de sus sistemas de reporte. Este trabajo no pretende replicar ese cálculo: el problema planteado en el Capítulo 1 es que el indicador agregado no revela *dónde* ni *cuándo* se concentra la afectación, que es la información necesaria para orientar la operación y el mantenimiento hacia la reducción de los índices anuales y de las compensaciones asociadas. Por esa razón, $\text{SAIDI}_{q,s}$ y $\text{SAIFI}_{q,s}$, definidos de forma idéntica en el planteamiento del problema, se interpretan como *indicadores operativos de afectación* del cuadrante q en la semana s y no como el indicador regulatorio desagregado.

La elección del denominador $UT_{m(s)}$, común a todos los cuadrantes, es deliberada y coherente con ese propósito. Con un denominador único, el valor de cada cuadrante–semana queda referido a la base de usuarios de la empresa y ordena las zonas según su peso en la afectación total percibida por los usuarios del operador. En consecuencia, un cuadrante con muchos usuarios y frecuentes interrupciones pesa más que uno pequeño con el mismo número de eventos, que es exactamente el ordenamiento que interesa para priorizar intervenciones

cuyo objetivo es reducir el índice global. Un denominador local, basado en los usuarios del cuadrante, respondería a una pregunta distinta —qué tan deficiente es la calidad percibida por el usuario típico de cada zona— y no permitiría ordenar las zonas según su impacto sobre la meta regulatoria.

Dos diferencias respecto del cálculo regulatorio deben quedar explícitas para evitar una lectura equivocada. Primera, el numerador de $\mathrm{SAIDI}_{q,s}$ combina la duración acumulada y los usuarios afectados de la semana, mientras que la regulación pondera cada evento por sus propios usuarios ($\sum_i D_i\, NU_i$); ambas expresiones coinciden exactamente en las semanas con un único evento ($46.3\,\%$ de las semanas con falla) y, en las demás, la forma agregada sobrestima el nivel. El Apéndice A.5 muestra que el ordenamiento de cuadrantes se conserva (correlación de Spearman de 0.87 y coincidencia del $65\,\%$ en los veinte cuadrantes más críticos), por lo que $\mathrm{SAIDI}_{q,s}$ se interpreta como un índice de severidad relativa y no como una fracción sumable del SAIDI de la empresa. Segunda, la cobertura del emparejamiento evento–elemento en 2024 y 2025 ($77.7\,\%$ y $92.4\,\%$; Tabla 6.9) implica que la suma de los indicadores por cuadrante no reproduce el valor oficial del operador; por ello los resultados se emplean para *ordenar y anticipar* la afectación territorial y no para estimar el indicador regulatorio.

En cambio, los indicadores operativos sí comparten con el cálculo regulatorio el universo de eventos. El numerador se construye solo con los eventos que la propia empresa registra como computables para la calidad del servicio: la extracción de BRAE conserva los registros con `FDD_EXCLUSION` $=$ `NO EXCLUIDA`, descarta la causa `FDD_CAUSA_SSPD` $= 1$ y exige fecha de reconexión (Sección 5.1.3). De este modo quedan fuera, con el mismo criterio con que el operador reporta sus indicadores, los eventos que la Resolución CREG 015 de 2018 [1] exime del cálculo, como las interrupciones de hasta tres minutos, las originadas en activos del STN o del STR, los racionamientos programados, las catástrofes naturales y los actos de terrorismo (Sección 3.1). La verificación sobre los $39\,272$ eventos de 2024–2025 confirma que ninguno dura menos de tres minutos; 161 eventos ($0.41\,\%$) duran exactamente tres minutos, valor que no puede discriminarse mejor porque los registros tienen resolución de minuto, y cuyo peso es demasiado pequeño para alterar los resultados. Esta coherencia con las exclusiones regulatorias es la que permite interpretar la afectación modelada como la que efectivamente cuenta para las metas y compensaciones del operador.

La segunda es la asignación mensual del denominador a la semana. La serie de usuarios totales se reporta con periodicidad mensual, mientras que el panel opera en semanas; la regla adoptada asigna a cada semana el UT del mes calendario de su fecha de inicio. El efecto de esta aproximación es pequeño en la práctica, porque UT varía lentamente (crecimiento vegetativo de la base de clientes) frente

a la variabilidad semanal del numerador, pero debe quedar documentada como una fuente menor de imprecisión en las semanas que cruzan el cambio de mes.

La tercera es la decisión de *modelar ambos indicadores por separado* en lugar de imponerles una especificación única. SAIDI y SAIFI comparten el factor `usuarios_afectados` pero difieren en que el primero lo pondera por la duración acumulada: SAIFI mide cuántos usuarios se vieron interrumpidos y SAIDI cuánto tiempo lo estuvieron. Operativamente responden a palancas distintas —la frecuencia depende de la exposición y del estado del activo, la duración depende además de la capacidad de respuesta y de la accesibilidad del punto de falla—, y sus distribuciones difieren en varios órdenes de magnitud, lo que haría que un modelo conjunto quedara dominado por la escala de uno de los dos. Los resultados de la Etapa 5 confirman esta decisión: el mejor modelo de pronóstico no coincide entre indicadores (Sección 6.5).

Finalmente, `n_eventos` y `duracion_total` no se modelan como Y: permanecen como insumos de construcción y como historial rezagado. `elementos_afectados` no entra en Y ni como predictora contemporánea, y queda restringido a la descripción de severidad del EDA.

5.4.3. Análisis de asociación y depuración de variables cuantitativas

Se define el conjunto candidato *ex ante* sobre D_{mod} (clima rezagado, histórico de eventos, rasgos del cuadrante, exposición y estacionalidad) y se excluyen, por diseño, el clima contemporáneo, la respuesta alterna contemporánea y el impacto posterior (`usuarios_afectados`, `elementos_afectados`). La depuración se estima solo con el entrenamiento (2024) y combina filtros de cobertura, varianza casi nula, asociación de Spearman con corrección FDR, agrupamiento por redundancia ($|\rho| \geq 0.70$) y eliminación iterativa por VIF (umbral 5). No se borran variables del panel: se depuran de la matriz de diseño.

De 27 candidatas se retienen 13 (Figuras 5.12–5.14): precipitación rezagada y acumulada, humedad rezagada, viento máximo rezagado, rezagos de `n_eventos`, estacionalidad armónica, altitud, longitud y $\log(\texttt{n_activos} + 1)$ como *offset*. Las temperaturas y los promedios móviles del histórico se descartan por redundancia o multicolinealidad. Detalle reproducible en el Apéndice A.3.16 (informe HTML).

El orden de los filtros no es arbitrario y conviene explicitarlo, porque condiciona el resultado. Primero operan los criterios que no dependen de la respuesta —cobertura y varianza casi nula—, de modo que ninguna variable se descarta por su relación con Y antes de haber superado el umbral mínimo de informatividad propia. Después se evalúa la asociación con la respuesta mediante Spearman, deliberadamente en su versión por rangos y no de Pearson, dada la

asimetría y la cero-inflación documentadas en la Sección 6.3.4, y con corrección FDR porque el número de contrastes simultáneos hace esperable una proporción no despreciable de significancias espurias. Por último se aplica el tratamiento de redundancia: el agrupamiento por $|\rho| \geq 0.70$ identifica bloques de variables que miden esencialmente lo mismo y de cada bloque se conserva un representante, y la eliminación iterativa por VIF (umbral 5) remueve la colinealidad que solo aparece en combinaciones de tres o más variables y que el análisis bivariado no detecta.

Dos salvaguardas acompañan el procedimiento. La primera es que *todos* los estadísticos de depuración se calculan exclusivamente sobre el conjunto de entrenamiento. Estimarlos sobre el panel completo constituiría una forma sutil de fuga de información, porque la decisión de qué variables conservar habría sido tomada mirando datos del periodo de prueba. La segunda es que la depuración no borra columnas del panel: solo determina qué entra en la matriz de diseño. El panel enriquecido conserva las 27 candidatas, de modo que una especificación alternativa puede reconstruirse sin reejecutar la cadena de integración de las Etapas 1 y 2.

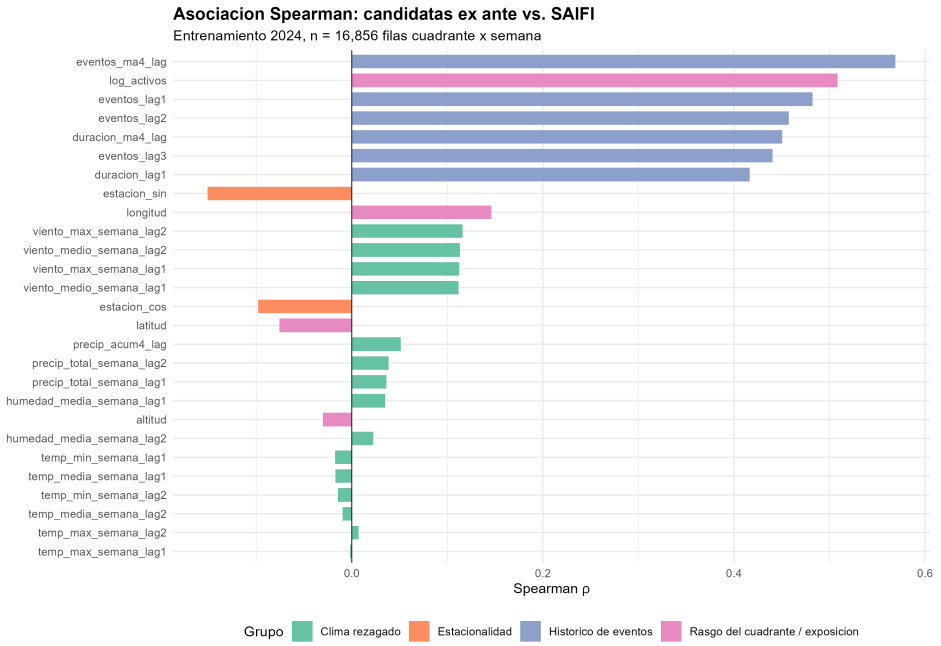


Figura 5.12: Asociación de Spearman entre candidatas *ex ante* y $SAIFI$ (entrenamiento 2024).

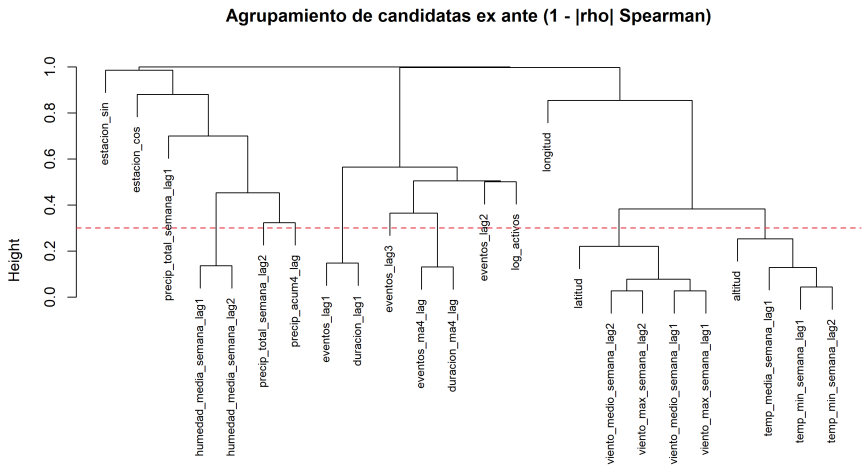


Figura 5.13: Agrupamiento jerárquico de candidatas ($1-|\rho|$ Spearman); la línea punteada marca el umbral $|\rho| = 0.70$.

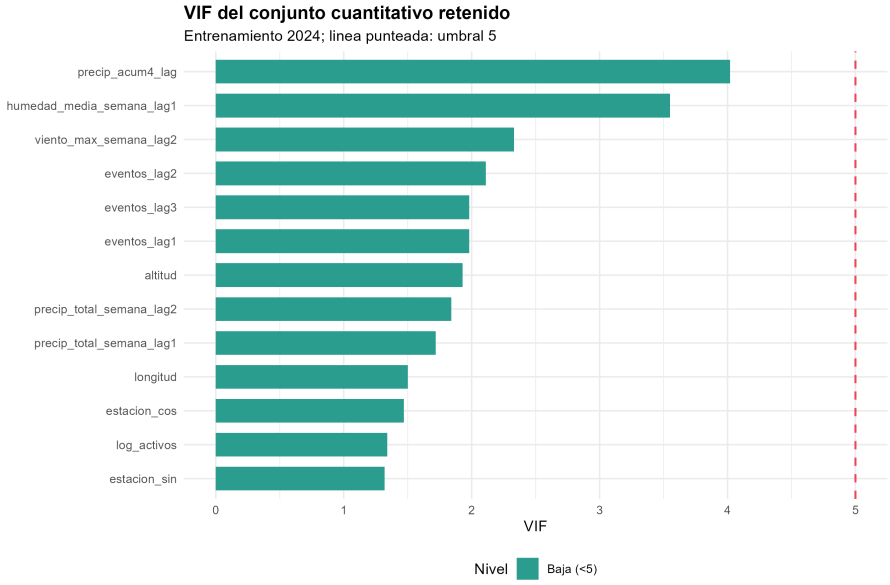


Figura 5.14: VIF del conjunto cuantitativo retenido tras la depuración iterativa (umbral 5).

5.4.4. Análisis de asociación y depuración de variables cualitativas

Las cualitativas candidatas (`estrato_predominante_municipal`, tipología de zona, indicadores de régimen lluvioso/seco y *flags* de exposición como `cat_ndvi`) se depuran por cobertura de categorías y por asociación con $SAIFI/SAIDI$ en el entrenamiento, siguiendo la misma lógica de la Sección 5.4.3 pero con instrumentos adecuados al nivel de medición.

El criterio de cobertura atiende un problema específico de las variables nominales en paneles territoriales: una categoría presente en un número reducido de cuadrantes produce coeficientes estimados sobre muy pocas observaciones efectivas, con errores estándar grandes y alta sensibilidad a la partición temporal. Cuando además esos cuadrantes se concentran en una franja del horizonte, la categoría puede quedar representada en el entrenamiento y ausente en la prueba, lo que impide generar predicción. Por ello las categorías con frecuencia marginal se colapsan en un nivel agregado antes de cualquier contraste, y no después.

La asociación con la respuesta se evalúa mediante el estadístico V de Cramér entre pares de cualitativas y mediante contrastes de diferencia de distribución de $SAIFI/SAIDI$ entre niveles, conforme se formaliza en la Sección 3.1.2. La elección de V de Cramér sobre el χ^2 crudo responde a que el primero normaliza por el tamaño muestral y por el número de categorías, lo que permite comparar la fuerza de asociación entre variables con distinto número de niveles; con $N_{\text{mod}} = 36\,120$ observaciones, prácticamente cualquier asociación resulta estadísticamente significativa y el valor p deja de ser un criterio discriminante útil.

Un resultado relevante de esta depuración es que buena parte del contenido de las cualitativas territoriales ya está representado de forma continua en el panel. El estrato predominante municipal, por ejemplo, resume en una etiqueta única la misma información que las proporciones `prop_estrato_1` a `prop_estrato_6` expresan con mayor resolución; conservar ambas introduce redundancia sin ganancia informativa. Por esa razón la matriz de diseño final privilegia las proporciones y deja la etiqueta modal (`estrato_modal_real`) como variable de apoyo interpretativo. Las variables sin contraste útil se excluyen de la matriz de diseño sin borrarlas del panel. El procedimiento reproducible se documenta en el Apéndice A.3.16 (informe HTML), y la construcción de las variables de estratificación en el Apéndice A.3.19 (informe HTML).

5.4.5. Codificación de variables categóricas

Las categóricas retenidas se codifican como *dummy* de referencia (contrastes tratamiento) o, cuando el orden es informativo, como factor ordinal. La distinción

tiene consecuencias interpretativas directas: bajo contrastes tratamiento cada coeficiente mide la diferencia respecto de una categoría base explícita, mientras que un factor ordinal impone una progresión monótona entre niveles. El estrato admite esta segunda lectura porque su escala es efectivamente ordenada en términos socioeconómicos y de densidad de demanda; la tipología de zona no, porque sus niveles no guardan relación de orden.

La codificación se ajusta además a la especificación empleada. En las estimaciones con efectos fijos de cuadrante, cualquier atributo invariante en el tiempo dentro del cuadrante queda absorbido por el efecto fijo y su *dummy* resulta no identificable; incluirla produciría colinealidad perfecta con el conjunto de indicadores de cuadrante. Por ello las cualitativas estáticas se conservan en las especificaciones *Pooled* OLS y en el corte transversal SAR/SEM, donde sí aportan variación explotable, y se omiten de las especificaciones FE. Esta no es una pérdida de información sino un reconocimiento de qué pregunta responde cada modelo: el FE estima el efecto de lo que cambia *dentro* de un cuadrante a lo largo del tiempo, no el de lo que distingue a un cuadrante de otro.

Ninguna codificación se deriva de información posterior al corte de prueba: los niveles, las categorías base y las reglas de colapsamiento se fijan sobre el entrenamiento y se aplican sin modificación al conjunto de prueba, incluso si en este aparece una categoría no observada previamente, caso en el que la observación se asigna al nivel agregado. En el panel de modelado espacial, las proporciones de estrato (`prop_estrato_*`, `prop_no_residencial`) entran ya como proporciones numéricas en $[0, 1]$ y no requieren *dummy* adicional.

5.4.6. Estandarización de variables cuantitativas

Las cuantitativas continuas se estandarizan (z-score) solo cuando el algoritmo lo exige. El criterio es que la estandarización es necesaria cuando el procedimiento de estimación depende de la escala —métodos regularizados, en los que la penalización castiga desproporcionadamente a las variables de magnitud pequeña, y métodos basados en distancias, en los que una variable medida en milímetros de lluvia dominaría mecánicamente a otra medida en proporciones— e innecesaria cuando no lo es. En OLS y en los efectos fijos de `fixest` las estimaciones son equivariantes ante cambios de escala, de modo que estandarizar no altera el ajuste y sí dificulta la lectura: un coeficiente en escala original expresa el cambio en la respuesta por milímetro adicional de precipitación o por año adicional de antigüedad del activo, magnitudes que el operador puede interpretar directamente. Random Forest, por su parte, es invariante ante transformaciones monótonas de los predictores, por lo que la estandarización es irrelevante para su ajuste.

Cuando sí se estandariza, los parámetros de centrado y escala ($\bar{x}$ y s_x) se estiman únicamente sobre el entrenamiento y se aplican al conjunto de prueba sin recalcular, por la misma razón que rige la depuración: recalcularlos sobre el panel completo filtraría información del periodo de prueba hacia el preprocesamiento.

Las respuestas reciben un tratamiento distinto al de los predictores. $SAIDI$ y $SAIFI$ se transforman con $\log(1+y)$ ante asimetría y presencia de ceros, según `Etapa5_01/Etapa5_02` (Apéndices A.3.28 y A.3.29). La elección de $\log(1+y)$ y no de $\log(y)$ es forzada por la masa de ceros estructurales del panel: en el $74.9\,\%$ de las semanas-cuadrante no se registra ningún evento (Sección 6.3.4) y el logaritmo simple no está definido en ese punto. El desplazamiento unitario preserva el cero como cero y aproxima el comportamiento logarítmico en la cola derecha, que es precisamente donde la asimetría compromete la estabilidad de la estimación.

5.4.7. Generación de ventanas temporales

Por cuadrante se construyen rezagos $t-1,\ldots,t-h$ de clima y de la respuesta, medias móviles (precipitación y viento a cuatro semanas, `precip_ma4` y `viento_ma4`) e indicadores de calendario (mes, trimestre, términos armónicos). La construcción se realiza *dentro* de cada cuadrante, previo ordenamiento por semana, de modo que ningún rezago arrastre valores de un cuadrante vecino ni cruce la frontera entre series territoriales distintas.

La justificación empírica es directa. El análisis exploratorio (Sección 6.3.5) estableció una autocorrelación de 0.80 en el primer rezago sobre D_{mod} (el 0.92 de D_{EDA} está inflado por el cambio de nivel de 2024), con decaimiento lento (0.60 a doce semanas, 0.38 a veintiséis) y un repunte a 0.43 en el rezago de cincuenta y dos semanas. Estos tres hechos determinan tres decisiones de diseño distintas: la persistencia de corto plazo motiva incluir al menos el primer rezago de la respuesta como predictora *ex ante*; el decaimiento lento, sin corte abrupto, desaconseja fijar un orden de rezago elevado, puesto que rezagos sucesivos aportan información cada vez más redundante y encarecen la estimación con un costo creciente en grados de libertad; y el repunte anual justifica la inclusión de términos estacionales explícitos en lugar de intentar capturar la estacionalidad mediante un rezago de orden 52, que consumiría un año completo de datos en una ventana de modelado de apenas dos años.

El costo de esta construcción es la pérdida de las primeras observaciones de cada serie, para las que el rezago no está definido. Con h fijado en valores bajos y medias móviles de cuatro semanas, la pérdida se concentra en las primeras semanas de D_{mod} y resulta marginal frente a las 105 semanas disponibles. La evidencia que respalda la selección concreta de rezagos se documenta en el

Apéndice A.3.27 (informe HTML).

5.4.8. Partición de datos en entrenamiento y prueba

Con fundamento en el diagnóstico de cobertura del emparejamiento evento–elemento (Sección 6.3.5), el universo de estimación se restringe a D_{mod}: observaciones cuadrante $\times$ semana con `year(semana)` $\in \{2024, 2025\}$, periodo en el que la coincidencia entre `COMPONENTE_FALLADO` y el inventario GIS (`tipo_elemento.csv`) alcanza al menos el $79.8\,\%$, frente a $\approx 31\,\%$ en 2021–2023 bajo OMS-SPARD. Los años 2021–2023 no se incluyen ni en entrenamiento ni en prueba, dado el sesgo por incompatibilidad entre código de activo y código de sitio: entrenar con ese tramo introduciría un subregistro sistemático y no aleatorio de eventos, que el modelo aprendería como si fuera una propiedad del territorio.

La partición es *estrictamente temporal* y nunca aleatoria. La razón es que el muestreo aleatorio sobre un panel autocorrelacionado produce una estimación optimista del desempeño: con una ACF de 0.80 en el primer rezago, una observación asignada al conjunto de prueba tiene vecinas temporales inmediatas en el conjunto de entrenamiento, de modo que el modelo dispone de información casi equivalente a la que debe predecir. El corte cronológico reproduce, en cambio, la situación real de uso, en la que el modelo se entrena con el pasado y se evalúa sobre un futuro que no ha observado.

El corte es proporcional: se ordenan las semanas del panel y se reserva el $15\,\%$ final como *holdout*. La semana de corte es la del 8 de septiembre de 2025, de modo que el entrenamiento comprende las semanas del 1 de enero de 2024 al 8 de septiembre de 2025 y la prueba las 16 semanas comprendidas entre el 15 de septiembre y el 29 de diciembre de 2025. Este esquema maximiza el tamaño del conjunto de entrenamiento en un horizonte ya corto y garantiza que ninguna semana de prueba preceda a una semana de entrenamiento. La depuración de variables de la Sección 5.4.3 se estimó sobre 2024, un subconjunto del entrenamiento, por lo que tampoco utiliza información del periodo de prueba.

Una consecuencia conocida de la partición temporal estricta afecta a la especificación con efectos fijos de cuadrante y semana: como las semanas del conjunto de prueba no aparecen en el entrenamiento, sus efectos fijos temporales no están estimados y el modelo no produce predicción fuera de muestra. Esto no invalida la especificación —sigue siendo informativa para la descomposición de varianza dentro de muestra— pero sí implica que no participa de la comparación predictiva, como se documenta en la Sección 6.5.

5.4.9. Construcción de matrices de diseño

Esta subsección cierra la partición formulada en la ecuación (5.1): fija de manera explícita y verificable qué columnas constituyen el vector de respuesta $\mathbf{y}$ y

cuáles la matriz de predictoras $\mathbf{X}$ con la que se estiman los modelos de la Etapa 5. La especificación semanal que se somete a estimación adopta la forma

$$\begin{aligned}\log\left(1+Y_{q,s}\right) = \mathbf{x}_{q,s}^{\top}\boldsymbol{\beta} + \gamma\log\left(1+Y_{q,s-1}\right) + \phi\,\overline{Y}_{\mathcal{N}(q),\,s-1} \\ + \mu_q + \tau_s + \varepsilon_{q,s},\end{aligned} \tag{5.3}$$

donde:

- $Y_{q,s}$: Respuesta del cuadrante q en la semana s, con $Y \in \{\text{SAIDI}, \text{SAIFI}\}$.
- $\mathbf{x}_{q,s}$: Vector de covariables *ex ante*; $\boldsymbol{\beta}$, su vector de coeficientes.
- γ: Coeficiente del rezago propio de la respuesta.
- $\overline{Y}_{\mathcal{N}(q),\,s-1}$: Promedio de la respuesta en los cuadrantes vecinos de q en la semana anterior.
- ϕ: Coeficiente del rezago espacial; se usa ϕ y no ρ para no confundirlo con el parámetro autorregresivo espacial del modelo SAR.
- μ_q, τ_s: Efectos fijos de cuadrante y de semana, presentes solo en las especificaciones que los declaran.
- $\varepsilon_{q,s}$: Término de error.

La Tabla 5.11 detalla la asignación final de columnas a cada clase. La estructura de $\mathbf{X}$ es prácticamente idéntica para ambos indicadores; la única diferencia es que los términos autorregresivos y el rezago espacial se construyen sobre la respuesta que se está modelando, de modo que al estimar SAIDI entran `SAIDI_lag1` y `SAIDI_vecinos_lag1`, y al estimar SAIFI sus equivalentes. Esta simetría es deliberada: permite atribuir las diferencias de desempeño entre indicadores a la naturaleza del fenómeno y no a una asimetría introducida por el diseño de la matriz.

Tres observaciones precisan la lectura de la tabla. La primera es que `id_cuadrante` y `semana` ocupan una posición intermedia entre llave y predictora: no son covariables sustantivas, pero en las especificaciones FE se consumen como índices de absorción y, en esa función, capturan toda la heterogeneidad no observada invariante en cada dimensión. La segunda es que las coordenadas no entran como regresores sino como insumo de la matriz de contigüidad *queen* que define la vecindad $\mathcal{N}(q)$; su rol es estructural, no explicativo. La tercera es que el bloque $\mathcal{P}$ no se elimina del panel: permanece disponible para el análisis descriptivo de severidad y para la construcción de las respuestas, pero no se expone al estimador como covariable.

El número de predictoras, 18, es deliberadamente moderado frente a las 44 candidatas inicialmente disponibles en el panel enriquecido. Con 343 cuadrantes

Tabla 5.11: Partición final de variables antes de la estimación: respuesta $\mathbf{y}$, predictoras $\mathbf{X}$, llaves y exclusiones

Clase	Bloque	Variables
$\mathbf{y}$ (respuesta)	Continuidad	`SAIDI`, `SAIFI`; estimadas como `log_SAIDI1` $= \log(1 + \text{SAIDI})$ y `log_SAIFI1` $= \log(1 + \text{SAIFI})$, en modelos separados
$\mathbf{X}$ (predictoras)	Clima $(t-1)$	`temp_media_semana`, `viento_max_semana`, `precip_total_semana`, `precip_ma4`
	Vegetación $(t-1)$	`ndvi_semanal`
	Exposición externa $(t-1)$	`n_sismos_r50`, `dist_sismo_min_km_r50`
	Infraestructura y topología	`n_elementos`, `longitud_red_km`, `densidad_terminales`
	Composición socioeconómica	`prop_estrato_1`, `prop_estrato_2`, `prop_no_residencial`
	Activos y mantenimiento	`edad_activo_mas_viejo_anios`, `PROM_CANT_MODIFICACIONES`
	Dinámica temporal y espacial	`SAIDI_lag1` o `SAIFI_lag1`; `SAIDI_vecinos_lag1` o `SAIFI_vecinos_lag1`; `ndvi_vecinos` $(t-1)$
$\mathcal{K}$ (llaves)	Identificación	`id_cuadrante`, `semana` (índices de efectos fijos y de ordenamiento); `latitud`, `longitud`, `altitud` (geolocalización y matriz de vecindad)
$\mathcal{P}$ (excluidas)	Impacto posterior	`usuarios_afectados`$_t$, `elementos_afectados`$_t$
	Insumos de la respuesta	`n_eventos`$_t$, `duracion_total`$_t$ (admitidas solo rezagadas)
	Respuesta cruzada	SAIFI_t al modelar SAIDI_t, y viceversa

Nota: el conjunto de 18 predictoras de $\mathbf{X}$ corresponde a la especificación final de la Etapa 5 (`Etapa5_03_reestimacion_cierre.R`), obtenida tras depurar las 44 candidatas iniciales por los criterios de las Secciones 5.4.3 y 5.4.4. Respecto de la especificación de los informes preliminares (`Etapa5_01` y `Etapa5_02`), las variables observadas en la semana s —clima, vegetación y sismicidad— entran rezagadas una semana $(t-1)$, para que todo el bloque $\mathbf{X}$ esté disponible antes de la semana pronosticada; y se añade `n_elementos`, que es constante en el tiempo y, por tanto, disponible *ex ante*. Con el panel corregido, la especificación contemporánea y la rezagada alcanzan el mismo error de prueba (RMSE de 0.1011 y 0.1013 para FE de cuadrante en SAIDI), de modo que el rezago no cuesta precisión y elimina toda duda sobre el uso de información posterior.

y 105 semanas, el panel semanal admitiría técnicamente especificaciones más amplias, pero el corte transversal empleado para SAR/SEM opera sobre $N = 343$ observaciones, donde la parsimonia deja de ser una preferencia estética y pasa a ser una condición de identificabilidad. Mantener una matriz común entre ambas escalas de análisis permite comparar coeficientes entre la especificación de panel y la estructural sin reabrir la discusión de selección de variables en cada una.

Los insumos se materializan en `data_final_modelo_cuadrantes_reales.rds`, cuya construcción y verificación se documentan en los Apéndices A.3.22 (informe HTML) y A.3.25 (informe HTML), y cuyo uso en la estimación se detalla en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.4.10. Reducción de dimensionalidad

La reducción de dimensionalidad en este trabajo se entiende como selección de variables y no como proyección a un espacio latente. Además del filtrado por Spearman y VIF descrito en la Sección 5.4.3, opera un segundo mecanismo dependiente de la especificación: las variables estáticas por cuadrante quedan absorbidas por los efectos fijos cuando la especificación es FE y, en consecuencia, se omiten de esa matriz, mientras se retienen en *Pooled* OLS y en el corte transversal SAR/SEM, donde constituyen precisamente la fuente de variación de interés.

La decisión de no emplear PCA como paso obligatorio merece justificación, porque es una desviación respecto de la práctica habitual en problemas con bloques de covariables correlacionadas. El PCA sí se ejecutó, pero como *diagnóstico* de redundancia y no como generador de predictoras (Apéndice A.10): confirmó que dos componentes concentran el 87.3 % de la varianza climática y que el bloque operativo se resume casi por completo en una sola dirección (83.8 % en PC1). Convertir esas componentes en regresores habría reducido la dimensión, pero a un costo incompatible con el objetivo del proyecto. Una componente principal es una combinación lineal de temperaturas, humedad, viento y precipitación sin referente físico ni operativo; un coeficiente estimado sobre ella no puede traducirse en una recomendación de gestión. Dado que el OE2 exige *identificar qué variables son más relevantes* y el OE3 evaluar modelos con vocación de uso, se privilegió conservar variables originales interpretables y resolver la colinealidad eliminando redundancia explícita.

El criterio operativo resultante es que la reducción se guía por dos señales: la redundancia medida (agrupamiento jerárquico y VIF) y el aporte marginal verificado. Este último se evalúa en la Etapa 5 mediante la significancia de cada variable en el modelo FE, su importancia por permutación en el Random Forest

y su contribución en el corte transversal (Tabla 6.20), lo que permite decidir la permanencia de cada bloque con evidencia y no por supuesto.

5.4.11. Segmentación analítica

El modelado principal opera sobre las semanas con falla (`hubo_falla`$= 1$), decisión que condiciona la interpretación de todos los resultados posteriores y debe explicitarse. El panel completo está dominado por ceros estructurales: el $74.9\,\%$ de los pares cuadrante–semana no registra ningún evento (Sección 6.3.4). Estimar sobre el panel completo convertiría el problema en uno de detección de ausencia de falla, donde un modelo trivial que prediga siempre cero alcanzaría un error aparentemente bajo sin contenido informativo alguno. Al restringir la estimación a las semanas con evento, la pregunta se reformula con precisión: condicional a que el cuadrante experimentó al menos una interrupción, ¿qué magnitud alcanza su contribución a SAIDI o SAIFI? Esta es la pregunta operativamente relevante, porque es la que determina el impacto sobre el indicador agregado del operador.

La contrapartida es que el modelo de magnitud no pronostica la *ocurrencia* de falla. Para cubrir esa parte se estima un segundo componente: un clasificador Random Forest de `hubo_falla` sobre el panel completo, con las mismas predictoras *ex ante* más el indicador de falla de la semana anterior, evaluado por el área bajo la curva ROC. Ambos componentes se combinan en el valor esperado incondicional $\mathbb{E}[Y_{q,s}] = P(\text{falla}_{q,s}) \times \mathbb{E}[Y_{q,s} \mid \text{falla}_{q,s}]$, lo que constituye una estructura en dos partes. Un modelo de conteo con inflación de ceros queda como alternativa para trabajo futuro (Capítulo 7).

En paralelo opera una segunda segmentación, de naturaleza distinta: el corte transversal ponderado agrega el panel a un único vector por cuadrante para estimar SAR y SEM sobre $N = 343$ observaciones. La ponderación sigue un esquema de *suma de dígitos*, que asigna a la semana en posición t de un total de n un peso $w_t = t \,/\, [n(n+1)/2]$, creciente de forma lineal hacia lo reciente y con suma unitaria. La elección responde a que el objetivo de esta agregación es caracterizar el estado *actual* del patrón territorial: una media simple trataría como equivalentes a una semana de inicio de 2024 y a una de cierre de 2025, pese a que la segunda es más representativa de la configuración vigente de la red.

Finalmente, la segmentación territorial derivada del EDA (los cuatro *clusters* de cuadrantes de la Sección 6.3.9) informa la interpretación de resultados y la priorización operativa, pero no sustituye la partición temporal ni se emplea para estimar modelos separados por grupo: con 343 cuadrantes repartidos en cuatro estratos muy desiguales, la estimación por grupo comprometería la precisión sin ganancia clara en capacidad explicativa.

5.4.12. Transformaciones adicionales para modelado

Sobre la matriz de diseño se aplican tres familias de transformaciones, cada una motivada por una propiedad distinta de los datos documentada en el EDA.

Transformación de escala de la respuesta. Se construyen $\log(1 + \text{SAIDI})$ y $\log(1 + \text{SAIFI})$. Más allá de la justificación por asimetría y ceros expuesta en la Sección 5.4.6, la transformación tiene una implicación interpretativa deseable: en escala logarítmica, los coeficientes de la ecuación (5.3) se leen aproximadamente como efectos relativos, lo que resulta más natural para un indicador cuya magnitud absoluta varía en varios órdenes entre cuadrantes. También implica que las métricas de desempeño reportadas en la Etapa 5 están en escala logarítmica y no son directamente comparables con errores expresados en horas-usuario.

Rezagos espaciales. Se construyen `SAIDI_vecinos_lag1`, `SAIFI_vecinos_lag1` y `ndvi_vecinos` mediante una matriz de contigüidad *queen* estimada con `spdep`, en la que dos cuadrantes son vecinos si comparten al menos un punto de frontera. El criterio *queen* —frente al *rook*, que exige frontera compartida de longitud positiva— se adopta porque sobre la malla regular de cuadrantes incorpora también los vecinos diagonales, lo que resulta más coherente con la propagación de fallas a lo largo de circuitos que no siguen la orientación de la malla. Dos precisiones son importantes: el rezago espacial se toma siempre en $t - 1$, nunca contemporáneo, porque el valor simultáneo de los vecinos no está disponible en el momento de pronosticar y su uso reintroduciría fuga de información; y la vecindad se define sobre cuadrantes con presencia efectiva de red, con política de cero vecinos admitida para las celdas aisladas. La construcción de la matriz de vecindad se documenta en el Apéndice A.3.21 (informe HTML).

Interacciones exposición $\times$ infraestructura. Se construyen `ndvi_x_elementos` y `sismo_x_elementos`, bajo la hipótesis de que el riesgo ambiental se materializa de forma proporcional a la cantidad de activos expuestos. Incluirlas como términos explícitos permite que las especificaciones lineales capturen una relación que, de otro modo, solo Random Forest podría aproximar; su comparación informa, por tanto, sobre cuánto de la ventaja del modelo no paramétrico proviene de interacciones de este tipo y cuánto de no linealidades de otra naturaleza. El detalle de implementación se documenta en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.4.13. Resultados y entregables de la etapa

La Etapa 4 convierte el panel enriquecido de la Etapa 2, depurado y diagnosticado en la Etapa 3, en un artefacto listo para estimación. Su resultado sustantivo no es un conjunto de datos adicional sino una *decisión documentada*: la partición de la ecuación (5.1), materializada en la Tabla 5.11, que fija qué se predice, con qué se predice y qué se excluye deliberadamente pese a estar disponible. Esta última categoría es la que distingue un ejercicio predictivo válido de uno que solo parece serlo.

Resultado: panel analítico con respuestas SAIDI y SAIFI formalmente definidas, 18 predictoras *ex ante* depuradas de 44 candidatas, rezagos temporales y espaciales construidos sin fuga de información, y partición temporal documentada (*holdout* del 15 % final de semanas, con corte el 8 de septiembre de 2025).

Entregable: matriz depurada de predictoras (Secciones 5.4.3 y 5.4.9) y panel analítico final `data_final_modelo_cuadrantes_reales.rds`, documentados en los Apéndices A.3.26 (informe HTML), A.3.27 (informe HTML), A.3.16 (informe HTML), A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.5. Etapa 5 – Modelado predictivo y evaluativo

En esta etapa se estiman y comparan modelos para *SAIDI* y *SAIFI* por separado a grano cuadrante $\times$ semana, siguiendo `Etapa5_01_modelo_SAIDI_espacial.Rmd` y `Etapa5_02_modelo_SAIFI_espacial.Rmd` (Apéndices A.3.28–A.3.29). El diseño combina (i) modelos de panel para pronóstico semanal y (ii) modelos espaciales formales SAR/SEM en corte transversal ponderado. La validación es temporal; las métricas de referencia son $RMSE$, MAE y R^2 en escala $\log(1 + y)$.

5.5.1. Selección de algoritmos

Se seleccionan cuatro familias para el panel semanal: (1) *Pooled OLS*; (2) *efectos fijos de cuadrante*; (3) *efectos fijos de cuadrante y semana*; (4) *Random Forest* (`randomForest` con valores por defecto y `ranger` con hiperparámetros ajustados). Los efectos fijos se estiman por mínimos cuadrados con variables indicadoras, estimación idéntica a la de `feols` (`fixest`), con errores estándar agrupados por cuadrante y de Driscoll–Kraay (`sandwich`). En el corte transversal se estiman *SAR* y *SEM* (`spatialreg`). Todos los modelos se comparan además con dos *pronósticos de referencia* que no requieren estimación: la persistencia, que asigna a cada cuadrante el valor de su semana anterior, y la media histórica del cuadrante en el entrenamiento. Un modelo solo aporta valor predictivo si supera a ambos.

La selección no responde a un criterio de exhaustividad sino a una secuencia

de relajación de supuestos, en la que cada familia levanta una restricción de la anterior y permite atribuir las ganancias de desempeño a una causa identificable. *Pooled* OLS constituye la referencia mínima: supone que todos los cuadrantes comparten el mismo intercepto y que las covariables observadas agotan la heterogeneidad territorial, supuesto que el EDA ya había cuestionado al documentar concentración espacial de fallas. Los efectos fijos de cuadrante relajan ese supuesto permitiendo un intercepto por celda, con lo que absorben toda la heterogeneidad no observada invariante en el tiempo —calidad constructiva de la red, accesibilidad del terreno, prácticas de mantenimiento local— sin necesidad de medirla; el precio es que los atributos estáticos del cuadrante dejan de ser identificables. Los efectos fijos de cuadrante y semana añaden un intercepto temporal común que captura choques sistémicos que afectan a toda la concesión en una semana dada, como un temporal regional o un cambio en los protocolos de registro. Random Forest abandona la linealidad y la aditividad, y permite contrastar cuánta estructura queda sin capturar por las especificaciones paramétricas.

Los modelos espaciales responden a una pregunta distinta de las anteriores. Mientras las cuatro familias de panel tratan la dependencia entre vecinos de forma reducida, mediante un regresor de rezago espacial, SAR y SEM la modelan de forma estructural: SAR supone que la respuesta de un cuadrante depende directamente de la respuesta de sus vecinos (ρWy), lo que es coherente con una propagación real de la falla a través de circuitos interconectados; SEM supone en cambio que la dependencia reside en los errores (λWu), lo que corresponde a la existencia de factores no observados espacialmente correlacionados, como condiciones de terreno o de vegetación no capturadas por las covariables. La comparación entre ambos por AIC no es, por tanto, un mero ejercicio de ajuste: discrimina entre dos hipótesis sustantivas sobre el origen de la autocorrelación observada.

La dependencia espacial se diagnostica previamente con el índice de Moran, paso que condiciona la pertinencia de todo el bloque espacial: si el índice no fuera significativo, tanto los rezagos de vecinos como SAR y SEM carecerían de justificación empírica. La Figura 5.15 ilustra el patrón territorial de $SAIDI$ promedio por cuadrante sobre el que se calcula el estadístico.

5.5.2. Entrenamiento del modelo

El entrenamiento usa solo semanas anteriores al corte temporal y la matriz de diseño fijada en la Sección 5.4.9: clima, precipitación móvil, NDVI y sismicidad de la semana anterior, rezago propio (`SAIDI_lag1`/`SAIFI_lag1`), topología de red, proporciones de estrato, edad y modificaciones de activos, y rezagos espa-

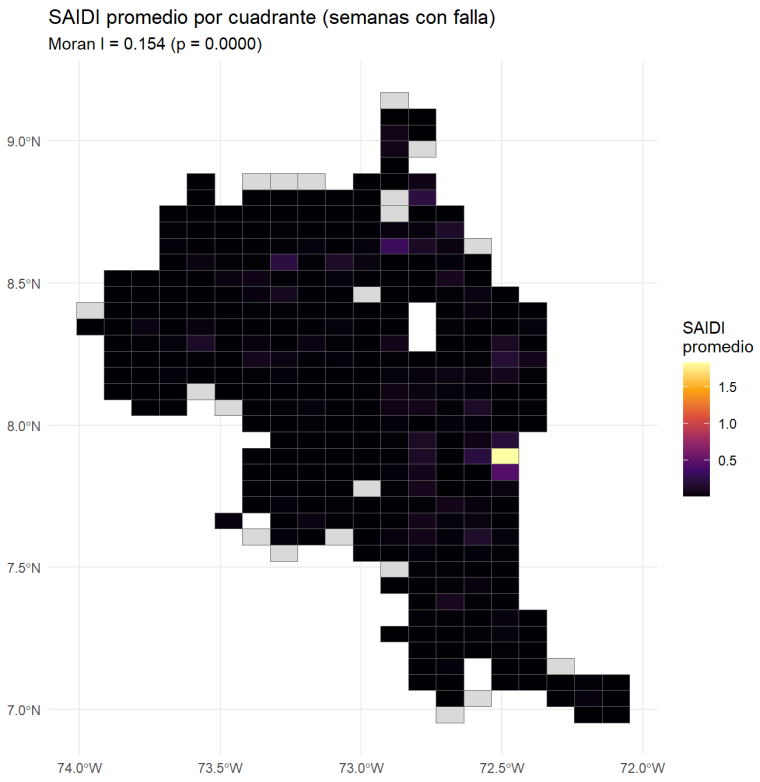


Figura 5.15: Mapa de $SAIDI$ promedio por cuadrante usado en el diagnóstico de autocorrelación espacial (Moran).

ciales de vecinos. SAIDI y SAIFI se modelan en escala $\log(1 + y)$ y en modelos independientes, conforme a la justificación de la Sección 5.4.2.

Las cuatro especificaciones de panel comparten exactamente el mismo conjunto de predictoras y difieren únicamente en la estructura de efectos fijos declarada, de modo que cualquier diferencia de desempeño entre ellas es atribuible a esa estructura y no a una selección distinta de variables. Esta homologación es la que permite leer la comparación de la Sección 5.5.6 como evidencia sobre la naturaleza del fenómeno y no como el resultado de un ajuste diferencial de hiperparámetros.

El entrenamiento se restringe además a las observaciones con `hubo_falla`$= 1$, por la razón expuesta en la Sección 5.4.11, y descarta por `na.omit` las filas con valores ausentes en alguna predictora, lo que afecta principalmente a las primeras semanas de cada serie, donde los rezagos aún no están definidos. La Figura 5.16 muestra la partición temporal train/test resultante en el panel de SAIDI, análoga a la de SAIFI: el volumen de observaciones por semana es comparable entre ambos conjuntos, lo que descarta que el corte haya aislado un tramo atípicamente denso o escaso de actividad.

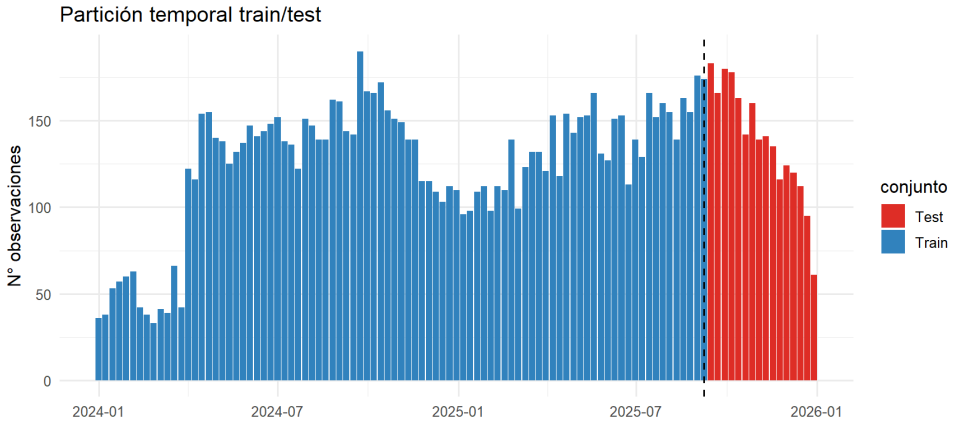


Figura 5.16: Partición temporal entrenamiento/prueba para el modelado de $SAIDI$ (holdout $\approx 15\,\%$ final de semanas).

5.5.3. Validación del modelo

La validación es *holdout temporal*: se reserva aproximadamente el $15\,\%$ final de semanas ordenadas y no se permite muestreo aleatorio, por las razones de autocorrelación expuestas en la Sección 5.4.8. Sobre 105 semanas disponibles, el corte deja alrededor de dieciséis semanas de evaluación, un horizonte suficiente para detectar degradación sistemática del pronóstico pero demasiado corto para evaluar estabilidad interanual, limitación que se discute en el Capítulo 7.

La elección de un esquema de *holdout* simple en lugar de validación cruzada

deliberada merece justificación. La validación cruzada con k pliegues aleatorios es inadmisible aquí porque rompería el orden temporal. Como verificación de estabilidad, el desempeño se evalúa además mediante validación de origen móvil: se fijan cuatro cortes sucesivos (semanas 52, 64, 76 y 88 del panel), en cada uno se reestiman los modelos con todas las semanas anteriores y se evalúan sobre las doce semanas siguientes. Se reportan la media y la desviación estándar del RMSE entre cortes (Tabla 6.16), lo que permite distinguir diferencias sistemáticas entre modelos de las que dependen de una ventana de prueba particular.

Un caso particular exige tratamiento explícito. El FE de cuadrante y semana no resulta evaluable fuera de muestra cuando las semanas de prueba no están representadas en el entrenamiento, situación que la partición temporal estricta garantiza por construcción: los efectos fijos τ_s de las semanas de prueba no están estimados y el modelo no puede generar predicción para ellas. La consecuencia no es un defecto del estimador sino una incompatibilidad estructural entre efectos fijos temporales y validación prospectiva; la especificación se conserva por su valor descriptivo dentro de muestra y se excluye de la comparación predictiva, en la que participan *Pooled* OLS, FE de cuadrante, Random Forest y los dos pronósticos de referencia.

Como verificación complementaria, el aporte de la dimensión espacial al pronóstico se juzga por la significancia de los rezagos de vecinos en el modelo FE y por su importancia en el Random Forest, y no solo por el diagnóstico de Moran, que acredita la existencia de autocorrelación pero no que explotarla mejore la predicción.

5.5.4. Ajuste de hiperparámetros

En Random Forest se ajustan los dos hiperparámetros que controlan el grado de regularización: el número de variables candidatas en cada división (`mtry`) y el tamaño mínimo de los nodos terminales. Se evalúa una grilla de 6×4 combinaciones ($\texttt{mtry} \in \{2, 4, 6, 9, 13, 18\}$, donde 18 equivale a usar todas las predictoras, y tamaño mínimo de nodo $\in \{5, 10, 20, 50\}$), con 500 árboles y semilla fija. Para no consumir información del conjunto de prueba, la selección se hace con una *validación temporal interna*: cada combinación se estima con el $85\,\%$ inicial de las semanas de entrenamiento (hasta el 2 de junio de 2025) y se evalúa en las semanas de entrenamiento restantes; el error *out-of-bag* se reporta como referencia. La combinación de menor error de validación interna se reestima con todo el entrenamiento y $1\,000$ árboles, y es la que se evalúa en prueba. El resultado se presenta en la Tabla 6.15 y la Figura 6.9.

En SAR y SEM el ajuste no es de hiperparámetros en sentido estricto sino de *especificación*: se compara el AIC entre ambas estructuras de dependencia y

frente al OLS de referencia sobre el mismo corte transversal, y se selecciona la que minimiza el criterio. Dado que SAR y SEM no son modelos anidados entre sí, el AIC es el instrumento adecuado para discriminarlos, en tanto penaliza la complejidad sin requerir una relación jerárquica entre especificaciones.

La robustez de los modelos de corte transversal se verifica mediante cuatro pruebas complementarias, orientadas a descartar que el alto ajuste observado sea un artefacto de colinealidad estructural con el tamaño del cuadrante. La primera examina la correlación entre los predictores retenidos y el número de usuarios del cuadrante, candidato natural a variable de confusión por estar asociado simultáneamente a la cantidad de infraestructura y al numerador del indicador. La segunda reestima el modelo incorporando $\log(1 + \texttt{cantidad_usuarios_cuadrante})$ como control explícito y mide la caída del R^2: una caída pequeña indica que la capacidad explicativa no provenía del tamaño. La tercera cuantifica la pérdida de ajuste al excluir cada predictor por separado, lo que detecta si el resultado depende de una única variable dominante. La cuarta es una prueba de permutación con 500 remuestreos de la respuesta, que construye la distribución empírica del R^2 bajo la hipótesis nula de ausencia de relación y permite asignar un valor p empírico al ajuste observado. La quinta es una validación cruzada espacial: los cuadrantes se dividen en cinco franjas de latitud y cada franja se predice con el modelo estimado sobre las otras cuatro, lo que mide si el patrón explicado es transferible entre zonas o solo describe la muestra. El detalle de sensibilidad y los resultados de las cuatro pruebas se documentan en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.5.5. Evaluación de desempeño

Sobre el conjunto de prueba se calculan $RMSE$, MAE y R^2 en escala $\log(1+y)$, además del MASE (MAE del modelo dividido por el MAE de la persistencia) y del MAE en la escala original del indicador. La significancia de las diferencias de error entre modelos se contrasta con la prueba de Diebold–Mariano [36] sobre los errores cuadráticos con horizonte de una semana. Las tres métricas se reportan conjuntamente porque informan sobre aspectos distintos del error y su lectura aislada puede inducir a conclusiones opuestas. El $RMSE$ penaliza cuadráticamente las desviaciones grandes y es, por tanto, sensible a los fallos de pronóstico en las semanas de mayor afectación, que son precisamente las de mayor relevancia operativa. El MAE pondera todos los errores por igual y resulta más representativo del desempeño típico. El R^2, calculado como el cuadrado de la correlación entre observado y predicho, mide la proporción de variabilidad ordenada correctamente, con independencia de un posible sesgo de nivel. Un modelo puede, en consecuencia, presentar menor $RMSE$ y menor

R^2 que otro: el primero sería más preciso en magnitud y el segundo mejor en ordenamiento relativo de cuadrantes, y la elección entre ambos depende del uso previsto.

Debe subrayarse que todas las métricas se expresan en escala logarítmica, lo que las hace comparables entre modelos del mismo indicador pero no entre SAIDI y SAIFI, cuyas escalas difieren en varios órdenes de magnitud, ni con errores expresados en horas-usuario. Los valores observados frente a los predichos del mejor modelo de cada indicador se presentan en las Figuras 6.12 y 6.13 (Sección 6.5). La lectura de estos diagramas es informativa más allá del resumen numérico: la dispersión en torno a la diagonal revela si el error es homogéneo a lo largo del rango o si se concentra en los valores extremos, diagnóstico que ninguna de las tres métricas agregadas permite por sí sola.

5.5.6. Comparación de modelos

La comparación distingue dos usos que responden a preguntas diferentes y que, por tanto, no admiten un criterio único de selección. El primero es el *pronóstico semanal*, evaluado por el menor $RMSE$ en el conjunto de prueba entre *Pooled* OLS, FE de cuadrante y Random Forest, con la condición adicional de superar de forma significativa a los dos pronósticos de referencia. El segundo es la *explicación estructural* del patrón territorial, evaluada por el menor AIC entre OLS, SAR y SEM sobre el corte transversal ponderado.

Esta separación no es una concesión metodológica sino una consecuencia de la naturaleza del problema. Un modelo de pronóstico se juzga por su error sobre observaciones que no ha visto; un modelo estructural se juzga por la verosimilitud con que describe la generación de los datos observados y por la interpretabilidad de sus parámetros. Las métricas correspondientes no son conmensurables: un $RMSE$ en escala logarítmica sobre $2\,215$ observaciones semanales y un AIC sobre 343 promedios por cuadrante miden objetos distintos, y compararlos directamente carecería de sentido. Por esta misma razón el Capítulo 6 advierte explícitamente contra la lectura conjunta del R^2 de ambas escalas.

SAIDI y SAIFI se reportan por separado, lo que permite detectar si el modelo preferido coincide entre indicadores. Que no coincida es, en sí mismo, un resultado sustantivo: indicaría que la duración y la frecuencia de interrupción obedecen a estructuras de dependencia distintas y que una política de gestión única para ambos indicadores estaría mal especificada. Las tablas numéricas completas se concentran en el Capítulo 6 y en los Apéndices A.3.28 (informe HTML) y A.3.29 (informe HTML).

5.5.7. Interpretación de resultados

La interpretación combina tres fuentes de evidencia de naturaleza complementaria, cuya convergencia o divergencia es en sí misma informativa: los coeficientes de las especificaciones lineales y de efectos fijos, la importancia de variables del Random Forest, y los parámetros espaciales de SAR y SEM.

Cada fuente tiene un alcance y una limitación propios. Los coeficientes lineales son directamente interpretables como efectos marginales y admiten contraste de significancia, pero presuponen una forma funcional que el propio desempeño de Random Forest sugiere incompleta. La importancia por permutación del Random Forest (aumento del error cuadrático medio al permutar cada variable) captura relaciones no lineales e interacciones, pero no informa sobre el *signo* del efecto: una variable puede resultar altamente importante tanto por aumentar como por reducir el indicador. Los parámetros ρ de SAR y λ de SEM cuantifican la intensidad de la dependencia espacial, pero se estiman sobre promedios y no sobre la dinámica semanal.

El criterio de interpretación adoptado es, en consecuencia, de *triangulación*: se consideran robustos aquellos hallazgos que aparecen en al menos dos de las tres fuentes, y se tratan con cautela los que dependen de una sola especificación. Este criterio adquiere especial relevancia en presencia de colinealidad residual, donde el reparto de la contribución entre variables correlacionadas es inestable entre métodos: un coeficiente lineal puede resultar no significativo simplemente porque otra variable del mismo bloque absorbió su efecto, mientras que la importancia del Random Forest, al evaluar la pérdida de ajuste ante permutación, puede señalar a ambas. Las Figuras 6.10 y 6.11 resumen la importancia relativa de predictores en los Random Forest de $SAIDI$ y $SAIFI$, y su contraste con los coeficientes de las regresiones de corte transversal se desarrolla en la Sección 6.5.

5.5.8. Resultados y entregables de la etapa

La Etapa 5 produce seis modelos estimados por indicador y escala de análisis: cuatro especificaciones de panel semanal y dos espaciales formales, para SAIDI y SAIFI respectivamente. Su valor no reside únicamente en el modelo de mejor desempeño, sino en la comparación sistemática entre especificaciones bajo una matriz de diseño homologada, que permite atribuir las diferencias observadas a la estructura de dependencia y no a decisiones arbitrarias de preparación de datos.

Resultado: modelos de SAIDI y SAIFI entrenados, validados en *holdout* temporal, contrastados con especificaciones espaciales formales y sometidos a verificación de robustez frente a colinealidad estructural.

Entregables:

- `Etapa5_01_modelo_SAIDI_espacial.html`, con la estimación, validación, diagnóstico de supuestos y pruebas de robustez del modelo de duración (Apéndice A.3.28; informe HTML).
- `Etapa5_02_modelo_SAIFI_espacial.html`, con el análisis equivalente para el modelo de frecuencia (Apéndice A.3.29; informe HTML).

5.6. Etapa 6 – Cierre metodológico, documentación y reportes

En la etapa final se consolidan los resultados del proyecto y se documentan de forma integral las técnicas aplicadas, las transformaciones realizadas y el código reproducible (en R o Python). El capítulo incluye apéndices técnicos, tablas de validación, bibliografía y lineamientos de reproducibilidad, así como una discusión orientada a interpretar los hallazgos en términos técnicos y operativos para la toma de decisiones del operador de red.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.6.1. Presentación de resultados del modelo

Los resultados de los seis modelos estimados (cuatro de panel semanal y dos espaciales formales, para SAIDI y SAIFI) se organizaron en tablas homologadas de desempeño comparado, acompañadas de figuras de valores observados frente a predichos y de importancia de variables, presentadas en el Capítulo de Resultados (Sección 6.5).

El criterio de organización privilegia la comparabilidad sobre la exhaustividad. Cada tabla reporta las mismas tres métricas para todas las especificaciones del mismo indicador, incluidas aquellas que no resultaron evaluables, señaladas de forma explícita en lugar de omitidas: documentar que el FE de cuadrante y semana no produce predicción fuera de muestra es parte del resultado, porque informa sobre una restricción estructural del diseño de validación y no sobre una omisión del análisis. De forma análoga, las tablas de corte transversal reportan tanto los predictores significativos como el conjunto de los no significativos, de modo que el lector pueda verificar qué hipótesis fueron contrastadas y descartadas, y no solo las confirmadas.

5.6.2. Métricas de desempeño

Sobre el conjunto de prueba se calcularon RMSE, MAE y R^2 en escala $\log(1+y)$ para los cuatro modelos de panel, y AIC para los modelos espaciales SAR/SEM, siguiendo las definiciones formalizadas en la Sección 3.1.2 y los criterios de lectura de la Sección 5.5.5.

A estas métricas se añadió una verificación de significancia empírica sobre el corte transversal, consistente en contrastar el R^2 observado contra la distribución generada por 500 permutaciones aleatorias de la respuesta. Esta prueba responde a una preocupación específica de los modelos estimados sobre 343 observaciones con un número no trivial de predictores: parte del ajuste podría deberse a capacidad de sobreajuste y no a una relación real. La distribución de permutación proporciona el punto de comparación correcto, puesto que preserva la estructura de la matriz de predictores y destruye únicamente su asociación con la respuesta.

5.6.3. Hallazgos principales

Los hallazgos de las seis etapas se consolidaron en una síntesis única que articula el resultado principal de cada etapa con los tres objetivos específicos del proyecto (Sección 6.6).

La consolidación distingue dos clases de hallazgo que conviene no confundir. Los *hallazgos sustantivos* responden a las preguntas de investigación: qué variables explican la variación territorial de los indicadores, qué modelos pronostican mejor y con qué precisión. Los *hallazgos de proceso* surgieron durante la ejecución y no eran anticipables en el diseño; el principal es el sesgo de cobertura del emparejamiento evento–elemento entre 2021 y 2023 (Sección 6.3.5), que no es un defecto del análisis sino un diagnóstico sobre la calidad de la información histórica del operador, con valor propio para la organización con independencia de los modelos estimados. Ambas clases se reportan, porque un trabajo que solo documentara los hallazgos sustantivos ocultaría la evidencia que explica por qué el horizonte de modelado quedó restringido a dos años.

5.6.4. Interpretación técnica y operativa

Los resultados se tradujeron en implicaciones para la gestión operativa del operador de red, priorizando aquellas variables sobre las cuales existe margen de acción. Esta distinción es central: no todas las variables relevantes son accionables. La exposición sísmica y la distancia al epicentro son determinantes del riesgo pero no modificables; la vegetación es modificable mediante poda programada; la densidad de red, la antigüedad de los activos y el ritmo de reposición son directamente gestionables mediante planes de inversión. Una recomenda-

ción operativa útil debe, por tanto, ordenar las variables no solo por importancia estadística sino por el cruce entre importancia y capacidad de intervención.

La traducción también exige explicitar el horizonte de uso de cada modelo. El modelo de panel semanal sirve a la programación de cuadrillas y a la anticipación de semanas críticas; el modelo espacial de corte transversal sirve a la priorización de inversión en cuadrantes estructuralmente vulnerables, una decisión de ciclo anual o plurianual. Confundir ambos horizontes llevaría a usar un modelo de ordenamiento territorial para decisiones operativas de corto plazo, para las que no fue validado. Esta interpretación se desarrolla en el Capítulo 7.

5.6.5. Generación de reportes

Cada etapa del proyecto se documentó en informes reproducibles (R Markdown renderizados a HTML), consolidados en el Apéndice A.3, junto con el código fuente de extracción, integración y modelado (Apéndice A.2).

El esquema de reproducibilidad adoptado tiene tres propiedades que conviene hacer explícitas. Primero, cada informe contiene simultáneamente el código ejecutado, los resultados y la narrativa interpretativa, de modo que no existe posibilidad de divergencia entre lo reportado y lo computado. Segundo, las rutas de datos se resuelven mediante una variable de entorno (`UBICACION_DATA`) y no mediante rutas absolutas, lo que permite reejecutar la cadena completa en una máquina distinta sin editar el código; las credenciales de acceso a las bases institucionales se gestionan por el mismo mecanismo y nunca se incorporan al repositorio. Tercero, los informes se publican como páginas estáticas con URL estable, de modo que cada afirmación del documento puede verificarse en su evidencia computacional de origen mediante los enlaces incorporados en las referencias de apéndice a lo largo de este capítulo.

5.6.6. Discusión de resultados

El análisis crítico de fortalezas, limitaciones y comparaciones entre los modelos estimados se desarrolla en el Capítulo 7, para no duplicar contenido entre los capítulos de Metodología y Discusión. La separación responde a una división funcional: este capítulo documenta *qué se hizo y por qué*, el Capítulo de Resultados reporta *qué se obtuvo*, y el de Discusión interpreta *qué significa* y bajo qué condiciones los hallazgos son generalizables.

5.6.7. Limitaciones y trabajos futuros

Las limitaciones identificadas a lo largo del proyecto y las líneas de trabajo futuro se consolidan en la Sección 7.2. Las de origen metodológico quedan ya señaladas en este capítulo y conviene enumerarlas aquí para trazabilidad: el sesgo de cobertura del emparejamiento 2021–2023, que redujo el horizonte de

modelado a dos años (Sección 5.4.8); la señal climática contemporánea débil en el grano semanal, que limita el aporte del bloque meteorológico sin rezagos de mayor orden (Sección 5.4.1); la restricción del modelado a semanas con falla, que deja fuera el componente de ocurrencia (Sección 5.4.11); la imposibilidad de validar fuera de muestra la especificación con efectos fijos dobles (Sección 5.5.3); y la brevedad del *holdout*, que impide evaluar estabilidad interanual (Sección 5.5.4).

5.6.8. Resultados y entregables de la etapa

Resultado: documentación final del proyecto y resultados consolidados, con trazabilidad verificable entre cada afirmación del documento y el informe reproducible que la sustenta.

Entregables: compendio de documentación del proyecto (informe final, informe descriptivo, informe de evaluación de modelos y reporte técnico de variables relevantes), código reproducible publicado en el repositorio del proyecto (Apéndices A.3 y A.2) y documentación detallada de procesos y transformaciones a lo largo de las seis etapas.

5.7. Relación entre etapas metodológicas y objetivos específicos

La Tabla 5.12 sintetiza cómo cada etapa de la metodología contribuye a los objetivos específicos formulados en el Capítulo 2. Los objetivos no se reformulan aquí: se indica únicamente su correspondencia con las etapas, de modo que la trazabilidad entre el diseño metodológico y el alcance del proyecto quede explícita. De forma complementaria, los informes reproducibles derivados de los archivos `EtapaX_Y_*.Rmd` se documentan como informes HTML en el Apéndice A.3 (subsecciones de enriquecimiento, ingeniería de variables y modelado espacial).

P1 a P4 denotan las preguntas de sistematización en el orden en que se formulan en la Sección 1.2. En síntesis, las Etapas 1 y 2 materializan el OE1 y responden a la primera pregunta; las Etapas 3 y 4 sustentan el OE2 y la segunda pregunta; la Etapa 5 concentra el OE3 y la tercera pregunta, con aporte interpretativo al OE2; y la Etapa 6, transversal a los tres objetivos, responde a la cuarta pregunta mediante los artefactos reproducibles y los reportes técnicos del proyecto.

Tabla 5.12: Correspondencia entre preguntas de sistematización, objetivos específicos y etapas metodológicas

Etapa	Pregunta	Objetivo	Aporte y evidencia
Etapa 1 – Extracción (Sección 5.1)	P1	OE1	Extracción de las fuentes; linaje de datos (Tabla 5.7); catálogo de datos (Apéndice A.4).
Etapa 2 – Integración (Sección 5.2)	P1	OE1	Panel activo × día y cuadrante × semana; métricas de integridad y cobertura del emparejamiento (Tabla 6.9).
Etapa 3 – EDA (Sección 5.3)	P2	OE2	Patrones temporales, espaciales, estacionales y atípicos; redundancias y señal climática.
Etapa 4 – Ingeniería de variables (Sección 5.4)	P2, P3	OE2, OE3	Respuestas, predictoras *ex ante*, depuración y partición temporal.
Etapa 5 – Modelado (Sección 5.5)	P3	OE2, OE3	Comparación de modelos, variables relevantes e interpretación para los gestores.
Etapa 6 – Cierre y reportes (Sección 5.6)	P4	Transversal (OE1–OE3)	Artefactos reproducibles (informes R Markdown, entorno `renv` y contenedor) y reportes técnicos (Apéndice A.6).

6 Resultados

6.1. Etapa 1 – Resultados de la extracción de datos

La extracción documentada en la Sección 5.1 consolidó seis fuentes complementarias (BRAE, BRAE + QA_TTC1, OMS SPARD, OMS SP7, GIS GTECH y NASA POWER), cuyo linaje de datos se resume en la Tabla 5.7. El resultado directo de esta etapa es la base transaccional de eventos de interrupción del sistema (`tabla_eventos`), con 95 280 eventos depurados tras el filtrado regulatorio del periodo 2021–2025, la exclusión de registros no válidos y la eliminación de duplicados. En paralelo, la extracción climática de NASA POWER produjo una serie diaria de 83.5 millones de registros meteorológicos, con cobertura completa y homogénea sobre toda el área de concesión (Sección 5.2.8).

Cada fuente quedó sujeta a reglas explícitas y verificables de filtrado y homologación (Tabla 5.7), lo que garantiza que el insumo inicial para la integración de la Etapa 2 sea trazable y reproducible: la totalidad del proceso de extracción está documentado mediante consultas SQL y fragmentos de código reproducible (Apéndice A.2).

6.2. Etapa 2 – Resultados de la integración y depuración de datos

La integración secuencial descrita en la Sección 5.2 produjo dos tablas base, cuya construcción se documenta en los Apéndices A.3.1 (informe HTML) y A.3.2 (informe HTML). La primera, con grano activo eléctrico $\times$ día (Tabla 5.8), alcanza $N = 87\,007\,074$ observaciones ($47\,649$ activos únicos $\times$ $1\,826$ días), preservando trazabilidad completa entre el inventario georreferenciado y el calendario de análisis 2021–2025. La segunda, agregada a grano cuadrante $\times$ semana sobre la malla institucional de 800 cuadrantes (Figura 5.1), alcanza $N_{\text{agr}} = 90\,128$ observaciones (Tabla 5.10) para el horizonte completo 2021–2025. En esta segunda tabla se incorporaron, además del clima y los eventos, variables de caracterización territorial por cuadrante: composición socioeconómica (estrato, proporción de clientes no residenciales), topología e infraestructura de red (número de elemen-

tos, longitud de red, densidad de nodos terminales, número de circuitos) y las fuentes de exposición adicionales descritas en el Capítulo de Datos (sismicidad y vegetación/NDVI).

Un hallazgo relevante de esta etapa es un sesgo sistemático detectado al contrastar el conteo anual de eventos de la base BRAE con la suma territorial de eventos de la tabla agregada durante 2021–2023 (Tabla 6.9; Figura 6.2). El diagnóstico descarta la ausencia de datos como causa —el campo `COMPONENTE_FALLADO` está completo en el 100 % de los registros BRAE— y la atribuye a una incompatibilidad entre esquemas de codificación al cruzar eventos con el inventario georreferenciado. Este hallazgo, que no era anticipable antes del análisis, llevó a delimitar el subconjunto de datos con cobertura de emparejamiento confiable como el dataset de modelado D_{mod}: 36 120 filas cuadrante–semana, 105 semanas y 33 410 eventos georreferenciados en el periodo 2024–2025 (15 211 en 2024 y 18 199 en 2025), que es el que efectivamente alimenta el modelado de la Etapa 5. El horizonte completo 2021–2025 (D_{EDA}) se conserva para el análisis exploratorio de la Etapa 3. El diagnóstico de cobertura se documenta en el Apéndice A.3.9 (informe HTML) y la materialización del subconjunto de modelado en el Apéndice A.3.10 (informe HTML).

Conviene subrayar el alcance de este hallazgo más allá de su consecuencia inmediata sobre el horizonte de modelado. Que el campo `COMPONENTE_FALLADO` esté completo en el 100 % de los registros y que, pese a ello, solo alrededor del 31 % de los eventos de 2021–2023 logre emparejarse con el inventario georreferenciado, demuestra que la completitud formal de un campo no garantiza su utilidad analítica. La discrepancia no se origina en la ausencia de datos sino en la convivencia de dos esquemas de codificación —código de sitio, estable en el tiempo, y código de activo, sujeto a cambio en cada reposición— que el sistema histórico OMS-SPARD empleaba de forma intercambiable. Un diagnóstico basado únicamente en conteos de valores ausentes, como el que se reporta en la Sección 6.3, habría calificado la fuente como de calidad alta y no habría detectado el problema. El hallazgo tiene, por tanto, valor propio para la gobernanza de datos del operador, con independencia de los modelos estimados en este trabajo.

El marco institucional de gobernanza de datos de CENS y la documentación pública y versionada de NASA POWER (Sección 5.2.8) respaldan el origen de las fuentes; su aptitud para este estudio se verificó empíricamente con las métricas de integridad del catálogo de datos (Apéndice A.4).

6.3. Etapa 3 – Resultados del análisis descriptivo y exploratorio

Esta sección presenta, para cada procedimiento del análisis descriptivo y exploratorio descrito en la Sección 5.3, su ejecución y sus hallazgos. Para no recargar el cuerpo del documento, aquí se conservan las figuras que sustentan decisiones metodológicas; las demás figuras del análisis exploratorio se reúnen en el Apéndice A.9. Las Secciones 6.3.1 a 6.3.4 corresponden al preprocesamiento y la caracterización de la base (faltantes, extremos y distribuciones); las siguientes, al análisis temporal, espacial, de asociación y multivariado que fundamentó la ingeniería de variables.

6.3.1. Identificación de datos faltantes

Sobre el panel consolidado final (`data_consolidada.csv`), con $N = 87\,007\,074$ observaciones (grano activo eléctrico $\times$ día), se realizó un diagnóstico sistemático de valores faltantes (`NA`) con dos enfoques complementarios: (i) conteo de `NA` por variable y (ii) conteo de observaciones del panel con al menos un `NA` por fila. El objetivo fue cuantificar la magnitud y localizar el origen de la incompletitud como insumo del EDA y para fundamentar las decisiones de imputación o exclusión en la Etapa 4.

En el análisis por columna, para cada una de las 16 variables del panel se calculó el número absoluto de `NA` y su porcentaje respecto a N. En el análisis por fila, se determinó cuántas observaciones (i, t) presentan cero, uno o más campos incompletos, junto con el máximo de variables faltantes registradas en una misma fila.

Los resultados muestran que la incompletitud se concentra en las variables climáticas integradas desde NASA POWER en el paso 5.2.1.6. Las seis variables meteorológicas (`velocidad_viento_ms`, `temperatura_media_c`, `humedad_relativa_pct`, `temperatura_minima_c`, `temperatura_maxima_c` y `precipitacion_total_mm`) presentan exactamente $3\,401\,838$ valores faltantes cada una, equivalente al $3.91\,\%$ de N. Este patrón es coherente con el cruce izquierdo por (`ELEMENTO`, `FECHA_DIA`): las filas sin emparejamiento en la base climática conservan `NA` en el bloque meteorológico. La variable `ALTITUD` registra $32\,868$ faltantes ($0.04\,\%$ de N), asociados al inventario GIS. El resto de variables del panel, identificación del activo (`ELEMENTO`, `TIPO`, `LATITUD`, `LONGITUD`), calendario (`FECHA_DIA`), severidad (`CANTIDAD_ELEMENTOS`, `CANTIDAD_USUARIOS`) y continuidad (`DURACION_min`, `FRECUENCIA`), no presentan `NA`, dado que los pasos 5.2.1.5 y 5.2.1.7 asignan 0 en días sin evento.

A nivel de fila, $83\,576\,020$ observaciones ($96.06\,\%$) están completas; $3\,431\,054$

filas (3.94 %) tienen al menos un NA, y el máximo de variables incompletas en una misma observación es 7 (combinación de las seis variables climáticas más ALTITUD). La Figura A.2a (Apéndice A.8) y la Tabla 6.1 resumen el porcentaje de faltantes por variable, ordenado de mayor a menor.

Tabla 6.1: Resumen de valores faltantes por variable en el panel consolidado

Variable	n de NA	% sobre N
velocidad_viento_ms	3 401 838	3.91
temperatura_media_c	3 401 838	3.91
humedad_relativa_pct	3 401 838	3.91
temperatura_minima_c	3 401 838	3.91
temperatura_maxima_c	3 401 838	3.91
precipitacion_total_mm	3 401 838	3.91
ALTITUD	32 868	0.04
Resto de variables del panel: 0 NA (0 %)		

En síntesis, la calidad estructural del panel es alta en variables operativas de interrupción (sin NA), y la incompletitud relevante para el modelado se limita al bloque climático y, en menor medida, a ALTITUD. Las reglas de imputación o exclusión se definen con base en este diagnóstico y se aplican en la Etapa 4.

Tabla agrupada cuadrante × semana. Sobre la tabla de análisis data_agrupada.csv (Sección 5.2.5), con $N_{\text{agr}} = 90\,128$ observaciones y 16 variables, se replicó el mismo esquema de diagnóstico: conteo de NA por variable y por fila. El procedimiento se documenta en el Apéndice A.3.3.

En el análisis por columna, las 16 variables del grano agregado, identificación y calendario (id_cuadrante, semana), georreferenciación (latitud, longitud, altitud), severidad (usuarios_afectados, elementos_afectados), clima semanal (temp_media_semana, temp_max_semana, temp_min_semana, humedad_media_semana, viento_medio_semana, viento_max_semana, precip_total_semana) y continuidad (n_eventos, duracion_total), registran 0 valores faltantes (0 % sobre N_{agr}). A nivel de fila, las 90 128 observaciones están completas: ninguna fila presenta al menos un NA y el máximo de variables incompletas por fila es 0.

Este resultado es coherente con la agregación descrita en la Sección 5.2.5: las sumas y promedios semanales emplean na.rm = TRUE, de modo que los NA del panel diario no se propagan como campos vacíos en el grano agregado; las métricas operativas sin evento se consolidan en 0, y cada fila exportada conserva llaves estructurales definidas (id_cuadrante, semana). La Figura A.2b (Apéndice A.8) ilustra la ausencia de faltantes en una muestra de las primeras 50 filas: todas las celdas se clasifican como completas.

En consecuencia, la tabla agrupada no requiere reglas de imputación por valores faltantes en la Etapa 4; el tratamiento de incompletitud documentado en los párrafos anteriores aplica al panel consolidado activo $\times$ día, grano en el que se originan los `NA` climáticos y de `ALTITUD`.

6.3.2. Identificación de valores extremos en variables cuantitativas

Se evaluó la presencia de valores extremos en las variables cuantitativas mediante reglas univariadas y diagramas de caja e histogramas. El análisis distingue observaciones operativamente plausibles de posibles inconsistencias de registro, sin aplicar aún transformaciones ni exclusiones definitivas; el tratamiento se difiere a la Etapa 4 con base en estos hallazgos. Para cada variable se aplicaron la regla de Tukey [14], el rango intercuartílico ampliado y el criterio de percentiles P1–P99, conforme a lo formalizado en la Sección 3.1.2. Como complemento interpretativo de la dispersión relativa entre variables de distinta escala, se reporta el coeficiente de variación (CV; Sección 3.1.2).

Panel consolidado activo $\times$ día. Sobre `data_consolidada.csv` ($N = 87\,007\,074$) se aplicó el protocolo descrito, excluyendo coordenadas geográficas (`LATITUD`, `LONGITUD`, `ALTITUD`). El detalle reproducible se documenta en el Apéndice A.3.4.

Variables climáticas diarias. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas, baja dispersión relativa (CV entre 0.16 y 0.20) y un porcentaje muy bajo de extremos bajo la regla de Tukey (entre $0\,\%$ para `humedad_relativa_pct` y $0.20\,\%$ para `temperatura_minima_c`); con el factor 3.0 prácticamente no se identifican extremos severos. El viento exhibe mayor heterogeneidad relativa (CV $= 0.69$). La `precipitacion_total_mm` constituye la excepción: por su naturaleza fuertemente asimétrica, con exceso de ceros y CV $= 2.12$, la regla de Tukey marca el $10.38\,\%$ de las observaciones y la ampliada el $5.30\,\%$, aunque la regla de percentiles solo señala el $1.00\,\%$. Estos valores corresponden a días de lluvia intensa operativamente plausibles, no a errores de registro. La Tabla 6.2 resume estos resultados y las Figuras A.2c y A.5 muestran, respectivamente, los diagramas de caja y los histogramas sobre una muestra de $200\,000$ observaciones.

Variables de severidad y continuidad diarias. Estas variables están dominadas por ceros (días sin interrupción): el $99.94\,\%$ de las filas registra 0, por lo que sobre el panel completo se cumple $Q_1 = Q_3 = 0$ y la regla de Tukey resulta poco informativa (marca como extremo cualquier día con evento, $0.06\,\%$ del panel); el CV del panel completo queda artificialmente inflado por la masa en cero.

Tabla 6.2: Valores extremos y dispersión relativa en variables climáticas (panel completo)

Variable	Mediana	CV	% IQR 1.5	% IQR 3.0	% P1–P99
velocidad_viento_ms	1.20	0.69	0.03	0.00	1.60
temperatura_media_c	25.47	0.17	0.02	0.00	1.99
humedad_relativa_pct	69.08	0.18	0.00	0.00	1.98
temperatura_minima_c	20.91	0.20	0.20	0.00	1.99
temperatura_maxima_c	31.32	0.16	0.05	0.00	1.99
precipitacion_total_mm	0.50	2.12	10.38	5.30	1.00

Por ello, el análisis relevante se realiza sobre los días con evento (valor > 0), donde se concentran $48\,375$ registros de afectación y $48\,364$ de continuidad. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha y de alta dispersión relativa: la mediana de `CANTIDAD_USUARIOS` es 23 usuarios pero su máximo alcanza $34\,622$ (CV $= 3.97$); la `DURACION_min` tiene mediana de 417 minutos (≈ 7 horas) y un máximo de $332\,395$ minutos (≈ 231 días; CV $= 3.56$), sugerente de posibles inconsistencias de registro que se marcan para revisión. La regla de Tukey marca entre el $9\,\%$ y el $15\,\%$ de los días con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 6.3 resume estos resultados y las Figuras A.2d y A.6 presentan los diagramas de caja e histogramas sobre los días con evento.

Tabla 6.3: Valores extremos y dispersión relativa en severidad y continuidad (días con evento, valor > 0)

Variable	n	Mediana	Máximo	CV	% IQR 1.5	% IQR 3.0
CANTIDAD_ELEMENTOS	48 375	2	2 469	3.15	14.91	11.78
CANTIDAD_USUARIOS	48 375	23	34 622	3.97	14.50	10.83
DURACION_min	48 364	417	332 395	3.56	8.94	5.36
FRECUENCIA	48 364	1	6	0.15	1.96	1.96

Tabla agrupada cuadrante $\times$ semana. Sobre `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90\,128$ observaciones, se replicó el mismo esquema excluyendo `id_cuadrante`, `latitud`, `longitud` y `altitud`. El procedimiento se documenta en el Apéndice A.3.5.

Variables climáticas semanales. El diagnóstico se realizó sobre la tabla completa. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas, baja dispersión relativa (CV entre 0.16 y 0.25) y un porcentaje muy bajo de extremos bajo Tukey (entre $0\,\%$ y $0.03\,\%$); con el factor 3.0 no se identifican extremos severos. El viento semanal es más heterogéneo (CV ≈ 0.78–0.81). La `precip_total_semana` constituye la excepción: al ser un

acumulado semanal asimétrico a la derecha con CV $= 1.17$, la regla de Tukey marca el $6.21\,\%$ de las observaciones y la ampliada el $1.79\,\%$, aunque la regla de percentiles solo señala el $0.99\,\%$. Los valores señalados corresponden a semanas de lluvia intensa operativamente plausibles: el máximo observado es de 198.1 mm acumulados en la semana, magnitud compatible con los registros de temporada de lluvia en la región. La Tabla 6.4 resume estos resultados y las Figuras A.3a y A.7 muestran los diagramas de caja y los histogramas sobre las $90\,128$ observaciones.

Tabla 6.4: Valores extremos y dispersión relativa en variables climáticas semanales (tabla agrupada)

Variable	Mediana	CV	% IQR 1.5	% IQR 3.0	% P1–P99
`temp_media_semana`	24.84	0.19	0.00	0.00	1.95
`temp_max_semana`	32.72	0.17	0.00	0.00	1.99
`temp_min_semana`	18.95	0.25	0.03	0.00	1.96
`humedad_media_semana`	72.28	0.16	0.00	0.00	1.97
`viento_medio_semana`	0.91	0.81	0.00	0.00	1.99
`viento_max_semana`	1.26	0.78	0.00	0.00	1.69
`precip_total_semana`	9.78	1.17	6.21	1.79	0.99

Variables de severidad y continuidad. En la tabla completa persisten semanas sin interrupción registrada ($Q_1 = Q_3 = 0$ en `usuarios_afectados`, `elementos_afectados` y `n_eventos`), por lo que la regla de Tukey sobre el total es poco informativa para esas variables y el CV del panel completo queda inflado por ceros (Tabla 6.7). El análisis relevante se realiza sobre semanas con evento (valor > 0), con $22\,660$–$24\,800$ registros según la variable. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha y de alta dispersión relativa: la mediana de `usuarios_afectados` es 52 usuarios pero su máximo alcanza $69\,928$ (CV $= 3.82$); `duracion_total` tiene mediana de 19.7 horas y un máximo de $2\,227$ horas (≈ 93 días acumulados; CV $= 1.73$). La regla de Tukey marca entre el $11.6\,\%$ y el $15.2\,\%$ de las semanas con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 6.5 resume estos resultados y las Figuras A.3b y A.8 presentan los diagramas de caja e histogramas.

En síntesis, en el grano cuadrante $\times$ semana los extremos climáticos son escasos y operativamente plausibles (con la precipitación acumulada como única variable de asimetría apreciable y CV superior a la unidad), mientras que en severidad y continuidad la cola pesada y el CV condicionado a semanas con evento reflejan semanas de alta afectación o múltiples eventos en un mismo cuadrante. No se aplican transformaciones ni exclusiones en esta etapa; las decisiones de tratamiento se documentan y ejecutan en la Etapa 4 a partir de este diagnóstico sobre

Tabla 6.5: Valores extremos y dispersión relativa en severidad y continuidad (semanas con evento, valor > 0)

Variable	n	Mediana	Máximo	CV	% IQR 1.5	% IQR 3.0
`usuarios_afectados`	22 660	52	69 928	3.82	15.16	11.21
`elementos_afectados`	22 660	7	3 626	2.75	15.00	10.70
`duracion_total`	24 800	19.7	2 227	1.73	11.56	4.25
`n_eventos`	22 659	1	58	1.08	14.53	5.73

la tabla de análisis.

6.3.3. Cálculo de estadísticos descriptivos

Tras el diagnóstico de completitud (Sección 6.3.1) y el análisis de valores extremos (Sección 6.3.2), se calculó un conjunto sistemático de estadísticos descriptivos sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90\,128$ observaciones cuadrante $\times$ semana. Se excluyeron las llaves y coordenadas (`id_cuadrante`, `latitud`, `longitud`, `altitud`) y se evaluaron las 11 variables numéricas de severidad, clima semanal y continuidad. El procedimiento reproducible se documenta en el Apéndice A.3.6.

Para cada variable se reportaron: (i) medidas de tendencia central (media, mediana y moda); (ii) medidas de dispersión (rango, varianza, desviación estándar y coeficiente de variación; Sección 3.1.2); (iii) medidas de posición (cuartiles, deciles y percentiles P1, P5, P95 y P99); (iv) medidas de forma (asimetría y curtosis con exceso); y (v) distribución de frecuencias de la categoría derivada *actividad semanal del cuadrante*, construida a partir de `n_eventos` (sin eventos; 1 evento; 2–5 eventos; más de 5 eventos). Las Figuras A.9 y A.3c presentan la vista panorámica de las 11 variables mediante histogramas y diagramas de caja.

Variables climáticas semanales. Las siete variables meteorológicas agregadas presentan distribuciones aproximadamente simétricas y baja dispersión relativa: el coeficiente de variación (CV) se ubica entre 0.16 (`humedad_media_semana`) y 0.81 (`viento_medio_semana`). La temperatura media semanal tiene mediana de 24.8 °C (media 23.8 °C; Q_1–Q_3: 20.4–27.2 °C) y asimetría cercana a cero (-0.37). La humedad relativa media semanal concentra la mediana en 72.3 % (CV $= 0.16$). La excepción es `precip_total_semana`: acumulado semanal con mediana de 9.8 mm, media de 16.0 mm, CV $= 1.17$ y asimetría positiva (1.98), con un recorrido de 0 a 198.1 mm y un percentil 99 de 85.1 mm que corresponde a semanas de lluvia intensa puntuales. La Tabla 6.6 resume tendencia central y dispersión; la Figura A.10 muestra las curvas de densidad.

Tabla 6.6: Estadísticos descriptivos de variables climáticas semanales (tabla agrupada)

Variable	Media	Mediana	Desv. est.	CV	Asimetría
`temp_media_semana`	23.8	24.8	4.63	0.19	−0.37
`temp_max_semana`	31.9	32.7	5.29	0.17	−0.44
`temp_min_semana`	17.9	19.0	4.49	0.25	−0.49
`humedad_media_semana`	70.9	72.3	11.5	0.16	−0.36
`viento_medio_semana`	0.99	0.91	0.80	0.81	0.44
`viento_max_semana`	1.30	1.26	1.01	0.78	0.37
`precip_total_semana`	16.0	9.8	18.7	1.17	1.98

Variables de severidad y continuidad. Las cuatro variables operativas están dominadas por ceros: la mediana de `usuarios_afectados`, `elementos_afectados`, `n_eventos` y `duracion_total` es 0 en el 74.9 % de las semanas-cuadrante sin eventos registrados (Tabla 6.8; Figura A.11). Cuando ocurre al menos un evento, las distribuciones son fuertemente leptocúrticas y con cola derecha pesada: `usuarios_afectados` alcanza un máximo de 69 928 usuarios (media 156.1; CV del panel completo = 7.81, inflado por ceros; CV condicionado a semanas con evento = 3.82); `duracion_total` un máximo de 2 227 horas acumuladas en la semana (media 13.7 h; CV completo = 3.67; CV condicionado = 1.73). La Tabla 6.7 resume las medidas principales del panel completo; la Tabla 6.5 reporta el CV condicionado; la Figura A.12 presenta las densidades en escala logarítmica desplazada (Sección 3.1.2) para semanas con evento.

Tabla 6.7: Estadísticos descriptivos de severidad y continuidad (tabla agrupada; panel completo)

Variable	Media	Mediana	Máx.	CV	Asimetría	Q_3
`usuarios_afectados`	156.1	0	69 928	7.81	20.6	1
`elementos_afectados`	12.0	0	3 626	5.74	14.1	1
`n_eventos`	0.55	0	58	2.76	8.18	1
`duracion_total`	13.7	0	2 227	3.67	10.2	2.5

Nota: el CV del panel completo queda inflado por la cero-inflación; el CV condicionado a semanas con evento se reporta en la Tabla 6.5.

Tabla 6.8: Distribución de frecuencias por actividad semanal del cuadrante

Categoría (`n_eventos`)	Frec. absoluta	Frec. relativa (%)	Frec. acumulada (%)
Sin eventos	67 469	74.86	74.86
1 evento	12 115	13.44	88.30
2 a 5 eventos	9 246	10.26	98.56
Más de 5 eventos	1 298	1.44	100.00

En síntesis, el clima semanal exhibe comportamiento estable y casi simétrico,

mientras que las variables operativas reflejan fuerte cero-inflación y colas pesadas propias del fenómeno de interrupciones. Estos perfiles, especialmente la asimetría de `precip_total_semana` y la concentración de semanas sin evento, orientan las transformaciones logarítmicas desplazadas (Sección 3.1.2) y la selección de modelos en la Etapa 4.

6.3.4. Análisis de la distribución de variables

Con el propósito de comprender el comportamiento estadístico de las variables incluidas en el estudio, se realizó un análisis de distribución sobre las variables climáticas, de severidad y de continuidad contenidas en la tabla agregada cuadrante $\times$ semana ($N_{\text{agr}} = 90\,128$; Sección 5.2.5). Para las variables cuantitativas se emplearon diagramas de densidad, complementados con indicadores de forma (asimetría, curtosis y proporción de ceros) y con el coeficiente de variación reportado en las Secciones 6.3.2–6.3.3, lo que permitió evaluar simetría, dispersión relativa, unimodalidad y presencia de valores extremos. El procedimiento reproducible se documenta en el Apéndice A.3.7.

Variables climáticas. Los resultados evidencian que las variables meteorológicas presentan distribuciones heterogéneas. Las temperaturas (media, máxima y mínima) y la humedad relativa muestran comportamientos estables, aproximadamente unimodales, con asimetría cercana a cero (entre -0.49 y -0.36) y CV bajo (0.16–0.25), coherentes con las curvas de densidad presentadas en la Figura A.10. En contraste, la precipitación acumulada semanal presenta asimetría positiva (coeficiente de 1.98 y curtosis con exceso de 4.78), CV $= 1.17$, alta frecuencia de semanas con valores bajos de lluvia (el $9.1\,\%$ registra 0 mm) y un número reducido de observaciones con precipitaciones intensas. La Figura A.13 contrasta la distribución en escala original y en escala logarítmica desplazada (Sección 3.1.2): la transformación aproxima la distribución a una forma simétrica, lo que anticipa su utilidad en la Etapa 4.

Variables de severidad y continuidad. Las variables asociadas a interrupciones del servicio (`usuarios_afectados`, `elementos_afectados`, `duracion_total` y `n_eventos`) muestran distribuciones altamente sesgadas hacia cero: la proporción de filas con valor 0 se ubica entre el $72.5\,\%$ (`duracion_total`) y el $74.9\,\%$ (resto de variables), como ilustra la Figura 6.1. Este comportamiento es esperado, dado que la mayor parte de las semanas-cuadrante no registra fallas. Sin embargo, condicionando a la ocurrencia de eventos (valor > 0), las distribuciones presentan colas derechas largas, con asimetrías entre 8.2 y 20.6 y curtosis entre 139 y 643, que reflejan la existencia de incidentes de alta severidad con impacto

significativo sobre la continuidad del servicio, según se aprecia en las densidades en escala logarítmica desplazada de la Figura A.12.

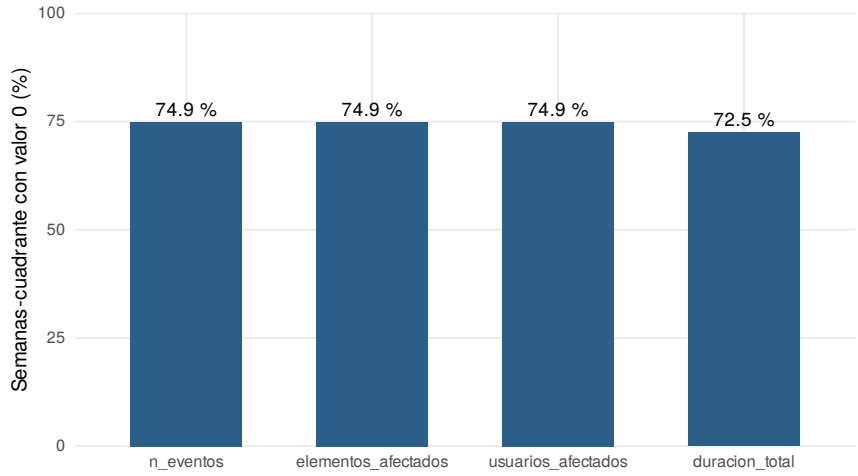


Figura 6.1: Proporción de ceros en las variables de severidad y continuidad de la tabla agrupada.

En síntesis, el análisis de distribución confirma dos regímenes claramente diferenciados: un bloque climático estable y casi simétrico (CV bajo, con la precipitación como excepción asimétrica de CV algo superior a la unidad) y un bloque operativo cero-inflado con colas pesadas y CV condicionado alto. Estos hallazgos fundamentan las transformaciones logarítmicas desplazadas (Sección 3.1.2) y la consideración de modelos aptos para datos cero-inflados en la Etapa 4.

6.3.5. Análisis temporal de eventos

Para caracterizar la dinámica temporal de las interrupciones se construyó, a partir de la tabla agregada `data_agrupada.csv` (Sección 5.2.5), la serie territorial semanal que consolida el total de `n_eventos` de todos los cuadrantes en cada semana calendario. La serie cubre 262 semanas del horizonte 2021–2025, con una mediana de 124.5 eventos por semana (media 188.5; máximo 648). El procedimiento reproducible se documenta en el Apéndice A.3.8.

Evolución de la serie semanal. La Figura A.14 presenta la serie semanal con su tendencia suavizada (LOESS) sobre el horizonte exploratorio 2021–2025 (D_{EDA}). Se distinguen dos regímenes visuales: entre 2021 y 2023 la actividad se mantiene en un nivel bajo y relativamente estable, mientras que a partir de 2024 se observa un incremento sostenido del nivel de la serie. La agregación anual (Figura A.15) cuantifica este cambio: de 5 167 eventos en 2021 y 4 934 en 2022, se pasa a 15 211 en 2024 y 18 199 en 2025; en términos de intensidad, el promedio asciende de

≈ 99 a ≈ 350 eventos por semana entre 2021 y 2025. La reinterpretación de este salto a la luz de la cobertura de integración se desarrolla en el párrafo siguiente (Sección 6.3.5).

Diagnóstico de cobertura del emparejamiento evento–elemento. Al contrastar el conteo anual de eventos en `tabla_eventos_ajustado.csv` (BRAE) con la suma territorial de `n_eventos` en `data_agrupada.csv`, se identificó un *sesgo sistemático* en el grano espacial durante 2021–2023 (Tabla 6.9; Figura 6.2). La causa no es la ausencia del campo `COMPONENTE_FALLADO`, completo en el 100 % de los registros BRAE, sino la *incompatibilidad entre esquemas de codificación* al cruzar eventos con el inventario georreferenciado `tipo_elemento.csv` (Tabla 5.5).

En la operación de la red coexisten dos identificadores para un mismo punto de conexión: (i) el *código de sitio* (ubicación), estable en el tiempo y empleado por el inventario GIS como `ELEMENTO`; y (ii) el *código de activo*, asociado al equipo instalado y *sujeto a cambio* cuando el activo se repone por mantenimiento o renovación, mientras el código de sitio permanece invariante. El panel consolidado y la agregación cuadrante $\times$ semana se construyen sobre el código de sitio. No obstante, en el sistema histórico OMS-SPARD (Sección 5.1.5) el elemento fallado (`BREAKER` $\rightarrow$ `COMPONENTE_FALLADO`) se registraba con frecuencia mediante el *código del activo* y no el del sitio. Ello impide el seguimiento histórico del punto de desconexión, unidad espacial central para el pronóstico territorial de $SAIDI$ y $SAIFI$ en esta tesis, pues el cruce `COMPONENTE_FALLADO` $=$ `ELEMENTO` no encuentra coincidencia en el inventario y el evento no genera `FRECUENCIA` en el panel activo $\times$ día.

El diagnóstico cuantitativo confirma esta hipótesis: la proporción de eventos cuyo `COMPONENTE_FALLADO` coincide con algún `ELEMENTO` de `tipo_elemento.csv` es del 30.5 % (2021), 30.9 % (2022) y 31.7 % (2023), valores cercanos a la cobertura del panel espacial en esos años (28.1 %, 28.1 % y 29.1 %, respectivamente). Con la migración a OMS-SP7 (Sección 5.1.6), la coincidencia asciende al 79.8 % (2024) y al 95.0 % (2025), acompañada por coberturas del panel del 77.7 % y 92.4 %. La Figura A.15 debe interpretarse a la luz de esta brecha: el salto a partir de 2024 refleja en gran medida una *mayor homogeneización de la codificación* bajo OMS-SP7, y no únicamente un incremento operativo de interrupciones.

El procedimiento reproducible se documenta en el Apéndice A.3.9. Con base en este hallazgo, emergido en el presente análisis temporal, se define el *dataset de modelado* D_{mod} como el subconjunto de `data_agrupada.csv` con `year(semana)` $\in \{2024, 2025\}$, que comprende 36 120 filas cuadrante $\times$ semana, 105 semanas y 33 410 eventos georreferenciados en total (15 211 en 2024 y 18 199 en 2025). El horizonte 2021–2025 se conserva como D_{EDA} para las Secciones 6.3.1–6.3.5, pero

no se empleará para estimar el modelo predictivo de la Etapa 4.

Tabla 6.9: Cobertura anual de la trazabilidad al inventario GIS y al panel espacial.

Año	Eventos BRAE	En inventario (%)	Panel espacial	Cobertura (%)
2021	18 398	30.5	5 167	28.1
2022	17 542	30.9	4 934	28.1
2023	20 068	31.7	5 845	29.1
2024	19 583	79.8	15 211	77.7
2025	19 689	95.0	18 199	92.4

Nota: "En inventario (%)" es la proporción de eventos cuyo `COMPONENTE_FALLADO` coincide con `ELEMENTO` en `tipo_elemento.csv` (código de sitio). "Panel espacial" es la suma anual de `n_eventos` en `data_agrupada.csv`. La brecha entre ambas columnas en 2021–2023 se atribuye al registro del código de activo, y no del código de sitio, en OMS-SPARD, lo que impide el seguimiento histórico del punto de desconexión. Los años 2024–2025 delimitan D_{mod}.

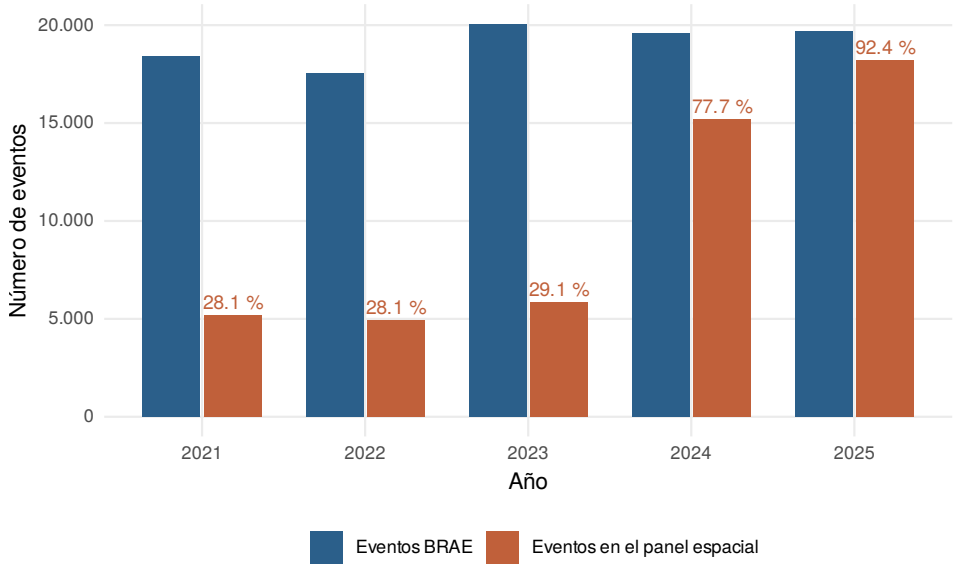


Figura 6.2: Comparación anual entre eventos BRAE y eventos reflejados en el panel espacial. Las etiquetas indican el porcentaje de cobertura respecto a BRAE; la brecha histórica se explica por la incompatibilidad entre el código de activo registrado en OMS-SPARD y el código de sitio del inventario GIS.

Estacionalidad intra-anual. La Figura A.16 muestra la distribución de los totales semanales según el mes calendario. Se aprecia heterogeneidad estacional, con mayor actividad y dispersión en algunos meses del año, patrón que motiva incorporar términos estacionales en la Etapa 4. La atribución de esta estacionalidad a la temporada de lluvias debe tomarse con cautela: como se documenta en la Sección 6.3.7, la asociación semanal entre precipitación y frecuencia de eventos es débil en el grano cuadrante $\times$ semana.

Autocorrelación temporal. Las funciones de autocorrelación simple y parcial de la serie semanal (Figura A.17) evidencian fuerte persistencia: la autocorrelación es 0.92 en el rezago de una semana y decae lentamente (0.60 a 12 semanas; 0.38 a 26), manteniéndose significativa frente al intervalo de confianza del $95\,\%$ bajo ruido blanco (± 0.12). Adicionalmente, el rezago de 52 semanas conserva una autocorrelación de 0.43, indicativa de un componente estacional anual. Esta estructura justifica la incorporación de rezagos y términos estacionales como variables predictoras en la Etapa 4.

Evolución de la severidad y extensión territorial. La Figura A.18 presenta las series semanales de usuarios afectados y duración acumulada: ambas acompañan el incremento de nivel observado en la frecuencia de eventos a partir de 2024, lo que indica que el cambio de régimen no es solo de conteo sino también de impacto sobre la continuidad del servicio. Complementariamente, la Figura A.19 muestra el número de cuadrantes con al menos un evento por semana, que crece en paralelo: la mayor actividad reciente se distribuye sobre una porción más amplia del territorio y no se explica por unos pocos cuadrantes puntuales.

En síntesis, el análisis temporal sobre D_{EDA} revela: (i) un cambio de nivel de la serie a partir de 2024, reinterpretado como mayor homogeneización de la codificación activo/sitio bajo OMS-SP7, y no como incremento operativo aislado, lo que motiva la restricción del dataset de modelado a D_{mod} (2024–2025; Sección 6.3.5); (ii) estacionalidad intra-anual en la actividad de interrupciones, cuya atribución al régimen de lluvias no se sostiene con el acumulado semanal de precipitación (Sección 6.3.7); y (iii) fuerte persistencia semanal con componente anual, que fundamenta el uso de rezagos temporales como predictores en D_{mod}. Estos hallazgos orientan la generación de ventanas temporales y la partición de datos de la Etapa 4.

Materialización de D_{mod}. Para operacionalizar la delimitación temporal sin alterar el insumo exploratorio, se construyó el archivo `data_agrupada_mod.csv` como subconjunto de `data_agrupada.csv` con filtro `year(semana)` $\in \{2024, 2025\}$, conservando el grano cuadrante $\times$ semana y el conjunto completo de variables climáticas y operativas. La tabla original 2021–2025 permanece intacta como D_{EDA}; el resultado filtrado ($36\,120$ filas; 344 cuadrantes; 105 semanas; $33\,410$ eventos) constituye el insumo analítico para las Secciones 6.3.6 en adelante y la Etapa 4, con partición natural entrenamiento 2024 / prueba 2025. El procedimiento reproducible, lectura, filtro, resumen por año y exportación, se documenta en el Apéndice A.3.10.

Enriquecimiento de D_{mod}. Sobre la llave cuadrante–semana se incorporaron 16 variables destinadas a ampliar la caracterización de exposición, composición de usuarios y trayectoria de intervención de los activos. La serie mensual `data_usuarios_totales_sistema.csv` aporta `usuarios_totales`, asignada a cada semana de acuerdo con el mes calendario de su fecha de inicio y utilizada como denominador en la construcción de SAIDI y SAIFI. Por otra parte, `cant_usuarios_x_transformador.csv` aporta `cantidad_usuarios_cuadrante`, calculada como la suma mensual de usuarios de los transformadores asociados a cada cuadrante.

La composición socioeconómica y de uso del servicio se integró desde `DATA_ESTRATO_SECTOR.csv`, agregando por cuadrante y mes las variables `ESTRATO_1` a `ESTRATO_6`, `INDUSTRIAL`, `COMERCIAL`, `OFICIAL`, `PROVISIONAL` y `ALUMBRADO_PUBLICO`. Para los meses faltantes de los cuadrantes 258 y 273 se empleó la moda mensual del respectivo cuadrante; los cuadrantes 68, 140, 333 y 344, ausentes en la fuente, se asignaron en cero.

Finalmente, se integró el archivo `Fecha_transformadores.csv` mediante la llave `ID_CUADRANTE`. Para cada elemento se contabilizaron sus registros de modificación y se tomó la última `TT2_FMODIFICACION` en estado `OPERACION`; posteriormente, por cuadrante, se derivaron `FECHA_ACTIVO_MAS_VIEJO`, `FECHA_ACTIVO_MAS_NUEVO` y `PROM_CANT_MODIFICACIONES`. Estas variables permiten evaluar la relación entre la trayectoria de intervención de la infraestructura y los indicadores de continuidad. No obstante, las fechas representan modificaciones registradas y no necesariamente la instalación original del activo. Para evitar fuga de información, su uso predictivo debe restringirse a registros conocidos antes de la semana pronosticada; SAIDI y SAIFI se emplean exclusivamente como variables objetivo.

6.3.6. Identificación de patrones, tendencias y visualización exploratoria

Con fundamento en la delimitación de D_{mod} (Sección 6.3.5), se identifican patrones temporales, espaciales y de asociación clima–evento sobre la tabla `data_agrupada_mod.csv` ($36\,120$ filas cuadrante $\times$ semana; 344 cuadrantes; 105 semanas; $33\,410$ eventos en 2024–2025). En esta misma subsección se integra la *visualización exploratoria* sobre D_{mod}: series de tiempo, diagramas de dispersión y mapas temáticos que complementan el análisis cuantitativo de patrones. El procedimiento reproducible se documenta en el Apéndice A.3.11.

Patrones temporales. La Figura 6.3 presenta la serie semanal territorial de eventos en D_{mod}, con media de ≈ 318 eventos por semana. Aunque las etiquetas

del eje horizontal se muestran cada 3 meses para facilitar la lectura, cada tramo de la linea corresponde a observaciones semanales consecutivas. La intensidad promedio asciende de 287 eventos/semana en 2024 a 350 en 2025. La estacionalidad mensual (Figura A.20) confirma la heterogeneidad entre meses observada en la Sección 6.3.5 sobre D_{EDA}, sin que el acumulado semanal de lluvia explique ese patrón. La ACF de la serie semanal (Figura 6.4) mantiene persistencia elevada (rezago $1 = 0.80$), lo que respalda el uso de rezagos como predictores en la Etapa 4.

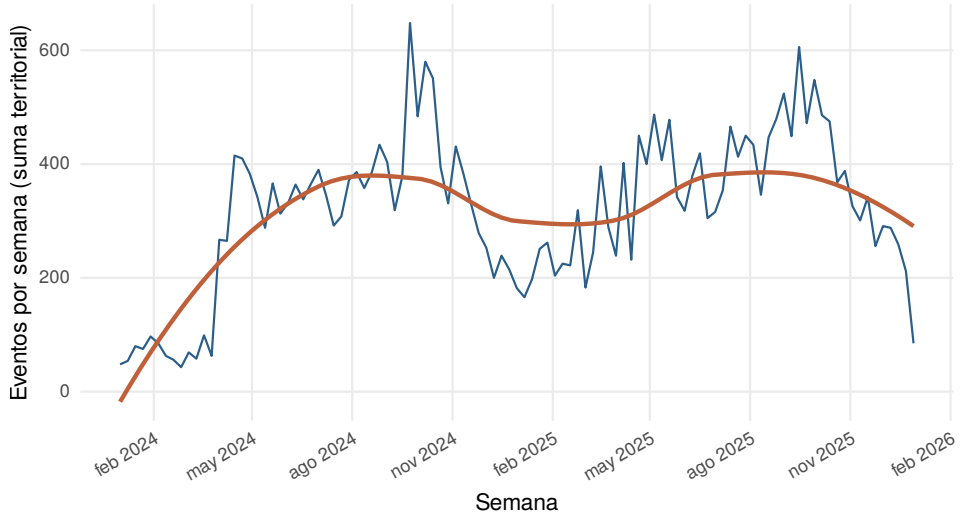


Figura 6.3: Evolución semanal de eventos sobre D_{mod} (2024–2025).

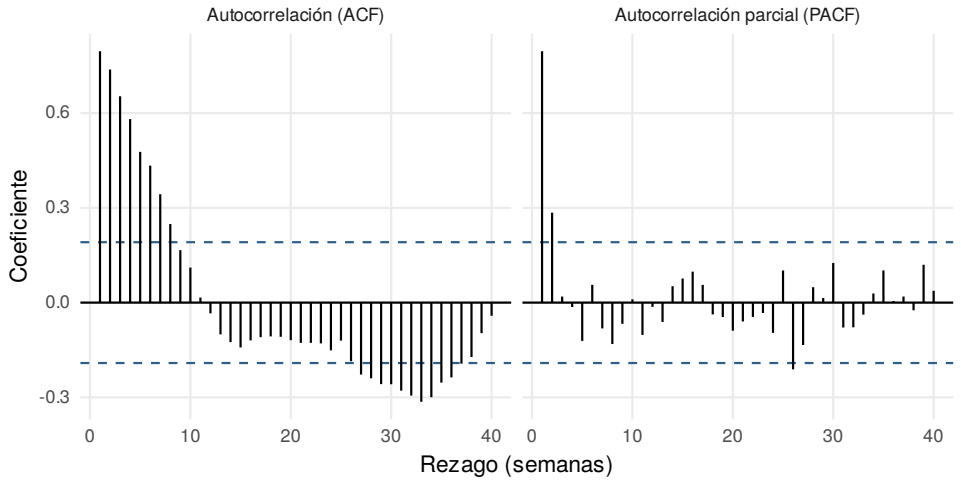


Figura 6.4: Persistencia y estructura temporal de la serie semanal de eventos en D_{mod}.

Patrones espaciales. El ranking de cuadrantes por total de `n_eventos` (Figura A.21) y el mapa de intensidad territorial (Figura 6.5) evidencian heterogeneidad espacial: los diez cuadrantes más activos concentran el 20.5 % de los eventos del periodo, mientras el 14.2 % de los cuadrantes (49 de 344) se clasifica en nivel de actividad *alta* (Figura A.23). La actividad no se distribuye de forma uniforme sobre la malla de 800 cuadrantes, sino que se agrupa en zonas de mayor exposición operativa.

La Figura A.3d complementa el ranking anterior con la *ubicación geográfica* de los cuadrantes más activos sobre la malla territorial del área de estudio. Los recuadros resaltados corresponden a los primeros cuadrantes *top* del periodo 2024–2025 y muestran una concentración en cuatro zonas: (i) el área metropolitana de Cúcuta y Villa del Rosario; (ii) un corredor al suroccidente, en torno a Salazar, Arboledas, Durania y Chinácota; (iii) la subregión de Tibú, al norte del departamento; y (iv) los municipios de Ocaña y Aguachica, al occidente. Esta distribución espacial confirma que la mayor actividad de interrupciones no es aleatoria, sino que se agrupa en núcleos urbanos y corredores de servicio de la red.

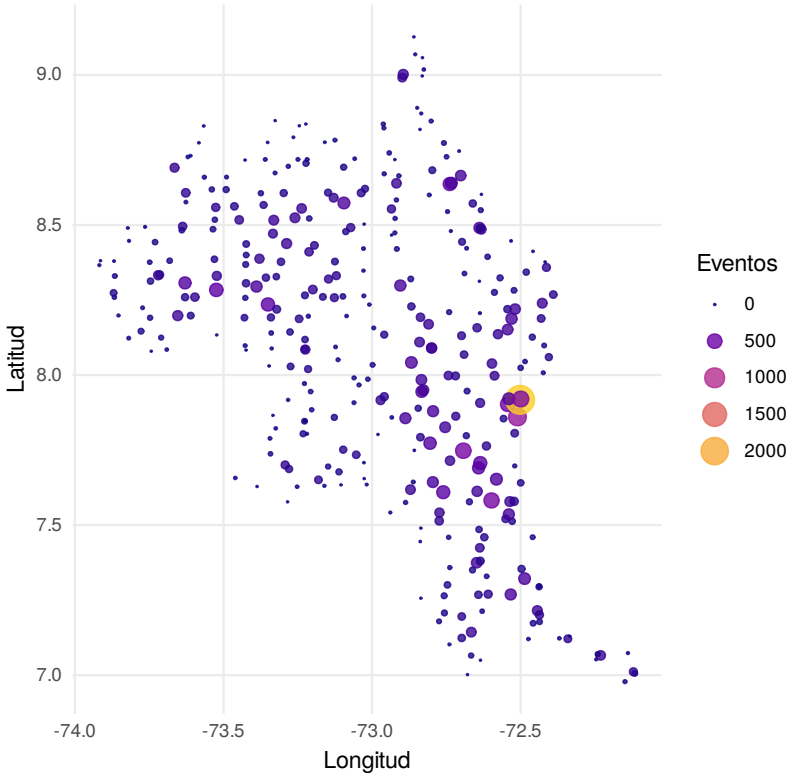


Figura 6.5: Intensidad territorial de eventos por cuadrante (2024–2025).

Patrones clima–evento. Mediante la estimación de la correlación de Spearman a nivel cuadrante × semana, las variables de viento exhiben la asociación positiva más fuerte con `n_eventos` (`viento_max_semana`: $\hat{\rho} = 0.14$; `viento_medio_semana`: $\hat{\rho} = 0.14$; $p < 0.001$), seguidas de la precipitación acumulada semanal (`precip total semana`: $\hat{\rho} = 0.07$) y la humedad ($\hat{\rho} = 0.05$). La Figura A.22 ilustra la relación entre precipitación y frecuencia de eventos: la nube muestra una tendencia positiva leve, sin un patrón fuerte. Las temperaturas presentan asociaciones débiles y negativas ($|\hat{\rho}| < 0.05$). En el grano semanal, por tanto, la señal climática es de magnitud modesta y está encabezada por el viento, no por la lluvia.

En síntesis, el análisis de patrones y la visualización exploratoria sobre D_{mod} confirman: (i) persistencia y estacionalidad temporal (series semanales, estacionalidad mensual y ACF); (ii) concentración espacial en un subconjunto de cuadrantes (ranking, mapa de intensidad y segmentación por actividad); y (iii) asociación positiva pero débil entre las covariables meteorológicas y la frecuencia de interrupciones, encabezada por el viento y seguida por la precipitación (correlación de Spearman y diagrama de dispersión). Estos hallazgos orientan la selección de variables predictoras y la estratificación territorial de la Etapa 4. Los mapas de calor de correlaciones y el análisis multivariado formal se desarrollan en las Secciones 6.3.7 y 6.3.8.

6.3.7. Análisis de correlación y asociación

Con fundamento en los patrones preliminares de la Sección 6.3.6, se realizó un análisis sistemático de asociación pareada sobre `data_agrupada_mod.csv` (D_{mod}; 36 120 filas cuadrante × semana). Dado el carácter asimétrico, cero-inflado y de colas pesadas de las variables operativas (Sección 6.3.4), se empleó el coeficiente de correlación de *Spearman* en lugar de Pearson. El procedimiento reproducible se documenta en el Apéndice A.3.12.

Matriz de asociación global. Se calcularon las correlaciones de Spearman entre las variables operativas (`n_eventos`, `usuarios_afectados`, `elementos_afectados`, `duracion_total`), las siete variables climáticas semanales y las coordenadas geográficas (`altitud`, `latitud`, `longitud`). La Figura 6.6 resume la submatriz clima–operativo. Los pares con mayor asociación absoluta del panel completo concentran redundancia operativa: `usuarios_afectados`–`elementos_afectados` ($\rho = 0.99$), `n_eventos`–`elementos_afectados` ($\rho = 0.98$) y `n_eventos`–`usuarios_afectados` ($\rho = 0.97$). Parte de esta magnitud es *mecánica*: las tres métricas provienen de la misma tabla de eventos, comparten la masa de ceros en semanas sin interrupción y, al agregarse por suma, crecen juntas

cuando aumenta el número de eventos. Por ello no deben interpretarse como evidencia de tres dimensiones independientes ni usarse simultáneamente como respuesta y predictoras; la definición definitiva del rol de la severidad se aplaza a la Etapa 4.

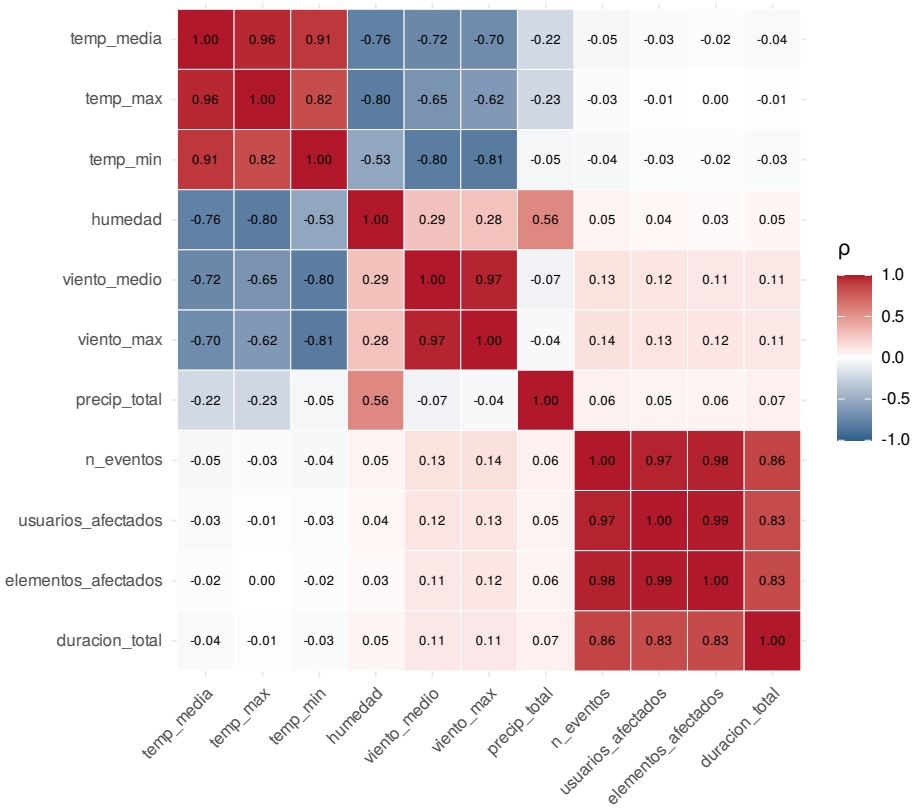


Figura 6.6: Asociación de Spearman entre variables climáticas y operativas en D_{mod}.

Bloque climático: redundancias. En el bloque meteorológico (Figura A.24) se identificaron *diez* pares con $|\rho| \geq 0.70$, principalmente entre temperaturas (`temp_media`–`temp_max`: $\rho = 0.96$; `temp_media`–`temp_min`: $\rho = 0.91$) y entre componentes de viento ($\rho = 0.97$). Las temperaturas presentan además asociación negativa moderada con la humedad ($\rho \approx -0.76$ a -0.80) y con el viento ($\rho \approx -0.70$ a -0.81). La precipitación no participa en ninguno de estos pares: su mayor asociación dentro del bloque queda por debajo del umbral, lo que la señala como la única covariable climática no redundante. Estos resultados anticipan *multicolinealidad* entre temperaturas y vientos, y orientan la depuración de variables en la Etapa 4.

Bloque operativo. La Figura A.25 muestra que las cuatro métricas de continuidad y severidad están fuertemente correlacionadas entre sí (ρ entre 0.83 y 0.99), aunque `duracion_total` exhibe una asociación algo menor con `n_eventos` ($\rho = 0.86$) que con las variables de afectación. Frecuencia y duración capturan dimensiones parcialmente distintas; el alcance (`usuarios_afectados`, `elementos_afectados`) queda, en esta construcción, muy alineado con la frecuencia y se trata aquí como diagnóstico exploratorio de severidad, no como predictor independiente.

Clima → operativo. La Figura A.26 y la Tabla 6.10 cuantifican la asociación entre covariables meteorológicas y métricas de interrupción. Todas las asociaciones son estadísticamente significativas, consecuencia esperable del tamaño del panel, pero de magnitud pequeña. Las variables de *viento* encabezan el bloque: `viento_max_semana` con `n_eventos` ($\rho = 0.139$) y `viento_medio_semana` con `n_eventos` ($\rho = 0.135$), con valores del mismo orden frente a `usuarios_afectados` ($\rho \approx 0.12$), `elementos_afectados` ($\rho \approx 0.11$) y `duracion_total` ($\rho \approx 0.11$). La `precip_total_semana` le sigue con asociaciones positivas débiles ($\rho = 0.069$ con `duracion_total` y $\rho = 0.065$ con `n_eventos`), mientras la humedad ($\rho \approx 0.05$) y las temperaturas ($|\rho| < 0.05$, con signo negativo) resultan prácticamente irrelevantes en el grano semanal.

Conviene precisar el alcance de este resultado. La magnitud reducida de la asociación no implica ausencia de efecto físico de la lluvia sobre la red, sino que el acumulado semanal por cuadrante es un descriptor grueso del fenómeno: promedia días secos y días de tormenta, y no captura la intensidad horaria ni la coincidencia temporal exacta entre el evento meteorológico y la desconexión. Con este descriptor, la asociación bivariada disponible en el grano cuadrante × semana es débil, y así se reporta.

Tabla 6.10: Asociación Spearman entre clima y variables operativas: pares de mayor magnitud (D_{mod}; panel completo)

Par de variables	**Spearman ρ**	**p-valor**
`viento_max_semana` ↔ `n_eventos`	0.139	< 0.001
`viento_medio_semana` ↔ `n_eventos`	0.135	< 0.001
`viento_max_semana` ↔ `usuarios_afectados`	0.125	< 0.001
`viento_max_semana` ↔ `duracion_total`	0.112	< 0.001
`precip_total_semana` ↔ `duracion_total`	0.069	< 0.001
`precip_total_semana` ↔ `n_eventos`	0.065	< 0.001
`precip_total_semana` ↔ `elementos_afectados`	0.056	< 0.001
`precip_total_semana` ↔ `usuarios_afectados`	0.053	< 0.001
`humedad_media_semana` ↔ `n_eventos`	0.054	< 0.001
`temp_media_semana` ↔ `n_eventos`	$-0{,}047$	< 0.001

Análisis condicionado. Dado que el 63 % de las filas cuadrante × semana registra `n_eventos` $= 0$, se repitió el análisis sobre el subconjunto con al menos un evento (13 351 filas; 37 % del panel). En este régimen la asociación precipitación–`n_eventos` se atenúa aún más ($\rho = 0.029$) y el viento conserva la primacía ($\rho = 0.097$ para `viento_max_semana`), lo que indica que la escasa señal climática se concentra en la transición entre semanas sin y con interrupción, y no en la intensidad condicional de los eventos. La Figura A.27 resume las correlaciones en este subconjunto.

En síntesis, el análisis de correlación sobre D_{mod} confirma: (i) *alta redundancia* entre variables operativas de severidad y entre temperaturas/vientos del bloque climático; (ii) una *señal climática débil en términos bivariados*, encabezada por el viento ($\rho \approx 0.14$) y seguida por la precipitación ($\rho \approx 0.07$); y (iii) *asociaciones prácticamente nulas* de temperatura y humedad en el grano semanal. Estos hallazgos fundamentan conservar `viento_medio_semana` y `precip_total_semana` como candidatas climáticas, sujetas a la regla de disponibilidad *ex ante* (rezago o pronóstico; Sección 3.1.2), la exclusión de variables climáticas redundantes y la fijación de la respuesta en `n_eventos` y/o `duracion_total`, dejando `usuarios_afectados` y `elementos_afectados` fuera del conjunto de predictoras contemporáneas (impacto posterior). Asimismo advierten que la Etapa 4 no debe apoyarse únicamente en covariables meteorológicas de la misma semana: la estructura temporal y territorial de la propia serie de eventos (Secciones 6.3.5 y 6.3.9) concentra la mayor parte de la señal predictiva disponible. El análisis multivariado formal (VIF, redundancia simultánea) se desarrolla en la Sección 6.3.8.

6.3.8. Evaluación inicial de relaciones multivariadas

Con fundamento en las redundancias bivariadas identificadas en la Sección 6.3.7, se evaluaron las relaciones *simultáneas* entre covariables sobre D_{mod} mediante VIF, PCA exploratorio, agrupamiento jerárquico de variables climáticas, correlación parcial y un GLM Poisson de diagnóstico (Sección 3.1.2). El procedimiento reproducible se documenta en el Apéndice A.3.13.

Multicolinealidad climática (VIF). Se estimó un modelo auxiliar lineal `n_eventos` $\sim$ bloque climático completo para calcular el VIF de cada covariable. La Figura 6.7 muestra VIF elevados en `temp_media_semana` (43.92), `viento_medio_semana` (24.22), `viento_max_semana` (22.58), `temp_max_semana` (17.27) y `temp_min_semana` (14.37), mientras `precip_total_semana` (1.50) presenta inflación baja y `humedad_media_semana` (5.68) apenas moderada. Al restringir el bloque a `precip_total_semana`, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana`, los VIF descienden a valores aceptables (máximo 7.21 en

temperatura media; Tabla 6.11).

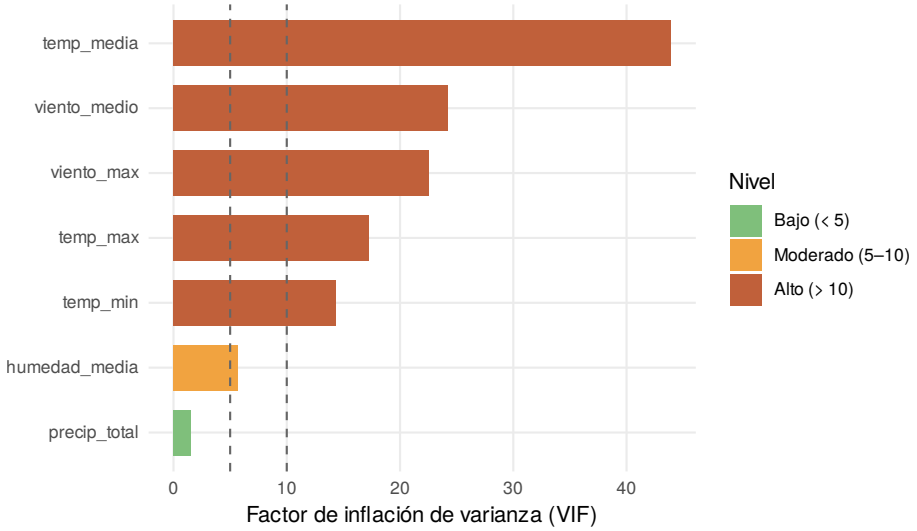


Figura 6.7: Inflación de varianza en el bloque climático (modelo auxiliar `n_eventos` ∼ `clima`; D_{mod}).

Tabla 6.11: Inflación de varianza con subconjunto climático reducido propuesto para la Etapa 4

Variable	VIF
`temp_media_semana`	7.21
`humedad_media_semana`	4.47
`viento_medio_semana`	3.27
`precip_total_semana`	1.49

Se realizó adicionalmente un PCA exploratorio del bloque climático como diagnóstico de redundancia (no como fuente de predictoras finales); no se emplea como paso obligatorio del modelado. El detalle completo (variables de entrada, condiciones de aplicación, varianza retenida y cargas) se documenta en el Apéndice A.10.

Agrupamiento jerárquico. El dendrograma de la Figura A.28 confirma dos clusters principales: (i) temperaturas y vientos, altamente intercorrelados; y (ii) `precip_total_semana`, relativamente aislada. Este resultado valida la exclusión de `temp_max_semana`, `temp_min_semana` y `viento_max_semana` del conjunto predictor reducido.

Asociación multivariada clima → `n_eventos`. La correlación parcial de Spearman entre precipitación y `n_eventos`, controlando `temp_media_semana` y

`viento_medio_semana`, es $\rho = 0.114$, casi el doble del valor bivariado ($\rho = 0.065$). El aumento al condicionar indica que temperatura y viento, correlacionadas con la precipitación, enmascaraban parcialmente su asociación con los eventos; aun así, la magnitud sigue siendo modesta. Un GLM Poisson exploratorio con el subconjunto reducido (Figura A.29) arroja coeficientes positivos y significativos para las cuatro covariables, con la temperatura media estandarizada ($\hat{\beta} = 0.81$) y el viento medio estandarizado ($\hat{\beta} = 0.73$) como efectos dominantes, seguidos de la humedad ($\hat{\beta} = 0.35$) y de la precipitación en transformación logarítmica desplazada ($\hat{\beta} = 0.13$; todos con $p < 0.001$). Este contraste con el orden bivariado, donde las temperaturas eran irrelevantes, es consistente con la multicolinealidad diagnosticada por el VIF y refuerza que los coeficientes del bloque climático completo no admiten lectura causal individual; se reportan como diagnóstico exploratorio. El supuesto de equidispersión del modelo de Poisson no se cumple: la varianza de `n_eventos` (4.39) casi quintuplica su media (0.92) y el estadístico de dispersión de Pearson es 3.82. Un modelo binomial negativo con las mismas covariables reduce el AIC de 117 787 a 89 960 (razón de verosimilitud = 27 830; $p < 0.001$; $\hat{\theta} = 0.41$) y reproduce la proporción observada de semanas sin eventos (63.2 % frente a 63.0 % observado, contra 43.0 % del Poisson). Los coeficientes apenas cambian (temperatura 0.75, viento 0.70, humedad 0.34 y precipitación 0.14), pero sus errores estándar casi se duplican; todos siguen siendo significativos ($p < 0.001$). La sobredispersión y el exceso de ceros documentados aquí son los que motivan, en la Etapa 5, modelar la magnitud condicional a la ocurrencia de falla y estimar la ocurrencia por separado (Sección 5.4.11).

De forma análoga se aplicó un PCA exploratorio al bloque operativo (frecuencia, afectación y duración) para delimitar dimensiones de impacto, sin emplearlo como fuente de predictoras. El detalle completo se documenta en el Apéndice A.10.

En síntesis, la evaluación multivariada sobre D_{mod} recomienda: (i) predictoras climáticas `precip_total_semana`, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana`, justificadas por loadings, VIF y dendrograma (el PCA no se usa como modelo predictivo, sino como diagnóstico de redundancia); (ii) $SAIFI$ y $SAIDI$ como variables respuesta del modelado, construidas en la Etapa 4; (iii) exclusión de temperaturas extremas y viento máximo por redundancia simultánea; (iv) expectativas moderadas sobre la capacidad explicativa del bloque meteorológico contemporáneo, dado el tamaño reducido de las asociaciones observadas, lo que hace aconsejable complementarlo con rezagos de la propia serie de eventos y con la estratificación territorial; y (v) uso de `usuarios_afectados` solo en el numerador de Y, no como predictora contemporánea. Estos

criterios se operacionalizan en la depuración cuantitativa y la construcción de matrices de diseño de la Etapa 4.

6.3.9. Segmentación exploratoria

Con fundamento en la segmentación territorial introducida en la Sección 6.3.6, se profundizó la heterogeneidad de D_{mod} mediante perfiles comparativos por nivel de actividad, evolución 2024–2025, estratificación por régimen de precipitación semanal y clustering multivariado de cuadrantes. El procedimiento reproducible se documenta en el Apéndice A.3.14.

Perfiles por nivel de actividad. Sobre los 344 cuadrantes del periodo, la clasificación Baja/Media/Alta (cuantiles P50 y P85 entre cuadrantes con eventos) arroja: 162 cuadrantes baja (47.1 %), 113 media (32.8 %) y 49 alta (14.2 %); 20 cuadrantes (5.8 %) no registraron eventos. Los perfiles acumulados, resumidos en la Figura A.30, muestran escalamiento marcado en las variables operativas: media de 22 eventos por cuadrante en nivel baja frente a 114.6 en media y 344.7 en alta, con usuarios afectados medios de 1 588 a 88 534. El clima, en cambio, no acompaña ese escalamiento: la precipitación semanal media desciende ligeramente de 19.6 mm (baja) a 18.5 mm (media) y 17.0 mm (alta), de modo que los estratos de mayor actividad no son los más lluviosos. La Figura A.4a confirma que la dispersión semanal de `n_eventos` crece con el estrato territorial.

Evolución 2024 vs 2025 por estrato. El total territorial ascendió de 15 211 eventos en 2024 (287/semana) a 18 199 en 2025 (350/semana). Al desagregar por nivel fijado en el periodo completo, el ratio medio 2025/2024 es homogéneo: 1.24 (baja), 1.26 (media) y 1.24 (alta), lo que indica incremento transversal sin reordenamiento fuerte de la jerarquía territorial (Figura A.31). El crecimiento observado en 2024–2025 debe interpretarse en coherencia con la homogeneización de codificación activo/sitio bajo OMS-SP7 (Sección 6.3.5), no exclusivamente como deterioro operativo.

Régimen climático semanal. Se estratificaron las filas según el percentil 75 de `precip_total_semana` (24.7 mm). Las semanas lluviosas (25 % de las filas; 9 030 observaciones) presentan media de `n_eventos` de 0.918, prácticamente igual a la de las semanas secas (0.927; 75 %; 27 090 filas), con 37.7 % frente a 36.7 % de semanas con al menos un evento. La prueba de Wilcoxon no detecta diferencia significativa ($p = 0.175$; Figura A.4b), resultado consistente con la débil asociación bivariada precipitación–eventos de la Sección 6.3.7. La dicotomización por umbral resulta así insuficiente para separar regímenes operativos: si la lluvia

tiene efecto, opera a través de la intensidad de episodios puntuales y no del acumulado semanal, lo que sugiere explorar en la Etapa 4 indicadores de intensidad diaria o de número de días de lluvia dentro de la semana.

Clustering multivariado de cuadrantes. Se aplicó k-means ($k = 4$) sobre cuadrantes con al menos un evento, con variables estandarizadas de frecuencia, severidad, duración, clima y altitud (Sección 3.1.2; excluyendo covariables de varianza nula). El mapa de la Figura 6.8 y el heatmap de la Figura A.32 distinguen: C3 (1 cuadrante; 2 224 eventos; hub extremo), C1 (139 cuadrantes; media 107.4 eventos; mayor severidad y duración acumulada, altitud media 496 m), C4 (126 cuadrantes; media 97.7 eventos; el estrato de mayor altitud, 1 741 m) y C2 (58 cuadrantes; media 68.0 eventos; el más lluvioso, 26.2 mm semanales, y el de menor duración acumulada). Que el cluster más lluvioso sea también el de menor actividad refuerza que la precipitación no ordena por sí sola el territorio; la altitud y el perfil de severidad discriminan más. La existencia de un hub aislado y de estratos con perfiles distinguibles respalda evaluar modelado global frente a estratificación por cluster en la Etapa 4.

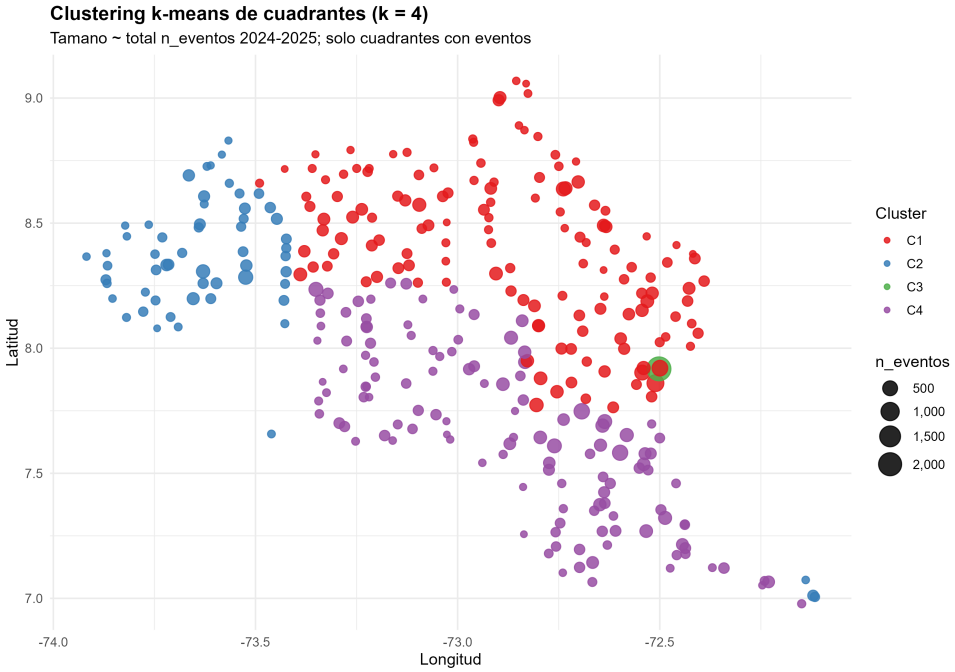


Figura 6.8: Perfiles territoriales de cuadrantes según actividad y clima ($k = 4$; D_{mod}).

En síntesis, la segmentación exploratoria sobre D_{mod} evidencia: (i) heterogeneidad territorial persistente (14.2 % de cuadrantes en nivel alta concentran actividad desproporcionada); (ii) incremento homogéneo 2024→2025 en todos los

estratos; (iii) *ausencia* de diferencia significativa en la frecuencia de interrupciones entre semanas lluviosas y secas cuando la lluvia se mide como acumulado semanal; y (iv) cuatro perfiles espaciales distinguibles por clustering, ordenados principalmente por severidad y altitud más que por régimen de lluvia. Estos criterios orientan la estratificación territorial y la partición entrenamiento/prueba de la Etapa 4.

6.3.10. Resultados y entregables de la etapa

La Etapa 3 sobre D_{mod} (2024–2025; 36 120 filas cuadrante $\times$ semana) produjo un diagnóstico exploratorio integrado: calidad y distribución de variables (Secciones 6.3.1–6.3.4), delimitación temporal y materialización del panel de modelado (Sección 6.3.5), patrones y visualización (Sección 6.3.6), correlación bivariada (Sección 6.3.7), evaluación multivariada con recomendación de predictoras y respuesta (Sección 6.3.8) y segmentación territorial (Sección 6.3.9). Los hallazgos convergentes son: (i) señal climática contemporánea *débil* en el grano semanal (viento por delante de precipitación); (ii) *redundancia* en bloques operativo y climático que justifica subconjuntos reducidos, con la severidad (`usuarios_afectados`, `elementos_afectados`) altamente alineada a `n_eventos` en parte por construcción; (iii) *taxonomía de tres grupos* (Sección 3.1.2): predictoras disponibles *ex ante*, respuestas $SAIFI/SAIDI$, e impacto posterior excluido como predictor contemporáneo; (iv) *heterogeneidad espacial* y clusters territoriales que sugieren estratificación en el modelado; y (v) la necesidad de una *partición temporal estricta*, sin muestreo aleatorio, dentro del periodo de cobertura homogénea del emparejamiento evento–elemento. Los informes HTML reproducibles se consolidan en el Apéndice A.3; el *entregable ejecutivo consolidado* corresponde al Apéndice A.3.15 (síntesis de las Secciones 6.3.1–6.3.10 con hallazgos, figuras representativas y lineamientos para la Etapa 4). La ingeniería de variables de la Etapa 4 operacionaliza esa taxonomía, incluidos rezagos climáticos y operativos y, si procede, la reelaboración de la métrica de severidad solo con fines descriptivos.

Resultado: conocimiento exploratorio del comportamiento de los datos y hallazgos relevantes para el modelado.

Entregable: Documento de análisis descriptivo y exploratorio (EDA), Apéndice A.3.15.

6.3.11. Síntesis de los hallazgos del análisis exploratorio

El diagnóstico de completitud sobre la tabla agregada ($N_{\text{agr}} = 90\,128$) no encontró valores faltantes: las 16 variables registran 0 % de datos ausentes y ninguna fila queda incompleta (Sección 6.3.1; Apéndice A.3.3, informe HTML).

Este resultado no debe interpretarse como ausencia de incompletitud en el proyecto, sino como consecuencia del grano de agregación: los valores ausentes del bloque climático y de `ALTITUD` se originan en el panel activo $\times$ día y quedan absorbidos por las reglas de resumen semanal, que operan sobre los días efectivamente disponibles de cada cuadrante. La tabla agregada hereda, por tanto, una completitud estructural que no exige imputación en la Etapa 4, pero cuya interpretación requiere conocer el grano en el que se originó la incompletitud.

El análisis de valores extremos (Sección 6.3.2; Apéndice A.3.4, informe HTML) muestra que las variables climáticas diarias tienen baja dispersión relativa (CV entre 0.16 y 0.20) y una proporción marginal de extremos bajo la regla de Tukey, con la precipitación como excepción esperada (CV $= 2.12$; Tabla 6.2). En los días con evento, la severidad y la continuidad muestran alta dispersión relativa y colas pesadas: la duración de interrupción tiene una mediana de 417 minutos pero un máximo de $332\,395$ minutos (CV $= 3.56$), y el número de usuarios afectados una mediana de 23 pero un máximo de $34\,622$ (CV $= 3.97$; Tabla 6.3). Estos extremos no se excluyen del modelado, porque corresponden a interrupciones reales y de alto impacto. En la Etapa 5 se documentó su efecto mediante una regla explícita: se marcaron los cuadrantes–semana cuyo indicador supera el percentil 99.5 del entrenamiento (65 casos, el $0.49\,\%$ de las semanas con falla) y se reestimó el Random Forest con la respuesta recortada en ese umbral, como análisis de sensibilidad (Sección 6.5.2).

El análisis de correlación identificó redundancia operativa: los pares `usuarios_afectados`–`elementos_afectados` ($\rho = 0.99$), `n_eventos`–`elementos_afectados` ($\rho = 0.98$) y `n_eventos`–`usuarios_afectados` ($\rho = 0.97$) presentan la mayor asociación del panel (Sección 6.3.7; Apéndice A.3.12, informe HTML), en buena parte por construcción compartida desde la misma tabla de eventos. El diagnóstico de multicolinealidad climática (VIF) confirmó inflación severa en el bloque completo de variables meteorológicas (máximo VIF $= 43.92$ en temperatura media), que se redujo a valores aceptables (máximo 7.21) al restringir el bloque a precipitación, temperatura media, humedad media y viento medio (Sección 6.3.8; Apéndice A.3.13, informe HTML).

Estas dos redundancias tienen orígenes distintos y exigen tratamientos distintos, distinción que resultó determinante para la Etapa 4. La redundancia operativa es *mecánica*: las cuatro métricas provienen de la misma tabla de eventos, comparten la masa de ceros de las semanas sin interrupción y crecen conjuntamente con el número de eventos, de modo que su correlación no refleja una relación empírica sino la aritmética de la agregación. La redundancia climática es, en cambio, *física*: temperatura media, máxima y mínima miden el mismo fenómeno térmico con resoluciones distintas, y el viento medio y máximo lo pro-

pio con el régimen de viento. La primera se resolvió por decisión de rol —fijar la respuesta en los indicadores construidos y excluir la severidad del conjunto predictor—, mientras que la segunda se resolvió por selección de representantes dentro de cada bloque.

En conjunto, estos hallazgos —señal climática contemporánea débil, redundancia en los bloques operativo y climático, y la taxonomía de tres grupos de variables (predictoras *ex ante*, respuestas y variables de impacto posterior; Sección 3.1.2)— definen los criterios de selección de variables aplicados en la ingeniería de la Etapa 4. En particular, la debilidad de la señal climática contemporánea no condujo a descartar el bloque meteorológico, sino a reformular su forma de entrada: lo que el EDA descarta es la utilidad del clima *simultáneo* como predictor, no la del clima acumulado o rezagado, hipótesis que la Etapa 4 operacionaliza mediante `precip_ma4` y `viento_ma4`. El análisis exploratorio consolidado se documenta en el Apéndice A.3.15 (informe HTML).

6.4. Etapa 4 – Resultados de la ingeniería de variables

El resultado de esta etapa es el panel analítico final de modelado: un conjunto de predictoras restringido a variables disponibles *ex ante* de la semana a pronosticar (clima rezagado, histórico de eventos, características del cuadrante y estacionalidad), con las variables de impacto posterior (`usuarios_afectados`, `elementos_afectados`) excluidas explícitamente como predictoras contemporáneas (Sección 5.2.7). Se incorporaron rezagos espaciales de vecinos (`SAIDI_vecinos_lag1`, `SAIFI_vecinos_lag1`, `ndvi_vecinos`) mediante contigüidad *queen*, y transformaciones logarítmicas $\log(1 + \text{SAIDI})$ y $\log(1 + \text{SAIFI})$ para estabilizar la varianza de las variables respuesta.

El producto concreto de la etapa es la partición del conjunto de columnas del panel en cuatro clases disjuntas (Sección 5.4.9; Tabla 5.11). Las dos **variables respuesta** son SAIDI y SAIFI, estimadas como `log_SAIDI1` y `log_SAIFI1` en modelos independientes. Las **predictoras** quedaron en 18 variables de siete bloques temáticos, todas medidas en la semana anterior o constantes en el tiempo —clima, vegetación, exposición externa, topología de red, composición socioeconómica, activos y mantenimiento, y dinámica temporal y espacial—, seleccionadas desde un conjunto inicial de 44 candidatas disponibles en el panel enriquecido. Las **llaves** (`id_cuadrante`, `semana` y las coordenadas) no actúan como covariables sustantivas sino como índices de absorción en las especificaciones de efectos fijos y como insumo de la matriz de vecindad. Finalmente, el bloque de **exclusiones deliberadas** comprende las variables de impacto posterior, los insumos contemporáneos de construcción de la respuesta (`n_eventos`$_t$, `duracion_`

`total`$_t$, admitidos solo rezagados) y la respuesta cruzada contemporánea.

Esta última categoría condiciona la lectura de todas las métricas del siguiente apartado: las variables de impacto posterior, en particular `usuarios_afectados`, son las de mayor asociación con ambos indicadores, pero quedan fuera por la razón expuesta en la partición de columnas de la Sección 5.4 (ecuación (5.1)). Las métricas de la Sección 6.5 se obtienen, por tanto, bajo esa restricción de información.

La reducción de 44 a 18 predictoras se obtuvo mediante la secuencia de filtros descrita en la Sección 5.4.3, estimada exclusivamente sobre el conjunto de entrenamiento. En el bloque cuantitativo *ex ante* evaluado de forma independiente sobre D_{mod}, de 27 candidatas se retuvieron 13, con el descarte de las temperaturas por redundancia con el eje térmico ya representado y de los promedios móviles del histórico por multicolinealidad con los rezagos simples. En el bloque cualitativo, la depuración concluyó que la información del estrato predominante municipal ya estaba contenida, con mayor resolución, en las proporciones `prop_estrato_*`, por lo que la matriz final privilegia la representación continua. Ninguna variable fue eliminada del panel: la depuración opera sobre la matriz de diseño, de modo que especificaciones alternativas son reconstruibles sin reejecutar la cadena de integración de las Etapas 1 y 2.

La partición temporal quedó documentada en dos niveles consistentes entre sí: la frontera anual 2024/2025, que coincide con el límite natural de D_{mod}, y el *holdout* del 15 % final de semanas efectivamente aplicado en la estimación, que sobre las 105 semanas disponibles reserva aproximadamente las últimas dieciséis. Ambos esquemas son estrictamente cronológicos; en ningún caso se empleó muestreo aleatorio, dada la autocorrelación de 0.80 en el primer rezago sobre D_{mod}.

Este panel, materializado en `data_final_modelo_cuadrantes_reales.rds`, constituye el insumo directo para el entrenamiento y la validación de los modelos de la Etapa 5. Su construcción y verificación se documentan en los Apéndices A.3.26 (informe HTML), A.3.27 (informe HTML) y A.3.16 (informe HTML).

6.5. Etapa 5 – Resultados del modelado predictivo y evaluativo

Los resultados de esta sección corresponden a la re-estimación final de la Etapa 5 (`Etapa5_03_reestimacion_cierre.R`; Apéndice A.3.30), que incorpora tres cambios respecto de los informes preliminares: (i) todas las predictoras observadas en la semana s entran rezagadas una semana; (ii) las variables sísmicas se reconstruyeron tras corregir dos errores de integración (Sección 5.2.7); y (iii) el

desempeño se contrasta contra dos pronósticos de referencia. Con el panel original y la especificación original, el código reproduce las cifras de los informes preliminares (por ejemplo, RMSE de 0.1666 para *Pooled* OLS y de 0.1340 para FE de cuadrante en SAIDI), lo que garantiza que las diferencias que se reportan a continuación se deben a esos tres cambios y no a la implementación.

6.5.1. Dependencia espacial

El diagnóstico de dependencia espacial confirmó autocorrelación positiva y significativa en el promedio por cuadrante tanto de SAIDI (índice de Moran $I = 0.154$; $p < 0.001$) como de SAIFI ($I = 0.179$; $p < 0.001$), y en el corte transversal ponderado ($I = 0.146$ y $I = 0.240$, respectivamente; $p < 0.001$). La magnitud es moderada: la vecindad territorial explica una parte identificable pero no dominante de la variación, lo que justifica incorporar rezagos espaciales y estimar SAR y SEM, sin anticipar que estos dominen a los modelos no espaciales.

6.5.2. Pronóstico semanal frente a pronósticos de referencia

Las Tablas 6.12 y 6.13 presentan el desempeño en el conjunto de prueba (2 215 cuadrantes–semana con falla entre el 15 de septiembre y el 29 de diciembre de 2025) de los modelos de panel y de dos pronósticos de referencia: la *persistencia*, que pronostica para cada cuadrante el valor de su semana anterior, y la *media del cuadrante*, que pronostica su promedio histórico en el entrenamiento. El MASE expresa el MAE de cada modelo como fracción del MAE de la persistencia, de modo que valores menores que uno indican mejora sobre ella. El modelo de efectos fijos de cuadrante y semana no es evaluable fuera de muestra, porque las semanas de prueba no tienen efecto fijo estimado (Sección 5.5.3), y no se incluye en las tablas.

Tabla 6.12: Desempeño en el conjunto de prueba para SAIDI (escala $\log(1+y)$; $N = 2\,215$)

Modelo	RMSE	MAE	R^2	MASE	ΔRMSE vs. persistencia
Persistencia ($t-1$)	0.1278	0.0377	0.120	1.000	–
Media del cuadrante	0.1021	0.0358	0.208	0.948	$-20.1\,\%$
Pooled OLS	0.1016	0.0374	0.196	0.991	$-20.5\,\%$
FE cuadrante	**0.1013**	0.0376	**0.216**	0.996	$-20.7\,\%$
Random Forest (valores por defecto)	0.1236	0.0576	0.192	1.528	$-3.2\,\%$
Random Forest ajustado	0.1143	0.0536	0.192	1.422	$-10.6\,\%$

Tres resultados se desprenden de las tablas y se confirman con la prueba de Diebold–Mariano sobre los errores cuadráticos (Tabla 6.14). Primero, los modelos lineales superan con claridad a la persistencia: el RMSE se reduce entre un 20 y un

Tabla 6.13: Desempeño en el conjunto de prueba para SAIFI (escala $\log(1+y)$; $N = 2\,215$)

Modelo	RMSE	MAE	R^2	MASE	ΔRMSE vs. persistencia
Persistencia ($t-1$)	0.00324	0.00081	0.085	1.000	–
Media del cuadrante	**0.00237**	**0.00071**	**0.261**	**0.880**	$-26.9\,\%$
Pooled OLS	0.00243	0.00077	0.218	0.959	$-25.0\,\%$
FE cuadrante	0.00239	0.00073	0.257	0.908	$-26.3\,\%$
Random Forest (valores por defecto)	0.00273	0.00109	0.224	1.348	$-15.7\,\%$
Random Forest ajustado	0.00255	0.00105	0.218	1.304	$-21.3\,\%$

27 %, y la diferencia es significativa para FE de cuadrante en ambos indicadores ($p < 0.001$). Segundo, ninguno de ellos supera de forma significativa a la media histórica del cuadrante: para SAIDI, FE de cuadrante reduce el RMSE en un $0.8\,\%$ ($p = 0.11$), y para SAIFI la media del cuadrante es incluso marginalmente mejor ($p = 0.03$). Tercero, Random Forest es inferior a FE de cuadrante en ambos indicadores ($p < 0.001$), aun después del ajuste de hiperparámetros, y su MASE mayor que uno indica que, en error absoluto medio, no mejora siquiera a la persistencia.

Tabla 6.14: Prueba de Diebold–Mariano sobre los errores cuadráticos de prueba (horizonte de una semana)

	SAIDI		SAIFI	
Comparación	**DM**	**valor p**	**DM**	**valor p**
FE cuadrante vs. persistencia	-3.30	< 0.001	-3.38	< 0.001
FE cuadrante vs. media del cuadrante	-1.61	0.108	2.15	0.032
Random Forest ajustado vs. FE cuadrante	4.32	< 0.001	5.11	< 0.001

Nota: un estadístico negativo indica que el primer modelo tiene menor error cuadrático que el segundo.

La lectura conjunta es consistente: casi toda la capacidad predictiva semanal proviene del *nivel propio de cada cuadrante*. El R^2 *within* del modelo FE, que mide la variación explicada dentro de cada cuadrante a lo largo del tiempo, es de apenas 0.023 para SAIDI y 0.003 para SAIFI. Una vez conocido el nivel típico de afectación del cuadrante, las variables que cambian de semana a semana —clima rezagado, NDVI, sismicidad y rezago de los vecinos— aportan muy poca información adicional sobre la magnitud de la semana siguiente. El único término dinámico con efecto robusto es el rezago propio de SAIDI ($\hat{\gamma} = 0.044$; $p < 0.001$ con errores agrupados por cuadrante y $p = 0.009$ con errores de Driscoll–Kraay); ninguna variable climática, de vegetación o sísmica rezagada resulta significativa en ninguno de los dos indicadores. Este resultado precisa la pregunta de investigación: la parte pronosticable de la afectación es territorial

y estable, y la variación semanal alrededor de ese nivel se comporta, con la información disponible, como esencialmente impredecible.

Los diagnósticos de supuestos respaldan el uso de errores estándar robustos en esta inferencia. La prueba de Breusch–Pagan rechaza la homocedasticidad en ambos indicadores (estadísticos de $1\,473$ y 825; $p < 0.001$), por lo que todos los contrastes se basan en errores agrupados por cuadrante y en errores de Driscoll–Kraay, que además toleran correlación serial y espacial contemporánea. Los residuos del modelo FE de SAIDI conservan una autocorrelación de primer orden pequeña pero significativa (0.051; $p < 0.001$), mientras que los de SAIFI no la presentan (-0.005; $p = 0.59$). Los factores de inflación de varianza del modelo agrupado son altos para el par `prop_estrato_1`–`prop_estrato_2` (31 y 29) y moderados para `n_elementos` y `longitud_red_km` (17 y 16); ninguna variable con efecto semanal significativo tiene un VIF superior a 2, de modo que la colinealidad no explica la ausencia de significancia de las variables dinámicas, aunque sí obliga a leer con cautela los coeficientes individuales de estrato.

El bajo desempeño de Random Forest tiene una explicación coherente con lo anterior. La búsqueda de hiperparámetros (Tabla 6.15 y Figura 6.9) seleccionó en ambos indicadores el valor mínimo de `mtry` (2) y nodos terminales grandes (20 observaciones para SAIDI y 50 para SAIFI), es decir, la configuración más regularizada de la grilla. Ese patrón es el esperado cuando la señal es débil y el modelo tiende a ajustar ruido. Además, Random Forest es sensible a la cola de la distribución: al recortar la respuesta de entrenamiento en su percentil 99.5, que afecta a 65 cuadrantes–semana ($0.49\,\%$ de las semanas con falla), su RMSE de prueba en SAIDI baja de 0.1143 a 0.1014, al nivel de los modelos lineales (Sección 6.3.11).

Tabla 6.15: Ajuste de hiperparámetros del Random Forest: mejores configuraciones según la validación temporal interna

Indicador	`mtry`	Tamaño mínimo de nodo	RMSE OOB	RMSE validación interna
SAIDI	2	20	0.1098	0.1251
	2	50	0.1101	0.1253
	2	5	0.1099	0.1258
SAIFI	2	50	0.00276	0.00257
	6	50	0.00278	0.00263
	4	50	0.00277	0.00264

Nota: grilla de 6×4 combinaciones (`mtry` $\in \{2, 4, 6, 9, 13, 18\}$; tamaño mínimo de nodo $\in \{5, 10, 20, 50\}$), estimadas con `ranger` (500 árboles) sobre el entrenamiento hasta el 2 de junio de 2025 y evaluadas en las semanas de entrenamiento posteriores. El conjunto de prueba no interviene en el ajuste.

La estabilidad del resultado se verificó con validación de origen móvil en cuatro cortes sucesivos (diciembre de 2024, marzo, junio y septiembre de 2025), cada

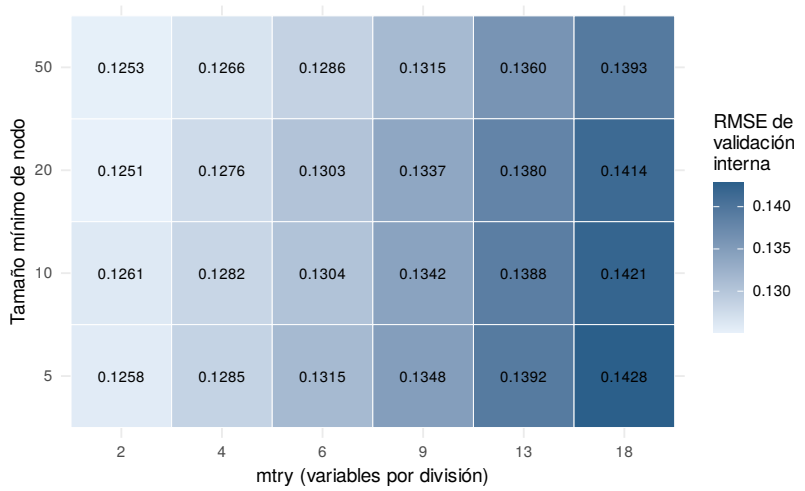


Figura 6.9: RMSE de validación interna del Random Forest de SAIDI según `mtry` y tamaño mínimo de nodo. La figura de SAIFI, con el mismo patrón, se incluye en el informe de la Etapa 5.

uno evaluado sobre las doce semanas siguientes (Tabla 6.16). FE de cuadrante supera a la persistencia en los cuatro cortes y en ambos indicadores. Frente a Random Forest, FE es mejor en tres de los cuatro cortes para SAIFI y en dos de los cuatro para SAIDI, con un RMSE medio menor en ambos casos. La dispersión entre cortes es del mismo orden que las diferencias entre modelos, lo que confirma que la ventaja de FE sobre Random Forest es estable pero pequeña, y que la ventaja de ambos sobre la persistencia es la única diferencia grande y sistemática.

Tabla 6.16: Validación de origen móvil: RMSE medio (desviación estándar) en cuatro cortes, escala $\log(1 + y)$

Modelo	SAIDI	SAIFI
Persistencia $(t - 1)$	0.132 (0.028)	0.00308 (0.00040)
FE cuadrante	0.107 (0.017)	0.00231 (0.00022)
Random Forest ajustado	0.111 (0.020)	0.00249 (0.00029)

6.5.3. Pronóstico de la ocurrencia de falla

Los modelos anteriores pronostican la magnitud *condicional* a que ocurra al menos una falla. Para completar el esquema en dos partes señalado en la Sección 5.4.11, se estimó un clasificador Random Forest de la ocurrencia de falla (`hubo_falla`) sobre el panel completo, con las mismas predictoras *ex ante* más el indicador de falla de la semana anterior. En el conjunto de prueba alcanza un área bajo la curva ROC de 0.838, frente a 0.720 de la regla de persisten-

cia ("habrá falla si la hubo la semana anterior"). A diferencia de la magnitud, la ocurrencia sí es pronosticable con una precisión útil para la operación: permite ordenar los cuadrantes según su probabilidad de registrar una falla la semana siguiente. Combinando ambas partes, el valor esperado incondicional $\mathbb{E}[Y] = P(\text{falla}) \times \mathbb{E}[Y \mid \text{falla}]$ ordena las observaciones de prueba con una correlación de Spearman de 0.46 para SAIDI y 0.39 para SAIFI.

6.5.4. Explicación estructural en corte transversal

Para la explicación del patrón territorial se agregó cada indicador como promedio ponderado por cuadrante a lo largo de 2024–2025 ($N = 343$ cuadrantes) y se estimaron OLS, SAR y SEM. La Tabla 6.17 resume la comparación. Para SAIDI, las pruebas de multiplicadores de Lagrange robustas favorecen la especificación de rezago (RLM_{lag}: $p < 0.001$) y SAR mejora el AIC del OLS en 39 unidades, con un parámetro $\hat{\rho} = -0.32$ ($p < 0.001$). Para SAIFI, la evidencia favorece débilmente al error espacial (RLM_{err}: $p = 0.030$): SEM mejora el AIC en menos de dos unidades, con $\hat{\lambda} = -0.21$ ($p = 0.049$). En ambos casos los residuos del OLS no presentan autocorrelación espacial significativa (Moran de residuos: $p = 0.37$ y $p = 0.91$).

Tabla 6.17: Modelos de corte transversal ($N = 343$): comparación OLS, SAR y SEM

	SAIDI	**SAIFI**
AIC OLS	-1265.8	-4266.0
AIC SAR	$\mathbf{-1305.2}$	-4264.1
AIC SEM	-1263.9	$\mathbf{-4267.9}$
$\hat{\rho}$ (SAR)	-0.315 ($p < 0.001$)	-0.003 ($p = 0.96$)
$\hat{\lambda}$ (SEM)	-0.035 ($p = 0.77$)	-0.210 ($p = 0.049$)
Moran de residuos OLS	-0.007 ($p = 0.37$)	-0.054 ($p = 0.91$)
R^2 OLS (en muestra)	0.901	0.838
R^2 validación cruzada espacial (5 bloques)	0.419	0.762
R^2 con control de $\log(1 + \text{usuarios del cuadrante})$	0.912	0.838
Caída de R^2 al excluir `n_elementos`	0.252	0.181
Prueba de permutación (500 réplicas)	$p < 0.002$	$p < 0.002$

El signo negativo de los parámetros espaciales requiere interpretación, porque el índice de Moran de la respuesta es positivo. Las dos afirmaciones son compatibles: los cuadrantes vecinos se parecen entre sí principalmente porque comparten infraestructura y exposición, y una vez que las covariables absorben esa similitud, el remanente espacial es negativo. Una explicación plausible, no verificada con los datos disponibles, es la forma en que se asignan los eventos: cada interrupción se atribuye íntegramente al cuadrante del elemento fallado, aunque sus usuarios afectados se distribuyan sobre cuadrantes vecinos del mismo circuito, lo que concentra la afectación en un cuadrante y la sustrae de los

adyacentes.

El ajuste dentro de muestra es alto ($R^2 = 0.90$ para SAIDI y 0.84 para SAIFI), significativo frente a la prueba de permutación y robusto al control por el número de usuarios del cuadrante. Dos verificaciones adicionales matizan su lectura. Primero, el ajuste descansa en buena medida en una sola variable: excluir `n_elementos` reduce el R^2 en 0.25 (SAIDI) y 0.18 (SAIFI). Segundo, al predecir cada bloque de cuadrantes con un modelo estimado sobre los demás (validación cruzada espacial por franjas de latitud), el R^2 desciende a 0.42 para SAIDI y se mantiene en 0.76 para SAIFI. El patrón territorial de SAIFI es, por tanto, transferible entre zonas; el de SAIDI lo es solo en parte, lo que es coherente con que la duración dependa además de factores locales de accesibilidad y capacidad de respuesta que el modelo no observa. Las Tablas 6.18 y 6.19 presentan los coeficientes de las especificaciones seleccionadas por AIC paso a paso.

Tabla 6.18: Corte transversal de SAIDI promedio por cuadrante, modelo *stepwise* ($N = 343$; $R^2 = 0.900$)

Predictor	**Coeficiente**	**valor p**
n_elementos	4.48×10^{-4}	< 0.001
longitud_red_km	-9.14×10^{-4}	< 0.001
edad_activo_mas_viejo_anios	-2.65×10^{-2}	< 0.001
ndvi_promedio	7.25×10^{-2}	0.007
prop_no_residencial	-1.27×10^{-1}	0.029
PROM_CANT_MODIFICACIONES	1.67×10^{-2}	0.078
prop_estrato_2	1.09×10^{-2}	0.095

Tabla 6.19: Corte transversal de SAIFI promedio por cuadrante, modelo *stepwise* ($N = 343$; $R^2 = 0.837$)

Predictor	**Coeficiente**	**valor p**
n_elementos	3.65×10^{-6}	< 0.001
longitud_red_km	-3.99×10^{-6}	0.018
dist_sismo_prom_km	7.49×10^{-6}	0.011
edad_activo_mas_viejo_anios	-1.13×10^{-4}	0.058

6.5.5. Variables más relevantes: triangulación entre modelos

La Tabla 6.20 reúne, para cada variable, la evidencia de las tres fuentes previstas en la Sección 5.5.7: la importancia por permutación del Random Forest ajustado (Figura 6.10 y Figura 6.11), los coeficientes del modelo FE del panel semanal y los del corte transversal. Una variable se considera relevante si aparece en al menos dos de ellas: entre las seis primeras por importancia en el Random Forest, con coeficiente significativo al $5\,\%$ en el modelo FE, o retenida y significativa al $5\,\%$

en el corte transversal.

Tabla 6.20: Triangulación de la relevancia de las variables entre modelos

	RF (rango)		FE semanal		Corte transversal		
Variable	SAIDI	SAIFI	SAIDI	SAIFI	SAIDI	SAIFI	**Veredicto**
`n_elementos`	2	1	abs.	abs.	$+^{***}$	$+^{***}$	Relevante
`longitud_red_km`	1	2	abs.	abs.	$-^{***}$	$-^{*}$	Relevante
`prop_estrato_1, _2`	3–4	3–4	n.s.	n.s.	$+^{\cdot}$	no ret.	Parcial
`prop_no_residencial`	5	6	n.s.	n.s.	$-^{*}$	no ret.	Relevante (SAIDI)
`ndvi` (propio y vecinos)	6–7	7–8	n.s.	n.s.	$+^{**}$	no ret.	Relevante (SAIDI)
`edad_activo_mas_viejo_anios`	11	10	n.s.	n.s.	$-^{***}$	$-^{\cdot}$	Solo corte transversal
Exposición sísmica	17–18	>10	n.s.	n.s.	no ret.	$+^{*}$	Débil (SAIFI)
Clima rezagado	8–16	>8	n.s.	n.s.	no ret.	no ret.	No relevante
Rezago propio ($t-1$)	13	>10	$+^{***}$	n.s.	–	–	Solo SAIDI semanal
Rezago de vecinos ($t-1$)	14	5	$+^{*}$	n.s.	–	–	Débil

Nota: rango de importancia por permutación entre 18 predictoras. FE semanal con errores agrupados por cuadrante; "abs.": variable constante en el tiempo, absorbida por el efecto fijo. Corte transversal: modelo seleccionado paso a paso (Tablas 6.18 y 6.19); "no ret.": no retenida por el AIC. *** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$; $^{\cdot}$ $p < 0.10$; n.s.: no significativa.

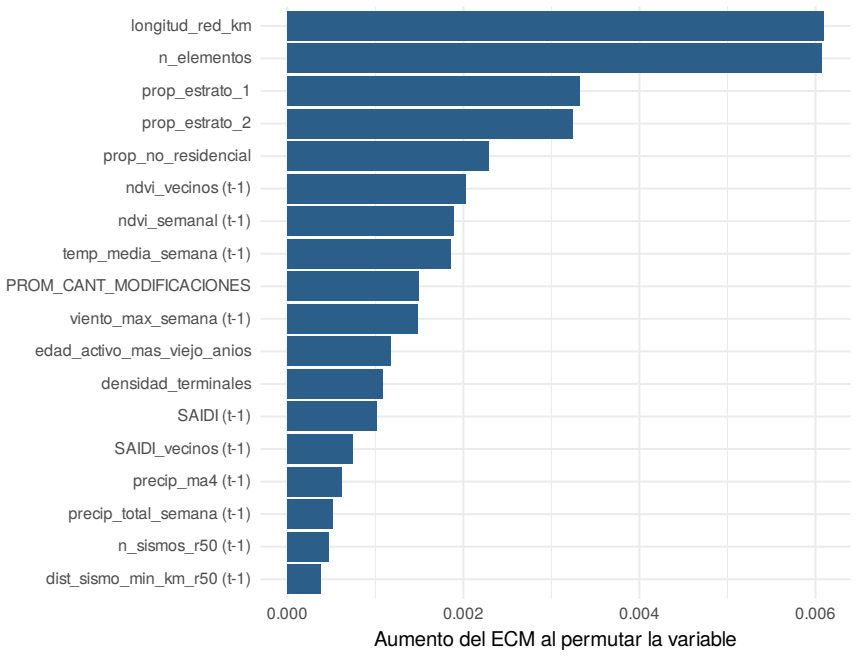


Figura 6.10: Importancia por permutación de las predictoras en el Random Forest ajustado de SAIDI.

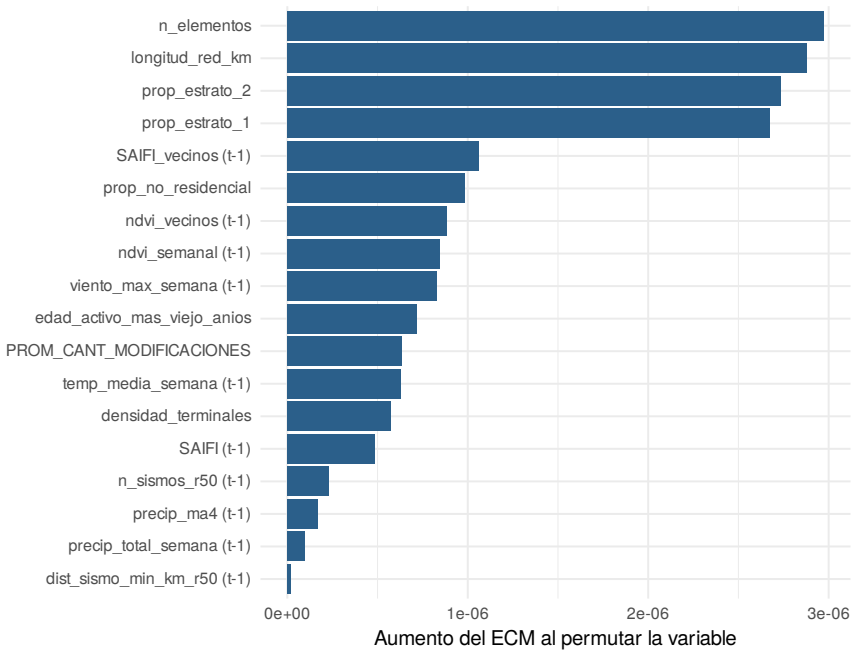


Figura 6.11: Importancia por permutación de las predictoras en el Random Forest ajustado de SAIFI.

La convergencia se limita a las variables de *tamaño y forma de la red*: el número de elementos y la longitud de red son las dos primeras en importancia en ambos Random Forest y las más significativas en ambos cortes transversales. Para SAIDI se suman la vegetación (NDVI) y la proporción de clientes no residenciales. La antigüedad del activo más viejo solo es significativa en el corte transversal, y con signo negativo. Las variables que cambian de semana a semana (clima, NDVI y sismicidad rezagados) no resultan significativas en ningún modelo de panel, lo que es coherente con el bajo R^2 *within* documentado arriba. Las proporciones de estrato ocupan posiciones altas en el Random Forest pero no son significativas en los modelos lineales; como son atributos fijos de cada cuadrante, es probable que el bosque las use como identificadores del cuadrante, es decir, como sustituto del efecto fijo, más que como un efecto socioeconómico propiamente dicho.

Dos signos merecen comentario porque podrían leerse como contraintuitivos. El coeficiente de `longitud_red_km` es negativo, pese a que una red más extensa expone más activos a falla. Condicionada al número de elementos, la longitud deja de medir exposición y pasa a aproximar el carácter rural y disperso del cuadrante: a igual número de activos, mayor longitud implica menor densidad de usuarios y, por tanto, menor contribución a un indicador ponderado por usuarios afectados. El coeficiente negativo de `edad_activo_mas_viejo_anios` no puede leerse como un efecto de la antigüedad. La variable se construye sobre

la última fecha de modificación registrada, y el 67 % de esas fechas corresponde a 2026, posterior al periodo de estudio, de modo que la "edad" es negativa en el 93.2 % de las filas (Apéndice A.4). Lo que mide es la distancia temporal a la última intervención registrada: un valor más negativo indica un cuadrante intervenido más recientemente, lo que puede reflejar que las intervenciones se dirigen a las zonas con más fallas. Con esta lectura, el signo negativo es coherente, pero la variable no permite concluir nada sobre el efecto del envejecimiento de la red. Ambas interpretaciones son plausibles pero no se verifican con los datos disponibles, y se señalan como hipótesis para trabajo posterior.

Las Figuras 6.12 y 6.13 contrastan los valores observados y pronosticados por FE de cuadrante en el conjunto de prueba. La nube se concentra en una banda estrecha de valores pronosticados para cada cuadrante, mientras los valores observados se dispersan en todo el rango: es la expresión gráfica de que el modelo anticipa el nivel del cuadrante, pero no la magnitud de la semana concreta.

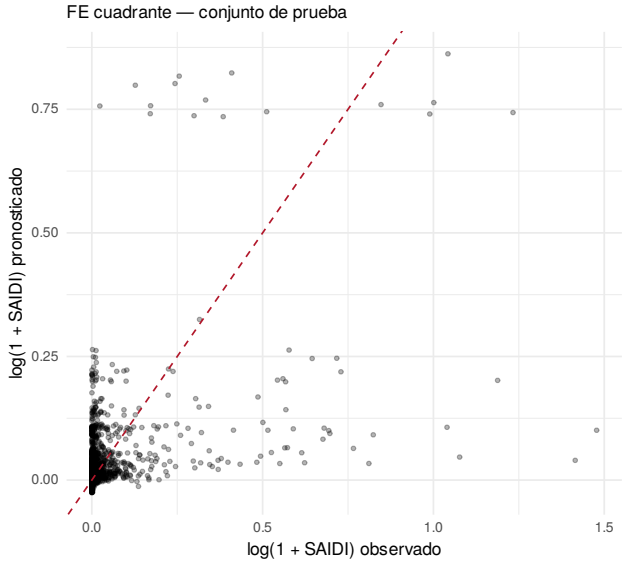


Figura 6.12: SAIDI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1 + y)$).

En síntesis: **para el pronóstico semanal de la magnitud, FE de cuadrante es el modelo de mejor desempeño en ambos indicadores**, superior a la persistencia y a Random Forest, pero estadísticamente equivalente a pronosticar el promedio histórico de cada cuadrante; **la ocurrencia de falla sí es pronosticable** (AUC de 0.84); y **para la explicación del patrón territorial, SAR (SAIDI) y SEM (SAIFI) son los modelos preferidos por AIC**, con un ajuste alto dominado por el tamaño de la red y transferible entre zonas en el caso de SAIFI.

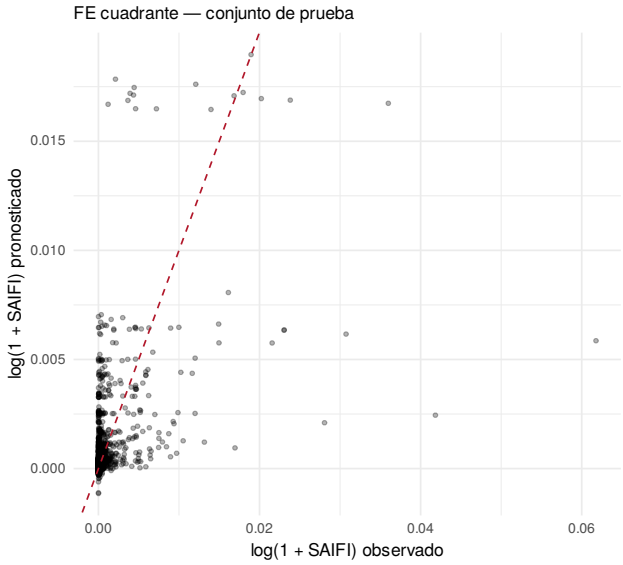


Figura 6.13: SAIFI observado frente a pronosticado por FE de cuadrante en el conjunto de prueba (escala $\log(1+y)$).

6.6. Etapa 6 – Síntesis general y cierre frente a los objetivos

El proyecto recorrió las seis etapas metodológicas descritas en el Capítulo 5 y produjo, de forma trazable y reproducible, un flujo completo desde la extracción de datos crudos hasta modelos predictivos y estructurales validados para SAIDI y SAIFI. La Tabla 6.21 resume el resultado principal de cada etapa.

La Tabla 6.22 articula estos resultados con los tres objetivos específicos del proyecto (Sección 2), evidenciando su cumplimiento.

Tabla 6.21: Síntesis de resultados por etapa metodológica

Etapa	Resultado principal
Etapa 1	Seis fuentes consolidadas (BRAE, OMS SPARD/SP7, GIS, NASA POWER); $95\,280$ eventos depurados y 83.5 millones de registros climáticos.
Etapa 2	Panel activo–día ($N = 87\,007\,074$) y panel cuadrante–semana ($N_{\text{agr}} = 90\,128$); detección de un sesgo sistemático de emparejamiento 2021–2023 que delimitó el dataset de modelado D_{mod} (2024–2025).
Etapa 3	Sin datos faltantes en la tabla agregada; redundancia identificada entre severidad y frecuencia; señal climática contemporánea débil; multicolinealidad climática corregida (VIF máximo de 43.92 a 7.21).
Etapa 4	Panel analítico final con partición explícita de columnas: 2 respuestas (SAIDI, SAIFI en escala $\log(1+y)$), 18 predictoras *ex ante* seleccionadas de 44 candidatas, llaves de identificación y un bloque de exclusiones deliberadas (impacto posterior y respuesta cruzada contemporánea); rezagos temporales y espaciales de vecinos construidos sin fuga de información.
Etapa 5	FE de cuadrante como mejor modelo de pronóstico semanal en ambos indicadores: 20–26 % menos RMSE que la persistencia, pero estadísticamente equivalente a la media histórica del cuadrante; ocurrencia de falla pronosticable (AUC $= 0.84$); SAR (SAIDI) y SEM (SAIFI) preferidos por AIC en el corte transversal (R^2 de 0.90 y 0.84; 0.42 y 0.76 en validación cruzada espacial); autocorrelación espacial significativa en ambos indicadores.
Etapa 6	Documentación reproducible de las seis etapas en informes HTML con URL estable (Apéndice A.3) y código fuente de extracción e integración (Apéndice A.2), con trazabilidad verificable entre cada afirmación del documento y su evidencia computacional.

Tabla 6.22: Cierre de resultados frente a los objetivos específicos

Objetivo específico	**Resultado que lo responde**
1. Consolidar las fuentes de datos relevantes, documentando cobertura, calidad y limitaciones mediante un catálogo de datos y métricas de integridad.	Tabla de linaje de datos (Tabla 5.7) con las seis fuentes, sus reglas de depuración y su resultado; diagnóstico de completitud sin valores faltantes; identificación y documentación explícita del sesgo de cobertura 2021–2023 como limitación conocida (Sección 6.2).
2. Determinar qué variables operativas, técnicas y climáticas son más relevantes para predecir SAIDI y SAIFI mediante modelos estadísticos o de Machine Learning.	Triangulación entre la importancia del Random Forest, los coeficientes del panel FE y los del corte transversal (Tabla 6.20): las variables técnicas de tamaño y forma de la red (número de elementos y longitud de red) son las más relevantes para ambos indicadores; la vegetación (NDVI) y la proporción de clientes no residenciales lo son además para SAIDI. Las variables climáticas rezagadas no resultan relevantes, y la única variable operativa con efecto semanal robusto es el historial reciente de SAIDI del propio cuadrante.
3. Evaluar el desempeño de diferentes métodos estadísticos o de Machine Learning para predecir SAIDI y SAIFI por circuito o zona.	Comparación de cuatro algoritmos de panel (Pooled OLS, FE cuadrante, FE cuadrante+semana, Random Forest ajustado) frente a dos pronósticos de referencia, con RMSE, MAE, R^2, MASE, prueba de Diebold–Mariano y validación de origen móvil (Tablas 6.12–6.16); clasificador de ocurrencia (Sección 6.5.3); y modelos espaciales SAR y SEM con validación cruzada espacial (Tabla 6.17). Se identifica el mejor modelo de pronóstico y el mejor modelo estructural para cada indicador, así como el límite de lo pronosticable con los datos disponibles.

7 Discusión y trabajo futuro

7.1. Discusión

El resultado central de la Etapa 5 es una separación nítida entre lo que es pronosticable y lo que no lo es con la información disponible. El *nivel* de afectación de cada cuadrante es estable y altamente explicable: los modelos de corte transversal alcanzan un R^2 de 0.90 (SAIDI) y 0.84 (SAIFI), significativo frente a una prueba de permutación, y conservan 0.42 y 0.76 cuando se predicen zonas no usadas en la estimación. La *ocurrencia* de falla en la semana siguiente también es pronosticable con precisión útil (AUC de 0.84). En cambio, la *magnitud* de la afectación en una semana concreta, alrededor del nivel del cuadrante, no lo es: el mejor modelo de panel supera a la persistencia en un 20–26 %, pero no mejora de forma significativa el pronóstico ingenuo que consiste en usar el promedio histórico de cada cuadrante (Tabla 6.14), y su R^2 *within* es inferior a 0.03. En términos prácticos, la red de Norte de Santander tiene un componente territorial altamente predecible —qué cuadrantes son sistemáticamente más vulnerables y cuáles tienen mayor probabilidad de falla la semana próxima— y un componente de magnitud semanal que, con las variables disponibles, se comporta como ruido.

La comparación entre familias de modelos es coherente con esa lectura. Los efectos fijos de cuadrante son el mejor modelo de magnitud en ambos indicadores porque capturan exactamente el componente que es pronosticable, el nivel propio de cada cuadrante; por la misma razón, su desempeño es casi idéntico al de la media del cuadrante. Random Forest resulta inferior pese al ajuste de hiperparámetros, y la búsqueda selecciona la configuración más regularizada de la grilla, un patrón típico cuando la señal es débil y el modelo flexible tiende a ajustar ruido. Su sensibilidad a la cola de la distribución lo confirma: al recortar el $0.5\,\%$ de valores extremos del entrenamiento, su error se iguala al de los modelos lineales. Este resultado difiere del de los informes preliminares, en los que Random Forest obtenía el menor error en SAIDI. La diferencia se explica por dos errores de construcción de las variables sísmicas, detectados y corregidos en la re-estimación (Sección 5.2.7): con ellos, la última semana del periodo de prueba registraba un número de sismos veinticuatro veces superior al máximo

de entrenamiento, y los modelos lineales extrapolaban ese valor de forma severa, mientras que el bosque, que no extrapola, quedaba protegido. Corregidos los datos, la aparente ventaja del modelo no lineal desaparece. El episodio ilustra por qué la verificación de cada variable contra su definición es parte del análisis y no un trámite previo.

Estas cifras deben leerse frente a la restricción de información bajo la cual se obtuvieron. El R^2 de prueba de entre 0.20 y 0.26 en el panel semanal es el alcanzable con predictoras disponibles antes de la semana pronosticada: las variables de severidad que solo se conocen al cerrar el evento quedaron excluidas por diseño (Sección 5.4; Tabla 5.11). Un modelo que las incluyera mostraría métricas mucho mejores y sería inútil en operación. El desempeño reportado es, por tanto, una medida de lo que el modelo puede ofrecer en condiciones reales de uso y la referencia frente a la cual deben compararse futuras iteraciones.

La autocorrelación espacial significativa detectada mediante el índice de Moran (SAIDI: $I = 0.154$; SAIFI: $I = 0.179$; ambos $p < 0.001$) confirma que el fenómeno de calidad del servicio no es independiente entre cuadrantes vecinos, lo que valida la inclusión de rezagos espaciales y respalda, desde la evidencia empírica, el enfoque territorial adoptado desde el planteamiento del problema. Asimismo, las variables que resultan relevantes en al menos dos modelos (Tabla 6.20) —el número de elementos y la longitud de red en ambos indicadores, y la vegetación y la proporción de clientes no residenciales en SAIDI— coinciden con la literatura revisada en los antecedentes, que señala la infraestructura y la vegetación como factores recurrentes en la predicción de confiabilidad de redes de distribución. En este estudio, sin embargo, la señal de infraestructura resultó claramente más determinante que la climática, y la exposición sísmica, una vez corregida su construcción, solo conserva una asociación débil con SAIFI en el corte transversal.

La comparación con los antecedentes permite situar estos resultados. Primero, la débil señal del clima semanal contrasta con los estudios de huracanes y tifones, en los que la velocidad del viento es el predictor dominante [12], [64]; la diferencia es coherente con la naturaleza de los datos, porque esos trabajos modelan eventos extremos de escala sinóptica, mientras que en Norte de Santander predominan tormentas convectivas locales de pocas horas que un acumulado semanal de reanálisis no captura, y porque la relación clima–interrupción documentada en la literatura es marcadamente no lineal [11]. Segundo, la elección de una celda de aproximadamente 5×2.5 km se ubica en el rango de resoluciones que la literatura identifica como un compromiso entre señal y dispersión [11], [63], [65], y la fracción de cuadrantes–semana sin eventos ($63\,\%$ en D_{mod}) reproduce el problema de inflación de ceros que motivó los esquemas multietapa

de Shashaani et al. [65], lo que respalda extender el modelo actual, condicional a la ocurrencia de falla, hacia una estructura de dos componentes. Tercero, la evidencia de que los modelos de árboles igualan o superan a especificaciones paramétricas con pocas variables [64] proviene de problemas con una señal meteorológica fuerte; cuando, como aquí, la señal dinámica es débil, la flexibilidad del modelo no se traduce en precisión, y la recomendación de Arora y Ceferino [12] de acompañar estos modelos con reentrenamiento periódico y con una referencia simple se vuelve especialmente pertinente. Finalmente, la heterogeneidad espacial encontrada coincide con la de Dunn et al. [7], quienes muestran que los indicadores de confiabilidad varían en órdenes de magnitud entre zonas y periodos y que los valores agregados la ocultan: ese es precisamente el vacío de información que este trabajo aborda para el operador.

Desde el punto de vista de la gestión, la distinción entre variables relevantes y variables accionables condiciona el uso práctico de estos resultados. Las señales más robustas —número de elementos y longitud de red— pertenecen al ámbito de la planeación de inversión y son modificables en horizontes plurianuales; el NDVI es gestionable mediante programas de poda con ciclos de meses; la exposición sísmica no es intervenible y su utilidad se limita a la priorización territorial. Esta jerarquía, unida a los resultados de desempeño, precisa el aporte del trabajo al operador. No reside en pronosticar cuántas horas de interrupción tendrá un cuadrante la semana próxima, sino en dos productos de uso directo: el ordenamiento de los cuadrantes según su nivel estructural de afectación, para concentrar inversión, mantenimiento y poda, y la probabilidad semanal de falla por cuadrante, para programar cuadrillas y recursos de respuesta. Ambos son útiles para reducir los índices anuales y las compensaciones, que es el propósito del proyecto.

Entre las limitaciones del estudio, la más relevante es el sesgo de cobertura de emparejamiento evento–elemento detectado entre 2021 y 2023 (Sección 6.2), que obligó a restringir el dataset de modelado a 2024–2025. Esta decisión, aunque necesaria para garantizar la validez de los resultados, redujo el horizonte temporal disponible para el entrenamiento y probablemente limita la capacidad de los modelos para capturar variabilidad interanual de más largo plazo; con solo 105 semanas útiles, el *holdout* del 15 % final deja una ventana de evaluación de aproximadamente dieciséis semanas, suficiente para detectar degradación sistemática pero no para contrastar la estabilidad del modelo ante un ciclo anual completo. Para mitigar esta limitación se complementó el *holdout* con una validación de origen móvil en cuatro cortes (Tabla 6.16): el ordenamiento de los modelos se mantiene —FE de cuadrante supera a la persistencia en los cuatro cortes y tiene el menor RMSE medio—, aunque la dispersión entre cortes es del

mismo orden que la diferencia entre FE y Random Forest, lo que confirma que esa diferencia es pequeña.

En segundo lugar, la señal climática contemporánea resultó débil en el grano semanal (Sección 6.3), lo que sugiere que futuras iteraciones del proyecto deberían profundizar en rezagos climáticos de mayor orden o en variables de exposición acumulada en lugar de solo variables climáticas instantáneas. Conviene precisar el alcance de esta limitación: lo que la evidencia descarta es la utilidad del clima *simultáneo* como predictor en el grano semanal, no la existencia de un efecto climático sobre la continuidad del servicio. La agregación a semana completa promedia condiciones meteorológicas muy heterogéneas dentro del periodo y puede diluir el efecto de episodios intensos de pocas horas, que son precisamente los que la operación asocia a fallas; una verificación de esta hipótesis exigiría trabajar con el grano diario o con indicadores de intensidad máxima intrasemanal, no solo con acumulados.

En tercer lugar, el modelo de magnitud se estimó sobre las semanas con falla (`hubo_falla`$= 1$), decisión justificada por la cero-inflación del $74.9\,\%$ del panel (Sección 5.4.11). El componente de ocurrencia estimado en la re-estimación completa el esquema en dos partes, pero de forma básica: ambos componentes se estimaron por separado y su combinación no se calibró. Un modelo conjunto (por ejemplo, de tipo *hurdle* o de conteo con inflación de ceros) permitiría evaluar el valor esperado incondicional con métricas propias de distribuciones con exceso de ceros.

En cuarto lugar, la sismicidad resultó menos informativa de lo previsto: una vez corregida, solo muestra una asociación débil en el corte transversal. Este hecho se documenta en el catálogo de datos como una limitación de la fuente y no como evidencia de ausencia de efecto.

Finalmente, el modelo de efectos fijos de cuadrante y semana no resultó evaluable en el conjunto de prueba por falta de traslape entre semanas de entrenamiento y de prueba, una limitación conocida de los modelos con efectos fijos dobles en validaciones temporales estrictas (*holdout*) y no un defecto del modelo en sí. Se reporta de forma explícita en las tablas de desempeño, antes que omitirse, porque documenta una incompatibilidad estructural entre efectos fijos temporales y validación prospectiva que cualquier replicación del trabajo volverá a encontrar.

7.2. Trabajos futuros

A partir de los hallazgos y las limitaciones identificadas, se proponen las siguientes líneas de trabajo futuro:

- Resolver de forma retroactiva la incompatibilidad de esquemas de codi-

ficación entre BRAE y el inventario georreferenciado (Sección 6.2), lo que permitiría extender el dataset de modelado más allá de 2024–2025 y evaluar la estabilidad de los modelos ante un horizonte temporal más largo.

- Explorar especificaciones espacio-temporales formales (por ejemplo, modelos de panel espacial dinámico o *spatial Durbin*) que integren simultáneamente la dependencia espacial confirmada por el índice de Moran y la persistencia temporal identificada en el análisis exploratorio, en lugar de tratarlas como dos modelos separados (panel semanal y corte transversal).
- Incorporar variables de exposición climática acumulada (por ejemplo, precipitación acumulada a varias semanas o índices de sequía/humedad del suelo) dado que la señal climática contemporánea resultó débil, con el fin de evaluar si el efecto del clima sobre SAIDI/SAIFI opera con rezagos más largos que los considerados en este trabajo.
- Incorporar información de mayor resolución temporal que pueda explicar la magnitud semanal alrededor del nivel del cuadrante, que con los datos actuales se comporta como ruido: pronósticos meteorológicos de intensidad máxima intradiaria, alertas de tormenta eléctrica, programación de mantenimientos y maniobras, y disponibilidad de cuadrillas. Solo con información de este tipo tiene sentido volver a evaluar modelos no lineales más flexibles, como *gradient boosting*.
- Consolidar el esquema en dos componentes en un modelo conjunto (*hurdle* o de conteo con inflación de ceros), calibrar la probabilidad de falla y evaluar el valor esperado incondicional con métricas apropiadas para distribuciones con exceso de ceros, de modo que el resultado sea directamente utilizable para la programación operativa.
- Incorporar al flujo controles automáticos de cada variable integrada (rango, variación entre unidades y continuidad temporal), como los que permitieron detectar los errores de la variable sísmica.
- Contrastar la robustez de la partición de variables mediante un ejercicio de *ablación* controlada: estimar deliberadamente una especificación que incluya el bloque de impacto posterior y cuantificar la magnitud exacta de la fuga de información. El resultado no sería un modelo utilizable, pero proporcionaría una cota superior del ajuste alcanzable y permitiría dimensionar con precisión el costo predictivo de la restricción *ex ante* adoptada en este trabajo.
- Revisar los signos negativos estimados en el corte transversal para la longitud de red (`longitud_red_km`) y para la antigüedad del activo más viejo (Sección 6.5), incorporando una medida explícita de densidad de usuarios

por kilómetro de red y una fecha de instalación original de los activos, distinta de la última fecha de modificación registrada. Ambas hipótesis interpretativas son plausibles pero no verificables con la información actualmente disponible.

- Diseñar un esquema de actualización periódica del panel y de reentrenamiento de los modelos, de modo que el operador de red pueda adoptar el flujo documentado en este trabajo como una herramienta de monitoreo continuo y no solo como un ejercicio académico puntual, en línea con el objetivo de reproducibilidad planteado desde el inicio del proyecto.

8 Conclusiones

8.1. Conclusión asociada al objetivo general

Este trabajo desarrolló una metodología basada en ciencia de datos, estructurada según CRISP-DM, para pronosticar los indicadores SAIDI y SAIFI por zona en la red de distribución de una empresa de energía eléctrica del Norte de Santander e identificar los factores que más influyen en su comportamiento. La metodología integró cinco sistemas corporativos (BRAE, `QA_TTC1`, OMS SPARD, OMS SP7 y GTECH) y cuatro fuentes externas (NASA POWER, MODIS, SGC y DANE) en un panel cuadrante $\times$ semana, sobre el que se construyeron indicadores operativos de afectación referidos a la base de usuarios de la empresa. En respuesta a la pregunta de investigación, la evidencia muestra que la afectación tiene dos componentes de naturaleza distinta. El primero es territorial y estable: el nivel de afectación de cada cuadrante se explica en un 84–90 % por la infraestructura y la exposición, y la probabilidad de que un cuadrante registre una falla la semana siguiente se pronostica con un AUC de 0.84. El segundo es la magnitud semanal alrededor de ese nivel, que con las variables disponibles no es pronosticable: el mejor modelo reduce el error de la persistencia en un 20–26 %, pero no mejora de forma significativa el promedio histórico del cuadrante. La metodología completa, desde la extracción de los datos hasta la evaluación de los modelos, quedó documentada en código e informes reproducibles y es replicable por el operador con sus propios sistemas.

8.2. Conclusión asociada al objetivo específico 1

Se consolidaron las fuentes enunciadas en el objetivo en un repositorio analítico trazable, documentado mediante el linaje de datos (Tabla 5.7) y el catálogo de datos (Apéndice A.4), que registra para cada fuente su cobertura, sus métricas de integridad y sus limitaciones. La métrica de integridad más relevante no fue la completitud de los campos, que fue alta, sino la trazabilidad evento–elemento: solo cerca del 31 % de los eventos de 2021–2023 podía vincularse al inventario georreferenciado, frente al 79.8 % en 2024 y el 95.0 % en 2025, por la coexistencia

de códigos de sitio y de activo en el sistema histórico de gestión de interrupciones. Este diagnóstico, que un análisis basado únicamente en valores faltantes no habría detectado, delimitó el periodo de modelado a 2024–2025 y constituye en sí mismo un aporte a la gobernanza de datos del operador. La verificación de cada variable contra su definición permitió además detectar y corregir dos errores en la construcción de la exposición sísmica.

8.3. Conclusión asociada al objetivo específico 2

Las variables con mayor relevancia para predecir SAIDI y SAIFI son técnicas y estructurales: el número de elementos y la longitud de la red del cuadrante son las más importantes en todos los modelos que pueden identificarlas, y para SAIDI se suman la vegetación (NDVI) y la proporción de clientes no residenciales (Tabla 6.20). Entre las variables operativas, el único efecto semanal robusto es el historial reciente de SAIDI del propio cuadrante. Las variables climáticas de la semana anterior no resultaron significativas en ningún modelo, lo que contradice la expectativa inicial de que el clima sería un predictor principal y sugiere que su efecto opera en escalas temporales más finas que la semana. Desde la perspectiva de la gestión, el hallazgo es favorable: los factores más informativos son, en buena medida, gestionables por el operador mediante inversión, reposición de activos y poda.

8.4. Conclusión asociada al objetivo específico 3

Se evaluaron cuatro especificaciones de panel semanal (*Pooled* OLS, efectos fijos de cuadrante, efectos fijos de cuadrante y semana, y Random Forest con ajuste de hiperparámetros), un clasificador de ocurrencia de falla y dos modelos espaciales formales (SAR y SEM) para cada indicador, bajo validación temporal estricta, con predictoras disponibles antes de la semana pronosticada y frente a dos pronósticos de referencia. Para la magnitud semanal, los efectos fijos de cuadrante obtuvieron el menor error en ambos indicadores y superaron de forma significativa a la persistencia y a Random Forest (prueba de Diebold–Mariano, $p < 0.001$), pero resultaron estadísticamente equivalentes al promedio histórico del cuadrante; el ordenamiento se mantuvo en una validación de origen móvil con cuatro cortes. Para la explicación territorial, SAR (SAIDI) y SEM (SAIFI) fueron preferidos por AIC, con un ajuste alto que se conserva en un $42\,\%$ y un $76\,\%$ al predecir zonas no usadas en la estimación. En consecuencia, se recomienda usar el modelo de efectos fijos o el promedio histórico del cuadrante como referencia de magnitud, el clasificador de ocurrencia para anticipar semanas y

zonas críticas y programar recursos operativos, y los modelos de corte transversal para priorizar territorialmente la inversión y el mantenimiento preventivo, que es donde el trabajo ofrece su mayor valor para reducir los índices anuales y las compensaciones asociadas. Los modelos más interpretables resultaron también los de mejor desempeño, lo que favorece su adopción por los gestores.

8.5. Recomendaciones para el operador de red

- Homologar retroactivamente los códigos de activo y de sitio en el histórico del sistema de gestión de interrupciones, lo que permitiría recuperar cerca del 70 % de los eventos de 2021–2023 para el análisis territorial.
- Incorporar el ranking de cuadrantes por contribución esperada a SAIDI y SAIFI (Apéndice A.6) en la planeación anual de mantenimiento preventivo, poda e inversión, y la probabilidad semanal de falla por cuadrante en la programación de cuadrillas.
- Registrar la fecha de instalación original y el tipo de intervención de los activos, hoy no disponibles, para mejorar la medición de su antigüedad y del efecto del mantenimiento.
- Actualizar periódicamente el panel y reentrenar los modelos con la cadena reproducible documentada en este trabajo, incluyendo controles automáticos de rango y continuidad de cada variable integrada.

Bibliografía

[1] Comisión de Regulación de Energía y Gas (CREG), «Resolución CREG 015 de 2018 – Por la cual se establecen los indicadores de calidad del servicio de energía eléctrica y las fórmulas de compensación,» CREG, Bogotá, Colombia, inf. téc., 2018. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0015_2018.htm

[2] S.-S. de Servicios Públicos Domiciliarios, «Resolución SSPD 20192200020155,» Superintendencia de Servicios Públicos Domiciliarios, inf. téc., 2019, [Online; accessed 2025-11-23]. dirección: https://www.superservicios.gov.co/node/5072

[3] IEEE Power and Energy Society, «IEEE Std 1366-2012: IEEE Guide for Electric Power Distribution Reliability Indices,» IEEE, New York, USA, inf. téc., 2012.

[4] A. Escalera, B. Hayes y M. Prodanović, «A survey of reliability assessment techniques for modern distribution networks,» *Renewable and Sustainable Energy Reviews*, vol. 91, págs. 344-357, 2018. DOI: 10.1016/j.rser.2018.02.031

[5] K. Zhou, C. Fu y S. Yang, «Big data driven smart energy management: From big data to big insights,» *Renewable and Sustainable Energy Reviews*, vol. 56, págs. 215-225, 2016. DOI: 10.1016/j.rser.2015.11.050

[6] M. Kezunovic, L. Xie y S. Grijalva, «The role of big data in improving power system operation and protection,» en *2013 IREP Symposium – Bulk Power System Dynamics and Control – IX Optimization, Security and Control of the Emerging Power Grid*, Rethymnon, Greece, 2013.

[7] L. N. Dunn, M. D. Sohn, K. H. LaCommare y J. H. Eto, «Exploratory analysis of high-resolution power interruption data reveals spatial and temporal heterogeneity in electric grid reliability,» *Energy Policy*, vol. 129, págs. 206-214, 2019. DOI: 10.1016/j.enpol.2019.01.042

[8] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Circular 063 de 2019 – Criterios técnicos para el cálculo de indicadores de calidad del servicio de energía eléctrica,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, Circular 063, 2019, [En línea]. dirección: https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/$FILE/Circular063-2019.pdf

[9] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Informe de Calidad del Servicio de Energía Eléctrica 2023,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, inf. téc., 2024, [En línea]. Disponible en: https://www.superservicios.gov.co. dirección: https://www.superservicios.gov.co

[10] U. de Planeación Minero Energética (UPME), «Plan de Expansión de Referencia Generación - Transmisión 2023 - 2037,» Unidad de Planeación Minero Energética (UPME), inf. téc., 2023.

[11] S.-R. Han, S. D. Guikema y S. M. Quiring, «Improving the Predictive Accuracy of Hurricane Power Outage Forecasts Using Generalized Additive Models,» *Risk Analysis*, vol. 29, n.º 10, págs. 1443-1453, 2009. DOI: 10.1111/j.1539-6924.2009.01280.x

[12] P. Arora y L. Ceferino, «Probabilistic and machine learning methods for uncertainty quantification in power outage prediction due to extreme events,» *Natural Hazards and Earth System Sciences*, vol. 23, n.º 5, págs. 1665-1683, 2023. DOI: 10.5194/nhess-23-1665-2023

[13] R. J. A. Little y D. B. Rubin, *Statistical Analysis with Missing Data*, 3.ª ed. Hoboken, NJ, USA: John Wiley & Sons, 2019.

[14] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[15] G. E. P. Box y D. R. Cox, «An Analysis of Transformations,» *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 26, n.º 2, págs. 211-252, 1964.

[16] G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5.ª ed. Hoboken, NJ, USA: John Wiley & Sons, 2015.

[17] C. Spearman, «The Proof and Measurement of Association between Two Things,» *The American Journal of Psychology*, vol. 15, n.º 1, págs. 72-101, 1904.

[18] H. Cramér, *Mathematical Methods of Statistics*. Princeton, NJ, USA: Princeton University Press, 1946.

[19] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.ª ed. Melbourne, Australia: OTexts, 2021. dirección: https://otexts.com/fpp3/

[20] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2.ª ed. New York, NY, USA: Springer, 2009.

[21] C. Bergmeir y J. M. Benítez, «On the Use of Cross-Validation for Time Series Predictor Evaluation,» *Information Sciences*, vol. 191, págs. 192-213, 2012. DOI: 10.1016/j.ins.2011.12.028

[22] I. T. Jolliffe, *Principal Component Analysis*, 2.ª ed. New York, NY, USA: Springer, 2002.

[23] L. Kaufman y P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. New York, NY, USA: John Wiley & Sons, 1990.

[24] J. MacQueen, «Some Methods for Classification and Analysis of Multivariate Observations,» en *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, Berkeley, CA, USA: University of California Press, 1967, págs. 281-297.

[25] M. H. Kutner, C. J. Nachtsheim, J. Neter y W. Li, *Applied Linear Statistical Models*, 5.ª ed. New York, NY, USA: McGraw-Hill/Irwin, 2005.

[26] R. M. O'Brien, «A Caution Regarding Rules of Thumb for Variance Inflation Factors,» *Quality & Quantity*, vol. 41, n.º 5, págs. 673-690, 2007. DOI: 10.1007/s11135-006-9018-6

[27] P. McCullagh y J. A. Nelder, *Generalized Linear Models*, 2.ª ed. London, UK: Chapman & Hall, 1989.

[28] A. C. Cameron y P. K. Trivedi, *Regression Analysis of Count Data*, 2.ª ed. Cambridge, UK: Cambridge University Press, 2013.

[29] J. M. Wooldridge, *Econometric Analysis of Cross Section and Panel Data*, 2.ª ed. Cambridge, MA, USA: MIT Press, 2010.

[30] L. Breiman, «Random Forests,» *Machine Learning*, 2003. DOI: 10.1023/A:1010933404324

[31] P. Probst, M. N. Wright y A.-L. Boulesteix, «Hyperparameters and tuning strategies for random forest,» *WIREs Data Mining and Knowledge Discovery*, vol. 9, n.º 3, e1301, 2019. DOI: 10.1002/widm.1301

[32] P. A. P. Moran, «Notes on Continuous Stochastic Phenomena,» *Biometrika*, vol. 37, n.º 1/2, págs. 17-23, 1950. DOI: 10.2307/2332142

[33] L. Anselin, *Spatial Econometrics: Methods and Models*. Dordrecht, Netherlands: Kluwer Academic Publishers, 1988. DOI: 10.1007/978-94-015-7799-1

[34] J. LeSage y R. K. Pace, *Introduction to Spatial Econometrics*. Boca Raton, FL, USA: Chapman y Hall/CRC, 2009. DOI: 10.1201/9781420064254

[35] R. J. Hyndman y A. B. Koehler, «Another look at measures of forecast accuracy,» *International Journal of Forecasting*, vol. 22, n.º 4, págs. 679-688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001

[36] F. X. Diebold y R. S. Mariano, «Comparing Predictive Accuracy,» *Journal of Business & Economic Statistics*, vol. 13, n.º 3, págs. 253-263, 1995. DOI: 10.1080/07350015.1995.10524599

[37] K. Xie, H. Zhang y C. Singh, «Reliability forecasting models for electrical distribution systems considering component failures and planned outages,» *International Journal of Electrical Power & Energy Systems*, vol. 78, págs. 337-346, 2016. DOI: 10.1016/j.ijepes.2016.01.020

[38] S. Das, P. Kankanala y A. Pahwa, «Outage Estimation in Electric Power Distribution Systems Using a Neural Network Ensemble,» *Energies*, 2021. DOI: 10.3390/en14164797

[39] M. Angalakudati et al., «Improving emergency storm planning using machine learning,» en *2014 IEEE PES T&D Conference and Exposition*, 2014. DOI: 10.1109/TDC.2014.6863406

[40] D. Owerko, F. Gama y A. Ribeiro, «Predicting Power Outages Using Graph Neural Networks,» en *IEEE Global Conference on Signal and Information Processing*, 2018. DOI: 10.1109/GLOBALSIP.2018.8646486

[41] D. Cerrai, P. L. Watson y E. N. Anagnostou, «Assessing the effects of a vegetation management standard on distribution grid outage rates,» *Electric Power Systems Research*, 2019. DOI: 10.1016/j.epsr.2019.105909

[42] R. Eskandarpour y A. Khodaei, «Machine Learning Based Power Grid Outage Prediction in Response to Extreme Events,» *IEEE Transactions on Power Systems*, 2017. DOI: 10.1109/TPWRS.2016.2631895

[43] C. Rudin et al., «Machine Learning for the New York City Power Grid,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012. DOI: 10.1109/TPAMI.2011.108

[44] L. Xu, M.-Y. Chow, J. Timmis y L. Taylor, «Power Distribution Outage Cause Identification With Imbalanced Data Using Artificial Immune Recognition System (AIRS) Algorithm,» *IEEE Transactions on Power Systems*, 2007. DOI: 10.1109/TPWRS.2006.889040

[45] S.-R. Han, S. D. Guikema, S. M. Quiring, K. H. Lee, D. V. Rosowsky y R. A. Davidson, «Estimating the spatial distribution of power outages during hurricanes in the Gulf coast region,» *Reliability Engineering & System Safety*, 2009. DOI: 10.1016/j.ress.2008.02.018

[46] F. Yang, D. W. Wanik, D. Cerrai, M. A. E. Bhuiyan y E. N. Anagnostou, «Quantifying Uncertainty in Machine Learning-Based Power Outage Prediction Model Training: A Tool for Sustainable Storm Restoration,» *Sustainability*, 2020. DOI: 10.3390/su12041525

[47] P. Kankanala, S. Das y A. Pahwa, «AdaBoost+: An Ensemble Learning Approach for Estimating Weather-Related Outages in Distribution Systems,» *IEEE Transactions on Power Systems*, 2013. DOI: 10.1109/TPWRS.2013.2281137

[48] Y. Kor, M. Reformat y P. Musilek, «Predicting Weather-related Power Outages in Distribution Grid,» en *IEEE Power & Energy Society General Meeting*, 2020. DOI: 10.1109/PESGM41954.2020.9281829

[49] M. Doostan y B. Chowdhury, «Predicting Lightning-Related Outages in Power Distribution Systems: A Statistical Approach,» *IEEE Access*, 2020. DOI: 10.1109/ACCESS.2020.2991923

[50] P.-C. Chen y M. Kezunović, «Fuzzy logic approach to predictive risk analysis in distribution outage management,» en *IEEE Power & Energy Society General Meeting*, 2017. DOI: 10.1109/PESGM.2017.8274298

[51] J. He, D. W. Wanik, B. Hartman, E. N. Anagnostou, M. Astitha y M. Frediani, «Nonparametric Tree-Based Predictive Modeling of Storm Outages on an Electric Distribution Network,» *Risk Analysis*, 2017. DOI: 10.1111/risa.12652

[52] H. Hou et al., «Spatial distribution assessment of power outage under typhoon disasters,» *International Journal of Electrical Power & Energy Systems*, 2021. DOI: 10.1016/j.ijepes.2021.107169

[53] M. Li et al., «Prediction of Power Outage Quantity of Distribution Network Users under Typhoon Disaster Based on Random Forest and Important Variables,» 2021. DOI: 10.1155/2021/6682242

[54] C. Zhai, T. Y.-J. Chen, A. White y S. D. Guikema, «Power outage prediction for natural hazards using synthetic power distribution systems,» *Reliability Engineering & System Safety*, 2021. DOI: 10.1016/j.ress.2020.107348

[55] D. Zhu, D. Cheng, R. Broadwater y C. Scirbona, «Storm modeling for prediction of power distribution system outages,» *Electric Power Systems Research*, 2007. DOI: 10.1016/j.epsr.2006.08.020

[56] A. Arif y Z. Wang, «Distribution Network Outage Data Analysis and Repair Time Prediction Using Deep Learning,» en *IEEE International Conference on Probabilistic Methods Applied to Power Systems*, 2018. DOI: 10.1109/PMAPS.2018.8440354

[57] D. W. Wanik, E. N. Anagnostou, B. Hartman, M. Frediani y M. Astitha, «Storm outage modeling for an electric distribution network in Northeastern USA,» *Natural Hazards*, 2015. DOI: 10.1007/s11069-015-1908-2

[58] A. Jaech, B. Zhang, M. Ostendorf y D. S. Kirschen, «Real-Time Prediction of the Duration of Distribution System Outages,» *IEEE Transactions on Power Systems*, 2018. DOI: 10.1109/TPWRS.2018.2860904

[59] D. Sorokin, «Machine learning application for power systems reliability assessment,» en *E3S Web of Conferences*, vol. 461, 2023. DOI: 10.1051/e3sconf/202346101032

[60] Z. Liu, J. Li, T. Zhang y J. Shao, «Rapid Calculation of Active Distribution Network Reliability Based on Dynamic Equipment Failure Rate,» *Energies*, vol. 16, n.º 14, 2023. DOI: 10.3390/en16145245

[61] E. Avcı, «Hybrid Artificial Intelligence Techniques for Enhanced Electricity Outage Prediction and Management in Distribution Networks,» *Turkish Journal of Electrical Power and Energy Systems*, 2024. DOI: 10.5152/TEPES.2024.24008

[62] J. Krstivojević y J. S. Terzić, «Enhancing Reliability Performance in Distribution Networks Using Monte Carlo Simulation for Optimal Investment Option Selection,» *Applied Sciences*, págs. 1-26, 2025.

[63] H. Liu, R. A. Davidson, D. V. Rosowsky y J. R. Stedinger, «Negative Binomial Regression of Electric Power Outages in Hurricanes,» *Journal of Infrastructure Systems*, vol. 11, n.º 4, págs. 258-267, 2005. DOI: 10.1061/(ASCE)1076-0342(2005)11:4(258)

[64] R. Nateghi, S. D. Guikema y S. M. Quiring, «Power Outage Estimation for Tropical Cyclones: Improved Accuracy with Simpler Models,» *Risk Analysis*, 2014. DOI: 10.1111/risa.12131

[65] S. Shashaani, S. D. Guikema, C. Zhai, J. V. Pino y S. M. Quiring, «Multi-Stage Prediction for Zero-Inflated Hurricane Induced Power Outages,» *IEEE Access*, vol. 6, págs. 62 432-62 449, 2018. DOI: 10.1109/ACCESS.2018.2877078

[66] D. B. McRoberts, S. M. Quiring y S. D. Guikema, «Improving Hurricane Power Outage Prediction Models Through the Inclusion of Local Environmental Factors,» *Risk Analysis*, vol. 38, n.º 12, págs. 2722-2737, 2018, Verificar DOI antes de citar.

[67] NASA Langley Research Center (LaRC) POWER Project, *NASA Prediction of Worldwide Energy Resources (POWER): Data Access Viewer and API documentation*, https://power.larc.nasa.gov/, Financiado por el programa NASA Earth Science/Applied Science; en línea, 2024.

[68] P. Chapman et al., «CRISP-DM 1.0: Step-by-step data mining guide,» SPSS Inc., inf. téc., 2000, Cross-Industry Standard Process for Data Mining.

[69] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política de Gestión de Tecnologías de la Información*, Sesión Junta Directiva No. 800, feb. de 2018.

[70] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política Sistema de Gestión Integrado*, Sesión Junta Directiva No. 831, abr. de 2020.

[71] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Instrumentos de gestión de información pública*, https://www.cens.com.co/transparencia-y-acceso-a-la-informacion-publica/instrumentos-de-gestion-de-informacion-publica, En línea; consultado, 2024.

A Anexos

A.1. Diagrama de integración del panel

La Figura A.1 presenta el diagrama de flujo de la secuencia de integración descrita en la Sección 5.2.1, desde las fuentes de origen hasta el panel consolidado activo × día.

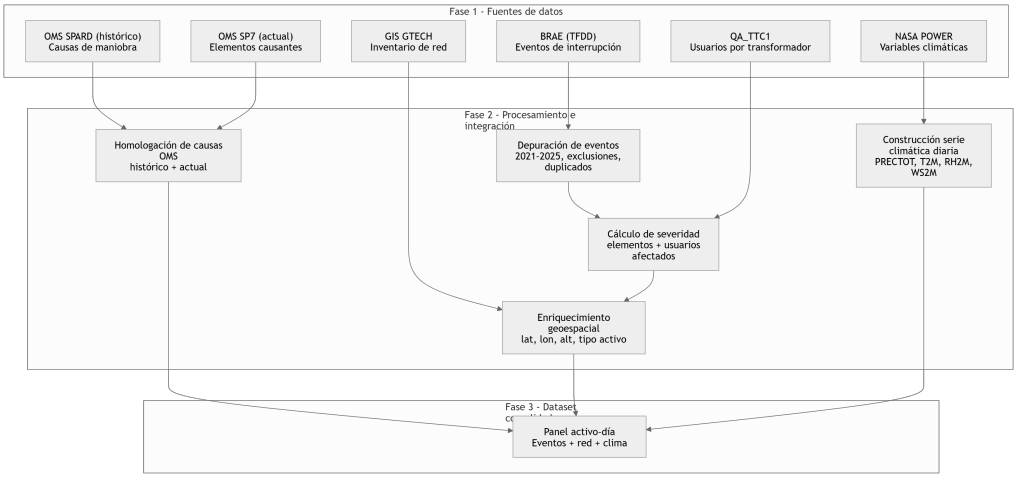


Figura A.1: Estructura del panel de datos activo–día

A.2. Código de extracción de datos

Esta sección consolida el código de extracción utilizado en la Etapa 1 de la metodología (consultas SQL y fragmentos Python). En el cuerpo del documento se describe el procedimiento y se referencia el listado correspondiente.

A.2.1. Consultas SQL

Eventos de interrupción (BRAE)

```sql
SELECT DISTINCT FDD_CODIGOEVENTO AS ID_EVENTO
      ,FDD_FINICIAL AS FECHA_DESCONEXION
      ,FDD_FFINAL AS FECHA_CONEXION
```

```
      ,'' AS ELEMENTO_FALLADO
FROM BRAE.QA_TFDDREGISTRO
WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
  AND FDD_EXCLUSION = 'NO EXCLUIDA'
  AND FDD_CAUSA_SSPD NOT IN (1)
  AND FDD_FFINAL IS NOT NULL;
```

Listado A.1: Consulta SQL de extracción y depuración de eventos de interrupción (BRAE)

Afectación por evento (BRAE + QA_TTC1)

```
SELECT FDD_CODIGOEVENTO AS ID_EVENTO
      ,COUNT(FDD_CODIGOELEMENTO) AS CANTIDAD_ELEMENTOS_FALLADOS
      ,SUM(CANTIDAD_USUARIOS) AS CANTIDAD_USUARIOS
FROM BRAE.QA_TFDDREGISTRO
LEFT JOIN (
    SELECT TC1_CODCONEX AS TRANSFORMADOR
          ,COUNT(TC1_CODCONEX) AS CANTIDAD_USUARIOS
          ,TC1_PERIODO AS PERIODO
    FROM QA_TTC1
    WHERE SUBSTR(TC1_PERIODO, 1, 4) IN ('2021', '2022', '2023', '2024', '2025')
    GROUP BY TC1_PERIODO, TC1_CODCONEX
) ON FDD_CODIGOELEMENTO = TRANSFORMADOR
 AND FDD_PERIODO_TC1 = PERIODO
WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
  AND FDD_EXCLUSION = 'NO EXCLUIDA'
  AND FDD_CAUSA_SSPD NOT IN (1)
  AND FDD_FFINAL IS NOT NULL
GROUP BY FDD_CODIGOEVENTO;
```

Listado A.2: Consulta SQL de afectación por evento (elementos y usuarios)

Elemento causante histórico (OMS SPARD)

```
SELECT CODE AS CODIGO_MANIOBRA
      ,BREAKER AS ELEMENTO_FALLADO
FROM OMS.MANIOBRAS@SPARD
WHERE TO_NUMBER(TO_CHAR(FECHA, 'YYYY')) >= 2021
  AND CAUSA != 'PRUEBA';
```

Listado A.3: Consulta SQL del elemento causante histórico (OMS SPARD)

Inventario georreferenciado (GIS GTECH)

```
SELECT
    nodo_transform_v AS ELEMENTO,
    coor_gps_lat     AS LATITUD,
```

```
    coor_gps_lon     AS LONGITUD,
    coor_z           AS ALTITUD,
    'Transformador'  AS TIPO,
    ubicacion
FROM ccomun@gtech c
JOIN cconectividad_e@gtech USING (g3e_fid)
WHERE c.estado = 'OPERACION'
  AND c.g3e_fno = 20400
UNION
SELECT
    r.codigo         AS ELEMENTO,
    coor_gps_lat     AS LATITUD,
    coor_gps_lon     AS LONGITUD,
    coor_z           AS ALTITUD,
    'Reconectador'   AS TIPO,
    ubicacion
FROM ereconec_at@gtech r
JOIN ccomun@gtech c USING (g3e_fid)
JOIN cconectividad_e@gtech USING (g3e_fid)
WHERE c.estado = 'OPERACION';
```

Listado A.4: Consulta SQL del inventario georreferenciado de activos (GIS GTECH)

La consulta del Listado A.4 se replica de forma análoga para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador, homologando el tipo de activo en cada bloque `UNION`.

A.2.2. Fragmentos Python

Elemento causante actual (OMS SP7)

```
columnas_necesarias = ['Maniobra Apertura', 'Tipo Elemento', 'Elemento_Falla']
df = pd.read_csv(ruta_actual)
df.columns = df.columns.str.strip()
df = df[columnas_necesarias].drop_duplicates()
```

Listado A.5: Fragmento Python de lectura y depuración del elemento causante actual (OMS SP7)

Parámetros meteorológicos (NASA POWER)

```
parametros_nasa = ("PRECTOT", "T2M", "T2M_MAX", "T2M_MIN", "RH2M", "WS2M")
```

Listado A.6: Definición de parámetros meteorológicos extraídos de NASA POWER

A.3. Informes reproducibles (HTML)

Los procedimientos de extracción, integración y análisis exploratorio descritos en la metodología se documentan de forma reproducible en informes HTML publicados en el repositorio del proyecto (GitHub Pages). En el cuerpo del documento se cita el apartado correspondiente de este apéndice; los hipervínculos a cada informe se concentran aquí.

A.3.1. Consolidación del panel activo–día

Informe `Consolidada.html`: detalle de los pasos 5.2.1.4 a 5.2.1.8 de integración hacia el panel consolidado. Abrir informe.

A.3.2. Agrupación cuadrante × semana

Informe `data_agrupacion.html`: construcción de la tabla de análisis a grano cuadrante × semana. Abrir informe.

A.3.3. Datos faltantes (tabla agrupada)

Informe `missing_values_grouped.html`: diagnóstico de valores faltantes en `data_agrupada.csv`. Abrir informe.

A.3.4. Valores extremos (panel consolidado)

Informe `detection_outliers.html`: identificación de valores extremos en el panel activo × día. Abrir informe.

A.3.5. Valores extremos (tabla agrupada)

Informe `outliers_gruped.html`: identificación de valores extremos en la tabla cuadrante × semana. Abrir informe.

A.3.6. Estadísticos descriptivos

Informe `calculo_estadistico_descriptivo.html`: cálculo de estadísticos descriptivos sobre la tabla agrupada. Abrir informe.

A.3.7. Distribución de variables

Informe `distribucion_variables.html`: análisis de la forma de las distribuciones (densidades, asimetría, curtosis y ceros). Abrir informe.

A.3.8. Análisis temporal de eventos

Informe `analisis_temporal_eventos.html`: series semanales, estacionalidad y autocorrelación de eventos. Abrir informe.

A.3.9. Emparejamiento evento–elemento

Informe `emparejamiento_eventos.html`: cobertura anual de la trazabilidad entre eventos BRAE e inventario GIS. Abrir informe.

A.3.10. Materialización de D_{mod}

Informe `consolidado_data_mod.html`: filtro y exportación del dataset de modelado 2024–2025. Abrir informe.

A.3.11. Identificación de patrones

Informe `identificacion_patrones.html`: patrones temporales, espaciales y clima–evento sobre D_{mod}. Abrir informe.

A.3.12. Análisis de correlación

Informe `analisis_correlacion.html`: asociaciones de Spearman entre variables climáticas y operativas. Abrir informe.

A.3.13. Análisis multivariado

Informe `analisis_multivariado.html`: VIF, PCA, agrupamiento jerárquico y GLM Poisson exploratorio. Abrir informe.

A.3.14. Segmentación exploratoria

Informe `segmentacion_exploratoria.html`: perfiles por nivel de actividad, régimen de lluvia y clustering de cuadrantes. Abrir informe.

A.3.15. EDA consolidado

Informe `EDA.html`: síntesis ejecutiva del análisis exploratorio (Etapa 3) con hallazgos y lineamientos para la Etapa 4. Abrir informe.

A.3.16. Asociación y depuración de variables cuantitativas

Informe `asociacion_depuracion_cuantitativas.html`: depuración *ex ante* de covariables cuantitativas y exportación de la matriz de diseño. Abrir informe.

A.3.17. Justificación de la agregación espacial

Informe `Etapa2_03_justificacion_agregacion_espacial.html`: justificación del grano cuadrante $\times$ semana y evidencia de concentración espacial de fallas. Abrir informe.

A.3.18. Infraestructura eléctrica por cuadrante

Informe `Etapa2_04_infraestructura_gis_cuadrante.html`: agregación de tipologías y conteos de infraestructura GIS al polígono de cada cuadrante. Abrir informe.

A.3.19. Estratificación municipal

Informe `Etapa2_05_estratificacion_municipal.html`: asignación espacial de municipio y estrato predominante a cuadrantes reales. Abrir informe.

A.3.20. Sismicidad SGC

Informe `Etapa2_07_sismicidad_sgc.html`: incorporación de sismicidad del SGC como exposición territorial del panel. Abrir informe.

A.3.21. Topología de red eléctrica

Informe `Etapa2_08_topologia_red.html`: métricas topológicas de red por cuadrante y vecindad espacial/eléctrica. Abrir informe.

A.3.22. Integración del panel final

Informe `Etapa2_09_integracion_panel_final.html`: unión de fuentes enriquecidas hacia el panel base de modelado. Abrir informe.

A.3.23. Cargue NASA POWER semanal

Informe `Etapa2_10_cargue_nasa_semana.html`: cargue de variables climáticas NASA POWER agregadas por semana. Abrir informe.

A.3.24. Cargue de eventos semanales

Informe `Etapa2_11_cargue_eventos_semana.html`: agregación de eventos y métricas de continuidad a cuadrante–semana. Abrir informe.

A.3.25. Unión del panel semanal

Informe `Etapa2_12_union_panel_semana.html`: unión semanal de clima, eventos y atributos territoriales. Abrir informe.

A.3.26. Ingeniería de variables para SAIDI y SAIFI

Informe `Etapa4_01_feature_engineering_general.html`: exploración de relaciones clima–indicador, matrices de correlación y gráficos de pares sobre el panel cuadrante–semana, como paso previo a la formalización de $SAIFI$ y $SAIDI$ con el denominador de usuarios totales. Abrir informe. *Nota:* es un informe exploratorio previo a la definición final de las respuestas; las fórmulas de trabajo

de $SAIFI$ y $SAIDI$ que emplea difieren de las adoptadas, que son las de la ecuación (5.2) (Sección 5.4.2).

A.3.27. Incorporación y selección de rezagos

Informe `Etapa4_02_rezagos_SAIDI.html`: justificación econométrica de la especificación dinámica $Y_t = X_t\beta + \gamma Y_{t-1} + \delta X_{t-1} + \varepsilon_t$ y evidencia empírica de dependencia temporal para la selección de rezagos. Abrir informe. *Nota:* informe exploratorio; la especificación de rezagos finalmente estimada es la de la Tabla 5.11.

A.3.28. Modelo espacial de SAIDI

Informe `Etapa5_01_modelo_SAIDI_espacial.html`: estimación, validación e interpretación del modelo espacial de SAIDI. Abrir informe. *Nota:* informe preliminar con la especificación contemporánea y el panel previo a la corrección de la sismicidad; las cifras definitivas son las de la re-estimación final (Apéndice A.3.30).

A.3.29. Modelo espacial de SAIFI

Informe `Etapa5_02_modelo_SAIFI_espacial.html`: estimación, validación e interpretación del modelo espacial de SAIFI. Abrir informe. *Nota:* informe preliminar; las cifras definitivas son las de la re-estimación final (Apéndice A.3.30).

A.3.30. Re-estimación final de la Etapa 5

Scripts `Etapa2_13_correccion_sismos.R` (reconstrucción de las variables sísmicas) y `Etapa5_03_reestimacion_cierre.R` (especificación *ex ante*, pronósticos de referencia, ajuste de hiperparámetros, origen móvil, Diebold–Mariano, modelos espaciales, componente de ocurrencia, atípicos y diccionario de variables). Generan todas las cifras de la Sección 6.5. Abrir carpeta de código.

A.3.31. Reporte técnico de priorización territorial

Informe `Etapa6_01_reporte_priorizacion.html`: concentración de la afectación por cuadrante, probabilidad semanal de falla, clases de prioridad, mapas y orientaciones de gestión; exporta `priorizacion_cuadrantes.csv`. Abrir informe.

A.4. Catálogo de datos y métricas de integridad

Este apéndice materializa el catálogo de datos previsto en el OE1. La Tabla A.1 documenta, para cada tipo de fuente enunciado en el objetivo, el sistema efectivamente consultado, su cobertura, sus métricas de integridad y sus limitaciones;

la Tabla A.2 presenta el diccionario de variables del panel de modelado. El objetivo exige documentar la cobertura, la calidad y las limitaciones de cada fuente: por ello, cuando una fuente se aprovechó solo de manera parcial, la tabla registra explícitamente la limitación que lo explica.

Tabla A.1: Catálogo de fuentes: cobertura, integridad y limitaciones

Fuente del OE1	Sistema o tabla consultada	Cobertura	Métricas de integridad	Limitación documentada	Uso en el modelo
SCADA/OMS y registros de fallas	BRAE `QA_TFDDREGISTRO`; OMS SPARD (`OMS.MANIOBRAS`); OMS SP7 (CSV mensuales)	2021–2025; 95 280 eventos no excluidos	`COMPONENTE_FALLADO` completo en el 100 %; emparejamiento con el inventario GIS de 30.5–31.7 % (2021–2023), 79.8 % (2024) y 95.0 % (2025)	Doble codificación sitio/activo en OMS SPARD (Sección 6.3.5); la información de los equipos de maniobra supervisados por SCADA llega al estudio a través del registro de eventos del OMS y no como serie de telemedida; solo eventos no excluidos (CREG 015 de 2018); 161 eventos de exactamente 3 min (0.41 %) por la resolución de minuto	Respuestas SAIDI/SAIFI y rezagos
GIS (inventario georreferenciado)	GTECH (`ccomun`, `cconectividad_e`)	47 649 activos; 344 cuadrantes con red	`ALTITUD` con 0.04 % de faltantes; coordenadas completas	Inventario vigente, sin histórico de altas y bajas de activos	Infraestructura, topología y vecindad
Mantenimientos	`Fecha_transformadores.csv` (`TT2_FMODIFICACION`, estado `OPERACION`)	28 878 registros (25 399 en operación); fechas de modificación entre marzo de 2023 y septiembre de 2026	0 % de faltantes; la fecha del activo más viejo es posterior a la semana del panel en el 93.2 % de las filas (edad negativa)	Registra la última modificación (67 % de las fechas en 2026) y el número de modificaciones, no la fecha de instalación original ni el tipo de intervención; la "edad" mide en realidad la distancia a la última intervención	`edad_activo_*`, `PROM_CANT_MODIFICACIONES`
Inventarios/SAC (usuarios)	`QA_TTC1`; `cant_usuarios_x_transformador.csv`; `DATA_ESTRATO_SECTOR.csv`; `data_usuarios_totales_sistema.csv`	2021–2025, mensual	Meses faltantes de los cuadrantes 258 y 273 imputados con la moda; cuadrantes 68, 140, 333 y 344 ausentes en la fuente (asignados en cero)	Usuarios asociados al transformador y no al punto exacto de conexión	Denominador UT, `usuarios_afectados`, composición de estrato y sector
Clima	NASA POWER (reanálisis MERRA-2)	Diario 2021–2025; 100 % del área de estudio	3.91 % de faltantes en el panel activo × día; 0 % en el panel cuadrante × semana	Resolución espacial gruesa; no captura tormentas convectivas de pocas horas	Clima rezagado y acumulado
Exposición externa (complementaria)	MODIS MOD13Q1 (NDVI); SGC (catálogo de sismos); DANE	2024–2025	0 % de faltantes en NDVI, sismicidad y estrato	DANE en escala municipal; dos errores de la sismicidad corregidos (Sección 5.2.7)	NDVI y sismicidad rezagados

Tabla A.2: Diccionario de variables del panel de modelado cuadrante × semana

Variable	Descripción	Unidad	Rol
`id_cuadrante`, `semana`	Identificación de la fila (cuadrante de la malla; lunes de inicio de la semana)	–	Llave
`SAIDI`, `SAIFI`	Indicadores operativos de afectación (Sección 5.4.2)	h; eventos	Respuesta
`usuarios_afectados`, `elementos_afectados`	Severidad del evento, conocida solo al cerrarlo	usuarios; elementos	Excluida (*ex post*)
`n_eventos`, `duracion_total`	Insumos de la respuesta	eventos; h	Solo rezagadas
`temp_media_semana`, `viento_max_semana`, `precip_total_semana`, `precip_ma4`	Clima semanal NASA POWER	°C; m/s; mm	Predictora ($t-1$)
`ndvi_semanal`, `ndvi_vecinos`	Índice de vegetación MODIS del cuadrante y de sus vecinos	adimensional	Predictora ($t-1$)
`n_sismos_r50`, `dist_sismo_min_km_r50`	Sismos a menos de 50 km del centroide; distancia al epicentro más cercano de la semana (SGC)	conteo; km	Predictora ($t-1$)
`longitud_red_km`, `densidad_terminales`, `n_elementos`	Topología e infraestructura de red	km; nodos/km; elementos	Predictora
`prop_estrato_1`, `prop_estrato_2`, `prop_no_residencial`	Composición de usuarios del cuadrante	proporción	Predictora
`edad_activo_mas_viejo_anios`, `PROM_CANT_MODIFICACIONES`	Años desde la última modificación registrada del transformador más antiguo (negativa en el 93.2 % de las filas) y número medio de modificaciones	años; modificaciones	Predictora
`SAIDI_lag1`, `SAIFI_lag1`, `*_vecinos_lag1`	Rezago propio y espacial de la respuesta	–	Predictora

A.5. Robustez de la construcción del indicador operativo

Para verificar que la forma agregada del numerador de $\mathrm{SAIDI}_{q,s}$ no altera las conclusiones, se recalculó el indicador evento a evento, $\mathrm{SAIDI}^{\mathrm{ev}}_{q,s} = \sum_{i \in (q,s)} D_i \, NU_i \,/\, UT_{m(s)}$, a partir de `tabla_eventos_ajustado.csv`, asignando cada evento a su cuadrante mediante el elemento fallado (`ELEMENTO_FALLA_CUADRANTE_800`) y a la semana de su fecha de desconexión. La comparación se realizó sobre las 13 350 semanas con falla de D_{mod} para las que existe la versión evento a evento (de 13 351); en el 95.5 % de ellas el número de eventos coincide con el registrado en el panel. La Tabla A.3 resume la concordancia.

Tabla A.3: Concordancia entre la versión agregada y la versión evento a evento de $\mathrm{SAIDI}_{q,s}$ (D_{mod}, semanas con falla)

Medida	Valor
Semanas con falla con un único evento (%)	46.3
Correlación de Spearman entre versiones	0.874
Coincidencia del grupo de 20 cuadrantes con mayor SAIDI promedio (%)	65
Razón mediana entre la versión agregada y la versión evento a evento	1.80
Rango intercuartílico de la razón	1.00–4.67

La lectura de la tabla tiene dos partes. En *orden*, ambas versiones son altamente concordantes: la correlación de rangos es de 0.87 y trece de los veinte cuadrantes más críticos coinciden, de modo que la priorización territorial, que es el uso que este trabajo da al indicador, no depende de la forma del numerador. En *nivel*, en cambio, la versión agregada sobrestima la evento a evento en las semanas con varios eventos, porque el producto de la duración total por el total de usuarios afectados excede la suma de los productos por evento; la razón vale exactamente 1 en las semanas con un único evento ($46.3\,\%$) y crece con el número de eventos. En consecuencia, los valores de $\mathrm{SAIDI}_{q,s}$ se interpretan como un índice de severidad relativa para ordenar y anticipar la afectación, no como minutos de SAIDI sumables al indicador de la empresa. Para $\mathrm{SAIFI}_{q,s}$ esta diferencia no existe, porque su numerador ya es la suma de los usuarios afectados por evento.

A.6. Artefactos reproducibles y reportes técnicos

Este apéndice reúne la evidencia de la cuarta pregunta de sistematización. Los *artefactos reproducibles* del proyecto son: (i) los informes R Markdown de cada etapa, publicados en HTML (Apéndice A.3); (ii) el repositorio de código `https://github.com/esilvas1/DataCollection_Tesis_MCD`, cuyo archivo `Scripts/README_reproducibilidad.md` indica el orden de ejecución de cada etapa, los productos que genera y la verificación numérica de la re-estimación; y (iii) el entorno de ejecución, documentado con las versiones de R y de los paquetes empleados (`sessionInfo`), con `requirements.txt` para los scripts de Python y con un `Dockerfile` basado en la imagen `rocker/geospatial`; el script `instalar_entorno.R` permite además fijar esas versiones en un archivo `renv.lock` para reconstruir el mismo entorno en otra máquina. Todos los modelos aleatorios usan semilla fija.

Los *reportes técnicos* alineados con los entregables del proyecto son tres:

1. *Informe descriptivo y exploratorio*: síntesis del EDA con hallazgos y lineamientos para el modelado (informe HTML; Apéndice A.3.15).

2. *Informe de evaluación de modelos*: estimación, validación, diagnóstico de supuestos y pruebas de robustez de los modelos de SAIDI y SAIFI (informe SAIDI y informe SAIFI; Apéndices A.3.28 y A.3.29).

3. *Reporte técnico de variables relevantes y priorización territorial*: ranking de los cuadrantes con mayor contribución esperada a SAIDI y SAIFI, variables que la explican y acciones de gestión asociadas (mantenimiento, poda e inversión), orientado al uso operativo y al seguimiento de la meta regulatoria (informe HTML; Apéndice A.3.31).

El reporte de priorización muestra que la afectación está muy concentrada: 6 de los 344 cuadrantes (1.7 %) acumulan la mitad del SAIDI operativo de 2024–2025 y 30 cuadrantes acumulan el 80 %; para SAIFI, la mitad se concentra en 9 cuadrantes y el 80 % en 41. Con ese criterio, 10 cuadrantes quedan en prioridad A (los que acumulan el primer 50 % de SAIDI o de SAIFI), 37 en prioridad B (hasta el 80 %) y 297 en seguimiento. La Tabla A.4 lista los cuadrantes de prioridad A. La probabilidad semanal de falla del clasificador validado está bien calibrada: en el decil de mayor probabilidad la tasa observada de falla en el periodo de prueba es del 90.7 %, frente al 2.0 % en el decil más bajo.

Tabla A.4: Cuadrantes de prioridad A según su participación en la afectación de 2024–2025

Cuadrante	Municipio	Rango SAIDI	% SAIDI	Rango SAIFI	% SAIFI	P(falla) semanal
117	Cúcuta	1	30.5	1	17.7	98 %
107	Los Patios	2	7.0	2	7.9	96 %
296	Tibú	3	4.0	8	2.5	68 %
116	Cúcuta	4	3.4	6	3.3	93 %
126	Cúcuta	5	3.0	4	4.2	98 %
198	Cúcuta	6	2.4	10	2.3	69 %
310	Tibú	9	1.8	3	5.6	78 %
203	Aguachica	11	1.7	5	3.9	89 %
38	Pamplona	18	1.1	9	2.4	86 %
190	Ocaña	42	0.4	7	2.6	60 %

Nota: participación en la suma de los indicadores operativos por cuadrante–semana; se interpreta como orden relativo y no como fracción del indicador regulatorio (Apéndice A.5). P(falla): probabilidad media pronosticada en las 16 semanas de prueba.

A.7. Muestra completa de tablas base del proyecto

Esta sección presenta, con todas las columnas y divididas en los bloques temáticos originales, las muestras ilustrativas de las dos tablas base descritas en la Etapa 2 de la metodología (Secciones 5.2.1 y 5.2.5). Las vistas previas de estas mismas filas, con un subconjunto representativo de columnas, se presentan en el cuerpo del documento (Tablas 5.8 y 5.10).

A.7.1. Tabla base consolidada (activo–día)

Tabla A.5: Muestra de la tabla base consolidada (grano activo–día) – Parte 1: activo y fecha

Id activo	Tipo	Lat.	Lon.	Alt.	Fecha día
AASW4819	Aisladero	8.5786778	-72.92349	219	01/01/2021
1T12452	Transformador	8.5839989	-72.92248	241	01/01/2021
REC21365	Reconectador	8.5840628	-72.92246	241	01/01/2021
CUC12345	Cuchilla	7.7523729	-73.23971	1236	01/01/2021
INT39845	Interruptor	7.7476080	-73.25551	1359	02/01/2021
AASW4820	Aisladero	7.7561057	-73.26037	1169	02/01/2021
1T12453	Aisladero	7.7409332	-73.20825	1636	02/01/2021
REC21366	Transformador	7.7428641	-73.18990	1542	02/01/2021
CUC12346	Reconectador	7.7538839	-73.17721	1707	03/01/2021

Tabla A.6: Muestra de la tabla base consolidada (grano activo–día) – Parte 2: severidad y clima inicial (continuación)

Id activo	Fecha día	C. elem.	C. usu.	Vel. viento	Temp. med.
AASW4819	01/01/2021	0	0	1.11	23.91
1T12452	01/01/2021	0	0	1.23	24.58
REC21365	01/01/2021	125	2015	0.96	23.04
CUC12345	01/01/2021	0	0	0.81	23.02
INT39845	02/01/2021	0	0	1.05	23.83
AASW4820	02/01/2021	0	0	1.12	24.08
1T12453	02/01/2021	0	0	1.08	24.52
REC21366	02/01/2021	0	0	1.26	24.37
CUC12346	03/01/2021	0	0	1.41	24.34

Tabla A.7: Muestra de la tabla base consolidada (grano activo–día) – Parte 3: clima complementario (continuación)

Id activo	Fecha día	Hum. rel.	Temp. min.	Temp. max.	Precip.
AASW4819	01/01/2021	78.91	20.06	29.98	3.19
1T12452	01/01/2021	75.79	20.27	30.90	1.31
REC21365	01/01/2021	83.94	20.26	27.82	3.19
CUC12345	01/01/2021	79.55	17.92	30.09	7.28
INT39845	02/01/2021	69.70	19.35	30.79	1.99
AASW4820	02/01/2021	61.99	17.20	30.81	0.98
1T12453	02/01/2021	72.16	20.38	30.59	2.70
REC21366	02/01/2021	75.50	20.18	30.63	3.29
CUC12346	03/01/2021	74.34	20.40	30.43	1.86

Nota: las filas de las Tablas A.5 a A.8 corresponden al mismo conjunto de observaciones en el mismo orden.

Tabla A.8: Muestra de la tabla base consolidada (grano activo–día) – Parte 4: variables de continuidad (continuación)

Duración (min)	Frecuencia
0	0
0	0
421.5	3
0	0
0	0
0	0
0	0
0	0
0	0

A.7.2. Tabla base semanal cuadrante

Tabla A.9: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo

Id cuad.	Semana	Lat.	Lon.	Alt.	Usu. afect.	Elem. afect.
1	28/12/2020	7.0012	-72.6855	3418	0	0
1	04/01/2021	7.0012	-72.6855	3418	0	0
3	04/01/2021	7.1548	-72.7196	2850	0	0
12	11/01/2021	7.4521	-72.8903	1240	842	18
45	18/01/2021	7.7539	-73.1204	890	0	0
117	25/01/2021	7.9215	-72.5021	286	1254	24
203	01/02/2021	8.0812	-72.4108	312	0	0
45	08/02/2021	7.7539	-73.1204	890	315	6
117	15/02/2021	7.9215	-72.5021	286	680	11

Tabla A.10: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 2: temperatura (continuación)

Id cuad.	Semana	Temp. med.	Temp. max.	Temp. min.
1	28/12/2020	13.6	19.8	6.2
1	04/01/2021	12.8	18.5	5.8
3	04/01/2021	13.1	19.2	6.0
12	11/01/2021	22.4	28.6	16.8
45	18/01/2021	23.8	30.1	18.2
117	25/01/2021	24.1	30.4	18.9
203	01/02/2021	24.5	30.8	19.1
45	08/02/2021	23.5	29.7	17.8
117	15/02/2021	24.3	30.2	18.6

Nota: las filas de las Tablas A.9 a A.12 corresponden al mismo conjunto de observaciones en el mismo orden. Cadena de unidades de continuidad: panel diario

Tabla A.11: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación)

Id cuad.	Semana	Hum. med.	Vel. med.	Vel. max.	Precip.
1	28/12/2020	82.4	1.15	2.31	18.5
1	04/01/2021	80.1	1.08	2.18	12.3
3	04/01/2021	81.6	1.12	2.25	15.7
12	11/01/2021	76.3	0.98	1.95	8.4
45	18/01/2021	74.8	1.05	2.10	6.2
117	25/01/2021	73.5	1.18	2.42	9.8
203	01/02/2021	72.9	1.22	2.55	4.1
45	08/02/2021	75.2	1.09	2.08	11.6
117	15/02/2021	74.1	1.14	2.35	7.3

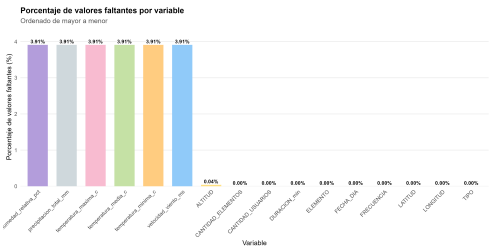
Tabla A.12: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación)

N eventos	Duración total (h)
0	0.0
0	0.0
0	0.0
5	28.4
0	0.0
8	41.7
0	0.0
2	12.6
4	22.3

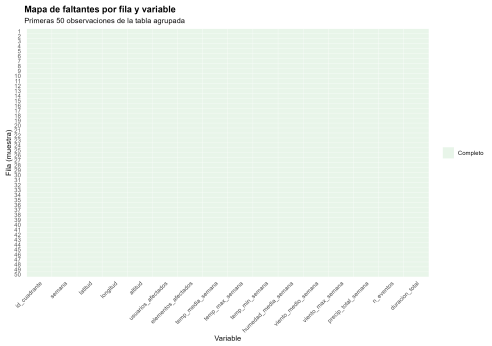
en minutos (`DURACION_min`) → conversión `/60` → `duracion_total` semanal en horas.

A.8. Figuras complementarias de completitud, extremos y localización territorial

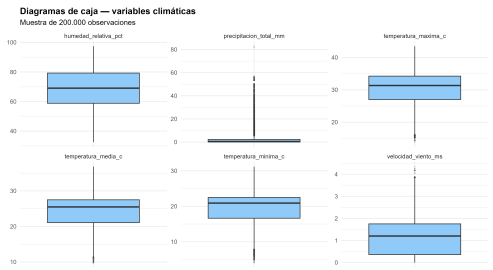
Esta sección reúne, en cuadrículas de cuatro figuras por página, las visualizaciones de apoyo del análisis exploratorio (Sección 6.3.1, 6.3.2, 6.3.3, 6.3.6 y 6.3.9) cuya lectura no es indispensable en el cuerpo principal del documento. El comentario e interpretación de cada una se mantiene en el capítulo de Metodología, junto a la referencia cruzada correspondiente.



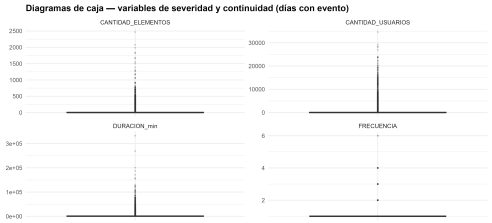
(a) Porcentaje de valores faltantes por variable en el panel consolidado ($N = 87\,007\,074$).



(b) Completitud de la tabla agrupada por fila y variable ($N_{\text{agr}} = 90\,128$; muestra de 50 filas).



(c) Distribución de las variables climáticas: mediana y extremos (muestra de 200 000 observaciones).

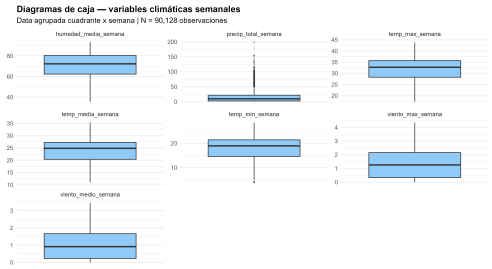


(d) Distribución de la severidad y continuidad en días con evento: mediana y extremos.

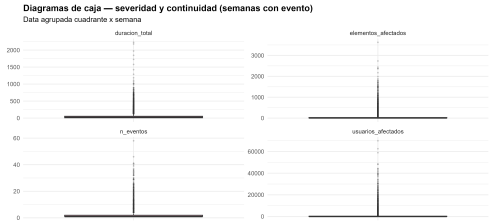
Figura A.2: Completitud del panel consolidado y extremos en variables diarias.

A.9. Figuras complementarias del análisis exploratorio

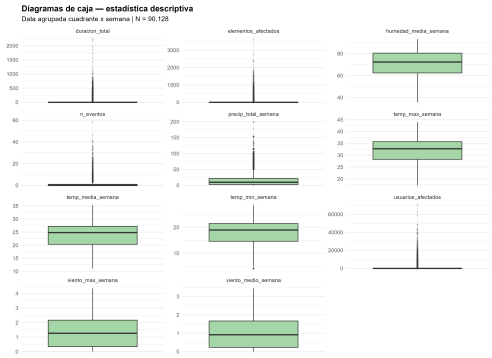
Este apéndice reúne las figuras del análisis exploratorio (Capítulo 6, Etapa 3) que documentan los hallazgos descritos en el texto pero no sustentan por sí



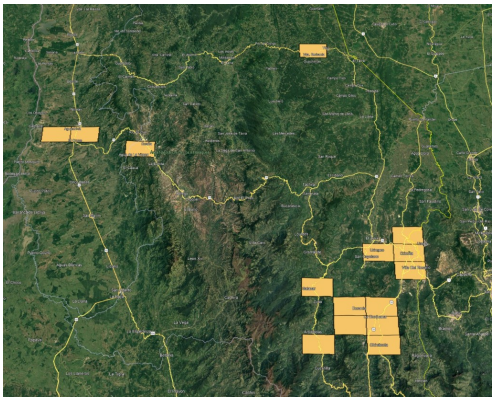
(a) Distribución de las variables climáticas semanales: mediana y extremos ($N_{\text{agr}} = 90\,128$).



(b) Distribución de la severidad y continuidad en semanas con evento: mediana y extremos.

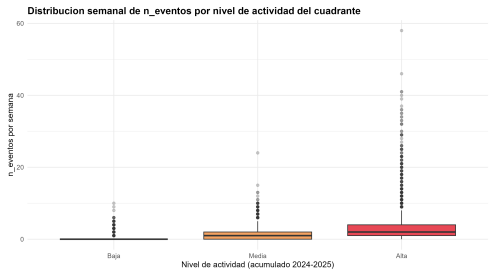


(c) Distribución de las variables numéricas de la tabla agrupada: mediana y extremos ($N_{\text{agr}} = 90\,128$).

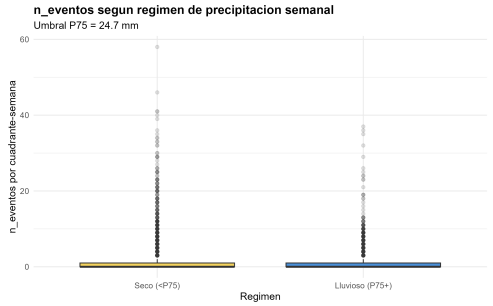


(d) Ubicación geográfica de los cuadrantes *top* con mayor acumulado de eventos en D_{mod} (2024–2025). Los recuadros resaltados identifican la posición espacial de los primeros cuadrantes del ranking.

Figura A.3: Extremos en variables agregadas y localización de los cuadrantes más activos.



(a) Distribución semanal de `n_eventos` por nivel de actividad del cuadrante (D_{mod}).



(b) `n_eventos` según régimen de precipitación semanal (umbral P75).

Figura A.4: Segmentación exploratoria de `n_eventos` por nivel de actividad y régimen de lluvia.

mismas una decisión metodológica. Las figuras que sí lo hacen se conservan en el cuerpo del documento.

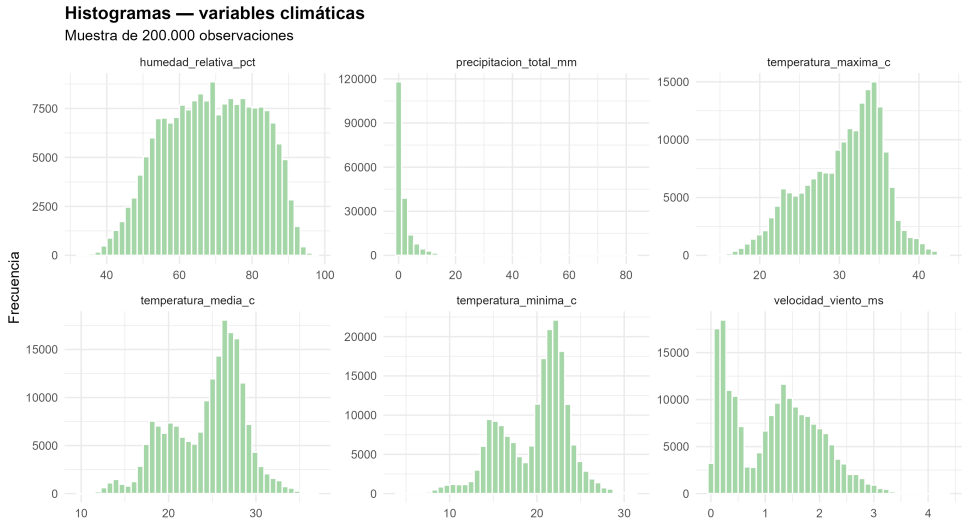


Figura A.5: Distribución de las variables climáticas: forma y cola (muestra de 200 000 observaciones).



Figura A.6: Distribución de la severidad y continuidad en días con evento: forma y cola.

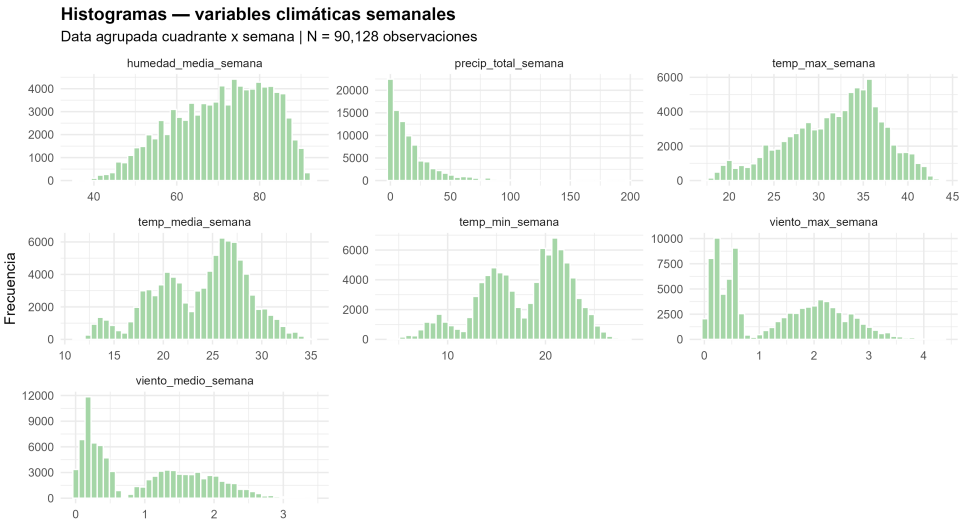


Figura A.7: Distribución de las variables climáticas semanales: forma y cola ($N_{\text{agr}} = 90\,128$).

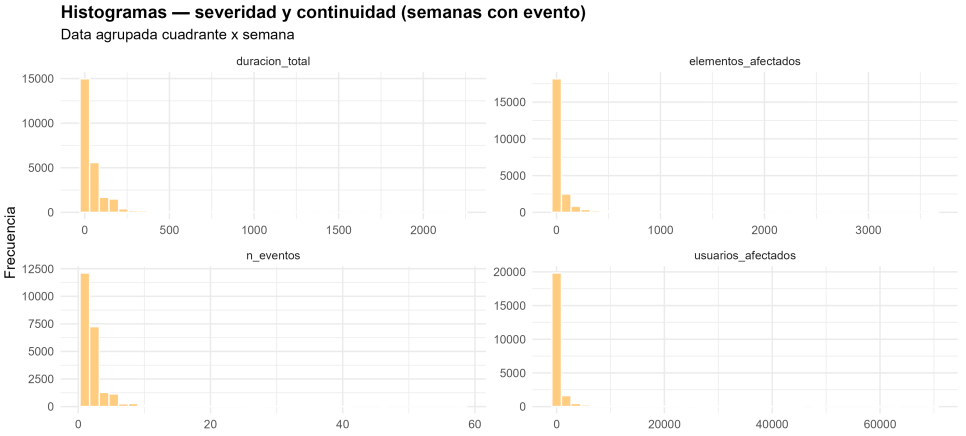


Figura A.8: Distribución de la severidad y continuidad en semanas con evento: forma y cola.

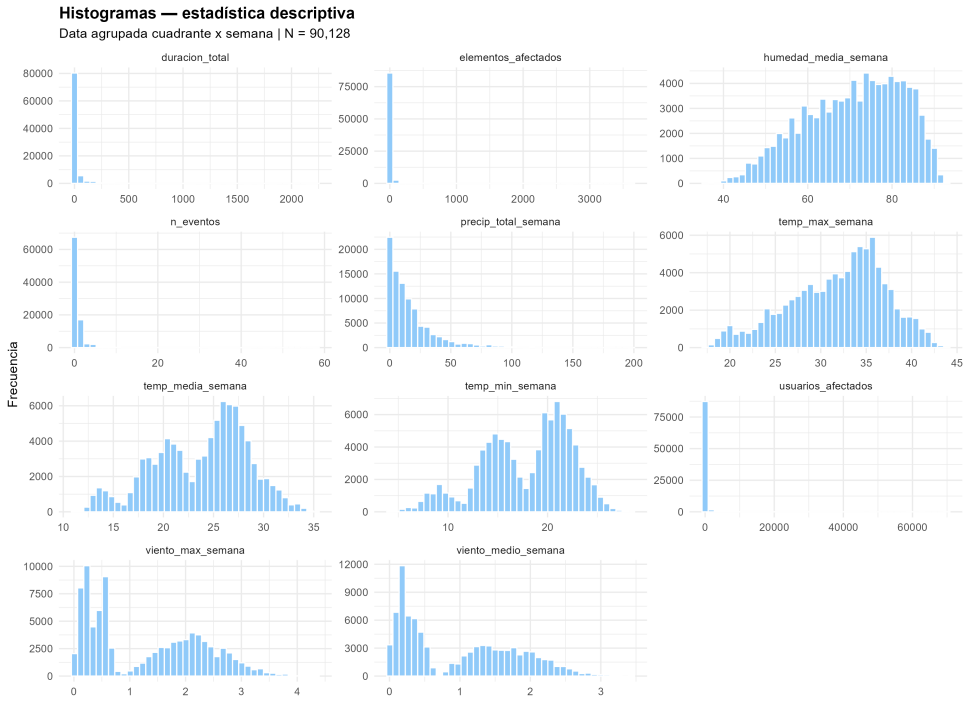


Figura A.9: Distribución de las variables numéricas de la tabla agrupada: forma y cola ($N_{\text{agr}} = 90\,128$).

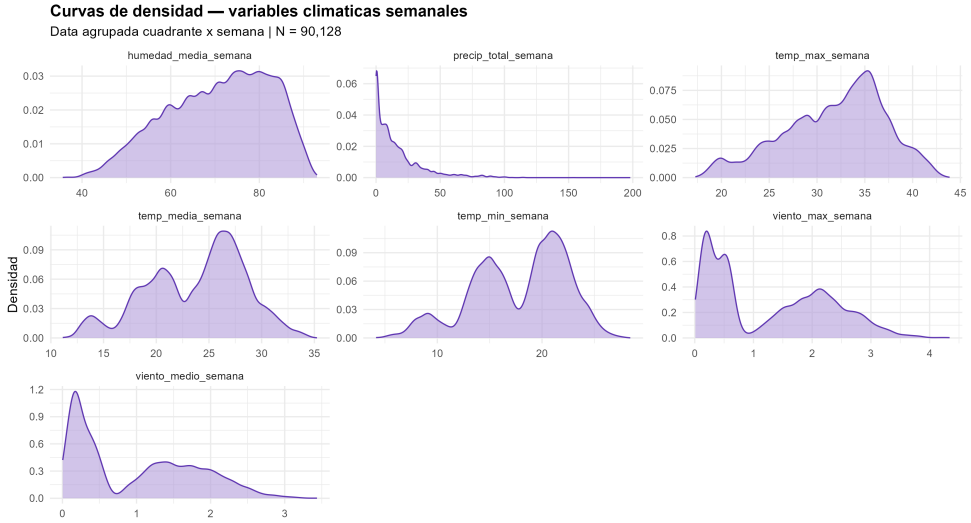


Figura A.10: Forma de la distribución de las variables climáticas semanales ($N_{\text{agr}} = 90\,128$).

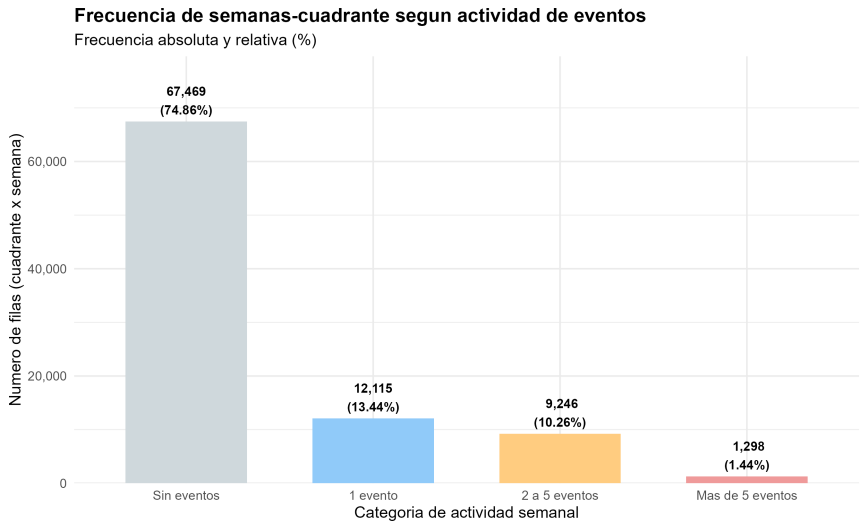


Figura A.11: Frecuencia de semanas-cuadrante según actividad de eventos ($N_{\text{agr}} = 90\,128$).

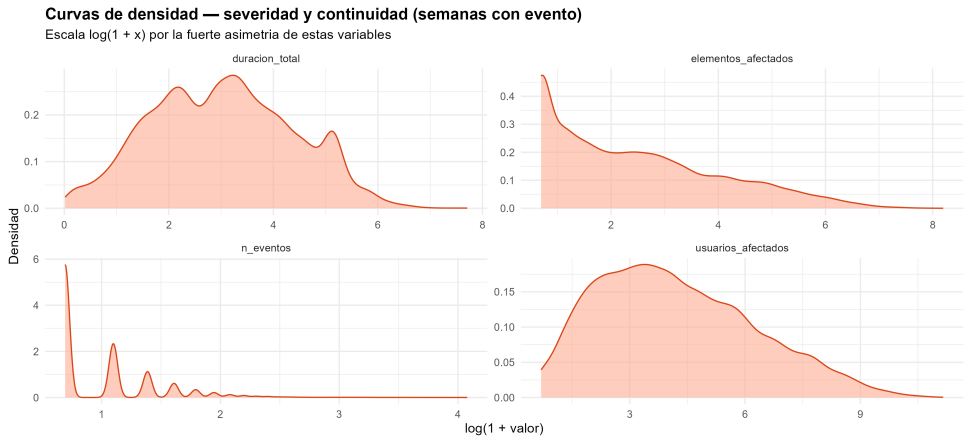


Figura A.12: Distribución de la severidad y continuidad en escala logarítmica desplazada (semanas con evento).

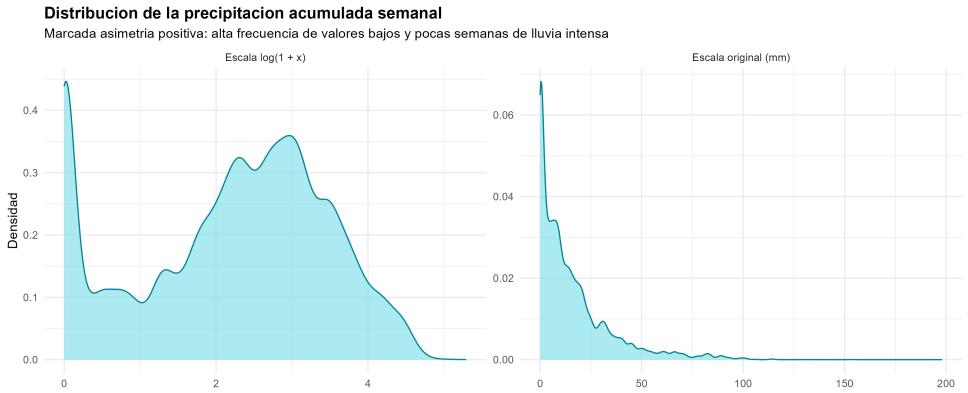


Figura A.13: Distribución de la precipitación acumulada semanal en escala original y logarítmica desplazada ($N_{\text{agr}} = 90\,128$).

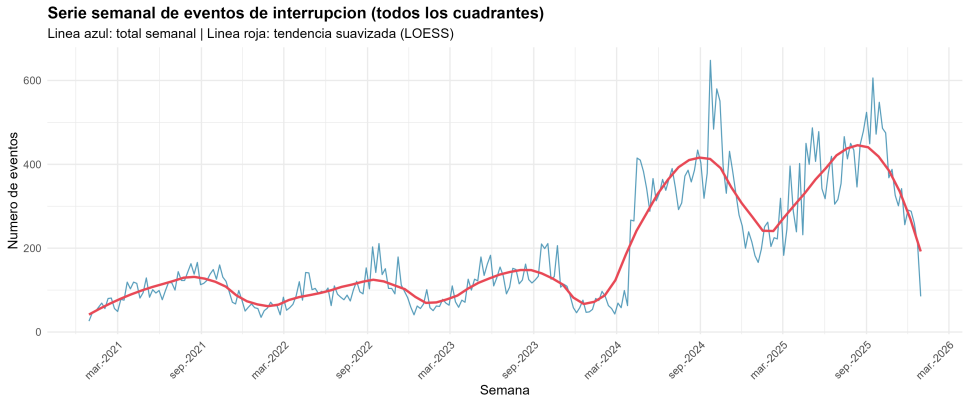


Figura A.14: Evolución semanal de los eventos de interrupción (suma territorial), 2021–2025.

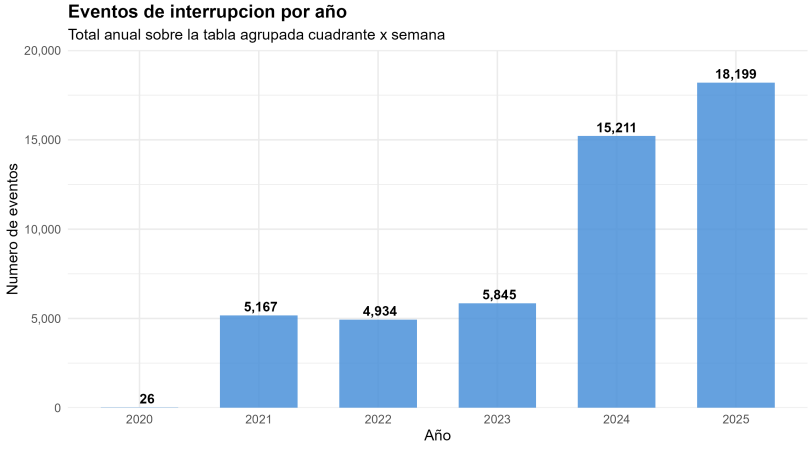


Figura A.15: Total anual de eventos de interrupción sobre la tabla agrupada.

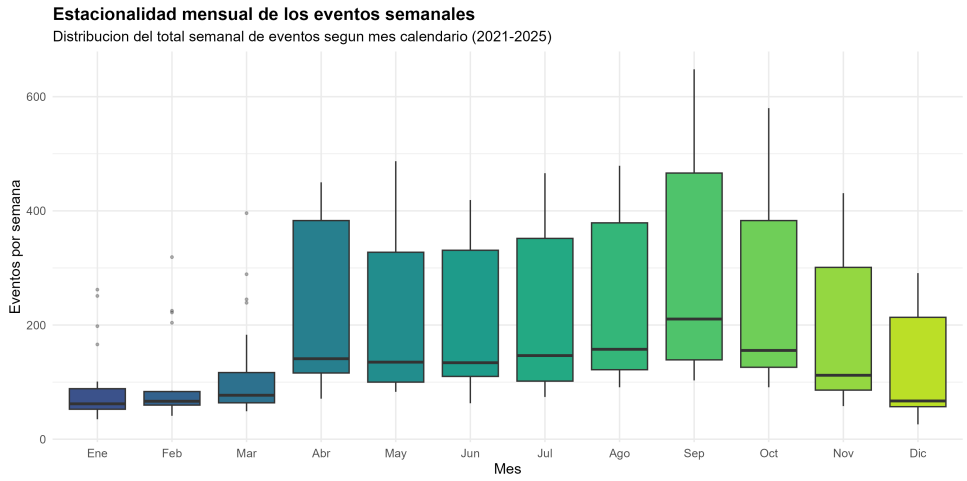


Figura A.16: Distribución del total semanal de eventos según mes calendario (2021–2025).

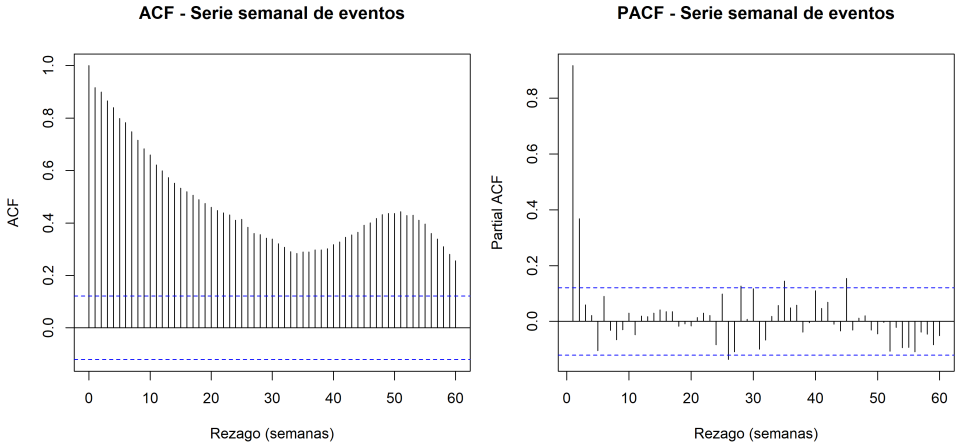


Figura A.17: Persistencia y estructura temporal de la serie semanal de eventos (rezagos en semanas).

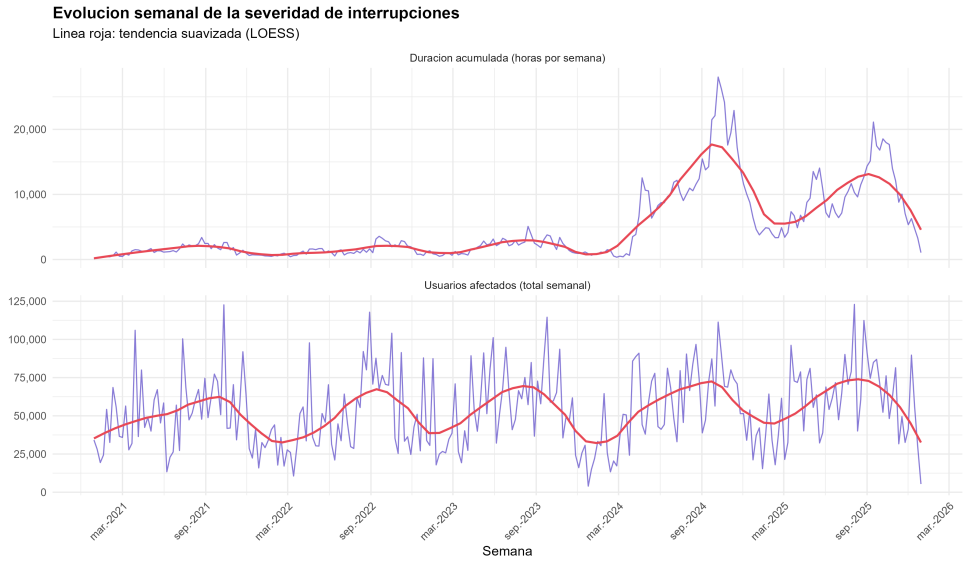


Figura A.18: Evolución semanal de usuarios afectados y duración acumulada.

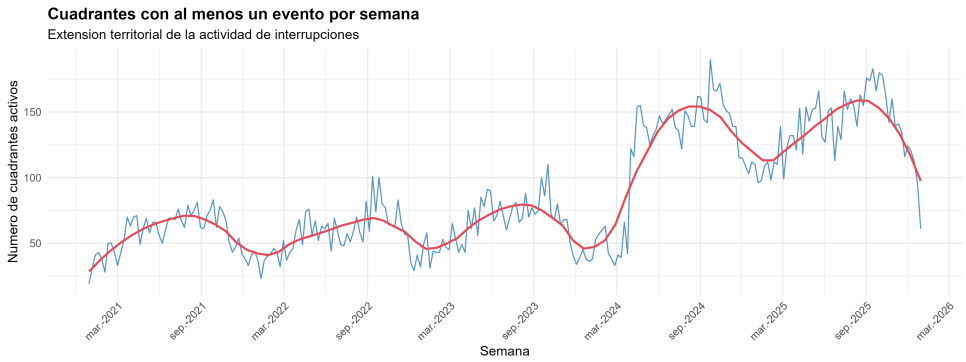


Figura A.19: Número de cuadrantes con al menos un evento por semana (extensión territorial de la actividad).

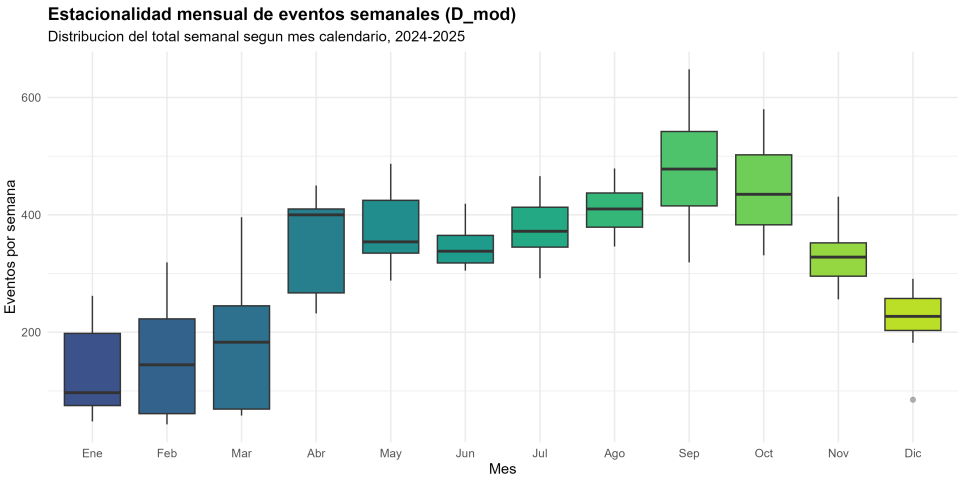


Figura A.20: Estacionalidad mensual del total semanal de eventos en D_{mod}.

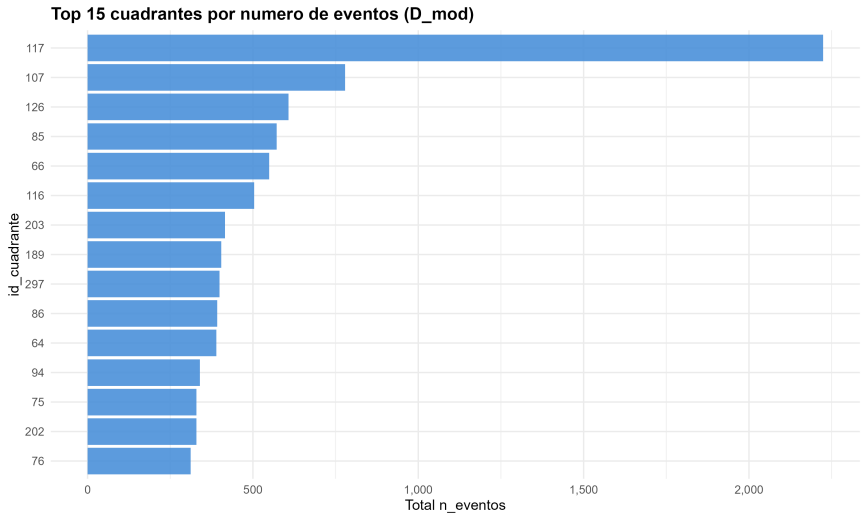


Figura A.21: Quince cuadrantes con mayor número acumulado de eventos en D_{mod}.

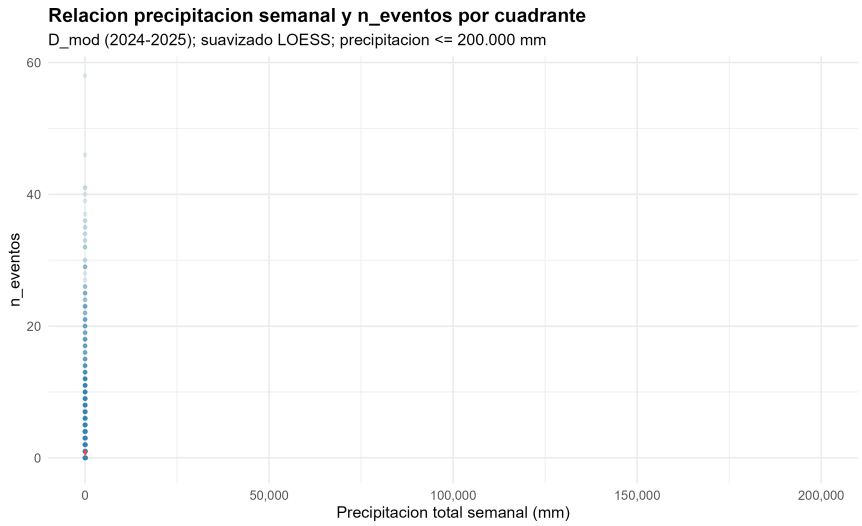


Figura A.22: Relación entre precipitación semanal y frecuencia de eventos por cuadrante en D_{mod}.

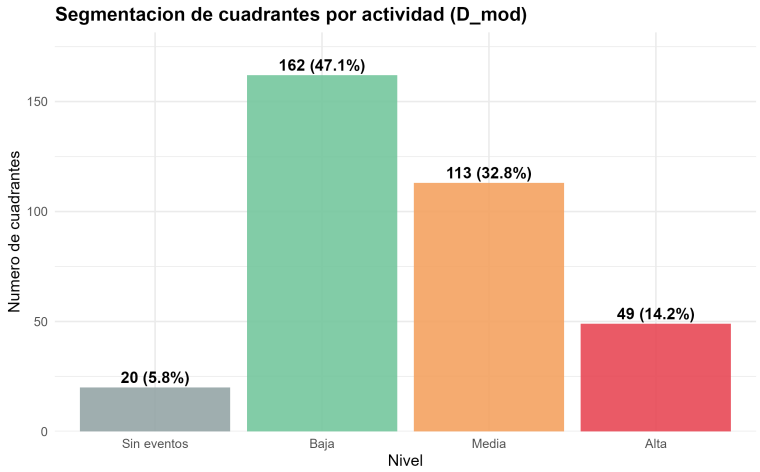


Figura A.23: Segmentación de cuadrantes por nivel de actividad acumulada en D_{mod}.

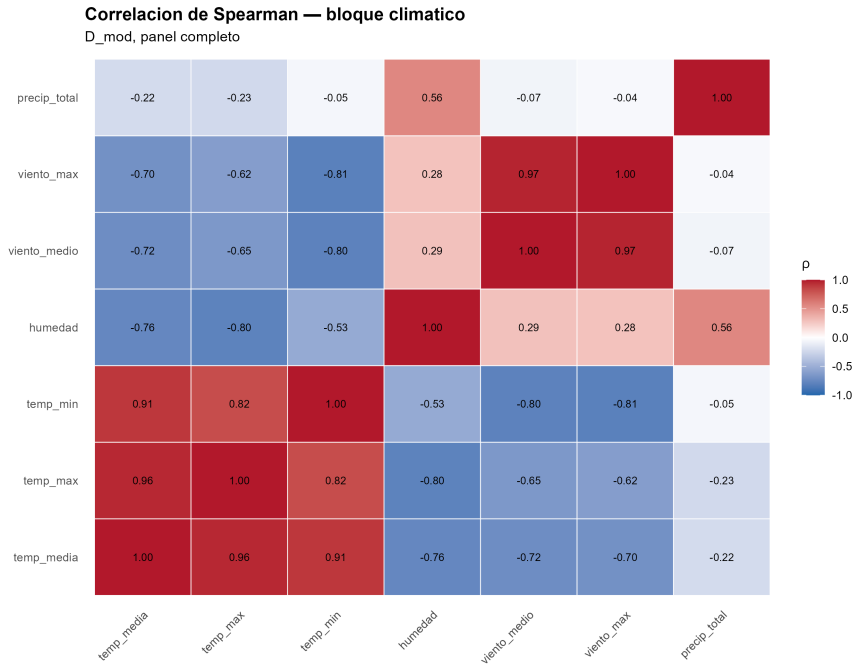


Figura A.24: Correlaciones de Spearman en el bloque climático semanal (D_{mod}).

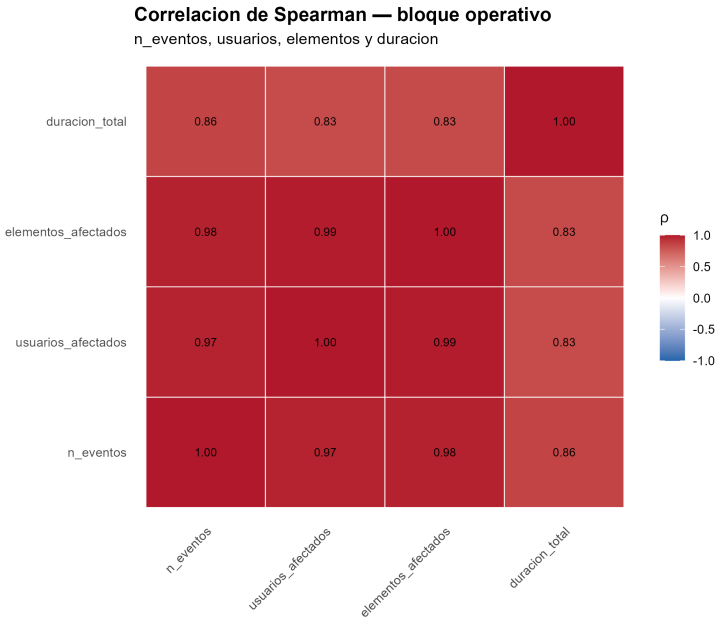


Figura A.25: Correlaciones de Spearman entre variables operativas en D_{mod}.

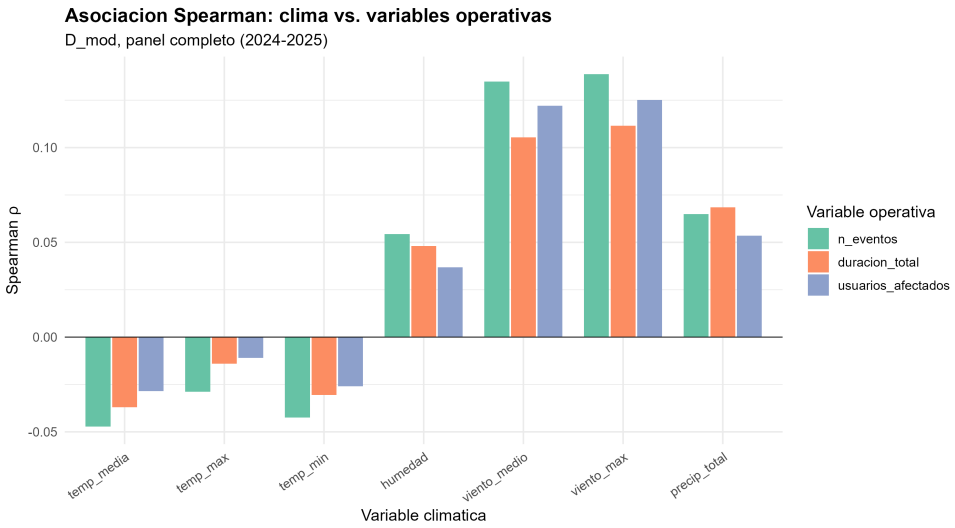


Figura A.26: Coeficientes de Spearman entre variables climáticas y operativas en D_{mod}.

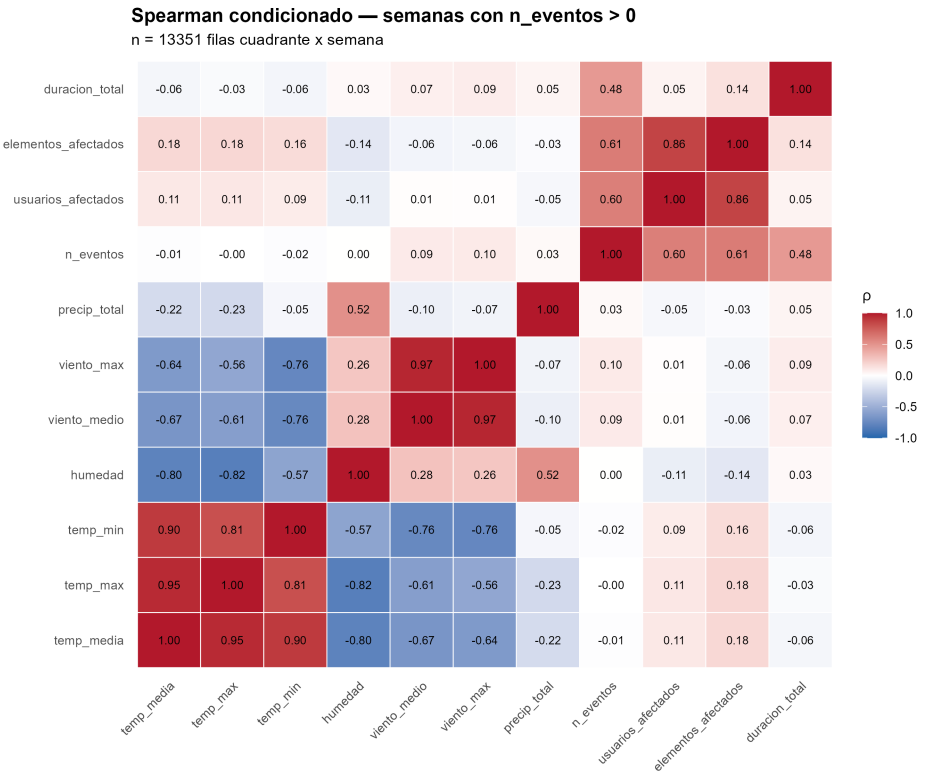


Figura A.27: Correlaciones de Spearman en semanas-cuadrante con `n_eventos` > 0 ($n = 13\,351$).

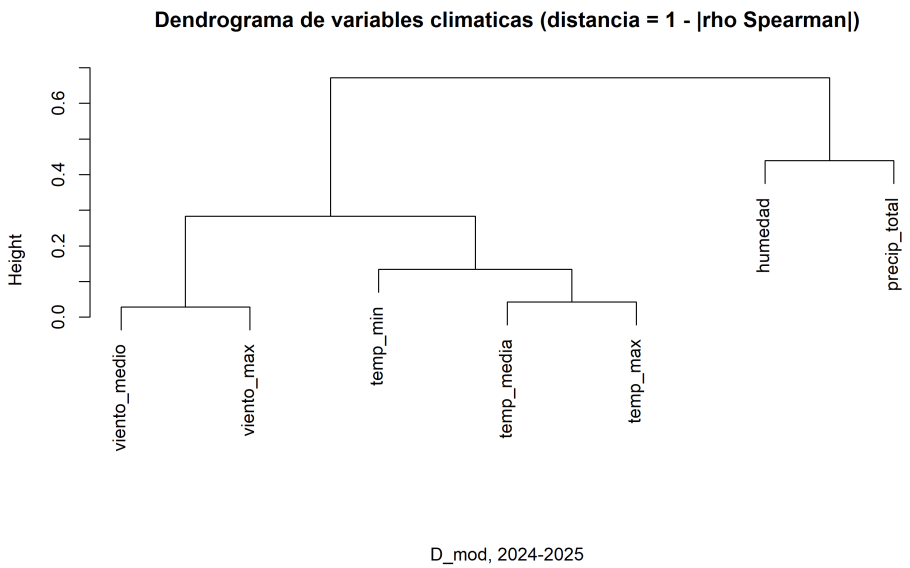


Figura A.28: Agrupamiento de redundancias entre variables climáticas (Sección 3.1.2).

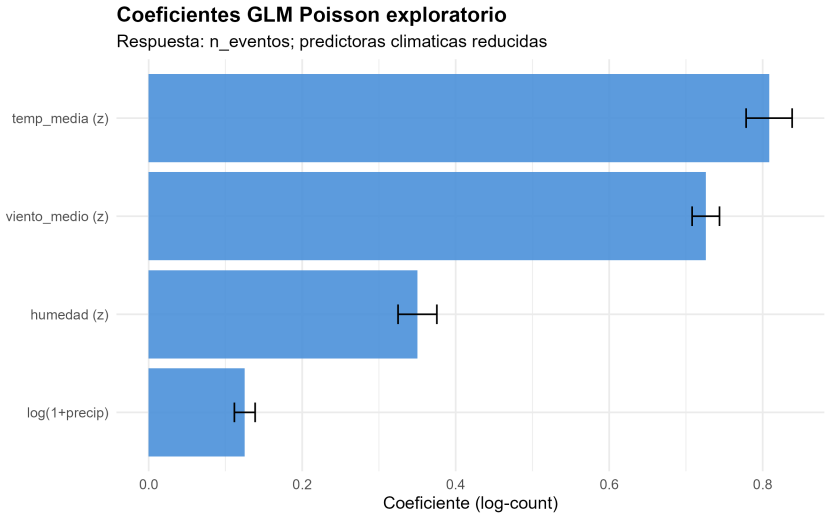


Figura A.29: Efecto conjunto del clima reducido sobre la frecuencia de eventos (diagnóstico EDA).

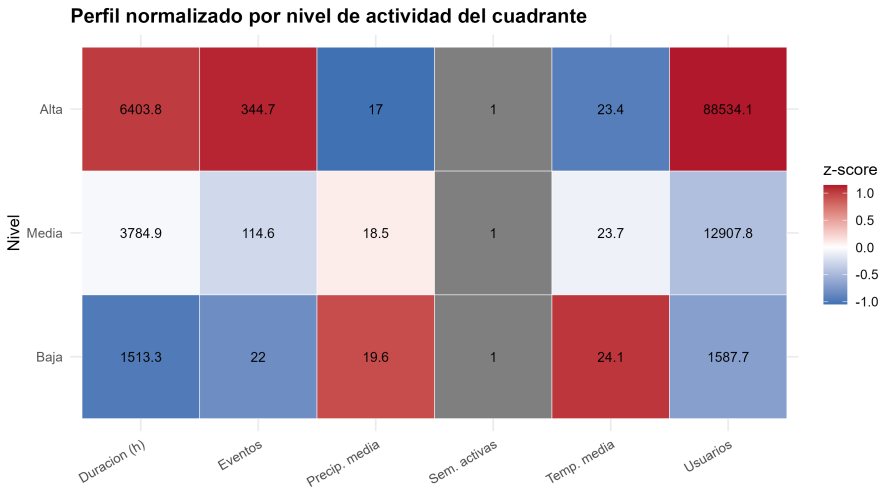


Figura A.30: Perfil normalizado por nivel de actividad (eventos, usuarios, duración, semanas activas, clima).

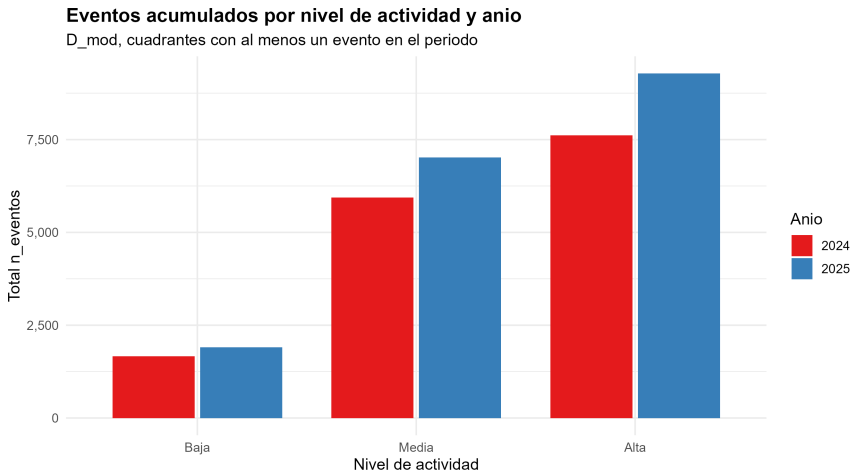


Figura A.31: Eventos acumulados por nivel de actividad y año en D_{mod}.

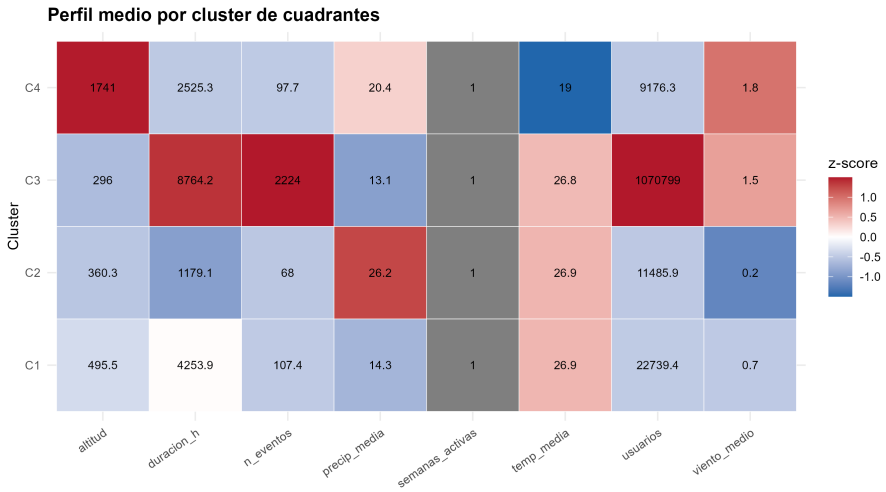


Figura A.32: Perfil medio por cluster de cuadrantes (variables operativas y climáticas).

A.10. Análisis de componentes principales (PCA) exploratorio

El equipo realizó un ejercicio de PCA exploratorio sobre los bloques climático y operativo de D_{mod}, documentado en detalle a continuación. Se trató de un diagnóstico de redundancia entre covariables, no de una técnica de reducción de dimensionalidad empleada para construir predictoras: ninguna componente principal se utilizó como insumo de los modelos de la Etapa 5. Las decisiones de selección de variables se basaron, en cambio, en el VIF y en el agrupamiento jerárquico presentados en la Sección 6.3.8.

A.10.1. PCA exploratorio del bloque climático

Variables de entrada. Ingresan las siete variables climáticas semanales de D_{mod} ($n = 36\,120$ filas cuadrante $\times$ semana; $p = 7$): `temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`, `viento_medio_semana`, `viento_max_semana` y `precip_total_semana`.

Condiciones de aplicación. Las siete son cuantitativas continuas; $n \gg p$; no hay faltantes en D_{mod}; y se homogenizan mediante estandarización (z-scores) porque tienen distintas unidades (°C, %, m/s, mm). El PCA se ejecuta sobre la matriz de correlaciones implícita en la estandarización (`prcomp` sobre la matriz centrada y escalada).

Varianza retenida y pesos (loadings). Las dos primeras componentes condensan el $87.3\,\%$ de la varianza (PC1: $66.9\,\%$; PC2: $20.4\,\%$) y PC3 aporta un $8.3\,\%$ adicional (acumulado $95.6\,\%$; Figura A.33a). La Tabla A.13 y la Figura A.33b reportan las cargas:

- *PC1 (eje térmico–viento):* dominan las temperaturas (`temp_media_semana` 0.45, `temp_max_semana` 0.43, `temp_min_semana` 0.43), con cargas negativas de viento (`viento_medio_semana` -0.40, `viento_max_semana` -0.39). La precipitación es irrelevante en este eje (-0.08).
- *PC2 (eje de humedad–lluvia):* la variable más importante es `precip_total_semana` (0.70), seguida de `humedad_media_semana` (0.51).
- *PC3:* contrastan precipitación (-0.66) y viento máximo (-0.43) frente a humedad (0.32), con contribución adicional del viento medio (-0.37).

En síntesis, las temperaturas (y, en sentido opuesto, el viento) concentran el peso en PC1, mientras la precipitación concentra su importancia en PC2–PC3,

resultado coherente con el VIF y el dendrograma presentados en el cuerpo del documento.

Tabla A.13: Cargas (loadings) del PCA climático: peso de cada variable por componente (D_{mod}; PC1–PC3)

Variable	PC1	PC2	PC3
temp_media_semana	0.45	−0,07	−0,22
temp_max_semana	0.43	−0,12	−0,28
temp_min_semana	0.43	0.11	−0,10
humedad_media_semana	−0,33	0.51	0.32
viento_medio_semana	−0,40	−0,33	−0,37
viento_max_semana	−0,39	−0,33	−0,43
precip_total_semana	−0,08	0.70	−0,66

Nota: se destacan como relevantes en la interpretación las cargas con valor absoluto ≥ 0.40.

A.10.2. PCA exploratorio del bloque operativo

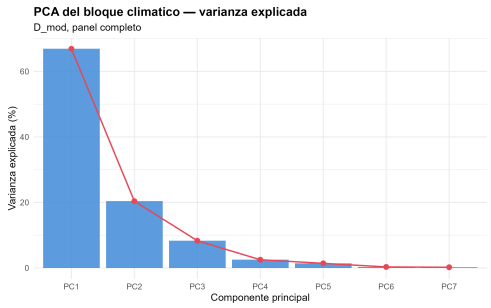
De forma análoga, se aplicó un PCA exploratorio al bloque operativo de D_{mod} para delimitar dimensiones de impacto, no para construir predictoras. Ingresan las cuatro métricas `n_eventos`, `usuarios_afectados`, `elementos_afectados` y `duracion_total` ($n = 36\,120$; $p = 4$), tras transformación logarítmica desplazada y estandarización, dadas la cero-inflación, la asimetría y las distintas escalas.

PC1 concentra el $83.8\,\%$ de la varianza, con cargas elevadas y del mismo signo en las cuatro variables (Tabla A.14; Figura A.33c): las más importantes son `usuarios_afectados` (0.53) y `n_eventos` (0.52), seguidas de `elementos_afectados` (0.50) y `duracion_total` (0.45). PC2 ($11.9\,\%$; acumulado $95.7\,\%$) contrasta duración (0.81) frente a afectación (`elementos_afectados` -0.48; `usuarios_afectados` -0.33). Este resultado, junto con la evaluación multivariada del cuerpo del documento, respalda no emplear simultáneamente las cuatro variables operativas como respuestas ni como predictoras, y construir $SAIFI$ y $SAIDI$ en la Etapa 4 a partir de `usuarios_afectados` y `duracion_total`.

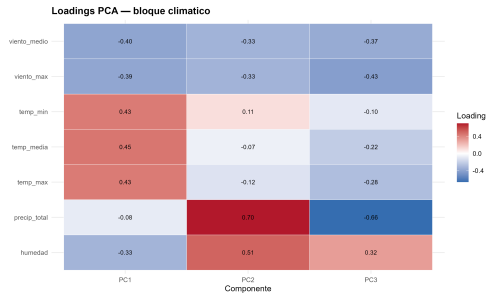
Tabla A.14: Cargas (loadings) del PCA operativo en escala logarítmica desplazada (D_{mod}; PC1–PC2)

Variable	PC1	PC2
n_eventos	0.52	0.09
usuarios_afectados	0.53	−0,33
elementos_afectados	0.50	−0,48
duracion_total	0.45	0.81

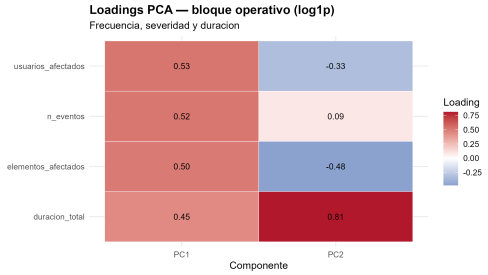
Nota: se interpretan como relevantes las cargas con valor absoluto ≥ 0.40.



(a) Varianza acumulada del bloque climático por componente principal.



(b) Peso (loadings) de las variables climáticas en las tres primeras componentes principales.



(c) Peso (loadings) de frecuencia, afectación y duración en las dos primeras componentes del bloque operativo.

Figura A.33: Figuras del PCA exploratorio climático y operativo.