



Pontificia Universidad
JAVERIANA
Cali

[VERGILADA MINEDUCACIÓN No. 12230 de 2016]

PONTIFICIA UNIVERSIDAD JAVERIANA CALI
FACULTAD DE INGENIERÍA Y CIENCIAS.
MAESTRÍA EN CIENCIA DE DATOS

Metodología Basada en Métodos de Ciencia de Datos para Pronosticar SAIDI y SAIFI en Redes de Distribución de una Empresa de Energía Eléctrica en el Norte de Santander

Edwin Henao Ochoa

Cindy Lugo Rozo

Edwin Silva Salas

DIRECTOR

Sandra Milena Ramírez Buelvas

Pontificia Universidad Javeriana



A nuestras familias y amigos
Edwin Henao Ochoa
Cindy Lugo Roza
Edwin Silva Salas

Índice general

Resumen	VIII
Introducción	x
1 Definición del problema	1
1.1 Planteamiento del problema	1
1.2 Formulación del problema	4
2 Objetivos del proyecto	6
2.1 Objetivo general	6
2.2 Objetivos específicos	6
3 Marco de referencia	7
3.1 Marco teórico	7
3.1.1 Contexto del estudio	7
3.1.2 Métodos y modelos	11
3.2 Antecedentes	16
3.2.1 Revisión de literatura	16
4 Datos	19
Tiempo o periodo de estudio.	19
Unidad muestral.	19
4.1 Construcción del dataset	19
4.1.1 Lógica estructural	19
4.1.2 Definición de variables de evento	20
4.1.3 Estructura del dataset consolidado	20
Número de observaciones.	21
Origen de la información.	21
Lugar donde se registra la información.	21
5 Metodología	22
5.1 Etapa 1 – Extracción de datos	22
Fuentes de informacion	23
5.1.1 Sistemas y fuentes consultadas	23
5.1.2 Extracción base y depuración de eventos de interrupción (BRAE)	23

5.1.3	Extracción de afectación por evento	24
5.1.4	Extracción del elemento causante histórico	25
5.1.5	Extracción del elemento causante actual	26
5.1.6	Extracción de inventario GIS	27
5.1.7	Extracción de variables meteorológicas	28
5.1.8	Resumen metodológico de extracción e integración de bases de datos	29
5.2	Etapa 2 - Integración y depuración de datos	31
5.2.1	Lógica de integración entre sistemas	31
5.2.2	Diagrama de flujo de la secuencia de integración	34
5.2.3	Descripción de la tabla base consolidada	34
5.2.4	Descripción de las variables	36
	Tabla 5.9 (severidad y clima inicial).	36
	Tabla 5.10 (clima complementario).	37
	Tabla 5.11 (variables de continuidad).	37
5.2.5	Agrupación de data consolidada por semana y cuadrante	38
	Definición del grano analítico (cuadrante $\times$ semana)	38
	Procedimiento de agregación	39
5.2.6	Descripción de la tabla base semanal cuadrante	41
5.2.7	Evidencia de calidad y confiabilidad de las fuentes	41
5.3	Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA)	45
5.3.1	Identificación de datos faltantes	45
	Tabla agrupada cuadrante $\times$ semana.	47
5.3.2	Identificación de valores extremos en variables cuantitativas	48
	Panel consolidado activo $\times$ día.	48
	Tabla agrupada cuadrante $\times$ semana.	52
5.3.3	Cálculo de estadísticos descriptivos	54
	Variables climáticas semanales.	55
	Variables de severidad y continuidad.	58
5.3.4	Análisis de la distribución de variables	58
	Variables climáticas.	60
	Variables de severidad y continuidad.	60
5.3.5	Análisis temporal de eventos	62
	Evolución de la serie semanal.	62
	Diagnóstico de cobertura del emparejamiento evento–elemento.	62
	Estacionalidad intra-anual.	64
	Autocorrelación temporal.	65
	Evolución de la severidad y extensión territorial.	66
	Materialización de D_{mod}	67
5.3.6	Identificación de patrones, tendencias y visualización exploratoria	67
	Patrones temporales.	67

	Patrones espaciales.	69
	Patrones clima–evento.	69
5.3.7	Análisis de correlación y asociación	72
	Matriz de asociación global.	72
	Bloque climático: redundancias.	73
	Bloque operativo.	74
	Clima → operativo.	74
	Análisis condicionado.	76
5.3.8	Evaluación inicial de relaciones multivariadas	76
	Multicolinealidad climática (VIF).	78
	PCA exploratorio del bloque climático.	79
	Agrupamiento jerárquico.	81
	Asociación multivariada clima → n_eventos.	82
	Dimensiones del bloque operativo.	82
5.3.9	Segmentación exploratoria	84
	Perfiles por nivel de actividad.	84
	Evolución 2024 vs 2025 por estrato.	84
	Régimen climático semanal.	86
	Clustering multivariado de cuadrantes.	86
5.3.10	Resultados y entregables de la etapa	88
5.4	Etapa 4 – Ingeniería de variables y preparación del modelo	89
5.4.1	Construcción de variables predictoras	89
5.4.2	Construcción de la variable respuesta	90
5.4.3	Análisis de asociación y depuración de variables cuantita- tivas	90
5.4.4	Análisis de asociación y depuración de variables cualitativas	90
5.4.5	Codificación de variables categóricas	90
5.4.6	Estandarización de variables cuantitativas	90
5.4.7	Generación de ventanas temporales	90
5.4.8	Partición de datos en entrenamiento y prueba	90
5.4.9	Construcción de matrices de diseño	92
5.4.10	Reducción de dimensionalidad	92
5.4.11	Segmentación analítica	92
5.4.12	Transformaciones adicionales para modelado	92
5.4.13	Resultados y entregables de la etapa	92
5.5	Etapa 5 – Modelado predictivo y evaluativo	93
5.5.1	Selección de algoritmos	93
5.5.2	Entrenamiento del modelo	93
5.5.3	Validación del modelo	93
5.5.4	Ajuste de hiperparámetros	93
5.5.5	Evaluación de desempeño	93
5.5.6	Comparación de modelos	93
5.5.7	Interpretación de resultados	93

5.5.8	Resultados y entregables de la etapa	93
5.6	Etapa 6 – Cierre metodológico, documentación y reportes	93
5.6.1	Presentación de resultados del modelo	94
5.6.2	Métricas de desempeño	94
5.6.3	Hallazgos principales	94
5.6.4	Interpretación técnica y operativa	94
5.6.5	Generación de reportes	94
5.6.6	Discusión de resultados	94
5.6.7	Limitaciones y trabajos futuros	94
5.6.8	Resultados y entregables de la etapa	94
5.7	Relación entre etapas metodológicas y objetivos específicos	94
6	Resultados	96
6.1	Resultados de la estimación del modelo	96
7	Discusión y trabajo futuro	97
7.1	Discusión	97
7.2	Trabajos futuros	97
8	Conclusiones	98
8.1	Conclusión asociada al objetivo general	98
8.2	Conclusión asociada al objetivo específico 1	98
8.3	Conclusión asociada al objetivo específico 2	98
8.4	Conclusión asociada al objetivo específico 3	98
A	Anexos	105
A.1	Diagrama de integración del panel	105
A.2	Código de extracción de datos	105
A.2.1	Consultas SQL	105
	Eventos de interrupción (BRAE)	105
	Afectación por evento (BRAE + QA_TTC1)	106
	Elemento causante histórico (OMS SPARD)	106
	Inventario georreferenciado (GIS GTECH)	106
A.2.2	Fragmentos Python	107
	Elemento causante actual (OMS SP7)	107
	Parámetros meteorológicos (NASA POWER)	107
A.3	Informes reproducibles (HTML)	108
A.3.1	Consolidación del panel activo–día	108
A.3.2	Agrupación cuadrante × semana	108
A.3.3	Datos faltantes (tabla agrupada)	108
A.3.4	Valores extremos (panel consolidado)	108
A.3.5	Valores extremos (tabla agrupada)	108
A.3.6	Estadísticos descriptivos	108
A.3.7	Distribución de variables	108
A.3.8	Análisis temporal de eventos	108

A.3.9	Emparejamiento evento–elemento	109
A.3.10	Materialización de D_{mod}	109
A.3.11	Identificación de patrones	109
A.3.12	Análisis de correlación	109
A.3.13	Análisis multivariado	109
A.3.14	Segmentación exploratoria	109
A.3.15	EDA consolidado	109
A.3.16	Asociación y depuración de variables cuantitativas	109

Resumen

La calidad del servicio de energía eléctrica en Colombia se evalúa mediante los indicadores regulatorios SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema), definidos por la CREG y vigilados por la SSPD. En la empresa de distribución objeto de estudio, ubicada en Norte de Santander, la información operativa se encuentra dispersa en plataformas heterogéneas (BRAE, OMS SPARD, OMS SP7 y GIS), con esquemas de codificación distintos y sin trazabilidad homogénea entre eventos y activos de red, lo que limita la construcción de modelos predictivos confiables e interpretables. El objetivo de este trabajo es desarrollar una metodología, basada en el estándar CRISP-DM, para pronosticar *SAIFI* y *SAIDI* por zona geográfica e identificar los factores técnicos, operativos y climáticos que explican su comportamiento. Se integraron seis fuentes corporativas y la fuente climática externa NASA POWER mediante consultas SQL y procesamiento en Python y R, conformando un panel de $N = 87.007.074$ observaciones con grano activo eléctrico $\times$ día ($A = 47.649$ activos $\times T = 1.826$ días, 2021–2025) y una tabla agregada de 90.128 observaciones con grano cuadrante $\times$ semana sobre una malla territorial de 800 celdas. El análisis exploratorio aplicó diagnóstico de valores faltantes por variable y por fila, detección de valores extremos mediante la regla de Tukey (factores 1.5 y 3.0) y percentiles P1–P99, caracterización de distribuciones asimétricas y cero-infladas, análisis de series semanales con ACF y PACF, correlación de Spearman bivariada y parcial, coeficiente de Cramér, factor de inflación de la varianza (VIF), análisis de componentes principales (PCA), agrupamiento jerárquico de variables, un modelo lineal generalizado de Poisson exploratorio y segmentación territorial mediante k -means. Los resultados de esta fase muestran que la trazabilidad evento–activo pasa de cerca del 31 % en 2021–2023 al 79.8 % en 2024 y al 95.0 % en 2025 tras la migración a OMS SP7, por lo que el universo de modelado se restringe a 2024–2025 (36.120 observaciones) con partición temporal de entrenamiento en 2024 y prueba en 2025; que la señal climática contemporánea sobre la frecuencia de interrupciones es débil en el grano cuadrante $\times$ semana y está encabezada por el viento ($\hat{\rho} = 0.14$; $p < 0.001$) por delante de la precipitación acumulada semanal ($\hat{\rho} = 0.07$, que asciende a $\hat{\rho} = 0.11$ al controlar temperatura y viento), lo que traslada el peso predictivo hacia la estructura temporal y territorial de la propia serie de eventos; que existe fuerte redundancia entre temperaturas y vientos (VIF de hasta 43.92, reducible a un máximo de 7.21 con un subconjunto de cuatro covariables) y entre las variables operativas de severidad; y que la actividad de interrupciones presenta marcada heterogeneidad espacial, con el 14.2 % de los cuadrantes concentrando la mayor parte de los eventos. Con base en estos hallazgos se definen *SAIFI* y *SAIDI* como variables respuesta, construidas en el grano de análisis con el *UT* mensual de `data_usuarios_totales_sistema.csv`, y un conjunto reduci-

do de predictoras climáticas y operativas. En la etapa siguiente se compararán modelos estadísticos y de aprendizaje automático aptos para datos no negativos con exceso de ceros y autocorrelación temporal, evaluados mediante MAE, RMSE y MAPE junto con análisis de importancia de variables. Los productos del trabajo son un repositorio analítico trazable, informes reproducibles del análisis exploratorio y lineamientos para anticipar la degradación de la continuidad del servicio, priorizar mantenimiento preventivo en zonas críticas y apoyar el cumplimiento regulatorio en beneficio de más de 600.000 usuarios de la región.

Palabras clave: continuidad del servicio eléctrico; SAIDI; SAIFI; CRISP-DM; integración de datos; análisis exploratorio de datos; modelos predictivos; variables climáticas.

Introducción

Sin duda, la energía eléctrica es vital para el progreso de cada región, tanto social, económica como industrialmente. En Colombia, el acceso a este servicio está estrictamente regulado en términos de provisión, con el objetivo de asegurar que todos los usuarios cuenten con un suministro de energía constante, seguro y de alta calidad para vivir y trabajar. Comisión de Regulación de Energía y Gas (CREG) [1]. Los operadores de red tienen de manera continua la responsabilidad de garantizar que la entrega de energía sea confiable para hogares, instituciones y negocios, evitando fallas en la prestación del servicio en cualquier tipo de edificación.

No obstante, esta tarea no es sencilla. La operación de los sistemas de distribución de energía se ve afectada por múltiples factores técnicos, ambientales y operativos, así como por la duración y frecuencia de las interrupciones del servicio. En este contexto, la Comisión de Regulación de Energía y Gas (CREG) adoptó los indicadores SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) como los criterios oficiales para evaluar la calidad del servicio en las redes de distribución, mediante la Resolución CREG 015 de 2018 Comisión de Regulación de Energía y Gas (CREG) [1]. Estos indicadores permiten evaluar el desempeño operativo y facilitan la implementación de esquemas de compensación y control por parte de la Superintendencia de Servicios Públicos Domiciliarios (SSPD) Servicios Públicos Domiciliarios [2].

Sin embargo, la gestión efectiva de estos indicadores ha resultado compleja, dada la heterogeneidad de los eventos que originan las interrupciones y la limitada conectividad de la información almacenada en sistemas dispares como SCADA, OMS, GIS, CIS y bases de datos externas.¹ Debido a que los registros operativos, climáticos y de mantenimiento se encuentran dispersos y fragmentados en múltiples plataformas, construir modelos analíticos capaces de pronosticar *SAIFI* y *SAIDI* en distintas áreas o circuitos representa un desafío significativo.

¹SCADA (*Supervisory Control and Data Acquisition*): sistema de supervisión y adquisición de datos de la operación de la red. OMS (*Outage Management System*): sistema de gestión de interrupciones. GIS (*Geographic Information System*): sistema de información geográfica de activos. CIS (*Customer Information System*): sistema de información de clientes.

Esta brecha limita la capacidad de las empresas para tomar decisiones oportunas, priorizar inversiones, mejorar la planificación del mantenimiento y responder adecuadamente a los requerimientos regulatorios. En consecuencia, resulta fundamental desarrollar herramientas apoyadas en ciencia de datos que permitan consolidar información histórica, identificar patrones relevantes y pronosticar *SAIFI* y *SAIDI*.

Este trabajo presenta técnicas para la recopilación de datos provenientes de plataformas operativas internas y fuentes externas, así como el análisis de modelos estadísticos y de aprendizaje automático orientados al **pronóstico de *SAIFI* y *SAIDI*** en una empresa de distribución de energía que opera en el departamento de Norte de Santander. Al adoptar esta estrategia, se busca anticipar cuándo y con qué intensidad operativa pueden ocurrir las interrupciones, e identificar las influencias técnicas, operativas y climáticas más relevantes en la continuidad del servicio. Este desarrollo constituye una contribución significativa para fortalecer la toma de decisiones basada en evidencia, optimizar los planes de mantenimiento, apoyar el cumplimiento regulatorio y ofrecer un caso académico aplicado sobre el uso de técnicas analíticas en el sector eléctrico regulado, beneficiando a más de 600.000 usuarios.

El documento se organiza de la siguiente manera. En la Sección 1 se presenta el planteamiento y la formulación del problema de continuidad del servicio. En la Sección 2 se exponen el objetivo general y los objetivos específicos, alineados con las preguntas de investigación. En la Sección 3 se desarrolla el marco teórico (definiciones regulatorias de *SAIDI* y *SAIFI*, exclusiones y factores asociados) y los antecedentes sobre modelación de interrupciones e indicadores de confiabilidad. En la Sección 4 se describe la fuente y la estructura de los datos empleados. En la Sección 5 se detallan las etapas metodológicas, desde la extracción e integración hasta el EDA, la ingeniería de variables y el modelamiento, orientadas al pronóstico de *SAIFI* y *SAIDI*. Posteriormente, en la Sección 6 se presentan los resultados por etapa; en la Sección 7 se discute el alcance, los aportes y las limitaciones frente a cada objetivo; y en la Sección 8 se consolidan las conclusiones del trabajo.

Definición del problema

1.1. Planteamiento del problema

Los indicadores de continuidad del servicio SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) en la empresa de distribución objeto de estudio presentan dificultades estructurales para su mejora sostenida. Si bien existen técnicas estadísticas y de aprendizaje automático ampliamente documentadas para el análisis de interrupciones en sistemas eléctricos, la principal limitación no radica en la ausencia de metodologías analíticas, sino en la calidad, estructura e interpretación de los datos disponibles, lo que dificulta el entrenamiento de modelos predictivos que sean simultáneamente confiables y explicativos Comisión de Regulación de Energía y Gas (CREG) [1], Servicios Públicos Domiciliarios [2], IEEE Power and Energy Society [3] y Wang y Chen [4]. En particular, resulta complejo detectar, cuantificar y explicar no solo las causas de las interrupciones, sino también su duración y los tiempos de restauración del servicio.

El objetivo predictivo de este trabajo son los indicadores *SAIFI* y *SAIDI* a escala de cuadrante $\times$ semana. Se construyen a partir de los registros operativos del panel, con el denominador de usuarios totales del operador (UT) tomado de la serie mensual `data_usuarios_totales_sistema.csv` y asignado a cada semana según el mes calendario de su fecha de inicio:

$$SAIFI_{q,s} = \frac{\text{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \quad SAIDI_{q,s} = \frac{\text{duracion_total}_{q,s} \times \text{usuarios_afectados}_{q,s}}{UT_{m(s)}} \quad (1.1)$$

`n_eventos` y `duracion_total` permanecen como insumos de construcción y de historial *ex ante*; no constituyen las variables a predecir. `usuarios_afectados` entra en el numerador de Y , pero no como predictora contemporánea.

Los principales obstáculos identificados son los siguientes:

- **Fragmentación de las fuentes de información:** La operación del sistema requiere el uso de múltiples registros provenientes de plataformas hetero-

géneas como SCADA, OMS, GIS, CIS,¹ bases de mantenimiento y fuentes meteorológicas externas. Estos datos se encuentran en distintos formatos, con estructuras disímiles y, en algunos casos, con ausencia de metadatos completos, lo que dificulta su integración sin pérdida de trazabilidad Ospina y López [5] y Pérez y Echeverría [6].

- **Problemas de sincronización temporal:** Los sistemas operativos no presentan una alineación temporal uniforme. Mientras algunos registran información en intervalos horarios, otros lo hacen en escalas de minutos o presentan series discontinuas. Esta falta de sincronización genera inconsistencias que afectan la estimación precisa de la duración de las interrupciones y de los tiempos de reposición del servicio Pérez y Echeverría [6].
- **Eventos extremos y ruido en los datos:** Los registros operativos de interrupciones eléctricas, provenientes de las plataformas mencionadas, contienen alta variabilidad, errores de captura, información incompleta y eventos atípicos, como fenómenos climáticos extremos o fallas excepcionales, que suelen ser excluidos del análisis. Esta situación dificulta la identificación de patrones robustos tanto a nivel agregado como local Comisión de Regulación de Energía y Gas (CREG) [1] y Huang y Zhang [7].
- **Pérdida de detalle por agregación:** El uso de indicadores promediados en escalas anuales o geográficas amplias oculta el comportamiento específico de circuitos o zonas particulares, lo que limita la identificación de causas operativamente accionables Servicios Públicos Domiciliarios [2] y Pérez y Echeverría [6].
- **Ausencia de estándares de datos:** La falta de catálogos de datos, definiciones homogéneas y métricas de integridad impide evaluar de manera sistemática si las fuentes disponibles son adecuadas para la construcción de modelos predictivos confiables Ospina y López [5] y Pérez y Echeverría [6].
- **Restricciones regulatorias:** Los organismos de control exigen que los resultados sean trazables y explicables. En consecuencia, no es suficiente emplear modelos con alto desempeño predictivo; estos deben ser interpretables y compatibles con los requerimientos de reporte regulatorio, lo que condiciona el tipo de metodologías que pueden adoptarse Servicios Públicos Domiciliarios [2] y IEEE Power and Energy Society [3].

¹SCADA (*Supervisory Control and Data Acquisition*): sistema de supervisión y adquisición de datos de la operación de la red. OMS (*Outage Management System*): sistema de gestión de interrupciones. GIS (*Geographic Information System*): sistema de información geográfica de activos. CIS (*Customer Information System*): sistema de información de clientes.

Estos obstáculos reducen la capacidad de la organización para explicar la variación de los indicadores SAIDI y SAIFI, priorizar actividades operativas y cumplir con los requerimientos regulatorios mediante herramientas predictivas IEEE Power and Energy Society [3] y Huang y Zhang [7]. En términos cuantitativos, el SAIDI promedio de la empresa es de 22.430 horas por año, valor que se ubica un 4.640 % por debajo de la meta establecida por la CREG (23.522 horas por año). Para el indicador SAIFI, el promedio anual es de 6.500 eventos, significativamente inferior al objetivo regulatorio de 9 eventos por año, lo que representa una reducción del 27.780 % Comisión de Regulación de Energía y Gas (CREG) [1]. Estos resultados sugieren que la empresa se encuentra dentro de los límites regulatorios; sin embargo, la gestión de dichos indicadores enfrenta importantes desafíos operativos e informativos.

Las compensaciones anuales asociadas a calidad del servicio ascienden aproximadamente a \$5 mil millones de pesos, y el análisis de datos históricos de cinco años evidencia que cerca del 2 % de los registros presenta información faltante o inconsistente, como tiempos de evento no registrados, campos incompletos o desajustes temporales entre sistemas. Si bien la Circular 063 de 2019 de la SSPD establece criterios técnicos para la exclusión válida de eventos asociados a factores externos, como fuerza mayor o fallas del Sistema Nacional de Transmisión, la presencia de problemas de calidad de datos limita la capacidad de construir modelos predictivos sólidos, diagnosticar con precisión las causas de las interrupciones y priorizar acciones operativas basadas en evidencia Comisión de Regulación de Energía y Gas (CREG) [1], Servicios Públicos Domiciliarios [2], IEEE Power and Energy Society [3] y Superintendencia de Servicios Públicos Domiciliarios (SSPD) [8].

Este problema no es exclusivo de la empresa analizada. En el sector eléctrico colombiano, la calidad del servicio constituye un desafío estructural. De acuerdo con el Informe de Calidad del Servicio de Energía Eléctrica de la SSPD 2023, el SAIDI promedio nacional fue de 16.83 horas por usuario, con valores que oscilaron entre 4.500 horas y más de 50 horas dependiendo del operador y de la región geográfica Superintendencia de Servicios Públicos Domiciliarios (SSPD) [9]. Esta dispersión refleja diferencias significativas en infraestructura, gestión operativa y exposición a condiciones climáticas extremas. Durante 2023, el 68 % de las interrupciones estuvo asociado a eventos externos, como contacto con vegetación, animales o terceros, mientras que el 24 % se atribuyó a fallas técnicas en equipos de red, evidenciando la naturaleza multicausal del problema Superintendencia de Servicios Públicos Domiciliarios (SSPD) [9].

El impacto regulatorio es considerable: en 2023, las compensaciones totales por incumplimiento de metas de calidad alcanzaron aproximadamente 487.000 mi-

llones a nivel nacional, siendo los indicadores de continuidad responsables del 73 % de este valor Superintendencia de Servicios Públicos Domiciliarios (SSPD) [9]. Para operadores de red ubicados en zonas con alta exposición climática, como Norte de Santander, la problemática se intensifica. Según datos de la SSPD consolidados por la UPME, los eventos meteorológicos extremos incrementaron en un 35 % las interrupciones no programadas respecto al periodo 2019–2021 Superintendencia de Servicios Públicos Domiciliarios (SSPD) [9] y Planeación Minero Energética (UPME) [10]. En este contexto, la dispersión de información en sistemas heterogéneos dificulta la identificación de patrones causales, la priorización del mantenimiento preventivo y la detección temprana de circuitos críticos, limitando la capacidad de las empresas distribuidoras para anticipar deterioros en la continuidad del servicio y cumplir de manera consistente con los objetivos regulatorios establecidos por la CREG.

1.2. Formulación del problema

¿Cómo desarrollar una metodología basada en métodos de ciencia de datos para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de zonas en redes de distribución de una empresa de energía eléctrica, ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento.?

A partir de la formulación anterior, se derivan las siguientes preguntas de sistematización:

1. ¿Cómo consolidar un repositorio analítico unificado y trazable que integre SCADA, OMS, GIS, CIS, registros de mantenimiento y datos climáticos, acompañado de un catálogo de datos y métricas de calidad que permitan para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas?
2. ¿Qué patrones temporales, espaciales, estacionales o comportamientos atípicos caracterizan la variabilidad de SAIDI y SAIFI a nivel de circuito, y de qué manera estos patrones influyen en la comprensión del fenómeno de continuidad del servicio eléctrico y en la identificación de los factores que explican sus fluctuaciones?
3. ¿Qué modelos tienen mejor desempeño para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de circuito o zona?

4. ¿Cómo construir artefactos reproducibles (notebooks, contenedores, documentación) y reportes técnicos alineados con los entregables del proyecto que faciliten la interpretación operativa y el uso de resultados en priorización de mantenimiento y reportes regulatorios?

2

Objetivos del proyecto

2.1. Objetivo general

Desarrollar una metodología basada en métodos de ciencia de datos para predecir los indicadores de calidad del servicio (SAIDI y SAIFI) en redes de distribución de una empresa de energía eléctrica ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento.

2.2. Objetivos específicos

1. Consolidar las fuentes de datos relevantes (SCADA/OMS, GIS, registros de fallas y mantenimientos, inventarios/SAC y datos climáticos), documentando su cobertura, calidad y limitaciones mediante un catálogo de datos y métricas de integridad.
2. Determinar qué variables operativas, técnicas y climáticas tienen mayor relevancia para predecir la duración y frecuencia de interrupciones (SAIDI y SAIFI) en la zona de estudio a partir de modelos estadísticos o de Machine Learning.
3. Evaluar el desempeño de diferentes métodos estadísticos o de Machine Learning para predecir SAIDI y SAIFI por circuito o zona, considerando la naturaleza de los datos y la interpretabilidad requerida por los gestores.

Marco de referencia

3.1. Marco teórico

3.1.1. Contexto del estudio

Cuando hablamos de calidad del servicio eléctrico, nos referimos básicamente a entregar energía de forma segura y eficiente, cumpliendo con estándares regulatorios que garanticen continuidad, confiabilidad y estabilidad para todos los tipos de usuarios: residenciales, industriales, comerciales e institucionales. En Colombia, este servicio es esencial y por eso está regulado por la Comisión de Regulación de Energía y Gas (CREG) IEEE Power and Energy Society [3], que ha establecido métricas y estándares específicos para hacer seguimiento a cómo se presta el servicio. Entre estas métricas, dos son particularmente importantes: el SAIDI (*System Average Interruption Duration Index*) y el SAIFI (*System Average Interruption Frequency Index*).

1. **Definición del SAIDI según la Resolución CREG 015 de 2018:** La Resolución CREG 015 de 2018 define el SAIDI como se indica a continuación. En dicha normativa, el **OR** es el **Operador de Red** y el **SDL** es el **Sistema de Distribución Local**.

La calidad media anual del OR se mide a través de los indicadores de duración y frecuencia de los eventos sucedidos en los SDL, que se establecen como se describe a continuación. El indicador SAIDI representa la duración total en horas de los eventos que en promedio percibe cada usuario del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:

$$SAIDI_{j,t} = \frac{\sum_{m=1}^{12} \sum_{i=1}^n D_{i,u,m} \times NU_{i,u,m}}{UT_{j,m} \times 60}, \quad (3.1)$$

donde:

- $SAIDI_{j,t}$: Indicador de duración promedio por usuario, de los

eventos sucedidos en el SDL del OR j , durante el año t , medido en horas al año.

- $D_{i,u,m}$: Duración en minutos del evento i , sucedido durante el mes m , que afectó al activo u perteneciente al SDL del OR j .
- $NU_{i,u,m}$: Número de usuarios que fueron afectados por el evento i sucedido durante el mes m , conectados al activo u .
- $UT_{j,m}$: Número total de usuarios conectados al SDL del OR j en el mes m .
- m : Mes del año t , con enero = 1, ..., diciembre = 12.

2. Definición del SAIFI según la Resolución CREG 015 de 2018: La misma resolución define el SAIFI como:

“El indicador SAIFI representa la cantidad total de los eventos que en promedio perciben todos los usuarios del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:”

$$SAIFI_{j,t} = \frac{\sum_{m=1}^{12} \sum_{i=1}^n NU_{i,u,m}}{UT_{j,m}}, \quad (3.2)$$

donde:

- $SAIFI_{j,t}$: Indicador de frecuencia promedio por usuario, de los eventos sucedidos en el SDL del OR j , durante el año t , medido en cantidad al año.
- $NU_{i,u,m}$: Número de usuarios que fueron afectados por el evento i sucedido durante el mes m , por encontrarse conectados al activo u .
- $UT_{j,m}$: Número total de usuarios conectados al SDL del OR j en el mes m .
- m : Mes del año t , con enero = 1, ..., diciembre = 12.

Cada OR es responsable del cálculo de los indicadores de calidad del servicio. Para ello, debe utilizar la información reportada conforme a lo establecido en el numeral 5.2.11.3.2 de la Resolución CREG 015 de 2018, así como la información de vinculación definida en el literal a) del numeral 5.2.10 Comisión de Regulación de Energía y Gas (CREG) [1]. Esta disposición garantiza que el cálculo de los indicadores se realice con base en

registros oficiales, trazables y consistentes con los lineamientos regulatorios vigentes.

3. **Interpretación de los indicadores:** Los indicadores SAIDI y SAIFI miden los *eventos* de interrupción del servicio eléctrico, entendidos como situaciones en las cuales se presenta una pérdida total o parcial del suministro. Dependiendo de su causa y de los criterios regulatorios aplicables, ciertos eventos son incluidos en el cálculo de los indicadores, mientras que otros pueden ser excluidos conforme a la normativa vigente.

El SAIDI expresa el tiempo promedio durante el cual un usuario permanece sin servicio eléctrico en un período determinado. Por su parte, el SAIFI mide la frecuencia promedio con la que un usuario experimenta interrupciones en el mismo período. En conjunto, ambos indicadores permiten evaluar la continuidad y confiabilidad del sistema de distribución.

Desde una perspectiva operativa, valores elevados de SAIDI o SAIFI pueden reflejar deficiencias en el mantenimiento de la red, limitaciones en la infraestructura, obsolescencia tecnológica, fallas en los procedimientos operativos o una alta exposición a factores externos como condiciones climáticas adversas Comisión de Regulación de Energía y Gas (CREG) [1] y Ospina y López [5]. En consecuencia, estos indicadores no solo describen el desempeño del sistema, sino que también permiten identificar áreas críticas que requieren intervención técnica o inversión en activos.

En el ámbito regulatorio, los OR deben reportar estos indicadores como métricas clave de desempeño y compararlos con las metas establecidas por la CREG. El cumplimiento de dichas metas está asociado a esquemas de remuneración por calidad del servicio, mientras que el incumplimiento puede dar lugar a ajustes tarifarios, obligaciones de reinversión o sanciones económicas IEEE Power and Energy Society [3] y Huang y Zhang [7]. Por tanto, SAIDI y SAIFI no solo constituyen medidas técnicas de continuidad, sino también variables con impacto financiero y regulatorio significativo.

4. **Meta de calidad media del SAIDI:** La Resolución CREG 015 de 2018 establece que la meta de calidad media para el indicador de duración de los eventos en el Sistema de Distribución Local (SDL) de cada OR se determina con base en una expresión específica definida por la regulación. Formalmente, dicha meta se calcula mediante la siguiente formulación:

“La meta para el indicador de frecuencia de los eventos sucedidos en el

SDL de cada OR se obtiene con base en la siguiente expresión:"

$$\text{SAIDI_M}_{j,t} = (1 - 0,08) \times \text{SAIDI_M}_{j,t-1}, \quad (3.3)$$

donde:

- $\text{SAIDI_M}_{j,t}$: Meta del indicador de duración de eventos, en horas al año, a ser alcanzada por el OR j al finalizar el año t .
- $\text{SAIDI_M}_{j,t-1}$: Meta del indicador de duración de eventos, en horas al año, para el año $t - 1$. Para el primer año de aplicación del esquema de calidad de cada OR esta variable será igual al indicador de referencia, SAIDI_R_j .

5. **Dimensión social y económica:** Desde una dimensión social y económica, un servicio deficiente ocasiona pérdidas significativas en la productividad empresarial y en los ingresos por remuneración al operador de red, y afecta la operación de instituciones comerciales e industriales. Por ello, mejorar la gestión y la capacidad de predicción de *SAIDI* y *SAIFI* es un objetivo estratégico para los operadores y para la regulación del sector, con impactos directos en usuarios, empresas y entes de control.
6. **Exclusiones de eventos:** Para la realización del cálculo de la calidad del servicio y el seguimiento de estos indicadores se tienen algunas exclusiones que permiten exonerar o excluir eventos de este cálculo. Entre los aspectos de la calidad del servicio de energía eléctrica que no serán observados dentro de este estudio se encuentran las siguientes exclusiones de eventos, tal como lo dicta la regulación CREG 015 del 2018 IEEE Power and Energy Society [3]:
 - Los menores o iguales a 3 minutos.
 - Los debidos a racionamientos programados.
 - Los causados por eventos de activos pertenecientes al Sistema de Transmisión Nacional (STN) y al Sistema de Transmisión Regional (STR).
 - Los eventos requeridos por seguridad ciudadana, solicitados por organismos de socorro o autoridades competentes.
 - Cuando se daña un activo de nivel de tensión 1 de propiedad del usuario.
 - Los debidos a catástrofes naturales.
 - Los debidos a actos de terrorismo.

- Eventos originados en exigencias de traslados y adecuaciones de la infraestructura eléctrica.
- Los eventos debidos a trabajos de reposición o modernización en subestaciones.
- Y otros menos relevantes para este estudio, pero que serán igualmente excluidos.

7. **Factores que afectan los indicadores:** Hay varios factores que deben considerarse, ya que terminan afectando negativamente los indicadores de calidad Comisión de Regulación de Energía y Gas (CREG) [1], Ospina y López [5] y Pérez y Echeverría [6]:

- **El clima:** Las tormentas eléctricas, vientos fuertes y otros fenómenos meteorológicos pueden dañar la infraestructura de distribución y causar interrupciones.
- **Aspectos técnicos e infraestructura:** Si el mantenimiento es deficiente, si los equipos están viejos u obsoletos, o si no hay redundancia en la red, se generan problemas que impactan los indicadores.
- **La gestión operativa:** Cuando falta planificación en el mantenimiento, cuando existen redes y equipos sin hojas de vida documentadas, cuando la respuesta a fallas es lenta o cuando el servicio está saturado, los indicadores se ven afectados. El problema se agrava al tener la información dispersa en múltiples sistemas.
- **Los datos:** Cuando la información está fragmentada en diferentes aplicativos, se dificulta el desarrollo de modelos predictivos que funcionen adecuadamente.

Por lo tanto, analizar en conjunto todas estas situaciones que afectan el indicador de forma negativa o positiva constituye un ejercicio relevante, ya que permitiría fortalecer la confiabilidad de los procesos internos y mejorar la gestión de los indicadores de calidad del servicio público de redes eléctricas de la empresa operadora de red de Norte de Santander.

3.1.2. Métodos y modelos

En este trabajo, la unidad de análisis del modelado es el par **cuadrante** $\times$ **semana** sobre D_{mod} (2024–2025). Para evitar **fuga de información** en el pronóstico,

las variables del panel se separan en tres grupos mutuamente excluyentes según su disponibilidad temporal respecto de la semana t a predecir:

1. **Disponibles antes del periodo a pronosticar** (candidatas a predictoras): clima *rezagado* ($t-1, \dots, t-h$) o *pronosticado* para t cuando exista un forecast operativo *ex ante*; histórico de eventos del cuadrante (y vecinos, si aplica); características del cuadrante (altitud, tipología de zona, número de activos, usuarios totales del inventario); estacionalidad y calendario; rezagos de Y o Y' . El clima contemporáneo de la semana t solo entra como predictora si está disponible *antes* de observar los eventos de t ; en el EDA se usa como asociación descriptiva, no como garantía de usabilidad predictiva.
2. **Variables respuesta:** $Y = \text{SAIFI}$ y $Y' = \text{SAIDI}$, construidas en el grano cuadrante $\times$ semana como $\text{SAIFI} = \text{usuarios_afectados} / UT_m$ y $\text{SAIDI} = (\text{duracion_total} \times \text{usuarios_afectados}) / UT_m$, donde UT_m es el número de usuarios totales del sistema en el mes m de la semana (serie `data_usuarios_totales_sistema.csv`). `n_eventos` y `duracion_total` son insumos de esa construcción y del historial *ex ante*, no las respuestas a predecir.
3. **Impacto posterior** (descriptivo / severidad): `usuarios_afectados` y `elementos_afectados` solo se conocen al ocurrir o cerrar el evento. `usuarios_afectados` entra en el numerador de Y y Y' , pero **no** se emplea como predictora contemporánea. `elementos_afectados` queda restringido a la descripción de severidad. Análogamente, `duracion_total_t` y `n_eventos_t` contemporáneos no entran como covariables al pronosticar SAIDI_t o SAIFI_t .

El vector climático de referencia, sujeto a la regla de disponibilidad del grupo 1, es

$$\mathbf{x} = (\text{precip_total_semana}, \text{temp_media_semana}, \text{humedad_media_semana}, \text{viento_medio_semana}), \quad (3.4)$$

eventualmente enriquecido con rezagos temporales de Y (o Y') y términos de estratificación territorial. A continuación se formalizan los métodos empleados en el EDA y en la preparación/modelado.

1. **Datos faltantes, tipos e imputación:** Sea X_j la j -ésima variable del panel. La proporción de faltantes se define como

$$p_j^{\text{NA}} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{X_{ij} = \text{NA}\}.$$

En el panel activo $\times$ día, los NA se concentran en el bloque climático y en ALTITUD; en la tabla agregada cuadrante $\times$ semana (D_{EDA} , D_{mod}) no se observan faltantes. Las reglas de imputación o exclusión se aplican en la Etapa 4 solo donde $p_j^{NA} > 0$ en el grano de origen, conforme a los criterios de tratamiento de datos incompletos de Little y Rubin [11].

2. **Dispersión relativa (coeficiente de variación):** Para comparar la variabilidad de variables cuantitativas con distintas unidades o escalas, se emplea el coeficiente de variación

$$CV(X) = \frac{s_X}{\bar{x}}, \quad \bar{x} \neq 0,$$

donde s_X es la desviación estándar muestral y $\bar{x}$ la media. Valores de CV cercanos a cero indican dispersión baja respecto a la media; valores $CV \gtrsim 1$ señalan alta heterogeneidad relativa. En variables cero-infladas (p. ej. métricas de interrupción), el CV del panel completo queda inflado por la masa en cero, por lo que se reporta también el CV condicionado a observaciones con valor positivo.

3. **Análisis de atípicos y extremos:** Para una variable cuantitativa X , se emplean reglas basadas en cuartiles, siguiendo el criterio de rango intercuartílico propuesto por Tukey [12]. Con Q_1 y Q_3 los cuartiles e $IQR = Q_3 - Q_1$, se marcan como extremos candidatos los valores

$$x \notin [Q_1 - k \cdot IQR, Q_3 + k \cdot IQR]$$

con factor $k = 1.5$ (regla de Tukey) y, de forma complementaria, $k = 3.0$ (extremos más severos). Estas reglas se contrastan con el criterio de percentiles P1–P99 sobre `n_eventos`, `duracion_total`, `usuarios_afectados` y `precip_total_semana`. El tratamiento definitivo (retención, winsorización o exclusión) se decide en la Etapa 4.

4. **Transformaciones de variables:** Ante asimetría y ceros, se usa la transformación logarítmica desplazada, caso límite de la familia de transformaciones de potencia de Box y Cox [13],

$$T(x) = \log(1 + x), \quad x \geq 0,$$

aplicada en particular a `precip_total_semana` y al bloque operativo (`n_eventos`, `duracion_total`, `usuarios_afectados`, `elementos_afectados`) cuando se requieren densidades o PCA más estables. Para homogenizar variables con distintas unidades (p. ej. antes del PCA o del clustering), se emplea la es-

tandarización por z -scores,

$$z = \frac{x - \bar{x}}{s},$$

que sitúa cada variable en media 0 y desviación típica 1.

5. **Series de tiempo y sus características:** Sea E_t el total semanal territorial de eventos. La función de autocorrelación (ACF) en el rezago h es

$$\rho(h) = \frac{\text{Cov}(E_t, E_{t-h})}{\text{Var}(E_t)}.$$

En D_{mod} se observa $\rho(1) \approx 0.80$, lo que motiva incorporar rezagos $E_{t-1}, \dots, E_{t-h}$ (o de `n_eventos` a nivel cuadrante) como predictoras. La PACF complementa la identificación del orden autorregresivo Box et al. [14]; la estacionalidad mensual se analiza agrupando E_t por mes calendario.

6. **Análisis de correlación:** Por la asimetría y la cero-inflación de las variables operativas, se emplea el coeficiente de correlación por rangos de Spearman [15]:

$$\rho_S(X, Y) = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)},$$

donde d_i es la diferencia de rangos. En D_{mod} , el par climático de mayor magnitud frente a `n_eventos` es (`viento_max_semana`, `n_eventos`) con $\rho_S \approx 0.14$, mientras el par de mayor interés conceptual, (`precip_total_semana`, `n_eventos`), alcanza $\rho_S \approx 0.07$. Entre variables cualitativas se emplea el estadístico V de Cramér Cramér [16]. Para el agrupamiento jerárquico de covariables se usa la distancia $d = 1 - |\rho_S|$.

7. **Datos de entrenamiento y prueba:** La partición es temporal (no aleatoria):

$$\mathcal{D}_{\text{train}} = \{(i, t) : \text{year}(t) = 2024\}, \quad \mathcal{D}_{\text{test}} = \{(i, t) : \text{year}(t) = 2025\},$$

sobre el grano cuadrante i y semana t de D_{mod} , preservando el orden cronológico ante la autocorrelación de la serie Hyndman y Athanasopoulos [17] y Hastie et al. [18].

8. **Validación cruzada:** Cuando se ajusten hiperparámetros en $\mathcal{D}_{\text{train}}$, se prioriza validación *forward-chaining* (bloques temporales sucesivos) en lugar de k -fold aleatorio, para no romper la dependencia temporal de `n_eventos` Bergmeir y Benítez [19].
9. **Análisis de componentes principales (PCA):** El PCA se emplea como

herramienta *exploratoria* de redundancia, no como modelo predictivo final Jolliffe [20]. Requiere variables cuantitativas, preferiblemente homogenizadas (estandarización o transformación previa) y con $n \gg p$. Dado el bloque climático estandarizado $\mathbf{Z}$, se resuelve

$$\mathbf{Z}^T \mathbf{Z} \mathbf{v}_\ell = \lambda_\ell \mathbf{v}_\ell,$$

y las componentes $\text{PC}_\ell = \mathbf{Z} \mathbf{v}_\ell$ resumen ejes de covarianza (temperaturas/vientos frente a precipitación). La importancia de cada variable en la componente ℓ se lee mediante las cargas (loadings) $v_{\ell j}$; en el EDA se interpretan como relevantes aquellas con $|v_{\ell j}| \geq 0.40$. Sobre el bloque operativo en escala $\log(1 + x)$, PC1 concentra la covarianza común de frecuencia, afectación y duración.

10. **Métodos de agrupación:** Los cuadrantes se segmentan por actividad (cuantiles de $\sum_t \text{n_eventos}$) y, de forma multivariada, por clustering (p. ej. jerárquico Kaufman y Rousseeuw [21] o k -means MacQueen [22]) sobre perfiles de frecuencia, duración y clima, con el fin de estratificar el modelado en zonas de distinto riesgo operativo.
11. **Factor de inflación de la varianza (VIF):** Para cada predictora X_j del bloque climático en un modelo auxiliar lineal $\text{n_eventos} \sim \mathbf{x}$,

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 proviene de regresar X_j sobre el resto de covariables Kutner et al. [23]. Valores altos en $\text{temp_max}/\text{temp_min}$ y viento_max motivan el subconjunto reducido $\mathbf{x}$ indicado arriba (VIF aceptables tras la depuración), teniendo en cuenta las advertencias sobre el uso mecánico de umbrales fijos señaladas por O'Brien [24].

12. **Modelo lineal generalizado de Poisson (GLM Poisson):** Como modelo diagnóstico de conteos McCullagh y Nelder [25] y Cameron y Trivedi [26],

$$Y_i \sim \text{Poisson}(\mu_i), \quad \log \mu_i = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i^*,$$

donde $Y_i = \text{n_eventos}$ en la observación cuadrante–semana i y $\mathbf{x}_i^*$ incluye, entre otros, $\log(1 + \text{precip_total_semana})$ y el viento medio estandarizado. Los coeficientes $\hat{\beta}$ cuantifican el efecto multiplicativo $e^{\hat{\beta}_j}$ sobre la tasa esperada de interrupciones; este esquema orienta el modelado predictivo de la Etapa 5.

3.2. Antecedentes

3.2.1. Revisión de literatura

Los avances recientes en ciencia de datos, estadística avanzada y aprendizaje automático han impulsado una evolución significativa en los métodos para predecir fallas, gestionar interrupciones y estimar la calidad del servicio en redes de distribución eléctrica.

En primer lugar, varios estudios han explorado la predicción de confiabilidad a partir de modelos híbridos que integran técnicas estadísticas y de inteligencia artificial. Xie et al. [27] desarrollan un modelo integral de pronóstico de confiabilidad que combina redes neuronales artificiales, análisis de relaciones grises y modelos de fallas programadas, demostrando alta aplicabilidad en sistemas en expansión. De manera complementaria, Das et al. [28] proponen un ensamble de redes neuronales profundas que mejora sustancialmente la estimación de interrupciones causadas por viento y descargas eléctricas, superando modelos estadísticos y de comité previos.

En el ámbito de eventos meteorológicos severos, Angalakudati et al. [29] introducen uno de los primeros modelos operativos basados en Machine Learning para la planificación de tormentas, combinando datos climáticos, propiedades físicas de la red e información histórica de daños. En la misma línea, Owerko et al. [30] emplean Graph Neural Networks para procesar mediciones meteorológicas distribuidas en un marco de señales sobre grafos, logrando errores de predicción inferiores al 1.1 % en la región de Nueva York.

El efecto de la vegetación como causa dominante de fallas también ha sido ampliamente estudiado. Cerrai et al. [31] cuantifican el impacto del estándar Enhanced Tree Trimming mediante análisis estadístico y modelos de predicción de interrupciones, mostrando reducciones entre el 16 % y 48 % en fallas durante tormentas. Por su parte, Eskandarpour y Khodaei [32] introducen un modelo predictivo para componentes de red ante huracanes basado en regresión logística, mientras que Rudin et al. [33] proponen un marco general para extraer conocimiento de datos históricos de la red de Nueva York con el fin de priorizar mantenimiento y estimar la vulnerabilidad de componentes críticos.

Otros aportes relevantes abordan la identificación de causas de fallas. Xu et al. [34] aplican un algoritmo inspirado en sistemas inmunológicos (AIRS) para clasificar causas de interrupción (árboles, animales, rayos), enfrentando el problema de datos desbalanceados. Mientras tanto, Breiman [35] establece los fundamentos teóricos de los Random Forest, técnica ampliamente usada en predicción de fallas debido a su robustez y capacidad de manejar alta dimensionalidad.

La estimación de interrupciones bajo condiciones extremas también ha sido

examinada mediante enfoques estadísticos. Han et al. [36] modelan la distribución espacial de fallas durante huracanes en la costa del Golfo utilizando variables físicas medibles. Yang et al. [37] estudian la incertidumbre en modelos de predicción de tormentas y demuestran que el rendimiento de los modelos basados en machine learning depende fuertemente del tamaño y representatividad del conjunto de entrenamiento. A su vez, Kankanala et al. [38] presentan AdaBoost+, un método de ensamble que supera regresión, redes neuronales y mixture of experts para estimar fallas asociadas al viento y los rayos.

Otras investigaciones incorporan análisis multivariable para predecir tipos específicos de interrupciones. Kor et al. [39] evalúan arquitecturas de aprendizaje automático para predecir fallas por viento, nieve e hielo, mientras que Doostan y Chowdhury [40] desarrollan un enfoque probabilístico para fallas asociadas a rayos utilizando aprendizaje no supervisado y técnicas de clasificación balanceada.

Asimismo, Chen y Kezunović [41] aplican lógica difusa para análisis predictivo de riesgo, y He et al. [42] comparan árboles de regresión no paramétricos (QRF y BART), demostrando ventajas complementarias según la granularidad espacial y las características del evento.

Dentro de los aportes más recientes, Hou et al. [43] desarrollan un enfoque basado en celdas espaciales de 1 km^2 y Random Forest para predecir interrupciones bajo tifones, alcanzando precisiones superiores al 92 %. De forma similar, Li et al. [44] construyen un modelo de predicción de cantidad de usuarios afectados por tifones, aplicando selección de variables para obtener un modelo simplificado sin sacrificar precisión.

Otras líneas introducen enfoques más estructurales o basados en simulación. Zhai et al. [45] proponen un modelo que genera sistemas de distribución sintéticos y estima fallas a nivel de edificio mediante funciones de fragilidad, reduciendo la dependencia en datos privados de operadores. Zhu et al. [46] desarrollan un modelo de tormentas de dos etapas para predecir interrupciones en tiempo real, mientras que Arif y Wang [47] combinan análisis estadístico y redes neuronales profundas para predecir tiempos de reparación.

Wanik et al. [48] demuestran que modelos basados en árboles y ensambles, alimentados con datos atmosféricos generados mediante WRF, pueden predecir con alta resolución espacial la distribución de fallas en Connecticut. Por su parte, Jaech et al. [49] incorporan procesamiento de lenguaje natural para actualizar predicciones de duración de interrupciones a partir de reportes de campo.

Más recientemente, Sorokin [50] sistematiza los principios y particularidades de la aplicación de métodos de aprendizaje automático a la evaluación de la confiabilidad de sistemas de potencia, y desarrolla un prototipo capaz de identificar

en tiempo real estados potencialmente peligrosos de la red. Por su parte, Liu et al. [51] presentan un método de cálculo rápido de la confiabilidad de redes de distribución activas basado en tasas de falla dinámicas de los equipos, mientras que Avcı [52] integra técnicas híbridas de inteligencia artificial para mejorar la predicción y la gestión de interrupciones, considerando factores meteorológicos, geográficos y operativos. Finalmente, Krstivojević y Terzić [53] aplican simulación de Monte Carlo para seleccionar la opción óptima de inversión orientada a mejorar el desempeño de confiabilidad en redes de distribución, vinculando así el diagnóstico predictivo con la priorización de inversiones.

Datos

Para el desarrollo del modelo de pronóstico de *SAIFI* y *SAIDI*, se utilizará una base de datos histórica de eventos de falla reportados en el sistema de distribución. La tabla principal consolidada tiene $N = 87.007.074$ observaciones ($A = 47.649$ activos eléctricos únicos $\times T = 1.826$ días), correspondientes al panel **activo $\times$ día** entre el 1 de enero de 2021 y el 31 de diciembre de 2025.

Tiempo o periodo de estudio. El periodo de estudio abarca desde el 1 de enero de 2021 hasta el 31 de diciembre de 2025.

Unidad muestral. La unidad muestral adoptada corresponde a un activo eléctrico por día, lo que define un nivel de granularidad tipo *elemento-día*. Esta elección permite capturar la variabilidad temporal de los eventos e integrar variables de red y climáticas a nivel diario.

4.1. Construcción del dataset

4.1.1. Lógica estructural

La construcción del conjunto de datos sigue la siguiente lógica:

- Se crea un calendario diario para el periodo comprendido entre el 01-01-2021 y el 31-12-2025.
- Se construye el producto cartesiano entre el inventario de activos eléctricos y el calendario diario, garantizando la presencia de todos los activos en cada día del periodo de análisis.
- Sobre esta estructura base se integran:
 - Variables de red.
 - Variables climáticas agregadas a nivel de activo por día.
 - Variables de eventos asociadas a cada activo por día.

4.1.2. Definición de variables de evento

Las variables de eventos se definen así:

- **Duración** (DURACION_min, en minutos): minutos de interrupción del activo en el día de observación, prorrateados según la intersección de [Fecha_Desconexion, Fecha_Conexion] con ese día calendario. Si el evento cruza varios días, su duración se reparte entre ellos; si hay varios eventos el mismo día, se suman. No se asigna la duración total del evento solo al día de desconexión. En días sin falla, el valor es 0.
- **Frecuencia** (FRECUENCIA): número de interrupciones cuyo inicio (Fecha_Desconexion) ocurre en el día (sin prorrateo de la frecuencia).

4.1.3. Estructura del dataset consolidado

El dataset final incluye las variables agrupadas por bloque temático, como se resume en la Tabla 4.1.

Tabla 4.1: Estructura del dataset consolidado (grano activo $\times$ día).

Bloque	Variables
Información del activo	Id_Activo_Electrico
	Tipo_Activo_Electrico
Información geoespacial	Latitud
	Longitud
	Altitud
	Id_Cuadrante
Variables de red	Latitud_Cuadrante
	Longitud_Cuadrante
	Fecha
	Cantidad_Elementos
	Cantidad_Usuarios
	Antiguedad_Red
Variables climáticas	Expansion_Red
	Velocidad_Viento_Ms
	Temperatura_Media_C
	Humedad_Relativa_Pct
	Temperatura_Minima_C
	Temperatura_Maxima_C
Variables objetivo	Precipitacion_Total_Mm
	DURACION_min
	FRECUENCIA

Número de observaciones. La tabla consolidada final se estima como

$$\text{Total de observaciones} = 47.649 \times 1.826 = 87.007.074,$$

correspondiente a cinco años de información a nivel elemento-día.

Procedencia de la información

Origen de la información. La empresa origen de los datos operativos y técnicos es **Centrales Eléctricas de Norte de Santander S.A E.S.P (Cens S.A E.S.P)**.

Lugar donde se registra la información. Sistemas corporativos (BRAE, OMS y GIS). Para variables climatológicas se utiliza la fuente institucional externa NASA POWER NASA Langley Research Center (LaRC) POWER Project [\[54\]](#).

La información se registra en la red de distribución eléctrica de Norte de Santander, con soporte de localización geográfica por activo y por cuadrante.

Nuestra metodología está organizada por etapas alineadas con los objetivos específicos del proyecto (Capítulo 2). El enfoque general consiste en integrar datos, limpiarlos, analizarlos y construir modelos para predecir los indicadores *SAIDI* y *SAIFI* de la empresa de distribución eléctrica en Norte de Santander. La correspondencia entre etapas y objetivos se resume al final de este capítulo en la Tabla 5.30.

Se decidió utilizar CRISP-DM (Cross-Industry Standard Process for Data Mining) como marco de referencia por ser un estándar reconocido en la industria para proyectos de ciencia de datos Chapman et al. [55], el cual fue adaptado al contexto específico del sector eléctrico regulado. Las fases de CRISP-DM se implementaron de la siguiente manera: el entendimiento del negocio (Business Understanding) se desarrolla en las Secciones 5.1 a 5.4. Las fases de entendimiento y preparación de datos (Data Understanding y Data Preparation) corresponden a las Etapas 1 a 4, en Secciones 5.1, 5.2, 5.3 y 5.4, en las que se integran, depuran y exploran los datos y se construyen las variables analíticas. La fase de modelado y evaluación (Modeling y Evaluation) se desarrolla en la Etapa 5, en la Sección 5.5, donde se construyen y validan los modelos predictivos. Finalmente, el despliegue (Deployment) corresponde a la Etapa 6 en la Sección 5.6, en la cual se consolidan los resultados, se documenta el proceso y se entrega código reproducible.

Esta adaptación de CRISP-DM considera los requisitos específicos del regulador (CREG, SSPD), las métricas propias del sector eléctrico (*SAIDI*, *SAIFI*) y la necesidad de que los modelos sean interpretables para su uso en la toma de decisiones.

5.1. Etapa 1 – Extracción de datos

Esta etapa comprende la recolección, integración y estandarización de las fuentes de datos internas (SCADA, OMS, GIS, CIS, registros de fallas y mantenimiento) y externas (NASA, CREG, SSPD). Incluye la creación de un repositorio analítico unificado y la elaboración de un catálogo de datos que documenta metadatos, alcances, limitaciones y métricas de integridad.

Fuentes de informacion

A partir del año 2023, la Electrificadora de Norte de Santander realizó una migración de su sistema de gestión de interrupciones. Como resultado, la recopilación de información de interrupciones eléctricas se llevó a cabo a partir de dos bases de datos provenientes de sistemas distintos:

- **OMS Energy:** sistema utilizado hasta antes de la migración, del cual se extrae la información histórica de interrupciones previas a 2023.
- **OMS SP7 de Siemens:** nuevo sistema implementado desde 2023, del cual se obtiene la información de interrupciones a partir de dicha fecha.

Esta dualidad de fuentes implica diferencias estructurales en los esquemas de datos (tales como nombres de campos, codificaciones y niveles de granularidad), las cuales fueron consideradas durante el proceso de integración y homologación de la información.

5.1.1. Sistemas y fuentes consultadas

Se integran datos de cinco fuentes de información principales:

- **BRAE:** base regulatoria e histórica de eventos.
- **OMS SPARD** (sistema histórico): fuente de elemento causante antes de la migración.
- **OMS SP7** (sistema actual): fuente de elemento causante en archivos CSV mensuales.
- **GTECH (GIS):** inventario y georreferenciación de activos eléctricos.
- **NASA POWER (API):** serie diaria de variables climatológicas por coordenada/cuadrante.

5.1.2. Extracción base y depuración de eventos de interrupción (BRAE)

La construcción de la base de eventos de interrupción se realizó a partir de la tabla transaccional `BRAE.QA_TFDDREGISTRO`, la cual contiene el registro histórico de eventos de desconexión del sistema eléctrico. A partir de esta fuente, se ejecutó una consulta SQL orientada a depurar inconsistencias, restringir el periodo de análisis y estandarizar la estructura del identificador de evento.

En primer lugar, se seleccionaron únicamente los campos relevantes para el análisis: el identificador del evento (`FDD_CODIGOEVENTO`), la fecha de inicio de

la desconexión (FDD_FINICIAL) y la fecha de reconexión (FDD_FFIMAL). Adicionalmente, se incluyó un campo vacío para ELEMENTO_FALLADO, con el fin de mantener compatibilidad estructural con otras fuentes que sí contienen este nivel de desagregación.

Posteriormente, se aplicaron criterios de depuración y filtrado. En primer lugar, se restringió la muestra al periodo comprendido entre los años 2021 y 2025, garantizando consistencia temporal del análisis. En segundo lugar, se excluyeron aquellos registros marcados como no relevantes mediante la variable FDD_EXCLUSION, conservando únicamente los eventos clasificados como NO EXCLUIDA. En tercer lugar, se eliminaron eventos asociados a causas no válidas según la regulación (FDD_CAUSA_SSPD NOT IN (1)), así como aquellos registros sin fecha de finalización (FDD_FFIMAL IS NOT NULL), los cuales no permiten calcular la duración del evento.

Finalmente, se utilizó la instrucción DISTINCT para garantizar la eliminación de duplicados en el identificador de evento, obteniéndose una base depurada y consistente a nivel de evento de interrupción. Como resultado de este proceso de extracción y limpieza, se obtuvo un total de 95.280 registros válidos de eventos de desconexión para el periodo de análisis. La Tabla 5.1 presenta una muestra de la estructura resultante. El código SQL correspondiente se presenta en el Listado A.1 (Apéndice A.2).

Tabla 5.1: Muestra de eventos depurados de interrupción (BRAE)

Id evento	Fecha desconexión	Fecha conexión	Elemento fallado
801851	14/03/21 06:59:00.000	14/03/21 09:30:00.000	(null)
787583	04/01/21 08:50:00.000	04/01/21 17:15:00.000	(null)
787496	03/01/21 14:18:14.296	03/01/21 14:40:42.699	(null)
787232	01/01/21 10:29:33.936	01/01/21 13:30:00.000	(null)
787455	03/01/21 10:34:23.000	03/01/21 13:30:00.000	(null)
787376	02/01/21 12:09:22.000	02/01/21 18:20:00.000	(null)
789756	16/01/21 08:50:00.000	16/01/21 15:50:00.000	(null)
788677	10/01/21 08:37:45.000	10/01/21 10:10:00.000	(null)
788932	12/01/21 06:47:47.000	12/01/21 08:30:00.000	(null)
787922	06/01/21 08:42:00.000	06/01/21 15:28:00.000	(null)

5.1.3. Extracción de afectación por evento

Con el fin de complementar la base de eventos de interrupción, se construyó una tabla de afectación asociada a cada evento, incorporando información sobre el número de elementos afectados y la cantidad de usuarios impactados. Este proceso permite pasar de una caracterización puramente temporal del evento a una medición de su severidad en términos de impacto en la red.

La extracción se realizó a partir de la tabla `BRAE.QA_TFDDREGISTRO`, la cual se utilizó como fuente principal de eventos, y se complementó mediante una unión (`LEFT JOIN`) con la base `QA_TTC1`, que contiene información asociada a la conexión de transformadores y el número de usuarios por conexión.

En particular, la variable `CANTIDAD_USUARIOS` se construyó a partir del conteo de usuarios asociados a cada transformador (`TC1_CODCONEX`) agrupados por periodo, mientras que la variable de afectación por evento se obtuvo mediante la agregación de estos usuarios a nivel de evento de interrupción.

Posteriormente, se aplicaron los mismos criterios de depuración utilizados en la etapa anterior, restringiendo el análisis al periodo 2021–2025, excluyendo eventos marcados como no relevantes (`FDD_EXCLUSION = 'NO EXCLUIDA'`), eliminando causas no válidas según la clasificación regulatoria (`FDD_CAUSA_SSPD NOT IN (1)`) y conservando únicamente registros con fecha de finalización válida (`FDD_FFIMAL IS NOT NULL`).

Finalmente, los datos se agregaron a nivel de evento (`FDD_CODIGOEVENTO`) utilizando la función `GROUP BY`, obteniendo como resultado dos indicadores clave: el número de elementos fallados por evento y el total de usuarios afectados. El procedimiento permitió consolidar una base consistente de 95.280 registros, alineada con la estructura del conjunto de eventos previamente depurado. La Tabla 5.2 ilustra una muestra de esta agregación. El código SQL correspondiente se presenta en el Listado A.2 (Apéndice A.2).

Tabla 5.2: Muestra de afectación por evento (BRAE + QA_TTC1)

Id evento	Cantidad elementos fallados	Cantidad usuarios afectados
795044	33	2692
795513	162	11796
788221	10	74
788203	240	3865
789543	8	45
789719	109	503
789929	109	503
788758	1	6
798712	159	1869

5.1.4. Extracción del elemento causante histórico

Con el objetivo de identificar el elemento de la red asociado a la causa de cada evento de maniobra, se realizó la extracción de información histórica desde la base de datos del sistema OMS (Outage Management System), específicamente desde la tabla `OMS.MANIOBRAS@SPARD`. Esta fuente permite complementar la in-

formación de eventos de interrupción mediante la identificación del elemento físico que originó la falla.

El proceso de extracción se centró en dos variables principales: el código de la maniobra (CODE), utilizado como identificador del evento en el sistema OMS, y el elemento fallado (BREAKER), que corresponde al activo de la red asociado a la causa de la interrupción. Estas variables permiten establecer la relación entre el evento registrado y el componente físico responsable dentro de la infraestructura eléctrica.

Adicionalmente, se aplicaron criterios de filtrado temporal y de calidad de datos. En primer lugar, se restringió la información a registros con fecha igual o posterior al año 2021, garantizando la consistencia histórica del análisis. En segundo lugar, se excluyeron aquellos eventos clasificados como pruebas operativas mediante la condición `CAUSA != 'PRUEBA'`, con el fin de conservar únicamente eventos reales de operación del sistema.

Como resultado de este proceso de extracción y depuración, se obtuvo una base de datos estructurada a nivel de maniobra, la cual permite complementar la trazabilidad entre eventos de interrupción y los elementos físicos de la red asociados a su ocurrencia. La Tabla 5.3 muestra un extracto de esta relación maniobra–elemento. El código SQL correspondiente se presenta en el Listado A.3 (Apéndice A.2).

Tabla 5.3: Muestra de elemento causante histórico (OMS SPARD)

Código maniobra	Elemento fallado
640011	AMVE271
634924	LMVEL79620
634978	LMVEL67393
631108	RMVEL79067-2
631464	CMVE2454
631761	SW6844
637873	BMVE749
640442	LMVEL99259
631793	SANC52

5.1.5. Extracción del elemento causante actual

Con el objetivo de actualizar la información histórica del sistema de maniobras, se realizó la extracción de los datos correspondientes a la versión más reciente del sistema OMS en formato plano (CSV). Este proceso permite complementar la información histórica con registros operativos actuales, garantizando la continuidad y consistencia de la base de datos utilizada en el análisis.

La extracción se realizó mediante un proceso de lectura y depuración de da-

tos en Python, a partir del archivo fuente correspondiente a la versión actual del sistema. En primer lugar, se cargó el archivo mediante la función `read_csv`, asegurando la correcta lectura de la estructura tabular. Posteriormente, se realizó una limpieza de los nombres de las columnas mediante la eliminación de espacios en blanco al inicio y al final, con el fin de evitar inconsistencias en la identificación de variables.

A continuación, se seleccionaron únicamente las variables relevantes para el análisis: `Maniobra Apertura`, `Tipo Elemento` y `Elemento_Falla`. Esta selección permitió homogenizar la estructura de la base con la información histórica previamente construida. Finalmente, se eliminaron los registros duplicados mediante la función `drop_duplicates`, garantizando la unicidad de las observaciones a nivel de combinación de variables relevantes.

Como resultado, se obtuvo una base depurada y estandarizada del sistema OMS actual, la cual es consistente con la estructura de la base histórica y permite su integración en el proceso de consolidación del dataset final. La Tabla 5.4 presenta una muestra de los registros resultantes. El fragmento Python correspondiente se presenta en el Listado A.5 (Apéndice A.2).

Tabla 5.4: Muestra de elemento causante actual (OMS SP7)

Maniobra apertura	Tipo elemento	Elemento falla
424000000000114424	Transformador de distribucion	1T07942
124000000000269842	Fusible	F1979
124000000000269842	Transformador de distribucion	F1979
124000000000273378	Fusible	F2004
124000000000269851	Fusible	F2000
124000000000273383	Fusible	F2001
124000000000273374	Fusible	F2006
124000000000273377	Fusible	F2004
124000000000273372	Fusible	F2006
124000000000273356	Fusible	F2005
124000000000273381	Fusible	F1993

5.1.6. Extracción de inventario GIS

Con el propósito de incorporar la dimensión espacial de la red eléctrica, se realizó la extracción del inventario georreferenciado a partir del sistema GIS corporativo. Esta información permite asociar cada activo de la red con sus coordenadas geográficas y características físicas, facilitando posteriormente el análisis espacial de los eventos de interrupción.

La extracción se efectuó desde la base de datos `ccomun@gtech`, la cual contiene el inventario técnico de los activos de la red. A partir de esta fuente, se seleccionaron las variables correspondientes al identificador del elemento

(nodo_transform_v), la latitud (coor_gps_lat), la longitud (coor_gps_lon) y la altitud (coor_z). Adicionalmente, se incluyó la variable ubicacion, que permite complementar la caracterización espacial del activo.

Asimismo, se definió explícitamente el tipo de activo como Transformador, con el fin de estandarizar la clasificación dentro del conjunto de datos integrado. Esta homogenización resulta clave para la posterior vinculación con los eventos de interrupción y la construcción del panel activo-día.

Como resultado, se obtuvo una base georreferenciada de los activos de la red, la cual constituye un insumo fundamental para el enriquecimiento espacial del dataset consolidado. La Tabla 5.5 ilustra la estructura de este inventario. El código SQL correspondiente se presenta en el Listado A.4 (Apéndice A.2); la consulta se replica de forma análoga para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador.

Tabla 5.5: Muestra de inventario georreferenciado de activos (GIS GTECH)

Elemento	Latitud	Longitud	Altitud	Tipo
2T01558	6.960719612	-72.18029066	636	Transformador
2T01557	6.972762106	-72.18726993	743	Transformador
2T01467	6.973200989	-72.15472768	815	Transformador
2T01466	6.978510343	-72.14903608	726	Transformador
F3199	6.978980206	-72.19049387	832	Aisladero
PSW8910	6.978980206	-72.19049387	832	Aisladero
2T01555	6.982222682	-72.19495813	825	Transformador
2T01554	6.982742594	-72.20226264	867	Transformador
2T01556	6.984663810	-72.18619273	727	Transformador
2T01465	6.985402944	-72.13537905	530	Transformador
F3192	6.987527091	-72.20044897	767	Aisladero
PSW8909	6.987527091	-72.20044897	767	Aisladero
F5217	6.991040416	-72.20123180	726	Aisladero
PSW8908	6.991040416	-72.20123180	726	Aisladero
2T01553	6.991242376	-72.19636467	679	Transformador
2T01470	6.991396285	-72.15644527	790	Transformador
ESW6924	6.992103744	-72.13486380	453	Aisladero
F5211	6.992103744	-72.13486380	453	Aisladero
2T01471	6.992290614	-72.13485446	453	Transformador
2T01469	6.993224220	-72.14776723	656	Transformador
F8201	6.997255476	-72.12409341	361	Aisladero

5.1.7. Extracción de variables meteorológicas

Con el objetivo de incorporar condiciones climáticas como variables explicativas en el análisis de interrupciones del sistema eléctrico, se realizó la extracción de información meteorológica a partir de la plataforma NASA POWER NASA Langley Research Center (LaRC) POWER Project [54]. Esta fuente proporciona

series temporales diarias de variables climáticas relevantes, las cuales permiten capturar la influencia del entorno atmosférico sobre la ocurrencia y duración de eventos en la red.

El proceso de extracción se centró en un conjunto de variables meteorológicas seleccionadas por su relevancia en el análisis de confiabilidad del sistema eléctrico. En particular, se consideraron las variables de precipitación total (PRECTOT), temperatura media (T2M), temperatura máxima (T2M_MAX), temperatura mínima (T2M_MIN), humedad relativa (RH2M) y velocidad del viento (WS2M). La Tabla 5.6 presenta una muestra de estas series. La definición de estos parámetros en el código de extracción se presenta en el Listado A.6 (Apéndice A.2).

Tabla 5.6: Muestra de variables meteorológicas (NASA POWER) - Parte 1

Vel. viento	Temp. media	Humedad	Temp. min	Temp. max	Precip.
2.06	13.27	87.24	9.12	18.63	2.6
2.66	13.89	88.27	10.71	18.92	1.41
1.93	13.66	88.59	10.29	18.96	3.04
1.73	13.6	85.07	9.13	20.17	9.07
1.45	11.52	69.12	5.95	18.7	0.79
1.1	12.29	80.8	7.55	17.76	0.77
1.76	13.23	88.9	10.65	17.93	3.03
2.34	12.95	88.44	10.14	17.84	2.51
2.41	12.69	87.38	9.48	16.55	1.84
2.98	12.99	90.13	9.65	17.44	3.35
3.18	13.12	87.67	10.58	17.69	0.9

Estas variables fueron extraídas a nivel diario para el periodo comprendido entre el 1 de enero de 2021 y el 31 de diciembre de 2025, lo que dio lugar a una base de aproximadamente 83.5 millones de registros. Este volumen de información refleja la estructura panelizada de la base climática, construida mediante la combinación de múltiples variables atmosféricas observadas diariamente a lo largo del horizonte temporal de análisis.

La incorporación de estas variables permite enriquecer el dataset consolidado con condiciones exógenas del entorno, facilitando el análisis de su relación con la frecuencia y severidad de las interrupciones en el sistema eléctrico.

5.1.8. Resumen metodológico de extracción e integración de bases de datos

La Tabla 5.7 sintetiza el proceso de extracción e integración desarrollado en la Etapa 1. En conjunto, se consolidaron seis fuentes complementarias: BRAE como base transaccional de eventos de interrupción; BRAE + QA_TTC1 para cuantificar la severidad operativa (usuarios afectados); OMS SPARD y OMS SP7 para

Tabla 5.7: Resumen metodológico de extracción e integración de bases de datos

Fuente	Variables principales	Proceso aplicado	Resultado
BRAE (TFDDREGISTRO)	Id evento, fecha desconexión, fecha conexión	Filtrado temporal (2021–2025), exclusión de registros no válidos, eliminación de duplicados	95.280 eventos de interrupción
BRAE + QA_TTC1	Cantidad usuarios, elementos de conexión	JOIN por elemento y periodo, agregación por evento	Base de severidad por evento (usuarios)
OMS SPARD (histórico)	Código maniobra, elemento fallado, elemento causante	Filtrado de registros desde 2021, exclusión de pruebas	Base histórica de causa de falla
OMS SP7 (actual)	Maniobra apertura, tipo elemento, cantidad elementos fallados, elemento falla	Lectura CSV, limpieza de columnas, eliminación de duplicados	Base actualizada de elementos causantes
GIS (GTECH)	Elemento, latitud, longitud, altitud, tipo	Extracción desde sistema georreferenciado corporativo	Inventario espacial de la red
NASA POWER	PRECTOT, T2M, T2M_MAX, T2M_MIN, RH2M, WS2M	Extracción diaria (2021–2025) por variables climáticas	83.5 millones de registros meteorológicos

identificar el elemento causante y fallado en los periodos pre y post migración del sistema; GIS (GTECH) para incorporar la georreferenciación de activos de red; y NASA POWER para enriquecer el análisis con variables climáticas diarias. Cada fuente fue sometida a reglas explícitas de filtrado, homologación y depuración, lo que permitió obtener bases consistentes y trazables que constituyen el insumo inicial para la integración del panel descrita en la Etapa 2.

5.2. Etapa 2 - Integración y depuración de datos

5.2.1. Lógica de integración entre sistemas

Una vez extraídas y depuradas las fuentes descritas en la Etapa 5.1, la integración se ejecuta de forma secuencial sobre tablas intermedias, preservando trazabilidad de llaves y evitando pérdida de emparejamiento entre sistemas con esquemas distintos (BRAE, OMS SPARD, OMS SP7, GIS y NASA POWER). La secuencia aplicada fue la siguiente.

5.2.1.1 Construcción de la tabla base de eventos (BRAE).

A partir de BRAE.QA_TFDDREGISTRO se genera la tabla `tabla_eventos` con `ID_EVENTO`, `FECHA_DESCONEXION` y `FECHA_CONEXION`, aplicando filtros regulatorios del periodo 2021–2025, exclusión de eventos no válidos y eliminación de duplicados. Esta tabla define el universo analítico de interrupciones (95.280 eventos).

5.2.1.2 Construcción de la tabla de afectación por evento (Tabla 5.2).

En la Sección 5.1.3 se construye la Tabla 5.2 de afectación por evento, la cual consolida las columnas `CANTIDAD_ELEMENTOS` y `CANTIDAD_USUARIOS` a nivel de `ID_EVENTO`. Su integración a la tabla base consolidada se realiza en el paso 5.2.1.5.

5.2.1.3 Completar ELEMENTO_FALLADO (OMS SPARD + OMS SP7).

La tabla base de eventos obtenida en la Sección 5.1.2 se construyó con el campo `ELEMENTO_FALLADO` vacío, reservado para su completamiento en la integración. Dado el cambio de sistema OMS en el año 2023, la información del elemento causante se extrajo de forma separada en dos fuentes: la Sección 5.1.4 (*Extracción del elemento causante histórico*, OMS SPARD) y la Sección 5.1.5 (*Extracción del elemento causante actual*, OMS SP7). En este paso, la tabla de la Sección 5.1.2 se cruza con ambas tablas OMS, aplicando en cada caso la lógica de emparejamiento definida en su extracción:

- **Histórico (Sección 5.1.4 – OMS SPARD):** cruce por CODIGO_MANIOBRA $\leftrightarrow$ ID_EVENTO para completar ELEMENTO_FALLADO con el valor de BREAKER en eventos del periodo pre-migración.
- **Actual (Sección 5.1.5 – OMS SP7):** cruce por MANIOBRA_APERTURA $\leftrightarrow$ ID_EVENTO para completar ELEMENTO_FALLADO con el valor de ELEMENTO_FALLA, junto con TIPO_ELEMENTO, en eventos del periodo post-migración.

5.2.1.4 Construcción de la tabla base consolidada (activo-día).

A partir de este paso se inicia la construcción de la tabla base consolidada del proyecto. Como insumo inicial se toma la Tabla 5.5 (inventario georreferenciado de activos obtenido en la Sección 5.1.6), del cual se conserva un registro por ELEMENTO (47.649 activos únicos), y se cruza con un calendario diario comprendido entre el 2021-01-01 y el 2025-12-31 (1.826 días), empleando el campo FECHA_DIA. Este cruce genera un producto cartesiano entre el universo de activos eléctricos y el horizonte temporal de análisis, con 87.007.074 observaciones (47.649×1.826), definiendo la estructura panel **activo** $\times$ **día** sobre la cual, en los pasos 5.2.1.5 a 5.2.1.8, se anexan los valores restantes de la secuencia de integración. El detalle del procedimiento para los pasos 5.2.1.4 a 5.2.1.8 se documenta en el Apéndice A.3.1.

5.2.1.5 Integración de CANTIDAD_ELEMENTOS y CANTIDAD_USUARIOS (afectación por evento).

Sobre la tabla base consolidada del paso 5.2.1.4, se anexan las métricas de **severidad del evento** (ELEMENTOS_AFECTADOS y USUARIOS_AFECTADOS de tabla_eventos_ajustado.csv, alineadas con la Tabla 5.2). Estas cantidades se miden a nivel de ID_EVENTO, tamaño del impacto de la interrupción, y se atribuyen al activo fallado mediante las llaves:

- COMPONENTE_FALLADO = ELEMENTO (activo de red, no el identificador del evento);
- as.Date(FECHA_DESCONEXION) = FECHA_DIA.

El cruce es izquierdo por (ELEMENTO, FECHA_DIA) y conserva $N = 87.007.074$ filas. Si un activo registra varios eventos el mismo día, se conserva un único valor de afectación (el primer ID_EVENTO ordenado); **no** se suman las severidades de esos eventos en el panel diario. La frecuencia de todas las desconexiones del día se construye por separado en el paso 5.2.1.7. En días sin falla, CANTIDAD_ELEMENTOS = 0 y CANTIDAD_USUARIOS = 0.

Nota metodológica: bajo esta regla, CANTIDAD_* no representa “usuarios del activo”, sino la severidad del evento anclada al breaker en el día de inicio. En la taxonomía de modelado (Sección 3.1.2), estas cantidades pertenecen al **impacto posterior**: describen severidad una vez ocurrido el evento y **no** son predictoras contemporáneas de frecuencia o duración. Definiciones alternativas de agregación, suma o máximo de todos los eventos del mismo activo-día, o conteo de usuarios únicos por cuadrante-semana, pueden reelaborarse en la Etapa 4 sin alterar ese rol.

5.2.1.6 Integración de variables climáticas (NASA POWER).

Sobre la tabla resultante del paso 5.2.1.5 ($N = 87.007.074$ filas), se anexan las variables de la serie diaria nasa_power_consolidado mediante cruce izquierdo por (ELEMENTO, FECHA_DIA), incorporando precipitación, temperatura (media, máxima, mínima), humedad relativa y velocidad del viento, sin modificar el cardinal del panel.

5.2.1.7 Agregación de variables objetivo (DURACION_min y FRECUENCIA).

En este paso se construyen las columnas DURACION_min y FRECUENCIA sobre la tabla resultante del paso 5.2.1.6 ($N = 87.007.074$ filas). Para ello, se expanden previamente los eventos de la Tabla 5.1 (Sección 5.1.2) a nivel (COMPONENTE_FALLADO, FECHA_DIA) y el resultado se integra al panel mediante cruce izquierdo por (ELEMENTO, FECHA_DIA). La Tabla 5.1 contiene los campos FECHA_DESCONEXION y FECHA_CONEXION. Con base en las fechas de desconexión y reconexión, se asignan los valores diarios de la siguiente forma:

- **Duración** (DURACION_min, en minutos): minutos de interrupción del activo en FECHA_DIA, prorrateados por día. Cuando un evento abarca varios días, su duración se reparte entre cada FECHA_DIA según los minutos que el evento ocupa dentro de ese día (intersección del intervalo [FECHA_DESCONEXION, FECHA_CONEXION] con cada día calendario). El día de inicio recibe los minutos desde FECHA_DESCONEXION hasta la medianoche; los días intermedios, 1.440 min cada uno; y el día de cierre, los minutos desde la medianoche hasta FECHA_CONEXION. Si varios eventos ocupan el mismo día, se suman los minutos prorrateados de cada uno. **No** se carga la duración total del evento únicamente en el día de desconexión.
- **Frecuencia** (FRECUENCIA): número de desconexiones cuyo inicio (FECHA_DESCONEXION) ocurre en FECHA_DIA (no se prorratea; se cuenta solo en el día de inicio).

Cuando el activo no presenta interrupciones en un día, se asigna $DURACION_min = 0$ y $FRECUENCIA = 0$. El cruce exige que $COMPONENTE_FALLADO$ coincida con $ELEMENTO$ del inventario `tipo_elemento.csv` (Tabla 5.5), el cual emplea el **código de sitio** georreferenciado. Cuando OMS registra el **código del activo** reemplazado en lugar del código de sitio, el emparejamiento falla y el evento no se propaga al panel espacial (Sección 5.3.5).

5.2.1.8 Consolidación del panel final (activo-día).

Sobre la tabla base consolidada definida en el paso 5.2.1.4, y una vez anexados los valores de los pasos 5.2.1.5 a 5.2.1.7, se obtiene el dataset final con grano **activo eléctrico** $\times$ **día** y 87.007.074 observaciones (47.649 activos $\times$ 1.826 días). En días sin falla se registra $DURACION_min = 0$, $FRECUENCIA = 0$, $CANTIDAD_ELEMENTOS = 0$ y $CANTIDAD_USUARIOS = 0$.

La base de datos consolidada se estructura como un panel de datos de tipo activo-tiempo, donde la unidad muestral corresponde a un **activo eléctrico observado diariamente**. Cada observación se identifica mediante el par activo-día dentro del periodo de análisis, lo que permite capturar la evolución temporal de cada activo a lo largo del horizonte de estudio. Con 47.649 activos eléctricos únicos en la Tabla 5.5 (inventario GIS, un registro por $ELEMENTO$) y 1.826 días observados (cinco años de información diaria), el panel balanceado comprende 87.007.074 observaciones.

5.2.2. Diagrama de flujo de la secuencia de integración

La secuencia de integración y la estructura del panel final se resumen visualmente en la Figura A.1 (Apéndice A.1), que especifica las relaciones entre las tablas y las operaciones aplicadas en cada paso.

5.2.3. Descripción de la tabla base consolidada

Las Tablas 5.8 a 5.11 presentan una muestra de la tabla base consolidada resultante del paso 5.2.1.8, con grano **activo eléctrico** $\times$ **día**. Por limitaciones de ancho en la página, la muestra se divide en cuatro bloques consecutivos que conservan el mismo orden de filas: identificación del activo (Tabla 5.8), severidad y clima inicial (Tabla 5.9), clima complementario (Tabla 5.10) y variables de continuidad (Tabla 5.11).

Nota: las filas de las Tablas 5.8 a 5.11 corresponden al mismo conjunto de observaciones en el mismo orden. Los registros sin interrupción en el día presentan

Tabla 5.8: Muestra de la tabla base consolidada (grano activo-día) – Parte 1: activo y fecha

Id activo	Tipo	Lat.	Lon.	Alt.	Fecha día
AASW4819	Aisladero	8.5786778	-72.92349	219	01/01/2021
1T12452	Transformador	8.5839989	-72.92248	241	01/01/2021
REC21365	Reconectador	8.5840628	-72.92246	241	01/01/2021
CUC12345	Cuchilla	7.7523729	-73.23971	1236	01/01/2021
INT39845	Interruptor	7.7476080	-73.25551	1359	02/01/2021
AASW4820	Aisladero	7.7561057	-73.26037	1169	02/01/2021
1T12453	Aisladero	7.7409332	-73.20825	1636	02/01/2021
REC21366	Transformador	7.7428641	-73.18990	1542	02/01/2021
CUC12346	Reconectador	7.7538839	-73.17721	1707	03/01/2021

Tabla 5.9: Muestra de la tabla base consolidada (grano activo-día) – Parte 2: severidad y clima inicial (continuación)

Id activo	Fecha día	C. elem.	C. usu.	Vel. viento	Temp. med.
AASW4819	01/01/2021	0	0	1.11	23.91
1T12452	01/01/2021	0	0	1.23	24.58
REC21365	01/01/2021	125	2015	0.96	23.04
CUC12345	01/01/2021	0	0	0.81	23.02
INT39845	02/01/2021	0	0	1.05	23.83
AASW4820	02/01/2021	0	0	1.12	24.08
1T12453	02/01/2021	0	0	1.08	24.52
REC21366	02/01/2021	0	0	1.26	24.37
CUC12346	03/01/2021	0	0	1.41	24.34

Tabla 5.10: Muestra de la tabla base consolidada (grano activo-día) – Parte 3: clima complementario (continuación)

Id activo	Fecha día	Hum. rel.	Temp. min.	Temp. max.	Precip.
AASW4819	01/01/2021	78.91	20.06	29.98	3.19
1T12452	01/01/2021	75.79	20.27	30.90	1.31
REC21365	01/01/2021	83.94	20.26	27.82	3.19
CUC12345	01/01/2021	79.55	17.92	30.09	7.28
INT39845	02/01/2021	69.70	19.35	30.79	1.99
AASW4820	02/01/2021	61.99	17.20	30.81	0.98
1T12453	02/01/2021	72.16	20.38	30.59	2.70
REC21366	02/01/2021	75.50	20.18	30.63	3.29
CUC12346	03/01/2021	74.34	20.40	30.43	1.86

Tabla 5.11: Muestra de la tabla base consolidada (grano activo–día) – Parte 4: variables de continuidad (continuación)

Duración (min)	Frecuencia
0	0
0	0
421.5	3
0	0
0	0
0	0
0	0
0	0
0	0

DURACION_min = 0 y FRECUENCIA = 0. La duración del panel diario se expresa en **minutos** (columna DURACION_min en data_consolidada.csv).

5.2.4. Descripción de las variables

Tabla 5.9 (severidad y clima inicial). Las columnas ID ACTIVO y FECHA DIA se repiten en esta tabla para facilitar la trazabilidad de filas entre bloques consecutivos. Las variables propias de este bloque son:

- **C. elem.** (CANTIDAD_ELEMENTOS): número de elementos de red afectados por el **evento** de interrupción atribuido al activo fallado (COMPONENTE_FALLADO) en el día de desconexión (paso 5.2.1.5). No es el inventario del activo ni un conteo de usuarios únicos del cuadrante. Si hay varios eventos el mismo activo–día, el panel conserva la severidad de un solo evento. Cuando el activo no registra falla en el día, el valor es 0. En el modelado es **impacto posterior** (Sección 3.1.2), no predictora contemporánea. **Clasificación:** cuantitativa discreta.
- **C. usu.** (CANTIDAD_USUARIOS): número de usuarios afectados por el mismo evento, con la misma atribución espacial y temporal que CANTIDAD_ELEMENTOS. Es una medida de severidad operativa del impacto sobre la demanda (impacto posterior; Sección 3.1.2), no una covariable disponible antes del evento ni una predictora válida de su ocurrencia o duración. En días sin interrupción, el valor es 0. **Clasificación:** cuantitativa discreta.
- **Vel. viento** (WS2M): velocidad del viento a 2 m de altura, expresada en m/s. Corresponde a la variable WS2M de NASA POWER (Sección 5.1.7) e integra al panel por FECHA_DIA en el paso 5.2.1.6. **Clasificación:** cuantitativa continua.
- **Temp. med.** (T2M): temperatura media del aire en el día, expresada en °C. Proviene del parámetro T2M de NASA POWER y captura las condiciones

térmicas promedio del entorno asociadas a cada observación activo-día.
Clasificación: cuantitativa continua.

Tabla 5.10 (clima complementario). Al igual que en la Tabla 5.9, ID ACTIVO y FECHA DIA permiten alinear filas entre tablas. Las variables climáticas restantes del bloque son:

- **Hum. rel. (RH2M):** humedad relativa del aire a 2 m, expresada en porcentaje (%). Proviene del parámetro RH2M de NASA POWER e integra al panel por FECHA_DIA. **Clasificación:** cuantitativa continua.
- **Temp. min. (T2M_MIN):** temperatura mínima diaria del aire, expresada en °C. Corresponde al parámetro T2M_MIN de NASA POWER y complementa la temperatura media con el extremo inferior del rango térmico del día. **Clasificación:** cuantitativa continua.
- **Temp. max. (T2M_MAX):** temperatura máxima diaria del aire, expresada en °C. Proviene del parámetro T2M_MAX de NASA POWER y representa el extremo superior del rango térmico observado en el día. **Clasificación:** cuantitativa continua.
- **Precip. (PRECTOT):** precipitación total acumulada en el día, expresada en mm. Corresponde al parámetro PRECTOT de NASA POWER y permite incorporar la exposición del activo a condiciones de lluvia en la fecha de observación. **Clasificación:** cuantitativa continua.

Tabla 5.11 (variables de continuidad). Este bloque concentra las variables objetivo del análisis, construidas en el paso 5.2.1.7 a partir de la Tabla 5.1 (eventos depurados, Sección 5.1.2) y de los campos FECHA_DESCONEXION y FECHA_CONEXION:

- **Duración (DURACION_min, en minutos):** minutos de interrupción del activo en FECHA_DIA, obtenidos prorrateando cada evento según la intersección de [FECHA_DESCONEXION, FECHA_CONEXION] con ese día (paso 5.2.1.7). Si el evento cruza varios días, su duración se reparte entre ellos; si hay varios eventos el mismo día, se suman los minutos prorrateados. No equivale a colocar la duración total del evento solo en el día de desconexión. En días sin falla, el valor es 0. **Clasificación:** cuantitativa continua.

- **Frecuencia** (FRECUENCIA): número de interrupciones del activo cuyo inicio (FECHA_DESCONEXION) ocurre en FECHA_DIA. La frecuencia se contabiliza únicamente en el día de inicio y **no** se prorratea entre días. En días sin falla, el valor es 0. **Clasificación:** cuantitativa discreta.

Una vez construido el panel consolidado (pasos de integración 5.2.1.4–5.2.1.8), se deriva la tabla agregada por cuadrante y semana (Sección 5.2.5). La Etapa 2 cierra con la evidencia institucional de calidad de las fuentes (Sección 5.2.7). El diagnóstico de completitud del panel, la identificación de valores extremos y el resto del análisis exploratorio se desarrollan en la Etapa 3; la imputación, el tratamiento definitivo de atípicos y la preparación del dataset para modelado, en la Etapa 4.

5.2.5. Agrupación de data consolidada por semana y cuadrante

Definición del grano analítico (cuadrante $\times$ semana)

El panel consolidado con grano **activo eléctrico $\times$ día** ($N = 87.007.074$ observaciones) constituye la base de integración y trazabilidad del proyecto: preserva la relación uno a uno entre cada activo de red y cada día del horizonte 2021–2025, y permite reconstruir con rigor la secuencia de pasos descrita en la Sección 5.2.1. No obstante, el objetivo del estudio, pronosticar el comportamiento de *SAIDI* y *SAIFI* en distintas áreas del territorio de concesión, exige una unidad de análisis de mayor agregación espacial y temporal, coherente con la lectura regulatoria y operativa de los indicadores de continuidad del servicio.

Desde el punto de vista espacial, los indicadores de calidad se interpretan y gestionan a escala territorial (zonas de concentración, circuitos y áreas de servicio), no a nivel de un activo aislado. Para sintetizar el comportamiento de la red en unidades homogéneas del territorio, se adopta la malla institucional de **800 cuadrantes** que cubre el área de concesión de la red eléctrica. En esta malla, el sufijo **_800** identifica la versión del esquema con 800 divisiones espaciales; cada celda tiene dimensiones aproximadas de 5×2.5 km. Cada activo eléctrico se asigna a un **id_cuadrante** mediante el catálogo **ELEMENTO_FALLA_CUADRANTE_800**, de modo que las observaciones diarias de múltiples activos ubicados en la misma celda puedan consolidarse en una métrica zonal. La Figura 5.1 ilustra la estructura de esta partición espacial sobre el área de estudio.

Desde el punto de vista temporal, la granularidad diaria del panel es necesaria para la integración de eventos, clima y severidad, pero resulta excesivamente ruidosa para el análisis exploratorio espacial y para la modelación orientada a dinámicas semanales de continuidad y clima. Por ello, se define la **semana calendario** (con inicio en lunes) como periodo de agregación temporal, lo que




Figura 5.1: Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. 5×2.5 km).

permite suavizar fluctuaciones diarias, estabilizar las series de interrupción y alinear las covariables meteorológicas en un horizonte compatible con la gestión operativa y con visualizaciones espacio-temporales (mapas por cuadrante y series semanales).

Bajo esta definición, la unidad muestral del dataset agregado es el par (**cuadrante, semana**). El panel `data_consolidada.csv` se conserva como insumo base y referencia del proyecto; la tabla derivada `data_agrupada_por_cuadrante_semana.csv` constituye la representación analítica para los análisis territoriales posteriores, sin sustituir ni alterar el panel diario original.

Procedimiento de agregación

Con el panel consolidado `data_consolidada.csv`, se construyó la tabla de análisis a grano **cuadrante** $\times$ **semana**. El procedimiento se documenta en el Apéndice A.3.2.

El insumo principal es el panel del paso 5.2.1.8. Para asignar cada activo a su zona de análisis espacial, se utiliza el catálogo `ELEMENTO_FALLA_CUADRANTE_800`, del cual se extrae la relación `ELEMENTO` $\rightarrow$ `id_cuadrante` (campo `CUADRANTE_1`). La asignación se integra al panel mediante cruce izquierdo por `ELEMENTO`, conservando todas las filas del panel y anexando el identificador de cuadrante cuando existe emparejamiento. Complementariamente, el archivo `CUADRANTE_CORD_800` aporta la referencia de centroides por cuadrante.

Sobre el panel enriquecido, cada observación diaria se asigna a una semana

calendario mediante `floor_date(FECHA_DIA, unit = "week", week_start = 1)`, de modo que la semana inicia en lunes. La duración del panel activo $\times$ día se conserva en **minutos** (`DURACION_min`; paso 5.2.1.7). Para la agregación semanal se convierte a horas como `duracion_horas = DURACION_min / 60`. Esta conversión **no** vuelve a prorratear entre días: el prorrateo temporal ya se resolvió al construir el panel diario; aquí solo se unifican unidades y se suman los minutos diarios (ya prorrateados) de los activos del cuadrante.

La agregación distingue dos naturalezas de variable. Las variables **operativas** (impacto y continuidad) son propias de cada activo: dos activos del mismo cuadrante pueden fallar el mismo día y sus conteos deben sumarse, por lo que se agregan directamente sobre las filas activo $\times$ día con `group_by(id_cuadrante, semana)`. Las variables **climáticas**, en cambio, describen un campo espacial común: como consecuencia del cruce del paso 5.2.1.6, todos los activos de un mismo cuadrante comparten el valor meteorológico del día, de modo que la serie diaria aparece replicada tantas veces como activos tenga el cuadrante. Por ello el bloque climático se agrega en **dos etapas**: primero se colapsa el panel a un registro por (`id_cuadrante, FECHA_DIA`), eliminando la replicación por activo, y sobre esa serie diaria del cuadrante se calcula el resumen semanal. Omitir la primera etapa dejaría el acumulado de lluvia multiplicado por el número de activos del cuadrante, un sesgo multiplicativo que además varía entre cuadrantes y contamina cualquier comparación territorial posterior.

Las reglas de resumen son las siguientes:

- **Coordenadas del cuadrante** (latitud, longitud, altitud): primer valor registrado en el grupo (`first`), tomado del inventario georreferenciado del panel.
- **Impacto operativo**: `usuarios_afectados = sum(CANTIDAD_USUARIOS)` y `elementos_afectados = sum(CANTIDAD_ELEMENTOS)` en la semana, sumando las severidades de evento ya atribuidas a los activos del cuadrante (paso 5.2.1.5). Esta suma agrega **impactos de evento**, no un conteo de usuarios o elementos únicos de la semana; tampoco multiplica la severidad por el número de activos del cuadrante (a diferencia del clima, que sí requería colapsar la replicación diario-activo). En el modelado pertenecen al grupo de **impacto posterior** (Sección 3.1.2): se conservan para el EDA y la descripción de severidad, pero **no** entran como predictoras contemporáneas de `n_eventos` ni de `duracion_total`. Una reelaboración de la regla de agregación, si procede, se documenta en la Etapa 4 sin cambiar esa exclusión.
- **Variables climáticas semanales**: sobre la serie diaria por cuadrante de la

primera etapa, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana` como promedio de los días de la semana; `temp_max_semana` y `viento_max_semana` como máximo; `temp_min_semana` como mínimo; y `precip_total_semana` como suma de la precipitación diaria del cuadrante, es decir el acumulado de lluvia de la semana en milímetros.

- **Continuidad del servicio:** `n_eventos = sum(FRECUENCIA)` (total de desconexiones **iniciadas** en la semana, sin prorrateo de la frecuencia) y `duracion_total = sum(duracion_horas)` (suma semanal, en horas, de los minutos diarios de interrupción ya prorrateados en el panel activo $\times$ día; unidad resultante: horas).

El resultado se exporta como `data_agrupada_por_cuadrante_semana.csv` en la ruta definida por la variable de entorno `UBICACION_DATA`.

5.2.6. Descripción de la tabla base semanal cuadrante

La Tabla 5.12 resume la estructura del dataset agregado `data_agrupada.csv`, con grano **cuadrante $\times$ semana**. Cada fila corresponde a un par (`id_cuadrante`, `semana`) y concentra, para esa celda de la malla y ese periodo semanal, las coordenadas de referencia, el impacto operativo acumulado, las variables climáticas resumidas y las métricas de continuidad del servicio. Las Tablas 5.13 a 5.16 presentan una muestra ilustrativa; por limitaciones de ancho en la página, la muestra se divide en cuatro bloques consecutivos que conservan el mismo orden de filas: identificación espacio-temporal e impacto operativo (Tabla 5.13), temperatura (Tabla 5.14), clima complementario (Tabla 5.15) y continuidad del servicio (Tabla 5.16).

Nota: las filas de las Tablas 5.13 a 5.16 corresponden al mismo conjunto de observaciones en el mismo orden. Cadena de unidades de continuidad: panel diario en **minutos** (`DURACION_min`) $\rightarrow$ conversión $/60 \rightarrow$ `duracion_total` semanal en **horas**. El prorrateo entre días se aplica solo al construir `DURACION_min` (paso 5.2.1.7); la agregación semanal suma esos minutos ya prorrateados, convertidos a horas. Las semanas sin interrupciones registran `n_eventos = 0` y `duracion_total = 0`. Las unidades de temperatura, humedad, viento y precipitación coinciden con las del panel diario ($^{\circ}\text{C}$, %, m/s y mm, respectivamente).

5.2.7. Evidencia de calidad y confiabilidad de las fuentes

La validación de los datos recopilados por Centrales Eléctricas de Norte de Santander S.A. E.S.P. (CENS) se fundamenta en su arquitectura institucional de gestión, enmarcada en la Política de Gestión de Tecnología de la Información (Sesión de la Junta Directiva No. 800 del 20 de febrero de 2018) CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P. [56] y en la Política del Sistema

Tabla 5.12: Estructura de la tabla base semanal cuadrante (*data_agrupada.csv*).

Bloque	Variables	Regla de agregación
Identificación	id_cuadrante	Llave del grupo
Georreferencia	semana	first
	latitud	
	longitud	
Impacto	altitud	sum
	usuarios_afectados	
Clima	elementos_afectados	mean [†]
	temp_media_semana	mean [†]
	temp_max_semana	max [†]
	temp_min_semana	min [†]
	humedad_media_semana	mean [†]
	viento_medio_semana	mean [†]
	viento_max_semana	max [†]
	precip_total_semana	sum [†]
Continuidad	n_eventos	sum
	duracion_total	

Nota: [†] el bloque climático se resume en dos etapas; la regla indicada opera sobre la serie diaria por cuadrante, obtenida tras colapsar las filas activo × día que replican el mismo valor meteorológico.

Tabla 5.13: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo

Id cuad.	Semana	Lat.	Lon.	Alt.	Usu. afect.	Elem. afect.
1	28/12/2020	7.0012	-72.6855	3418	0	0
1	04/01/2021	7.0012	-72.6855	3418	0	0
3	04/01/2021	7.1548	-72.7196	2850	0	0
12	11/01/2021	7.4521	-72.8903	1240	842	18
45	18/01/2021	7.7539	-73.1204	890	0	0
117	25/01/2021	7.9215	-72.5021	286	1254	24
203	01/02/2021	8.0812	-72.4108	312	0	0
45	08/02/2021	7.7539	-73.1204	890	315	6
117	15/02/2021	7.9215	-72.5021	286	680	11

Tabla 5.14: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 2: temperatura (continuación)

Id cuad.	Semana	Temp. med.	Temp. max.	Temp. min.
1	28/12/2020	13.6	19.8	6.2
1	04/01/2021	12.8	18.5	5.8
3	04/01/2021	13.1	19.2	6.0
12	11/01/2021	22.4	28.6	16.8
45	18/01/2021	23.8	30.1	18.2
117	25/01/2021	24.1	30.4	18.9
203	01/02/2021	24.5	30.8	19.1
45	08/02/2021	23.5	29.7	17.8
117	15/02/2021	24.3	30.2	18.6

Tabla 5.15: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación)

Id cuad.	Semana	Hum. med.	Vel. med.	Vel. max.	Precip.
1	28/12/2020	82.4	1.15	2.31	18.5
1	04/01/2021	80.1	1.08	2.18	12.3
3	04/01/2021	81.6	1.12	2.25	15.7
12	11/01/2021	76.3	0.98	1.95	8.4
45	18/01/2021	74.8	1.05	2.10	6.2
117	25/01/2021	73.5	1.18	2.42	9.8
203	01/02/2021	72.9	1.22	2.55	4.1
45	08/02/2021	75.2	1.09	2.08	11.6
117	15/02/2021	74.1	1.14	2.35	7.3

Tabla 5.16: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación)

N eventos	Duración total (h)
0	0.0
0	0.0
0	0.0
5	28.4
0	0.0
8	41.7
0	0.0
2	12.6
4	22.3

de Gestión Integrado (Sesión de la Junta Directiva No. 831 del 22 de abril de 2020) CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P. [57], orientadas a garantizar una gestión sistemática de calidad continua, sostenibilidad ambiental y cumplimiento legal mediante la evaluación permanente de la calidad de los datos, priorizando consistencia, disponibilidad y accesibilidad de la información.

CENS refuerza su gobernanza de datos mediante Instrumentos de Gestión de Información Pública, entre los cuales se destacan el Registro de Activos de Información (IPR), utilizado para detectar, clasificar y almacenar conjuntos de datos institucionales; los Cuadros de Clasificación Documental; el Esquema de Publicación de Información (IPS); el Índice de Información Clasificada y Reservada; los Costos de Reproducción; y el Programa de Gestión Documental (PGD). Estos instrumentos enmarcan el proceso institucional de almacenamiento, organización, acceso, difusión, protección y preservación de la información CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P. [58].

En conjunto, estos mecanismos reflejan sistemas de control interno, gobernanza, confianza en la información documentada y transparencia institucional. Asimismo, evidencian el funcionamiento estructurado de los registros y su disponibilidad operativa, garantizando la calidad, veracidad y consistencia de los datos utilizados en este estudio para la toma de decisiones analíticas y gerenciales.

La fiabilidad técnica de las variables climáticas se sustenta en NASA POWER, plataforma del Langley Research Center de la NASA de la cual provienen las series meteorológicas integradas al panel (Sección 5.1). Esta fuente fue seleccionada por ofrecer cobertura diaria completa y homogénea sobre la totalidad del área de servicio durante el periodo de estudio, sin los vacíos ni las discontinuidades propias de una red de estaciones terrestres.

Los parámetros utilizados se derivan del reanálisis MERRA-2 del programa Earth Science de la NASA y se distribuyen mediante una API pública, documentada y versionada, con definiciones y unidades explícitas para cada variable. Estas características garantizan trazabilidad, reproducibilidad y consistencia metodológica en la captura de las series climáticas, de modo que la extracción documentada en la Etapa 1 puede replicarse de forma íntegra NASA Langley Research Center (LaRC) POWER Project [54].

5.3. Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA)

Una vez completadas las etapas de extracción e integración (Etapas 1 y 2), se desarrolla un análisis exploratorio orientado a caracterizar las distribuciones de las variables, diagnosticar la calidad del panel (valores faltantes y extremos), identificar patrones temporales y espaciales, y evaluar las relaciones entre co-variables que podrían explicar la variación de *SAIDI* y *SAIFI*. Esta etapa se concibe como un análisis diagnóstico previo al modelamiento, orientado a garantizar la estabilidad e interpretabilidad de los resultados y a fundamentar las decisiones de imputación y transformación de la Etapa 4.

Para las variables cuantitativas se calculan medidas de tendencia central y de dispersión, incluida la desviación estándar y el coeficiente de variación (CV; Sección 3.1.2), así como la proporción de valores atípicos; adicionalmente se construyen histogramas y diagramas de caja para examinar la forma de las distribuciones. En el caso de las variables categóricas, se analizan las frecuencias absolutas y relativas de cada categoría. El grado de asociación se evalúa con el coeficiente de Spearman Spearman [15] (cuantitativas) y el estadístico V de Cramér Cramér [16] (cualitativas), según se formalizan en la Sección 3.1.2, con el fin de identificar redundancias y relaciones preliminares que orienten la depuración de variables en la Etapa 4. Las visualizaciones incluyen series de tiempo, gráficos de dispersión, mapas temáticos y mapas de calor de correlaciones.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes. Tras la caracterización del panel, se documentan el diagnóstico de datos faltantes (Sección 5.3.1) y la identificación de valores extremos (Sección 5.3.2); a continuación se profundiza en estadísticos descriptivos, distribuciones, patrones temporales y asociaciones entre variables. Sobre D_{mod} , la identificación de patrones y la visualización exploratoria (series de tiempo, gráficos de dispersión y mapas temáticos) se integran en la Sección 5.3.6.

5.3.1. Identificación de datos faltantes

Sobre el panel consolidado final (`data_consolidada.csv`), con $N = 87.007.074$ observaciones (grano activo eléctrico $\times$ día), se realizó un diagnóstico sistemático de valores faltantes (NA) con dos enfoques complementarios: (i) conteo de NA por variable y (ii) conteo de observaciones del panel con al menos un NA por fila. El objetivo fue cuantificar la magnitud y localizar el origen de la incompletitud como insumo del EDA y para fundamentar las decisiones de imputación o exclusión en la Etapa 4.

En el análisis por columna, para cada una de las 16 variables del panel se

calculó el número absoluto de NA y su porcentaje respecto a N . En el análisis por fila, se determinó cuántas observaciones (i, t) presentan cero, uno o más campos incompletos, junto con el máximo de variables faltantes registradas en una misma fila.

Los resultados muestran que la incompletitud se concentra en las variables climáticas integradas desde NASA POWER en el paso 5.2.1.6. Las seis variables meteorológicas (`velocidad_viento_ms`, `temperatura_media_c`, `humedad_relativa_pct`, `temperatura_minima_c`, `temperatura_maxima_c` y `precipitacion_total_mm`) presentan exactamente 3.401.838 valores faltantes cada una, equivalente al 3.91 % de N . Este patrón es coherente con el cruce izquierdo por $(ELEMENTO, FECHA_DIA)$: las filas sin emparejamiento en la base climática conservan NA en el bloque meteorológico. La variable `ALTITUD` registra 32.868 faltantes (0.04 % de N), asociados al inventario GIS. El resto de variables del panel, identificación del activo (`ELEMENTO`, `TIPO`, `LATITUD`, `LONGITUD`), calendario (`FECHA\_DIA`), severidad (`CANTIDAD_ELEMENTOS`, `CANTIDAD_USUARIOS`) y continuidad (`DURACION_min`, `FRECUENCIA`), no presentan NA, dado que los pasos 5.2.1.5 y 5.2.1.7 asignan 0 en días sin evento.

A nivel de fila, 83.576.020 observaciones (96.06 %) están completas; 3.431.054 filas (3.94 %) tienen al menos un NA, y el máximo de variables incompletas en una misma observación es 7 (combinación de las seis variables climáticas más `ALTITUD`). La Figura 5.2 y la Tabla 5.17 resumen el porcentaje de faltantes por variable, ordenado de mayor a menor.




Figura 5.2: Porcentaje de valores faltantes por variable en el panel consolidado ($N = 87.007.074$).

En síntesis, la calidad estructural del panel es alta en variables operativas de interrupción (sin NA), y la incompletitud relevante para el modelado se limita

Tabla 5.17: Resumen de valores faltantes por variable en el panel consolidado

Variable	<i>n</i> de NA	% sobre <i>N</i>
velocidad_viento_ms	3.401.838	3.91
temperatura_media_c	3.401.838	3.91
humedad_relativa_pct	3.401.838	3.91
temperatura_minima_c	3.401.838	3.91
temperatura_maxima_c	3.401.838	3.91
precipitacion_total_mm	3.401.838	3.91
ALTITUD	32.868	0.04
<i>Resto de variables del panel: 0 NA (0 %)</i>		

al bloque climático y, en menor medida, a ALTITUD. Las reglas de imputación o exclusión se definen con base en este diagnóstico y se aplican en la Etapa 4.

Tabla agrupada cuadrante $\times$ semana. Sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90.128$ observaciones y 16 variables, se replicó el mismo esquema de diagnóstico: conteo de NA por variable y por fila. El procedimiento se documenta en el Apéndice A.3.3.

En el análisis por columna, las 16 variables del grano agregado, identificación y calendario (`id_cuadrante`, `semana`), georreferenciación (`latitud`, `longitud`, `altitud`), severidad (`usuarios_afectados`, `elementos_afectados`), clima semanal (`temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`, `viento_medio_semana`, `viento_max_semana`, `precip_total_semana`) y continuidad (`n_eventos`, `duracion_total`), registran 0 valores faltantes (0 % sobre N_{agr}). A nivel de fila, las 90.128 observaciones están completas: ninguna fila presenta al menos un NA y el máximo de variables incompletas por fila es 0.

Este resultado es coherente con la agregación descrita en la Sección 5.2.5: las sumas y promedios semanales emplean `na.rm = TRUE`, de modo que los NA del panel diario no se propagan como campos vacíos en el grano agregado; las métricas operativas sin evento se consolidan en 0, y cada fila exportada conserva llaves estructurales definidas (`id_cuadrante`, `semana`). La Figura 5.3 ilustra la ausencia de faltantes en una muestra de las primeras 50 filas: todas las celdas se clasifican como completas.

En consecuencia, la tabla agrupada no requiere reglas de imputación por valores faltantes en la Etapa 4; el tratamiento de incompletitud documentado en los párrafos anteriores aplica al panel consolidado activo $\times$ día, grano en el que se originan los NA climáticos y de ALTITUD.




Figura 5.3: Completitud de la tabla agrupada por fila y variable ($N_{\text{agr}} = 90.128$; muestra de 50 filas).

5.3.2. Identificación de valores extremos en variables cuantitativas

Se evaluó la presencia de valores extremos en las variables cuantitativas mediante reglas univariadas y diagramas de caja e histogramas. El análisis distingue observaciones operativamente plausibles de posibles inconsistencias de registro, sin aplicar aún transformaciones ni exclusiones definitivas; el tratamiento se difiere a la Etapa 4 con base en estos hallazgos. Para cada variable se aplicaron la regla de Tukey Tukey [12], el rango intercuartílico ampliado y el criterio de percentiles P1–P99, conforme a lo formalizado en la Sección 3.1.2. Como complemento interpretativo de la dispersión relativa entre variables de distinta escala, se reporta el coeficiente de variación (CV; Sección 3.1.2).

Panel consolidado activo $\times$ día. Sobre `data_consolidada.csv` ($N = 87.007.074$) se aplicó el protocolo descrito, excluyendo coordenadas geográficas (LATITUD, LONGITUD, ALTITUD). El detalle reproducible se documenta en el Apéndice A.3.4.

Variables climáticas diarias. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas, baja dispersión relativa (CV entre 0.16 y 0.20) y un porcentaje muy bajo de extremos bajo la regla de Tukey (entre 0 % para `humedad_relativa_pct` y 0.20 % para `temperatura_minima_c`);

con el factor 3.0 prácticamente no se identifican extremos severos. El viento exhibe mayor heterogeneidad relativa ($CV = 0.69$). La `precipitacion_total_mm` constituye la excepción: por su naturaleza fuertemente asimétrica, con exceso de ceros y $CV = 2.12$, la regla de Tukey marca el 10.38 % de las observaciones y la ampliada el 5.30 %, aunque la regla de percentiles solo señala el 1.00 %. Estos valores corresponden a días de lluvia intensa operativamente plausibles, no a errores de registro. La Tabla 5.18 resume estos resultados y las Figuras 5.4 y 5.5 muestran, respectivamente, los diagramas de caja y los histogramas sobre una muestra de 200.000 observaciones.

Tabla 5.18: Valores extremos y dispersión relativa en variables climáticas (panel completo)

Variable	Mediana	CV	% IQR 1.5	% IQR 3.0	% P1-P99
<code>velocidad_viento_ms</code>	1.20	0.69	0.03	0.00	1.60
<code>temperatura_media_c</code>	25.47	0.17	0.02	0.00	1.99
<code>humedad_relativa_pct</code>	69.08	0.18	0.00	0.00	1.98
<code>temperatura_minima_c</code>	20.91	0.20	0.20	0.00	1.99
<code>temperatura_maxima_c</code>	31.32	0.16	0.05	0.00	1.99
<code>precipitacion_total_mm</code>	0.50	2.12	10.38	5.30	1.00




Figura 5.4: Distribución de las variables climáticas: mediana y extremos (muestra de 200.000 observaciones).

Variables de severidad y continuidad diarias. Estas variables están dominadas por ceros (días sin interrupción): el 99.94 % de las filas registra 0, por lo que sobre el panel completo se cumple $Q_1 = Q_3 = 0$ y la regla de Tukey resulta




Figura 5.5: Distribución de las variables climáticas: forma y cola (muestra de 200.000 observaciones).

poco informativa (marca como extremo cualquier día con evento, 0.06 % del panel); el CV del panel completo queda artificialmente inflado por la masa en cero. Por ello, el análisis relevante se realiza sobre los días con evento (valor > 0), donde se concentran 48.375 registros de afectación y 48.364 de continuidad. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha y de alta dispersión relativa: la mediana de CANTIDAD_USUARIOS es 23 usuarios pero su máximo alcanza 34.622 ($CV = 3.97$); la DURACION_min tiene mediana de 417 minutos (≈ 7 horas) y un máximo de 332.395 minutos (≈ 231 días; $CV = 3.56$), sugerente de posibles inconsistencias de registro que se marcan para revisión. La regla de Tukey marca entre el 9 % y el 15 % de los días con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 5.19 resume estos resultados y las Figuras 5.6 y 5.7 presentan los diagramas de caja e histogramas sobre los días con evento.

Tabla 5.19: Valores extremos y dispersión relativa en severidad y continuidad (días con evento, valor > 0)

Variable	n	Mediana	Máximo	CV	% IQR 1.5	% IQR 3.0
CANTIDAD_ELEMENTOS	48.375	2	2.469	3.15	14.91	11.78
CANTIDAD_USUARIOS	48.375	23	34.622	3.97	14.50	10.83
DURACION_min	48.364	417	332.395	3.56	8.94	5.36
FRECUENCIA	48.364	1	6	0.15	1.96	1.96




Figura 5.6: Distribución de la severidad y continuidad en días con evento: mediana y extremos.



Figura 5.7: Distribución de la severidad y continuidad en días con evento: forma y cola.

Tabla agrupada cuadrante $\times$ semana. Sobre `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90.128$ observaciones, se replicó el mismo esquema excluyendo `id_cuadrante`, `latitud`, `longitud` y `altitud`. El procedimiento se documenta en el Apéndice A.3.5.

Variables climáticas semanales. El diagnóstico se realizó sobre la tabla completa. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas, baja dispersión relativa (CV entre 0.16 y 0.25) y un porcentaje muy bajo de extremos bajo Tukey (entre 0 % y 0.03 %); con el factor 3.0 no se identifican extremos severos. El viento semanal es más heterogéneo (CV $\approx$ 0.78–0.81). La `precip_total_semana` constituye la excepción: al ser un acumulado semanal asimétrico a la derecha con CV = 1.17, la regla de Tukey marca el 6.21 % de las observaciones y la ampliada el 1.79 %, aunque la regla de percentiles solo señala el 0.99 %. Los valores señalados corresponden a semanas de lluvia intensa operativamente plausibles: el máximo observado es de 198.1 mm acumulados en la semana, magnitud compatible con los registros de temporada de lluvia en la región. La Tabla 5.20 resume estos resultados y las Figuras 5.8 y 5.9 muestran los diagramas de caja y los histogramas sobre las 90.128 observaciones.

Tabla 5.20: Valores extremos y dispersión relativa en variables climáticas semanales (tabla agrupada)

Variable	Mediana	CV	% IQR 1.5	% IQR 3.0	% P1–P99
<code>temp_media_semana</code>	24.84	0.19	0.00	0.00	1.95
<code>temp_max_semana</code>	32.72	0.17	0.00	0.00	1.99
<code>temp_min_semana</code>	18.95	0.25	0.03	0.00	1.96
<code>humedad_media_semana</code>	72.28	0.16	0.00	0.00	1.97
<code>viento_medio_semana</code>	0.91	0.81	0.00	0.00	1.99
<code>viento_max_semana</code>	1.26	0.78	0.00	0.00	1.69
<code>precip_total_semana</code>	9.78	1.17	6.21	1.79	0.99

Variables de severidad y continuidad. En la tabla completa persisten semanas sin interrupción registrada ($Q_1 = Q_3 = 0$ en `usuarios_afectados`, `elementos_afectados` y `n_eventos`), por lo que la regla de Tukey sobre el total es poco informativa para esas variables y el CV del panel completo queda inflado por ceros (Tabla 5.23). El análisis relevante se realiza sobre semanas con evento (valor > 0), con 22.660–24.800 registros según la variable. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha y de alta dispersión relativa: la mediana de `usuarios_afectados` es 52 usuarios pero su máximo alcanza 69.928 (CV = 3.82); `duracion_total` tiene mediana de 19.7 horas y un máximo

Diagramas de caja — variables climáticas semanales

Data agrupada cuadrante x semana | N = 90,128 observaciones




Figura 5.8: Distribución de las variables climáticas semanales: mediana y extremos ($N_{\text{agr}} = 90.128$).

Histogramas — variables climáticas semanales

Data agrupada cuadrante x semana | N = 90,128 observaciones




Figura 5.9: Distribución de las variables climáticas semanales: forma y cola ($N_{\text{agr}} = 90.128$).

de 2.227 horas (≈ 93 días acumulados; $CV = 1.73$). La regla de Tukey marca entre el 11.6 % y el 15.2 % de las semanas con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 5.21 resume estos resultados y las Figuras 5.10 y 5.11 presentan los diagramas de caja e histogramas.

Tabla 5.21: Valores extremos y dispersión relativa en severidad y continuidad (semanas con evento, valor > 0)

Variable	n	Mediana	Máximo	CV	% IQR 1.5	% IQR 3.0
usuarios_afectados	22.660	52	69.928	3.82	15.16	11.21
elementos_afectados	22.660	7	3.626	2.75	15.00	10.70
duracion_total	24.800	19.7	2.227	1.73	11.56	4.25
n_eventos	22.659	1	58	1.08	14.53	5.73




Figura 5.10: Distribución de la severidad y continuidad en semanas con evento: mediana y extremos.

En síntesis, en el grano cuadrante $\times$ semana los extremos climáticos son escasos y operativamente plausibles (con la precipitación acumulada como única variable de asimetría apreciable y CV superior a la unidad), mientras que en severidad y continuidad la cola pesada y el CV condicionado a semanas con evento reflejan semanas de alta afectación o múltiples eventos en un mismo cuadrante. No se aplican transformaciones ni exclusiones en esta etapa; las decisiones de tratamiento se documentan y ejecutan en la Etapa 4 a partir de este diagnóstico sobre la tabla de análisis.

5.3.3. Cálculo de estadísticos descriptivos

Tras el diagnóstico de completitud (Sección 5.3.1) y el análisis de valores extremos (Sección 5.3.2), se calculó un conjunto sistemático de estadísticos descriptivos sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{agr} =$




Figura 5.11: Distribución de la severidad y continuidad en semanas con evento: forma y cola.

90.128 observaciones cuadrante $\times$ semana. Se excluyeron las llaves y coordenadas (*id_cuadrante*, *latitud*, *longitud*, *altitud*) y se evaluaron las 11 variables numéricas de severidad, clima semanal y continuidad. El procedimiento reproducible se documenta en el Apéndice A.3.6.

Para cada variable se reportaron: (i) medidas de tendencia central (media, mediana y moda); (ii) medidas de dispersión (rango, varianza, desviación estándar y coeficiente de variación; Sección 3.1.2); (iii) medidas de posición (cuartiles, deciles y percentiles P1, P5, P95 y P99); (iv) medidas de forma (asimetría y curtosis con exceso); y (v) distribución de frecuencias de la categoría derivada *actividad semanal del cuadrante*, construida a partir de *n_eventos* (sin eventos; 1 evento; 2–5 eventos; más de 5 eventos). Las Figuras 5.12 y 5.13 presentan la vista panorámica de las 11 variables mediante histogramas y diagramas de caja.

Variables climáticas semanales. Las siete variables meteorológicas agregadas presentan distribuciones aproximadamente simétricas y baja dispersión relativa: el coeficiente de variación (CV) se ubica entre 0.16 (*humedad_media_semana*) y 0.81 (*viento_medio_semana*). La temperatura media semanal tiene mediana de 24.8 °C (media 23.8 °C; Q_1 – Q_3 : 20.4–27.2 °C) y asimetría cercana a cero (–0.37). La humedad relativa media semanal concentra la mediana en 72.3 % (CV = 0.16). La excepción es *precip_total_semana*: acumulado semanal con mediana de 9.8 mm, media de 16.0 mm, CV = 1.17 y asimetría positiva (1.98), con un recorrido de 0 a 198.1 mm y un percentil 99 de 85.1 mm que corresponde a semanas de lluvia intensa puntuales. La Tabla 5.22 resume tendencia central y dispersión; la Figura 5.14 muestra las curvas de densidad.




Figura 5.12: Distribución de las variables numéricas de la tabla agrupada: forma y cola ($N_{agr} = 90.128$).

Tabla 5.22: Estadísticos descriptivos de variables climáticas semanales (tabla agrupada)

Variable	Media	Mediana	Desv. est.	CV	Asimetría
temp_media_semana	23.8	24.8	4.63	0.19	−0.37
temp_max_semana	31.9	32.7	5.29	0.17	−0.44
temp_min_semana	17.9	19.0	4.49	0.25	−0.49
humedad_media_semana	70.9	72.3	11.5	0.16	−0.36
viento_medio_semana	0.99	0.91	0.80	0.81	0.44
viento_max_semana	1.30	1.26	1.01	0.78	0.37
precip_total_semana	16.0	9.8	18.7	1.17	1.98




Figura 5.13: Distribución de las variables numéricas de la tabla agrupada: mediana y extremos ($N_{\text{agr}} = 90.128$).




Figura 5.14: Forma de la distribución de las variables climáticas semanales ($N_{\text{agr}} = 90.128$).

Variables de severidad y continuidad. Las cuatro variables operativas están dominadas por ceros: la mediana de `usuarios_afectados`, `elementos_afectados`, `n_eventos` y `duracion_total` es 0 en el 74.9% de las semanas-cuadrante sin eventos registrados (Tabla 5.24; Figuras 5.15 y 5.16). Cuando ocurre al menos un evento, las distribuciones son fuertemente leptocúrticas y con cola derecha pesada: `usuarios_afectados` alcanza un máximo de 69.928 usuarios (media 156.1; CV del panel completo = 7.81, inflado por ceros; CV condicionado a semanas con evento = 3.82); `duracion_total` un máximo de 2.227 horas acumuladas en la semana (media 13.7 h; CV completo = 3.67; CV condicionado = 1.73). La Tabla 5.23 resume las medidas principales del panel completo; la Tabla 5.21 reporta el CV condicionado; la Figura 5.17 presenta las densidades en escala logarítmica desplazada (Sección 3.1.2) para semanas con evento.

Tabla 5.23: Estadísticos descriptivos de severidad y continuidad (tabla agrupada; panel completo)

Variable	Media	Mediana	Máx.	CV	Asimetría	Q_3
<code>usuarios_afectados</code>	156.1	0	69.928	7.81	20.6	1
<code>elementos_afectados</code>	12.0	0	3.626	5.74	14.1	1
<code>n_eventos</code>	0.55	0	58	2.76	8.18	1
<code>duracion_total</code>	13.7	0	2.227	3.67	10.2	2.5

Nota: el CV del panel completo queda inflado por la cero-inflación; el CV condicionado a semanas con evento se reporta en la Tabla 5.21.

Tabla 5.24: Distribución de frecuencias por actividad semanal del cuadrante

Categoría (<code>n_eventos</code>)	Frec. absoluta	Frec. relativa (%)	Frec. acumulada (%)
Sin eventos	67.469	74.86	74.86
1 evento	12.115	13.44	88.30
2 a 5 eventos	9.246	10.26	98.56
Más de 5 eventos	1.298	1.44	100.00

En síntesis, el clima semanal exhibe comportamiento estable y casi simétrico, mientras que las variables operativas reflejan fuerte cero-inflación y colas pesadas propias del fenómeno de interrupciones. Estos perfiles, especialmente la asimetría de `precip_total_semana` y la concentración de semanas sin evento, orientan las transformaciones logarítmicas desplazadas (Sección 3.1.2) y la selección de modelos en la Etapa 4.

5.3.4. Análisis de la distribución de variables

Con el propósito de comprender el comportamiento estadístico de las variables incluidas en el estudio, se realizó un análisis de distribución sobre las variables climáticas, de severidad y de continuidad contenidas en la tabla agregada cua-




Figura 5.15: Frecuencia de semanas-cuadrante según actividad de eventos ($N_{agr} = 90.128$).




Figura 5.16: Distribución porcentual de semanas-cuadrante por actividad de eventos.




Figura 5.17: Distribución de la severidad y continuidad en escala logarítmica desplazada (semanas con evento).

drante $\times$ semana ($N_{\text{agr}} = 90.128$; Sección 5.2.5). Para las variables cuantitativas se emplearon diagramas de densidad, complementados con indicadores de forma (asimetría, curtosis y proporción de ceros) y con el coeficiente de variación reportado en las Secciones 5.3.2–5.3.3, lo que permitió evaluar simetría, dispersión relativa, unimodalidad y presencia de valores extremos. El procedimiento reproducible se documenta en el Apéndice A.3.7.

Variables climáticas. Los resultados evidencian que las variables meteorológicas presentan distribuciones heterogéneas. Las temperaturas (media, máxima y mínima) y la humedad relativa muestran comportamientos estables, aproximadamente unimodales, con asimetría cercana a cero (entre -0.49 y -0.36) y CV bajo (0.16 – 0.25), coherentes con las curvas de densidad presentadas en la Figura 5.14. En contraste, la precipitación acumulada semanal presenta asimetría positiva (coeficiente de 1.98 y curtosis con exceso de 4.78), $CV = 1.17$, alta frecuencia de semanas con valores bajos de lluvia (el 9.1% registra 0 mm) y un número reducido de observaciones con precipitaciones intensas. La Figura 5.18 contrasta la distribución en escala original y en escala logarítmica desplazada (Sección 3.1.2): la transformación aproxima la distribución a una forma simétrica, lo que anticipa su utilidad en la Etapa 4.

Variables de severidad y continuidad. Las variables asociadas a interrupciones del servicio (*usuarios_afectados*, *elementos_afectados*, *duracion_total* y *n_eventos*) muestran distribuciones altamente sesgadas hacia cero: la proporción de filas con valor 0 se ubica entre el 72.5% (*duracion_total*) y el 74.9% (resto de variables), como ilustra la Figura 5.19. Este comportamiento es esperado, dado que la mayor parte de las semanas-cuadrante no registra fallas. Sin




Figura 5.18: Distribución de la precipitación acumulada semanal en escala original y logarítmica desplazada ($N_{agr} = 90.128$).

embargo, condicionando a la ocurrencia de eventos (valor > 0), las distribuciones presentan colas derechas largas, con asimetrías entre 8.2 y 20.6 y curtosis entre 139 y 643, que reflejan la existencia de incidentes de alta severidad con impacto significativo sobre la continuidad del servicio, según se aprecia en las densidades en escala logarítmica desplazada de la Figura 5.17.




Figura 5.19: Proporción de ceros en las variables de severidad y continuidad de la tabla agrupada.

En síntesis, el análisis de distribución confirma dos regímenes claramente diferenciados: un bloque climático estable y casi simétrico (CV bajo, con la precipitación como excepción asimétrica de CV algo superior a la unidad) y un bloque operativo cero-inflado con colas pesadas y CV condicionado alto. Estos hallazgos fundamentan las transformaciones logarítmicas desplazadas (Sección 3.1.2) y la consideración de modelos aptos para datos cero-inflados en la Etapa 4.

5.3.5. Análisis temporal de eventos

Para caracterizar la dinámica temporal de las interrupciones se construyó, a partir de la tabla agregada `data_agrupada.csv` (Sección 5.2.5), la serie territorial semanal que consolida el total de `n_eventos` de todos los cuadrantes en cada semana calendario. La serie cubre 262 semanas del horizonte 2021–2025, con una mediana de 124.5 eventos por semana (media 188.5; máximo 648). El procedimiento reproducible se documenta en el Apéndice A.3.8.

Evolución de la serie semanal. La Figura 5.20 presenta la serie semanal con su tendencia suavizada (LOESS) sobre el horizonte exploratorio 2021–2025 (D_{EDA}). Se distinguen dos regímenes visuales: entre 2021 y 2023 la actividad se mantiene en un nivel bajo y relativamente estable, mientras que a partir de 2024 se observa un incremento sostenido del nivel de la serie. La agregación anual (Figura 5.21) cuantifica este cambio: de 5.167 eventos en 2021 y 4.934 en 2022, se pasa a 15.211 en 2024 y 18.199 en 2025; en términos de intensidad, el promedio asciende de ≈ 99 a ≈ 350 eventos por semana entre 2021 y 2025. La reinterpretación de este salto a la luz de la cobertura de integración se desarrolla en el párrafo siguiente (Sección 5.3.5).




Figura 5.20: Evolución semanal de los eventos de interrupción (suma territorial), 2021–2025.

Diagnóstico de cobertura del emparejamiento evento–elemento. Al contrastar el conteo anual de eventos en `tabla_eventos_ajustado.csv` (BRAE) con la suma territorial de `n_eventos` en `data_agrupada.csv`, se identificó un **sesgo sistemático** en el grano espacial durante 2021–2023 (Tabla 5.25; Figura 5.22). La causa no es la ausencia del campo `COMPONENTE_FALLADO`, completo en el 100 % de los registros BRAE, sino la **incompatibilidad entre esquemas de codificación** al cruzar eventos con el inventario georreferenciado `tipo_elemento.csv`




Figura 5.21: Total anual de eventos de interrupción sobre la tabla agrupada.

(Tabla 5.5).

En la operación de la red coexisten dos identificadores para un mismo punto de conexión: (i) el **código de sitio** (ubicación), estable en el tiempo y empleado por el inventario GIS como ELEMENTO; y (ii) el **código de activo**, asociado al equipo instalado y **sujeto a cambio** cuando el activo se repone por mantenimiento o renovación, mientras el código de sitio permanece invariante. El panel consolidado y la agregación cuadrante $\times$ semana se construyen sobre el código de sitio. No obstante, en el sistema histórico OMS-SPARD (Sección 5.1.4) el elemento fallado (BREAKER $\rightarrow$ COMPONENTE_FALLADO) se registraba con frecuencia mediante el **código del activo** y no el del sitio. Ello impide el seguimiento histórico del punto de desconexión, unidad espacial central para el pronóstico territorial de SAIDI y SAIFI en esta tesis, pues el cruce COMPONENTE_FALLADO = ELEMENTO no encuentra coincidencia en el inventario y el evento no genera FRECUENCIA en el panel activo $\times$ día.

El diagnóstico cuantitativo confirma esta hipótesis: la proporción de eventos cuyo COMPONENTE_FALLADO coincide con algún ELEMENTO de tipo_elemento.csv es del 30.5 % (2021), 30.9 % (2022) y 31.7 % (2023), valores cercanos a la cobertura del panel espacial en esos años (28.1 %, 28.1 % y 29.1 %, respectivamente). Con la migración a OMS-SP7 (Sección 5.1.5), la coincidencia asciende al 79.8 % (2024) y al 95.0 % (2025), acompañada por coberturas del panel del 77.7 % y 92.4 %. La Figura 5.21 debe interpretarse a la luz de esta brecha: el salto a partir de 2024 refleja en gran medida una **mayor homogeneización de la codificación** bajo OMS-SP7, y no únicamente un incremento operativo de interrupciones.

El procedimiento reproducible se documenta en el Apéndice A.3.9. Con base en este hallazgo, emergido en el presente análisis temporal, se define el **dataset de modelado** D_{mod} como el subconjunto de data_agrupada.csv con year(semana)

$\in \{2024, 2025\}$, que comprende 36.120 filas cuadrante $\times$ semana, 105 semanas y 33.410 eventos georreferenciados en total (15.211 en 2024 y 18.199 en 2025). El horizonte 2021–2025 se conserva como D_{EDA} para las Secciones 5.3.1–5.3.5, pero no se empleará para estimar el modelo predictivo de la Etapa 4.

Tabla 5.25: Cobertura anual de la trazabilidad al inventario GIS y al panel espacial.

Año	Eventos BRAE	En inventario (%)	Panel espacial	Cobertura (%)
2021	18.398	30.5	5.167	28.1
2022	17.542	30.9	4.934	28.1
2023	20.068	31.7	5.845	29.1
2024	19.583	79.8	15.211	77.7
2025	19.689	95.0	18.199	92.4

Nota: “En inventario (%)” es la proporción de eventos cuyo COMPONENTE_FALLADO coincide con ELEMENTO en tipo_elemento.csv (código de sitio). “Panel espacial” es la suma anual de n_eventos en data_agrupada.csv. La brecha entre ambas columnas en 2021–2023 se atribuye al registro del código de activo, y no del código de sitio, en OMS-SPARD, lo que impide el seguimiento histórico del punto de desconexión. Los años 2024–2025 delimitan D_{mod} .




Figura 5.22: Comparación anual entre eventos BRAE y eventos reflejados en el panel espacial. Las etiquetas indican el porcentaje de cobertura respecto a BRAE; la brecha histórica se explica por la incompatibilidad entre el código de activo registrado en OMS-SPARD y el código de sitio del inventario GIS.

Estacionalidad intra-anual. La Figura 5.23 muestra la distribución de los totales semanales según el mes calendario. Se aprecia heterogeneidad estacional, con mayor actividad y dispersión en algunos meses del año, patrón que motiva incorporar términos estacionales en la Etapa 4. La atribución de esta estacionalidad a la temporada de lluvias debe tomarse con cautela: como se documenta en

la Sección 5.3.7, la asociación semanal entre precipitación y frecuencia de eventos es débil en el grano cuadrante $\times$ semana.




Figura 5.23: Distribución del total semanal de eventos según mes calendario (2021–2025).

Autocorrelación temporal. Las funciones de autocorrelación simple y parcial de la serie semanal (Figura 5.24) evidencian fuerte persistencia: la autocorrelación es 0.92 en el rezago de una semana y decae lentamente (0.60 a 12 semanas; 0.38 a 26), manteniéndose significativa frente al intervalo de confianza del 95 % bajo ruido blanco (± 0.12). Adicionalmente, el rezago de 52 semanas conserva una autocorrelación de 0.43, indicativa de un componente estacional anual. Esta estructura justifica la incorporación de rezagos y términos estacionales como variables predictoras en la Etapa 4.




Figura 5.24: Persistencia y estructura temporal de la serie semanal de eventos (rezagos en semanas).

Evolución de la severidad y extensión territorial. La Figura 5.25 presenta las series semanales de usuarios afectados y duración acumulada: ambas acompañan el incremento de nivel observado en la frecuencia de eventos a partir de 2024, lo que indica que el cambio de régimen no es solo de conteo sino también de impacto sobre la continuidad del servicio. Complementariamente, la Figura 5.26 muestra el número de cuadrantes con al menos un evento por semana, que crece en paralelo: la mayor actividad reciente se distribuye sobre una porción más amplia del territorio y no se explica por unos pocos cuadrantes puntuales.




Figura 5.25: Evolución semanal de usuarios afectados y duración acumulada.




Figura 5.26: Número de cuadrantes con al menos un evento por semana (extensión territorial de la actividad).

En síntesis, el análisis temporal sobre D_{EDA} revela: (i) un cambio de nivel de la serie a partir de 2024, reinterpretado como mayor homogeneización de la codificación activo/sitio bajo OMS-SP7, y no como incremento operativo aislado,

lo que motiva la restricción del dataset de modelado a D_{mod} (2024–2025; Sección 5.3.5); (ii) estacionalidad intra-anual en la actividad de interrupciones, cuya atribución al régimen de lluvias no se sostiene con el acumulado semanal de precipitación (Sección 5.3.7); y (iii) fuerte persistencia semanal con componente anual, que fundamenta el uso de rezagos temporales como predictores en D_{mod} . Estos hallazgos orientan la generación de ventanas temporales y la partición de datos de la Etapa 4.

Materialización de D_{mod} . Para operacionalizar la delimitación temporal sin alterar el insumo exploratorio, se construyó el archivo `data_agrupada_mod.csv` como subconjunto de `data_agrupada.csv` con filtro `year(semana) ∈ {2024, 2025}`, conservando el grano cuadrante $\times$ semana y el conjunto completo de variables climáticas y operativas. La tabla original 2021–2025 permanece intacta como D_{EDA} ; el resultado filtrado (36.120 filas; 344 cuadrantes; 105 semanas; 33.410 eventos) constituye el insumo analítico para las Secciones 5.3.6 en adelante y la Etapa 4, con partición natural entrenamiento 2024 / prueba 2025. El procedimiento reproducible, lectura, filtro, resumen por año y exportación, se documenta en el Apéndice A.3.10.

5.3.6. Identificación de patrones, tendencias y visualización exploratoria

Con fundamento en la delimitación de D_{mod} (Sección 5.3.5), se identifican patrones temporales, espaciales y de asociación clima–evento sobre la tabla `data_agrupada_mod.csv` (36.120 filas cuadrante $\times$ semana; 344 cuadrantes; 105 semanas; 33.410 eventos en 2024–2025). En esta misma subsección se integra la **visualización exploratoria** sobre D_{mod} : series de tiempo, diagramas de dispersión y mapas temáticos que complementan el análisis cuantitativo de patrones. El procedimiento reproducible se documenta en el Apéndice A.3.11.

Patrones temporales. La Figura 5.27 presenta la serie semanal territorial de eventos en D_{mod} , con media de ≈ 318 eventos por semana. Aunque las etiquetas del eje horizontal se muestran cada 3 meses para facilitar la lectura, cada tramo de la línea corresponde a observaciones semanales consecutivas. La intensidad promedio asciende de 287 eventos/semana en 2024 a 350 en 2025. La estacionalidad mensual (Figura 5.28) confirma la heterogeneidad entre meses observada en la Sección 5.3.5 sobre D_{EDA} , sin que el acumulado semanal de lluvia explique ese patrón. La ACF de la serie semanal (Figura 5.29) mantiene persistencia elevada (rezago 1 = 0.80), lo que respalda el uso de rezagos como predictores en la Etapa 4.




Figura 5.27: Evolución semanal de eventos sobre D_{mod} (2024–2025).




Figura 5.28: Estacionalidad mensual del total semanal de eventos en D_{mod} .




Figura 5.29: Persistencia y estructura temporal de la serie semanal de eventos en D_{mod} .

Patrones espaciales. El ranking de cuadrantes por total de $n_eventos$ (Figura 5.30) y el mapa de intensidad territorial (Figura 5.32) evidencian heterogeneidad espacial: los diez cuadrantes más activos concentran el 20.5 % de los eventos del periodo, mientras el 14.2 % de los cuadrantes (49 de 344) se clasifica en nivel de actividad *alta* (Figura 5.34). La actividad no se distribuye de forma uniforme sobre la malla de 800 cuadrantes, sino que se agrupa en zonas de mayor exposición operativa.




Figura 5.30: Quince cuadrantes con mayor número acumulado de eventos en D_{mod} .

La Figura 5.31 complementa el ranking anterior con la **ubicación geográfica** de los cuadrantes más activos sobre la malla territorial del área de estudio. Los recuadros resaltados corresponden a los primeros cuadrantes *top* del periodo 2024–2025 y muestran una concentración en cuatro zonas: (i) el área metropolitana de Cúcuta y Villa del Rosario; (ii) un corredor al suroccidente, en torno a Salazar, Arboledas, Durania y Chinácota; (iii) la subregión de Tibú, al norte del departamento; y (iv) los municipios de Ocaña y Aguachica, al occidente. Esta distribución espacial confirma que la mayor actividad de interrupciones no es aleatoria, sino que se agrupa en núcleos urbanos y corredores de servicio de la red.

Patrones clima–evento. Mediante la estimación de la correlación de Spearman a nivel cuadrante $\times$ semana, las variables de viento exhiben la asociación positiva más fuerte con $n_eventos$ ($viento_max_semana: \hat{\rho} = 0.14$; $viento_medio_semana: \hat{\rho} = 0.14$; $p < 0.001$), seguidas de la precipitación acumulada semanal ($precip_total_semana: \hat{\rho} = 0.07$) y la humedad ($\hat{\rho} = 0.05$). La Figura 5.33 ilustra la relación entre precipitación y frecuencia de eventos: la nube muestra una tendencia




Figura 5.31: Ubicación geográfica de los cuadrantes *top* con mayor acumulado de eventos en D_{mod} (2024–2025). Los recuadros resaltados identifican la posición espacial de los primeros cuadrantes del ranking.




Figura 5.32: Intensidad territorial de eventos por cuadrante (2024–2025).

positiva leve, sin un patrón fuerte. Las temperaturas presentan asociaciones débiles y negativas ($|\hat{\rho}| < 0.05$). En el grano semanal, por tanto, la señal climática es de magnitud modesta y está encabezada por el viento, no por la lluvia.




Figura 5.33: Relación entre precipitación semanal y frecuencia de eventos por cuadrante en D_{mod} .

En síntesis, el análisis de patrones y la visualización exploratoria sobre D_{mod} confirman: (i) persistencia y estacionalidad temporal (series semanales, estacionali-




Figura 5.34: Segmentación de cuadrantes por nivel de actividad acumulada en D_{mod} .

dad mensual y ACF); (ii) concentración espacial en un subconjunto de cuadrantes (ranking, mapa de intensidad y segmentación por actividad); y (iii) asociación positiva pero débil entre las covariables meteorológicas y la frecuencia de interrupciones, encabezada por el viento y seguida por la precipitación (correlación de Spearman y diagrama de dispersión). Estos hallazgos orientan la selección de variables predictoras y la estratificación territorial de la Etapa 4. Los mapas de calor de correlaciones y el análisis multivariado formal se desarrollan en las Secciones 5.3.7 y 5.3.8.

5.3.7. Análisis de correlación y asociación

Con fundamento en los patrones preliminares de la Sección 5.3.6, se realizó un análisis sistemático de asociación pareada sobre `data_agrupada_mod.csv` (D_{mod} ; 36.120 filas cuadrante $\times$ semana). Dado el carácter asimétrico, cero-inflado y de colas pesadas de las variables operativas (Sección 5.3.4), se empleó el coeficiente de correlación de **Spearman** en lugar de Pearson. El procedimiento reproducible se documenta en el Apéndice A.3.12.

Matriz de asociación global. Se calcularon las correlaciones de Spearman entre las variables operativas (`n_eventos`, `usuarios_afectados`, `elementos_afectados`, `duracion_total`), las siete variables climáticas semanales y las coordenadas geográficas (`altitud`, `latitud`, `longitud`). La Figura 5.35 resume la submatriz clima-operativo. Los pares con mayor asociación absoluta del panel completo concentran redundancia operativa: `usuarios_afectados`–`elementos_afectados` ($\rho = 0.99$), `n_eventos`–`elementos_afectados` ($\rho = 0.98$) y `n_eventos`–`usuarios_afectados` ($\rho = 0.97$). Parte de esta magnitud es **mecánica**: las tres métricas provienen de la misma tabla de eventos, comparten la masa de ceros en semanas sin interrupción

y, al agregarse por suma, crecen juntas cuando aumenta el número de eventos. Por ello no deben interpretarse como evidencia de tres dimensiones independientes ni usarse simultáneamente como respuesta y predictoras; la definición definitiva del rol de la severidad se aplaza a la Etapa 4.




Figura 5.35: Asociación de Spearman entre variables climáticas y operativas en D_{mod} .

Bloque climático: redundancias. En el bloque meteorológico (Figura 5.36) se identificaron **diez** pares con $|\rho| \geq 0.70$, principalmente entre temperaturas (temp_media–temp_max: $\rho = 0.96$; temp_media–temp_min: $\rho = 0.91$) y entre componentes de viento ($\rho = 0.97$). Las temperaturas presentan además asociación negativa moderada con la humedad ($\rho \approx -0.76$ a -0.80) y con el viento ($\rho \approx -0.70$ a -0.81). La precipitación no participa en ninguno de estos pares: su mayor asociación dentro del bloque queda por debajo del umbral, lo que la señala como la única covariable climática no redundante. Estos resultados anticipan **multicolinealidad** entre temperaturas y vientos, y orientan la depuración de variables en la Etapa 4.




Figura 5.36: Correlaciones de Spearman en el bloque climático semanal (D_{mod}).

Bloque operativo. La Figura 5.37 muestra que las cuatro métricas de continuidad y severidad están fuertemente correlacionadas entre sí (ρ entre 0.83 y 0.99), aunque *duracion_total* exhibe una asociación algo menor con *n_eventos* ($\rho = 0.86$) que con las variables de afectación. Frecuencia y duración capturan dimensiones parcialmente distintas; el alcance (*usuarios_afectados*, *elementos_afectados*) queda, en esta construcción, muy alineado con la frecuencia y se trata aquí como diagnóstico exploratorio de severidad, no como predictor independiente.

Clima $\rightarrow$ operativo. La Figura 5.38 y la Tabla 5.26 cuantifican la asociación entre covariables meteorológicas y métricas de interrupción. Todas las asociaciones son estadísticamente significativas, consecuencia esperable del tamaño del panel, pero de magnitud pequeña. Las variables de **viento** encabezan el bloque: *viento_max_semana* con *n_eventos* ($\rho = 0.139$) y *viento_medio_semana* con *n_eventos* ($\rho = 0.135$), con valores del mismo orden frente a *usuarios_afectados* ($\rho \approx 0.12$), *elementos_afectados* ($\rho \approx 0.11$) y *duracion_total* ($\rho \approx 0.11$). La *precip_total_semana* le sigue con asociaciones positivas débiles ($\rho = 0.069$ con *duracion_total* y $\rho = 0.065$ con *n_eventos*), mientras la *humedad* ($\rho \approx 0.05$) y las temperaturas ($|\rho| < 0.05$, con signo negativo) resultan prácticamente irrelevantes en el grano semanal.

Conviene precisar el alcance de este resultado. La magnitud reducida de la asociación no implica ausencia de efecto físico de la lluvia sobre la red, sino




Figura 5.37: Correlaciones de Spearman entre variables operativas en D_{mod} .

que el acumulado semanal por cuadrante es un descriptor grueso del fenómeno: promedia días secos y días de tormenta, y no captura la intensidad horaria ni la coincidencia temporal exacta entre el evento meteorológico y la desconexión. Con este descriptor, la asociación bivariada disponible en el grano cuadrante $\times$ semana es débil, y así se reporta.




Figura 5.38: Coeficientes de Spearman entre variables climáticas y operativas en D_{mod} .

Tabla 5.26: Asociación Spearman entre clima y variables operativas: pares de mayor magnitud (D_{mod} ; panel completo)

Par de variables	Spearman ρ	p -valor
viento_max_semana $\leftrightarrow$ n_eventos	0.139	< 0.001
viento_medio_semana $\leftrightarrow$ n_eventos	0.135	< 0.001
viento_max_semana $\leftrightarrow$ usuarios_afectados	0.125	< 0.001
viento_max_semana $\leftrightarrow$ duracion_total	0.112	< 0.001
precip_total_semana $\leftrightarrow$ duracion_total	0.069	< 0.001
precip_total_semana $\leftrightarrow$ n_eventos	0.065	< 0.001
precip_total_semana $\leftrightarrow$ elementos_afectados	0.056	< 0.001
precip_total_semana $\leftrightarrow$ usuarios_afectados	0.053	< 0.001
humedad_media_semana $\leftrightarrow$ n_eventos	0.054	< 0.001
temp_media_semana $\leftrightarrow$ n_eventos	-0,047	< 0.001

Análisis condicionado. Dado que el 63 % de las filas cuadrante $\times$ semana registra $n_eventos = 0$, se repitió el análisis sobre el subconjunto con al menos un evento (13.351 filas; 37 % del panel). En este régimen la asociación precipitación- $n_eventos$ se atenúa aún más ($\rho = 0.029$) y el viento conserva la primacía ($\rho = 0.097$ para viento_max_semana), lo que indica que la escasa señal climática se concentra en la transición entre semanas sin y con interrupción, y no en la intensidad condicional de los eventos. La Figura 5.39 resume las correlaciones en este subconjunto.

En síntesis, el análisis de correlación sobre D_{mod} confirma: (i) **alta redundancia** entre variables operativas de severidad y entre temperaturas/vientos del bloque climático; (ii) una **señal climática débil en términos bivariados**, encabezada por el viento ($\rho \approx 0.14$) y seguida por la precipitación ($\rho \approx 0.07$); y (iii) **asociaciones prácticamente nulas** de temperatura y humedad en el grano semanal. Estos hallazgos fundamentan conservar viento_medio_semana y precip_total_semana como candidatas climáticas, sujetas a la regla de disponibilidad *ex ante* (reza-go o pronóstico; Sección 3.1.2), la exclusión de variables climáticas redundantes y la fijación de la respuesta en $n_eventos$ y/o duracion_total, dejando usuarios_afectados y elementos_afectados fuera del conjunto de predictoras contemporáneas (impacto posterior). Asimismo advierten que la Etapa 4 no debe apoyarse únicamente en covariables meteorológicas de la misma semana: la estructura temporal y territorial de la propia serie de eventos (Secciones 5.3.5 y 5.3.9) concentra la mayor parte de la señal predictiva disponible. El análisis multivariado formal (VIF, redundancia simultánea) se desarrolla en la Sección 5.3.8.

5.3.8. Evaluación inicial de relaciones multivariadas

Con fundamento en las redundancias bivariadas identificadas en la Sección 5.3.7, se evaluaron las relaciones **simultáneas** entre covariables sobre D_{mod}




Figura 5.39: Correlaciones de Spearman en semanas-cuadrante con $n_eventos > 0$ ($n = 13.351$).

mediante VIF, PCA exploratorio, agrupamiento jerárquico de variables climáticas, correlación parcial y un GLM Poisson de diagnóstico (Sección 3.1.2). El procedimiento reproducible se documenta en el Apéndice A.3.13.

Multicolinealidad climática (VIF). Se estimó un modelo auxiliar lineal $n_eventos \sim \text{bloque climático completo}$ para calcular el factor de inflación de la varianza (VIF) de cada covariable. La Figura 5.40 muestra VIF elevados en $temp_media_semana$ (43.92), $viento_medio_semana$ (24.22), $viento_max_semana$ (22.58), $temp_max_semana$ (17.27) y $temp_min_semana$ (14.37), mientras $precip_total_semana$ (1.50) presenta inflación baja y $humedad_media_semana$ (5.68) apenas moderada. Al restringir el bloque a $precip_total_semana$, $temp_media_semana$, $humedad_media_semana$ y $viento_medio_semana$, los VIF descienden a valores aceptables (máximo 7.21 en temperatura media; Tabla 5.27).




Figura 5.40: Inflación de varianza en el bloque climático (modelo auxiliar $n_eventos \sim \text{clima}; D_{mod}$).

Tabla 5.27: Inflación de varianza con subconjunto climático reducido propuesto para la Etapa 4

Variable	VIF
temp_media_semana	7.21
humedad_media_semana	4.47
viento_medio_semana	3.27
precip_total_semana	1.49

PCA exploratorio del bloque climático. El PCA se aplica aquí como diagnóstico de redundancia entre covariables climáticas, no como fuente de predictoras finales, conforme a lo formalizado en la Sección 3.1.2.

Variables de entrada. Ingresan las siete variables climáticas semanales de D_{mod} ($n = 36.120$ filas cuadrante $\times$ semana; $p = 7$): `temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`, `viento_medio_semana`, `viento_max_semana` y `precip_total_semana`.

Condiciones de aplicación. Las siete son cuantitativas continuas; $n \gg p$; no hay faltantes en D_{mod} ; y se homogenizan mediante estandarización (z -scores; Sección 3.1.2) porque tienen distintas unidades ($^{\circ}\text{C}$, %, m/s, mm). El PCA se ejecuta sobre la matriz de correlaciones implícita en la estandarización (`prcomp` sobre la matriz centrada y escalada). La asociación previa entre variables (Sección 5.3.7) justifica el análisis: temperaturas y vientos están fuertemente intercorrelacionados, mientras la precipitación es relativamente independiente. Se reconoce que `precip_total_semana` es asimétrica; el ejercicio permanece exploratorio y se interpreta junto con VIF y el dendrograma.

Varianza retenida y pesos (loadings). Las dos primeras componentes condensan el 87.3 % de la varianza (PC1: 66.9 %; PC2: 20.4 %) y PC3 aporta un 8.3 % adicional (acumulado 95.6 %; Figura 5.41). La Tabla 5.28 y la Figura 5.42 reportan las cargas; se interpretan como variables relevantes en cada componente aquellas con $|loading| \geq 0.40$ (Sección 3.1.2):

- **PC1 (eje térmico–viento):** dominan las temperaturas (`temp_media_semana` 0.45, `temp_max_semana` 0.43, `temp_min_semana` 0.43), con cargas negativas de viento (`viento_medio_semana` -0.40 , `viento_max_semana` -0.39). La precipitación es irrelevante en este eje (-0.08).
- **PC2 (eje de humedad–lluvia):** la variable más importante es `precip_total_semana` (0.70), seguida de `humedad_media_semana` (0.51).
- **PC3:** contrastan precipitación (-0.66) y viento máximo (-0.43) frente a humedad (0.32), con contribución adicional del viento medio (-0.37).

En síntesis, las temperaturas (y, en sentido opuesto, el viento) concentran el peso en PC1, mientras la precipitación, variable de mayor interés operativo, concentra su importancia en PC2–PC3. Ello respalda conservar precipitación como predictora no redundante y depurar temperaturas/vientos extremos del conjunto reducido.

Tabla 5.28: Cargas (loadings) del PCA climático: peso de cada variable por componente (D_{mod} ; PC1-PC3)

Variable	PC1	PC2	PC3
temp_media_semana	0.45	-0,07	-0,22
temp_max_semana	0.43	-0,12	-0,28
temp_min_semana	0.43	0.11	-0,10
humedad_media_semana	-0,33	0.51	0.32
viento_medio_semana	-0,40	-0,33	-0,37
viento_max_semana	-0,39	-0,33	-0,43
precip_total_semana	-0,08	0.70	-0,66

Nota: se destacan como relevantes en la interpretación las cargas con valor absoluto ≥ 0.40 .




Figura 5.41: Varianza acumulada del bloque climático por componente principal.




Figura 5.42: Peso (loadings) de las variables climáticas en las tres primeras componentes principales.

Agrupamiento jerárquico. El dendrograma de la Figura 5.43 confirma dos clusters principales: (i) temperaturas y vientos, altamente intercorrelados; y (ii) `precip_total_semana`, relativamente aislada. Este resultado valida la exclusión de `temp_max_semana`, `temp_min_semana` y `viento_max_semana` del conjunto predictor reducido.




Figura 5.43: Agrupamiento de redundancias entre variables climáticas (Sección 3.1.2).

Asociación multivariada clima $\rightarrow$ n_eventos. La correlación parcial de Spearman entre precipitación y n_eventos, controlando temp_media_semana y viento_medio_semana, es $\rho = 0.114$, casi el doble del valor bivariado ($\rho = 0.065$). El aumento al condicionar indica que temperatura y viento actuaban como confusores que enmascaraban parcialmente la señal de lluvia; aun así, la magnitud sigue siendo modesta. Un GLM Poisson exploratorio con el subconjunto reducido (Figura 5.44) arroja coeficientes positivos y significativos para las cuatro covariables, con la temperatura media estandarizada ($\hat{\beta} = 0.81$) y el viento medio estandarizado ($\hat{\beta} = 0.73$) como efectos dominantes, seguidos de la humedad ($\hat{\beta} = 0.35$) y de la precipitación en transformación logarítmica desplazada ($\hat{\beta} = 0.13$; todos con $p < 0.001$). Este contraste con el orden bivariado, donde las temperaturas eran irrelevantes, es consistente con la multicolinealidad diagnosticada por el VIF y refuerza que los coeficientes del bloque climático completo no admiten lectura causal individual; se reportan como diagnóstico exploratorio.




Figura 5.44: Efecto conjunto del clima reducido sobre la frecuencia de eventos (diagnóstico EDA).

Dimensiones del bloque operativo. De forma análoga, se aplica un PCA exploratorio al bloque operativo de D_{mod} para delimitar dimensiones de impacto, no para construir predictoras.

Variables de entrada y condiciones. Ingresan las cuatro métricas n_eventos, usuarios_afectados, elementos_afectados y duracion_total ($n = 36.120$; $p = 4$), tras transformación logarítmica desplazada y estandarización (Sección 3.1.2), dadas la cero-inflación, la asimetría y las distintas escalas. Son cuan-

titativas, $n \gg p$ y no presentan faltantes.

Pesos e interpretación. PC1 concentra el 83.8 % de la varianza, con cargas elevadas y del mismo signo en las cuatro variables (Tabla 5.29; Figura 5.45): las más importantes son usuarios_afectados (0.53) y n_eventos (0.52), seguidas de elementos_afectados (0.50) y duracion_total (0.45). PC2 (11.9 %; acumulado 95.7 %) contrasta duración (0.81) frente a afectación (elementos_afectados -0.48 ; usuarios_afectados -0.33). Ello respalda no emplear simultáneamente las cuatro variables operativas como respuestas ni como predictoras, y construir *SAIFI* y *SAIDI* en la Etapa 4 a partir de usuarios_afectados y duracion_total. usuarios_afectados entra en el numerador de Y , pero queda excluido como predictora contemporánea para evitar fuga de información; elementos_afectados se reserva al diagnóstico de severidad (Sección 3.1.2).

Tabla 5.29: Cargas (loadings) del PCA operativo en escala logarítmica desplazada (D_{mod} ; PC1-PC2)

Variable	PC1	PC2
n_eventos	0.52	0.09
usuarios_afectados	0.53	-0.33
elementos_afectados	0.50	-0.48
duracion_total	0.45	0.81

Nota: se interpretan como relevantes las cargas con valor absoluto ≥ 0.40 .




Figura 5.45: Peso (loadings) de frecuencia, afectación y duración en las dos primeras componentes del bloque operativo.

En síntesis, la evaluación multivariada sobre D_{mod} recomienda: (i) predictoras climáticas precip_total_semana, temp_media_semana, humedad_media_semana y viento_medio_semana, justificadas por loadings, VIF y dendrograma (el PCA

no se usa como modelo predictivo, sino como diagnóstico de redundancia); (ii) *SAIFI* y *SAIDI* como variables respuesta del modelado, construidas en la Etapa 4; (iii) exclusión de temperaturas extremas y viento máximo por redundancia simultánea; (iv) expectativas moderadas sobre la capacidad explicativa del bloque meteorológico contemporáneo, dado el tamaño reducido de las asociaciones observadas, lo que hace aconsejable complementarlo con rezagos de la propia serie de eventos y con la estratificación territorial; y (v) uso de *usuarios_afectados* solo en el numerador de Y , no como predictora contemporánea. Estos criterios se operacionalizan en la depuración cuantitativa y la construcción de matrices de diseño de la Etapa 4.

5.3.9. Segmentación exploratoria

Con fundamento en la segmentación territorial introducida en la Sección 5.3.6, se profundizó la heterogeneidad de D_{mod} mediante perfiles comparativos por nivel de actividad, evolución 2024–2025, estratificación por régimen de precipitación semanal y clustering multivariado de cuadrantes. El procedimiento reproducible se documenta en el Apéndice A.3.14.

Perfiles por nivel de actividad. Sobre los 344 cuadrantes del periodo, la clasificación Baja/Media/Alta (cuantiles P50 y P85 entre cuadrantes con eventos) arroja: 162 cuadrantes baja (47.1 %), 113 media (32.8 %) y 49 alta (14.2 %); 20 cuadrantes (5.8 %) no registraron eventos. Los perfiles acumulados (Tabla implícita en Figura 5.47) muestran escalamiento marcado en las variables operativas: media de 22 eventos por cuadrante en nivel baja frente a 114.6 en media y 344.7 en alta, con usuarios afectados medios de 1.588 a 88.534. El clima, en cambio, no acompaña ese escalamiento: la precipitación semanal media desciende ligeramente de 19.6 mm (baja) a 18.5 mm (media) y 17.0 mm (alta), de modo que los estratos de mayor actividad no son los más lluviosos. La Figura 5.46 confirma que la dispersión semanal de *n_eventos* crece con el estrato territorial.

Evolución 2024 vs 2025 por estrato. El total territorial ascendió de 15.211 eventos en 2024 (287/semana) a 18.199 en 2025 (350/semana). Al desagregar por nivel fijado en el periodo completo, el ratio medio 2025/2024 es homogéneo: 1.24 (baja), 1.26 (media) y 1.24 (alta), lo que indica incremento transversal sin reordenamiento fuerte de la jerarquía territorial (Figura 5.48). El crecimiento observado en 2024–2025 debe interpretarse en coherencia con la homogeneización de codificación activo/sitio bajo OMS-SP7 (Sección 5.3.5), no exclusivamente como deterioro operativo.




Figura 5.46: Distribución semanal de $n_eventos$ por nivel de actividad del cuadrante (D_{mod}).




Figura 5.47: Perfil normalizado por nivel de actividad (eventos, usuarios, duración, semanas activas, clima).




Figura 5.48: Eventos acumulados por nivel de actividad y año en D_{mod} .

Régimen climático semanal. Se estratificaron las filas según el percentil 75 de `precip_total_semana` (24.7 mm). Las semanas lluviosas (25 % de las filas; 9.030 observaciones) presentan media de `n_eventos` de 0.918, prácticamente igual a la de las semanas secas (0.927; 75 %; 27.090 filas), con 37.7 % frente a 36.7 % de semanas con al menos un evento. La prueba de Wilcoxon no detecta diferencia significativa ($p = 0.175$; Figura 5.49), resultado consistente con la débil asociación bivariada precipitación–eventos de la Sección 5.3.7. La dicotomización por umbral resulta así insuficiente para separar regímenes operativos: si la lluvia tiene efecto, opera a través de la intensidad de episodios puntuales y no del acumulado semanal, lo que sugiere explorar en la Etapa 4 indicadores de intensidad diaria o de número de días de lluvia dentro de la semana.

Clustering multivariado de cuadrantes. Se aplicó k-means ($k = 4$) sobre cuadrantes con al menos un evento, con variables estandarizadas de frecuencia, severidad, duración, clima y altitud (Sección 3.1.2; excluyendo covariables de varianza nula). El mapa de la Figura 5.50 y el heatmap de la Figura 5.51 distinguen: C3 (1 cuadrante; 2.224 eventos; hub extremo), C1 (139 cuadrantes; media 107.4 eventos; mayor severidad y duración acumulada, altitud media 496 m), C4 (126 cuadrantes; media 97.7 eventos; el estrato de mayor altitud, 1.741 m) y C2 (58 cuadrantes; media 68.0 eventos; el más lluvioso, 26.2 mm semanales, y el de menor duración acumulada). Que el cluster más lluvioso sea también el de menor actividad refuerza que la precipitación no ordena por sí sola el territorio; la altitud y el perfil de severidad discriminan más. La existencia de un hub aislado y de estratos con perfiles distinguibles respalda evaluar modelado global frente a estratificación por cluster en la Etapa 4.




Figura 5.49: n_eventos según régimen de precipitación semanal (umbral P75).




Figura 5.50: Perfiles territoriales de cuadrantes según actividad y clima ($k = 4$; D_{mod}).




Figura 5.51: Perfil medio por cluster de cuadrantes (variables operativas y climáticas).

En síntesis, la segmentación exploratoria sobre D_{mod} evidencia: (i) heterogeneidad territorial persistente (14.2 % de cuadrantes en nivel alta concentran actividad desproporcionada); (ii) incremento homogéneo 2024→2025 en todos los estratos; (iii) **ausencia** de diferencia significativa en la frecuencia de interrupciones entre semanas lluviosas y secas cuando la lluvia se mide como acumulado semanal; y (iv) cuatro perfiles espaciales distinguibles por clustering, ordenados principalmente por severidad y altitud más que por régimen de lluvia. Estos criterios orientan la estratificación territorial y la partición entrenamiento/prueba de la Etapa 4.

5.3.10. Resultados y entregables de la etapa

La Etapa 3 sobre D_{mod} (2024–2025; 36.120 filas cuadrante $\times$ semana) produjo un diagnóstico exploratorio integrado: calidad y distribución de variables (Secciones 5.3.1–5.3.4), delimitación temporal y materialización del panel de modelado (Sección 5.3.5), patrones y visualización (Sección 5.3.6), correlación bivariada (Sección 5.3.7), evaluación multivariada con recomendación de predictoras y respuesta (Sección 5.3.8) y segmentación territorial (Sección 5.3.9). Los hallazgos convergentes son: (i) señal climática contemporánea **débil** en el grano semanal (viento por delante de precipitación); (ii) **redundancia** en bloques operativo y climático que justifica subconjuntos reducidos, con la severidad (usuarios_afectados, elementos_afectados) altamente alineada a n_eventos en parte por construcción; (iii) **taxonomía de tres grupos** (Sección 3.1.2): predictoras disponibles *ex ante*, respuestas SAIFI/SAIDI, e impacto posterior excluido como predictor contemporáneo; (iv) **heterogeneidad espacial** y clusters territoriales que sugieren estratificación en el modelado; y (v) **partición natural**

entrenamiento 2024 / prueba 2025 bajo cobertura homogénea de emparejamiento evento–elemento. Los informes HTML reproducibles se consolidan en el Apéndice A.3; el **entregable ejecutivo consolidado** corresponde al Apéndice A.3.15 (síntesis de las Secciones 5.3.1–5.3.10 con hallazgos, figuras representativas y lineamientos para la Etapa 4). La ingeniería de variables de la Etapa 4 operacionaliza esa taxonomía, incluidos rezagos climáticos/operativos y, si procede, la reelaboración de la métrica de severidad solo con fines descriptivos.

Resultado: conocimiento exploratorio del comportamiento de los datos y hallazgos relevantes para el modelado.

Entregable: Documento de análisis descriptivo y exploratorio (EDA), Apéndice A.3.15.

5.4. Etapa 4 – Ingeniería de variables y preparación del modelo

A partir de los hallazgos del EDA y de la taxonomía de la Sección 3.1.2, en esta etapa se transforma el dataset consolidado en una representación analítica adecuada para el entrenamiento de modelos. El criterio rector es evitar **fuga de información**: solo entran como predictoras variables disponibles *antes* de la semana t a pronosticar. Las actividades incluyen la definición formal de la variable respuesta, la construcción de predictoras informadas por el EDA (clima rezagado o pronosticado, histórico de eventos, rasgos del cuadrante, estacionalidad), la depuración y codificación de covariables, la estandarización de variables continuas y la partición temporal entrenamiento/prueba. `usuarios_afectados` y `elementos_afectados` se tratan como **impacto posterior**: el primero entra en el numerador de *SAIFI* y *SAIDI*, pero ninguno se habilita como predictora contemporánea. El preprocesamiento, incluida la selección de variables con base en el EDA, se concentra aquí, en coherencia con estabilidad numérica, identificabilidad y validez operativa del pronóstico.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.4.1. Construcción de variables predictoras

Se construyen únicamente variables del grupo **disponibles antes del periodo a pronosticar**: (i) clima rezagado ($t - 1, \dots, t - h$) o, cuando exista, clima pronosticado para t con fecha de emisión anterior al inicio de la semana; (ii) histórico de eventos del cuadrante (conteos o duraciones rezagadas) y, si procede, de vecinos espaciales; (iii) características del cuadrante (altitud, tipología de zona, número de activos, usuarios totales del inventario); (iv) estacionalidad y calendario (mes,

semana del año, indicadores de régimen). Quedan **excluidas** como predictoras contemporáneas `usuarios_afectadost`, `elementos_afectadost`, `n_eventost` y `duracion_totalt` al pronosticar `SAIFIt` o `SAIDIt`.

5.4.2. Construcción de la variable respuesta

Las respuestas son $Y_t = \text{SAIFI}_t$ y $Y'_t = \text{SAIDI}_t$, calculadas en cada fila cuadrante $\times$ semana como

$$\text{SAIFI}_{q,s} = \frac{\text{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \quad \text{SAIDI}_{q,s} = \frac{\text{duracion_total}_{q,s} \times \text{usuarios_afectados}_{q,s}}{UT_{m(s)}}, \quad (5.1)$$

donde $UT_{m(s)}$ es el valor mensual de usuarios totales del sistema (`CS1_UT_M` en `data_usuarios_totales_sistema.csv`) correspondiente al mes calendario de la fecha de inicio de la semana s . `n_eventos` y `duracion_total` no se modelan como Y : permanecen como insumos de construcción y como historial rezagado. `elementos_afectados` no entra en Y ni como predictora contemporánea.

5.4.3. Análisis de asociación y depuración de variables cuantitativas

Se define el conjunto candidato *ex ante* sobre D_{mod} (clima rezagado, histórico de eventos, rasgos del cuadrante, exposición y estacionalidad) y se excluyen, por diseño, el clima contemporáneo, la respuesta alterna contemporánea y el impacto posterior (`usuarios_afectados`, `elementos_afectados`). La depuración se estima solo con el entrenamiento (2024) y combina filtros de cobertura, varianza casi nula, asociación de Spearman con corrección FDR, agrupamiento por redundancia ($|\rho| \geq 0.70$) y eliminación iterativa por VIF (umbral 5). No se borran variables del panel: se depuran de la matriz de diseño.

De 27 candidatas se retienen 13 (Figuras 5.52–5.54): precipitación rezagada y acumulada, humedad rezagada, viento máximo rezagado, rezagos de `n_eventos`, estacionalidad armónica, altitud, longitud y $\log(\text{n_activos}+1)$ como *offset*. Las temperaturas y los promedios móviles del histórico se descartan por redundancia o multicolinealidad. Detalle reproducible en el Apéndice A.3.16.

5.4.4. Análisis de asociación y depuración de variables cualitativas

5.4.5. Codificación de variables categóricas

5.4.6. Estandarización de variables cuantitativas

5.4.7. Generación de ventanas temporales

5.4.8. Partición de datos en entrenamiento y prueba

Con fundamento en el diagnóstico de cobertura del emparejamiento evento–elemento (Sección 5.3.5), el universo de estimación se restringe a D_{mod} : observa-




Figura 5.52: Asociación de Spearman entre candidatas *ex ante* y *SAIFI* (entrenamiento 2024).




Figura 5.53: Agrupamiento jerárquico de candidatas ($1 - |\rho|$ Spearman); la línea punteada marca el umbral $|\rho| = 0.70$.




Figura 5.54: VIF del conjunto cuantitativo retenido tras la depuración iterativa (umbral 5).

ciones cuadrante $\times$ semana con $\text{year}(\text{semana}) \in \{2024, 2025\}$, periodo en el que la coincidencia entre COMPONENTE_FALLADO y el inventario GIS (`tipo_elemento.csv`) alcanza al menos el 79.8 %, frente a $\approx 31\%$ en 2021–2023 bajo OMS-SPARD. La partición temporal propuesta asigna las observaciones de **2024** al conjunto de entrenamiento y las de **2025** al conjunto de prueba, preservando el orden cronológico y la validez de la validación en series autocorrelacionadas (ACF reza go 1 = 0.92 en D_{EDA}). Los años 2021–2023 no se incluyen en el entrenamiento ni en la prueba del modelo predictivo, dado el sesgo por incompatibilidad entre código de activo y código de sitio.

5.4.9. Construcción de matrices de diseño

5.4.10. Reducción de dimensionalidad

5.4.11. Segmentación analítica

5.4.12. Transformaciones adicionales para modelado

5.4.13. Resultados y entregables de la etapa

Resultado: dataset analítico listo para entrenamiento y validación del modelo.

Entregable: Reporte técnico de ingeniería de variables y dataset analítico documentado.

5.5. Etapa 5 – Modelado predictivo y evaluativo

En esta etapa se desarrollan y evalúan diversos modelos estadísticos y de aprendizaje automático. La selección del enfoque (supervisado, no supervisado o híbrido) se determina según los hallazgos del análisis exploratorio, la naturaleza de los datos disponibles y los requerimientos de interpretabilidad. La evaluación comparativa considera métricas de error como *RMSE*, *MAE* y *MAPE*, así como la estabilidad del modelo y la validez de supuestos. Adicionalmente, se realiza un análisis de importancia de variables mediante técnicas interpretables, para identificar los factores operativos, técnicos o climáticos que influyen de manera significativa en la calidad del servicio.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

- 5.5.1. Selección de algoritmos
- 5.5.2. Entrenamiento del modelo
- 5.5.3. Validación del modelo
- 5.5.4. Ajuste de hiperparámetros
- 5.5.5. Evaluación de desempeño
- 5.5.6. Comparación de modelos
- 5.5.7. Interpretación de resultados
- 5.5.8. Resultados y entregables de la etapa

Resultado: modelo predictivo validado y evaluado técnicamente.

Entregables: Informe de evaluación comparativa de modelos predictivos y reporte técnico de importancia de variables.

5.6. Etapa 6 – Cierre metodológico, documentación y reportes

En la etapa final se consolidan los resultados del proyecto y se documentan de forma integral las técnicas aplicadas, las transformaciones realizadas y el código reproducible (en R o Python). El capítulo incluye apéndices técnicos, tablas de validación, bibliografía y lineamientos de reproducibilidad, así como una discusión orientada a interpretar los hallazgos en términos técnicos y operativos para la toma de decisiones del operador de red.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.6.1. Presentación de resultados del modelo**5.6.2. Métricas de desempeño****5.6.3. Hallazgos principales****5.6.4. Interpretación técnica y operativa****5.6.5. Generación de reportes****5.6.6. Discusión de resultados****5.6.7. Limitaciones y trabajos futuros****5.6.8. Resultados y entregables de la etapa**

Resultado: documentación final del proyecto y resultados consolidados.

Entregables: Compendio de documentación del proyecto (informe final, informe descriptivo, informe de evaluación de modelos y reporte técnico de variables relevantes), código reproducible y documentación detallada de procesos y transformaciones.

5.7. Relación entre etapas metodológicas y objetivos específicos

La Tabla 5.30 sintetiza cómo cada etapa de la metodología contribuye a los objetivos específicos formulados en el Capítulo 2. Los objetivos no se reformulan aquí: se indica únicamente su correspondencia con las etapas, de modo que la trazabilidad entre el diseño metodológico y el alcance del proyecto quede explícita.

En síntesis, las Etapas 1 y 2 materializan el OE1; las Etapas 3 y 4 sustentan el OE2; la Etapa 5 concentra el OE3 (con apoyo interpretativo al OE2); y la Etapa 6 cierra el ciclo con el OE4.

Tabla 5.30: Correspondencia entre etapas de la metodología y objetivos específicos

Etapas	Objetivo(s)	Aporte metodológico
Etapa 1 – Extracción de datos (Sección 5.1)	OE1	Recolección e integración de fuentes internas y externas; repositorio analítico unificado y catálogo de calidad.
Etapa 2 – Integración y depuración (Sección 5.2)	OE1	Construcción del panel activo $\times$ día, agregación cuadrante $\times$ semana y trazabilidad entre sistemas.
Etapa 3 – EDA (Sección 5.3)	OE2	Diagnóstico de faltantes y extremos; patrones temporales, espaciales y estacionales; correlación y segmentación exploratoria.
Etapa 4 – Ingeniería de variables (Sección 5.4)	OE2	Definición de respuesta y predictoras (incl. el rol o reelaboración de la severidad), depuración, transformaciones y partición temporal de entrenamiento y prueba.
Etapa 5 – Modelado predictivo (Sección 5.5)	OE2, OE3	Entrenamiento, validación y comparación de modelos; análisis de importancia de variables.
Etapa 6 – Cierre y documentación (Sección 5.6)	OE4	Documentación reproducible, reportes técnicos y artefactos orientados al uso operativo y regulatorio.

6

Resultados

6.1. Resultados de la estimación del modelo

Discusión y trabajo futuro

7.1. Discusión

7.2. Trabajos futuros

Conclusiones

- 8.1. Conclusión asociada al objetivo general
- 8.2. Conclusión asociada al objetivo específico 1
- 8.3. Conclusión asociada al objetivo específico 2
- 8.4. Conclusión asociada al objetivo específico 3

Bibliografía

- [1] Comisión de Regulación de Energía y Gas (CREG), «Resolución CREG 015 de 2018 – Por la cual se establecen los indicadores de calidad del servicio de energía eléctrica y las fórmulas de compensación,» CREG, Bogotá, Colombia, inf. téc., 2018. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0015_2018.htm
- [2] S.-S. de Servicios Públicos Domiciliarios, «Resolución SSPD 20192200020155,» Superintendencia de Servicios Públicos Domiciliarios, inf. téc., 2019, [On-line; accessed 2025-11-23]. dirección: <https://www.superservicios.gov.co/node/5072>
- [3] IEEE Power and Energy Society, «IEEE Std 1366-2012: IEEE Guide for Electric Power Distribution Reliability Indices,» IEEE, New York, USA, inf. téc., 2012.
- [4] Y. Wang y S. Chen, «Modern reliability assessment of power distribution systems: A data-driven approach,» *Energies*, vol. 12, n.º 15, pág. 2857, 2019.
- [5] J. M. A. Ospina y T. L. López, «Efecto de variables meteorológicas en la confiabilidad del servicio eléctrico en Colombia,» *Revista Energética Colombiana*, vol. 18, n.º 2, págs. 67-75, 2020.
- [6] D. M. Pérez y L. J. Echeverría, «Aplicación de herramientas de analítica de datos para la mejora de indicadores de calidad eléctrica en redes de distribución,» *Ingeniería y Desarrollo*, vol. 39, n.º 1, págs. 25-40, 2021.
- [7] Y. L. Huang y Z. M. Zhang, «Application of deep learning to predict SAIDI and SAIFI indicators in smart grids,» *IEEE Transactions on Smart Grid*, vol. 11, n.º 6, págs. 5153-5163, 2020.
- [8] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Circular 063 de 2019 – Criterios técnicos para el cálculo de indicadores de calidad del servicio de energía eléctrica,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, Circular 063, 2019, [En línea]. dirección: [https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/\\$FILE/Circular063-2019.pdf](https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/$FILE/Circular063-2019.pdf)

- [9] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Informe de Calidad del Servicio de Energía Eléctrica 2023,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, inf. téc., 2024, [En línea]. Disponible en: <https://www.superservicios.gov.co>. dirección: <https://www.superservicios.gov.co>
- [10] U. de Planeación Minero Energética (UPME), «Plan de Expansión de Referencia Generación - Transmisión 2023 - 2037,» Unidad de Planeación Minero Energética (UPME), inf. téc., 2023.
- [11] R. J. A. Little y D. B. Rubin, *Statistical Analysis with Missing Data*, 3.^a ed. Hoboken, NJ, USA: John Wiley & Sons, 2019.
- [12] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.
- [13] G. E. P. Box y D. R. Cox, «An Analysis of Transformations,» *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 26, n.º 2, págs. 211-252, 1964.
- [14] G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5.^a ed. Hoboken, NJ, USA: John Wiley & Sons, 2015.
- [15] C. Spearman, «The Proof and Measurement of Association between Two Things,» *The American Journal of Psychology*, vol. 15, n.º 1, págs. 72-101, 1904.
- [16] H. Cramér, *Mathematical Methods of Statistics*. Princeton, NJ, USA: Princeton University Press, 1946.
- [17] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.^a ed. Melbourne, Australia: OTexts, 2021. dirección: <https://otexts.com/fpp3/>
- [18] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2.^a ed. New York, NY, USA: Springer, 2009.
- [19] C. Bergmeir y J. M. Benítez, «On the Use of Cross-Validation for Time Series Predictor Evaluation,» *Information Sciences*, vol. 191, págs. 192-213, 2012. DOI: [10.1016/j.ins.2011.12.028](https://doi.org/10.1016/j.ins.2011.12.028)
- [20] I. T. Jolliffe, *Principal Component Analysis*, 2.^a ed. New York, NY, USA: Springer, 2002.
- [21] L. Kaufman y P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. New York, NY, USA: John Wiley & Sons, 1990.

-
- [22] J. MacQueen, «Some Methods for Classification and Analysis of Multivariate Observations,» en *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, Berkeley, CA, USA: University of California Press, 1967, págs. 281-297.
 - [23] M. H. Kutner, C. J. Nachtsheim, J. Neter y W. Li, *Applied Linear Statistical Models*, 5.^a ed. New York, NY, USA: McGraw-Hill/Irwin, 2005.
 - [24] R. M. O'Brien, «A Caution Regarding Rules of Thumb for Variance Inflation Factors,» *Quality & Quantity*, vol. 41, n.º 5, págs. 673-690, 2007. DOI: [10.1007/s11135-006-9018-6](https://doi.org/10.1007/s11135-006-9018-6)
 - [25] P. McCullagh y J. A. Nelder, *Generalized Linear Models*, 2.^a ed. London, UK: Chapman & Hall, 1989.
 - [26] A. C. Cameron y P. K. Trivedi, *Regression Analysis of Count Data*, 2.^a ed. Cambridge, UK: Cambridge University Press, 2013.
 - [27] K. Xie, H. Zhang y C. Singh, «Reliability forecasting models for electrical distribution systems considering component failures and planned outages,» *International Journal of Electrical Power & Energy Systems*, vol. 78, págs. 337-346, 2016. DOI: [10.1016/j.ijepes.2016.01.020](https://doi.org/10.1016/j.ijepes.2016.01.020)
 - [28] S. Das, P. Kankanala y A. Pahwa, «Outage Estimation in Electric Power Distribution Systems Using a Neural Network Ensemble,» *Energies*, 2021. DOI: [10.3390/en14164797](https://doi.org/10.3390/en14164797)
 - [29] M. Angalakudati et al., «Improving emergency storm planning using machine learning,» en *2014 IEEE PES T&D Conference and Exposition*, 2014. DOI: [10.1109/TDC.2014.6863406](https://doi.org/10.1109/TDC.2014.6863406)
 - [30] D. Owerko, F. Gama y A. Ribeiro, «Predicting Power Outages Using Graph Neural Networks,» en *IEEE Global Conference on Signal and Information Processing*, 2018. DOI: [10.1109/GLOBALSIP.2018.8646486](https://doi.org/10.1109/GLOBALSIP.2018.8646486)
 - [31] D. Cerrai, P. L. Watson y E. N. Anagnostou, «Assessing the effects of a vegetation management standard on distribution grid outage rates,» *Electric Power Systems Research*, 2019. DOI: [10.1016/j.epsr.2019.105909](https://doi.org/10.1016/j.epsr.2019.105909)
 - [32] R. Eskandarpour y A. Khodaei, «Machine Learning Based Power Grid Outage Prediction in Response to Extreme Events,» *IEEE Transactions on Power Systems*, 2017. DOI: [10.1109/TPWRS.2016.2631895](https://doi.org/10.1109/TPWRS.2016.2631895)
 - [33] C. Rudin et al., «Machine Learning for the New York City Power Grid,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012. DOI: [10.1109/TPAMI.2011.108](https://doi.org/10.1109/TPAMI.2011.108)

- [34] L. Xu, M.-Y. Chow, J. Timmis y L. Taylor, «Power Distribution Outage Cause Identification With Imbalanced Data Using Artificial Immune Recognition System (AIRS) Algorithm,» *IEEE Transactions on Power Systems*, 2007. doi: [10.1109/TPWRS.2006.889040](https://doi.org/10.1109/TPWRS.2006.889040)
- [35] L. Breiman, «Random Forests,» *Machine Learning*, 2003. doi: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324)
- [36] S.-R. Han, S. D. Guikema, S. M. Quiring, K. H. Lee, D. V. Rosowsky y R. A. Davidson, «Estimating the spatial distribution of power outages during hurricanes in the Gulf coast region,» *Reliability Engineering & System Safety*, 2009. doi: [10.1016/j.ress.2008.02.018](https://doi.org/10.1016/j.ress.2008.02.018)
- [37] F. Yang, D. W. Wanik, D. Cerrai, M. A. E. Bhuiyan y E. N. Anagnostou, «Quantifying Uncertainty in Machine Learning-Based Power Outage Prediction Model Training: A Tool for Sustainable Storm Restoration,» *Sustainability*, 2020. doi: [10.3390/su12041525](https://doi.org/10.3390/su12041525)
- [38] P. Kankanala, S. Das y A. Pahwa, «AdaBoost+: An Ensemble Learning Approach for Estimating Weather-Related Outages in Distribution Systems,» *IEEE Transactions on Power Systems*, 2013. doi: [10.1109/TPWRS.2013.2281137](https://doi.org/10.1109/TPWRS.2013.2281137)
- [39] Y. Kor, M. Reformat y P. Musilek, «Predicting Weather-related Power Outages in Distribution Grid,» en *IEEE Power & Energy Society General Meeting*, 2020. doi: [10.1109/PESGM41954.2020.9281829](https://doi.org/10.1109/PESGM41954.2020.9281829)
- [40] M. Doostan y B. Chowdhury, «Predicting Lightning-Related Outages in Power Distribution Systems: A Statistical Approach,» *IEEE Access*, 2020. doi: [10.1109/ACCESS.2020.2991923](https://doi.org/10.1109/ACCESS.2020.2991923)
- [41] P.-C. Chen y M. Kezunović, «Fuzzy logic approach to predictive risk analysis in distribution outage management,» en *IEEE Power & Energy Society General Meeting*, 2017. doi: [10.1109/PESGM.2017.8274298](https://doi.org/10.1109/PESGM.2017.8274298)
- [42] J. He, D. W. Wanik, B. Hartman, E. N. Anagnostou, M. Astitha y M. Frediani, «Nonparametric Tree-Based Predictive Modeling of Storm Outages on an Electric Distribution Network,» *Risk Analysis*, 2017. doi: [10.1111/risa.12652](https://doi.org/10.1111/risa.12652)
- [43] H. Hou et al., «Spatial distribution assessment of power outage under typhoon disasters,» *International Journal of Electrical Power & Energy Systems*, 2021. doi: [10.1016/j.ijepes.2021.107169](https://doi.org/10.1016/j.ijepes.2021.107169)
- [44] M. Li et al., «Prediction of Power Outage Quantity of Distribution Network Users under Typhoon Disaster Based on Random Forest and Important Variables,» 2021. doi: [10.1155/2021/6682242](https://doi.org/10.1155/2021/6682242)

-
- [45] C. Zhai, T. Y.-J. Chen, A. White y S. D. Guikema, «Power outage prediction for natural hazards using synthetic power distribution systems,» *Reliability Engineering & System Safety*, 2021. DOI: [10.1016/j.ress.2020.107348](https://doi.org/10.1016/j.ress.2020.107348)
 - [46] D. Zhu, D. Cheng, R. Broadwater y C. Scirbona, «Storm modeling for prediction of power distribution system outages,» *Electric Power Systems Research*, 2007. DOI: [10.1016/j.epsr.2006.08.020](https://doi.org/10.1016/j.epsr.2006.08.020)
 - [47] A. Arif y Z. Wang, «Distribution Network Outage Data Analysis and Repair Time Prediction Using Deep Learning,» en *IEEE International Conference on Probabilistic Methods Applied to Power Systems*, 2018. DOI: [10.1109/PMAPS.2018.8440354](https://doi.org/10.1109/PMAPS.2018.8440354)
 - [48] D. W. Wanik, E. N. Anagnostou, B. Hartman, M. Frediani y M. Astitha, «Storm outage modeling for an electric distribution network in Northeastern USA,» *Natural Hazards*, 2015. DOI: [10.1007/s11069-015-1908-2](https://doi.org/10.1007/s11069-015-1908-2)
 - [49] A. Jaech, B. Zhang, M. Ostendorf y D. S. Kirschen, «Real-Time Prediction of the Duration of Distribution System Outages,» *IEEE Transactions on Power Systems*, 2018. DOI: [10.1109/TPWRS.2018.2860904](https://doi.org/10.1109/TPWRS.2018.2860904)
 - [50] D. Sorokin, «Machine learning application for power systems reliability assessment,» en *E3S Web of Conferences*, vol. 461, 2023. DOI: [10.1051/e3sconf/202346101032](https://doi.org/10.1051/e3sconf/202346101032)
 - [51] Z. Liu, J. Li, T. Zhang y J. Shao, «Rapid Calculation of Active Distribution Network Reliability Based on Dynamic Equipment Failure Rate,» *Energies*, vol. 16, n.º 14, 2023. DOI: [10.3390/en16145245](https://doi.org/10.3390/en16145245)
 - [52] E. Avcı, «Hybrid Artificial Intelligence Techniques for Enhanced Electricity Outage Prediction and Management in Distribution Networks,» *Turkish Journal of Electrical Power and Energy Systems*, 2024. DOI: [10.5152/TEPES.2024.24008](https://doi.org/10.5152/TEPES.2024.24008)
 - [53] J. Krstivojević y J. S. Terzić, «Enhancing Reliability Performance in Distribution Networks Using Monte Carlo Simulation for Optimal Investment Option Selection,» *Applied Sciences*, págs. 1-26, 2025.
 - [54] NASA Langley Research Center (LaRC) POWER Project, *NASA Prediction of Worldwide Energy Resources (POWER): Data Access Viewer and API documentation*, <https://power.larc.nasa.gov/>, Financiado por el programa NASA Earth Science/Applied Science; en línea, 2024.
 - [55] P. Chapman et al., «CRISP-DM 1.0: Step-by-step data mining guide,» SPSS Inc., inf. téc., 2000, Cross-Industry Standard Process for Data Mining.

-
- [56] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política de Gestión de Tecnologías de la Información*, Sesión Junta Directiva No. 800, feb. de 2018.
- [57] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política Sistema de Gestión Integrado*, Sesión Junta Directiva No. 831, abr. de 2020.
- [58] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Instrumentos de gestión de información pública*, <https://www.cens.com.co/transparencia-y-acceso-a-la-informacion-publica/instrumentos-de-gestion-de-informacion-publica>, En línea; consultado, 2024.

Anexos

A.1. Diagrama de integración del panel

La Figura A.1 presenta el diagrama de flujo de la secuencia de integración descrita en la Sección 5.2.1, desde las fuentes de origen hasta el panel consolidado activo $\times$ día.




Figura A.1: Estructura del panel de datos activo-día

A.2. Código de extracción de datos

Esta sección consolida el código de extracción utilizado en la Etapa 1 de la metodología (consultas SQL y fragmentos Python). En el cuerpo del documento se describe el procedimiento y se referencia el listado correspondiente.

A.2.1. Consultas SQL

Eventos de interrupción (BRAE)

```
1 SELECT DISTINCT FDD_CODIGOEVENTO AS ID_EVENTO
2     ,FDD_FINICIAL AS FECHA_DESCONEXION
3     ,FDD_FFIMAL AS FECHA_CONEXION
```



```

4      , '' AS ELEMENTO_FALLADO
5 FROM BRAE.QA_TFDDREGISTRO
6 WHERE TO_CHAR(FDD_FINICIAL, 'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
7      AND FDD_EXCLUSION = 'NO EXCLUIDA'
8      AND FDD_CAUSA_SSPD NOT IN (1)
9      AND FDD_FFINAL IS NOT NULL;

```

Listado A.1: Consulta SQL de extracción y depuración de eventos de interrupción (BRAE)

Afectación por evento (BRAE + QA_TTC1)

```

1 SELECT FDD_CODIGOEVENTO AS ID_EVENTO
2      , COUNT(FDD_CODIGOELEMENTO) AS CANTIDAD_ELEMENTOS_FALLADOS
3      , SUM(CANTIDAD_USUARIOS) AS CANTIDAD_USUARIOS
4 FROM BRAE.QA_TFDDREGISTRO
5 LEFT JOIN (
6     SELECT TC1_CODCONEX AS TRANSFORMADOR
7           , COUNT(TC1_CODCONEX) AS CANTIDAD_USUARIOS
8           , TC1_PERIODO AS PERIODO
9     FROM QA_TTC1
10    WHERE SUBSTR(TC1_PERIODO, 1, 4) IN ('2021', '2022', '2023', '2024', '2025')
11    GROUP BY TC1_PERIODO, TC1_CODCONEX
12 ) ON FDD_CODIGOELEMENTO = TRANSFORMADOR
13    AND FDD_PERIODO_TC1 = PERIODO
14 WHERE TO_CHAR(FDD_FINICIAL, 'YYYY') IN ('2021', '2022', '2023', '2024', '2025')
15      AND FDD_EXCLUSION = 'NO EXCLUIDA'
16      AND FDD_CAUSA_SSPD NOT IN (1)
17      AND FDD_FFINAL IS NOT NULL
18 GROUP BY FDD_CODIGOEVENTO;

```

Listado A.2: Consulta SQL de afectación por evento (elementos y usuarios)

Elemento causante histórico (OMS SPARD)

```

1 SELECT CODE AS CODIGO_MANIOBRA
2      , BREAKER AS ELEMENTO_FALLADO
3 FROM OMS.MANIOBRAS@SPARD
4 WHERE TO_NUMBER(TO_CHAR(FECHA, 'YYYY')) >= 2021
5      AND CAUSA != 'PRUEBA';

```

Listado A.3: Consulta SQL del elemento causante histórico (OMS SPARD)

Inventario georreferenciado (GIS GTECH)

```

1 SELECT
2     nodo_transform_v AS ELEMENTO,
3     coor_gps_lat     AS LATITUD,

```

```

4   coor_gps_lon      AS LONGITUD,
5   coor_z            AS ALTITUD,
6   'Transformador'  AS TIPO,
7   ubicacion
8 FROM ccomun@gtech c
9 JOIN cconectividad_e@gtech USING (g3e_fid)
10 WHERE c.estado = 'OPERACION'
11     AND c.g3e_fno = 20400
12 UNION
13 SELECT
14     r.codigo        AS ELEMENTO,
15     coor_gps_lat     AS LATITUD,
16     coor_gps_lon     AS LONGITUD,
17     coor_z           AS ALTITUD,
18     'Reconectador'  AS TIPO,
19     ubicacion
20 FROM ereconec_at@gtech r
21 JOIN ccomun@gtech c USING (g3e_fid)
22 JOIN cconectividad_e@gtech USING (g3e_fid)
23 WHERE c.estado = 'OPERACION';

```

Listado A.4: Consulta SQL del inventario georreferenciado de activos (GIS GTECH)

La consulta del Listado A.4 se replica de forma análoga para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador, homologando el tipo de activo en cada bloque UNION.

A.2.2. Fragmentos Python

Elemento causante actual (OMS SP7)

```

1 columnas_necesarias = ['Maniobra Apertura', 'Tipo Elemento', 'Elemento_Falla']
2 df = pd.read_csv(ruta_actual)
3 df.columns = df.columns.str.strip()
4 df = df[columnas_necesarias].drop_duplicates()

```

Listado A.5: Fragmento Python de lectura y depuración del elemento causante actual (OMS SP7)

Parámetros meteorológicos (NASA POWER)

```

1 parametros_nasa = ("PRECTOT", "T2M", "T2M_MAX", "T2M_MIN", "RH2M", "WS2M")

```

Listado A.6: Definición de parámetros meteorológicos extraídos de NASA POWER

A.3. Informes reproducibles (HTML)

Los procedimientos de extracción, integración y análisis exploratorio descritos en la metodología se documentan de forma reproducible en informes HTML publicados en el repositorio del proyecto (GitHub Pages). En el cuerpo del documento se cita el apartado correspondiente de este apéndice; los hipervínculos a cada informe se concentran aquí.

A.3.1. Consolidación del panel activo-día

Informe `Consolidada.html`: detalle de los pasos 5.2.1.4 a 5.2.1.8 de integración hacia el panel consolidado. [Abrir informe](#).

A.3.2. Agrupación cuadrante $\times$ semana

Informe `data_agrupacion.html`: construcción de la tabla de análisis a grano cuadrante $\times$ semana. [Abrir informe](#).

A.3.3. Datos faltantes (tabla agrupada)

Informe `missing_values_grouped.html`: diagnóstico de valores faltantes en `data_agrupada.csv`. [Abrir informe](#).

A.3.4. Valores extremos (panel consolidado)

Informe `detection_outliers.html`: identificación de valores extremos en el panel activo $\times$ día. [Abrir informe](#).

A.3.5. Valores extremos (tabla agrupada)

Informe `outliers_gruped.html`: identificación de valores extremos en la tabla cuadrante $\times$ semana. [Abrir informe](#).

A.3.6. Estadísticos descriptivos

Informe `calculo_estadistico_descriptivo.html`: cálculo de estadísticos descriptivos sobre la tabla agrupada. [Abrir informe](#).

A.3.7. Distribución de variables

Informe `distribucion_variables.html`: análisis de la forma de las distribuciones (densidades, asimetría, curtosis y ceros). [Abrir informe](#).

A.3.8. Análisis temporal de eventos

Informe `analisis_temporal_eventos.html`: series semanales, estacionalidad y autocorrelación de eventos. [Abrir informe](#).

A.3.9. Emparejamiento evento–elemento

Informe `emparejamiento_eventos.html`: cobertura anual de la trazabilidad entre eventos BRAE e inventario GIS. [Abrir informe](#).

A.3.10. Materialización de D_{mod}

Informe `consolidado_data_mod.html`: filtro y exportación del dataset de modelado 2024–2025. [Abrir informe](#).

A.3.11. Identificación de patrones

Informe `identificacion_patrones.html`: patrones temporales, espaciales y clima–evento sobre D_{mod} . [Abrir informe](#).

A.3.12. Análisis de correlación

Informe `analisis_correlacion.html`: asociaciones de Spearman entre variables climáticas y operativas. [Abrir informe](#).

A.3.13. Análisis multivariado

Informe `analisis_multivariado.html`: VIF, PCA, agrupamiento jerárquico y GLM Poisson exploratorio. [Abrir informe](#).

A.3.14. Segmentación exploratoria

Informe `segmentacion_exploratoria.html`: perfiles por nivel de actividad, régimen de lluvia y clustering de cuadrantes. [Abrir informe](#).

A.3.15. EDA consolidado

Informe `EDA.html`: síntesis ejecutiva del análisis exploratorio (Etapa 3) con hallazgos y lineamientos para la Etapa 4. [Abrir informe](#).

A.3.16. Asociación y depuración de variables cuantitativas

Informe `asociacion_depuracion_cuantitativas.html`: depuración *ex ante* de covariables cuantitativas y exportación de la matriz de diseño. [Abrir informe](#).